경영정보학연구
제27권 제2호, 2025년 5월 http://dx.doi.org/10.14329/isr.2025.27.2.127

HyDE 기반 멀티 홉 검색 기법을 활용한 검색 성능 향상 방안

HyDE-Based Multi-Hop Retrieval Approach for Enhancing Retrieval Performance

김 예 은 (Ye-eun Kim) 광주과학기술원 전기및전자공학전공 학부생
이 재 홍 (Jae-Hong Lee) CJ올리브네트웍스 AI연구소 연구원
원 상 혁 (Sang-Huck Won) CJ올리브네트웍스 AI연구소 연구원
정 우 혁 (Woo-Hyuk Jung) CJ올리브네트웍스 AI연구소 연구원
우 지 환 (Jihwan Woo) AWS Sr. Specialist Partner SA AI/ML, 교신저자

요 약

생성형 인공지능과 대형 언어 모델(LLM)의 발전은 기업의 업무 프로세스에 혁신을 가져오며 도메인 특화된 업무를 처리하기 위한 맞춤형 LLM 도입을 촉진하고 있다. 그러나 LLM의 환각(hallucination) 문제와 도메인 적합성 부족을 해결하기 위한 Retrieval-Augmented Generation(RAG) 시스템은 검색 단계에서 복잡한 멀티 홉 질의 처리 시 오류 누적 문제로 인해 성능 저하를 겪는다. 본 연구는 이러한 문제를 해결하기 위해 Hypothetical Document Embedding(HyDE) 기법을 멀티 홉 검색에 통합하여 RAG 성능을 개선하는 프레임워크를 제안한다. HyDE 기법은 질의의 의미를 반영한 가상 문서를 생성하여 검색 정확성을 향상시키며, 본 연구에서는 복잡한 질의를 단계적으로 단일 홉 질의로 분해하고 각 단계에서 HyDE를 적용하는 방식을 채택하였다. 실험은 검색 정확도를 측정하기 위해 precision@k, recall@k, F1 score, MAP, MRR, hit rate와 같은 지표를 사용하여 진행되었다. 실험 결과 HyDE 기반 멀티 홉 검색은 모든 지표에서 기존 대비 향상된 성능을 보였으며, 특히 recall이 약 19.53%, hit rate가 21.21% 증가하였다. 이는 HyDE가 멀티 홉 검색에서 검색의 정확성을 높이는 데 효과적임을 보여준다. 향후 연구에서는 멀티 홉 검색에 최적화된 데이터셋 개발, 가상 문서 생성 전략의 개선 등을 시도할 수 있을 것으로 기대된다.

키워드 : 검색 기반 생성, 가설 문서 임베딩, 다중 단계 검색, 질의 분해, 대규모 언어 모델, 생성형 인공지능

Ⅰ. 서 론

생성형 인공지능과 대형 언어 모델(Large Language Model, LLM)의 발전은 기업의 업무 프로세스에 혁신적인 변화를 가져오고 있다. 특히 대화형 AI 모델인 ChatGPT를 시작으로 우수한 성능의 LLM 모델이 시장에 등장하고 경쟁이 심화되면서 기업들이 맞춤형 LLM을 구축하기 용이해졌다(Zechen

Ji, 2025). IT 및 비즈니스 시장 조사의 선도 기관인 가트너에 따르면 2026년에는 기업의 20%가 중간 관리자를 AI로 대체할 것이라고 전망했다(Gartner, 2024).

이러한 시류에 맞추어 많은 기업들이 LLM을 활용한 업무용 챗봇 개발을 추진하고 있으나 몇 가지 장애 요인이 존재한다. 먼저 신뢰성 부족이 큰 문제로 나타난다. LLM의 우수한 언어 생성 능력의 이면에는 데이터에 존재하지 않거나 맥락에 부합하지 않는 정보를 생성하는 환각(hallucination) 현상이 존재한다(Yao *et al.*, 2023). 중요한 의사결정이나 고객 지원에 거짓 정보가 반영된다면 기업이 심각한 타격을 입을 수 있다. 또한 사내 챗봇은 회사에서 진행하는 업무, 필수 문서, 작업 처리 방법 등 기업의 특성과 요구에 맞추어 조정되어야 하지만 ChatGPT와 같은 범용 서비스를 통해서는 원하는 수준의 기능을 구현하기 어렵다(Ming Cheung, 2024).

이를 해결하기 위해 오픈 소스 LLM 모델을 기반으로 한 미세 조정(fine-tuning)이나 네이버의 하이퍼클로바 X 같이 자체 LLM 모델을 개발하는 경우도 있다(Ming Cheung, 2024; Yoo *et al.*, 2024). 그러나 이러한 접근은 높은 수준의 기술적 전문성과 대규모 데이터, 그리고 고성능 컴퓨팅 자원을 요구하기 때문에 대부분의 중소기업에게는 현실적인 선택지가 되기 어렵다(이광우, 김수균, 2024). 자체 LLM을 개발하더라도 글로벌 LLM과의 성능 격차를 해소하기 어렵고, 비용 면에서도 경쟁력을 갖추기 어려워 실질적인 대안으로 자리 잡기에는 한계가 있다.

이러한 문제를 극복하기 위해 검색 증강 생성 기법 (Retrieval Augmented Generation, RAG)에 대한 연구가 활발히 진행되고 있다(Lewis *et al.*, 2020). RAG는 검색 엔진을 활용하여 신뢰할 수 있는 데이터베이스에서 정보를 검색하고 이를 기반으로 LLM이 응답을 생성하도록 설계된다. 이 방식은 기존 LLM의 범용성을 유지하면서도 기업의 도메인 특화 요구를 충족할 수 있는 적합한 답변을 제공하며, 환각 문제를 완화하는 데 효과적이다(박대민, 이한종, 2024).

RAG 시스템은 검색 단계에서 코사인 유사도를 기반으로 문서를 선택하지만 높은 유사도를 가진 문서가 질문과 맥락적으로 적합하지 않은 경우 답변의 성능이 저하될 수 있다(Cuconasu *et al.*, 2024). 이러한 현상은 질문과 관련 없는 문서가 프롬프트 컨텍스트에 포함될 경우 모델이 혼란을 겪어 출력의 정확성과 신뢰성이 떨어질 수 있음을 보여준다. 이는 RAG의 주요 한계로 지적되며 검색 단계에서의 성능 개선이 시스템 전체의 성능을 향상시키는 핵심 과제임을 시사한다. 특히 LLM이 지속적으로 발전하고 비용 효율성이 높아지고 있는 상황에서 생성보다 검색의 성능을 개선하는 것이 최종 응답 품질에 더욱 중요한 영향을 미친다.

기존의 단일 홉 검색 방식은 복잡한 질문에 대해 적절한 문서를 찾는 데 한계가 있다. 예를 들어 ‘Google, Apple 및 Nvidia 중 어느 회사가 2023년 3분기 보고서에서 가장 큰 이익 마진을 보고했는가?’와 같이 여러 문서를 검색해야 하는 복잡한 질문에서는 단일 검색으로 모든 요소를 포괄하는 문서를 찾기 어렵다(Tang *et al.*, 2024). 이를 해결하기 위해 제안된 멀티 홉 검색은 복잡한 질문을 여러 하위 질의로 분해하여 순차적으로 검색을 수행함으로써 더 정확한 정보를 찾을 수 있다는 장점이 있다(Tang *et al.*, 2024). 그러나 멀티 홉 검색은 각 단계에서 발생하는 오류가 다음 단계로 전파되어 누적될 수 있으며, 특히 초기 단계에서의 검색 실패가 전체 검색 과정의 실패로 이어질 수 있다는 중대한 취약점을 가지고 있다(Lee *et al.*, 2022).

한편 하이드(Hypothetical Document Embedding, HyDE)는 질문에 대한 가상의 이상적 문서를 LLM을 통해 먼저 생성한 후, 이 가상 문서와 실제 문서 간의 유사도를 측정하여 검색 정확도를 높이는 기법이다(Gao *et al.*, 2022). 단어 수준의 일치율을 기반으로 검색을 수행하던 기존 방식(Robertson and Zaragoza, 2009)과 달리, HyDE는 질문에 대한 풍부

한 정보를 담은 가상 문서를 생성함으로써 질문과 문서 사이의 의미적 연결고리를 강화한다. 이를 통해 단어가 다르더라도 개념상 관련 있는 문서를 더 잘 찾아낼 수 있어 더 정확하고 포괄적인 의미적 유사도 계산이 가능해진다. 이러한 HyDE 방법론은 단일 홉 검색을 전제로 하고 있어 단일 문서 참조로 충분한 경우에는 우수한 성능을 보인다. 그러나 Google, Apple, Nvidia의 분기별 보고서 비교처럼 여러 문서의 정보를 결합해야 하는 복잡한 질의에서는 단일 홉만으로는 충분하지 않을 수 있다.

본 연구는 RAG 시스템의 검색 단계 성능 향상을 위해 멀티 홉 검색과 HyDE를 결합한 새로운 방법론을 제안한다. 두 기법의 결합은 각각의 한계점을 상호보완한다. 먼저 멀티 홉 검색의 주요 약점인 각 단계에서의 검색 정확도 문제를 HyDE를 통해 개선할 수 있다. 각 하위 질의마다 LLM이 생성한 가상의 이상적 문서를 활용함으로써 키워드 기반 검색보다 의미적으로 더 적합한 문서를 찾을 수 있다. 이는 특히 초기 단계의 검색 정확도를 높여 오류 전파 문제를 완화한다. 반대로 HyDE가 단일 홉 검색을 전제로 하고 있어 복잡한 다중 문서 참조 질의에 완전히 대응하기 어려운 점은 멀티 홉 접근법을 통해 해결할 수 있다. <그림 1>은 본 연구에서 제안한 HyDE 기반 멀티 홉 검색 모델의 전체 구조를 보여준다. 이 모델은 복잡한 질문을 하위 질의로 분해한 후, 각 단계에서 HyDE를 활용해 검색 정확도를 높인다.

본 연구의 주요 목표는 다음과 같다. 첫째, 복잡한 질문을 효과적으로 분해하여 단계적 검색을 수행하는 멀티 홉 프레임워크를 개발한다. 둘째, 각 검색 단계에서 HyDE를 적용하여 문서 선택의 정확도를 향상시킨다. 셋째, 제안된 방법론의 효과성을 검증하기 위해 기존 멀티 홉 RAG 시스템과의 비교 실험을 수행한다. 이를 통해 기업용 RAG 시스템의 실용성을 제고하고자 한다.

본 논문은 총 5장으로 구성되어 있다. 제Ⅱ장에서는 RAG 시스템의 이론적 배경과 관련 연구를 살펴보고, 제Ⅲ장에서는 본 연구에서 제안하는 HyDE 기반 다중 단계 검색 기법과 구체적인 구현 방법을 소개한다. 제Ⅳ장에서는 실험 환경과 설정을 상세히 기술하고, 실험 결과를 통해 제안 기법의 성능을 검증한다. 마지막으로 제Ⅴ장에서는 본 연구의 결

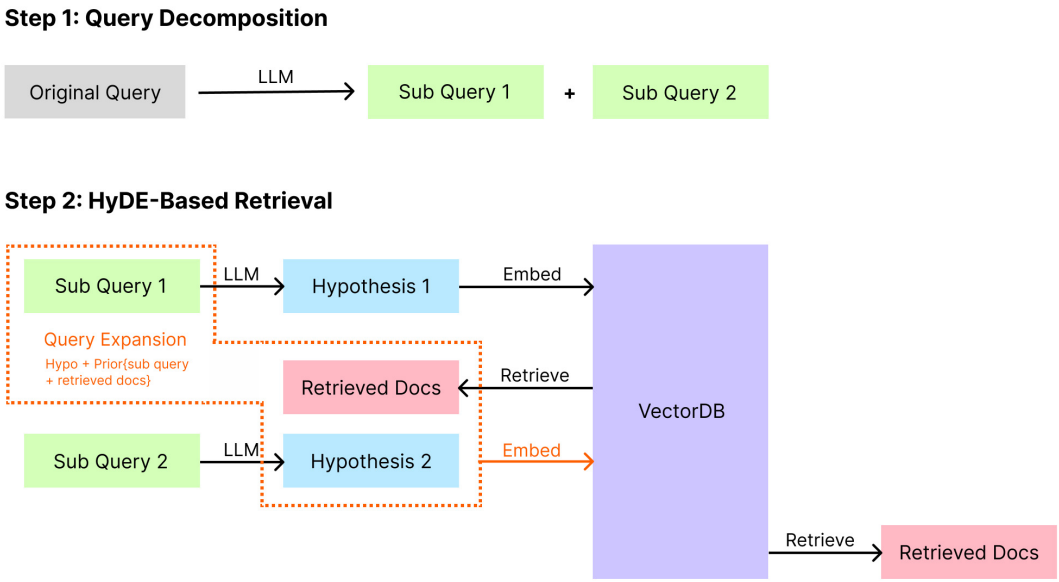

〈그림 1〉 HyDE 기반 멀티 홉 검색 모델 구조

론과 의의, 그리고 향후 연구 방향을 제시한다.

Ⅱ 이론적 배경

본 연구에서 참고한 주요 선행 연구들을 <표 1>로 정리하였다. <표 1>은 RAG 시스템의 구조와 작동 원리, 검색 성능 향상, 멀티 홉 질의응답, 임베딩 기법, 평가 방법론 등과 관련된 주요 연구들을 체계적으로 요약한 것이다. 이를 통해 이론적 배경에서 논의할 RAG 시스템의 핵심 개념과 관련 기술에 대한 기초를 제공하고자 한다. 이후 본 장에서는 RAG 시스템의 기본 개념과 구조를 검토하고, 검색 성능 향상과 평가를 위한 다양한 접근법을 논의한다.

〈표 1〉 RAG 시스템 및 관련 기술에 대한 주요 선행 연구 요약

저자	방법론	연구 내용 및 기여점
A. RAG & Vector DB		
Patrick Lewis *et al.* (2020)	(RAG) 검색 기반 생성	사전 학습된 seq2seq 모델(BART)과 사전 학습된 검색 모델(DPR)을 결합하여 검색된 문서를 기반으로 텍스트를 생성. 기존 생성 모델이 내부 파라미터에 의존하는 것과 달리, 검색된 외부 문서를 활용하여 더 정확하고 최신의 정보를 생성 가능.
Akari Asai *et al.* (2023)	(RAG+LLM) LLM과 벡터DB 기반 검색 생성	LLM과 벡터DB를 결합하여 검색과 생성을 통합. 기존의 RAG와 달리 임베딩 기반 검색(Vector Search)과 LLM을 활용하여 더욱 확장성 높은 검색-생성 구조를 제공.
B. Query Transformation		
Luyu Gao *et al.* (2022)	(HyDE) LLM 기반 가설 문서 임베딩	LLM을 활용해 질의와 관련된 가설 문서를 생성한 뒤, 이를 contrastive encoder로 임베딩하여 검색 수행. 기존 dense retrieval이 질의를 직접 임베딩하는 것과 달리, HyDE는 가설 문서를 생성하고 이를 임베딩하여 문서-문서 유사성을 기반으로 검색을 수행.
Liang Wang, Nan Yang, Furu Wei (2023)	(Query2Doc) LLM 기반 의사(pseudo) 문서 생성	Few-shot 프롬프팅을 통해 의사 문서를 생성하고 이를 원래 질의에 추가하여 검색 성능을 향상. HyDE가 LLM을 통해 생성한 가설 문서로 질의를 대체하는 것과 달리 확장한 질의를 검색에 활용.
Zhihong Shao *et al.* (2023)	(ITERRETGEN) LLM 기반 반복적 검색-생성	LLM의 응답을 활용하여 검색과 생성을 반복적으로 수행. 기존 검색이 질의만을 이용하는 것과 달리 이전에 생성된 응답을 검색 질의로 활용하여 더욱 관련성 높은 정보를 검색.
Xinbei Ma *et al.* (2023)	(RRR) LM 기반 질의 재작성	LLM이 질의를 재작성한 후 웹 검색을 수행하여 검색 성능을 향상. 질의 확장이나 가설 문서 생성과 달리 RRR은 LLM의 출력을 학습하는 소형 모델(rewriter)로 최적화하여 검색 질의를 점진적으로 개선하며 강화 학습을 통해 LLM의 검색 성능을 지속적으로 향상.
C. Multi Hop		
Wenhan Xiong *et al.* (2021)	(MDR) 다중 홉 Dense 검색	이전 검색 결과를 활용하여 질의를 점진적으로 변형하며 다중 홉 검색을 수행. 기존 단일 홉 검색이 개별 문서 검색에 의존하는 것과 달리 MDR은 검색된 문서를 질의와 결합하여 점진적으로 검색을 개선하고 그래프 기반 접근 방식 없이 다중 문서 정보를 통합.
Yixuan Tang, Yi Yang (2024)	(MultiHop-RAG) 다중 홉 검색 기반 RAG 벤치마킹	다중 홉 질의 처리를 위한 RAG 시스템의 성능을 평가하는 벤치마크 데이터셋 구축. 기존 RAG 모델이 단일 문서 검색을 전제로 하는 것과 달리 MultiHop-RAG는 다중 문서를 연쇄적으로 검색·활용하는 실세계 시나리오를 반영하여 LLM 기반 검색 및 생성 성능을 평가.

저자	방법론	연구 내용 및 기여점
Jiahao Zhang *et al.* (2024)	(Beam Retrieval) 빔 서치 기반 다중 홉 검색	다중 홉 질의 응답을 위해 검색 과정 전체를 엔드투엔드 방식으로 최적화. 기존의 단계별 검색 방식과 달리 빔 서치를 활용하여 다중 후보 문서를 유지하며 검색을 수행하여 검색 오류를 줄이고 검색된 문맥의 품질을 개선하여 LLM 및 QA 모델의 성능을 향상.
Zhilin Yang *et al.* (2018)	(HotpotQA) 다중 홉 질의 응답 벤치마크	위키피디아 기반 113K 개의 다중 홉 질의 응답 데이터셋을 구축하여 QA 모델의 복합적인 추론 능력과 설명 가능성을 평가. 기존 단일 문서 기반 QA 데이터셋과 달리 다중 문서를 종합적으로 활용해야 하며 문장 수준의 정답 근거를 제공하여 모델의 해석 가능성을 높임.
Jason Wei *et al.* (2022)	(CoT) 연쇄 추론 프롬프트	LLM이 복잡한 추론 문제를 해결하도록 하기 위해 정답에 도달하는 중간 사고 과정(Chain-of-Thought)을 프롬프트에 포함하여 모델의 추론 성능을 향상. 기존 단순 프롬프팅에선 모델 규모가 증가해도 성능 향상이 제한적인 것과 달리 CoT는 충분히 큰 모델에서 논리적 추론 능력을 자연스럽게 유도하여 산술, 상식, 기호적 추론 문제 해결 능력을 향상.
D. Survey Papers		
Xiaohua Wang *et al.* (2024)	RAG 최적화 연구	RAG 시스템의 각 구성 요소(질의 분류, 검색, 재정렬, 요약 등)를 체계적으로 분석하여 최적의 구현 방식을 탐색. 다양한 조합을 실험하여 성능과 효율성 균형을 고려한 RAG 구현 전략을 제시. 질의 변환 방법론 중 HyDE의 성능이 가장 우수하다는 점과 HyDE 방법론 내에서 가설 문서를 1개만 이용해도 성능에 큰 차이가 없다는 점을 시사.
Yunfan Gao *et al.* (2024)	RAG 연구 개관	LLM 시대의 RAG 발전 패러다임을 Naive RAG, Advanced RAG, Modular RAG로 구분하여 정리하고 검색, 증강, 생성 등 주요 구성 요소를 분석. RAG의 평가 방법, 최신 연구 동향, 향후 연구 방향을 정리하여 RAG 연구의 체계적인 이해를 제공.
E. RAG in Practice		
이광우, 김수균 (2024)	한국어 문장 임베딩과 RAG 기반 지식 검색	한국어 문장 임베딩(Sentence-BERT)과 RAG 구조를 결합하여 기업 문서를 기반으로 질의응답 시스템을 설계. 시스템은 폐쇄망에서 동작하도록 설계되어 기밀 유출 위험을 최소화함.
정진철 등 (2024)	다중 에이전트 및 반복적 답변 생성·평가	오픈소스 LLM을 활용하여 사규 검색용 프라이빗 RAG 시스템을 구축. 다중 에이전트로 답변을 생성하고 단답형 채점 방식을 통해 답변을 정량적으로 평가하며 필요시 질의를 재작성하여 최적의 답변을 도출.
김도현 등 (2024)	웹문서 본문 정제 및 추출 시스템	웹문서의 HTML 태그 구조를 분석하고 코사인 유사도와 태그 문장화를 활용하여 사용자 질의와 관련성이 높은 본문을 효과적으로 추출하여 RAG 성능을 향상시킴.
최은실 (2024)	앙상블 기반 OCR 및 RAG 기술 통합	OCR 프로세스에 이미지 전처리와 하이브리드 정보 추출 모델을 적용하여 텍스트 인식 정확도를 향상시키고, RAG 파이프라인에 레이아웃 분석, Re-ranking 알고리즘, 앙상블 검색기를 적용하여 ESG 문서 검토를 자동화하고 성능을 최적화함.
F. Multilingual Embedding Model		
Jianlv Chen *et al.* (2024)	(M3-Embedding) 다국어 임베딩 모델	100개 이상의 언어를 지원하는 다국어 텍스트 임베딩 모델로, 밀집(dense), 희소(sparse), 다중 벡터(multi-vector) 검색을 통합하여 다양한 검색 기능을 제공. 자기 지식 증류(self-knowledge distillation) 기법을 활용해 학습 효율성을 높이고, 장문(8192 토큰) 처리 성능을 최적화하여 다국어 검색 및 정보 검색(IR) 성능을 향상.

본 장에서는 RAG 시스템의 기본 개념과 구조, 검색 성능 향상을 위한 기존 연구들을 살펴본다. 먼저 RAG의 기본 구조와 작동 원리를 검토하고, 검색 성능 향상을 위한 기존 연구인 멀티 홉 검색과 HyDE에 대해 논의한다. 마지막으로 RAG 시스템의 성능 평가 방법론을 고찰하여 본 연구의 이론적 토대를 마련한다.

2.1 RAG 시스템

RAG는 외부 지식을 활용하여 LLM의 생성 능력을 보완하는 프레임워크로, 검색과 생성을 결합한 통합적 접근 방식을 취한다. LLM은 방대한 양의 텍스트 데이터를 기반으로 학습되어 언어 생성 능력이 뛰어나지만 최신 정보나 특정 도메인 지식에 대한 한계를 지닌다. RAG는 이러한 문제를 해결하기 위해 실시간으로 외부 데이터베이스에서 관련 정보를 검색하여 생성 과정에 통합함으로써 보다 정확하고 신뢰성 있는 응답을 제공한다.

RAG 시스템의 전체적인 과정은 다음과 같다. 먼저 텍스트 데이터를 수집하고 전처리를 거쳐 문서를 일정한 크기의 청크(chunk)로 나눈다. 이러한 청크들은 임베딩 모델을 통해 벡터 공간에 매핑(mapping)되어 벡터 데이터베이스를 구축한다. 사용자의 질의가 입력되면 해당 질의 역시 임베딩 벡터로 변환되어 벡터 데이터베이스에서 유사도가 높은 청크를 검색한다. 검색된 문서들을 컨텍스트(context)라고 하며 이 컨텍스트와 질의를 결합하여 LLM의 프롬프트로 전달한다. 이처럼 LLM은 외부 문서를 참조하여 신뢰성이 높은 응답을 생성할 수 있다.

2.1.1 임베딩 모델

임베딩(Embedding)은 텍스트 데이터를 고차원 벡터로 변환하여 의미적 유사성을 계산할 수 있게 하는 기술이다(Mikolov *et al.*, 2013). 이는 단어, 문장, 문서 등의 텍스트를 실수 벡터로 표현하여 기계 학습 모델이 처리할 수 있도록 한다. RAG 시스템에서 임베딩 모델은 소스 데이터의 각 청크와 사용자 질의를 임베딩 벡터로 변환하여 벡터 데이터베이스에서 유사한 문서를 검색하는 데 핵심적인 역할을 한다. 따라서 적절한 모델의 선택이 검색 성능에 직접적인 영향을 미친다.

대부분의 RAG 시스템에서는 BERT (Bidirectional Encoder Representations from Transformers) 계열 모델이 널리 사용된다(Devlin *et al.*, 2019). BERT는 문맥을 양방향으로 고려하여 텍스트의 의미를 벡터로 표현할 수 있어 기존 단방향 모델보다 문맥 이해도가 뛰어나다. 이후 등장한 RoBERTa(Robustly Optimized BERT Approach)는 학습 전략을 개선하여 더 많은 데이터와 긴 학습 시간, 동적 마스킹(dynamic masking)을 활용함으로써 성능을 극대화하였다(Liu *et al.*, 2019). 이 외에도 검색 및 추천 시스템에서 최적화된 E5(Embeddings from Encoder with n-gram tokenizers) 시리즈는 질의와 문서 간 의미적 유사성을 정확히 측정하는 데 효과적이다.

임베딩 모델의 성능 평가는 Massive Text Embedding Benchmark(MTEB) 등 벤치마크를 통해 이루어진다(Muennighoff *et al.*, 2022). MTEB는 분류, 검색, 군집화 등 8개의 자연어 처리 태스크에서 텍스트 임베딩 모델의 성능을 체계적으로 비교할 수 있는 벤치마크이다. 총 58개의 데이터셋으로 구성되어 있으며, 한국어를 포함한 여러 언어를 지원한다. 각 태스크의 성능 평가는 태스크에 적합한 평가 메트릭을 활용하여 이루어진다. 검색 태스크에서는 recall@k, nDCG@k, MRR 등의 메트릭을 사용하여 모델이 의미적 유사성을 얼마나 잘 반영하는지 측정하며 분류 태스크에서는 Accuracy나 F1 score와 같은 분류 지표를 활용한다. 이러한 체계적인 메트릭 기반 평가를 통해 모델 간 성능 비교가 가능하다. 한국어 임베딩 모델의 성능을 평가하기 위해 MTEB의 한국어 데이터셋을 활용하거나 추가적인 한국어 데이터셋을 구축해 맞춤형 태스크를 설정할 수 있다.

한국어를 지원하는 임베딩 모델로는 multilingual-e5-base(ME5), bge-m3(BGE), jina-embeddings-v3(JE3)

등이 있다(Chen *et al.*, 2024; Jina AI, 2023; Wang *et al.*, 2024). 이들은 다국어 처리를 위해 설계되었으며 한국어 태스크에서도 안정적인 성능을 보이는 것으로 알려져 있다.

ME5는 최대 입력 토큰 수가 514개, 임베딩 차원은 1024, 모델을 로드하고 추론하는 데 약 2.09GB의 메모리가 필요하다. BGE는 최대 입력 토큰 수가 8,192개, 임베딩 차원은 1024, 메모리 사용량은 약 2.11GB이다. JE3는 최대 입력 토큰 수가 8192개, 임베딩 차원은 1024, 메모리 사용량은 약 2.13GB이다.

〈표 2〉 MTEB(Multilingual Text Embedding Benchmark)를 기반으로 한 ME5, BGE, JE3 모델의 검색 성능 비교

모델명	STS Spearman 상관 계수	Retrieval nDCG@10	Reranking MAP
ME5	80.62	54.87	57.55
BGE	83.13	59.98	61.20
JE3	83.50	42.95	56.93

<표 2>에서는 MTEB(Multilingual Text Embedding Benchmark)의 주요 검색 태스크를 기반으로 ME5, BGE, JE3 모델의 성능을 비교하였다. 해당 성능 데이터는 공개된 GitHub 프로젝트에서 수집되었다(Park, 2023). 검색 태스크와 관련된 대표적인 평가지표로는 의미적 유사도를 측정하는 STS(Semantic Textual Similarity) 태스크의 Spearman 상관 계수, 관련 문서를 검색하는 Retrieval 태스크의 nDCG@10, 초기 검색 결과를 재정렬하여 품질을 평가하는 Reranking 태스크의 MAP(Mean Average Precision)을 선정하였다. 이들 지표는 각 모델의 검색 품질을 다각도로 평가하는 데 유용하다.

2.1.2 벡터 데이터베이스

벡터 데이터베이스(Vector Database)는 임베딩된 벡터를 효율적으로 저장하고 검색하는 특화된 데이터베이스로 RAG 시스템에서 핵심적인 역할을 한다. 전통적인 관계형 데이터베이스는 구조화된 데이터의 저장과 검색에 적합하지만 고차원 벡터 형태의 비정형 데이터에 대한 효율적인 검색을 지원하지 못한다. 임베딩된 벡터는 고차원 공간에 위치하며 이러한 벡터 간의 유사도를 빠르게 계산하기 위해 벡터 데이터베이스가 필요하다. 이는 RAG 시스템에서 실시간으로 사용자 질의에 대응하기 위한 필수 요소이다.

벡터 데이터베이스의 기능은 크게 벡터 저장, 인덱싱, 검색 알고리즘으로 구분된다. 인덱싱은 고차원 벡터 공간에서 검색 속도를 향상시키기 위해 설계된 특수한 데이터 구조를 의미하며 근사 최근접 이웃(Approximate Nearest Neighbor, ANN) 검색 방법을 통해 고속 검색을 지원한다. ANN 검색은 정확한 최근접 이웃을 찾는 대신 충분히 유사한 근사치를 빠르게 찾는 방법으로, 대규모 데이터에서 검색 속도를 크게 향상시킬 수 있다.

인덱싱 방법으로는 HNSW(Hierarchical Navigable Small World graphs), IVF(Inverted File Index), PQ(Product Quantization) 등이 사용된다(Jégou *et al.*, 2011; Malkov and Yashunin, 2018). HNSW는 그래프 기반의 인덱스로, 노드 간의 연결을 활용하여 고차원 공간에서 효율적인 검색을 가능하게 한다. IVF는 벡터를 여러 개의 클러스터로 나누어 인버티드 인덱스를 생성하는 방법이며 PQ는 벡터를 서브 벡터로 분할하고 각 부분을 양자화하여 저장함으로써 메모리 사용을 줄이고 검색 효율을 높인다.

검색 알고리즘은 코사인 유사도, 내적(dot product), 유클리드 거리 등 수학적 측정 기준을 기반으로 질의 벡터와 데이터베이스 내 벡터 간의 유사도를 계산한다. 코사인 유사도는 두 벡터 간 각도를 계산해 방향성의 유사도를 측정하며 내적은 벡터의 크기와 방향을 모두 고려한다. 이러한 알고리즘은 질의의 의미적 맥락을 이해하고 유사도가 높은 벡터를 빠르게 검색하여 결과를 반환하는 데 중점을 둔다.

대표적인 벡터 데이터베이스 솔루션으로는 FAISS, Milvus 등이 있다. FAISS(Facebook AI Similarity Search)는 Facebook AI Research에서 개발한 오픈

소스 라이브러리로, 고차원 벡터 데이터 검색을 위한 다양한 인덱싱 및 검색 알고리즘을 제공한다. GPU 가속을 지원하여 대규모 데이터에서도 높은 성능을 발휘한다. Milvus는 대규모 데이터를 처리하기 위해 분산형 아키텍처를 채택한 벡터 데이터베이스로, 실시간 검색과 확장성을 지원하며 클라우드 환경에서도 효율적으로 동작한다.

벡터 데이터베이스를 활용함으로써 RAG 시스템은 대용량의 외부 지식 베이스에서 필요한 정보를 실시간으로 검색하고, 사용자에게 적합한 응답을 제공할 수 있다. 그러나 고차원 벡터 공간에서의 검색은 복잡도가 높아 인덱싱과 검색 알고리즘의 선택이 중요하다. 또한 근사 최근접 이웃 검색은 정확도와 속도 간의 균형을 이루어야 하며, 응용 분야에 따라 적절한 설정이 필요하다.

2.1.3 생성 모델

생성 모델(Generative Model)은 주어진 입력 데이터로부터 새로운 데이터를 생성하는 기계 학습 모델을 의미한다. 자연어 처리 분야에서 생성 모델은 문장이나 단락과 같은 텍스트 데이터를 생성하는데 사용되며 LLM이 그 대표적인 예이다(Brown *et al.*, 2020). 이러한 모델은 방대한 양의 텍스트 데이터를 학습하여 언어의 통계적 패턴과 구조를 이해하고, 이를 기반으로 새로운 문장을 생성할 수 있다.

RAG 시스템에서 생성 모델은 검색 단계에서 얻은 관련 문서를 기반으로 최종 응답을 생성하는 역할을 수행한다. 검색된 문서를 컨텍스트로 프롬프트에 포함하여 모델에 입력하면, 생성 모델은 해당 정보를 활용하여 사용자 질의에 대한 정확하고 유창한 응답을 생성한다. 이는 생성 모델이 외부 지식을 활용하여 환각 현상을 줄이고, 도메인 특화된 지식을 반영한 응답을 생성할 수 있도록 한다.

현대에는 다양한 대형 언어 모델이 개발되어 활용되고 있다. OpenAI의 GPT-3, GPT-4 등은 API를 통해 접근할 수 있어 복잡한 인프라를 구축하지 않고도 강력한 언어 모델의 성능을 활용할 수 있다. Meta의 LLaMA는 모델의 사전 학습 가중치가 공개되어 사용자가 직접 다운로드하고 로컬 환경에서 실행하거나 특정 데이터로 파인 튜닝(fine-tuning)을 수행하여 도메인 특화된 응답을 생성할 수 있다(Touvron *et al.*, 2023). 허깅페이스(Hugging Face)는 Transformers 라이브러리를 통해 다양한 언어 모델을 제공하며 사용자는 사전 학습된 모델을 로컬 환경에 다운로드하거나 특정 태스크에 맞게 조정할 수 있다(Wolf *et al.*, 2020).

생성 모델을 선택할 때는 성능, 라이선스, 비용, 도메인 적합성 등을 고려해야 한다. 또한 RAG 시스템에서 생성 모델을 효과적으로 활용하기 위해서는 적절한 프롬프트 구성과 컨텍스트 관리가 중요하다. 검색된 문서에서 핵심적인 정보를 요약하거나 필요한 부분만 선택하여 프롬프트에 포함시켜야 한다. 모델의 입력 길이 제한을 고려하여 중요한 정보를 우선적으로 반영하고 불필요한 내용을 배제함으로써 효율적인 응답 생성을 지원할 수 있다.

2.2 RAG 시스템의 검색 성능 향상 연구

RAG 시스템의 검색 성능을 향상시키기 위한 연구는 전체 검색 프로세스를 사전 검색(Pre-retrieval), 검색 파이프라인(Retrieval Pipeline), 후처리(Post-retrieval)의 세 단계로 구분하여 진행되어 왔다. 이 과정에서 질의와 문서 간의 의미적 연결성을 강화하고, 효율성을 높이며, 최종 응답 품질을 개선하기 위한 다양한 방법이 제안되었다. 각 단계에서 이루어진 주요 연구들을 구체적으로 살펴보면 다음과 같다.

2.2.1 사전 검색 단계

사전 검색 단계에서는 임베딩 개선과 데이터 전처리를 통해 질의와 문서 간의 표현력을 극대화하는 연구가 이루어졌다. 질의와 문서의 표현력이 높아질수록 벡터 데이터베이스에서 정확한 검색이 가능하기 때문이다. 도메인 특화 임베딩 모델을 학습하면 특정 산업이나 주제에 맞는 검색 성능을

대폭 향상시킬 수 있다. 또한 계층적 임베딩 구조를 도입한 연구는 문장, 단락, 문서 수준에서의 다중 표현을 생성하여 검색의 정밀도를 높였다(Wu *et al.*, 2021).

문서의 레이아웃을 고려하여 텍스트를 추출하는 접근도 제안되었다(최은실, 2024). 이 연구는 다단 구조나 헤더·푸터의 혼재로 인해 발생할 수 있는 문맥 훼손 문제를 완화하고 텍스트의 의미론적 구조를 보존함으로써 검색 단계에서의 데이터 품질을 개선하고자 하였다. 이러한 방식은 긴 문서나 복잡한 레이아웃을 가진 문서에서 검색 성능을 향상시키는 데 유용하게 활용될 수 있다.

추가적으로 웹문서의 HTML 태그 구조를 분석하여 불필요한 데이터를 제거하고 핵심 본문을 추출하는 시스템도 제안되었다(김도현 외, 2024). 이 연구는 코사인 유사도와 태그 문장화를 활용하여 사용자 쿼리와 관련성이 높은 본문을 효과적으로 식별하고 정제된 데이터를 제공함으로써 RAG 시스템의 성능을 개선하였다. 이러한 방법은 웹 문서의 노이즈를 줄이고 최신 정보를 반영한 고품질 데이터를 검색 단계에 제공하는 데 기여한다.

2.2.2 검색 파이프라인 단계

검색 파이프라인 단계에서는 검색 알고리즘을 최적화하여 효율적이고 정확한 문서 검색을 목표로 하는 연구가 주를 이루었다. 멀티 홉 검색은 복잡한 질의에 대한 단계적 검색을 가능하게 하여 단일 홉 검색 대비 평균 35% 이상의 검색 정확도를 달성한 것으로 보고되었다(Tang *et al.*, 2024). 이 과정에서 발생할 수 있는 오류 누적 문제를 해결하기 위해 Zhang *et al.*(2024)은 Beam Retrieval 기법을 도입하여 검색 단계별 다중 가설을 유지하고, 단계별 결과를 최적화하는 방법을 제안하였다.

2.2.3 후처리 단계

후처리 단계에서는 검색된 문서의 순위를 재조정하여 최종 응답의 품질을 개선하는 연구가 이루어졌다. 크로스 인코더(Cross-Encoder) 기반 재순위화는 질의와 검색된 문서를 입력하여 문맥적 상호작용을 반영한 유사도를 계산하며, 기존의 단순 벡터 기반 순위보다 더 높은 정확도를 제공한다(Reimers and Gurevych, 2019).

또한 LLM을 활용한 재순위화 방법은 대형 언어모델의 언어 이해 능력을 바탕으로 검색 결과의 품질을 크게 향상시켰다(Qin *et al.*, 2024). 특히 재순위화 과정에서 중요한 정보를 강조하고, 불필요한 정보는 배제함으로써 응답의 신뢰성과 유창성을 동시에 확보하는 방식을 제안하였다.

다중 에이전트와 반복적 답변 생성 및 평가 방식을 적용한 Self-Corrective RAG 접근도 제안되었다(정진철 외, 2024). 이 연구는 오픈소스 LLM을 활용하여 후보 답변을 생성하고 단답형 채점 방식을 통해 품질을 정량적으로 평가하며, 필요시 질의를 재작성하여 최적의 답변을 도출하는 과정을 포함한다. 이러한 접근은 복잡한 규정을 검색하는 데 적합하며 반복적인 피드백 루프를 통해 응답의 정확성과 신뢰성을 크게 향상시킨다.

2.3 멀티 홉 검색

멀티 홉 검색은 복잡한 질의를 여러 단계로 분해하여 순차적으로 정보를 검색하는 방식으로, 복합적인 추론이 필요한 질문을 해결하는 데 효과적인 접근법이다. 여기서 홉(hop)이란 단일 검색 단계에서 수행되는 검색 및 정보 추출 과정을 의미하며 각 홉의 출력은 다음 단계의 입력으로 활용된다. 이를 통해 질의의 범위를 점진적으로 확장하거나 세분화하며 복잡한 문제를 체계적으로 해결할 수 있다.

멀티 홉 검색은 각 단계에서 질의와 검색 결과를 유기적으로 연결하는 프로세스를 통해 진행된다. 초기에는 사용자의 질의에서 주요 키워드를 추출하여 첫 번째 검색을 수행하고 검색된 문서에서 핵심 정보를 추출한다. 이후 이 정보를 바탕으로 새로운 질의를 생성해 두 번째 검색을 수행하며 이러한 과정이 반복된다. 예를 들어 “세계에서 가장 큰 호수가 위치한 국가의 수도는?”이라는 복합

질의가 주어졌을 때, 첫 번째 홉에서 “세계에서 가장 큰 호수”를 검색하여 “카스피해”라는 결과를 얻고 이를 활용해 두 번째 홉에서 “카스피해가 위치한 국가”를 검색한 뒤 마지막 단계에서 해당 국가의 수도를 검색하는 방식으로 진행된다. 이와 같이 각 단계는 이전 단계에서 얻은 정보를 기반으로 검색 방향을 구체화하여 최종적으로 복합 질의에 대한 응답을 생성한다.

2.4 HyDE 기법

HyDE는 LLM을 활용하여 질의에 대한 가상의 이상적인 문서를 생성하고 이를 임베딩하여 검색에 활용하는 기법이다. HyDE는 기존 키워드 기반이나 임베딩 기반 검색이 질의와 문서 간의 표면적 유사도에 의존하는 한계를 극복하기 위해 개발되었다. 가상 문서는 질의의 의미적 의도를 반영하여 생성되며 이를 통해 검색 성능을 향상시킨다.

HyDE의 작동 과정은 크게 세 단계로 구성된다. 먼저 사용자가 질의를 입력하면 LLM을 활용하여 해당 질의의 응답을 포함할 가능성이 높은 가상 문서를 생성한다. 이 가상 문서는 질의의 의미적 의도를 반영하여 설계되며 생성된 문서는 임베딩 모델을 통해 벡터로 변환된다. 이후 이 벡터를 벡터 데이터베이스에서 검색하여, 데이터베이스 내에서 가장 유사한 문서를 찾아낸다. 최종적으로 검색된 문서를 활용하여 사용자 질의에 적합한 응답을 생성하거나 문제를 해결한다.

예를 들어 사용자가 “지구 온난화의 주요 원인은 무엇인가?”라는 질문을 입력했을 때 LLM은 이에 대한 가상의 응답으로 “지구 온난화의 주요 원인은 화석 연료의 연소로 인한 이산화탄소 배출이다.”라는 문서를 생성한다. 이 가상 문서는 벡터로 변환되어 벡터 데이터베이스 내 문서와 비교되며 검색 결과는 사용자의 질문과 연관성이 높은 문서를 포함하도록 보완된다. 이러한 과정을 통해 HyDE는 검색 결과의 품질을 향상시킨다.

본 연구는 HyDE의 이러한 장점을 활용하여 멀티 홉 검색에서 질의의 의미를 보다 정교하게 반영하고 각 단계의 검색 과정에서 보다 유의미한 결과를 도출하기 위해 HyDE를 통합한다. 특히 복잡한 멀티 홉 질의에서 각 단계의 검색 성능을 강화하는 데 있어 HyDE가 제공하는 가상 문서 생성의 이점은 본 연구의 목적에 부합한다. 이를 통해 HyDE는 질의의 의미적 구조를 보완하고 검색 성능을 극대화하는 데 중요한 기여를 할 것으로 기대된다.

2.5 멀티 홉 검색과 HyDE의 결합에 대한 연구의 필요성

현재 멀티 홉 검색과 HyDE 기법을 결합하여 검색 성능을 향상시키는 연구는 제한적이다. 멀티 홉 검색은 복잡한 질의에 대한 단계적 접근을 제공하지만 각 단계에서의 오류 누적과 계산 비용 증가 문제가 있다. 한편 HyDE는 질의의 의도를 반영한 가상 문서를 통해 검색 정확도를 높일 수 있으나 주로 단일 홉 검색에 적용되어 왔다.

따라서 멀티 홉 검색 과정에서 HyDE를 효율적으로 적용하여 검색 성능을 개선하는 것은 새로운 연구 분야로서 가치가 있다. 본 연구에서는 멀티 홉 검색의 각 단계에서 HyDE를 적용함으로써 질의의 의도를 보다 정확히 반영하고, 오류 누적을 완화할 수 있는 방법론을 제안하고자 한다. 이는 복잡한 질의에 대한 검색 정확도를 높이면서도 계산 효율성을 유지하는 데 기여할 것으로 기대된다.

2.6 RAG 시스템 성능 평가 방법론

RAG 시스템에서의 성능 평가는 검색 단계의 품질을 측정하기 위한 IR 지표와 최종 응답 품질을 평가하기 위한 QA 지표로 나눌 수 있다. 본 연구에서는 RAG 시스템에서 생성단을 배제한 검색 성능 개선을 목표로 삼기 때문에 IR 지표만을 활용한다.

대표적인 IR 지표에는 recall@k, precision@k, hit@k, Mean Average Precision(MAP), Mean Reciprocal Rank(MRR) 등이 있다.

recall@k는 실제 정답이 포함된 문서를 상위 k개 결과 내에서 얼마나 회수(recall)했는지를 평가하는 지표로, 검색 누락을 최소화하는 데 초점을 맞춘다. precision@k는 상위 k개의 문서 중 실제 정답과 관련된 문서의 비율을 나타내어 검색 결과의 정확성을 직관적으로 파악할 수 있도록 한다.

본 연구에서는 검색 결과가 항상 상위 k개의 결과로 제한되므로 precision@k와 recall@k는 전체 검색 결과의 품질을 평가하는 데 사용되며 개념적으로 일반적인 precision과 recall과 동일한 의미로 사용된다. 이를 통해 검색 결과가 상위 k개의 결과로 제한된 상황에서 직관적인 평가를 가능하게 한다. 이후에는 편의상 precision@k와 recall@k를 precision, recall로 칭한다.

$$\text{Recall@K} = \frac{|\{\text{관련 문서}\} \cap \{\text{상위 } K \text{ 문서}\}|}{|\{\text{전체 관련 문서}\}|}$$

$$\text{Precision@K} = \frac{|\{\text{관련 문서}\} \cap \{\text{상위 } K \text{ 문서}\}|}{K}$$

hit@k는 검색 결과 상위 k개의 문서 중 하나라도 정답 문서가 포함되어 있는지를 평가하는 이진 지표로 정의된다. 즉, 질의에 대한 검색 결과 중 상위 k개의 문서 목록에서 하나 이상의 정답 문서가 존재하면 hit@k 값은 1이 되고 그렇지 않으면 0이 된다.

$$\text{Hit@K} = \begin{cases} 1, & \text{상위 K개 검색 결과 중 정답 문서 포함} \\ 0, & \text{그렇지 않음} \end{cases}$$

개별 질의에 대한 hit@k 값을 여러 질의에 걸쳐 평균 내면 hit rate로 확장할 수 있다. hit rate는 전체 질의 집합에 대해 hit@k의 평균값을 계산한 것으로 검색 시스템이 k개의 검색 결과 내에서 정답 문서를 포함할 확률을 나타낸다.

$$\text{Hit Rate} = \frac{1}{N}\sum_{i=1}^{N} \text{Hit@K}_i$$

- Ni: 전체 질의 개수

hit rate는 간단한 측정 방식으로 인해 검색 시스템의 성능을 직관적으로 평가하는 데 유용하지만 검색된 문서의 정렬 순서나 개별 문서의 기여도를 반영하지 않는 한계를 가진다. 검색된 문서의 유사도 순서가 중요한 경우, MAP 또는 MRR과 같은 지표가 적절한 평가 방법이 될 수 있다.

MAP은 검색된 문서의 순위를 고려하여 평균적인 precision을 측정하는 지표로 각 질의별 Average Precision(AP) 값을 계산한 후 전체 질의에 대해 평균을 낸 값으로 정의된다. AP는 검색 결과 내에서 정답 문서가 등장할 때마다 precision 값을 계산하고, 이를 정답 문서 개수로 나눈 값이다.

$$AP = \frac{1}{R}\sum_{k=1}^{N} P(k) \cdot \text{rel}(k)$$

- R: 해당 질의의 전체 정답 문서 개수
- P(k): 상위 k개 문서까지의 precision
- rel(k): 해당 k번째 문서가 정답 문서인지 여부 (1 or 0)

MAP는 모든 질의에 대해 AP 값을 평균하여 계산된다. 검색 시스템이 정확한 문서를 얼마나 높은 순위에 배치하는지 평가하는 데 유용하며 정답 문서가 앞쪽에 위치할수록 높은 점수를 부여한다.

$$MAP = \frac{1}{Q}\sum_{i=1}^{Q} AP_i$$

Q: 전체 질의 개수

MRR은 검색된 문서 목록에서 첫 번째 정답 문서의 위치를 반영하는 지표이다. 이는 사용자가 정답을 찾기 위해 몇 번째 문서까지 확인해야 하는지를 나타내며, Reciprocal Rank(RR)의 평균으로 계산된다. RR은 정답 문서의 최초 등장 위치의 역수로 정의되며 수식은 다음과 같다.

$$MRR = \frac{1}{Q}\sum_{i=1}^{Q} \frac{1}{rank_i}$$

$rank_i$: 해당 질의에서 첫 번째로 등장한 정답 문서의 순위

MRR은 MAP과 마찬가지로 문서의 순위를 고려하지만 첫 번째 정답 문서에만 집중하는 특징이 있다. 따라서 MRR은 사용자가 가장 빠르게 정답을 찾을 수 있도록 검색 시스템을 평가할 때 적절한 지표로 활용된다.

한편 대표적인 QA 지표로는 Exact Match (EM)와 F1 점수가 있다. 이 지표들은 최종적으로 생성된 응답이 정답과 얼마나 유사하거나 동일한지를 평가하기 위한 것으로 QA 성능을 정량화하는 데 활용된다.

EM은 문자열을 기준으로 답변이 정답과 완전히 일치하는지 이진값으로 판단한다. EM은 개별 질문 단위로 측정되며 여러 질문에 대한 평균값을 EM 점수로 삼는다. QA에서 '정확히 일치하는 답변'을 평가할 때 유용하다.

F1 점수는 precision과 recall을 계산한 뒤 이들의 조화 평균을 계산한 것으로, 0에서 1 사이의 값을 가지며 1에 가까울수록 모델의 응답이 정답과 유사성이 높음을 의미한다. 이는 단순한 단어 일치뿐만 아니라 정답과의 부분적 유사성을 반영할 수 있어 EM보다 더욱 유연한 성능 평가가 가능하다. IR에서도 문서 수준에서의 precision과 recall을 동시에 고려해 F1을 계산할 수 있다.

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

복잡한 질의나 멀티 홉 검색에서는 검색된 문서들이 최종 응답 생성에 얼마나 기여했는지도 중요한 평가 요소이다. 이를 위해 최근에는 LLM을 활용한 자동 평가 방법이나 문맥적 적합성을 측정하는 정성적 평가 방법이 제안되었으며(Rahman *et al.*, 2024) 이러한 접근은 기존의 정량적 지표가 포착하지 못하는 문서 간의 논리적 연계성을 평가하는 데 기여할 수 있다. 또한 멀티 홉 검색을 평가하기 위한 전용 벤치마크(예: HotpotQA, MuSiQue)가 활용되며(Yang *et al.*, 2018) 이 벤치마크에서는 각 단계별 정확한 단서를 회수하는 능력과 최종 정답 도출 능력을 종합적으로 평가한다.

Ⅲ. 제안 방법론

본 장에서는 LLM을 활용하여 질의를 단계적으로 분해하여 단일 홉 질문을 멀티 홉으로 변환하고, 각 홉의 검색 과정에 HyDE(Hypothetical Document Embeddings)를 통합하는 HyDE 기반 Chained Retrieval 프레임워크를 제안한다. 이를 통해 복잡한 질의에 대한 정보 검색의 효율성과 정확도를 동시에 개선하는 것을 목표로 한다.

3.1 전체 구조 개요

본 연구의 기본 아이디어는 여러 문서를 참조해야 하는 복잡한 질의를 멀티 홉으로 분할하고 각 홉에서 HyDE 기법을 활용하여 질의 의도를 반영한 가상 문서를 생성한 뒤, 이를 벡터 데이터베이스 검색에 활용하는 것이다.

본 연구에서 제안하는 파이프라인은 다음과 같은 단계를 거친다. 먼저 복잡한 질의를 멀티 홉 형태로 분해한다. 이는 LLM 또는 규칙 기반 접근을 통해 가능하며 복잡한 질의를 각 홉마다 해소 가능한 하위 질의로 재구성한다. 다음으로 각 홉에서 HyDE 기법을 적용한다. 해당 홉의 질의를 LLM에 입력하여 가상의 이상적 문서를 생성하고 이를 임베딩한 뒤 FAISS 벡터 데이터베이스에 질의로 제출한다. FAISS는 코사인 유사도 또는 내적을 기반으로 상위 k개의 유사 문서를 반환한다. 상위 k개의 문서는 이전 질의와 함께 다음 홉으로 전달한다. 이를 통해 매 단계에서 질의 의도를 명확히 하고 필요한 정보만을 점진적으로 축적하여 마지막 홉의 검색 결과를 최적화한다.

마지막 홉에 이르러서는 Retrieval 결과, 즉 상위 k개 문서와 정답을 비교하는 것으로 실험을 종료

한다. 본 연구는 멀티 홉과 HyDE의 결합을 통한 Retrieval 성능 개선을 주목적으로 하기에 LLM을 활용한 최종 응답을 생성하지 않으며 reranking 모델을 적용하지 않는다.

3.2 단계별 프로세스 설계

3.2.1 질의 분해(Question Decomposition)

초기의 단일 홉 질의를 LLM에 입력하여 멀티 홉 형태로 분해한다. LLM에게 질의를 제시하고 "이 질문을 해결하기 위한 하위 질의를 나열하라"는 식의 프롬프트로 질의를 분해한다. 이렇게 얻은 각 홉별 질의는 독립적으로 해결 가능한 단일 홉 형태의 검색 문제로 변환된다.

3.2.2 HyDE 기반 가상 문서 생성 및 검색

각 홉별로 HyDE를 적용한다. 즉 해당 홉 질의를 LLM에 입력하여 가상의 이상적 답변 문서를 생성하고, 이 가상 문서에 이전 단계의 질의와 검색된 문서를 결합하여 질의를 확장한다. 확장된 질의를 임베딩하여 FAISS 벡터 데이터베이스에서 검색을 수행하면 FAISS는 코사인 유사도 또는 내적 등을 활용하여 유사도가 높은 상위 k개 문서를 반환한다. 상위 k개 문서 중 일부는 다음 단계에서 질의를 보완하는 데 직접 활용하거나 핵심 정보 추출 과정을 거쳐 다음 홉 질의에 사용한다.

3.3 성능 평가 및 분석

제안된 프레임워크의 성능은 precision, recall, F1 score, MAP, MRR, hit rate를 기준으로 평가된다. 이러한 지표는 검색 성능의 다양한 측면을 정량적으로 측정할 수 있는 도구로, 프레임워크의 강점과 한계를 파악하고 최적화를 위한 기반을 제공한다.

검색된 문서의 개수 k 값은 평가 지표에 영향을 미칠 수 있다. 일반적으로 k가 증가하면 더 많은 정답 문서를 포함할 가능성이 커지므로 recall과 hit rate는 증가하는 경향을 보인다. 반면, precision은 검색된 문서 중 정답이 차지하는 비율을 고려하기 때문에 k가 커지면 낮아질 수 있다. F1 score는 precision과 recall 간의 균형을 반영하므로 k 값에 따라 증가하거나 감소할 수 있다.

순위 기반 지표인 MAP과 MRR 역시 k 값에 영향을 받지만 단순히 증가한다고 해서 성능이 향상되는 것은 아니다. MAP은 검색된 정답 문서의 전체적인 순위를 고려하기 때문에 정답이 상위에 위치할수록 높은 값을 갖는다. MRR은 첫 번째 정답 문서의 순위에 의존하므로 k가 증가해도 정답이 상위에 배치되지 않으면 값이 크게 변하지 않을 수 있다.

따라서 검색 성능을 평가할 때는 단일 지표만을 고려하는 것이 아니라, 다양한 지표 간의 균형을 분석하는 것이 중요하다. 특히, k 값의 변화가 precision과 recall뿐만 아니라 MAP, MRR, hit rate 등의 지표에도 영향을 미칠 수 있으므로 실험 환경에 따라 적절한 평가 기준을 설정할 필요가 있다.

Ⅳ. 실험 및 결과

4.1 데이터셋 준비

본 실험은 Allganize RAG 평가 데이터셋(Korean) 중 금융 도메인을 활용하여 수행하였다. 이 데이터셋은 다양한 길이의 금융 분야 PDF 문서 10개, 문서의 내용과 관련된 질문 60개가 담긴 CSV로 구성되어 있다. CSV 파일은 각 질문에 대한 정답 문서의 파일명(target file name)과 페이지 번호(target page no)를 제공한다. 해당 데이터셋은 RAG 시스템의 검색 성능 평가를 위해 설계되었으며 정답 문서와 페이지 정보를 기준으로 검색 결과를 평가할 수 있도록 구성되어 있다.

실험에 사용된 원본 문서 데이터는 PDF 형식으로 제공되었으며 이를 활용하기 위해 가공 및 전처리 과정을 거친다. PDF에서 직접 텍스트를 추출하는 기존 방식의 성능을 보완하기 위해 PDF에서 이미지로, 다시 텍스트로 변환하는 3단계로 진행된

다. PDF 파일을 이미지 형식으로 변환하기 위해 pdf2image 라이브러리를 활용하고, 이미지에서 텍스트를 추출하기 위해 사전 학습된 비전-언어 모델인 qwen-VL을 사용한다. 이 모델은 이미지에서 텍스트를 높은 정확도로 추출할 수 있어 PDF 문서 내 텍스트가 복잡한 경우에도 적합한 데이터를 생성할 수 있다.

텍스트 추출이 완료된 문서는 JSON 형식으로 변환되고 각 문서에는 해당 페이지 번호와 파일 이름 등의 메타데이터가 포함된다. 이후 문서 데이터를 검색에 적합한 형태로 가공하기 위해 텍스트를 756자 길이로 분할하며 각 분할은 50자씩가 중첩되도록 처리한다. 각 문서를 Document 객체로 변환한 뒤 FAISS 벡터 데이터베이스를 구축한다.

본 연구에서는 RAG의 생성단은 배제하기 때문에 CSV 파일이 제공하는 정답 문장(target answer)은 사용하지 않으며 검색 단계에서 반환된 문서의 파일명과 페이지 번호가 정답 파일명, 정답 페이지 번호와 얼마나 일치하는지를 기준으로 성능을 평가한다. 질문과 정답 정보는 제공된 CSV 파일에서 불러온다.

4.2 실험 설정 및 구성

4.2.1 실험 환경 및 설정

본 실험은 Google Colab CPU 환경에서 진행되고 벡터 데이터 베이스는 FAISS를 기반으로 구축된다. FAISS는 빠르고 효율적인 벡터 검색을 가능하게 하며 문서 간의 코사인 유사도 또는 내적을 기반으로 검색을 수행한다. 임베딩 생성에는 BAAI/bge-m3 모델을 사용한다. 해당 모델은 문서와 질의 간의 의미적 유사성을 효과적으로 반영하는 사전 학습된 언어 모델이다. 질의 분해 및 HyDE 기반 가상 문서 생성을 위한 LLM 모델은 Groq사에서 무료로 제공하는 LLaMA3-8B 언어 모델을 활용한다.

4.2.2 검색 시험 조건 및 프로세스

본 실험은 검색 프레임워크의 성능을 비교하기 위해 일반 멀티 홉 검색과 HyDE 기반 멀티 홉 검색 두 가지 실험 구성으로 진행된다. <그림 2>는 두 실험 구성의 개요를 나타낸다.

첫 번째 실험은 멀티 홉 검색으로, 복잡한 질의를 두 개의 하위 질의로 분해하여 단계적으로 검

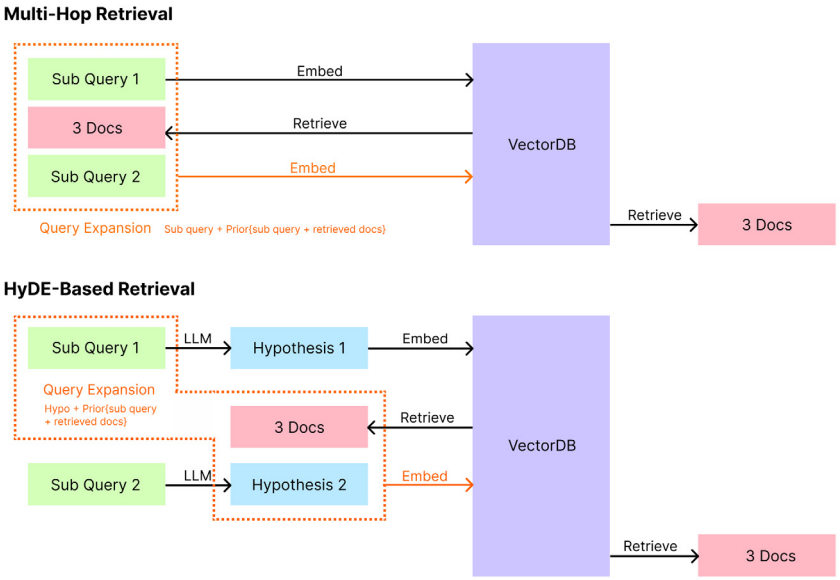

〈그림 2〉 멀티 홉 검색과 HyDE 기반 멀티 홉 검색

색을 수행한다. 이 설정에서 각 하위 질의는 독립적으로 벡터 데이터베이스에 제출되어 상위 k=3개의 문서를 반환한다. 첫 번째 홉의 하위 질의와 검색 결과 쌍은 두 번째 하위 질의와 결합되어 질의를 확장하고, 확장된 질의를 벡터 데이터베이스에 임베딩하여 최종적으로 상위 k=3개의 문서를 검색한다.

두 번째 실험은 HyDE 기반 멀티 홉 검색으로, 각 하위 질의에 대해 HyDE 기법을 적용하여 가상의 이상적 문서(Hypothesis)를 생성한다. LLM을 이용해 생성된 가상 문서는 벡터 데이터베이스에 제출되어 검색 질의로 활용된다. 첫 번째 홉의 하위 질의와 검색 결과 쌍은 두 번째 가상 문서와 결합되어 검색에 사용되는 질의를 확장한다. 첫 번째 홉과 마찬가지로 하위 질의가 직접적으로 임베딩되는 것이 아니라 가상 문서가 검색에 사용되기 때문에 질의 확장을 위해 하위 질의가 아닌 가상 문서를 이용한다. 확장된 질의를 이용해 최종 검색을 수행하고 k=3개의 문서를 반환한다.

반환된 문서의 파일명과 페이지 번호가 정답 파일명과 페이지 번호와 얼마나 일치하는지를 기준으로 검색 성능을 평가한다. 이를 통해 멀티 홉 검색과 HyDE 기반 검색 프레임워크의 검색 성능을 정량적으로 비교할 수 있다.

4.3 평가 지표

검색 성능을 정량적으로 평가하기 위해 precision, recall, F1 score, MAP, MRR, hit rate를 사용한다. 평가 과정은 검색된 문서가 청크 단위로 반환된다는 점을 고려하여 설계된다. 하나의 문서의 한 페이지는 여러 청크로 분할될 수 있으므로 해당 페이지와 관련된 모든 청크를 정확히 검색했는지를 기반으로 성능 지표를 계산한다.

k값에 따라 각 지표에서 나타날 수 있는 최댓값이 달라지기 때문에 본 연구에서는 k=3인 경우를 기준으로 각 지표의 최댓값을 <표 3>에 실험 결과와 함께 제시하였다.

4.4 실험 결과

실험 결과는 <표 3>에 정리되어 있다. 멀티 홉 검색 실험 결과, 평균 precision은 0.2333, recall 0.3303, F1 score 0.2600, MAP와 MRR은 각각 0.7250으로 계산되었다. hit rate는 0.5500으로, 전체 질의 중 55%에서 상위 3개의 검색 결과 내에 적어도 하나의 정답 문서가 포함되었다는 것을 의미한다.

HyDE 기법을 적용한 멀티 홉 검색에서는 precision 0.2500(7.16% 증가), recall 0.3948(19.53% 증가), F1 score 0.2990(15.00% 증가), MAP와 MRR은 각각 0.7389(1.92% 증가), 0.7361(1.53% 증가), hit rate는 0.6667(21.21% 증가)로 모든 값이 증가하였다.

〈표 3〉 멀티 홉 검색과 HyDE 기반 멀티 홉 검색 성능 비교

성능 지표	멀티 홉 검색	HyDE-멀티 홉 검색	최댓값
precision	0.2333	0.2500	0.5611
recall	0.3303	0.3948	0.7668
F1 score	0.2600	0.2990	0.6048
MAP	0.7250	0.7389	0.7668
MRR	0.7250	0.7361	0.8333
hit rate	0.5500	0.6667	1.0000

Ⅴ. 결 론

본 연구는 RAG(Retrieval-Augmented Generation) 시스템의 검색 성능 향상을 위해 멀티 홉 검색과 HyDE(Hypothetical Document Embeddings) 기법을 결합한 새로운 프레임워크를 제안하고, 이를 통해 복잡한 질의에 대한 검색 성능 개선 가능성을 실증적으로 검증하였다. HyDE를 활용하여 각 홉에서 질의 의도를 반영한 가상 문서를 생성하고 이를 검색 과정에 통합함으로써 단계적 접근 방식을 통해 검색 정확성을 향상시킬 수 있음을 확인하였다.

실험 결과, HyDE 기반 멀티 홉 검색은 recall, F1 score, hit rate에서 기존 멀티 홉 검색 대비 15~21%로 의미 있는 성능 향상을 보였으며, precision도 약

7.16% 개선되었다. 또한 MAP와 MRR도 각각 1.92%, 1.53% 상승하여 전반적으로 긍정적인 결과를 확인할 수 있었다.

이러한 결과를 세부적으로 분석하면, precision의 절대적인 값이 낮게 나온 이유는 정답 문서가 검색된 상위 k개의 결과 내에 존재하더라도 해당 문서를 구성하는 chunk 개수가 상대적으로 적었기 때문이다. 즉 도출될 수 있는 precision의 최댓값 자체가 낮아 절대적인 값이 작게 나왔으며, 성능 향상의 폭도 recall에 비해 제한적으로 나타났다. 따라서 precision의 개별적 변화보다는 recall과의 균형을 고려하기 위해 F1 score를 함께 분석하여 성능 개선을 평가하였다.

또한 MAP와 MRR의 성능 향상 폭이 상대적으로 작았던 것은 두 지표가 검색된 문서의 순서를 평가하는 데 중점을 두기 때문이다. 본 연구에서 HyDE를 적용함으로써 검색된 문서 목록 자체의 품질은 향상되었지만 기존 검색에서도 정답 문서가 상위에 위치하는 경우가 많아 문서의 순위 개선 폭이 제한적이었을 가능성이 있다.

5.1 학술적 기여

본 연구는 RAG 시스템의 검색 성능을 향상시키기 위해 멀티 홉 검색과 HyDE 기법을 결합한 새로운 검색 프레임워크를 제안하였으며, 이를 한국어 환경에서 실증적으로 검증하였다.

기존에 HyDE는 단일 홉 검색 환경에서 주로 활용되었지만, 본 연구는 이를 멀티 홉 검색 환경에 적용하여 검색 성능을 향상시킬 수 있음을 실험적으로 입증하였다. 이는 가상 문서 생성 기법이 보다 복잡한 검색 프로세스에서도 효과적으로 활용될 수 있음을 시사한다. 향후 연구에서는 홉 간 성능 전이의 영향을 보다 세밀하게 분석함으로써 검색 과정에서 발생하는 정보 손실을 최소화할 수 있는 최적화 전략을 모색할 수 있을 것이다.

기존 멀티 홉 검색 연구는 주로 영어 기반 데이터셋과 QA(Question Answering) 태스크를 중심으로 이루어졌으며, 한국어 데이터셋을 활용한 연구는 상대적으로 부족했다. 본 연구는 제한적인 수량의 문서와 한국어 단일 홉 QA 데이터셋을 활용하여 제안 기법이 한국어 환경에서 성능 향상을 보인다는 점을 입증했다. 이는 다국어 기반 검색 시스템 연구의 확장 가능성을 제시한다는 점에서 의의를 갖는다.

기존 멀티 홉 검색 연구들은 대부분 멀티 홉 질의가 포함된 벤치마크 데이터셋을 활용하여 실험을 진행해 왔으나 본 연구는 단일 홉 데이터셋을 멀티 홉 형태로 변환하여 실험을 수행했다는 점에서 차별성을 가진다. 즉 사전에 구축된 멀티 홉 데이터셋 없이 제한적인 환경에서도 단일 홉 데이터를 활용하는 방안을 모색하고 그 가능성을 실증적으로 검토하였다. 멀티 홉 데이터셋이 미비한 한계를 극복하고 보다 다양한 환경에서 멀티 홉 검색 연구를 수행할 수 있는 가능성을 확장했다는 점에서 의의가 있다.

5.2 실무적 시사점

최근 기업들은 고객 지원 챗봇, 기술 문서 검색, 내부 지식관리 시스템 등 다양한 영역에서 RAG 시스템을 도입하고 있다. 그러나 기존 RAG 모델은 단일 홉 검색을 기반으로 구현되는 경우가 많아 여러 문서를 참조해야 하는 복잡한 질의에서는 성능이 저하되는 문제가 있었다. 본 연구는 이러한 한계를 해결하기 위해 HyDE 기반 멀티 홉 검색 기법을 제안하고 실험을 통해 제안 모델이 우수한 성능을 보임을 확인하였다. 특히 복잡한 질의를 처리해야 하는 금융, 법률, 의료 같은 분야에서 실무적으로 활용될 수 있을 것이다.

또한 멀티 홉 데이터셋이 충분하지 않은 환경에서도 본 연구에서 제안한 접근법을 적용하여 검색 성능을 개선할 수 있다는 점에서 실무적 활용 가능성이 크다. 기존 멀티 홉 검색 연구는 주로 사전에 구축된 데이터셋을 활용하여 성능을 평가하였지만, 실제 기업 환경에서는 반드시 멀티 홉 검색을

위한 학습 데이터가 충분하지 않을 수 있다. 본 연구는 단일 홉 데이터셋을 변환하여 멀티 홉 검색 실험을 수행함으로써 제한된 환경에서도 멀티 홉 검색 기법을 적용할 수 있는 가능성을 제시하였다.

5.3 한계 및 향후 연구 방향

본 연구는 의미 있는 성과를 도출하였으나 몇 가지 한계를 가진다.

실험에 사용된 Allganize 데이터셋이 본래 단일 홉 검색용으로 설계되어 멀티 홉 검색 평가에 최적화되어 있지 않다는 데이터셋 관련 한계가 있다. 이러한 특성으로 인해 첫 번째 홉에서 성능 측정이 불가능했고, HyDE가 멀티 홉 검색 성능 향상에 영향을 준다는 가설을 엄밀하게 검증하기 어려웠다. 향후 연구에서는 한국어 기반의 멀티 홉 검색에 특화된 데이터 셋을 구축하거나 기존 데이터셋을 멀티 홉 검색에 적합하게 확장하고 검증하는 방안을 고안하면 좋을 것이다.

참 고 문 헌

[1] 김도현, 원일용, 유상현, 김현정, “RAG 시스템 성능 향상을 위한 웹문서 본문 정제 및 추출 시스템”, *한국통신학회 인공지능 학술대회논문집*, 2024, pp. 305-306.

[2] 박대민, 이한종, “챗GPT 등장 이후 인공지능 환각 연구의 문헌 검토: 아카이브(arXiv)의 논문을 중심으로”, *정보화정책*, 제31권, 제2호, 2024, pp. 3-38.

[3] 이광우, 김수균, “국내 기업을 위한 RAG 구조 기반 질의응답시스템 설계”, *한국컴퓨터정보학회논문지*, 제29권, 제7호, 2024, pp. 81-88.

[4] 정진철, 김대호, 정유철, “다중 Agent와 반복적 답변 생성·평가 기법을 적용한 사규 검색용 Self-Corrective RAG 시스템 연구”, *Proceedings of KIIT Conference*, 2024, pp. 588-591.

[5] 최은실, “앙상블 기반 OCR과 RAG 기술을 활용한 ESG 서류 검토 자동화 시스템 개발”, *한국컴퓨터정보학회논문지*, 제29권, 제9호, 2024, pp. 25-37.

[6] Asai, A., S. Min, Z. Zhong, and D. Chen, “Retrieval-based language models and applications”, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics* (Volume 6: Tutorial Abstracts), 2023, pp. 41-46.

[7] Brown, T., B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, *et al.*, “Language models are few-shot learners”, *Advances in Neural Information Processing Systems*, Vol.33, 2020, pp. 1877-1901.

[8] Chen, J., S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation”, arXiv preprint, arXiv:2402.03216, 2024.

[9] Cuconasu, F., G. Trappolini, F. Siciliano, S. Filice, C. Campagnano, Y. Maarek, N. Tonellotto, and F. Silvestri, “The power of noise: Redefining retrieval for RAG systems”, arXiv preprint, 2024.

[10] Devlin, J., M. W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding”, arXiv preprint, arXiv:1810.04805, 2019.

[11] Gao, L., X. Ma, J. Lin, and J. Callan, “Precise zero-shot dense retrieval without relevance labels”, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 2022, pp. 1762-1777.

[12] Gao, Y., Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, and H. Wang, “Retrieval-augmented generation for large language models: A survey”, arXiv preprint, arXiv:2312.10997, 2023.

[13] Gartner, “Top Technology Trends [Research Report]”, 2024, Available at https://www.gartner.com/en/co

nfirmation/information-technology/research/top-technology-trends-thank-you-it.

[14] Jégou, H., M. Douze, and C. Schmid, "Product quantization for nearest neighbor search", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol.33, No.1, 2011, pp. 117-128.

[15] Jina AI, "Jina Embeddings V3 [Language Model]", Available at https://jina.ai/embeddings.

[16] Lee, H., S. Yang, H. Oh, and M. Seo, "Generative Multi-hop Retrieval", 2022, arXiv preprint arXiv: 2204.13596.

[17] Lewis, P., B. Oguz, R. Rinott, Y. Liu, K. Lo, H. Zhu, S. Levine, M. Ott, W. Yih, and L. Zettlemoyer, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks", arXiv preprint, arXiv:2005.11401, 2020.

[18] Liu, S., W. Yu, S. Wang, P. Shi, S. Reddy, and K. W. Chang, "Self-RAG: Learning to retrieve, generate, and critique through self-reflection", arXiv preprint, arXiv:2310.11511, 2023.

[19] Liu, Y., M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "RoBERTa: A robustly optimized bert pretraining approach", arXiv preprint, arXiv:1907.11692, 2019.

[20] Ma, X., Y. Gong, P. He, H. Zhao, and N. Duan, "Query rewriting for retrieval-augmented large language models", arXiv preprint, arXiv:2305.14283, 2023.

[21] Malkov, Y. A. and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol.42, No.4, 2018, pp. 824-836.

[22] Mikolov, T., K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space", arXiv preprint, arXiv:1301.3781, 2013.

[23] Muennighoff, N., N. Tazi, L. Magne, and N. Reimers, "MTEB: Massive text embedding benchmark", arXiv preprint, arXiv:2210.07316, 2022.

[24] Ouyang, L., J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, *et al.*, "Training language models to follow instructions with human feedback", arXiv preprint, arXiv:2203.02155, 2022.

[25] Park, S., "MTEB KO Leaderboard [Software Repository]", Available at https://github. com/su-park/mteb_ko_leaderboard.

[26] Qin, Z., R. Jagerman, K. Hui, H. Zhuang, J. Wu, L. Yan, J. Shen, T. Liu, J. Liu, D. Metzler, *et al.*, "Pairwise ranking prompting: A new framework for text ranking with large language models", arXiv preprint, arXiv:2401.12345, 2024.

[27] Rahman, M. T. R., S. Alqahtani, M. S. Bari, M. Rahman, M. A. M. Khan, H. Khan, I. Jahan, A. Bhuiyan, C. W. Tan, M. R. Parvez, *et al.*, "A systematic survey and critical review on evaluating large language models: Challenges, limitations, and recommendations", arXiv preprint, arXiv: 2407.04069, 2024.

[28] Reimers, N. and I. Gurevych, "Sentence-BERT: Sentence embeddings using siamese bert-networks", *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 2019, pp. 3982-3992.

[29] Robertson, S. and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond", *Foundations and Trends in Information Retrieval*, Vol.3, No.4, 2009, pp. 333-389.

[30] Shao, Z., Y. Gong, Y. Shen, M. Huang, N. Duan, and W. Chen, "Enhancing retrieval-augmented large language models with iterative retrieval-gen-

eration synergy", arXiv preprint, arXiv:2305.15294, 2023.

[31] Tang, Y. and Y. Yang, "MultiHop-RAG: Benchmarking retrieval-augmented generation for multi-hop queries", arXiv preprint, arXiv:2401.15391, 2024.

[32] Touvron, H., T. Lavril, G. Izacard, X. Martinet, M. A. Lachaux, T. Lacroix, B. Roziere, N. Goyal, E. Hambro, F. Azhar, *et al.*, "LLaMA: Open and efficient foundation language models", arXiv preprint, arXiv:2302.13971, 2023.

[33] Wang, L., N. Yang, and F. Wei, "Query2doc: Query expansion with large language models", arXiv preprint, arXiv:2303.07678, 2023.

[34] Wang, L., N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 Text embeddings: A technical report", arXiv preprint, arXiv:2402.05672, 2024.

[35] Wang, X., Z. Wang, X. Gao, F. Zhang, Y. Wu, Z. Xu, T. Shi, Z. Wang, S. Li, Q. Qian, R. Yin, C. Lv, X. Zheng, and X. Huang, "Searching for best practices in retrieval-augmented generation", arXiv preprint, arXiv:2407.01219, 2024.

[36] Wei, J., X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou, "Chain-of-Thought prompting elicits reasoning in large language models", *Proceedings of the 36th Conference on Neural Information Processing Systems (NeurIPS 2022)*, 2022.

[37] Wolf, T., L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, *et al.*, "Transformers: State-of-the-Art natural language processing", *Proceedings of EMNLP 2020: System Demonstrations*, 2020, pp. 38-45.

[38] Wu, C., F. Wu, T. Qi, and Y. Huang, "Hi-Transformer: Hierarchical interactive transformer for efficient and effective long document modeling", 기관 등 추가, 2021.

[39] Xiong, W., X. L. Li, S. Iyer, J. Du, P. Lewis, W. Y. Wang, Y. Mehdad, W. Yih, S. Riedel, D. Kiela, and B. Oğuz, "Answering complex open-domain questions with multi-hop dense retrieval", *Proceedings of the 9th International Conference on Learning Representations (ICLR 2021)*, 2021.

[40] Yang, Z., P. Qi, S. Zhang, Y. Bengio, W. Cohen, R. Salakhutdinov, and C. D. Manning, "HotpotQA: A dataset for diverse, explainable multi-hop question answering", *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, 2018, pp. 2369-2380.

[41] Yao, J.-Y., K.-P. Ning, Z.-H. Liu, M.-N. Ning, and L. Yuan, "LLM Lies: Hallucinations are not bugs, but features as adversarial examples", arXiv preprint, arXiv:2310.01469, 2023.

[42] Zhang, J., H. Zhang, D. Zhang, L. Yong, and S. Huang, "End-to-End beam retrieval for multi-hop question answering", *Proceedings of NAACL 2024*, 2024.

Information Systems Review
Volume 27 Number 2
May 2025

HyDE-Based Multi-Hop Retrieval Approach for Enhancing Retrieval Performance

Ye-eun Kim* · Jae-Hong Lee** · Sang-Huck Won** · Woo-Hyuk Jung** · Jihwan Woo***

Abstract

The development of generative AI and large language models (LLMs) is revolutionizing business processes and fostering the adoption of customized LLMs for domain-specific tasks. However, Retrieval-Augmented Generation (RAG) systems designed to address hallucination and domain relevance issues face performance degradation due to error accumulation in handling complex multi-hop queries. This study proposes a framework that integrates the Hypothetical Document Embedding (HyDE) technique into multi-hop retrieval to enhance RAG performance. HyDE generates virtual documents reflecting query intent, improving retrieval accuracy by decomposing complex queries into single-hop queries and applying HyDE iteratively at each step. Experiments were conducted using precision@k, recall@k, F1 score, MAP, MRR, and hit rate as evaluation metrics. The results demonstrate that HyDE-based multi-hop retrieval improves performance across all metrics, with recall increasing by approximately 19.53% and hit rate by 21.21%. These findings confirm the effectiveness of HyDE in enhancing retrieval accuracy for multi-hop search. Future research directions include the development of optimized datasets for multi-hop retrieval and further refinement of virtual document generation strategies.

Keywords: ***Retrieval-Augmented Generation (RAG), Hypothetical Document Embedding (HyDE), Multi-hop Retrieval, Query Decomposition, Large Language Models (LLMs), Generative AI***

* Undergraduate Student, GIST School of EECS
** AI Researcher, CJ OliveNetworks
*** Corresponding Author, Sr. Specialist Partner SA AI/ML, AWS

◐ 저 자 소 개 ◑

김 예 은 (kimyeeun@gm.gist.ac.kr)

광주과학기술원 전기전자컴퓨터공학부 학부생이다. RAG, 분산 컴퓨팅, 시계열 데이터 예측 연구를 수행한 경험이 있으며 이외에 AI 최적화에 관심을 두고 있다.

이 재 홍 (jh.lee256@cj.net)

CJ올리브네트웍스 AI연구소에서 재직 중이다. 관심분야는 언어 모델을 활용한 텍스트 생성이며, 현재 연구는 검색 증강 생성(RAG)과 대형 언어 모델(LLM)에 관한 이론 및 활용 측면을 다루며, 기업형 모델 개발과 최적화에 중점을 두고 있다.

원 상 혁 (sh.won2@cj.net)

현재 CJ올리브네트웍스 AI연구소에서 언어 모델(Language Model)에 대한 연구를 수행중이다. 주요 연구 분야로는 LLM, RAG, Agent 등이다.

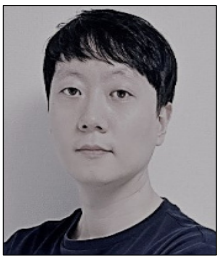

정 우 혁 (wh.jung2@cj.net)

CJ올리브네트웍스 AI연구소에서 재직 중이다. 주요 관심분야는 AI 기반 텍스트 생성 및 자연어 처리 기술을 활용한 Digital Transformation 전략이다.

우 지 환 (jihwan.woo@kakao.com)

삼성전자 삼성리서치와 미국 카네기멜론대학교 로봇연구소를 거쳐 CJ 올리브네트웍스 AI연구소에서 연구소장을 역임하였고, 고려대학교 기술경영대학원과 KAIST 경영대학원에서 겸임교수로 활동하였다. 현재는 AWS Asia Pacific Japan에서 Sr. Specialist Partner SA AI/ML로 재직 중이며, 인공지능과 클라우드 컴퓨팅 기술을 활용하여 아시아 지역 기업들의 디지털 전환을 지원하고 있다. 컴퓨터 비전 기반 로보틱스 및 인공지능 분야의 연구개발 경험을 보유하고 있으며, 기술 전략 수립과 기술 가치 평가에도 관심을 두고 있다.

논문접수일 : 2025년 01월 21일 **게재확정일 : 2025년 04월 02일**
1차 수정일 : 2025년 03월 06일