Contrastive CAD: 대형 언어 모델의 환각 완화를 위한 대조적 Context-Aware Decoding

장규식°[1],나승훈[1], 김태형[2], 류휘정[2], 장두성[2]
전북대학교[1], KT[2]
{jks4880, nash}@jbnu.ac.kr[1]
{taehyeong_2019.kim, hwijung.ryu, dschang}@kt.com[2]

Contrastive CAD: Contrastive Context-Aware Decoding for Mitigating Hallucinations of Large Language Models

Gyu-sik Jang°[1],Hyun-Min Lee, Seung-Hoon Na[1], Tae-Hyeong Kim[3], Hwi-Jung Ryu[3]
Jeonbuk National University[1], KT[3]

요 약

대규모 언어 모델은 자연어 처리, 기계 번역, 텍스트 생성, 질의응답 시스템 등 다양한 분야에서 뛰어난 성능을 발휘하고 있다. 그러나 디코딩 과정에서 발생하는 환각(hallucination)은 잘못된 토큰 선택으로 이어져 생성된 텍스트의 신뢰성을 저하시키는 문제가 있다. 기존 디코딩 방식은 일반적으로 확률이 높은 토큰을 선택하는 데 의존하지만, 이로 인해 문맥에 맞지 않는 단어나 구가 선택될 수 있다. 이를 해결하기 위해 본 연구에서는 확률 분포를 기반으로 낮은 확률의 토큰을 제거하고, 필터링된 컨텍스트와 원본 컨텍스트를 합산하여 디코딩하는 새로운 방식을 제안한다. 이 방법은 모델이 신뢰할 수 있는 토큰만을 남기게 하여 더 높은 신뢰도의 텍스트 생성을 유도한다. 제안된 기법은 LLaMA 기반 모델의 질의응답 작업에서 성능을 향상시킬 수 있었다.

주제어: 거대언어모델, 디코딩, 환각

1. 서론

대규모 언어 모델은 다양한 분야에서 뛰어난 성능을 발휘하며, 자연어 처리, 기계 번역, 텍스트 생성, 질의응답 시스템 등 여러 영역에서 혁신적인 발전을 이끌어내고 있다. 이러한 모델들은 방대한 양의 데이터를 학습하여 언어의 복잡한 구조와 문맥을 이해하고, 높은 정확도로 텍스트를 생성할 수 있다. 그러나 이러한 모델들의 디코딩 과정에서 발생하는 환각(hallucination)으로 인해 잘못된 토큰이 선택될 수 있으며, 이는 생성된 텍스트의 신뢰성을 저하시키는 문제로 이어질 수 있다.

기존의 디코딩 기법들은 일반적으로 확률이 높은 토큰을 선택하여 문장을 생성하는 방식에 의존한다. 그러나 이 접근법은 종종 컨텍스트의 의미를 충분히 반영하지 못하고, 문맥에 맞지 않는 단어나 구가 선택되는 문제를 야기할 수 있다. 이러한 문제를 해결하기 위해 생성 중 표현 편집이나 대조 디코딩(contrastive decoding)[1]과 같은 방법들이 제안되었으나, 이들 기법은 대규모 언어 모델이 신뢰하는 토큰을 효과적으로 선택하는 데 한계가 있을 수 있다.

이에 따라, 우리는 컨텍스트의 확률 분포를 기반으로 낮은 확률의 토큰을 제거하여 모델이 신뢰할 수 있는 부분만을 남기고, 필터링된 토큰과 온전한 컨텍스트를 합산하여 디코딩하는 새로운 기법을 제안한다. 이 방법은 언어 모델이 더 높은 신뢰도를 바탕으로 텍스트를 생성하도록 유도한다.

이 기법을 통해 LLaMA기반[2] 모델의 질의응답(QA) 작업에서 성능 향상을 달성할 수 있었으며, 대조 디코딩[1]과 같은 연산 방식이 아닌 로짓을 합산하는 방식으로도 성능을 향상시킬 수 있다. 저희 논문의 기여는 다음과 같다.

- 컨텍스트에서 임계값을 설정해, 해당 임계값 이하의 확률을 가진 토큰을 제거하여 모델이 신뢰할 수 있는 토큰만 남긴후 합산하는 디코딩 방식을 제안한다.
- 컨텍스트를 합산한 디코딩 방법이 일부 질의 작업에서 성능이 개선이 됨을 확인하였다.

2. 관련 연구

2.1 검색 증강 언어모델

대규모 언어 모델은 광범위한 지식을 매개변수에 내포하고 있지만, 학습 과정에서 빈번하게 노출되지 않은 엔티티나 정보에 대해서는 기억이 제한적이며, 환각(hallucination)에 취약한 경향을 보인다. 또한, 매개변수에 저장된 지식은 시간이 지남에 따라 빠르게 구식이 될 수 있다. 최근 연구에서는 검색된 지식을 활용[3]하여 작은 모델이 대형 모델과 유사한 성능을 발휘할 수 있도록 하는 방법에 주목하고 있다. 외부 지식을 중간 상태나 출력 공간에 통합하는 연구[4][5]는 대규모 언어 모델이 겪는 기억 및 지식 업데이트의 한계를 효과적으로 극복할 수 있음을 보여주었다. 검색 증강을 통해 잘못된 생성의 빈도가 감소하였으며, 이러한 접근을 기반으로 적응형 검색과 멀티홉 검색 등을 도입한 연구들이 유망한 결과를 제시하고 있다.

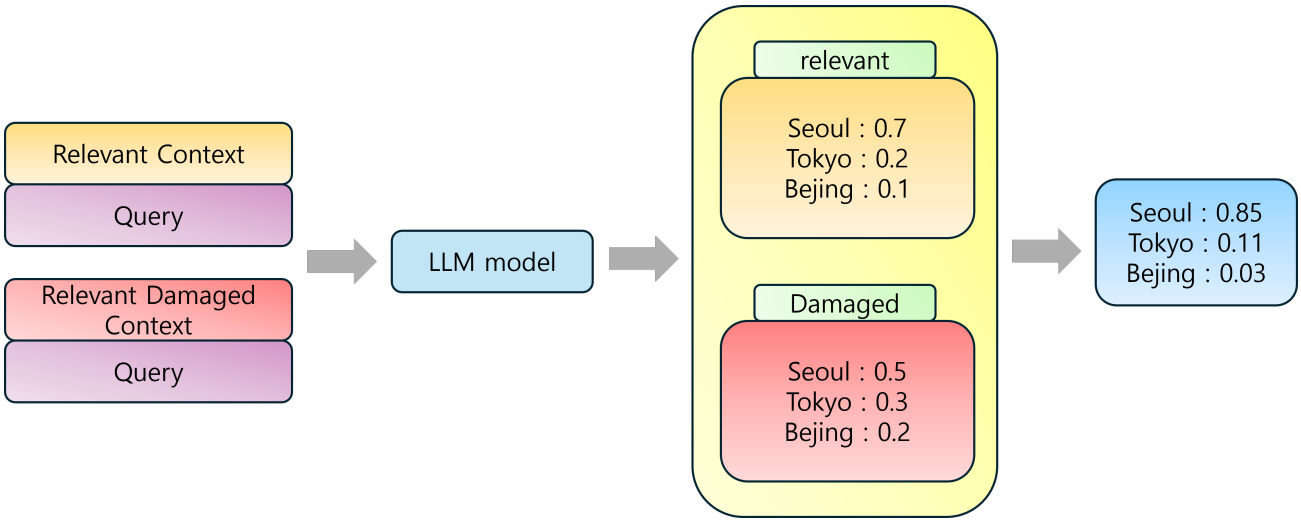

그림 1. 검색된 문맥과 이를 손상시켜 만든 손상된 문맥을 LLM에 입력하여 각각의 logit 값을 계산한 후, 두 logit 값을 더해 다음토큰을 최종적으로 결정한다. 손상된 컨텍스트는 모델의 확률이 임계값 이하인 토큰을 공백으로 대체하여 생성되며, 이 둘을 더하는 과정은 모델의 진실성을 향상하기 위해 사용된다.

2.2 대조 디코딩

대조 디코딩은 대규모 언어 모델의 환각 현상을 완화하기 위한 디코딩 방법으로 연구되어 왔다. 이 기법은 아마추어 모델과 전문가 모델 간의 확률 분포 차이를 증폭시켜, 생성된 텍스트의 유창성과 일관성을 향상시킨다. 그러나 이 방법의 효과는 전문가 모델과 대조하는 아마추어 모델의 크기에 의존하기 때문에, 적절한 크기의 모델을 선택하는 것이 중요하다.

이러한 대조 디코딩 방법을 단일 모델에서 활용하는 Dola[6] 방법은 모델 내 계층 간 성능 차이를 기반으로, 출력 단계를 위한 최종 레이어와 이를 대조할 조기 종료 레이어를 동적으로 선택하여 모델의 환각을 줄이는 전략을 사용한다. 이 방법은 최종 레이어와 선택된 조기 종료 레이어 간의 대조를 통해 확률을 증폭하여 토큰 생성의 품질을 향상시킨다.

반면, 컨텍스트 존재 여부를 기반으로 한 컨텍스트 인식 디코딩(CAD)[7]은 검색된 정보와 모델의 내부 지식을 대조함으로써 외부 지식에 대한 인식 효과를 강화하는 접근법이다. 이러한 방법을 통해 외부 지식을 보다 효과적으로 반영한 답변을 생성할 수 있음을 확인할 수 있었다.

그러나 CAD를 제외한 다른 대조 디코딩 방법들, 특히 CD[1]와 Dola[6]와 같은 기법들은 외부 지식에 의존하면서도 비모수 지식을 효과적으로 통합하지 못하는 한계를 보였다.[8]

본 논문에서는 디코딩 성능을 향상시키기 위해 생성 과정에서 결합하는 새로운 디코딩 방식을 제안한다. 특히, 확률 임계값을 설정하여 동일한 컨텍스트 내에서 확률이 낮은 토큰을 빈칸으로 대체함으로써, 모델이 혼동할 수 있는 토큰을 제거하고, 온전한 컨텍스트와 결합하여 모델 출력을 조정하는 방법을 사용한다.

2.3 지식 충돌

외부 지식이 내부 지식과 충돌할 때, 언어 모델이 내부 지식에만 의존하지 않고 제공된 컨텍스트를 기반으로 답변을 생성하는 것이 바람직하다. 검색 증강 언어 모델은 외부에서 검색된 문서를 활용하여 모델의 구식 정보를 대체하려고 한다. 그러나 대규모 언어 모델은 종종 컨텍스트를 충분히 반영하지 못하고 내부 지식에 크게 의존하기 때문에, 단순히 문서를 추가하는 것만으로는 생성 결과에 충분한 영향을 미치지 못한다.[9]

지시데이터를 활용한 연구[10]는 지시(prompting)를 통해 모델의 일관성을 향상시키는 방법이 제안되었으나, 이러한 접근은 대규모 지시 데이터로 학습된 모델에만 적용 가능하다는 한계가 있다. 저희 연구는 이러한 문제를 해결하기 위해 추가적인 검색을 필요로 하지 않고, 기존의 검색된 컨텍스트를 재활용하여 모델이 내부 지식을 더 잘 반영할 수 있도록 하는 방안을 제시한다.

3. 방법

3.1 배경 지식

대규모 언어 모델은 입력 쿼리 x를 처리하고, 쿼리에 적합한 응답 y를 생성하기 위해 후속 토큰들을 생성하는 작업을 수행한다. 응답 y는 x를 조건으로 한 조건부 확률 분포에서 도출된다.

$$y_t \sim p_0(y_t \mid x, y_{<t}) \tag{1}$$

컨텍스트 c가 주어지면, 모델은 이전에 생성된 쿼리, 컨텍스트 및 응답을 고려하여 새로운 응답 y를 생성한다. 이 과정에서 모델의 반응에 포함된 비모수적 지식과 내부 지식이 충돌할 경우,

외부 지식을 우선시하기를 바란다.

$$y_t \sim p_0(y_t \mid c, x, y_{<t}) \tag{2}$$

그러나 외부 검색을 통해 얻어진 비모수적 지식은 쿼리와 관련이 없거나 부정확한 정보를 포함할 수 있다. 따라서 우리는 비모수적 지식을 매개변수적 지식을 활용하여 필터링함으로써 지식 충돌을 완화할 것을 제안한다.

Context-Aware Decoding

Context-Aware Decoding (CAD)는 모델의 원래 출력 확률 분포에서 발생하는 문제를 완화하기 위해 설계된 방법입니다. 이 방법은 모델의 이전 예측에 대한 사전 지식을 고려하고, 이를 컨텍스트와 대조하여 조정합니다. 이 과정에서 점별 상호 정보(Pointwise Mutual Information, PMI)를 사용하여 출력 확률을 조정합니다.

모델의 원래 출력 확률을 $p(y_t \mid x, y_{<t})$라고 할 때, CAD는 이를 다음과 같이 조정합니다:

$$y_t \propto \hat{p}(y_t \mid c, x, y_{<t}) \cdot \left(\frac{p(y_t \mid c, x, y_{<t})}{p(y_t \mid x, y_{<t})} \right)^{\alpha}$$

여기서 α는 PMI에 가중치를 부여하는 매개변수로, 컨텍스트의 중요도를 조절한다. 컨텍스트를 고려했을 때 더 가능성이 높은 출력에 가중치를 부여한다. 정규화를 통하여 최종적으로 다음과 같은 형태를 얻을 수 있습니다:

$$y_t \sim \text{softmax}\left((1+\alpha)\log p(y_t \mid c, x, y_{<t}) - \alpha \log p(y_t \mid x, y_{<t})\right)$$

여기서 $\alpha = 0$일 경우, 일반적인 디코딩 방법으로 되돌아가며, α 값이 클수록 컨텍스트에 더 많은 가중치를 부여하게 됩니다.

이 방식은 원래의 출력 확률과 컨텍스트 기반 출력을 대조하여, 컨텍스트를 포함했을 때 더 가능성이 높은 출력을 강조합니다.

3.2 신뢰도가 낮은 컨텍스트를 위한 토큰 제거

제안된 방법에서는 컨텍스트 내 모든 토큰의 확률을 대규모 언어 모델(LLM)에 입력하여 계산한다. 그런 다음, 이 확률을 기반으로 미리 정의된 임계값 아래에 있는 토큰을 식별하고, 해당 토큰을 빈 토큰으로 대체한다. 이러한 방식으로 재구성된 컨텍스트는 신뢰 임계값을 충족하는 토큰만을 유지하게 된다. 컨텍스트 $C = \{t_1, t_2, \ldots, t_n\}$가 주어졌을 때, 각각의 토큰 t_i에 대하여 토큰별 확률 값은 다음과 같이 계산된다.

$$p_i = P(t_i \mid C) \tag{3}$$

컨텍스트를 모델에 입력을 제공한후 포워드를 진행하여, 컨텍스트가 주어 졌을때 내부 토큰별 확률 값을 구할 수 있다. 주어진 확률을 기반으로 컨텍스트 C는 임계값 λ를 기준으로 업데이트된다. 수정된 컨텍스트 C'은 다음과 같이 정의된다.

$$t'_i = \text{blank} \quad \text{if} \quad p_i \leq \lambda \tag{4}$$

여기서 t'_i는 토큰 t_i의 확률 p_i가 임계값 λ이하일 경우 t_i를 대체하는 토큰을 나타낸다.

3.3 Contrastive CAD

일부 토큰을 빈 토큰으로 대체했음에도 불구하고 수정된 컨텍스트C'는 전체적으로 원래 컨텍스트 C와 유사한 구조를 유지한다. 그러나 이 과정에서 확률이 낮은 토큰이 변경이 되어 손상이 된다.

그럼에도 불구하고 수정된 컨텍스트는 모델이 불확실하다고 간주하는 토큰을 무시함으로써, 모델이 외부 지식과 충돌하는 부분을 식별하고, 지식 충돌이 발생하는 지점을 파악할 수 있다. 그러나 이 컨텍스트만을 사용할 경우, 모델이 외부 지식을 기반으로 정확한 답변을 생성하지 못할 수 있으며, 오히려 파괴된 맥락으로 인해 내부 지식을 충분히 활용하지 못할 가능성이 있다.

이를 보완하기 위해, 원래의 입력도 함께 제공하여 병렬적으로 로짓을 생성하도록 한다. 이렇게 함으로써, 모델은 원래의 컨텍스트에서 비롯된 풍부한 내부 지식과 수정된 컨텍스트에서 모델이 확신하는 정보를 결합하여 보다 정확하고 일관된 답변을 생성할 수 있다. 우리의 접근 방식은 디코딩 단계에서 이러한 두 가지 컨텍스트의 예측 결과를 결합함으로써, 보다 신뢰성 높은 정답을 도출한다.

$$\begin{aligned} y_t &\sim \hat{p}_\theta(y_t \mid c, x, y_{<t}) \\ &\propto p_\theta(y_t \mid c, x, y_{<t})(p_\theta(y_t \mid c', x, y_{<t}))^{\alpha} \end{aligned}$$

응답이 높은 확률을 얻기 위해서는 내부적 지식과 외부적 지식을 모두 활용해야 한다. 따라서 $(p_\theta(y_t \mid c', x, y_{<t}))^{\alpha}$는 내부 지식이 신뢰하지 않는 부분을 조정하고, 신뢰하는 내용에 집중하도록 하는 스케일링 요소로 동작한다.

위의 수식을 정규화를 통하여 최종적으로 변형하게 되면 CAD와는 달리 가중 합산하는 다음의 형태를 얻을 수 있다.

$$y_t \sim \text{softmax}\left(\log p_0(y_t \mid c, x, y_{<t}) + \alpha \cdot \log p_0(y_t \mid c', x, y_{<t})\right)$$

여기서 α는 하이퍼파라미터로, 불확실한 정보에서 생성 과정을 조절하는 역할을 한다. 기존 논문의 CAD는 내부 지식과 외부지식이 충돌하는 상황에서 대조 디코딩을 구성하였다. 반면 본 연구에서는 관련 컨텍스트와 모델이 신뢰하는 부분만을 남긴 컨텍스트를 구성하여 합산하는 방식으로 동작한다.

4. 실험 및 평가 데이터

본 연구는 자연어로 된 사실적 질문에 대한 응답을 생성하는 작업인 오픈 도메인 질의응답(Open-domain Question Answering)에 초점을 맞추어 평가를 진행한다. 오픈 도메인 QA는 모델이 사전에 학습된 정보뿐만 아니라, 외부에서 제공되는 지식 소스를 활용하여 질문에 답변할 수 있는 능력을 요구한다. 특히, 본 연구에서는 추론 과정에서 질문과 관련된 컨텍스트를 모델에 제공하여, 모델이 외부 지식을 적극적으로 활용할 수 있도록 하는 오픈북(Open-book) QA에 중점을 두었다.

데이터셋

본 연구에서는 세 가지 대표적인 질의응답(QA) 벤치마크를 사용하여 모델의 성능을 평가하였다: TriviaQA[11], Natural Questions(NQ)[12], 그리고 PopQA[13]를 사용하였다. 또한, PopQA 및 TriviaQA의 경우 검색된 문서 데이터를 활용하기 위해 Contriever MS-MARCO를 사용하여 질의에 맞는 문서를 검색하고 제공하는 방식으로 실험을 진행하였다.

- **TriviaQA**: TriviaQA는 웹에서 수집된 질문들로 구성되어 있으며, 주로 사실적 정보에 대한 질문들을 포함한다.
- **Natural Questions (NQ)**: NQ는 구글 검색 쿼리에서 파생된 질문들로 구성되어 있으며, 답변 범위는 주로 위키백과(Wikipedia) 문서에서 주석자들이 식별한 부분에 위치한다. 본 연구에서는 실험을 위해 NQ_open_gold로 알려진 Huggingface의 데이터셋을 활용하였다.
- **PopQA**: PopQA는 엔티티 중심의 오픈 도메인 QA 데이터셋으로, 14,000개의 질문-답변 쌍을 포함하고 있는 질의응답 데이터셋 이다.

Metrics

오픈 도메인 질의응답(Open-domain Question Answering) 작업에서 모델의 성능을 평가하기 위해 주로 사용되는 두 가지 주요 지표는 F1 점수와 Exact Match이다.

F1 점수는 정밀도와 재현율의 조화 평균으로, 모델의 예측 성능을 종합적으로 평가하는 지표이다. EM(Exact Match)은 모델의 예측이 정답과 정확히 일치하는지를 평가하는 지표로, 정답과 완전히 동일한 경우에만 점수를 부여한다.

이 두 가지 지표는 모델의 응답 정확도를 평가하는 데 널리 사용되며, 오픈 도메인 QA에서 중요한 성능 평가 기준이다.

5. Baseline 및 모델

검색기 (Retriever)

본 연구에서는 오픈북(Open-book) 설정에서 대규모 언어 모델의 성능을 향상시키기 위해 검색 증강 접근 방식을 채택하였다. 이를 위해 각 쿼리에 대해 위키백과(Wikipedia)에서 관련 컨텍스트를 오프라인으로 검색한 후, 이를 원래의 쿼리와 연결하여 모델의 입력으로 사용하였다.

이 과정에서 우리는 주로 Contriever[14]를 검색기로 활용하였다. Contriever는 대규모 비지도 학습된 코퍼스에서 사전 학습된 모델로, 질의와 관련된 정보를 효과적으로 검색할 수 있다. Contriever-MS MARCO 버전을 사용하여 MS MARCO 데이터셋으로 미세 조정된 Contriever를 활용하였다.

Contriever를 사용한 검색 방법은 특히 TriviaQA와 NQ 데이터셋에서 활용되었으며, 이 데이터셋들에 대하여, top1 문서를 질의와 같이 제공하여 성능을 비교하였다.

Baseline

기본 접근 방식으로는 이전 연구에 따라 그리디 디코딩(Greedy Decoding)과 같은 일반적인 디코딩 방법을 사용하였다.또한, 우리는 컨텍스트 인식 디코딩(CAD)을 사용해 컨텍스트 유무에 따른 모델 출력 분포를 증폭하는 방법을 비교하였다.

Model

본 연구에서는 Meta의 LLaMA-7b, LLaMA2-7b, LLaMA2-7b-chat 모델을 사용했다. LLaMA-7b와 LLaMA2-7b는 70억 개의 파라미터로 구성된 범용 자연어 처리 모델로, 다양한 작업에서 우수한 성능을 보인다. LLaMA2-7b-chat 모델은 대화형 작업에 최적화된 모델로, 강화학습(RLHF)으로 추가 학습된 모델이다. 이 모델은 대화형 자연어 처리 작업에서 특히 높은 성능을 발휘한다.

6. 실험 결과

본 연구에서는 Natural QA, Trivia QA, Pop QA 세 가지 질문-응답 데이터셋을 사용하여 다양한 디코딩 전략을 평가하였다. 실험에 사용된 디코딩 방법은 그리디 디코딩, $\alpha = 0.5$로 설정한 컨텍스트 인식 디코딩(CAD), $\alpha = 1.0$ 및 threshold = 0.4로 설정한 제안된 방법과 저희 논문의 방법을 비교하였다. 각 방법은 LLaMA2 Chat, LLaMA2-7b, LLaMA-7b 모델에서 테스트되었다.

표1이 제시하는 전체 결과에서 제안된 방법은 그리디 디코딩에 비해 전반적으로 약간 더 우수한 성능을 보였으며, 특히 CAD와 비교했을 때 차이가 두드러졌다. Trivia QA 데이터셋에서 LLaMA2-7b 모델을 사용할 경우, 제안된 방법이 CAD와 그리디 디코딩보다 크게 성능이 향상된 것을 확인할 수 있었다. 그러나, 정답이 포함된 문서를 제공하는 Natural QA 데이터셋에서는 성능이 비교적 낮게 나타났다. 이를 분석한 결과, Natural QA의 일부 질문에서 모델이 지식 간의 충돌이 심하게 발생하는 경우에는 내부 지식에 더 중점을 두는 경향을 보였음을 확인할 수 있었다.

Dataset	Decoding	LLaMA2 Chat Model		LLaMA2-7b		LLaMA-7b	
		EM	F1	EM	F1	EM	F1
Natural QA	Greedy	60.85	73.04	**55.85**	**66.21**	**52.56**	**70.64**
	CAD (α=0.5)	56.55	70.39	51.21	65.19	38.14	61.84
	C2AD (α=1.0, thres=0.4)	**61.89**	**73.55**	50	60.29	44.52	58.53
Trivia QA	Greedy	59.06	65.86	33.47	50.37	50.61	61.68
	CAD (α=0.5)	50.13	59.57	49.41	**59.24**	38.82	55.70
	C2AD (α=1.0, thres=0.4)	**59.66**	**66.28**	**50.37**	57.64	**55.24**	**62.91**
Pop QA	Greedy	33.18	38.25	27.55	28.94	32.21	36.59
	CAD (α=0.5)	29.15	35.35	28.91	35.74	29.96	35.59
	C2AD (α=1.0, thres=0.4)	**33.46**	**38.55**	**28.94**	**30.75**	**34.28**	**38.83**

표 1. LLaMA1, LLaMA2, LLaMA2-chat 모델에 대하여 NQ, TriviaQA, PopQA에 대한 디코딩 방법 별 성능 비교

6.1 임계값을 기준으로 한 토큰 삭제의 방향

데이터셋	낮은 확률 제거		높은 확률 제거	
	EM	F1	EM	F1
NQ	61.89	73.55	33.07	48.86
TriviaQA	59.66	66.28	30.12	41.05
PopQA	33.46	38.55	14.89	19.40

표 2. 제안된 방법과 확률이 높은 토큰을 임계값을 기준으로 삭제한 성능 비교 (LLaMA2-Chat 모델)

확률에 따른 토큰 삭제 방식의 성능 차이를 분석하기 위해, 확률이 높은 토큰을 임계값을 기준으로 삭제한 경우의 성능을 LLaMA2-Chat 모델을 사용해 평가했다.

표2에서의 실험 결과는 확률이 높은 토큰들을 추가 조치 없이 임계값을 기준으로 제거할 경우, 문맥이 크게 손상되어 컨텍스트를 제공하더라도 성능이 크게 감소할 수 있음을 보여준다. 이러한 방식은 문맥의 일관성을 유지하지 못해 성능에 부정적 영향을 미칠 수 있다. 반면, 확률이 낮은 토큰을 제거함으로써 모델이 신뢰하는 주요 컨텍스트의 맥락을 유지하고, 혼동을 야기할 수 있는 토큰을 제거하여 신뢰하는 정보에 집중할 수 있게 한다. 이를 통해 제안된 디코딩 방식이 효과적임을 확인할 수 있다.

7. 결론

제안한 방법은 컨텍스트 인식 디코딩의 연산량을 유지하면서도, 질의 응답에서 성능 향상을 보였다. 논문의 주요 기여는 모델의 확률로 신뢰할 수 없는 부분을 제거 후 합산하는 전략을 도입한다. 이를 통해 모델이 진실하다고 판단하는 토큰을 강화하여, 일부 질의 응답 작업에서 성능을 향상시킬 수 있었다.

그러나, 제안된 방법은 모델이 혼동하고 있는 특정 토큰에 접근하여 해결하지는 못한 한계가 있다. 또한, 모델의 지식 충돌 시점을 정확하게 식별하고, 해당 부분에 대해 외부 지식을 강조하는 데는 미흡하다. 이러한 한계는 향후 연구에서 보완할 부분으로 남아 있다.

8. 감사의 글

본 연구는 (주)케이티의 “언어모델 생성 능력 향상을 위한 기술 연구 개발”과제의 지원을 받아 수행된 연구임.

참고문헌

[1] X. L. Li, A. Holtzman, D. Fried, P. Liang, J. Eisner, T. Hashimoto, L. Zettlemoyer, and M. Lewis, “Contrastive decoding: Open-ended text generation as optimization,” *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, A. Rogers, J. Boyd-Graber, and N. Okazaki, Eds., pp. 12 286–12 312, Jul. 2023. [Online]. Available: https://aclanthology.org/2023.acl-long.687

[2] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample, “Llama: Open and efficient foundation language models,” 2023. [Online]. Available: https://arxiv.org/abs/2302.13971

[3] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato,

R. Hadsell, M. Balcan, and H. Lin, Eds., Vol. 33, pp. 9459–9474, 2020. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf

[4] Z. Zhong, T. Lei, and D. Chen, "Training language models with memory augmentation," *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, Y. Goldberg, Z. Kozareva, and Y. Zhang, Eds., pp. 5657–5673, Dec. 2022. [Online]. Available: https://aclanthology.org/2022.emnlp-main.382

[5] S. Min, W. Shi, M. Lewis, X. Chen, W.-t. Yih, H. Hajishirzi, and L. Zettlemoyer, "Nonparametric masked language modeling," *Findings of the Association for Computational Linguistics: ACL 2023*, A. Rogers, J. Boyd-Graber, and N. Okazaki, Eds., pp. 2097–2118, Jul. 2023. [Online]. Available: https://aclanthology.org/2023.findings-acl.132

[6] Y.-S. Chuang, Y. Xie, H. Luo, Y. Kim, J. R. Glass, and P. He, "Dola: Decoding by contrasting layers improves factuality in large language models," *The Twelfth International Conference on Learning Representations*, 2024. [Online]. Available: https://openreview.net/forum?id=Th6NyL07na

[7] W. Shi, X. Han, M. Lewis, Y. Tsvetkov, L. Zettlemoyer, and W.-t. Yih, "Trusting your evidence: Hallucinate less with context-aware decoding," *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers)*, K. Duh, H. Gomez, and S. Bethard, Eds., pp. 783–791, Jun. 2024. [Online]. Available: https://aclanthology.org/2024.naacl-short.69

[8] B. Bi, S. Liu, Y. Wang, L. Mei, and X. Cheng, "Is factuality decoding a free lunch for llms? evaluation on knowledge editing benchmark," *arXiv preprint arXiv:2404.00216*, 2024.

[9] S. Longpre, K. Perisetla, A. Chen, N. Ramesh, C. DuBois, and S. Singh, "Entity-based knowledge conflicts in question answering," *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, M.-F. Moens, X. Huang, L. Specia, and S. W.-t. Yih, Eds., pp. 7052–7063, Nov. 2021. [Online]. Available: https://aclanthology.org/2021.emnlp-main.565

[10] W. Zhou, S. Zhang, H. Poon, and M. Chen, "Context-faithful prompting for large language models," *Findings of the Association for Computational Linguistics: EMNLP 2023*, H. Bouamor, J. Pino, and K. Bali, Eds., pp. 14 544–14 556, Dec. 2023. [Online]. Available: https://aclanthology.org/2023.findings-emnlp.968

[11] M. Joshi, E. Choi, D. Weld, and L. Zettlemoyer, "TriviaQA: A large scale distantly supervised challenge dataset for reading comprehension," *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, R. Barzilay and M.-Y. Kan, Eds., pp. 1601–1611, Jul. 2017. [Online]. Available: https://aclanthology.org/P17-1147

[12] T. Kwiatkowski, J. Palomaki, O. Redfield, M. Collins, A. Parikh, C. Alberti, D. Epstein, I. Polosukhin, J. Devlin, K. Lee, K. Toutanova, L. Jones, M. Kelcey, M.-W. Chang, A. M. Dai, J. Uszkoreit, Q. Le, and S. Petrov, "Natural Questions: A Benchmark for Question Answering Research," *Transactions of the Association for Computational Linguistics*, Vol. 7, pp. 453–466, 08 2019. [Online]. Available: https://doi.org/10.1162/tacl_a_00276

[13] A. Mallen, A. Asai, V. Zhong, R. Das, D. Khashabi, and H. Hajishirzi, "When not to trust language models: Investigating effectiveness of parametric and non-parametric memories," *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, A. Rogers, J. Boyd-Graber, and N. Okazaki, Eds., pp. 9802–9822, Jul. 2023. [Online]. Available: https://aclanthology.org/2023.acl-long.546

[14] G. Izacard, M. Caron, L. Hosseini, S. Riedel, P. Bojanowski, A. Joulin, and E. Grave, "Unsupervised dense information retrieval with contrastive learning," *Transactions on Machine Learning Research*, 2022. [Online]. Available: https://openreview.net/forum?id=jKN1pXi7b0