한국정보전자통신기술학회논문지(jkiiect)'25-4, Vol.18 No.2
논문 25-18-02-143 http://dx.doi.org/10.17661/jkiiect.2025.18.2.143

RAG 시스템 성능 평가를 위한 자동 데이터 셋 생성 프레임워크 비교 분석 연구

김범석*, 양진홍*

Comparative Analysis Study on Automated Dataset Generation Frameworks for RAG System Performance Evaluation

Beomseok Kim*, Jinhong Yang*

요 약 본 논문은 최근 주목받고 있는 검색 증강 생성(RAG) 시스템의 성능 평가를 위한 테스트 데이터셋 생성 방법을 비교 분석하였다. 대규모 언어 모델(LLM)의 한계를 극복하는 RAG 기술의 필요성과 중요성을 설명하고, 수동 생성 방식과 LLM을 활용한 자동 생성 방식의 특징과 장단점을 정리하였다. 또한 자동화된 데이터셋 구축 프레임워크 중 RAGAS, AutoRAG, DeepEval을 선정하여 의료,금융,법률 문서를 입력으로 각각 100개의 질문-답변 세트를 생성한 후 정확성을 평가하였다. 평가 결과, AutoRAG가 한국어 문장 표현의 자연성과 컨텍스트 기반의 정확성 측면에서 가장 뛰어난 성능을 보였으며, RAGAS는 문서 처리 과정에서 불필요한 정보 포함 등의 오류가 많았고, DeepEval은 한국어 지원 부족으로 인해 성능이 상대적으로 낮았다. 향후 연구에서는 LLM을 활용하여 사용자의 의도와 컨텍스트를 더욱 정확히 반영하는 고급 프롬프팅 기법과 자동화된 데이터 품질 평가 및 개선 전략을 중점적으로 탐색할 계획이다.

Abstract This paper conducts a comparative analysis of test dataset generation methods for evaluating the performance of Retrieval-Augmented Generation (RAG) systems, which have recently gained significant attention. It explains the necessity and importance of RAG technology in overcoming the limitations of large language models (LLMs) and summarizes the characteristics, advantages, and disadvantages of manually created datasets versus LLM-based automatic generation methods. Among automated dataset construction frameworks, RAGAS, AutoRAG, and DeepEval were selected, and for each, 100 question-answer pairs were generated using documents from the medical, financial, and legal domains. The accuracy of the generated datasets was then evaluated. The results showed that AutoRAG demonstrated the best performance in terms of natural Korean language expression and context-based accuracy. In contrast, RAGAS frequently included unnecessary information during document processing, and DeepEval showed relatively lower performance due to insufficient Korean language support. Future research will focus on developing advanced prompting techniques that more accurately reflect user intent and context, as well as exploring strategies for automated dataset quality evaluation and improvement.

Key Words : Dataset Generation, Evaluation, Frameworks, LLM, Retrieval-Augmented Generation (RAG)

This work was supported by the Institute of Information & Communications Technology Planning & Evaluation(IITP)-Innovative Human Resource Development for Local Intellectualization program grant funded by the Korea government (MSIT)(IITP-2025-RS-2024-00436773)
* Department of Healthcare IT Engineering, INJE Univeristy (qjatjr9958@oasis.inje.ac.kr)
** Corresponding Author : Department of Medical IT, INJE University (jinhong@inje.ac.kr)
Received April 01, 2025 Revised April 13, 2025 Accepted April 28, 2025

1. 서론

최근 대규모 언어 모델(LLM)은 대량의 데이터를 기반으로 한 심층 학습을 통해 텍스트의 이해, 요약 및 생성 능력에서 탁월한 성과를 나타내고 있다[1].

그러나 이러한 LLM은 일반적으로 공개된 인터넷 자료나 도서 등에서 특정 시점까지의 정보만을 학습하기 때문에, 최신 정보나 특정 도메인에 대한 상세 지식을 실시간으로 제공하는 데 한계가 있다. 이러한 정보의 지연성 및 도메인 특화 지식의 부족은 현실 세계의 다양한 응용 분야에서 활용성을 제한하고 있다[2].

이러한 한계를 극복하기 위해 최근 연구 분야에서 주목받는 기술이 검색 증강 생성(RAG: Retrieval-Augmented Generation) 아키텍처이다. RAG 기술은 2020년 Facebook AI(현재 Meta AI) 연구팀에 의해 제안된 것으로, LLM이 질문이나 특정 작업과 관련된 외부 지식을 실시간으로 검색하여 이를 컨텍스트로 활용함으로써 모델의 성능과 효율성을 크게 향상시킨다[3]. 보다 구체적으로, RAG는 사용자가 질문이나 요청을 입력했을 때 우선 외부 지식 베이스 또는 웹에서 관련 정보를 검색하고, 검색된 정보를 LLM의 컨텍스트로 제공하여 질문과 직접적으로 관련된 응답을 생성하도록 유도한다. 이 과정에서 LLM은 기존의 사전 학습된 지식을 유지하면서도, 검색된 최신 정보를 반영하여 정확하고 신뢰할 수 있는 결과를 도출한다.

이러한 RAG 시스템을 평가하기 위해서는 평가 목적에 부합하는 테스트 데이터 세트 구축이 필수적이다. 일반적으로 RAG 평가 데이터 세트는 질문, 컨텍스트 및 정답(ground truth answer)의 세 가지 요소로 구성된다[4]. 질문은 시스템이 해결해야 할 정보 요구 사항을 명확히 나타내며, 컨텍스트는 외부 지식 소스로부터 검색된 증거로서 LLM의 답변 생성 과정에 투입되는 핵심 정보이다. 정답은 평가 기준으로 사용되며, RAG 시스템이 생성한 답변이 제공된 컨텍스트를 기반으로 얼마나 정확하고 관련성이 높으며 충실한지를 판단하는 기준이 된다.

본 논문에서는 RAG 시스템의 성능을 확인하기 위한 자동 데이터셋 생성 프레임워크에 대해 산업안전보건법 문서를 기반으로 성능 평가를 수행하고 각각을 비교한다.

2. 데이터 셋 생성 방법론

효과적인 RAG 시스템의 성능 평가를 위해서는 정확하고 신뢰할 수 있는 테스트 데이터 셋의 확보가 필수적이다[5]. 테스트 데이터 셋의 품질은 평가의 정확성에 직접적인 영향을 미치며, 데이터 셋을 구축하는 방법론은 평가 데이터의 성격과 효용성을 결정짓는 중요한 요인이 된다. 본 장에서는 대표적인 두 가지 데이터 셋 생성 방법론, 즉 사람이 직접 데이터를 구축하는 방법과 대규모 언어 모델(LLM)을 활용한 자동 데이터 생성 방법에 대해 상세히 기술한다.

2.1 사람이 직접 생성하는 데이터 셋

RAG 시스템을 평가하기 위한 가장 전통적인 방식 중 하나는 평가자가 직접 질문, 이상적인 답변(ground truth) 및 관련 맥락 정보를 구성하여 데이터 셋을 구축하는 것이다. 이러한 수동 방식의 가장 큰 장점은 평가 목적과 기준을 명확히 정의할 수 있으며, 실제 사용자의 질의 의도와 현실적인 질문 패턴을 반영할 수 있다는 점이다[6].

사람이 직접 테스트 데이터를 생성하는 과정은 일반적으로 평가 목표 및 질문 유형 정의, 이상적인 답변과 관련 맥락 정보 구성, 생성된 데이터의 정리와 검수라는 단계로 이루어진다. 우선 평가자는 시스템의 목표와 평가 범위를 명확히 설정한 뒤, 실제 사용 환경에서 자주 발생할 수 있는 사실 확인형, 비교형, 설명형 등 다양한 질문 유형을 설계한다. 이후 평가자는 도메인 전문 지식을 바탕으로 질문에 대한 이상적이고 정확한 답변을 작성하며, 이러한 답변을 뒷받침할 수 있는 관련 문서 또는 텍스트 구절을 수집하여 맥락 정보를 구축한다. 마지막으로 이렇게 생성된 질문-답변-맥락 정보는 객관적 검수를 거쳐 일관되고 체계적인 데이터 셋으로 정리된다.

대표적인 사례로는 자연어 이해 평가를 위한 Google의 Natural Questions 데이터 셋(Kwiatkowski et al., 2019)이나 스탠퍼드의 SQuAD 데이터 셋(Rajpurka

r et al., 2016)과 같은 수동 구축 데이터 셋이 있으며, 특히 법률, 의료, 금융 등 특정 도메인의 깊이 있는 평가에 유리하다[7][8].

그러나 수동 방식은 많은 시간과 비용이 소요되는 반면, 평가자의 주관성 개입 가능성과 데이터 양 및 다양성을 확보하기 어렵다는 한계를 가지고 있어, 최근에는 자동화 방식이 더욱 주목받고 있다.

2.2 LLM을 활용한 데이터 셋 생성

최근 대규모 언어 모델(LLM)의 발전은 테스트 데이터 셋 구축 방법에 중요한 혁신을 가져왔다[9]. LLM은 문서 내용을 바탕으로 질문과 답변을 자동 생성하는 능력을 갖추고 있어 데이터 생성의 효율성을 획기적으로 높일 수 있다. 일반적으로 LLM을 활용한 데이터 셋 생성 방식은 문서 기반의 질문-답변 자동 생성, 품질 평가 및 필터링, 데이터 후처리 및 최종화 단계로 구성된다. 첫째, 준비된 문서나 외부 지식 데이터를 LLM에 입력하여, 프롬프트 엔지니어링 기법을 통해 질문의 유형, 난이도 및 도메인을 세밀하게 제어하며 질문-답변 쌍을 대규모로 생성한다. 둘째, 생성된 데이터는 자동화된 필터링 절차를 통해 사실적 정확성, 문법적 적합성, 중복 여부 등을 평가하고, 필요한 경우 인간 평가자의 반자동 검수를 병행하여 데이터 품질을 높인다. 마지막으로 검증된 질문-답변 쌍에 적절한 맥락 정보를 연결하고 추가적인 후처리를 실시하여 평가에 적합한 형태의 데이터 셋으로 완성한다. 이러한 자동화 방식은 데이터 구축에 소요되는 시간과 비용을 현저히 절감할 수 있으며, 질문의 다양성과 확장성 측면에서도 뛰어난 장점을 제공한다. 특히 RAGAS, AutoRAG, DeepEval 등 최신 프레임워크는 LLM을 활용하여 자동화된 평가 데이터 셋 생성과 품질 검증 도구를 지원하여 연구자들이 신속하고 신뢰할 수 있는 데이터를 구축하도록 돕는다. 그러나 LLM 기반 데이터 생성 방식은 생성된 질문의 사실 정확성 문제, 모델 자체의 편향성, 지나치게 단순하거나 현실성을 떨어뜨리는 인위적 질문 생성 가능성과 같은 한계도 존재한다. 이를 극복하기 위해서는 데이터 품질 관리 및 검증 절차를 철저히 수행해야 한다.

본 연구는 앞서 언급된 RAGAS, AutoRAG, DeepEval과 같은 대표적인 프레임워크의 데이터 생성 결과 정확도를 상호 비교 분석함으로써, 실제로 RAG 시스템 구축 및 평가를 수행하고자 하는 연구자와 실무자들에게 각 프레임워크의 특징과 성능을 기반으로 실질적인 선택 기준을 제공하고자 한다[10][11][12].

3. 프레임워크 개요

3.1 RAGAS

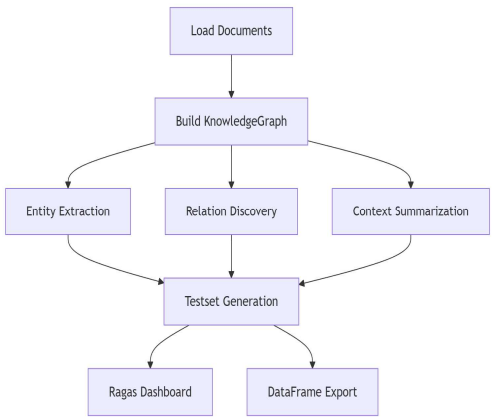

그림 1. RAGAS 데이터 셋 생성 흐름도
Fig. 1. RAGAS Dataset generation flow

그림 1은 RAGAS 프레임워크의 데이터 셋 생성 흐름도이다. RAGAS는 다양한 소스에서 문서를 로드한다. 이후 로드된 문서를 기반으로 지식 그래프(Knowledge Graph)를 구축한다. 지식 그래프는 문서 내에서 발견된 개체(Entity)와 관계(Relation)를 구조적으로 연결하여 정보를 체계화 한다. 지식 그래프가 완성되면, 이를 바탕으로 세 가지 주요 작업이 병렬적으로 이루어진다. 첫 번째로, 문서에서 중요한 개체를 추출하는 엔터티 추출(Entity Extraction) 작업이 수행된다. 두 번째로, 추출된 개체들 간의 관계를 탐색하고 정의하는 관계 발견(Relation Discovery) 과정이 진행된다. 세 번째로, 문서 내용을 요약하

여 핵심 정보를 간결하게 표현하는 콘텐츠 요약(Content Summarization)이 이루어진다.

이후, 이러한 작업을 통해 생성된 데이터를 기반으로 테스트 세트를 생성한다. 테스트 세트는 모델의 성능 평가와 시스템 검증에 활용된다. 마지막으로, 생성된 결과물은 두 가지 방식으로 출력된다. 하나는 RAGAS Dashboard를 통해 시각적으로 결과를 확인할 수 있는 형태로 제공되며, 데이터 프레임(Data Frame) 형태로 저장 가능하다.

3.2 AutoRAG

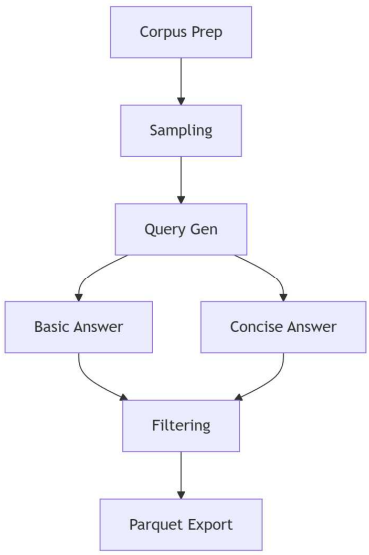

그림 2. AutoRAG 데이터 셋 생성 흐름도
Fig. 2. AutoRAG Dataset generation flow

그림 2는 AutoRAG 프레임워크의 데이터 셋 생성 흐름도이다. 첫 번째 단계인 코퍼스 준비(Corpus Prep) 과정에서는 원시 문서를 수집하고 정제한다. 이 단계에서는 다양한 소스로부터 획득한 문서들을 파싱하고, 정규화하며, 후속 처리를 위한 구조화된 형태로 변환한다. 이렇게 준비된 코퍼스는 AutoRAG 시스템의 기초 데이터로 활용된다.

두 번째 단계는 샘플링(Sampling)으로, 준비된 코퍼스에서 유의미한 콘텐츠를 추출하는 과정이다. 이 단계에서는 random_single_hop과 같은 샘플링 메서드를 적용하여 후속 질의 생성에 적합한 문서 조각들을 선별한다. 효과적인 샘플링 전략은 최종 데이터셋의 다양성과 대표성에 직접적인 영향을 미친다.

세 번째 단계인 쿼리 생성(Query Gen)에서는 대규모 언어 모델(LLM)을 활용하여 앞서 샘플링된 텍스트 조각을 기반으로 질문을 자동 생성한다. 이 과정에서는 factoid_query_gen과 같은 함수를 사용하여 코퍼스의 내용에 기반한 사실적 질문을 생성한다. 이 단계는 데이터셋의 질적 특성을 결정짓는 핵심 프로세스다.

네 번째 단계는 두 가지 병렬 경로로 진행되는 답변 생성 과정이다. '기본 답변(Basic Answer)' 경로에서는 make_basic_gen_gt 함수를 통해 질문에 대한 상세한 답변을 생성한다. 동시에 '간결한 답변(Concise Answer)' 경로에서는 make_concise_gen_gt 함수를 사용하여 더 압축되고 직접적인 답변을 생성한다. 이러한 이중 답변 접근법은 다양한 RAG 시스템 평가 시나리오에 대응할 수 있는 유연성을 제공한다.

다섯 번째 단계인 필터링(Filtering)에서는 생성된 질문-답변 쌍의 품질을 평가하고 부적절하거나 저품질의 데이터를 제거한다. dontknow_filter_rule_based와 같은 필터링 규칙을 적용하여 "don't know" 형태의 불확실한 답변이나 관련성이 낮은 쌍을 제거한다. 이 과정은 최종 데이터셋의 신뢰성과 유용성을 보장하는 중요한 단계이다.

마지막 단계는 파켓 내보내기(Parquet Export)로, 생성되고 필터링된 데이터셋을 효율적인 파켓(Parquet) 형식으로 저장한다. 파켓 형식은 컬럼 기반 데이터 저장 방식으로, 대규모 데이터셋의 효율적인 저장과 빠른 검색을 가능하게 한다.이 형식으로 저장된 QA 데이터셋과 코퍼스 데이터는 다양한 RAG 시스템 개발 및 벤치마킹에 즉시 활용될 수 있다.

3.3 DeepEval

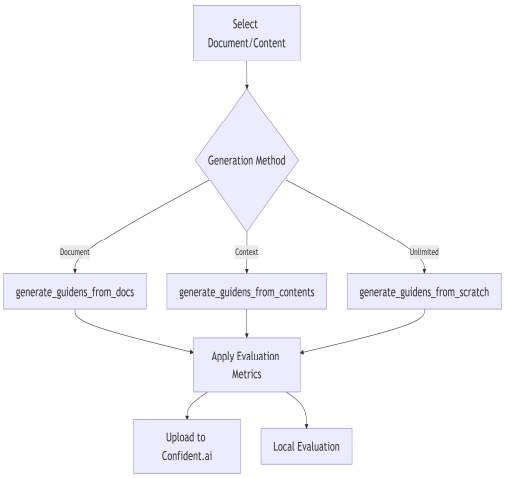

그림 3. DeepEval 데이터 셋 생성 흐름도
Fig. 3. DeepEval Dataset generation flow

그림 3은 DeepEval 프레임워크의 데이터 셋 생성 흐름도이다.첫 번째 단계에서는 문서 또는 컨텍스트를 선택하는 과정이 이루어진다. 이 단계에서 사용자는 평가 데이터셋 생성의 기초가 될 소스 자료를 지정한다. 이는 텍스트 파일, PDF, Word 문서 등 다양한 형식의 문서가 될 수 있으며, 이미 준비된 컨텍스트 목록을 사용할 수도 있다.

두 번째 단계에서는 생성 방법을 결정한다. DeepEval은 세 가지 주요 생성 방법을 제공한다: 문서 기반 생성(generate_goldens_from_docs), 컨텍스트 기반 생성(generate_goldens_from_contexts), 그리고 제한 없는 생성(generate_goldens_from_scratch)이다. 문서 기반 생성 방법은 지식 베이스 문서에서 추출한 컨텍스트를 기반으로 골든(입력과 기대 출력 쌍)을 생성한다. 컨텍스트 기반 생성은 사용자가 준비한 컨텍스트 목록을 사용하며, 제한 없는 생성은 지식 베이스에 의존하지 않고 자유롭게 데이터를 생성한다. 각 생성 방법은 내부적으로 DeepEval의 Synthesizer를 사용하며, 모든 방법은 동일한 네 단계 파이프라인(입력 생성, 필터링, 진화, 스타일링)을 따른다. 문서 기반 생성의 경우, 추가적인 컨텍스트 구성 단계가 선행되며, 모든 방법에는 최종 스타일링 전에 기대 출력 생성 단계가 포함된다. 특히 문서로부터 생성할 때는 Synthesizer가 먼저 문서에서 컨텍스트를 추출한 다음, 해당 컨텍스트에 기반하여 입력과 기대 출력을 생성한다.

생성된 데이터셋에는 평가 메트릭이 적용된다. DeepEval은 GEval과 같은 연구 기반 메트릭을 제공하여 LLM 출력을 인간과 유사한 정확도로 평가할 수 있게 한다. 이러한 메트릭은 생성된 골든 데이터셋을 사용하여 LLM 어플리케이션의 성능을 다양한 측면에서 평가한다.

마지막으로, 평가 결과는 두 가지 방식으로 활용될 수 있다. 하나는 Confident AI에 업로드하여 다양한 테스트 실행을 비교하고 시각화하는 것이고, 다른 하나는 로컬에서 평가 결과를 분석하는 것이다. Confident AI에 업로드하면 회귀 테스트나 개선 사항을 쉽게 식별할 수 있어,LLM 어플리케이션의 지속적인 개선에 도움이 된다.

DeepEval의 데이터셋 생성 프로세스는 높은 수준의 사용자 정의가 가능하다. StylingConfig를 통해 출력 스타일과 형식을 맞춤화할 수 있으며, FiltrationConfig와 EvolutionConfig를 통해 필터링 정도와 진화 복잡성을 조정할 수 있다. 이러한 유연성은 다양한 LLM 어플리케이션 평가 시나리오에 적합한 데이터셋을 생성할 수 있게 한다.

4. 연구 방법

4.1 연구 설계

본 연구의 목적은 RAG 시스템의 성능 평가를 위한 자동 테스트 데이터 셋 생성 분야에서 대표적으로 활용되는 RAGAS, AutoRAG, DeepEval 세 가지 프레임워크 간의 성능 차이를 비교 분석하는 데 있다. 이를 통해 프레임워크의 선택이 실제 생성되는 데이터 셋의 품질과 정확도에 어떠한 영향을 미치는지를 실증적으로 규명하고자 한다. 연구 설계는 실험 연구 방식을 채택하였으며, 독립 변수로서 데이터 셋 자동 생성 프레임워크(RAGAS, AutoRAG, DeepEval)를 설정하고, 각 프레임워크를 통해 생성된 테스트 데이터 셋의 성능 및 품질을 종속 변수로 설정하

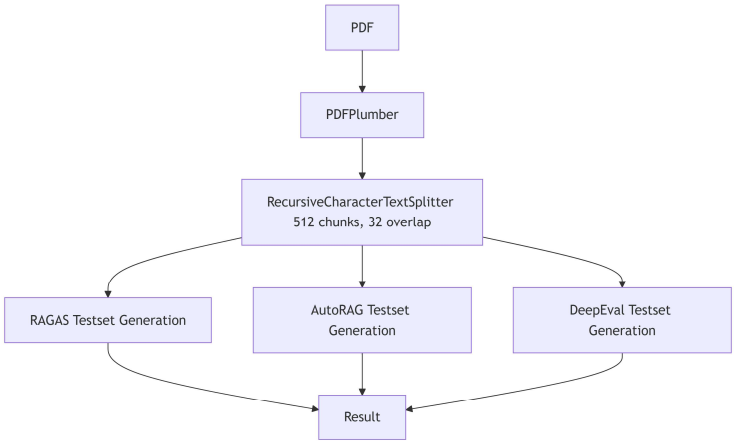

그림 4. 연구 절차
Fig. 4. research procedure

였다.

연구의 객관성을 확보하고 각 프레임워크 간 성능 비교의 공정성을 유지하기 위해 모든 데이터 셋 생성 과정에서 동일한 전처리 기준을 적용한 세 가지 도메인의 문서를 입력으로 활용하였다. 사용된 문서는 금융 도메인의 지급결제제도(한국은행), 의료 도메인의 결핵진료지침, 그리고 법률 도메인의 산업안전보건법 문서이다.또한, 동일한 LLM 모델(GPT-4o-mini)을 적용하여 입력 데이터와 언어 모델의 영향력을 통제하였다. 이를 통해 본 연구는 프레임워크 자체의 특성과 기능적 차이에 의한 성능 격차를 명확하게 분석할 수 있도록 설계되었다. 성능 비교의 신뢰성을 높이기 위해, 각 프레임워크별로 각 도메인에서 총 100개의 질문-답변-컨텍스트 세트를 기준으로 데이터 셋을 생성하였으며, 각데이터 셋의 품질은 정확도, 사실성, 관련성 등의 다양한 관점에서 정량적 및 정성적으로 비교 평가하도록 한다.

4.2 연구 절차

본 연구의 구체적인 연구 절차는 그림4와 같다. 먼저, 실험에 사용될 테스트 데이터셋을 생성하기 위해 금융 도메인의 지급결제제도(한국은행), 의료 도메인의 결핵진료지침, 그리고 법률 도메인의 산업안전보건법 문서를 선정하였다.

금융 도메인에서는 한국은행이 발행한 공식 문서를 활용하였으며, 지급결제제도의 기본 구조와 금융시장 인프라 운영에 관한 체계적인 설명을 제공한다. 의료 도메인에서는 국가 결핵 관리지침을 기반으로 한 결핵진료지침을 사용하여, 결핵의 진단 및 검사 프로토콜을 종합적으로 다루었다. 법률 도메인에서는 산업재해 예방과 관련된 법적 기준을 명시한 산업안전보건법을 활용하여, 최신 개정 사항을 반영한 안전보건 관리체계를 분석하였다. PDF 문서에서 정확한 텍스트를 추출하기 위해 PDFPlumber 라이브러리를 활용하여 PDF 형식을 텍스트 형식으로 파싱(parsing)하였다. 이 과정은 추출된 텍스트의 정확성을 높이고, 이후 진행되는 문서 처리 과정에서의 오류 발생 가능성을 최소화하기 위함이다.

이어서 파싱된 텍스트는 RAG 시스템에서 일반적으로 활용되는 문서 처리 방식인 청킹(chunking) 과정을 수행하였다. 구체적으로, LangChain 라이브러리에서 제공하는 RecursiveCharacterTextSplitter를 활용하여 텍스트를 512 토큰 크기의 청크로 나누었으며, 각 청크 간에는 32 토큰의 오버랩(overlap)을 설정하여 각 청크가 충분한 맥락 정

보를 포함하면서도 모델 입력 제
한을 초과하지 않도록 하였다. 이러한 청킹 전략은 생성되는 질문과 답변이 보다 정확하고 컨텍스트에 충실한 정보를 담을 수 있도록 지원한다.

이후, 준비된 문서 청크는 세 가지 프레임워크(RAGAS, AutoRAG, DeepEval)의 자동 테스트 데이터 셋 생성 기능에 각각 입력되어 질문-답변-컨텍스트 세트를 생성하였다. 데이터 셋 생성 시, AutoRAG와 RAGAS는 프레임워크에서 기본으로 제공하는 한국어 프롬프트를 그대로 활용하였다. 반면 DeepEval의 경우 공식적으로 제공되는 한국어 지원 프롬프트가 없기 때문에, 이 프레임워크에서 제공하는 StylingConfig 모듈을 활용하여 한국어 기반의 프롬프트를 별도로 작성하고 최적화하여 데이터 셋 생성 과정에서 프레임워크 간 언어적 편차를 최소화하였다.

본 연구의 전체 실험 과정은 이와 같은 절차를 통해 공정한 조건에서 데이터를 구축하고, 결과를 상세히 비교·분석함으로써 각 프레임워크의 성능과 특징을 객관적이고 체계적으로 평가할 수 있도록 설계하였다.

5. 결과

본 연구에서는 RAGAS, AutoRAG, DeepEval 세 가지 프레임워크를 사용하여 각각 50개의 질문-답변-컨텍스트 세트를 생성하였다. 앞서 서론에서 기술한 바와 같이, RAG 시스템 평가를 위한 테스트 데이터 셋은 질문(question), 컨텍스트(context), 정답(answer)의 세 가지 요소로 구성된다. 다만 각 프레임워크별로 생성된 데이터 셋의 컬럼명이 서로 다르므로, 이를 명확히 구분하기 위해 프레임워크별 질문, 컨텍스트, 정답에 해당하는 컬럼명을 표 1에 정리하였다.

표 1. 프레임워크별 컬럼 명
Table 1. Column name of each framework

Framework	Question	Context	Answer
RAGAS	user_input	reference_contexts	reference
AutoRAG	query	retrieval_gt_contents	generation_gt
DeepEval	input	context	expected_output

생성된 테스트 데이터의 품질 평가는 프레임워크별·도메인별로 구성된 평가표를 기반으로 수행되었으며, 이는 본 연구에서 정의한 질문 및 답변 평가 기준에 따라 구조화된 엑셀 시트를 활용하였다. 평가 작업은 저자를 포함한 IT 전공자 2인이 각각 독립적으로 진행하였으며, 각 항목은 사전에 정의된 평가 기준에 맞춰 정성적으로 판단하였다. 해당 기준은 표 2에 제시되어 있다. 추가적으로, 평가자 간의 일관성을 검증하기 위해 Cohen's Kappa 계수를 계산하여 평가 신뢰도를 정량적으로 측정하였다[13].

먼저, 질문의 정확도 평가는 두 가지 측면에서 이루

표 2. 테스트 데이터 셋 평가 기준
Table 2. Test data set evaluation criteria

Evaluation Target	Evaluation Item	Detailed Criteria	Correctness Condition
Question	Naturalness in Korean	Is the generated question naturally expressed in Korean?	Correct only if both criteria are satisfied
	Context-based Generation	Is the generated question accurately based on the provided context?	
Answer	Naturalness in Korean	Is the generated answer naturally expressed in Korean?	Correct only if all three criteria are satisfied
	Relevance to the Question	Does the generated answer properly address the intent of the given question?	
	Context-based Generation	Is the generated answer accurately based on the provided context?	

어졌다. 첫 번째는 질문이 문법적으로 올바른 자연스러운 한국어 문장으로 생성되었는지를 확인하는 것이며, 두 번째는 주어진 컨텍스트(문맥) 기반으로 의미 있는 질문이 잘 생성되었는지를 판단하였다.

답변의 정확도 평가는 총 세 가지 평가 기준이 적용되었는데, 첫째는 답변이 자연스러운 한국어 문장으로 생성되었는지, 둘째는 해당 답변이 주어진 질문과 논리적으로 연관성을 가지고 있는지, 셋째는 주어진 컨텍스트에 기반한 타당한 내용을 포함하고 있는지를 검토하였다.

이러한 기준에 따라 수행된 평가 결과는 이어지는 도메인별 평가 결과 표에 정리하였다. 각 평가 결과표에서는 질문 및 답변 평가 기준을 표 2에서 제시한 순서(1번: 질문의 문법적 자연성, 2번: 질문의 컨텍스트 적합성, 3번: 답변의 문법적 자연성, 4번: 답변의 질문 연관성, 5번: 답변의 컨텍스트 적합성)에 따라 항목 번호를 부여하여 표시하였다. 각 항목에 대한 세부 설명은 본문에서 별도로 반복하지 않고, 표 번호 및 항목 번호를 기준으로 해석하면 된다.

5.1 금융 도메인 평가 결과

표 3은 금융 도메인에서 평가 기준별로 평가자별 정답 수를 정리한 것이며, 표 4는 평가자 간 평가 결과를 비교하여 일치한 항목 수를 나타낸다. 이어서 표 5는 이 결과를 바탕으로 산출한 Cohen's Kappa 값을 정리한 표이다.

표 3. 평가자 별 정답 수
Table 3. Numbers of Correct Answers per Evaluator

Framework		Question (out of 100 items)				
		Q1	Q2	Q3	Q4	Q5
RAGAS	Evaluator1	100	92	100	89	80
	Evaluator2	100	90	100	91	83
Auto RAG	Evaluator1	100	93	100	94	91
	Evaluator2	100	94	100	92	93
Deep Eval	Evaluator1	95	91	99	95	89
	Evaluator2	95	87	99	92	86

표 4. 평가자 간 평가 결과 일치 수
Table 4. Number of Agreement Cases Between Evaluators

Framework	Agreement(out of 100 items)				
	Q1	Q2	Q3	Q4	Q5
RAGAS	100	92	100	94	88
AutoRAG	100	98	100	96	97
DeepEval	100	91	100	95	91

표 5. cohen's kappa 결과
Table 5. cohen's kappa result

Framework	Question				
	Q1	Q2	Q3	Q4	Q5
RAGAS	1.000	0.5122	1.0000	0.6670	0.6026
AutoRAG	1.000	0.5888	1.000	0.5399	0.7965
DeepEval	1.000	0.5422	1.000	0.5902	0.5894

금융 도메인에서는 질문 및 답변의 자연스러움, 질문 컨텍스트 적합성, 답변 질문 연관성, 답변 컨텍스트 적합성 등 다섯 가지 평가 항목에 대해 프레임워크별 데이터 생성 품질을 비교하였다. 평가자별 정답 수와 평가자 간 일치 결과를 분석한 결과, 모든 프레임워크가 질문 및 답변의 한국어 생성 자연스러움 항목(Q1, Q3)에서 대체적으로 높은 성능을 보였으나 DeepEval에서 소폭 낮은 모습을 보였다. RAGAS, AutoRAG, DeepEval 모두 Q1과 Q3 항목에서 평가자 간 일치율 100%를 기록하였으며, Cohen's Kappa 값 역시 모두 1.0000으로, 거의 완벽한 수준의 평가 일치도를 보였다.

질문 컨텍스트 적합성(Q2) 항목에서는 프레임워크 간 차이가 나타났다. RAGAS는 평가자 간 일치율 92%, Cohen's Kappa 0.5122를 기록하였으며, DeepEval은 일치율 91%, Kappa 0.5422를 보였다. AutoRAG는 해당 항목에서 98%의 일치율과 0.5888의 Kappa를 기록하여 상대적으로 높은 평가 일치를 보였다.

답변 질문 연관성(Q4) 항목에서는 RAGAS가 평가자 간 일치율 94%, Kappa 0.6670을 기록하였고, DeepEval은 일치율 95%, Kappa 0.5902를 나타냈다. AutoRAG는 96%의 일치율과 0.5399의 Kappa 값을 보였다.

답변 컨텍스트 적합성(Q5) 항목에서는 전반적으로

평가 일치율이 다소 낮아졌다. RAGAS는 일치율 88%, Kappa 0.6026을 기록하였으며, DeepEval은 91%의 일치율과 0.5894의 Kappa를 보였다. AutoRAG는 해당 항목에서 97%의 평가 일치율과 0.7965의 Kappa를 기록하여, 세 프레임워크 중 가장 높은 일치 수준을 보였다.

이상의 결과를 통해 금융 도메인에서는 질문 및 답변의 자연스러움 항목에서 모든 프레임워크가 높은 성능을 보였으며, 컨텍스트 기반성 및 질문 연관성 항목에서는 프레임워크별로 다소 차이가 발생하는 경향을 확인할 수 있었다.

5.2 의료 도메인 평가 결과

표 6은 의료 도메인에서 평가 기준별로 평가자별 정답 수를 정리한 것이며, 표 7은 평가자 간 평가 결과를 비교하여 일치한 항목 수를 나타낸다. 이어서 표 8은 이 결과를 바탕으로 산출한 Cohen's Kappa 값을 정리한 표이다.

표 6. 평가자 별 정답 수
Table 6. Numbers of Correct Answers per Evaluator

Framework		Question (out of 100 items)				
		Q1	Q2	Q3	Q4	Q5
RAGAS	Evaluator1	95	92	95	94	68
	Evaluator2	95	86	95	91	71
Auto RAG	Evaluator1	100	97	100	90	91
	Evaluator2	100	94	100	92	92
Deep Eval	Evaluator1	98	89	100	93	86
	Evaluator2	98	94	100	91	87

표 7. 평가자 간 평가 결과 일치 수
Table 7. Number of Agreement Cases Between Evaluators

Framework	Agreement(out of 100 items)				
	Q1	Q2	Q3	Q4	Q5
RAGAS	100	92	100	90	73
AutoRAG	100	98	100	94	95
DeepEval	100	92	100	96	93

표 8. cohen's kappa 결과
Table 8. cohen's kappa result

Framework	Question				
	Q1	Q2	Q3	Q4	Q5
RAGAS	1.000	0.5951	1.0000	0.2816	.3638
AutoRAG	1.000	0.7685	1.000	0.6341	0.6787
DeepEval	1.000	0.4898	1.000	0.7286	0.7003

의료 도메인에서도 금융 도메인과 동일한 다섯 가지 평가 항목을 기준으로 프레임워크별 데이터 생성 품질을 비교하였다. 평가자별 정답 수와 평가자 간 일치 결과를 분석한 결과, 질문 및 답변의 한국어 생성 자연스러움 항목(Q1, Q3)에서는 모든 프레임워크가 높은 성능을 보였으나, RAGAS, DeepEval에서 소폭 낮은 성능을 보여주었다. 이는 치료 지침문서에 영어가 많이 포함되어있어 질문이 생성된 컨텍스트가 대부분 영어로 이루어져있는 경우 영어로 된 질문 및 답변을 생성하는 결과를 보였다 RAGAS, AutoRAG, DeepEval 모두 Q1과 Q3 항목에서 평가자 간 일치율 100%를 기록하였으며, Cohen's Kappa 값 또한 모두 1.0000으로 거의 완벽한 수준의 평가 일치도를 나타냈다.

질문 컨텍스트 적합성(Q2) 항목에서는 평가 일치율과 Kappa 값에서 프레임워크 간 차이가 확인되었다. RAGAS는 일치율 92%와 Kappa 0.5951을 기록하였고, DeepEval은 92% 일치율과 Kappa 0.4898을 보였다. AutoRAG는 98% 일치율과 0.7685의 Kappa 값을 기록하여 상대적으로 높은 평가 일치를 나타냈다.

답변 질문 연관성(Q4) 항목에서는 RAGAS가 평가자 간 일치율 90%, Kappa 0.2816을 기록하였으며, DeepEval은 96% 일치율과 0.7286의 Kappa, AutoRAG는 94% 일치율과 0.6341의 Kappa 값을 보였다.

답변 컨텍스트 적합성(Q5) 항목에서는 세 프레임워크 모두 상대적으로 낮은 일치율을 보였다. RAGAS는 일치율 73%, Kappa 0.3638을 기록하였으며, DeepEval은 일치율 93%와 Kappa 0.7003을 나타냈다. AutoRAG는 95% 일치율과 0.6787의 Kappa를 기록하여 세 프레임워크 중 가장 높은 일치율을 보였다.

이상의 결과를 통해 의료 도메인에서도 질문 및 답변의 자연스러움 항목에서는 모든 프레임워크가 매우 높은 품질을 달성하였으며, 컨텍스트 기반성 및 질문 연관성 항목에서는 프레임워크별로 평가자 간 일치율과 Kappa 값에서 차이를 보이는 경향을 확인할 수 있었다.

5.3 법률 도메인 평가 결과

표 9는 법률 도메인에서 평가 기준별로 평가자별 정답 수를 정리한 것이며, 표 10은 평가자 간 평가 결과를 비교하여 일치한 항목 수를 나타낸다. 이어서 표 11은 이 결과를 바탕으로 산출한 Cohen's Kappa 값을 정리한 표이다.

표 9. 평가자 별 정답 수
Table 9. Numbers of Correct Answers per Evaluator

Framework		Question (out of 100 items)				
		Q1	Q2	Q3	Q4	Q5
RAGAS	Evaluator1	100	82	100	93	71
	Evaluator2	100	86	100	95	74
Auto RAG	Evaluator1	100	95	100	91	82
	Evaluator2	100	93	100	93	84
Deep Eval	Evaluator1	96	92	98	89	89
	Evaluator2	96	94	98	92	84

표 10. 평가자 간 평가 결과 일치 수
Table 10. Number of Agreement Cases Between Evaluators

Framework	Agreement(out of 100 items)				
	Q1	Q2	Q3	Q4	Q5
RAGAS	100	94	100	96	86
AutoRAG	100	98	100	96	92
DeepEval	100	96	100	97	92

표 11. cohen's kappa 결과
Table 11. cohen's kappa result

Framework	Question				
	Q1	Q2	Q3	Q4	Q5
RAGAS	1.000	0.7774	1.0000	0.6460	0.6493
AutoRAG	1.000	0.8230	1.000	0.7286	0.5894
DeepEval	1.000	0.6933	1.000	0.7100	0.6593

법률 도메인에서 동일하게 다섯 가지 평가 항목에 대해 프레임워크별 데이터 생성 품질을 비교하였다. 평가자별 정답 수와 평가자 간 일치 결과를 분석한 결과, 질문 및 답변의 한국어 생성 자연스러움 항목(Q1, Q3)에서는 모든 프레임워크가 높은 평가 결과를 보였다. RAGAS, AutoRAG, DeepEval 모두 Q1과 Q3 항목에서 평가자 간 일치율 100%를 기록하였으며, 이에 따른 Cohen's Kappa 값도 모두 1.0000으로 나타나 거의 완벽한 평가 일치도를 보였다.

질문 컨텍스트 적합성(Q2) 항목에서는 프레임워크 간 일부 차이가 확인되었다. RAGAS는 평가자 간 일치율 94%, Kappa 0.7774를 기록하였고, DeepEval은 일치율 96%, Kappa 0.6933을 나타냈다. AutoRAG는 98% 일치율과 0.8230의 Kappa 값을 기록하여 상대적으로 가장 높은 평가 일치 수준을 보였다.

답변 질문 연관성(Q4) 항목에서는 RAGAS가 평가자 간 일치율 96%, Kappa 0.6460을 기록하였으며, DeepEval은 97% 일치율과 0.7100의 Kappa, AutoRAG는 96% 일치율과 0.7286의 Kappa를 보였다.

답변 컨텍스트 적합성(Q5) 항목에서는 RAGAS가 일치율 86%와 Kappa 0.6493을 기록하였고, DeepEval은 92% 일치율과 0.6593의 Kappa를 나타냈다. AutoRAG는 92% 일치율과 0.5894의 Kappa를 기록하였다.

이상의 결과를 통해 법률 도메인에서도 질문 및 답변의 자연스러움 항목에서는 모든 프레임워크가 매우 높은 품질을 보였으며, 컨텍스트 기반성과 질문 연관성 항목에서는 프레임워크별로 평가자 간 일치율과 Kappa 값에 일부 차이가 발생하는 경향을 확인할 수 있었다.

6. 결론

본 연구에서는 RAGAS, AutoRAG, DeepEval 세 가지 프레임워크를 대상으로, 금융, 의료, 법률 도메인별 테스트 데이터셋을 생성하고, 생성된 질문-컨텍스트-답변 세트에 대해 평가 기준별 성능을 비교 분석하였다. 모든 프레임워크는 자연스러운 한국어 질문 및 답변 생성 항목(Q1, Q3)에서는 높은 성능을 보였으며, 이중 AutoRAG가 3개의 프레임 워크 중 한국어 데이터 셋 생성 측면에 있어 가장 높은 정확도를 보였다. 평가자 간 일치율 또한 거의 완벽한 수준(κ = 1.0000)을 기록하였다.

반면, 질문 컨텍스트 적합성(Q2), 답변 질문 연관성(Q4), 답변 컨텍스트 적합성(Q5) 항목에서는 프레임워크별로 평가자 간 일치율 및 Cohen's Kappa 값에 차이를 보였다. 특히 답변 컨텍스트 기반성(Q5) 항목에서는 전반적으로 일치율이 낮아지는 경향을 보였으며, 프레임워크별로 평가자 해석 차이가 가장 크게 나타나는 항목임을 확인할 수 있었다.

모든 프레임워크는 기본(Default) 설정을 적용하여 데이터셋을 생성하였으며, 이로 인해 프레임워크별 고유한 질문 생성 전략과 답변 생성 방식이 평가 결과에 영향을 미친 것으로 분석된다. RAGAS는 지식그래프를 활용해 single-hop, multi-hop에서 컨텍스트에 없는 추상적 질문을 받는 상황 대비해 추상적 질문에 대한 답변을 생성하는 기능이 default 설정에 포함 되어있어, 해당 기능으로 생성된 질문은 문맥 기반성 평가 항목에서 평가자 간 해석 차이가 다소 많이 발생하였다. 하지만, 이는 적절한 옵션 조정, 데이터 파싱 및 청킹 전략 최적화, 보다 성능이 우수한 LLM 사용 등을 통해 성능을 충분히 개선 할 수 있다고 판단된다.

AutoRAG는 다른 프레임워크와 달리, 제공된 컨텍스트가 불충분할 경우 구체적 내용을 추론하거나 생성하는 대신 "추가 정보가 필요하다"는 메시지를 답변에 명시하는 보수적 전략을 채택하였다. 이로 인해 컨텍스트 기반성 평가 항목(Q5)에서 평가자 간 일치율이 상대적으로 높게 나타났으며, 특히 금융과 의료 도메인에서는 답변의 일관성과 신뢰성을 강화하는 데 긍정적인 영향을 미친 것으로 분석된다.

DeepEval은 단일 문맥(single-hop) 기반 질문 생성을 중심으로 설계되어, 단순 질의응답 형태에서는 안정적인 평가 결과를 보였으나, 복잡한 문맥이나 다단계 추론이 필요한 상황에서는 평가자 간 해석 차이가 다소 발생하였다. 특히 의료 및 금융 도메인에서는 복합적 문맥을 요구하는 경우 답변 품질 및 평가 일치도가 일부 저하되는 경향이 관찰되었다.

종합적으로, 본 연구 결과는 모든 프레임워크가 자연스러운 한국어 질문 및 답변 생성에서는 신뢰할 수 있는 성능을 보였으나, 문맥 기반 정확성과 답변 일관성 항목에서는 프레임워크별 전략적 차이에 따라 품질 편차가 발생함을 보여준다.

향후 연구에서는 대규모 언어 모델(LLM)을 활용하여 더욱 정확하고 사실적인 질문 생성을 위한 프롬프팅 방법론과 기술적 접근법을 심도 있게 연구할 필요가 있다. 특히, LLM을 이용하여 사용자의 의도를 정확히 반영한 질문 생성 기법, 질문과 컨텍스트의 연관성을 자동으로 평가하고 개선하는 방법, 복잡한 맥락에서 정확한 답변 생성이 가능하도록 LLM의 문장 생성 능력을 향상시키는 기술적 접근 등을 탐색할 것이다.

REFERENCES

[1] T. B. Brown, B. Mann, N. Ryder, et al., "Language Models are Few-Shot Learners", arXiv:2005.14165, 2020.

[2] E. M. Bender, T. Gebru, A. McMillan-Major, and S. Shmitchell, "On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?", Proc. of the 2021 ACM Conference on Fairness, Accountability, and Transparency, pp. 610-623, March, 2021.

[3] P. Lewis, E. Perez, A. Piktus, et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks", arXiv:2005.11401, 2020.

[4] Gao, L., Xiong, Y., Gao, K., Dai, X., & Xiao, G. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey. arXiv preprint arXiv:2312.10997.

[5] M. T. Ribeiro, T. Wu, C. Guestrin, S. Singh, "CheckList: A Rigorous Testing Methodology for NLP Models", Proc. of the 58th Annual

Meeting of the Association for Computational Linguistics, pp. 4902-4913, July, 2020.
[6] R. Snow, B. O'Connor, D. Jurafsky, A. Y. Ng, "Cheap and Fast---But Is It Good? Evaluating Non-Expert Annotations for Natural Language Tasks", Proc. of the 2008 Conference on Empirical Methods in Natural Language Processing, pp. 254-263, 2008.
[7] T. Kwiatkowski, J. Fu, D. Khashabi, et al., "Natural Questions: a Benchmark for Question Answering Research", Transactions of the Association for Computational Linguistics, vol. 7, pp. 453-466, 2019.
[8] A. Rajpurkar, J. Zhang, K. Lopyrev, P. Liang, "SQuAD: 100,000+ Questions for Machine Comprehension of Text", Proc. of the 2016 Conference on Empirical Methods in Natural Language Processing, pp. 2383-2392, 2016.
[9] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," June 2023.
[10] Shahul Es, Jithin James, Luis Espinosa-Anke, Steven Schockaert, "RAGAS: Automated Evaluation of Retrieval Augmented Generation," arXiv preprint arXiv:2309.15217, 2023.
[11] Dongkyu Kim, Byoungwook Kim, Donggeon Han, Matouš Eibich, "AutoRAG: Automated Framework for optimization of Retrieval Augmented Generation Pipeline," arXiv preprint arXiv:2410.20878, 2024.
[12] Yixin Yang, Zheng Li, Qingxiu Dong, Heming Xia, Zhifang Sui, "Can Large Multimodal Models Uncover Deep Semantics Behind Images?", arXiv preprint arXiv:2402.11281, 2024.
[13] Jacob Cohen. "A Coefficient of Agreement for Nominal Scales." Educational and Psychological Measurement, vol. 20, no. 1, pp. 37-46, 1960

저자약력

김 범 석 (Beomseok Kim)

- 2024년 2월: 인제대학교 BNIT융합대학 의료IT학과 학사
- 2024년 2월 ~ 현재: 인제대학교 일반대학원 헬스케어IT공학 석사

〈관심분야〉 Generative AI, LLM, Patent Analysis,개인정보보호

양 진 홍 (Jinhong Yang)

- 2017년 2월: KAIST 정보통신 공학 박사
- 2017년 2월 ~ 2018년 1월: HECAS 최고기술책임(CTO)
- 2017년 10월 ~현재: 한국과학기술원 IT융합연구소 겸직교수
- 2018년 3월 ~ 현재: 인제대학교 의료IT 학과 부교수

〈관심분야〉 데이터 컴플라이언스, 마이데이터, 헬스케어 데이터활용