

졸업자격시험보고서

한국어 질의-영어 학술·기술 문서
RAG에서의 HyDE·CAD·SCD 조합
실험

지도교수 [지도교수 입력]

[소속 학과 입력]
[소속 대학·캠퍼스 입력]

[학생명 입력], [학번 입력]

[제출연도 입력]

졸업자격실험보고서

한국어 질의-영어 학술·기술 문서 RAG에서의 HyDE·CAD·SCD 조합 실험

Combination Experiments of HyDE, CAD, and
SCD in RAG with Korean Queries over English
Academic and Technical Documents

[학생명 입력], [학번 입력]

지도교수 [지도교수 입력]

본 보고서를 졸업자격 실험보고서로 제출함.
[제출일 입력]

[학생명 입력]의 졸업자격 실험보고 통과를 인준함.
[인준일 입력]

주심 [주심 입력] (인)

부심 [부심 입력] (인)

[소속 대학·캠퍼스 입력] [소속 학과 입력]

국문초록

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 외부 문서에서 질문과 관련된 내용을 검색하고, 이를 생성 모델에 제공하여 답변을 생성하는 방법이다. 한국어 질문으로 영어 학술 및 기술 문서를 검색하는 과정에서는 질문과 원문의 표현 차이가 검색 결과에 영향을 줄 수 있다. 생성된 답변의 근거 충실도와 한국어 문자 비율은 각각 별도로 측정하였다. 본 연구에서는 Hypothetical Document Embeddings(HyDE), Context-Aware Decoding(CAD), Soft Constrained Decoding(SCD)을 각각 밀집 검색 입력 변경, 검색 문맥을 활용한 로짓 조정, 한국어 출력 제어에 적용하였다. 세 기법의 ON/OFF를 조합하여 RAG-Cube의 8개 실험 조건을 구성하였다.

검색 단계에서는 BGE-M3 밀집 검색과 BM25 희소 검색을 사용하고, 두 검색 결과를 weighted Reciprocal Rank Fusion으로 결합한 뒤 CrossEncoder로 재정렬하였다. 답변 생성에는 K-intelligence/Midm-2.0-Base-Instruct를 사용하였다. RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report를 대상으로 각 문서에 대한 한국어 평가 질의를 15개씩 작성하여 총 60개를 구성하였다. 각 질의에 8개 조건을 적용하고 480개의 생성 기록을 저장하였다. HyDE는 CAD와 SCD를 모두 OFF로 고정한 60개 대응쌍에서 비교하였다. CAD는 HyDE와 SCD를 모두 OFF로 고정하고 검색 문맥이 동일한 대응쌍에서 평가하였다. SCD는 HyDE를 OFF로 고정하고 검색 문맥이 동일한 120개 대응쌍을 주 비교로 사용하였으며, HyDE와 CAD의 적용 상태를 각각 맞춘 전체 240개 대응쌍도 분석하였다.

HyDE의 답변 관련성 평균 대응 차이는 +0.0805였고, 95% 신뢰구간은 [+0.0110, +0.1514]였다. 근거 충실도, 문맥 정밀도와 문맥 재현율의 평균 대응 차이는 각각 +0.0436, -0.0343, 0.0000이었다. CAD의 근거 충실도 평균 대응 차이는 양쪽 평가값이 있는 58쌍에서 +0.0288이었고, 95% 신뢰구간은 [-0.0367, +0.0934]로 0을 포함하였다. 답변 관련성의 평균 대응 차이는 60쌍에서 -0.0073이었다. SCD의 한국어 문자 비율 평균 대응 차이는 HyDE OFF 동일 문맥 120개 대응쌍에서 +0.2182였고, 95% 신뢰구간은 [+0.1880, +0.2487]였다. 전체 240개 대응쌍에서는 +0.2289였다.

주요어: Retrieval-Augmented Generation, HyDE, Context-Aware Decoding, Soft Constrained Decoding, 한국어 질의, 영어 학술 및 기술 문서, 언어 이탈

Abstract

Retrieval-augmented generation (RAG) retrieves information relevant to a question from external documents and supplies it to a generative model to produce an answer. When Korean questions are used to search English academic and technical documents, differences between the question and the source text can affect retrieval. We separately evaluated the faithfulness of generated answers to the retrieved evidence and the proportion of Korean characters in those answers. We used Hypothetical Document Embeddings (HyDE) to modify dense-retrieval inputs, Context-Aware Decoding (CAD) to adjust token scores using retrieved context, and Soft Constrained Decoding (SCD) to control Korean output. We evaluated eight combinations of these methods in a RAG-Cube experiment.

The Paper-RAG backbone used BGE-M3 for dense retrieval and BM25 for sparse retrieval. We combined their results using weighted Reciprocal Rank Fusion, reranked the candidates with a CrossEncoder, and generated answers with K-intelligence/Midm-2.0-Base-Instruct. We constructed 15 Korean evaluation queries for each of four English academic or technical documents, for a total of 60 queries. Each query was assigned a target document and evaluated under eight configurations, yielding 480 stored generation records. HyDE was compared on 60 matched pairs with CAD and SCD disabled. CAD was compared with HyDE and SCD disabled and the retrieval contexts held identical. The primary SCD comparison used 120 HyDE-OFF pairs with identical retrieval contexts. We also analyzed all 240 ON/OFF pairs matched by query and by HyDE and CAD settings.

The mean paired difference in answer relevancy between HyDE ON and OFF was +0.0805, with a 95% bootstrap confidence interval of [+0.0110, +0.1514]. The corresponding differences in faithfulness, context precision, and context recall were +0.0436, -0.0343, and 0.0000, respectively. In the identical-context CAD comparison, the mean paired difference in faithfulness was +0.0288 on 58 pairs with both scores available, with a 95% bootstrap confidence interval of [-0.0367, +0.0934], which included zero. The mean paired difference in answer relevancy was -0.0073 on 60 pairs. In the primary SCD comparison, the mean paired difference in the Korean-character ratio was +0.2182 on 120 HyDE-OFF identical-context pairs, with a 95% bootstrap confidence interval of [+0.1880, +0.2487]. The mean paired difference across all 240 state-matched pairs was +0.2289.

Keywords: Retrieval-Augmented Generation, HyDE, Context-Aware Decoding, Soft Constrained Decoding, Korean query, English academic or technical document, language drift

목 차

1. 서론	1
1.1 연구배경 및 목적	1
1.2 연구범위	1
1.3 연구 질문, 분석 관점 및 논문 구성	2
2. 이론적 배경	3
2.1 Retrieval-Augmented Generation	3
2.2 하이브리드 검색과 재정렬	3
2.3 HyDE와 가상 문서 기반 검색	5
2.4 Context-Aware Decoding	5
2.5 Soft Constrained Decoding과 언어 이탈	6
2.6 RAG 평가	7
2.7 관련 연구와 본 연구의 위치	8
3. 시스템 설계	10
3.1 연구 및 실험 요구사항	10
3.2 아키텍처 설계	10
3.3 상세설계	11
4. 프로그램 구현	13
4.1 시스템 환경	13
4.2 시스템 구성	14
4.3 시스템 구현	15
5. 실험	17
5.1 실험 대상과 구성	17
5.2 평가 및 분석 방법	17
5.3 RAG-Cube 조합별 결과	19
5.4 HyDE 결과 및 해석	20
5.5 CAD 결과 및 해석	22
5.6 SCD 출력 언어 결과 및 해석	24

5.7 대표 입출력 및 요구사항별 실행 결과	27
5.8 종합 논의	28
5.9 실험 범위와 해석 기준	30
6. 결론	31
6.1 연구 질문별 최종 답	31
6.2 비교 설계의 의의	31
6.3 적용 시 실험 조건 선택	32
6.4 후속 연구 방향	32
참고문헌	33
그림 자료 이용 정보	35
부록 A~B	36, 44

그 립 목 차

[그림 1-1] 한국어 질의와 영어 학술 및 기술 문서를 사용하는 RAG 실험 환경	1
[그림 2-1] RAG의 검색기-생성기 구조	3
[그림 2-2] 긴 문맥에서 관련 정보 위치에 따른 성능 변화	4
[그림 2-3] HyDE의 가상 문서 기반 검색 구조	5
[그림 2-4] Context-Aware Decoding의 분포 대조 구조	6
[그림 2-5] 다국어 RAG의 출력 언어 이탈 사례	6
[그림 2-6] RAGAS의 근거 충실도 높음/낮음 예시	8
[그림 3-1] HyDE, CAD, SCD를 조합한 RAG-Cube 8개 조건	11
[그림 4-1] 고정 Paper-RAG 백본 실행 흐름	14
[그림 4-2] 생성 기록-평가-대응 분석 흐름	16
[그림 5-1] 60개 질의 평가 및 HyDE, CAD, SCD의 대응 비교 설계	19
[그림 5-2] 평가 프로토콜별 RAG-Cube 조건 평균	20
[그림 5-3] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례	21
[그림 5-4] HyDE와 CAD의 주 대응 비교	22
[그림 5-5] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례	23
[그림 5-6] RAG-Cube 조건별 평균 실행 시간	24
[그림 5-7] SCD OFF 조건의 출력 언어 이탈 사례	25
[그림 5-8] 동일 검색 문맥에서 SCD 적용 전후 출력 언어 변화 사례	26
[그림 5-9] SCD의 한국어 문자 비율 변화	27
[그림 5-10] 질문, 검색 근거, 생성 답변과 평가 결과 예시	28
[그림 5-11] HyDE와 CAD의 조건군별 근거 충실도 및 답변 관련성 평균 대응 차이	29
[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 추가 사례	44

표 목 차

[표 2-1] 관련 연구와 본 실험의 연결	9
[표 3-1] 연구 및 실험 요구사항	10
[표 3-2] RAG-Cube 8개 조건	11
[표 3-3] 실험 요인별 적용 위치와 비교 단위	12
[표 4-1] 실험 실행 환경	13
[표 4-2] 고정 Paper-RAG 백본	14
[표 4-3] 실험 조건별 실행 시간	15
[표 4-4] 생성 기록의 주요 필드	15
[표 5-1] 4개 문서별 질의 구성	17
[표 5-2] SCD 평가 프로토콜별 RAG-Cube 조건 평균	19
[표 5-3] HyDE 주 비교 결과	21
[표 5-4] CAD 동일 문맥 주 비교 결과	23
[표 5-5] SCD 조합별 한국어 문자 비율 변화	26
[표 5-6] SCD 대응쌍 분석 요약	26
[표 A-1] 60개 질의-대상 문서 쌍	36
[표 B-1] 문서별 탐색 분석	45
[표 B-2] 질문 유형별 탐색 분석	46


1. 서론

1.1 연구배경 및 목적

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 외부 문서에서 질문과 관련된 내용을 검색하고, 검색된 문맥을 생성 모델에 제공하여 답변을 생성하는 방법이다[1]. 본 연구에서는 한국어 질의로 영어 학술 및 기술 문서에서 근거를 검색하고, 이를 이용해 한국어 답변을 생성하는 과정을 분석하였다. 한국어 질문과 영어 원문의 표현 차이는 검색 결과에 영향을 줄 수 있다. 생성된 답변에 대해서는 검색 근거에 대한 충실도와 한국어 문자 비율을 각각 측정하였다.

HyDE는 입력 질의를 바탕으로 가상 문서를 생성하고, 이를 벡터로 변환하여 관련 문서를 검색한다[2]. CAD는 검색 문맥을 포함한 입력과 제외한 입력에서 다음 토큰의 로짓을 각각 계산한다. 두 로짓을 가중 결합하여 토큰 선택에 반영한다[3]. SCD는 토큰을 목표 언어, 다른 언어와 중립 토큰으로 구분한다. 본 구현에서는 목표 언어와 다른 언어 토큰의 로짓에 각각 정해진 계수를 곱하고, 중립 토큰의 로짓은 유지한다[4].

HyDE, CAD, SCD를 같은 Paper-RAG 백본에 적용하고 각 기법의 ON/OFF 결과를 비교하였다[2][3][4]. HyDE는 적용 전후 검색 문맥과 생성 답변의 변화를 함께 비교하였다. CAD는 검색 문맥을 동일하게 유지한 상태에서 답변 품질과 조건 실행 시간을 비교하였다. SCD는 HyDE OFF 조건에서 검색 문맥이 동일한 대응쌍을 사용해 한국어 문자 비율의 변화를 분석하였다. 대응쌍의 구성과 문맥 동일성 확인 기준은 3.3절에 제시한다.



고정 Paper-RAG 백본에서 HyDE, CAD, SCD를 독립 실험 요인으로 적용

[그림 1-1] 한국어 질의와 영어 학술 및 기술 문서를 사용하는 RAG 실험 환경

1.2 연구범위

연구 대상으로 RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 영어 문서 4개를 선정하였다. 네 문서에 대해 각각 한국어 평가 질의 15개를 작성하였다. 총 60개 질의에는 각각 검색 대상 문서를 지정하였다. 각 질의에 8개 RAG-Cube 조건을 적용하여 480개의 생성 기록을 저장하였다. 검색 범위는 각 질의에 지정한 문서의 청크로 정하였다.

BGE-M3와 BM25의 검색 결과를 weighted RRF로 결합하고 CrossEncoder로 재정렬하였다. 재정렬 상위 5개 청크에 문맥 길이 관리 절차를 적용한 뒤 Mi:dm 2.0 Base Instruct에 입력하였다. 실행 설정은 4.1절에 정리하였다.

HyDE는 CAD와 SCD가 모두 OFF인 60개 대응쌍에서 검색부터 답변 생성까지의 변화를 비교하였다. CAD는 동일한 검색 문맥에서 생성한 답변의 품질과 조건 실행 시간을 비교하였다. SCD는 HyDE OFF 동일 문맥 120개 대응쌍을 주 비교로 삼고, 동일 질의의 HyDE와 CAD 상태를 각각 맞춘 전체 240개 대응쌍을 함께 분석하였다. 답변 품질은 RAGAS 지표로, 출력 언어는 한국어 문자 비율로 측정하였다.

1.3 연구 질문, 분석 관점 및 논문 구성

연구 질문은 다음 네 가지로 설정하였다. 첫째, CAD와 SCD를 OFF로 고정한 상태에서 HyDE를 적용하면 답변 관련성, 근거 충실도, 문맥 정밀도와 문맥 재현율은 어떻게 달라지는가? 둘째, 동일한 검색 문맥에서 CAD 적용 여부에 따라 답변 품질과 조건 실행 시간은 어떻게 달라지는가? 셋째, SCD 적용 여부에 따라 한국어 문자 비율은 어떻게 달라지는가? 넷째, 기법별 평가 결과와 조건 실행 시간을 기준으로 실험 조건을 어떻게 선택할 수 있는가?

SCD의 주 비교에는 HyDE를 OFF로 고정하고 검색 문맥이 동일한 120개 대응쌍을 사용하였다. 추가로 HyDE와 CAD의 적용 상태를 각각 맞춘 전체 240개 대응쌍도 분석하였다. 동일 질의의 ON 평가값에서 OFF 평가값을 뺀 대응 차이와 부트스트랩 신뢰구간을 계산하였다. 각 대응쌍의 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥을 대조하여 입력 문맥의 동일성을 확인하였다. 개별 사례에서는 질문, 검색 근거, 생성 답변과 평가값을 함께 제시하였다.


2장에서는 RAG와 세 실험 요인, 평가 및 관련 연구를 정리한다. 3장은 실험 요구사항과 비교 설계를, 4장은 구현과 생성 기록 저장 구조를 설명한다. 5장은 60개 질의 평가 결과와 사례를 제시하고, 6장은 주요 결과와 적용 기준 및 후속 연구를 종합한다.

2. 이론적 배경

2.1 Retrieval-Augmented Generation

RAG는 질의와 관련된 외부 문서를 검색하고, 검색한 문맥을 생성 모델에 제공하여 답변을 만드는 구조이다[1]. 검색기는 질의 q 를 이용해 문서 집합 D 에서 관련 문맥 C_q 를 선택한다. 생성 모델은 질의 q 와 검색된 문맥 C_q 를 입력받아 답변 y 를 생성한다. 검색 결과의 관련성과 답변의 근거 충실도는 별도로 평가한다.

Lewis 외[1]는 검색기(retriever)가 외부 문서 인덱스에서 관련 문서를 찾고, 생성기(generator)가 질의와 검색 문서를 함께 사용해 출력을 생성하는 RAG 구조를 제시하였다. 그림 2-1은 검색 문서를 생성기의 입력으로 제공하는 RAG 구조를 나타낸다. 본 연구에서는 HyDE를 밀집 검색 입력에 적용하고, CAD와 SCD를 답변 생성 단계에 적용하였다.



[그림 2-1] RAG의 검색기-생성기 구조

본 연구에서 작성한 도식이며, Lewis 외[1]의 RAG 구조를 참고하였다.

검색 청크 ID, 재정렬 청크 ID, 최종 검색 문맥과 생성 답변을 저장하고, 검색 문맥에 관한 지표와 답변에 관한 지표를 구분하여 계산하였다.

$$C_q = \text{Retrieve}(q, D)$$

$$y = \text{LM}(q, C_q)$$

2.2 하이브리드 검색과 재정렬

고정 백본은 BGE-M3 밀집 검색과 BM25 희소 검색을 결합한다. 밀집 검색은 질의와 문서 구간의 의미적 유사성을 기준으로 관련 문서 구간을 검색한다. BM25는 모델명, 약어, 수치처럼 질의와 원문에 동일하게 등장하는 표현을 검색 단서로 활용하였다[5][6]. 두 검색 결과의 순위를 weighted Reciprocal Rank Fusion으로 결합한다[7]. 이어 CrossEncoder가 원질의와 각 후보 구간의 관련성을 계산하여 순서를 다시 정한다[8].


밀집 검색과 BM25의 가중치는 각각 0.6과 0.4, 검색 후보 수와 재정렬 후보 수는 각각 8개, 최종 문맥 수는 5개로 고정하였다. 이 설정을 모든 RAG-Cube 조건에 공통으로 적용하였

다.

한국어로 작성한 질문은 영어 문서에 사용된 제목이나 방법론 용어와 어휘 및 표현 방식에서 차이가 날 수 있다. BM25의 어휘 일치 검색에는 논문명, 데이터셋명, 모델 크기와 하이퍼파라미터 표기를 검색 단서로 사용하였다.

재정렬은 검색 후보의 우선순위를 조정하고, 생성 모델은 선택된 문맥을 입력으로 답변을 만든다. HyDE 비교에는 검색 결과의 변화를 포함하였고, CAD 주 비교에서는 검색 문맥을 동일하게 유지하였다.

관련 문서 구간을 검색하더라도 생성 모델이 이를 활용하는 정도는 입력 내 위치에 따라 달라질 수 있다. Liu 외[9]는 다중 문서 질의응답에서 정답 문서가 입력의 처음이나 끝에 있을 때보다 중간에 있을 때 성능이 낮아지는 U자형 패턴을 보고하였다. 그림 2-2는 관련 정보의 입력 위치에 따른 성능 차이를 보여준다. 본 실험에서는 최종 입력 문맥을 상위 5개 청크로 구성하고, 재정렬 순서대로 배치하였다. 검색 성능과 답변 품질은 별도 지표로 평가하였다.



[그림 2-2] 긴 문맥에서 관련 정보 위치에 따른 성능 변화

출처: Liu 외[9], 그림 1에서 발췌.


본 실험에서는 RRF 상수 k 를 60으로 설정하였다. 두 검색 순위를 결합한 점수는 다음 식으로 계산하였다.

$$RRF(d) = \frac{0.6}{k + rank_{dense}(d)} + \frac{0.4}{k + rank_{BM25}(d)}$$

2.3 HyDE와 가상 문서 기반 검색

HyDE는 입력 질의를 바탕으로 가상 문서를 생성한 뒤, 이를 임베딩 벡터로 변환한다. 생성된 벡터를 이용해 실제 문서 집합에서 유사한 문서를 검색한다[2].

그림 2-3은 입력 질의로 가상 문서를 생성하고, 이를 임베딩한 뒤 실제 문서 집합을 검색하는 HyDE의 처리 과정을 나타낸다.



[그림 2-3] HyDE의 가상 문서 기반 검색 구조

출처: Gao 외[2]의 그림 1을 발췌하여 편집하였다.

HyDE ON 조건에서는 한국어 질의를 영어로 번역하고 가상 문서를 생성하였다. 생성된 가상 문서를 BGE-M3로 임베딩하여 밀집 검색에 사용하였다. BM25 검색과 CrossEncoder 재정렬에는 원래의 한국어 질의를 사용하였다. 검색 범위는 질의에 지정한 문서의 청크로 정하였으며, 최종 답변은 검색한 실제 문서 구간으로 생성하였다. HyDE ON/OFF 비교에서는 질의 번역과 가상 문서 생성에 따라 밀집 검색 입력이 달라진다. 검색 청크 ID와 최종 검색 문맥을 대조하여 검색 결과의 변화를 확인하고, 생성 답변의 답변 관련성도 함께 분석하였다.

2.4 Context-Aware Decoding

CAD는 검색 문맥을 포함한 경우와 제외한 경우에 계산한 다음 토큰의 점수를 비교하는 디코딩 방법이다. 두 조건에서 계산한 로짓을 가중 결합하여 검색 문맥의 영향을 토큰 선택에 반영한다[3]. CAD ON 조건에는 $\alpha=0.5$ 를 적용하였다. CAD 주 비교에는 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 동일한 대응쌍을 사용하였다.

그림 2-4에서 문맥을 포함한 분포와 제외한 분포는 모두 “Two”의 점수가 가장 높다. 두 분포의 로짓을 CAD 식으로 결합하면 문맥에 제시된 우승 횟수에 해당하는 “Three”가 선택된다.




Figure 1: An illustration of context-aware decoding.

[그림 2-4] Context-Aware Decoding의 분포 대조 구조

출처: Shi 외[3], 그림 1에서 발췌.

같은 질의와 생성 접두 시퀀스에서 계산한 문맥 포함 로짓을 z_{ctx} , 문맥 제외 로짓을 z_{noctx} 라고 하면, 본 연구의 CAD 점수는 다음과 같이 표현된다.

$$z_{CAD} = (1 + \alpha)z_{ctx} - \alpha z_{noctx}$$

CAD는 토큰을 생성할 때 검색 문맥을 포함한 입력과 제외한 입력에 대해 각각 다음 토큰의 로짓을 계산한다. 5.5절에서는 답변 품질의 대응 차이, 질의별 변화 분포와 조건 실행 시간의 증가를 분석하였다.

2.5 Soft Constrained Decoding과 언어 이탈

다국어 RAG에서는 검색 문서의 언어로 답변이 생성되는 출력 언어 이탈(language drift)이 발생할 수 있다. Li 외[4]는 목표 언어와 비목표 언어가 추론 과정에서 혼합된 뒤 최종 출력이 비목표 언어로 이동하는 사례를 분석하였다. 그림 2-5는 원 논문의 출력 언어 이탈 사례다.




Figure 1: Illustration of language drift in multilingual RAG. The user query and in-context examples are provided in the target language (e.g., Chinese), while the retrieved context is written in a non-target language (e.g., English). During reasoning, the model mixes languages and ultimately outputs the final answer in a non-target language.

[그림 2-5] 다국어 RAG의 출력 언어 이탈 사례

출처: Li 외[4]의 그림 1을 발췌하여 편집하였다.

SCD는 어휘 집합을 목표 언어 토큰, 비목표 언어 토큰과 중립 토큰으로 나누고, 토큰의 로짓을 조정하는 디코딩 방법이다[4]. 본 실험에서는 한국어를 목표 언어로 두고 $\alpha=1.1$, $\beta=0.9$, $T_{start}=5$ 를 사용하였다. 이미 생성된 토큰이 5개 미만이면 로짓을 그대로 사용하고, 5개 이상이면 한국어 목표 토큰의 로짓에는 α , 비목표 언어 토큰의 로짓에는 β 를 곱하였다. 중립 토큰의 로짓은 그대로 유지하였다. CAD와 함께 적용하는 조건에서는 CAD 로짓을 계산한 뒤 SCD를 적용하였다.

한국어 문자 비율은 생성 답변의 한글 문자 수를 한글 문자 수와 ASCII 영문자 수의 합으로 나누어 계산하였다.

SCD의 토큰 그룹별 점수 조정과 한국어 문자 비율은 다음 수식으로 정의한다.

$$\tilde{z}_i = \alpha z_i$$

$$\tilde{z}_i = \beta z_i$$

$$\tilde{z}_i = z_i$$

$$KoreanRatio = \frac{N_{Hangul}}{N_{Hangul} + N_{ASCII}}$$

한국어 문자 비율을 계산할 때는 답변에 포함된 영어 논문 제목, 모델명과 데이터셋명의 ASCII 영문자도 분모에 포함하였다. SCD 대응쌍의 구성과 변화 판정 기준은 5.2절에서 설명한다.

2.6 RAG 평가

HyDE와 CAD의 답변 품질은 RAGAS의 근거 충실도(faithfulness), 답변 관련성(answer relevancy), 문맥 정밀도(context precision), 문맥 재현율(context recall)로 평가하였다[10]. 근거 충실도는 검색 문맥이 답변의 주장을 뒷받침하는 정도를 측정한다. 답변 관련성은 평가 모델이 생성 답변을 바탕으로 만든 질문과 원질문의 의미적 유사도를 이용해 측정한다. 본 실험에서 사용한 RAGAS 0.2.15의 문맥 정밀도는 참조 답변을 기준으로 검색 문맥의 관련성을 판정하고, 관련 문맥이 상위에 배치되는 정도를 측정한다. 문맥 재현율은 검색 문맥이 참조 답변의 내용을 뒷받침하는 정도를 측정한다.

Es 외[10]는 WikiEval에서 동일한 질문과 검색 문맥에 대한 서로 다른 답변을 비교하여 근거 충실도를 설명하였다. 그림 2-6은 원 논문의 표 2에서 발췌한 사례이며, 같은 검색 문맥으로 뒷받침되는 답변과 그렇지 않은 답변을 보여준다.

Question	Context	Answer
Who directed the film Oppenheimer and who stars as J. Robert Oppenheimer in the film?	Oppenheimer is a 2023 biographical thriller film written and directed by Christopher Nolan. Based on the 2005 biography American Prometheus by Kai Bird and Martin J. Sherwin, the film chronicles the life of J. Robert Oppenheimer, a theoretical physicist who was pivotal in developing the first nuclear weapons as part of the Manhattan Project, and thereby ushering in the Atomic Age. Cillian Murphy stars as Oppenheimer, with Emily Blunt as Oppenheimer's wife Katherine "Kitty" Oppenheimer.	<i>High Faithfulness:</i> Christopher Nolan directed the film Oppenheimer. Cillian Murphy stars as J. Robert Oppenheimer in the film. <i>Low Faithfulness:</i> James Cameron directed the film Oppenheimer. Tom Cruise stars as J. Robert Oppenheimer in the film.

Table 2: Example from WikiEval, showing answers with high and low faithfulness.

[그림 2-6] RAGAS의 근거 충실도 높음/낮음 예시

출처: Es 외[10], 표 2에서 발췌.

같은 질의의 ON 평가값에서 OFF 평가값을 뺀 대응 차이를 계산하고, 질의를 재표집하여 부트스트랩 신뢰구간을 추정하였다. 각 지표는 ON과 OFF의 평가값이 모두 존재하는 대응쌍으로 분석하였다. SCD의 출력 언어 변화는 한국어 문자 비율로 측정하였다. 대응쌍의 구성, 유효 표본 수와 변화 판정 기준은 5.2절에서 제시한다.

2.7 관련 연구와 본 연구의 위치

RAG 관련 선행연구에서는 검색기의 표현력, 여러 검색 문맥의 활용, 디코딩 제어와 검색 근거의 품질을 다루었다. Dense Passage Retrieval은 질의와 문서 구간을 각각 임베딩하여 검색하는 구조를 제시했고[11], Fusion-in-Decoder는 여러 검색 문서 구간을 각각 인코딩한 뒤 디코더에서 함께 활용하는 방식을 제안했다[12]. 긴 문맥에서는 관련 정보의 입력 위치에 따라 답변 성능이 달라지는 현상이 보고되었으며[9], Contrastive Decoding은 큰 모델과 작은 모델의 출력 로그확률 차이를 토큰 선택에 활용하였다[13]. RAPTOR는 문서 청크를 반복적으로 군집화하고 요약하여 계층적 검색 구조를 구성했다[14]. Self-RAG[15]는 검색 필요성과 생성 결과를 평가하는 방법을 제안하였다. Corrective RAG[16]는 검색된 문서의 품질을 평가하고 검색 결과를 보완하는 방법을 제안하였다.

RAG 시스템을 정리한 조사 연구[17], 한국어와 영어를 다루는 Mi:dm 2.0 연구[18], RAG의 구성과 평가를 다룬 조사 연구[19]를 참고하여 검색 구조, 생성 구조와 언어 조건을 설정하였다. BEIR[20]와 MTEB[21]는 검색 및 임베딩 모델을 여러 데이터셋과 과제에서 평가하는 선행 연구로 참고하였다. 실험 대상 문서 중 Mi:dm K 2.5 Pro는 해당 기술 보고서[22]를 사용하였다.

본 연구에서는 HyDE를 밀집 검색 입력에, CAD와 SCD를 답변 생성 단계에 적용하였다. HyDE는 검색 결과와 답변의 변화를, CAD는 같은 검색 문맥에서 답변 품질의 변화를, SCD는 한국어 문자 비율의 변화를 비교하였다.

표 2-1은 선행연구와 본 실험의 연결을 정리한 것이다. 앞서 설명한 Contrastive Decoding과 CAD는 대조 대상이 다르다. Contrastive Decoding은 큰 모델과 작은 모델의 출력을, CAD는 같은 모델에 문맥을 포함한 경우와 제외한 경우의 다음 토큰 분포를 대조한다. Self-RAG와 CRAG는 검색 및 근거 품질을 점검하는 관련 연구로 참고하였다.

[표 2-1] 관련 연구와 본 실험의 연결

연구 흐름	대표 연구	본 연구에서의 적용 범위	해석 범위
밀집 검색과 검색 평가	DPR[11], BEIR[20]	한국어 질의와 영어 문서 사이의 검색 표현 차이를 HyDE 조건으로 비교	DPR은 검색 방법, BEIR은 관련 평가 연구로 참조
다중 문맥 생성	FiD[12], 긴 문맥 분석[9]	재정렬 순위에 따라 상위 5개 청크를 선택하고 답변 지표와 문맥 지표를 구분	문맥 수와 순서 정책 고정
가상 문서 검색	HyDE[2]	H1/H0 종단 간 대응 비교와 검색 청크 ID 확인	가상 문서는 검색 표현으로 사용
대조 디코딩	CAD[3], Contrastive Decoding[13]	같은 질의와 검색 문맥에서 C1/C0 주 비교	CAD ON 조건의 $\alpha=0.5$ 고정
교정 및 자기검증 RAG	Self-RAG[15], CRAG[16]	검색, 생성과 출력 언어의 문제를 구분하여 설명	관련 연구의 비교 관점으로 참조
RAG 평가	RAGAS[10], RAG survey[19]	근거 충실도, 답변 관련성, 문맥 정밀도와 문맥 재현을 평가	자동 평가 지표와 대응 비교에 사용

3. 시스템 설계

3.1 연구 및 실험 요구사항

각 질의 ID를 하나의 대상 문서와 연결하였다. 이후 60개 질의 각각에 HyDE, CAD, SCD의 적용 여부를 조합한 8개 조건을 실행하였다. 검색 모델, 재정렬 모델과 생성 모델은 모든 조건에서 동일하게 사용하였다. 각 생성 기록에는 생성 답변, 검색 청크 ID, 재정렬 청크 ID, 최종 검색 문맥, 디코딩 설정과 조건 실행 시간을 저장하였다. 질의 데이터에는 원문 페이지와 정답 근거 구간을 기록하였다.


[표 3-1] 연구 및 실험 요구사항

요구사항	확인 기준	값
한국어 질의 기반 영문 문서 QA	질의와 대상 문서 연결	60개 질의-문서 쌍
실험 요인	HyDE, CAD, SCD의 ON/OFF	2×2×2, 8개 조건
생성 기록	조건별 생성 기록	480개, 조건별 60개
출력 언어	한국어 문자 비율	SCD ON/OFF 240개 대응쌍
자료 식별	query ID, config_name, 원문 페이지, 정답 근거 구간	60개 질의 메타데이터와 480개 생성 기록

3.2 아키텍처 설계

실험에서는 질의를 입력받아 조건에 맞는 검색 입력을 구성하였다. HyDE OFF 조건에서는 원래의 한국어 질의를 밀집 검색에 사용하였다. HyDE ON 조건에서는 한국어 질의를 영어로 번역한 뒤 가상 문서를 생성하고, 이를 벡터로 변환하여 밀집 검색에 사용하였다. HyDE ON과 OFF 조건 모두 BGE-M3를 사용해 밀집 검색용 벡터를 생성하였다. BM25 검색과 CrossEncoder 재정렬에는 두 조건 모두 원래의 한국어 질의를 사용하였다. 밀집 검색과 BM25의 후보를 weighted RRF로 결합하고 CrossEncoder로 재정렬하였다. 재정렬 순위에 따라 상위 5개 청크를 선택한 뒤 ContextCompressor로 입력 문맥의 길이를 관리하였다. 이 문맥을 생성 모델에 제공하여 답변을 생성하고, 생성 결과를 저장한 뒤 평가하였다.

답변 생성에는 모든 조건에서 같은 Mi:dm 2.0 Base Instruct를 사용하였다. CAD ON에서는 검색 문맥을 포함했을 때와 제외했을 때 계산한 로짓을 이용해 다음 토큰의 점수를 조정하였다. SCD ON에서는 어휘를 한국어 토큰, 다른 언어의 토큰과 중립 토큰으로 구분하였다. 한국어 토큰과 다른 언어 토큰의 로짓에 각각 정해진 계수를 곱하고, 중립 토큰의 로짓은 유지하였다. 실행이 끝나면 질의, 대상 문서, 실험 조건, 최종 검색 문맥, 생성 답변, 조건 실행 시간과 요인별 메타데이터를 저장하였다. 평가 단계에서는 생성 기록을 불러와 평가값을 계산하고 요인별 대응 차이를 분석하였다.



[그림 3-1] HyDE, CAD, SCD를 조합한 RAG-Cube 8개 조건

3.3 상세설계

RAG-Cube의 여덟 조건은 HyDE(H), CAD(C), SCD(S)의 ON/OFF 조합으로 구성하였다. 0은 OFF, 1은 ON을 뜻하며, 각 조건을 H0C0S0과 같은 형식으로 표기하였다. 실제 적용 상태는 생성 기록의 config_name, use_hyde, use_cad, use_scd 필드로 확인하였다. SCD ON 기록에는 mode=reference_scd, alpha=1.1, beta=0.9, Tstart=5를, CAD ON 기록에는 alpha=0.5를 저장하였다.

[표 3-2] RAG-Cube 8개 조건

조건	HyDE	CAD	SCD	생성 수
H0C0S0	OFF	OFF	OFF	60
H0C1S0	OFF	ON	OFF	60
H0C0S1	OFF	OFF	ON	60
H0C1S1	OFF	ON	ON	60
H1C0S0	ON	OFF	OFF	60
H1C1S0	ON	ON	OFF	60
H1C0S1	ON	OFF	ON	60
H1C1S1	ON	ON	ON	60

[표 3-3] 실험 요인별 적용 위치와 비교 단위

요인	적용 위치	주 비교	주 지표
HyDE	검색 표현 확장	CAD와 SCD가 모두 OFF인 60개 대응쌍	RAGAS 품질 지표
CAD	문맥 기반 디코딩	동일 문맥 60쌍(근거 충실도 유효쌍 58개)	근거 충실도, 답변 관련성과 조건 실행 시간
SCD	출력 토큰 로짓 제어	HyDE OFF 동일 문맥 120쌍; 동일 질의의 HyDE와 CAD 상태를 맞춘 전체 240쌍	한국어 문자 비율

요인별 대응쌍은 다음과 같이 구성하였다. HyDE 주 비교에서는 동일 질의의 H1C0S0과 H0C0S0을 연결하여 검색 결과의 변화까지 포함한 답변 차이를 측정하였다. CAD 주 비교에서는 동일 질의의 H0C1S0과 H0C0S0을 연결하고, 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 모두 동일한지 확인하였다. SCD 주 비교에서는 HyDE를 OFF로 고정하고 CAD 상태가 같은 SCD ON/OFF 기록을 연결하여 120개 대응쌍을 구성하였다. 이 120쌍도 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 동일함을 확인하였다. 추가로 동일 질의의 HyDE와 CAD 상태를 각각 맞춘 전체 240개 SCD 대응쌍에서 출력 언어 변화를 분석하였다. 전체 240쌍에는 HyDE ON 조건의 가상 문서 샘플링에 따른 검색 문맥 변화가 포함된다.

평가값은 질의 ID와 실험 조건으로 생성 기록에 연결하였다. 조건별 평균은 각 지표의 평가값이 있는 기록으로 계산하였다. 평균 대응 차이는 같은 질의의 ON 평가값에서 OFF 평가값을 뺀 차이의 평균이다. 질의 단위 부트스트랩으로 대응 차이의 95% 신뢰구간을 추정하였다. 조건별 평균과 대응 비교에는 각각의 유효 표본 수와 비교 조건을 기록하였다.

4. 프로그램 구현

4.1 시스템 환경

생성에는 K-intelligence/Midm-2.0-Base-Instruct를 사용하고 최대 생성 토큰 수를 512로 설정하였다. 답변 생성에는 각 단계에서 점수가 가장 높은 토큰을 선택하는 탐욕적 디코딩을 사용하였다.

일반 텍스트는 Python split()의 공백 분리 단위를 기준으로 청크로 나누었다. 청크의 최대 크기는 512단어, 최소 크기는 50단어로 설정하였으며, 같은 텍스트 구간에서 연속으로 나눈 청크는 64단어가 겹치도록 하였다. section 분할 전략에서는 수식, 표와 코드 블록을 나누지 않고 각각 독립된 구조 청크로 보존하였다. BGE-M3 밀집 검색과 BM25 희소 검색은 dense 0.6, BM25 0.4의 weighted RRF(k=60)로 결합하고 cross-encoder/ms-marco-MiniLM-L-6-v2로 재정렬하였다. 같은 CrossEncoder를 모든 조건에 적용하였다. 검색 후보 수와 재정렬 후보 수는 각각 8개, 최종 생성 문맥은 5개로 설정하였다.

ContextCompressor의 문맥 길이 상한은 Python split() 기준 3,072개 단어, 추출식 압축 비율은 0.5로 설정하였다. 모듈은 입력 문맥이 상한을 초과할 때 추출식 압축을 수행하고, 상한 이내이면 입력 청크를 그대로 반환한다. 표 4-1에는 모델 구성, 검색 및 생성 설정과 HyDE, CAD, SCD의 파라미터를 정리하였다.

검색 폭 설정은 최종 평가 집합과 분리된 5개 튜닝 질의를 사용하여 사전에 선정하였다. 검색 후보 수, 재정렬 후보 수와 최종 문맥 수를 달리한 세 가지 설정을 비교하였으며, 문맥 재현율 0.95 이상을 충족한 후보 가운데 평균 근거 충실도가 가장 높은 설정을 선택하였다. 선정된 검색 후보 8개, 재정렬 후보 8개, 최종 문맥 5개 설정을 60개 평가 질의의 모든 조건에 적용하였다.

[표 4-1] 실험 실행 환경

구성	생성 기록 기준 값
생성 모델	K-intelligence/Midm-2.0-Base-Instruct
답변 생성 방식	각 단계에서 최종 로짓이 가장 높은 토큰 선택
검색 구성	BGE-M3 밀집 검색 + BM25 희소 검색 + weighted RRF(k=60; 0.6/0.4) + cross-encoder/ms-marco-MiniLM-L-6-v2
검색 후보 수 / 재정렬 후보 수	8 / 8
일반 텍스트 청크 분할	공백 분리 기준 최대 크기 512개 단어 / 중첩 크기 64개 단어 / 최소 크기 50개 단어
문맥 길이 관리	ContextCompressor; 공백 분리 기준 3,072개 단어 초과 시 추출식 압축, 압축 비율 설정 0.5
최종 문맥 수	5
max_new_tokens	512
CAD ON의 α	0.5
SCD	$\alpha=1.1$, $\beta=0.9$, Tstart=5

[표 4-2] 고정 Paper-RAG 백본

단계	고정 구성
입력	한국어 질의와 지정 대상 문서
검색	BGE-M3 밀집 검색 + BM25 희소 검색
결합	weighted Reciprocal Rank Fusion
재정렬	cross-encoder/ms-marco-MiniLM-L-6-v2
문맥 구성	재정렬 상위 5개 청크 선택 → ContextCompressor의 조건부 추출식 압축 → 3,072개 단어 상한에 맞춘 문맥 절단
생성	Mi:dm 2.0 Base Instruct; max_new_tokens=512
요인	HyDE는 밀집 검색 입력에 적용 / CAD와 SCD는 답변 디코딩에 적용


[표 4-2 주석] 검색 후보 수 8, 재정렬 후보 수 8, 최종 문맥 수 5는 최종 평가 집합과 분리된 5개 튜닝 질의의 검색 폭 비교를 통해 사전에 선정한 값이다. CAD와 SCD의 파라미터는 각 기법의 실험 설정에 따라 별도로 적용하였다.

4.2 시스템 구성

프로그램은 입력부, 검색 표현 구성부, 검색 및 재정렬부, 답변 생성부, 기록 저장부, 분석 및 재현 모듈로 구성하였다. 검색 및 재정렬부는 밀집 검색과 BM25 검색의 결과를 weighted RRF로 결합하고, CrossEncoder 재정렬, 상위 청크 선택과 문맥 길이 관리를 수행한다. 답변 생성부는 조건에 따라 CAD와 SCD를 적용한다. 모든 조건에서 질의 집합과 백본을 고정하고 HyDE(H), CAD(C), SCD(S)의 ON/OFF를 바꾼다.

검색부는 HyDE의 가상 문서 또는 한국어 원질의를 BGE-M3로 임베딩하여 밀집 검색을 수행하고, 한국어 원질의로 BM25 검색과 CrossEncoder 재정렬을 수행하였다. 생성부에는 최종 검색 문맥과 한국어 원질의를 전달하고, CAD와 SCD 처리기를 조건에 따라 적용하였다. 대응쌍을 구성할 때는 저장된 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥을 대조해 문맥의 동일성을 확인하고, 파라미터 기록으로 각 기법의 적용 상태를 확인하였다.

고정 요소: 검색 후보 8, 재정렬 후보 8, 최종 문맥 5, 최대 생성 토큰 512



[그림 4-1] 고정 Paper-RAG 백본 실행 흐름

4.3 시스템 구현

실험 실행기는 60개 질의-대상 문서 쌍에 각각 8개 조건을 적용하였다. HyDE ON 기록에는 번역 질의와 가상 문서를 저장하였다. CAD와 SCD의 활성 상태 및 파라미터, 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥도 기록하였다. 생성 기록의 주요 필드는 답변, 조건 실행 시간과 디코딩 방식이며, 표 4-4에 정리하였다.


[표 4-3] 실험 조건별 실행 시간

조건	생성 수	평균 조건 실행 시간(초)	조건 실행 시간 중앙값(초)
H0C0S0	60	20.792	16.077
H0C1S0	60	63.867	57.819
H0C0S1	60	18.898	17.579
H0C1S1	60	55.159	51.127
H1C0S0	60	23.44	22.245
H1C1S0	60	73.532	71.7
H1C0S1	60	24.892	24.714
H1C1S1	60	64.125	64.834

[표 4-4] 생성 기록의 주요 필드

구분	필드
식별	query_id, paper, config_name, status
요인	use_hyde, use_cad, use_scd, parameter fields
검색	retrieved_chunk_ids(검색 후보 ID), reranked_chunk_ids(재정렬 후 최종 선택 청크 ID), contexts(최종 검색 문맥)
생성	generated_answer, duration_seconds, decoding_mode
재현	generation_model, retrieval backend, context count

CAD는 같은 질의와 생성 접두 시퀀스에서 문맥 포함 로짓과 문맥 제외 로짓을 계산한다. SCD는 답변 생성 단계에서 토큰의 로짓을 조정한다. 표 4-3은 검색부터 답변 생성까지의 조건 실행 시간을 정리한 것이며, HyDE ON의 실행 시간에는 질의 번역과 가상 문서 생성 시간이 포함된다. 한국어 문자 비율은 저장된 답변 문자열에서 계산하였다.



질의 ID, 실험 조건, 검색 및 재정렬 ID, 검색 문맥, 생성 답변, 조건 실행 시간

[그림 4-2] 생성 기록-평가-대응 분석 흐름

5. 실험

5.1 실험 대상과 구성

RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 네 영어 문서를 대상으로 문서별 15개씩, 총 60개의 한국어 평가 질의를 구성하였다. 모든 질의는 한국어로 작성하고, 지정된 영어 문서에서 근거를 검색하였다.

네 문서의 평가 질의는 같은 절차로 작성하였다. 연구자는 각 문서의 질문 형식과 범위를 정하기 위해 초기 질문 3개를 작성하였다. 이후 초기 질문의 표현 방식과 범위를 기준으로 LLM이 각 문서의 주요 내용을 요약하도록 하였다. 요약을 15개의 내용 단위로 나누고, 각 단위에서 한국어 평가 질의 1개를 작성하여 문서별 15개, 총 60개를 구성하였다.

연구자는 각 질의를 원문 PDF와 대조하여 대상 문서, 원문 페이지, 정답 근거와 답변 가능성을 확인하였다. 원문에서 찾은 정답 근거를 기록하고, 질문과 근거가 대응하는지 검토하였다.

평가 질의는 요구하는 정보에 따라 사실 및 정의, 방법 및 절차, 결과 및 비교, 목적 및 기여의 네 유형으로 분류하였다. 사실 및 정의 유형은 개념, 수치 또는 구성 요소를 묻는 질의이다. 방법 및 절차 유형은 모델 구조, 처리 과정, 데이터셋 구성, 평가 방법 또는 실험 설정을 묻는다. 결과 및 비교 유형은 정량적 결과, 정성적 결과 또는 방법 간 비교를 묻는다. 목적 및 기여 유형은 연구 목적, 문제 설정 또는 주요 기여를 묻는다. 최종 분포는 사실 및 정의 8개, 방법 및 절차 29개, 결과 및 비교 20개, 목적 및 기여 3개다.

검색 설정을 정할 때는 최종 평가 집합과 분리한 튜닝 질의 5개를 사용하였다. 이 과정에서 검색 후보 수 8, 재정렬 후보 수 8, 최종 생성 문맥 5를 확정하였다. 최종 평가에서는 검색 설정을 고정하고, 60개 질의 각각에 8개 RAG-Cube 조건을 적용하여 총 480개의 생성 기록을 저장하였다.

[표 5-1] 4개 문서별 질의 구성

대상 문서	질의 수
RAG Survey	15
CAD	15
RAPTOR	15
Mi:dm K 2.5 Pro Technical Report	15
합계	60

5.2 평가 및 분석 방법

질의 ID와 실험 조건을 기준으로 생성 기록과 평가값을 연결하고, 3.3절의 대응 비교 설계에 따라 분석하였다. RAGAS 0.2.15를 사용하였으며, 평가 모델은 OpenAI gpt-4o, 답변 관련성 계산에 사용하는 임베딩 모델은 BAAI/bge-m3로 설정하였다. 평가 지표는 근거 충실도, 답변 관련성, 문맥 정밀도와 문맥 재현율의 네 항목이다.

SCD OFF의 RAGAS 평가에는 생성 기록의 영어 검색 문맥을 사용하였다. SCD ON 조건의 RAGAS 평가에서는 저장된 영어 검색 문맥을 gpt-4o로 한국어 번역하여 평가 문맥으로 사용하였다. 생성 답변은 번역하거나 수정하지 않고 저장된 원문을 사용하였다. 문맥 번역은 자동 평가 단계에서 수행하였으며, 답변 생성 모델의 입력은 영어 검색 문맥이었다. SCD OFF와 ON의 RAGAS 결과는 평가 문맥의 언어에 따라 두 블록의 조건별 기술통계로 제시하였다. 출력 언어 변화는 저장된 답변에서 직접 계산한 한국어 문자 비율의 대응 차이로 분석하였다.

근거 충실도는 ON과 OFF 양쪽에 평가값이 있는 대응쌍으로 분석하였다. CAD 주 비교의 유효 대응쌍은 58개였다.


HyDE 주 비교는 CAD와 SCD를 모두 OFF로 고정한 60개 질의에서 수행하였다. CAD 주 비교는 검색 체크 ID, 재정렬 체크 ID와 최종 검색 문맥이 동일한 대응쌍을 사용하여 검색 결과를 고정한 상태의 답변 차이를 측정하였다. SCD의 주 비교에는 HyDE를 OFF로 고정하고 CAD 상태를 맞춘 120개 대응쌍을 사용하였다. 이 대응쌍의 검색 체크 ID, 재정렬 체크 ID와 최종 검색 문맥은 동일하였다. 추가로 동일 질의의 HyDE와 CAD 상태를 각각 맞춘 전체 240개 SCD 대응쌍에서 8개 조건의 출력 언어 변화를 집계하였다.

최종 답변 생성 설정은 4.1절과 동일하게 유지하였다. HyDE 가상 문서 생성에는 temperature=0.1, top_p=0.9의 샘플링을 사용하였다. 요인별 대응 차이는 같은 질의의 ON 평가값에서 OFF 평가값을 빼서 계산하였다. 대응 차이의 신뢰구간을 계산하기 위해 질의 단위로 200,000회 부트스트랩 재표집을 수행하였다. 난수 시드는 20260713으로 고정하였다. SCD 분석에서는 같은 질의에 속한 2개 또는 4개의 대응쌍을 함께 재표집하였다. RAGAS 지표의 대응 차이가 +0.01을 초과하면 증가, -0.01 미만이면 감소, -0.01 이상 +0.01 이하이면 동물로 집계하였다. 한국어 문자 비율의 대응 차이는 +0.02 초과를 증가, -0.02 미만을 감소, -0.02 이상 +0.02 이하를 동물로 집계하였다. 신뢰구간은 네 대상 문서를 고정했을 때 질의 수준의 변동성을 나타낸다.

개별 대응쌍의 차이와 평균 대응 차이는 다음 식으로 계산한다.

$$\Delta_i = s_i^{ON} - s_i^{OFF}$$

$$\overline{\Delta} = \frac{1}{n} \sum_{i=1}^n \Delta_i$$



품질: 대응 부트스트랩 95% 신뢰구간 출력 언어: 한국어 문자 비율

[그림 5-1] 60개 질의 평가 및 HyDE, CAD, SCD의 대응 비교 설계

5.3 RAG-Cube 조합별 결과

표 5-2에 SCD OFF와 ON을 평가 프로토콜별로 구분하여 8개 조건의 RAGAS 평균과 한국어 문자 비율을 제시하였다.

SCD OFF에서는 H1C1S0의 근거 충실도가 0.8599, H1C0S0의 답변 관련성이 0.7633으로 가장 높았다. 문맥 정밀도는 H0C0S0에서 0.7488이었고, 문맥 재현율은 H0C0S0과 H1C0S0에서 0.9333이었다. 한국어 문자 비율은 전체 8개 조건 가운데 H1C0S1에서 0.8072로 가장 높았다.


[표 5-2] SCD 평가 프로토콜별 RAG-Cube 조건 평균

[SCD OFF – 영어 검색 문맥 평가]						
조건	생성 수	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 문자 비율
H0C0S0	60	0.7906	0.6828	0.7488	0.9333	0.4943
H0C1S0	60	0.8385	0.6755	0.7395	0.9167	0.4877
H1C0S0	60	0.8342	0.7633	0.7145	0.9333	0.5561
H1C1S0	60	0.8599	0.7045	0.7357	0.9	0.5031
[SCD ON – 한국어 변환 평가 문맥]						
조건	생성 수	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 문자 비율
H0C0S1	60	0.7869	0.6372	0.7634	0.9	0.699
H0C1S1	60	0.7768	0.5996	0.7523	0.85	0.7195
H1C0S1	60	0.8223	0.7097	0.7426	0.9	0.8072
H1C1S1	60	0.8313	0.6671	0.754	0.9167	0.7314
[표 5-2 주석] 두 평가 프로토콜 블록은 각 평가 문맥 구성 방식 안에서 조건별 기술통계로 해석한다. SCD의 주 비교는 표 5-5와 표 5-6의 한국어 문자 비율 대응 결과를 사용한다.						

SCD OFF 블록은 저장된 영어 검색 문맥을 평가 문맥으로 사용한다.

SCD ON 블록은 각 생성 기록의 영어 검색 문맥을 한국어로 번역한 문맥을 RAGAS 평가에 사용한다.

표의 생성 수는 각 조건에 저장된 생성 기록의 수이다. 근거 충실도 평균에 사용한 유효 평가값은 H0C1S0에서 58개, H0C0S1에서 57개이며 나머지 조건에서는 각각 60개다. 조건별 평균은 SCD OFF에서 영어 문맥으로, SCD ON에서 한국어 번역 문맥으로 평가한 값이다.



두 블록은 서로 다른 평가 문맥 프로토콜을 사용하므로 각 블록 안에서 조건별 기술통계로 해석

[그림 5-2] 평가 프로토콜별 RAG-Cube 조건 평균

(a)는 영어 검색 문맥을 사용한 SCD OFF의 RAGAS 평가 결과이고, (b)는 한국어로 번역한 문맥을 사용한 SCD ON의 RAGAS 평가 결과이다.

5.4 HyDE 결과 및 해석

HyDE의 답변 관련성 평균 대응 차이는 +0.0805이고 95% 부트스트랩 신뢰구간은 [+0.0110, +0.1514]이다. 답변 관련성은 29개 질의에서 증가, 15개에서 감소하였으며, 16개는 동률이였다. 근거 충실도 평균 대응 차이는 +0.0436, 95% 신뢰구간은 [-0.0262, +0.1153]이며 증가 24개, 감소 21개, 동률 15개였다. 문맥 정밀도의 평균 대응 차이는 -0.0343이었고, 문맥 재현율의 평균 대응 차이는 0.0000이었다.

HyDE 비교에는 질의 번역, 가상 문서 생성과 검색 문맥 선택의 변화가 함께 포함된다. 문서별 결과와 질문 유형별 결과는 부록 B에 제시하였다.

그림 5-3은 HyDE 적용 전후의 검색 문맥과 생성 답변을 비교한 사례다. 질의 ext_midm_004의 H0C0S0과 H1C0S0은 같은 질문을 사용하였으며, 검색 체크 ID, 재정렬 체크 ID와 최종 검색 문맥은 서로 달랐다. 답변 관련성은 0.0000에서 0.8531로, 문맥 재현율은 0.0000에서 1.0000으로 변화였다. HyDE ON 답변은 한국어 멀티턴 대화 데이터의 세 설계 차원으로 interaction structure, topic and task, persona를 제시하였다.

E04 | ext_midm_004

질문: Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?

A/B 검색 문맥, 검색 및 재정렬 ID 변경

A | hyde_off_no_decoder_control

HyDE OFF / CAD OFF / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_midm_88a1c1d7a494, paper_midm_6954efe611cf

문맥[1] 발췌: [...] complex tasks. Furthermore, we have expanded Mi:dm K from a Korean-English bilingual model to a multilingual model supporting four languages, including Japanese and Chine [...]

저장 답변 발췌: [...] 제공된 논문 컨텍스트를 면밀히 검토한 결과, Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터가 어떤 세 가지 차원을 기준으로 고품질 대화를 설계하는지에 관한 구체적인 정보를 확인할 수 없습니다. [...]

Faithfulness 0.9000 | Answer Relevancy 0.0000

Context Precision 0.0000 | Context Recall 0.0000

전체 답변 한국어 비율 0.8250

B | hyde_on_no_decoder_control

HyDE ON / CAD OFF / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_midm_b8ec113edfbf, paper_midm_94d24ba9b194

문맥[4] 발췌: [...] We define high quality multi-turn conversations along three dimensions: interaction structure, topic and task, and persona. [...]

저장 답변 발췌: [...] **1. 상호작용 구조(Interaction Structure) 차원** [...]

저장 답변 발췌: [...] **2. 주제 및 과제(Topic and Task) 차원** [...]

저장 답변 발췌: [...] **3. 페르소나(Persona) 차원** [...]

Faithfulness 0.8824 | Answer Relevancy 0.8531

Context Precision 0.3250 | Context Recall 1.0000


전체 답변 한국어 비율 0.6773

발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 5-3] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례

[표 5-3] HyDE 주 비교 결과

지표	평균 대응 차이 ON-OFF	95% 신뢰구간	증가	감소	동률	n
근거 충실도	+0.0436	[-0.0262 , +0.1153]	24	21	15	60
답변 관련성	+0.0805	[+0.0110 , +0.1514]	29	15	16	60
문맥 정밀도	-0.0343	[-0.0932 , +0.0247]	17	23	20	60
문맥 재현율	0	[-0.1000 , +0.1000]	4	4	52	60



[그림 5-4] HyDE와 CAD의 주 대응 비교

점은 ON-OFF 평균 차이, 선은 95% 부트스트랩 신뢰구간이다.

5.5 CAD 결과 및 해석

CAD는 같은 질의와 검색 문맥에서 OFF와 ON의 답변을 비교하였다. 근거 충실도의 평균 대응 차이는 양쪽 평가값이 있는 58쌍에서 +0.0288이었고, 95% 신뢰구간은 [-0.0367, +0.0934]로 0을 포함하였다. 근거 충실도는 58개 유효 대응쌍 중 21쌍에서 증가하고 24쌍에서 감소하였으며, 13쌍은 동률이었다. 답변 관련성의 평균 대응 차이는 60쌍에서 -0.0073이었고, 신뢰구간은 [-0.0855, +0.0719]였다. 답변 관련성은 60개 대응쌍 중 19쌍에서 증가하고 32쌍에서 감소하였으며, 9쌍은 동률이었다.

검색 문맥이 동일한 CAD 대응쌍에서도 문맥 정밀도는 60쌍 중 8쌍, 문맥 재현율은 60쌍 중 1쌍에서 자동 평가값이 달랐다. 이 차이는 자동 평가의 변동을 확인하기 위한 진단값으로 기록하였다. 표 4-3의 H0S0, H0S1, H1S0, H1S1 조건군에서 CAD 적용 전후 평균 조건 실행 시간은 각각 20.792초에서 63.867초, 18.898초에서 55.159초, 23.440초에서 73.532초, 24.892초에서 64.125초로 증가하였다.

그림 5-5는 같은 검색 문맥에서 CAD 적용 전후의 근거 충실도를 비교한 사례다. 질의 ext_midm_001은 Mi:dm K 2.5 Pro의 학습 데이터 확보 경로 세 가지를 묻는다. CAD OFF와 ON의 검색 체크 ID, 재정렬 체크 ID와 검색 문맥은 모두 같다. 두 답변은 licensed proprietary datasets, commercial-use public datasets, in-house synthetic data의 세 경로를 제시하였다. 저장된 근거 충실도는 OFF에서 0.8333, ON에서 1.0000이었고 답변 관련성은 각각 0.8261과 0.8124였다. 근거 충실도가 감소한 추가 사례는 부록 B의 그림 B-1에 제시하였다.

E05 | ext_midm_001

질문: Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?

A/B 검색 문맥, 검색 및 재정렬 ID 동일**A | hyde_off_no_decoder_control**

HyDE OFF / CAD OFF / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_midm_6954efe611cf, paper_midm_88370fe7a52d

문맥[2] 발췌: [...] licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data. [...]

저장 답변 발췌: [...] **1. 라이선스 보유 독점(proprietary) 데이터셋** [...]

저장 답변 발췌: [...] **2. 상업적 이용이 허가된 공개(public) 데이터셋** [...]

저장 답변 발췌: [...] **3. 자체(in-house) 합성(synthetic) 데이터** [...]

Faithfulness 0.8333 | Answer Relevancy 0.8261

Context Precision 0.5833 | Context Recall 1.0000

전체 답변 한국어 비율 0.7606**B | hyde_off_cad_only**

HyDE OFF / CAD ON / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_midm_6954efe611cf, paper_midm_88370fe7a52d

저장 답변 발췌: [...] **1. Licensed Proprietary Datasets (라이선스 취득 전용 데이터셋)** [...]

저장 답변 발췌: [...] **2. Public Datasets Permitting Commercial Use (상업적 이용이 허용된 공개 데이터셋)** [...]

저장 답변 발췌: [...] **3. In-house Synthetic Data (자체 생성 합성 데이터)** [...]

Faithfulness 1.0000 | Answer Relevancy 0.8124

Context Precision 0.5833 | Context Recall 1.0000


전체 답변 한국어 비율 0.7466

발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 5-5] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례

[표 5-4] CAD 동일 문맥 주 비교 결과

지표	평균 대응 차이 ON-OFF	95% 신뢰구간	증가	감소	동률	n
근거 충실도	+0.0288	[-0.0367 , +0.0934]	21	24	13	58
답변 관련성	-0.0073	[-0.0855 , +0.0719]	19	32	9	60
[진단값] 동일 검색 입력에서 자동 평가 모델 값 차이: 문맥 정밀도 8/60쌍, 문맥 재현율 1/60쌍						



[그림 5-6] RAG-Cube 조건별 평균 실행 시간

5.6 SCD 출력 언어 결과 및 해석

SCD를 적용한 답변과 적용하지 않은 답변의 한국어 문자 비율을 비교하였다. 두 조건 모두 생성 모델에는 영어 검색 문맥을 입력하였다. HyDE OFF에서 검색 청크 ID, 재정렬 청크 ID와 검색 문맥이 같은 120쌍의 평균 대응 차이는 +0.2182였고, 95% 신뢰구간은 [+0.1880, +0.2487]이었다. 동일 질의에서 HyDE와 CAD의 ON/OFF 상태를 맞춘 전체 240개 SCD 대응쌍의 평균 대응 차이는 +0.2289였고, 95% 신뢰구간은 [+0.2051, +0.2532]이었다. 전체 240쌍에서 +0.02를 초과한 증가는 219개, -0.02 미만의 감소는 10개, -0.02 이상 +0.02 이하의 동률은 11개였다.

SCD 적용에 따른 한국어 문자 비율의 평균 변화는 H0C0 조건에서 +0.2047, H0C1 조건에서 +0.2317, H1C0 조건에서 +0.2511, H1C1 조건에서 +0.2283이었다. HyDE OFF의 H0C0과 H0C1 조건군에서는 SCD 적용 전후에 동일한 검색 문맥을 사용하였다. H1의 두 조건군에는 조건마다 독립 생성한 HyDE 가상 문서에 따른 검색 문맥 변화가 포함된다.

답변에 포함된 영어 논문 제목, 모델명과 데이터셋명의 ASCII 영문자도 한국어 문자 비율의 분모에 포함하였다.

그림 5-7은 SCD OFF에서 영어 중심 답변이 생성된 사례다. 한국어 질문과 영어 검색 근거가 주어졌으며, 생성 답변의 한국어 문자 비율은 0.0000이었다.

E02 | ext_cad_007

질문: CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?

A | hyde_on_cad_only

HyDE ON / CAD ON / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_nlp_cad_363806f889e1,

paper_nlp_cad_6d4aeefa6dab

문맥[1] 발췌: [...] CAD can be used with off-the-shelf pretrained language models without any additional training. [...]

저장 답변 발췌: [...] . Improving transformer generalization through weight normalization. _arXiv preprint arXiv:2204.03296_. Sheng-Hong Huang, Xiaodan Zheng, and Jianfeng Gao. 2018. Factually faithful abstractive summarization. In _Proceedings of the 2018 Conference [...]

Faithfulness 0.0769 | Answer Relevancy 0.4602

Context Precision 1.0000 | Context Recall 1.0000

전체 답변 한국어 비율 0.0000

발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 5-7] SCD OFF 조건의 출력 언어 이탈 사례

그림 5-8은 같은 검색 문맥에서 SCD 적용 전후의 답변 언어를 비교한다. 질의 ext_midm_005의 H1C0S0과 H1C0S1은 검색 청크 ID, 재정렬 청크 ID와 검색 문맥이 같고 SCD 상태만 다르다. 한국어 문자 비율은 0.0000에서 0.7713으로 증가하였으며, SCD ON 답변은 한국어 중심으로 생성되었다.

E03 | ext_midm_005

질문: Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?

A/B 검색 문맥, 검색 및 재정렬 ID 동일

A | hyde_on_no_decoder_control

HyDE ON / CAD OFF / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_midm_5fd8fb92ae53, paper_midm_fe2d192ffc71

문맥[1] 발췌: [...] In the Fusion SFT phase, we partition the training data into reasoning and non-reasoning subsets. We deliberately emphasize non-reasoning tasks that are relatively underrepresented in earlier stages, including creative writing, translation, and general question answering. [...]

저장 답변 발췌: [...] tasks such as math problems, code snippets, and general knowledge questions, with a composition of 29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, we apply a model merging technique using checkpoints saved at regular intervals [25]. [...]

Faithfulness 0.8125 | Answer Relevancy 0.4632

Context Precision 0.8667 | Context Recall 1.0000

전체 답변 한국어 비율 0.0000

B | hyde_on_scd_only

HyDE ON / CAD OFF / SCD ON

검색 ID (앞 2개 / 전체 8개): paper_midm_5fd8fb92ae53, paper_midm_fe2d192ffc71

저장 답변 발췌: [...] tasks such as math problems, code snippets, and general knowledge questions, with a composition of 29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, 우리는 정기적인 간격으로 저장된 체크포인트를 사용한 모델 병합 기법을 적용합니다 [25]. 단계 1의 최종 체크포인트와 비교하여, 병합된 모델은 대부분의 평가 지표에서 향상된 성능을 보여주며, GSM8K [15]를 제외하고는 그렇습니다. CPT 단계 2에서는 이전 단계에 비해 [...]

Faithfulness 0.8889 | Answer Relevancy 0.5231

Context Precision 0.8667 | Context Recall 1.0000

전체 답변 한국어 비율 0.7713

발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.


[그림 5-8] 동일 검색 문맥에서 SCD 적용 전후 출력 언어 변화 사례

[표 5-5] SCD 조합별 한국어 문자 비율 변화

SCD OFF	SCD ON	쌍 수	평균 대응 차이	신뢰구간 하한	신뢰구간 상한	증가	감소	동률
H0C0S0	H0C0S1	60	+0.2047	+0.1566	+0.2512	51	4	5
H0C1S0	H0C1S1	60	+0.2317	+0.1874	+0.2786	54	2	4
H1C0S0	H1C0S1	60	+0.2511	+0.1938	+0.3078	57	1	2
H1C1S0	H1C1S1	60	+0.2283	+0.1832	+0.2762	57	3	0

[표 5-6] SCD 대응쌍 분석 요약

비교	쌍 수	한국어 문자 비율 평균 대응 차이	95% 신뢰구간	증가 / 감소 / 동률
전체 SCD ON/OFF 대응	240	+0.2289	[+0.2051, +0.2532]	219 / 10 / 11
HyDE OFF 동일 문맥	120	+0.2182	[+0.1880, +0.2487]	105 / 6 / 9



오차막대: query-clustered bootstrap 95% CI

[그림 5-9] SCD의 한국어 문자 비율 변화

H0 조건군은 동일 검색 문맥 주 비교이며, H1 조건군은 조건별 HyDE 샘플링을 포함한다. 오차막대는 95% 부트스트랩 신뢰구간이다.

5.7 대표 입출력 및 요구사항별 실행 결과

그림 5-10은 질문, 검색 근거, 생성 답변과 RAGAS 평가값을 함께 제시한 입출력 사례다.

질의 ext_raptor_011은 RAPTOR의 계층적 검색이 DPR보다 주제형 질문과 멀티홉 질문에 유리한 이유를 묻는다. HOCOS0 답변의 근거 충실도는 1.0000, 답변 관련성은 0.9365였으며, 문맥 정밀도와 문맥 재현율은 각각 1.0000이었다.

E01 | ext_raptor_011

질문: Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제 형·멀티홉 질문에 유리했던 이유는 무엇입니까?

A | hyde_off_no_decoder_control

HyDE OFF / CAD OFF / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_nlp_raptor_12d47c916205,

paper_nlp_raptor_4f4f51e0f19a

문맥[1] 발췌: [...] RAPTOR selects nodes from different layers depending on the level of granularity required by the Published as a conference paper at ICLR 2024

Algorithm 2 Collapsed Tree A [...]

저장 답변 발췌: [...] 첫째, RAPTOR는 계층적 구조를 통해 다양한 수준의 추상화(abstraction)를 제공합니다. 논문의 Figure 4에서 확인할 수 있듯이, RAPTOR는 질문의 요구사항에 따라 서로 다른 층위(layer)에서 노드를 선택할 수 있습니다. 반면 DPR은 단일 층위의 leaf 노드만을 선택하여 정보를 제공합니다. [...]

Faithfulness 1.0000 | Answer Relevancy 0.9365

Context Precision 1.0000 | Context Recall 1.0000

전체 답변 한국어 비율 0.5274

발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 5-10] 질문, 검색 근거, 생성 답변과 평가 결과 예시

부록 B의 그림 B-1에는 CAD의 근거 충실도가 감소한 사례를 추가하였다.

5.8 종합 논의

HyDE 적용 후 답변 관련성의 평균 대응 차이는 +0.0805였으며, 문맥 정밀도는 -0.0343, 문맥 재현율은 0.0000이었다. 그림 5-3의 사례에서도 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 달라졌다. 따라서 HyDE의 결과는 질의 번역과 가상 문서 생성에 따른 검색 경로의 변화를 포함하여 해석하였다.

CAD 동일 문맥 비교에서 근거 충실도의 평균 대응 차이는 +0.0288, 답변 관련성의 평균 대응 차이는 -0.0073이었다. 두 지표의 95% 부트스트랩 신뢰구간은 모두 0을 포함하였다. CAD ON은 같은 검색 문맥을 유지하면서 문맥을 제외한 입력의 로짓을 추가로 계산하였다.


SCD의 한국어 문자 비율 평균 대응 차이는 HyDE OFF 동일 문맥 120개 대응쌍에서 +0.2182였고, HyDE와 CAD 상태를 맞춘 전체 240개 대응쌍에서 +0.2289였다.

표 5-2의 조합별 평균은 8개 실험 조건 각각에서 계산한 지표별 평균이다. 표 5-3~5-6의 요인별 대응 차이는 동일한 질의에서 특정 기법을 적용했을 때와 적용하지 않았을 때의 평가 값 차이를 나타낸다. 조건 선택에는 답변 관련성, 근거 충실도, 조건 실행 시간과 한국어 문자 비율 중 적용 목적에 맞는 지표를 사용한다.

그림 5-11에는 HyDE와 CAD의 근거 충실도 및 답변 관련성 평균 대응 차이를 제시하였다. HyDE의 결과는 CAD와 SCD의 설정별로, CAD의 결과는 HyDE와 SCD의 설정별로 구분하였다. 답변 관련성에서 HyDE의 평균 대응 차이는 C0S0에서 +0.0805, C1S0에서 +0.0290, C0S1에서 +0.0725, C1S1에서 +0.0675였다. CAD의 답변 관련성 평균 대응 차이는 H0S0에서 -0.0073, H1S0에서 -0.0588, H0S1에서 -0.0377, H1S1에서 -0.0427이었다. HyDE ON에서는 각 실험 조건마다 temperature=0.1, top_p=0.9로 가상 문서를 독립 생성하였다. 따라

서 H1 조건의 CAD 비교와 SCD 비교에는 디코딩 설정에 따른 답변 변화와 HyDE 샘플링에 따른 검색 문맥 변화가 함께 포함된다.

부록 B는 문서별 및 질문 유형별 대응 차이를 제시한다. 각 문서의 질의 수는 15개다. 질문 유형별 질의 수는 사실 및 정의 8개, 방법 및 절차 29개, 결과 및 비교 20개, 목적 및 기여 3개이며, 각 결과는 해당 표본 수를 기준으로 탐색적으로 해석하였다.



[그림 5-11] HyDE와 CAD의 조건군별 근거 충실도 및 답변 관련성 평균 대응 차이

5.9 실험 범위와 해석 기준

영어로 작성된 학술 및 기술 문서 4개를 대상으로 문서별 한국어 평가 질의 15개씩, 총 60개를 구성하였다. 각 질의의 원문 페이지와 정답 근거 구간을 확인하였다. 답변 생성에는 K-intelligence/Midm-2.0-Base-Instruct를 사용하였으며, CAD ON 조건에만 $\alpha=0.5$ 를 적용하였다.

이 실험의 HyDE 비교에는 질의 번역, 가상 문서 생성과 밀집 검색 입력의 변화가 포함된다. 가상 문서는 temperature=0.1, top_p=0.9로 생성하였고, 비교에는 저장된 검색 기록과 생성 기록을 사용하였다. SCD의 RAGAS 결과는 SCD ON의 한국어 번역 문맥과 SCD OFF의 영어 문맥을 사용하는 두 평가 프로토콜의 조건별 기술통계이다. 출력 언어의 변화는 답변 원문의 한국어 문자 비율로 비교하였다.

6. 결론

본 연구에서는 영어 문서 4개를 대상으로 한국어 평가 질의 60개를 구성하고, HyDE, CAD, SCD의 적용 여부에 따른 총 480개의 생성 결과를 비교하였다.

6.1 연구 질문별 최종 답

첫 번째 연구 질문에서는 CAD와 SCD가 OFF인 대응쌍을 비교하였다. HyDE의 답변 관련성 평균 대응 차이는 +0.0805였고, 95% 부트스트랩 신뢰구간은 [+0.0110, +0.1514]였다. 근거 충실도, 문맥 정밀도와 문맥 재현율의 평균 대응 차이는 각각 +0.0436, -0.0343, 0.0000이었다.

두 번째 연구 질문에서는 검색 문맥을 고정하고 CAD를 비교하였다. 근거 충실도의 평균 대응 차이는 58개 유효쌍에서 +0.0288이었고, 95% 신뢰구간은 [-0.0367, +0.0934]였다. 답변 관련성의 평균 대응 차이는 60쌍에서 -0.0073이었고 신뢰구간은 0을 포함하였다. 네 대응 조건군에서 CAD ON의 평균 조건 실행 시간은 OFF보다 길었다.

세 번째 연구 질문에서는 SCD 적용 전후의 한국어 문자 비율을 비교하였다. 평균 대응 차이는 HyDE OFF 동일 문맥 120개 대응쌍에서 +0.2182였고, 같은 질의의 HyDE와 CAD 상태를 맞춘 전체 240개 대응쌍에서 +0.2289였다.

네 번째 연구 질문에서는 적용 목적에 따른 실험 조건의 선택 기준을 검토하였다. 답변 관련성, 근거 충실도, 조건 실행 시간과 한국어 문자 비율 중 우선할 지표를 정하고, 해당 지표의 요인별 대응 결과를 확인한다. 목적별 비교 방법은 6.3절에 제시한다.

6.2 비교 설계의 의의

HyDE, CAD, SCD의 적용 단계와 검색 문맥의 동일성 여부를 기준으로 대응쌍을 구성하였다. HyDE는 검색부터 답변 생성까지의 변화를 비교하고, CAD는 검색 체크 ID, 재정렬 체크 ID와 최종 문맥이 같은 쌍에서 답변 품질을 비교하였다. SCD는 HyDE OFF 동일 문맥 120쌍을 주 비교로 삼고, 같은 질의의 HyDE와 CAD 상태를 맞춘 전체 240개 대응쌍에서 조합 전 반의 출력 언어 변화를 집계하였다.

조합별 평균은 특정 실험 조건에서 평가값이 있는 기록으로 계산한 지표별 평균이다. 요인별 대응 차이는 동일 질의에서 특정 기법을 적용했을 때와 적용하지 않았을 때의 평가값 차이를 나타낸다. H1C1S0의 근거 충실도 평균 0.8599는 한 설정의 평균이다. CAD의 +0.0288은 같은 질의와 검색 문맥을 사용한 유효 대응쌍에서 구한 ON-OFF 평균 차이이다.

그림 5-3, 5-5, 5-7, 5-8, 5-10에는 저장된 질문, 검색 문맥과 생성 답변에 평가값을 연결하여 제시하였다. 부록 B의 그림 B-1에는 CAD 적용 후 근거 충실도가 감소한 사례를 수록하였다.

6.3 적용 시 실험 조건 선택

실험 조건을 선택할 때는 적용 목적에 맞는 평가 지표를 먼저 정하고, 해당 지표의 대응 비교 결과를 확인한다. 답변 관련성이 중요한 경우에는 HyDE 적용 전후의 검색 문맥과 답변 관련성을 비교한다. 동일한 검색 문맥에서 생성 품질을 평가할 때는 CAD의 근거 충실도, 답변 관련성과 조건 실행 시간을 함께 검토한다. 한국어 출력이 중요한 경우에는 HyDE OFF 동일 문맥 대응쌍에서 SCD 적용 전후의 한국어 문자 비율을 비교한다. 고유명사, 인용 표현과 전문용어의 보존 여부는 후속 사람 평가에서 확인할 항목으로 제안한다.

6.4 후속 연구 방향

후속 연구에서는 평가 질의, 문서 도메인과 생성 모델의 범위를 확대하는 방향을 제안한다. 답변 불가능 질의, 대상 문서를 잘못 지정한 질의와 검색 근거가 제공되지 않은 입력을 추가하여 근거가 부족한 상황의 생성 결과를 평가하는 과제가 있다. 문서 도메인, 생성 모델과 토큰나이를 달리한 반복 실험에서는 조건별 답변 품질과 한국어 문자 비율의 차이를 분석할 수 있다.

HyDE에는 질의 번역, 가상 문서 생성과 밀집 검색 입력 변경을 분리한 실험을 제안한다. 같은 질의로 가상 문서를 반복 생성하여 검색 결과의 실행 간 변동을 측정하는 절차도 포함한다. CAD는 α 와 검색 문맥의 길이를 달리하여 근거 충실도, 답변 관련성과 조건 실행 시간의 변화를 비교하는 것이 후속 과제다.

SCD의 후속 평가 항목은 답변의 자연스러움, 번역 충실도, 내용 정확성과 전문용어 보존이다. 평가자에게 기법의 적용 여부를 알리지 않는 사람 평가로 이 항목들을 확인하는 절차를 제안한다. 재정렬 단계의 비교에서는 현재 CrossEncoder와 다국어 재정렬 모델에 같은 검색 후보를 제공하고, 최종 검색 문맥과 답변 품질의 차이를 분석할 수 있다.

참고문헌

- [1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” *Advances in Neural Information Processing Systems*, Vol. 33, 2020.
- [2] L. Gao et al., “Precise Zero-Shot Dense Retrieval without Relevance Labels,” *Proceedings of ACL*, pp. 1762-1777, 2023.
- [3] W. Shi et al., “Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding,” *Proceedings of NAACL*, pp. 783-791, 2024.
- [4] B. Li, Z. Xu, and R. Xie, “Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation,” *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 40, No. 37, pp. 31519-31526, 2026.
- [5] J. Chen et al., “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” *Findings of the Association for Computational Linguistics: ACL 2024*, pp. 2318-2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.
- [6] S. E. Robertson et al., “Okapi at TREC-3,” *Text REtrieval Conference*, 1994.
- [7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” *Proceedings of SIGIR*, pp. 758-759, 2009.
- [8] R. Nogueira and K. Cho, “Passage Re-ranking with BERT,” *arXiv:1901.04085*, 2019.
- [9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” *Transactions of the Association for Computational Linguistics*, Vol. 12, pp. 157-173, 2024.
- [10] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented Generation,” *Proceedings of EACL System Demonstrations*, pp. 150-158, 2024.
- [11] V. Karpukhin et al., “Dense Passage Retrieval for Open-Domain Question Answering,” *Proceedings of EMNLP*, pp. 6769-6781, 2020.
- [12] G. Izacard and E. Grave, “Leveraging Passage Retrieval with Generative

- Models for Open Domain Question Answering,” Proceedings of EACL, pp. 874–880, 2021.
- [13] X. L. Li et al., “Contrastive Decoding: Open-ended Text Generation as Optimization,” Proceedings of ACL, pp. 12286–12312, 2023.
 - [14] P. Sarthi et al., “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval,” Proceedings of ICLR, 2024.
 - [15] A. Asai et al., “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection,” Proceedings of ICLR, 2024.
 - [16] S.-Q. Yan et al., “Corrective Retrieval Augmented Generation,” arXiv:2401.15884, 2024.
 - [17] P. Zhao et al., “Retrieval-Augmented Generation for AI-Generated Content: A Survey,” Data Science and Engineering, Vol. 11, pp. 1–29, 2026, doi: 10.1007/s41019-025-00335-5.
 - [18] D. Shin et al., “Mi:dm 2.0 Korea-centric Bilingual Language Models,” arXiv:2601.09066, 2026.
 - [19] Y. Gao et al., “Retrieval-Augmented Generation for Large Language Models: A Survey,” arXiv:2312.10997, 2023.
 - [20] N. Thakur et al., “BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models,” Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.
 - [21] N. Muennighoff et al., “MTEB: Massive Text Embedding Benchmark,” Proceedings of EACL, pp. 2014–2037, 2023.
 - [22] KT Tech Innovation Group, “Mi:dm K 2.5 Pro,” technical report, arXiv:2603.18788v2, 2026.

그림 자료 이용 정보

그림 2-2~2-6은 CC BY 4.0에 따라 이용하였다. 각 그림의 저자와 서지정보는 참고문헌 번호로 표시하였다. 원본 자료의 주소와 편집 내역은 아래와 같다.

공통 라이선스: CC BY 4.0.

라이선스 안내: <https://creativecommons.org/licenses/by/4.0/>

그림 2-1 - 본 연구 작성. Lewis 외[1]의 RAG 구조를 참고하여 독립 도식을 작성하였다.

원본 자료: <https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>

그림 2-2 - Nelson F. Liu 외[9], TACL 2024, 12:157-173; PDF page 2 (printed 158). 원본 그림 1. 변경: 도표 영역 잘라내기.

원본 자료: <https://aclanthology.org/2024.tacl-1.9.pdf>

그림 2-3 - Luyu Gao 외[2], ACL 2023, 1762-1777; PDF page 2 (printed 1763). 원본 그림 1. 변경: 도식 영역 잘라내기, OpenAI 로고 생략.

원본 자료: <https://aclanthology.org/2023.acl-long.99.pdf>

그림 2-4 - Weijia Shi 외[3], NAACL 2024 short, PDF page 1. 원본 그림 1. 변경: 그림 영역 잘라내기.

원본 자료: <https://aclanthology.org/2024.naacl-short.69.pdf>

그림 2-5 - Bo Li 외[4], arXiv:2511.09984v1, PDF page 1. 원본 그림 1. 변경: 그림 영역 잘라내기, OpenAI와 Ollama 로고 생략.

원본 자료: <https://arxiv.org/pdf/2511.09984v1>

그림 2-6 - Shahul Es 외[10], arXiv:2309.15217v2, PDF page 8. 원본 표 2. 변경: 표 영역 잘라내기.

원본 자료: <https://arxiv.org/pdf/2309.15217v2>

부록 A. 60개 질의 목록

부록 A의 질문 문장은 실제 실험 입력을 그대로 수록하였다.

[표 A-1] 60개 질의-대상 문서 쌍

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_001	언어 모델이 생성 시 활용하는 prior knowledge와 context knowledge는 각각 어디에서 오는 정보입니까?	CAD	사실 및 정의	1	the context contains external knowledge; prior knowledge is encoded in the model parameters
ext_cad_002	CAD의 요약 실험에는 어떤 데이터셋과 평가 지표가 사용되었습니까?	CAD	방법 및 절차	3	CNN-DM and XSUM; ROUGE-L, BERT-Precision, and FactKB
ext_cad_003	CAD의 지식 충돌 실험에는 어떤 두 데이터셋이 사용되었고 각각 무엇을 평가합니까?	CAD	방법 및 절차	3	MemoTrap investigates memorization traps; NQ-Swap tests faithful answering from a modified reliable document.
ext_cad_004	NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?	CAD	방법 및 절차	3	identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity
ext_cad_005	CAD 실험에서 요약 과제와 지식 충돌 과제에 사용한 α 값은 각각 얼마이며, 지식 충돌 과제에서 더 큰 값을 사용한 이유는 무엇입니까?	CAD	방법 및 절차	3	$\alpha = 0.5$ for summarization and $\alpha = 1$ for knowledge conflicts, where prior knowledge needs to be factored out more
ext_cad_006	CAD 논문의 베이스라인 디코딩은 요약 과제와 지식 충돌 과제에서 각각 어떤 샘플링 전략을 사용합니까?	CAD	방법 및 절차	3	greedy decoding for knowledge conflict tasks and top-p sampling with $p=0.9$ for summarization tasks
ext_cad_007	CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?	CAD	방법 및 절차	3	OPT, GPT-Neo, LLaMA, and FLAN-T5
ext_cad_008	지식 충돌 과제에서 모델 크기가 커질수록 CAD의 성능 향상 폭은 어떤 경향을 보였습니까?	CAD	결과 및 비교	5	the gain increases as the model size grows

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_009	LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?	CAD	결과 및 비교	4	Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3
ext_cad_010	외부 컨텍스트가 생성 토큰과 조건부 독립이라면 α 가 0이 아니어도 CAD의 출력 분포에는 어떤 영향이 있습니까?	CAD	사실 및 정의	2	even a non-zero α would not have an impact to the original output distribution
ext_cad_011	CAD는 특정 instruction-finetuned 언어 모델에만 제한됩니까, 아니면 어떤 언어 모델에도 적용 가능한 디코딩 전략입니까?	CAD	사실 및 정의	6	a decoding strategy applicable to any LM
ext_midm_001	Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	3	licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data
ext_midm_002	Mi:dm K 2.5 Pro는 한국어 중심 학습을 유지하기 위해 다국어 데이터를 한국어 코퍼스 대비 어느 정도 비율로 제한하며, 그 이유는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	3	3-10% of the Korean corpus, to encourage cross-lingual transfer without diluting the Korean-language focus
ext_midm_003	응답 스타일 재작성 후 평균 응답 길이는 몇 % 증가했고, bullet_count=0인 응답의 비율은 어떻게 변했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	8	mean response length increases by 256.70%; bullet_count = 0 drops from 82.8% to 3.9%
ext_midm_004	Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	15	interaction structure, topic and task, and persona
ext_midm_005	Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	21	to favor versatile conversational alignment; creative writing, translation, and general question answering
ext_midm_006	Fully asynchronous GSPO 학습은 synchronous 방식과 비교해 step time과 token throughput을 각각 어느 정도 개선했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	23	reduces step time by approximately 15% and improves token throughput by approximately 30%

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_midm_007	LLM-as-a-Judge 기반 reward signal은 사람의 평가와 어느 정도의 일치율을 보였습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	24	an agreement rate of 91%
ext_midm_008	Reasoning-enabled 평가에서 Mi:dm K 2.5 Pro가 HumanEval+와 τ^2 -Bench Telecom에서 기록한 점수는 각각 얼마입니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	25	HumanEval+ 92.07% and τ^2 -Bench Telecom 89%
ext_midm_009	한국어 red-teaming 평가에서 Mi:dm K 2.5 Pro의 Attack Success Rate는 얼마였으며 비교 모델들 가운데 어떤 수준이었습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	31	ASR of 36.3%, the lowest attack success rate among the compared models
ext_rag_001	Advanced RAG의 pre-retrieval 단계는 인덱스와 사용자 질의를 각각 어떤 방향으로 최적화합니까?	RAG Survey	방법 및 절차	4	optimizing the indexing structure and the original query
ext_rag_002	Advanced RAG의 post-retrieval 단계에서 사용되는 두 가지 핵심 방법은 무엇입니까?	RAG Survey	방법 및 절차	4	rerank chunks and context compressing
ext_rag_003	RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?	RAG Survey	방법 및 절차	8	Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.
ext_rag_004	문서 청크에 타임스탬프 같은 메타데이터를 부여하면 time-aware RAG는 최신 정보를 어떻게 우선할 수 있습니까?	RAG Survey	방법 및 절차	8	Assigning different weights to document timestamps during retrieval can achieve time-aware RAG, ensuring the freshness of knowledge and avoiding outdated information.
ext_rag_005	Reverse HyDE는 문서로부터 가상의 질문을 생성해 원래 질문과 답변 사이의 의미적 간극을 어떻게 줄입니까?	RAG Survey	방법 및 절차	8	using LLM to generate questions that can be answered by the document, then calculating the similarity between the original question and the hypothetical question

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_rag_006	Multi-Query와 Sub-Query 방식은 원래 질의를 확장하거나 분해하는 방식에서 어떻게 다릅니까?	RAG Survey	방법 및 절차	8	Multi-Query expands queries via LLMs for parallel execution; Sub-Query decomposes a complex question into simpler sub-questions.
ext_rag_007	Iterative Retrieval, Recursive Retrieval, Adaptive Retrieval은 검색을 반복하거나 중단하는 방식에서 각각 어떻게 구분됩니까?	RAG Survey	방법 및 절차	11	Iterative retrieval alternates retrieval and generation; recursive retrieval refines queries and breaks problems into sub-problems; adaptive retrieval determines whether retrieval is necessary and when to stop.
ext_rag_008	RAG 평가에서 요구되는 네 가지 핵심 능력은 무엇입니까?	RAG Survey	방법 및 절차	12	noise robustness, negative rejection, information integration, and counterfactual robustness
ext_rag_009	RAG 평가에서 Negative Rejection은 어떤 능력을 측정합니까?	RAG Survey	사실 및 정의	12	refraining from responding when the retrieved documents do not contain the necessary knowledge to answer a question
ext_rag_010	RAG와 파인튜닝을 비교할 때 지식 업데이트의 동적 특성과 해석 가능성 측면에서 RAG가 갖는 특징은 무엇입니까?	RAG Survey	결과 및 비교	5	real-time knowledge updates and effective utilization of external knowledge sources with high interpretability
ext_raptor_001	RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?	RAPTOR	방법 및 절차	3	length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk
ext_raptor_002	RAPTOR의 leaf node를 만들 때 텍스트 임베딩에 사용한 모델은 무엇입니까?	RAPTOR	방법 및 절차	3	SBERT, a BERT-based encoder (multi-qa-mpnet-base-cos-v1)
ext_raptor_003	RAPTOR의 GMM 클러스터링 전에 UMAP을 사용하는 이유는 무엇입니까?	RAPTOR	방법 및 절차	4	to mitigate the challenge of high-dimensional vector embeddings by dimensionality reduction
ext_raptor_004	RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?	RAPTOR	방법 및 절차	4	to determine the optimal number of clusters

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_rapto r_005	RAPTOR에서 클러스터별 요약물 생성하는 데 사용한 언어 모델은 무엇입니까?	RAPTOR	방법 및 절차	4	gpt-3.5-turbo
ext_rapto r_006	RAPTOR의 트리 구축 비용은 문서 길이가 증가할 때 build time과 token expenditure 측면에서 어떻게 확장됩니까?	RAPTOR	결과 및 비교	16	both build time and token expenditure scale linearly with document length
ext_rapto r_007	QASPER 데이터셋은 몇 개의 질문과 NLP 논문으로 구성되며, 논문에서는 어떤 지표로 성능을 평가합니까?	RAPTOR	방법 및 절차	6	5,049 questions across 1,585 NLP papers; accuracy is measured using standard F1
ext_rapto r_008	QuALITY-HARD는 일반 QuALITY 질문 중 어떤 기준을 만족하는 질문들로 구성됩니까?	RAPTOR	사실 및 정의	6	questions that a majority of human annotators answered incorrectly in a speed-setting
ext_rapto r_009	QASPER에서 RAPTOR의 F1 Match 점수는 GPT-3, GPT-4, UnifiedQA를 사용할 때 각각 얼마였습니까?	RAPTOR	결과 및 비교	7	53.1%, 55.7%, and 36.6%, respectively
ext_rapto r_010	QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?	RAPTOR	결과 및 비교	9	57.9 with one leaf layer versus 73.68 with all three layers
ext_rapto r_011	Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?	RAPTOR	결과 및 비교	20	RAPTOR retrieves relevant information across tree layers, while DPR retrieves detailed descriptions of a narrow subset of the story
track1_0 009	RAG가 LLM에서 사실적으로 부정확한 콘텐츠 생성을 줄이는 데 어떻게 기여합니까?	RAG Survey	목적 및 기여	1	By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content.
track1_0 010	RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?	RAG Survey	방법 및 절차	3	The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework.

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0012	RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?	RAG Survey	목적 및 기여	1	This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.
track1_0015	RAG 프로세스에서 핵심적인 역할을 하는 세 가지 구성 기술은 무엇인가요?	RAG Survey	사실 및 정의	2	the aspects of Retrieval, Generation and Augmentation
track1_0016	RAG 방법론의 평가 방법은 어떻게 요약되어 있습니까?	RAG Survey	방법 및 절차	2	We have summarized the current assessment methods of RAG, covering 26 tasks, nearly 50 datasets, outlining the evaluation objectives and metrics, as well as the current evaluation benchmarks and tools.
track1_0019	LLaMA-30B 모델에 CAD를 적용했을 때 CNN-DM 데이터셋에서 어떤 성과가 있었나요?	CAD	결과 및 비교	3	Specifically, when applied to LLaMA-30B in CNN-DM, CAD leads to 21% increase in ROUGE-L, 14.3% increase in factKB and 7.8% increase in BERT-P.
track1_0021	CAD는 어떻게 잘못된 정보 생성을 줄이나요?	CAD	결과 및 비교	2	These results demonstrate the potential of CAD in mitigating hallucinations in text generation and overriding prior knowledge with reliable and trusted information.
track1_0023	CAD는 언어 모델이 생성하는 요약문의 사실적 정확성을 향상시키나요?	CAD	결과 및 비교	1	Experimental results from summarization tasks show that context-aware decoding significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs such as FLAN (Chung et al., 2022).

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0024	CAD를 적용하지 않은 경우와 비교했을 때, knowledge conflict QA 데이터셋에서 LLaMA-30B의 성능은 어떻게 변화하나요?	CAD	결과 및 비교	2	CAD brings a 2.9x improvement to LLaMA-30B on a knowledge conflicts QA dataset (Longpre et al., 2021).
track1_0025	RAPTOR 모델이 QuALITY 벤치마크에서 기존 성능을 얼마나 개선했나요?	RAPTOR	결과 및 비교	1	we can improve the best performance on the QuALITY benchmark by 20% in absolute accuracy.
track1_0026	RAPTOR의 트리 구조는 텍스트 클러스터링을 통해 어떻게 구축되나요?	RAPTOR	방법 및 절차	2	RAPTOR recursively clusters chunks of text based on their vector embeddings and generates text summaries of those clusters, constructing a tree from the bottom up.
track1_0027	RAPTOR가 여러 QA 작업에서 달성한 결과는 무엇인가요?	RAPTOR	결과 및 비교	2	RAPTOR coupled with GPT-4, and sometimes even with UnifiedQA, gives new state-of-the-art results on three QA tasks: free text response questions on books and movies (NarrativeQA, Kočiský et al. 2018), full-text NLP papers (QASPER, Dasigi et al. 2021), and multiple-choice questions based on medium-length passages (QuALITY, Pang et al. 2022).
track1_0032	RAPTOR의 계층에서 검색된 노드가 어느 계층에서 오는지에 대한 연구 결과는 무엇인가요?	RAPTOR	결과 및 비교	22	We observe that between 18.5% to 57% of the retrieved nodes come from non-leaf nodes.
track1_0033	Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까?	Mi:dm K 2.5 Pro Technical Report	사실 및 정의	2	32B parameters
track1_0034	Mi:dm K 2.5 Pro의 방법론에서 AST 분석은 어떤 목적으로 사용됩니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	1	abstract syntax tree (AST) analysis for code
track1_0035	Mi:dm K 2.5 Pro 모델은 어떤 한국어 벤치마크에서 최첨단 결과를 달성했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	1	sets state-of-the-art results on Korean-specific benchmarks

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0036	Mi:dm K 2.5 Pro가 해결하려는 주요 문제는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	목적 및 기여	1	address enterprise-grade complexity through reasoning-focused optimization
track1_0037	Mi:dm K 2.5 Pro 모델의 컨텍스트 윈도우(context window) 길이는 얼마인가요?	Mi:dm K 2.5 Pro Technical Report	사실 및 정의	1	128K token context window
track1_0040	Mi:dm K 2.5 Pro의 사후 훈련 파이프라인에서 모델 병합은 어떤 역할을 합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	2	improve training stability and achieve balanced performance across complex reasoning, coding, instruction following, and agentic task execution

부록 B. 추가 사례 및 탐색 분석

B.1 추가 입출력 사례

그림 B-1은 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 사례다.

E06 | track1_0012

질문: RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?

A/B 검색 문맥, 검색 및 재정렬 ID 동일

A | hyde_off_no_decoder_control

HyDE OFF / CAD OFF / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_nlp_rag_bf4cd54870dd_2,

paper_nlp_rag_bf4cd54870dd

문맥[1] 발췌: [...] knowledge-intensive tasks across different topics, [28] revealed that while unsupervised fine-tuning shows some improvement, RAG consistently outperforms it, for both existing knowledge encountered du [...]

저장 답변 발췌: [...] ### 1. 외부 지식 활용의 우수성

논문에서는 "RAG excels in dynamic environments by offering realtime knowledge updates and effective utilization of external knowledge sources with high interpretability"라고 명시하고 있습니다. [...]

Faithfulness 0.9375 | Answer Relevancy 0.9001

Context Precision 1.0000 | Context Recall 1.0000

전체 답변 한국어 비율 0.4157

B | hyde_off_cad_only

HyDE OFF / CAD ON / SCD OFF

검색 ID (앞 2개 / 전체 8개): paper_nlp_rag_bf4cd54870dd_2,

paper_nlp_rag_bf4cd54870dd

저장 답변 발췌: [...] 논문]

위 내용 참조

**

답변을 뒷받침하는 구체적인 예시나 연구 결과도 포함해 주세요.

breath

** [...]

Faithfulness 0.5000 | Answer Relevancy 0.0000

Context Precision 1.0000 | Context Recall 1.0000

전체 답변 한국어 비율 0.8462

발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 추가 사례

질의 ID: track1_0012.

B.2 문서별 및 질문 유형별 탐색 분석

표 B-1에는 문서별 평균 대응 차이와 유효쌍 수를, 표 B-2에는 질문 유형별 평균 대응 차이와 유효쌍 수를 정리하였다. 목적 및 기여 유형에는 질의가 3개 포함되었다. 질문 유형별 분석 결과는 각 유형의 질의 수를 고려하여 탐색적으로 해석하였다.

[표 B-1] 문서별 탐색 분석

대상 문서	요인	지표	유효쌍 수 n	평균 대응 차이
Mi:dm K 2.5 Pro Technical Report	HyDE	근거 충실도	15	0.0007
Mi:dm K 2.5 Pro Technical Report	HyDE	답변 관련성	15	0.0994
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 정밀도	15	-0.0145
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 재현율	15	0.1333
Mi:dm K 2.5 Pro Technical Report	CAD	근거 충실도	15	0.0081
Mi:dm K 2.5 Pro Technical Report	CAD	답변 관련성	15	0.0339
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 정밀도	15	0
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 재현율	15	0
CAD	HyDE	근거 충실도	15	-0.0491
CAD	HyDE	답변 관련성	15	-0.0019
CAD	HyDE	문맥 정밀도	15	-0.0823
CAD	HyDE	문맥 재현율	15	-0.0667
CAD	CAD	근거 충실도	15	0.0664
CAD	CAD	답변 관련성	15	-0.0099
CAD	CAD	문맥 정밀도	15	-0.0552
CAD	CAD	문맥 재현율	15	-0.0667
RAG Survey	HyDE	근거 충실도	15	0.1575
RAG Survey	HyDE	답변 관련성	15	0.1314
RAG Survey	HyDE	문맥 정밀도	15	0.0036
RAG Survey	HyDE	문맥 재현율	15	0.0667
RAG Survey	CAD	근거 충실도	13	-0.0416
RAG Survey	CAD	답변 관련성	15	-0.1004
RAG Survey	CAD	문맥 정밀도	15	0.0074
RAG Survey	CAD	문맥 재현율	15	0
RAPTOR	HyDE	근거 충실도	15	0.0652
RAPTOR	HyDE	답변 관련성	15	0.093

대상 문서	요인	지표	유효쌍 수 n	평균 대응 차이
RAPTOR	HyDE	문맥 정밀도	15	-0.0441
RAPTOR	HyDE	문맥 재현율	15	-0.1333
RAPTOR	CAD	근거 충실도	15	0.0731
RAPTOR	CAD	답변 관련성	15	0.047
RAPTOR	CAD	문맥 정밀도	15	0.0108
RAPTOR	CAD	문맥 재현율	15	0

[표 B-2] 질문 유형별 탐색 분석

질문 유형	요인	지표	유효쌍 수 n	평균 대응 차이
사실 및 정의	HyDE	근거 충실도	8	0.0966
사실 및 정의	HyDE	답변 관련성	8	0.0455
사실 및 정의	HyDE	문맥 정밀도	8	-0.1328
사실 및 정의	HyDE	문맥 재현율	8	-0.125
사실 및 정의	CAD	근거 충실도	8	0.0005
사실 및 정의	CAD	답변 관련성	8	-0.0145
사실 및 정의	CAD	문맥 정밀도	8	-0.0486
사실 및 정의	CAD	문맥 재현율	8	0
방법 및 절차	HyDE	근거 충실도	29	0.0792
방법 및 절차	HyDE	답변 관련성	29	0.1719
방법 및 절차	HyDE	문맥 정밀도	29	-0.0029
방법 및 절차	HyDE	문맥 재현율	29	0.069
방법 및 절차	CAD	근거 충실도	27	0.0823
방법 및 절차	CAD	답변 관련성	29	0.0684
방법 및 절차	CAD	문맥 정밀도	29	0.0029
방법 및 절차	CAD	문맥 재현율	29	0
결과 및 비교	HyDE	근거 충실도	20	-0.0509
결과 및 비교	HyDE	답변 관련성	20	-0.0216
결과 및 비교	HyDE	문맥 정밀도	20	-0.0289
결과 및 비교	HyDE	문맥 재현율	20	-0.05
결과 및 비교	CAD	근거 충실도	20	-0.0037
결과 및 비교	CAD	답변 관련성	20	-0.0683
결과 및 비교	CAD	문맥 정밀도	20	-0.0124
결과 및 비교	CAD	문맥 재현율	20	-0.05
목적 및 기여	HyDE	근거 충실도	3	0.1875
목적 및 기여	HyDE	답변 관련성	3	-0.0289
목적 및 기여	HyDE	문맥 정밀도	3	-0.1111
목적 및 기여	HyDE	문맥 재현율	3	0
목적 및 기여	CAD	근거 충실도	3	-0.1597
목적 및 기여	CAD	답변 관련성	3	-0.3139

질문 유형	요인	지표	유효쌍 수 n	평균 대응 차이
목적 및 기여	CAD	문맥 정밀도	3	0
목적 및 기여	CAD	문맥 재현율	3	0