졸업자격실험보고서

# 한국어 질의 기반 영문 문서 검색 증강 생성(RAG)의 성능 개선 알고리즘 비교 분석

지도교수

졸업자격실험보고서

# 한국어 질의 기반 영문 문서 검색 증강 생성(RAG)의 성능 개선 알고리즘 비교 분석

# Comparative Analysis of Performance Improvement Algorithms for Retrieval-Augmented Generation (RAG) on English Documents with Korean Queries

지도교수

본 보고서를 졸업자격 실험보고서로 제출함.

졸업자격 실험보고 통과를 인준함.

주심 (인)

부심 (인)

# 목 차

1. 서론 ····· 1
1.1 연구배경 및 목적 ····· 1
1.2 연구범위 ····· 2
1.3 연구 질문 및 논문 구성 ····· 2
2. 이론적 배경 ····· 3
2.1 검색 증강 생성 ····· 3
2.2 하이브리드 검색과 재정렬 ····· 3
2.3 가상 문서 임베딩과 검색 ····· 4
2.4 문맥 인식 디코딩 ····· 4
2.5 소프트 제약 디코딩과 언어 이탈 ····· 5
2.6 RAG 평가 ····· 6
2.7 관련 연구와 본 연구의 위치 ····· 6
3. 시스템 설계 ····· 7
3.1 연구 및 실험 요구사항 ····· 7
3.2 아키텍처 설계 ····· 7
3.3 실험 조건과 비교 방법 ····· 7
4. 프로그램 구현 ····· 9
4.1 시스템 환경 ····· 9
4.2 시스템 구성 ····· 10
4.3 시스템 구현과 실행 기록 ····· 10
5. 실험 ····· 12
5.1 질문 구성과 질문 유형 ····· 12
5.2 평가 지표와 평가 입력 ····· 12
5.3 분석 방법 ····· 14
5.4 조건별 평가 결과 ····· 15
5.5 질문 유형별 결과 ····· 16
5.6 질문별 원점수의 분포 ····· 19

5.7 실제 답변에서 확인한 변화 ····· 22
5.8 질문 유형에 따른 기법 선택 ····· 24
6. 결론 ····· 25
6.1 연구 질문별 결과 ····· 25
6.2 연구의 의의와 적용 조건 ····· 25
6.3 후속 연구 ····· 25
참고문헌 ····· 26
부록 A. 60개 질문과 정답 근거 ····· 30
부록 B. 질문별 검색 근거와 실제 답변 ····· 40
B.1 RAPTOR에서 BIC가 결정하는 항목 ····· 40
B.2 NQ-Swap 데이터셋의 생성 절차 ····· 40
B.3 Fusion SFT의 non-reasoning 비중 확대 목적 ····· 41
B.4 QuALITY의 계층별 검색 성능 비교 ····· 41
B.5 LLaMA-30B의 XSUM 세 지표 비교 ····· 41
B.6 RAPTOR 청크 길이와 문장 경계 처리 ····· 42
B.7 지식 집약 과제에서 RAG의 이점 ····· 42
B.8 Naive RAG의 처리 과정 ····· 43
B.9 큰 청크와 작은 청크의 장단점 ····· 43

# 그 림 목 차

[그림 1-1] Paper-RAG에서 HyDE, CAD, SCD의 적용 위치 ····· 2
[그림 2-1] RAG의 검색기와 생성기 구조[1] ····· 3
[그림 2-2] HyDE의 가상 문서 기반 검색 구조[2] ····· 4
[그림 2-3] CAD의 문맥 포함 로짓과 제외 로짓의 결합[3] ····· 5
[그림 2-4] SCD의 토큰 그룹별 로짓 조정[4] ····· 5
[그림 4-1] 한국어 질의의 검색, 융합, 재정렬과 답변 생성 흐름 ····· 10
[그림 4-2] 수치 질문 하나에서 본 HyDE, CAD, SCD의 작동 방식 ····· 11
[그림 5-1] 질문별 생성 기록과 평가값을 연결하는 분석 절차 ····· 13
[그림 5-2] RAPTOR의 BIC 질문에 대한 입력 구간, 답변과 평가값 ····· 14
[그림 5-3] 수치 질문 18개의 조건별 원점수 평행좌표 ····· 20
[그림 5-4] 방법 질문 25개의 조건별 원점수 평행좌표 ····· 21
[그림 5-5] 개념과 결과 질문 17개의 조건별 원점수 평행좌표 ····· 22

# 표 목 차

[표 2-1] 선행 연구의 핵심 접근과 본 연구와의 관계 ····· 6
[표 3-1] 기법 적용 조건과 품질 평가 근거의 언어 ····· 7
[표 4-1] 단계별 모델, 공통 설정과 기법별 파라미터 ····· 9
[표 5-1] 8개 조건의 평가 지표별 평균(표준편차) ····· 15
[표 5-2] 질문 유형별 8개 조건의 평가 지표 평균 ····· 18
[표 A-1] 60개 질문의 대상 문서, 유형과 정답 근거 ····· 30

# 1. 서론

이 장은 연구 배경과 목적, 연구 범위, 연구 질문을 제시한다.

## 1.1 연구배경 및 목적

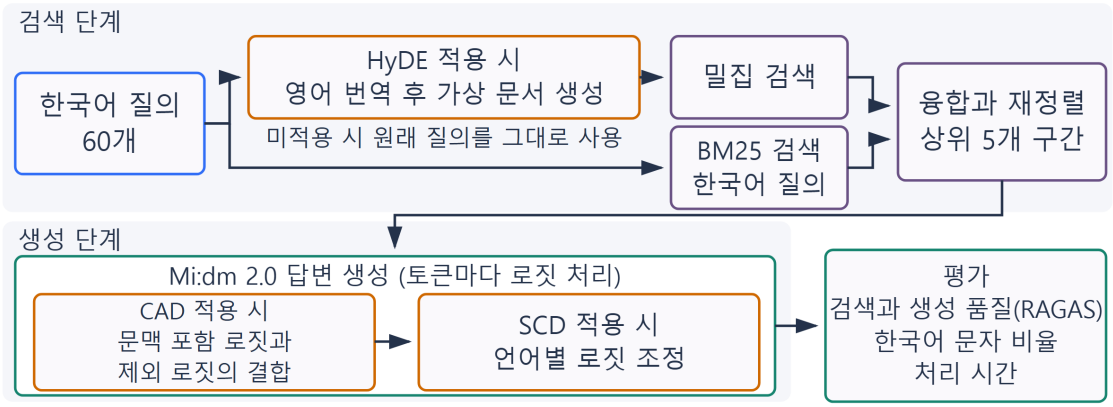
검색 증강 생성(Retrieval-Augmented Generation, RAG)은 질의와 관련된 문서 구간을 외부 자료에서 검색하고, 검색한 구간을 생성 모델의 입력에 넣어 답변을 만드는 방법이다[1]. RAG는 모델의 학습 시점 이후에 나온 논문과 기술 문서에 관한 질문에도 원문을 근거로 답할 수 있어 학술 문서 질의응답에 널리 쓰인다.

RAG의 성능을 높이는 기법은 검색 단계와 생성 단계에 모두 있으며, 생성 단계의 기법은 다음 토큰(모델이 생성하는 단어 조각)을 고르는 디코딩에 작용한다. 검색 단계의 가상 문서 임베딩(Hypothetical Document Embeddings, HyDE)은 질의에 대한 답변 형태의 가상 문서를 먼저 생성하고, 이 문서의 임베딩(텍스트를 벡터로 바꾼 표현)으로 실제 문서를 검색한다[2]. 생성 단계의 문맥 인식 디코딩(Context-Aware Decoding, CAD)은 검색 결과를 입력에 포함했을 때와 제외했을 때의 다음 토큰 점수를 비교하여, 검색 결과가 뒷받침하는 토큰이 선택될 가능성을 높인다[3]. 소프트 제약 디코딩(Soft Constrained Decoding, SCD)도 생성 단계에서 목표 언어 토큰과 다른 언어 토큰의 로짓(소프트맥스 적용 전의 토큰 점수)에 서로 다른 계수를 곱해 출력 언어를 제어한다[4]. 선행 연구에서 HyDE는 웹 검색, 질의응답, 사실 검증과 한국어를 포함한 다국어 검색에서, CAD는 요약과 지식 충돌(모델의 사전 지식과 입력 문서의 내용이 충돌하는 상황) 과제에서, SCD는 답변이 질의와 다른 언어로 바뀌는 언어 이탈(language drift) 과제에서 각각 효과가 보고되었다.

한국어 질의로 영어 문서를 다루는 RAG는 세 가지 과제를 함께 풀어야 한다. 검색에서는 한국어 질의와 영어 원문의 어휘 차이를 넘어 근거를 찾아야 하고, 답변 생성에서는 영어 근거의 내용을 한국어 답변에 충실히 반영해야 한다. 또한 모델이 영어 근거를 따라 영어로 답하는 언어 이탈을 막아야 한다. HyDE는 검색 입력을, CAD는 근거 반영을, SCD는 출력 언어를 조정하므로 세 기법은 이 과제에 하나씩 대응한다. 선행 연구에서는 각 기법을 서로 다른 모델과 과제에서 따로 평가하였다. 그러나 문서 질의응답에서는 수치를 옮기는 질문, 과정을 설명하는 질문, 개념을 해석하는 질문처럼 질문마다 요구하는 작업이 다르고, 같은 기법도 질문의 종류에 따라 효과가 달라질 수 있다. 따라서 세 기법과 그 조합을 한 파이프라인에서 질문 유형별로 비교해야 기법을 고르는 기준을 얻을 수 있다.

실험에는 영어 학술 및 기술 문서를 검색하여 한국어 답변을 생성하는 고정 파이프라인 Paper-RAG를 사용하였다. 같은 한국어 질문 60개에 HyDE, CAD, SCD의 적용 여부를 조합한 여덟 조건을 적용하였다(그림 1-1).

본 연구의 목적은 한국어 질의로 영어 문서를 검색하는 RAG에서 성능 개선 알고리즘인 HyDE, CAD, SCD와 그 조합을 질문 유형별로 비교 분석하여, 유형별로 적합한 조합을 고르는 기준을 제시하는 것이다. 이를 위해 여덟 조건의 원점수를 비교하고, 질문을 수치, 방법, 개념과 결과의 세 유형으로 나누어 같은 비교를 반복한 뒤, 점수가 크게 바뀐 질문의 검색 근거와 답변을 같은 질문의 미적용 조건 결과와 대조한다. 이 연구의 기여는 같은 파이프라인과 질문에서 측정한 세 기법과 조합의 이득과 비용을 질문 유형별로 제시하는 데 있다.




[그림 1-1] Paper-RAG에서 HyDE, CAD, SCD의 적용 위치

## 1.2 연구범위

검색 대상은 영어 문서 네 종으로, RAG Survey[D1], CAD 논문[D2], RAPTOR(Recursive Abstractive Processing for Tree-Organized Retrieval)[D3], Mi:dm K 2.5 Pro Technical Report[D4]이다. 문서마다 한국어 질문을 15개씩, 총 60개 작성하였고, 각 질문의 검색 범위는 해당 문서로 한정하였다. 이 논문에서 질의는 검색과 생성 모델에 입력하는 문장을, 질문은 평가에 사용한 60개 문항을 가리킨다. 질문마다 여덟 조건을 적용하여 생성 답변 480개를 얻었다.

답변 생성 모델은 Mi:dm 2.0 Base Instruct[M1]이다. 검색과 생성의 품질은 RAGAS(Retrieval Augmented Generation Assessment)의 네 지표로, 출력 언어는 한국어 문자 비율로, 비용은 처리 시간으로 측정하였다. 검색, 재정렬, 생성의 설정은 4장에 정리하였다.

## 1.3 연구 질문 및 논문 구성

연구의 중심 질문은 '한국어 질의로 영어 문서를 다루는 RAG에서 HyDE, CAD, SCD와 그 조합의 효과는 질문 유형에 따라 어떻게 달라지는가?'이다. 이를 다음 세 연구 질문(research question, RQ)으로 나누었다.

RQ1. 여덟 조건에서 답변 품질, 한국어 문자 비율과 처리 시간은 어떻게 다른가?

RQ2. 수치 질문, 방법 질문, 개념과 결과 질문에서 기법과 조합의 점수는 어떻게 다른가?

RQ3. 같은 유형 안에서 점수가 크게 오르거나 내린 질문은 검색 근거와 답변에서 무엇이 달라졌는가?

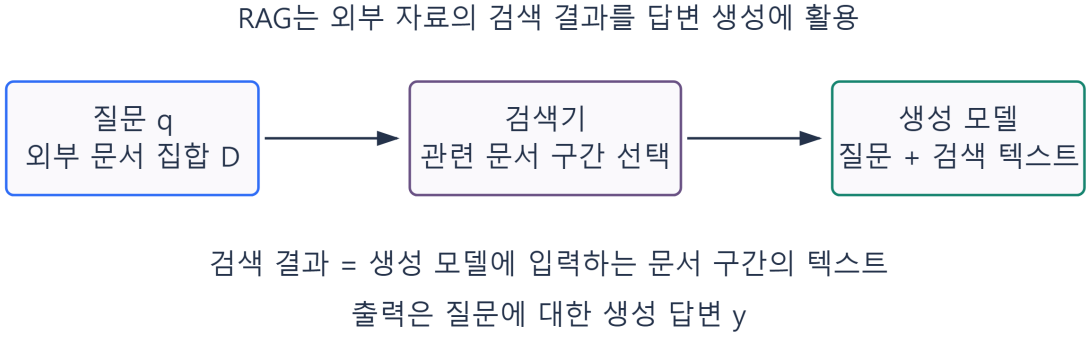
2장은 세 기법과 관련 연구를, 3장과 4장은 시스템 설계와 구현을 설명한다. 5장은 조건별 원점수와 질문 유형별 결과를 분석하고 점수가 크게 바뀐 질문의 실제 답변을 대조하며, 6장은 연구 질문별 결과와 적용 조건, 후속 연구를 정리한다. 부록 A는 60개 질문과 정답 근거를, 부록 B는 5.7절에서 다룬 질문의 정답 근거와 답변 발췌를 제시한다.

# 2. 이론적 배경

이 장은 RAG와 세 기법, 평가 지표, 관련 연구를 정리한다.

## 2.1 검색 증강 생성

Lewis 외의 RAG는 검색기(retriever)가 외부 문서 인덱스에서 관련 문서를 찾고, 생성기(generator)가 질의와 검색 문서를 함께 입력받아 답변을 생성하는 구조다(그림 2-1).




[그림 2-1] RAG의 검색기와 생성기 구조[1]

질의를 q, 문서 집합을 D라 하면 검색기 Retrieve는 D에서 질의와 관련된 문서 구간을 골라 검색 결과 $C_q$를 만들고, 생성 모델 LM은 q와 $C_q$를 입력받아 답변 y를 생성한다.

$$C_q = Retrieve(q, D)$$

$$y = LM(q, C_q)$$

## 2.2 하이브리드 검색과 재정렬

밀집 검색은 질의와 문서 구간을 임베딩한 벡터의 유사도로, BM25(Best Matching 25) 희소 검색은 두 텍스트의 어휘 일치로 관련 구간을 찾는다[5][6]. 한국어 질의와 영어 원문은 어휘가 대부분 다르지만, 논문명, 모델명, 데이터셋명, 수치처럼 두 언어에 같은 형태로 쓰이는 표기는 BM25의 검색 단서가 된다.

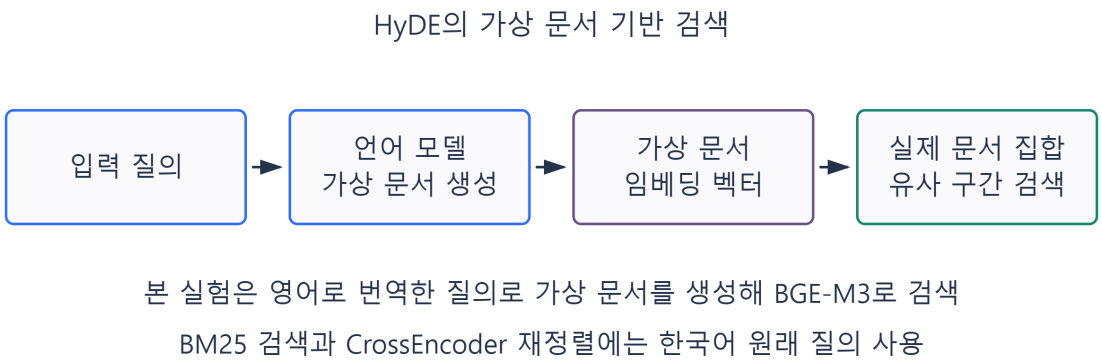
두 검색 결과는 가중 역순위 융합(weighted Reciprocal Rank Fusion, RRF)으로 결합한다[7]. 문서 d의 밀집 검색 순위와 BM25 순위를 각각 $rank_{dense}(d)$, $rank_{BM25}(d)$라 할 때, 가중치 0.6과 0.4, 상수 k=60을 적용한 결합 점수는 다음과 같다.

$$RRF(d) = \frac{0.6}{k + rank_{dense(d)}} + \frac{0.4}{k + rank_{BM25(d)}}$$

융합한 검색 후보는 질의와 후보 구간을 한 쌍으로 입력받는 재정렬 모델의 관련성 점수로 다시 정렬한다. 재정렬 모델로는 CEDR(Contextualized Embeddings for Document Ranking)[8] 등이 있다. 생성 모델은 입력 내 위치에 따라 근거를 다르게 활용할 수 있으므로[9], 재정렬 순서는 답변에도 영향을 줄 수 있다.

### 2.3 가상 문서 임베딩과 검색

HyDE는 입력 질의로 생성한 가상 문서를 임베딩하여 실제 문서 집합에서 유사한 문서를 검색한다. 가상 문서의 내용이 틀릴 수 있어도 답변과 비슷한 어휘와 문장 구조를 갖기 때문에, 짧은 질의를 그대로 임베딩할 때보다 관련 문서에 가까운 검색 입력을 얻을 수 있다. 가상 문서는 검색 입력으로만 쓰이고, 최종 답변의 근거는 검색한 실제 문서 구간이다(그림 2-2).




[그림 2-2] HyDE의 가상 문서 기반 검색 구조[2]

Gao 외는 관련성 레이블 없이 수행하는 검색에서 HyDE가 비지도 밀집 검색 모델인 Contriever보다 높은 성능을 보이고, 한국어를 포함한 비영어 검색에서도 효과가 있다고 보고하였다. 본 연구에서는 한국어 질의를 영어로 번역한 뒤 영어 가상 문서를 생성하였으므로, HyDE를 적용한 결과의 변화에는 번역과 가상 문서 생성의 효과가 함께 포함된다.

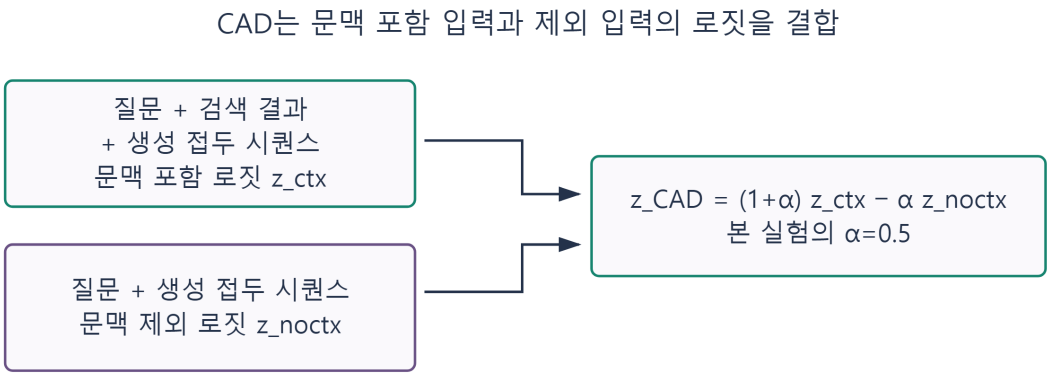
### 2.4 문맥 인식 디코딩

CAD는 검색 결과를 포함했을 때와 제외했을 때의 다음 토큰 로짓을 가중 결합하는 디코딩 방법이다. 검색 결과를 넣었을 때 로짓이 크게 오르는 토큰일수록 검색 결과의 영향을 많이 받는다. CAD는 두 로짓의 차이를 키워, 모델의 사전 지식보다 검색 결과의 내용을 반영하는 토큰이 선택되도록 한다(그림 2-3).

지금까지 생성한 토큰 시퀀스를 동일하게 두고, 검색 결과를 포함한 입력의 로짓을 $z_{ctx}$, 제외한 입력의 로짓을 $z_{noctx}$라 하면 CAD의 로짓은 다음과 같다. $\alpha$는 검색 결과의 영향을 키우는 정도를 정하며, $\alpha$=0이면 일반 디코딩과 같다.

$$z_{CAD} = (1+\alpha) z_{ctx} - \alpha z_{noctx}$$

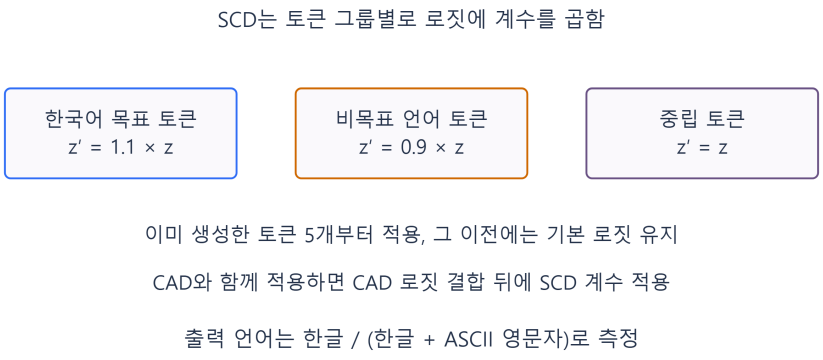
Shi 외는 요약 과제와 지식 충돌 과제에서 CAD가 입력 문서를 더 충실히 반영한다고 보고하였다. CAD는 토큰마다 검색 결과를 제외한 입력의 로짓을 한 번 더 계산하므로 생성 시간이 늘어난다.




[그림 2-3] CAD의 문맥 포함 로짓과 제외 로짓의 결합[3]

## 2.5 소프트 제약 디코딩과 언어 이탈

다국어 RAG에서는 질의와 다른 언어의 문서를 검색하면 답변이 검색 문서의 언어로 바뀌는 언어 이탈이 발생할 수 있다. Li 외는 이 현상을 분석하고, 디코딩 단계에서 목표 언어 토큰의 점수를 조정하는 SCD를 제안하였다. SCD는 어휘 집합을 목표 언어 토큰, 비목표 언어 토큰, 숫자나 기호 같은 중립 토큰으로 나누어 로짓을 조정한다(그림 2-4).




[그림 2-4] SCD의 토큰 그룹별 로짓 조정[4]

토큰 i의 로짓을 $z_i$라 하면, SCD는 생성한 토큰 수가 $T_{start}$ 이상일 때 목표 언어 토큰의 로짓에 α를, 비목표 언어 토큰의 로짓에 β를 곱하고 중립 토큰의 로짓은 그대로 둔다. 이 α와 β는 2.4절 CAD의 α와 별개인 SCD의 계수이며, 아래 세 식은 차례로 목표 언어, 비목표 언어, 중립 토큰의 조정된 로짓이다. 본 연구는 한국어를 목표 언어로 하여 원 논문의 곱셈식을 그대로 적용하였다. 이 식은 원래 로짓에 계수를 곱하므로, 로짓이 양수인 토큰과 음수인 토큰에서 점수가 변하는 방향이 반대가 된다.

$$\tilde{z}_i = \alpha z_i$$

$$\tilde{z}_i = \beta z_i$$

$$\tilde{z}_i = z_i$$

## 2.6 RAG 평가

RAGAS는 RAG의 검색과 생성을 나누어 자동으로 평가하는 프레임워크다[10]. RAGAS가 제공하는 근거 충실도(faithfulness), 답변 관련성(answer relevancy), 문맥 정밀도(context precision), 문맥 재현율(context recall) 가운데 근거 충실도와 답변 관련성은 생성 답변을, 문맥 정밀도와 문맥 재현율은 검색 결과를 평가한다. 근거 충실도는 평가 모델로 쓰는 대규모 언어 모델(Large Language Model, LLM)이 답변을 주장 단위로 나누고 각 주장이 검색 결과에 근거하는지 판정하여 계산한다. 지표별 계산 방식은 5.2절에 정리하였다.

## 2.7 관련 연구와 본 연구의 위치

Dense Passage Retrieval(DPR)[11]은 질의와 문서를 각각 임베딩하는 밀집 검색을, Fusion-in-Decoder(FiD)[12]는 여러 검색 구간을 디코더에서 결합하는 생성을 다룬다. Contrastive Decoding[13]은 두 모델의 출력 분포를 대조하며, CAD는 같은 모델에서 문맥을 포함한 입력과 제외한 입력을 대조한다.

RAPTOR[14]는 계층적 요약 검색을, Self-RAG[15]와 Adaptive-RAG[16]는 검색 필요성과 질문 복잡도에 따른 검색 전략을 다룬다. Zhao 외[17]와 Fan 외[18]는 RAG의 구성 요소별 기법을 정리하였고, BEIR(Benchmarking Information Retrieval)[19]와 MTEB(Massive Text Embedding Benchmark)[20]는 검색과 임베딩을 비교하는 벤치마크다.

본 연구는 검색과 생성의 구성을 고정한 채 HyDE, CAD, SCD와 그 조합을 비교하고, 한국어 질문 60개의 유형별 점수를 실제 검색 결과와 답변에 연결한다. 표 2-1은 선행 연구의 접근과 본 연구의 분석 대상을 정리한 것이다.

[표 2-1] 선행 연구의 핵심 접근과 본 연구와의 관계

| 연구 | 핵심 접근 | 본 연구와의 관계 |
|---|---|---|
| HyDE[2] | 가상 문서를 임베딩하여 검색 | 질문 유형별 답변 관련성과 검색 지표의 변화 |
| CAD[3] | 문맥을 포함한 로짓과 제외한 로짓의 결합 | 질문 유형별 근거 충실도와 처리 시간의 변화 |
| SCD[4] | 언어별 토큰 로짓의 조정 | 질문 유형별 한국어 문자 비율의 변화 |
| DPR[11], FiD[12] | 밀집 검색과 여러 검색 구간의 활용 | 모든 조건에 고정한 검색과 생성 구성 |
| Self-RAG[15], Adaptive-RAG[16] | 검색 필요성과 질문 복잡도에 따른 검색 전략 선택 | 질문 유형에 따라 기법을 고르는 기준 |
| RAGAS[10], BEIR[19], MTEB[20] | RAG 자동 평가와 검색 벤치마크 | 질문별 원점수와 유형별 평균의 비교 |

# 3. 시스템 설계

이 장은 실험 요구사항, 아키텍처, 실험 조건을 설명한다.

## 3.1 연구 및 실험 요구사항

모든 조건에서 검색, 재정렬, 생성 모델과 청크(문서를 나눈 검색 단위) 분할, 후보 수의 상한, 생성 설정을 고정하고, 같은 한국어 질문 60개를 사용하였다. 질문마다 검색 결과, 생성 답변, 처리 시간과 파라미터를 저장하여 조건 간 결과를 질문 ID로 연결하였다.

## 3.2 아키텍처 설계

Paper-RAG는 검색, 재정렬, 생성의 세 단계로 구성되며, 실행 순서는 4.2절의 그림 4-1에 제시하였다. 검색 단계에서는 BGE-M3[5] 기반 밀집 검색과 BM25 희소 검색을 함께 사용한다. HyDE는 밀집 검색의 입력만 원래 질의에서 영어 가상 문서로 바꾸고, BM25와 재정렬에는 항상 한국어 원래 질의를 사용한다.

두 검색 결과를 가중 RRF로 결합하고, 질의와 후보 구간을 한 쌍으로 입력받아 관련성 점수를 매기는 CrossEncoder로 재정렬한 뒤, 상위 5개 구간을 입력 구간으로 삼아 생성 모델에 입력한다. 생성 단계에서는 검색 결과 유무에 따른 원래 로짓의 차이를 쓰는 CAD를 먼저 적용하고, SCD는 CAD가 결합한 로짓에 언어별 계수를 곱한다. 두 기법은 생성 단계에만 작용하므로, HyDE를 적용하지 않은 조건에서 CAD와 SCD의 적용 전후 비교에는 같은 검색 결과가 쓰인다.

## 3.3 실험 조건과 비교 방법

세 기법의 적용 여부를 조합하여 여덟 조건을 만들고, 모든 조건에 같은 질문 60개를 입력하여 생성 기록 480개를 얻었다. 표 3-1은 조건 번호와 기법별 적용 여부, 품질 평가에 사용한 검색 결과의 언어를 나타낸다. 조건 번호는 미적용, 단일 기법, 두 기법 조합, 세 기법 조합의 순서이며 5장의 모든 표와 그림에 같은 번호를 사용한다.

[표 3-1] 기법 적용 조건과 품질 평가 근거의 언어

| 조건 | HyDE | CAD | SCD | 품질 평가 근거 |
|---|---|---|---|---|
| 1 미적용 | − | − | − | 영어 |
| 2 HyDE | + | − | − | 영어 |
| 3 CAD | − | + | − | 영어 |
| 4 SCD | − | − | + | 한국어 번역 |
| 5 HyDE+CAD | + | + | − | 영어 |
| 6 HyDE+SCD | + | − | + | 한국어 번역 |
| 7 CAD+SCD | − | + | + | 한국어 번역 |
| 8 HyDE+CAD+SCD | + | + | + | 한국어 번역 |

+는 적용, −는 미적용을 뜻한다. 품질 평가 근거는 근거 충실도, 문맥 정밀도, 문맥 재현율을 계산할 때 제공한 검색 결과의 언어이며, 답변 관련성은 질문과 답변만으로 계산한다.

SCD를 적용한 조건 4, 6, 7, 8은 답변이 대부분 한국어이므로 검색 결과를 쓰는 근거 충실도, 문맥 정밀도, 문맥 재현율을 한국어로 번역한 검색 결과로 평가하였고, 이 세 지표는 SCD 적용 여부가 같은 조건끼리 비교한다(5.2절). 한국어 문자 비율과 처리 시간은 여덟 조건 모두 저장된 답변과 실행 기록에서 같은 방식으로 계산하였다. 각 조건의 결과는 질문 ID로 연결하여, 같은 질문에서 두 조건의 점수를 비교하였다.

HyDE를 적용하지 않은 조건 1, 3, 4, 7은 질문마다 같은 검색 결과를 사용하였다. HyDE를 적용한 조건은 가상 문서를 조건마다 다시 생성하였으므로 검색 결과도 조건마다 달라질 수 있다. 예를 들어 HyDE와 HyDE+CAD의 입력 구간이 같은 질문은 60개 중 18개였고, HyDE+SCD와 HyDE+CAD+SCD는 24개였다. 따라서 HyDE를 포함한 조건 사이의 차이에는 생성 제어의 차이와 검색 결과의 차이가 함께 들어 있다.

# 4. 프로그램 구현

이 장은 시스템 환경, 처리 흐름, 실행 기록 방식을 설명한다.

## 4.1 시스템 환경

Paper-RAG는 Python과 PyTorch, Hugging Face Transformers 4.45.2로 구현하였다. 모든 조건은 같은 검색, 재정렬, 생성 설정을 사용하였다. 표 4-1은 공통 설정과 기법별 파라미터를 정리한 것이다. 청크 분할과 입력 길이는 공백 기준 단어 수로 계산하였고, 답변은 최대 512토큰까지 생성하였다.

[표 4-1] 단계별 모델, 공통 설정과 기법별 파라미터

| 구성 단계 | 사용 모델 또는 방법 | 주요 설정 |
|---|---|---|
| 밀집 검색 | BAAI/bge-m3 | 후보 8개, 가중치 0.6 |
| 희소 검색 | BM25 | 후보 8개, 가중치 0.4 |
| 순위 융합 | 가중 RRF | k=60 |
| 재정렬 | cross-encoder/ms-marco-MiniLM-L-6-v2 | 후보 8개, 최종 구간 5개 |
| 문서 분할 | 공백 기준 단어 분할 | 최대 512단어, 중첩 64단어, 최소 50단어 |
| 입력 길이 관리 | ContextCompressor | 3,072단어 초과 시 압축, 비율 0.5 |
| 답변 생성 | K-intelligence/Midm-2.0-Base-Instruct | greedy, 최대 새 토큰 512개 |
| HyDE | 영어 번역과 가상 문서 생성 | temperature=0.1, top_p=0.9, sampling |
| CAD | 문맥 포함 로짓과 제외 로짓의 결합 | $\alpha$=0.5 고정 |
| SCD | 목표 언어 토큰의 로짓 조정 | $\alpha$=1.1, $\beta$=0.9, $T_{start}$=5 |

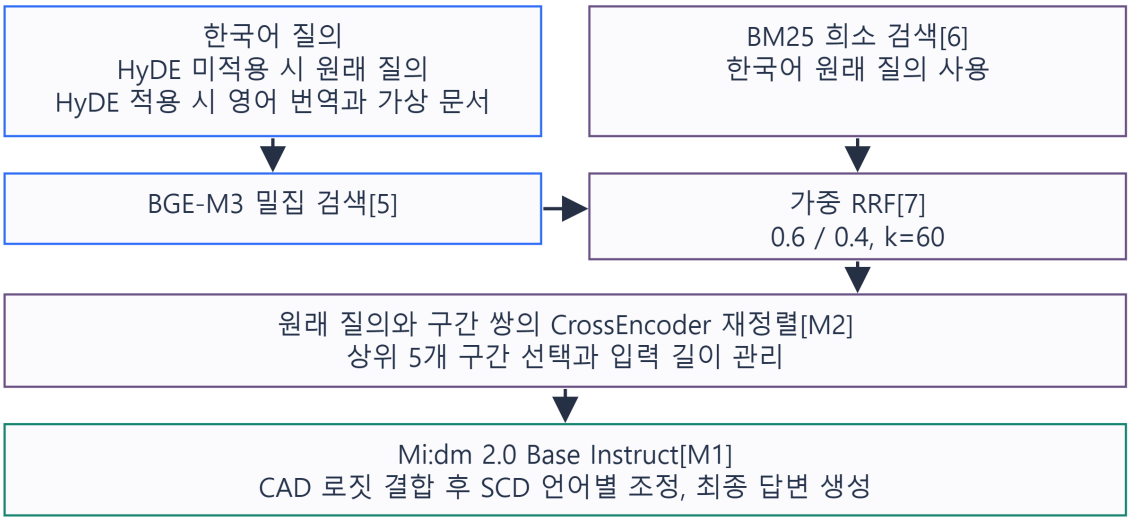
재정렬에는 검색 질의응답 데이터셋 MS MARCO(Microsoft Machine Reading Comprehension)로 학습한 MiniLM CrossEncoder[M2]를 사용하였고, 한국어 원래 질의와 영어 후보 구간을 한 쌍으로 입력하였다. 선택한 5개 구간의 단어 수 합이 3,072단어를 넘으면 ContextCompressor를 적용하였다. ContextCompressor는 질의와 겹치는 단어의 비율로 문장 순위를 정하고, 구간마다 단어 수의 50% 안에서 상위 문장을 골라 원래 순서대로 남긴다. 평가 질문과 분리한 튜닝 질문 5개에서 문맥 재현율이 0.95 이상인 후보 설정을 비교하였다. 그중 근거 충실도가 가장 높은 설정을 선택하여 검색 후보와 재정렬 후보의 상한을 각각 8개, 최종 입력 구간을 5개로 모든 조건에 설정하였다. CAD의 $\alpha$는 Shi 외가 요약 과제에 사용한 0.5로 고정하였다. SCD의 $\alpha$=1.1, $\beta$=0.9, $T_{start}$=5는 Li 외가 목표 언어의 일치와 문장의 자연스러움을 함께 고려하여 실험에 사용한 값이다[4]. HyDE의 번역문과 가상 문서는 확률에 따라 다음 토큰을 뽑는 샘플링으로 생성하였고, temperature 0.1과 top_p 0.9로 후보를 확률이 높은 토큰 쪽으로 좁혔다.

## 4.2 시스템 구성

Paper-RAG는 질의 하나를 검색 입력 구성, 검색과 재정렬, 답변 생성, 실행 기록의 순서로 처리한다(그림 4-1). 먼저 질의에 지정된 대상 문서의 밀집 검색 인덱스와 BM25 인덱스를 불러온다. HyDE를 적용하면 답변 생성에 쓰는 Mi:dm 2.0 Base Instruct로 한국어 질의를 영어로 번역하고, 번역문으로 영어 가상 문서를 생성하여 밀집 검색의 입력으로 쓴다.

검색 단계에서는 밀집 검색과 원래 질의를 쓰는 BM25 검색에서 각각 최대 후보 8개를 얻어 가중 RRF로 결합한다. 한국어 원래 질의로 BM25를 실행한 기록에서 후보가 0개인 질문은 13개, 2개인 질문은 3개, 8개인 질문은 44개였다. CrossEncoder로 후보를 재정렬하여 상위 5개 구간을 고른다. 고른 구간의 단어 수 합이 3,072단어를 넘으면 ContextCompressor로 압축한 뒤 생성 모델에 입력하고, 3,072단어 이내이면 그대로 입력한다.

생성 단계에서는 검색 결과만을 근거로 한국어로 답하라는 공통 프롬프트에 검색 결과와 질의를 넣고, 조건에 따라 CAD와 SCD의 로짓 처리기를 붙여 greedy 디코딩(매 단계에서 점수가 가장 높은 토큰을 고르는 방식)으로 답변을 생성한다. 끝으로 검색과 재정렬의 청크 ID, 최종 검색 결과, 답변, 처리 시간과 파라미터를 기록하며, 평가값은 질문 ID와 조건으로 이 기록에 연결한다.



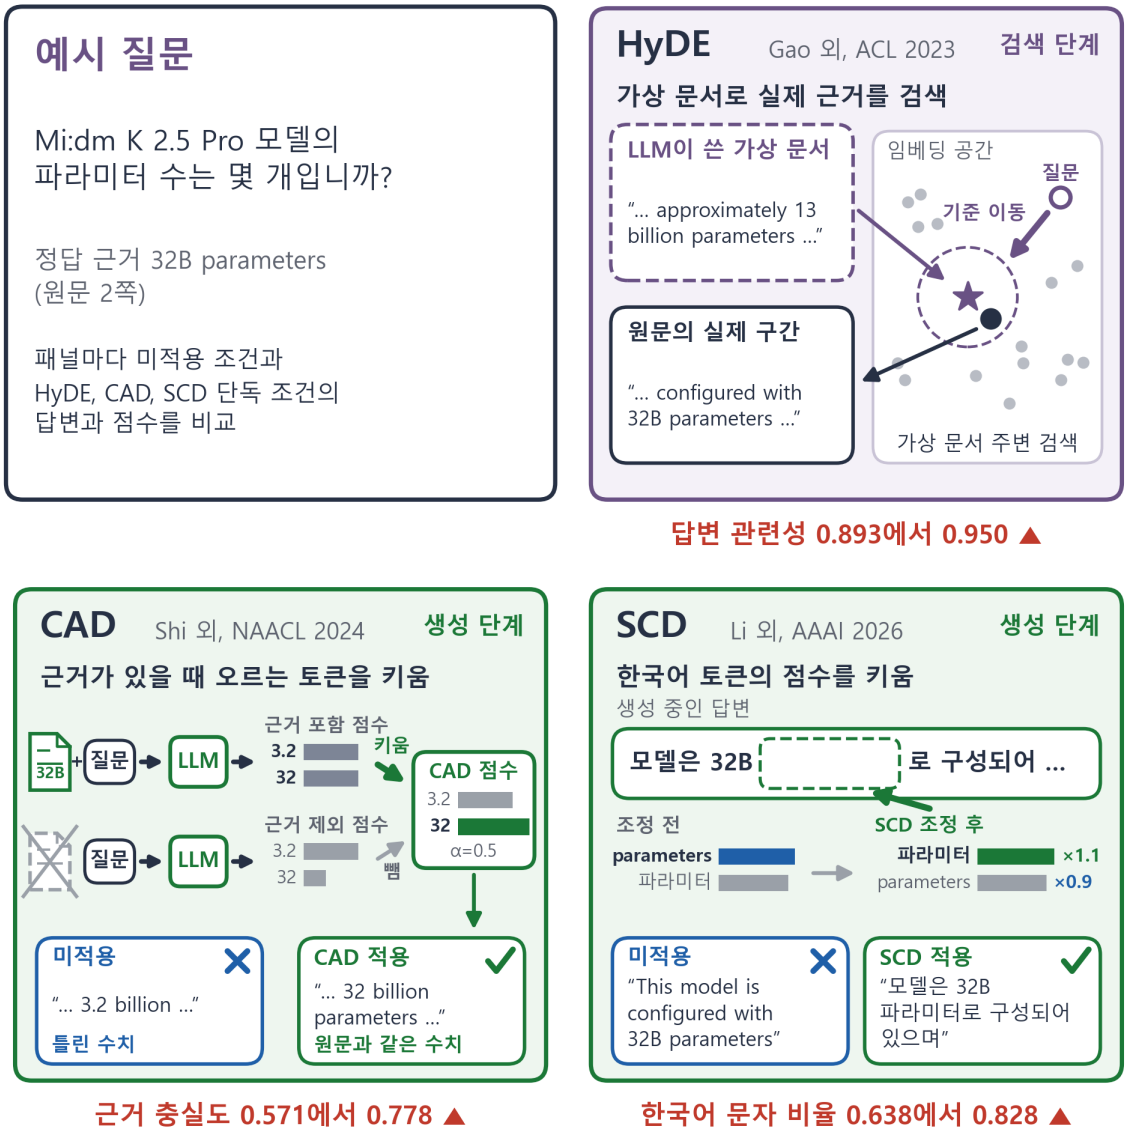

[그림 4-1] 한국어 질의의 검색, 융합, 재정렬과 답변 생성 흐름

## 4.3 시스템 구현과 실행 기록

CAD는 토큰을 하나 생성할 때마다 같은 프롬프트에서 검색 결과만 뺀 입력의 로짓을 추가로 계산하고, 두 로짓을 2.4절의 식으로 결합한다. SCD는 생성한 토큰이 5개 이상이 되면 한국어 토큰과 비한국어 토큰의 로짓에 각각 α와 β를 곱하고 중립 토큰은 그대로 둔다.

처리 시간은 모델과 검색 구성 요소를 초기화한 뒤 질문과 조건마다 측정하였고, HyDE를 적용한 조건에는 번역과 가상 문서 생성 시간이 포함된다. 각 생성 실행에서 처음 처리한 미적용 질문 두 개는 첫 추론의 준비 시간이 포함되어 각각 164.153초와 117.317초가 걸렸으므로, 처리 시간 비교에는 두 질문을 모든 조건에서 뺀 58개 질문을 사용하였다.

그림 4-2는 Mi:dm K 2.5 Pro의 파라미터 수를 묻는 수치 질문에서 세 기법이 작동하는 방식을 저장된 실행 기록으로 나타낸다. 정답 근거는 기술 보고서[D4] 2쪽의 32B parameters이다. HyDE가 생성한 가상 문서에는 13 billion parameters라는 틀린 수치가 들어 있었지만, HyDE 조건의 검색 결과에는 32B parameters 문장이 있는 실제 구간이 포함되었고 답변 관련성은 0.893에서 0.950으로 올랐다. 미적용 답변은 근거의 32B를 3.2 billion으로 옮겼고, CAD 답변은 32 billion parameters로 옮겨 근거 충실도가 0.571에서 0.778로 올랐다. 미적용 답변은 근거 문장을 영어 그대로 인용하였고, SCD 답변은 같은 문장을 한국어로 옮겨 인용하여 한국어 문자 비율이 0.638에서 0.828로 올랐다. HyDE 패널은 검색 기준이 질문에서 가상 문서로 옮겨 가는 과정을 나타낸다. CAD 패널은 근거를 넣은 입력에서 3.2와 32의 점수가 비슷할 때, 근거가 올린 점수를 키우면 32가 앞서는 과정을 나타내고, SCD 패널은 언어별 계수를 곱한 뒤 한국어 후보가 영어 후보보다 앞서는 과정을 나타낸다.




[그림 4-2] 수치 질문 하나에서 본 HyDE, CAD, SCD의 작동 방식

# 5. 실험

이 장은 질문 구성과 평가 방법을 설명하고 결과를 분석한다.

## 5.1 질문 구성과 질문 유형

실험에는 영어 문서 네 종에 관한 한국어 질문 60개를 사용하였다. RAG Survey는 RAG의 구성과 발전 과정을, CAD 논문은 검색 결과를 답변에 반영하는 디코딩 방법을, RAPTOR 논문은 문서 요약 트리를 이용한 계층적 검색을 다룬다. Mi:dm K 2.5 Pro Technical Report는 한국어와 영어를 함께 학습한 언어 모델의 학습 과정과 평가 결과를 다룬다. 문서마다 15개 질문을 구성하였고, 각 질문의 검색 범위는 해당 문서 하나다.

질문은 문서의 주요 내용을 고르게 다루도록 작성하였다. 문서마다 질문의 형식과 범위를 정하는 초기 질문 3개를 먼저 작성하고, GPT-4o로 문서의 주요 내용을 15개 단위로 요약하였다. 각 단위에 질문을 하나씩 배정하였으며 초기 질문 3개도 이 15개에 포함된다. 연구자는 원문 PDF에서 모든 질문의 답변 가능성과 정답 근거를 확인하고 해당 쪽을 기록하였다(부록 A). 질문을 작성하는 단계와 근거를 확인하는 단계를 나눈 방식은 논문 기반 질의응답 데이터셋인 QASPER[21]를, 언어 모델로 문서 내용에서 질문을 만드는 방식은 문서 기반 질문 생성 연구[22]를 참고하였다.

분석에서는 질문을 세 유형으로 나누었다. 질문마다 답변에 필요한 작업이 수치를 정확히 옮기는 일, 과정을 설명하는 일, 개념이나 결과를 해석하는 일로 달라지므로, 정답의 형태를 먼저 기준으로 삼고 서술형 질문만 내용으로 나누었다. 정답이 점수, 비율, 개수, 설정값 같은 수치인 질문 18개는 수치 질문이다. 나머지 서술형 질문 42개 가운데 처리 과정, 실험 구성, 사용한 모델과 자료를 묻는 질문 25개는 방법 질문, 개념의 정의와 연구 목적, 결과의 경향이나 이유를 묻는 질문 17개는 개념과 결과 질문이다. 예를 들어 장문 독해 데이터셋 QuALITY(Question Answering with Long Input Texts, Yes!)에서 한 계층과 세 계층을 검색했을 때의 정확도를 묻는 질문은 수치 질문, RAPTOR가 클러스터 수를 정하는 기준을 묻는 질문은 방법 질문, RAG가 지식 집약 과제에서 갖는 이점을 묻는 질문은 개념과 결과 질문이다. 문서별로 보면 Mi:dm 보고서의 질문 15개 가운데 8개가 수치 질문이고, RAG Survey의 질문 15개는 방법 질문 10개와 개념과 결과 질문 5개로 이루어져 있다.

## 5.2 평가 지표와 평가 입력

답변과 검색 결과의 품질은 RAGAS 0.2.15의 네 지표로 평가하였다. 평가 모델은 GPT-4o, 임베딩 모델은 BGE-M3이며, 참조 답변으로는 부록 A의 영어 정답 근거를 사용하였다.

근거 충실도는 생성 답변의 주장 가운데 입력 구간이 뒷받침하는 주장의 비율이다. 답변 관련성은 평가 모델이 생성 답변에서 역으로 만든 질문 세 개와 원래 질문의 임베딩 코사인 유사도를 평균한 값이다. 평가 모델이 답변을 모호하거나 회피하는 응답으로 판정하면 답변 관련성은 0이 된다. 480개 답변 가운데 54개가 0으로 기록되었고, 조건별로는 미적용 7개, HyDE 3개, CAD 6개, SCD 8개, HyDE+CAD 5개, HyDE+SCD 6개, CAD+SCD 11개, HyDE+CAD+SCD 8개였다.

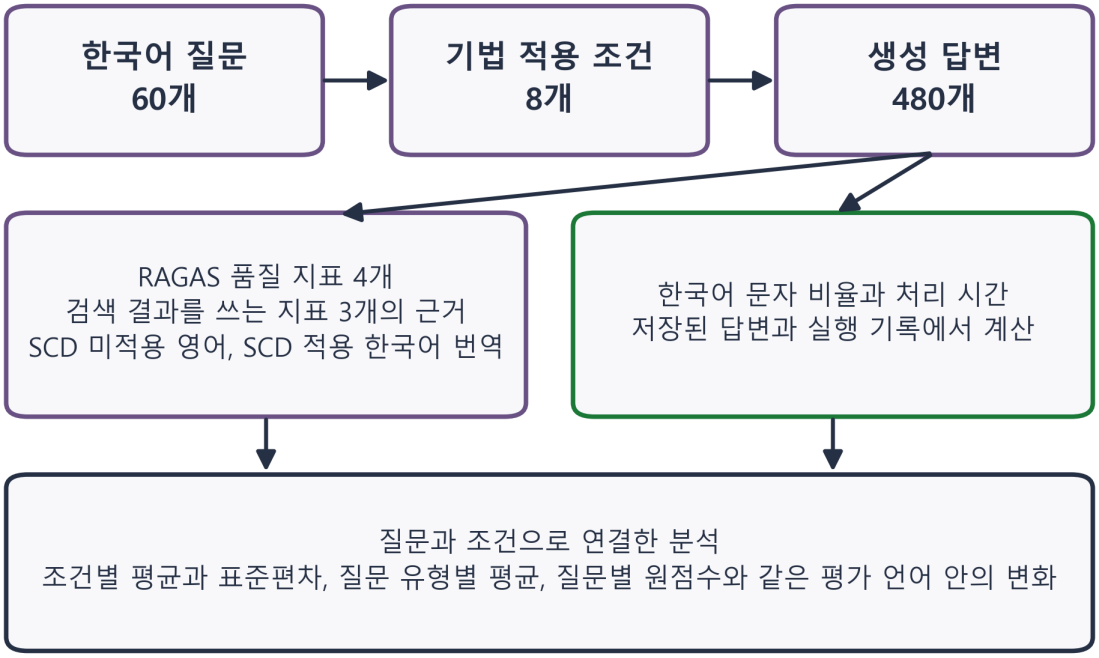
문맥 정밀도는 참조 답변에 유용한 구간이 입력 구간의 상위 순위에 놓인 정도이고, 문맥 재현율은 참조 답변의 주장을 입력 구간이 뒷받침하는 비율이다. 근거 충실도, 문맥 정밀도, 문맥 재현율은 0에서 1 사이의 값이다. 답변 관련성은 코사인 유사도의 평균이므로 이론적 범위가 −1에서 1이고, 이번 실험의 관측값은 모두 0에서 1 사이였다. 네 지표 모두 값이 클수록 품질이 높다.

출력 언어는 생성 답변의 한국어 문자 비율로 측정하였다. 한글 문자 수를 $N_{Hangul}$, ASCII(American Standard Code for Information Interchange) 영문자 수를 $N_{ASCII}$라 하면 한국어 문자 비율은 다음과 같다.

$$KoreanRatio = \frac{N_{Hangul}}{N_{Hangul} + N_{ASCII}}$$

모델명과 논문명의 영문자도 분모에 들어가므로, 자연스러운 한국어 답변도 1보다 낮은 값을 가진다. 처리 시간은 질문 하나의 처리 시작부터 답변 생성과 기록용 메타데이터 구성이 끝날 때까지의 초 단위 시간이며, 짧을수록 비용이 작다.

품질 평가에 제공한 검색 결과의 언어는 SCD 적용 여부에 따라 다르다. SCD를 적용한 조건의 답변은 대부분 한국어이므로, 같은 실행에서 저장한 영어 검색 결과를 GPT-4o로 번역하여 근거 충실도, 문맥 정밀도, 문맥 재현율의 평가에 사용하였다. SCD를 적용하지 않은 조건은 생성에 사용한 영어 검색 결과로 평가하였다. 따라서 이 세 지표는 SCD 적용 여부가 같은 네 조건 안에서 비교한다. 답변 관련성은 질문과 답변만으로 계산하므로 한국어 문자 비율과 함께 여덟 조건 전체에서 비교한다. 답변을 생성할 때는 모든 조건에 영어 검색 결과를 입력하였고, 참조 답변도 모든 조건에서 영어 원문이다. 그림 5-1은 생성 기록과 평가값을 질문과 조건으로 연결하는 과정을 나타낸다.




[그림 5-1] 질문별 생성 기록과 평가값을 연결하는 분석 절차

평가값은 질문, 참조 답변, 입력 구간, 생성 답변을 함께 볼 때 의미가 분명해진다. RAPTOR에서 베이즈 정보 기준(Bayesian Information Criterion, BIC)이 결정하는 항목을 묻는 질문에서 HyDE 조건의 입력 구간에는 최적 클러스터 수를 정한다는 원문 문장이 들어 있었고, 답변도 같은 내용을 설명하였다. 이 답변의 근거 충실도는 0.857, 문맥 재현율은 1.000이었다. 근거 충실도는 답변의 주장을 입력 구간과 대조하고, 문맥 재현율은 참조 답변을 입력 구간과 대조한다(그림 5-2).

| | |
|---|---|
| **질문** | RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까? |
| **참조 답변** | to determine the optimal number of clusters (원문 4쪽) |
| **입력 구간** | To determine the optimal number of clusters, we employ the Bayesian Information Criterion (BIC) for model selection. |
| **생성 답변** | 제공된 논문 컨텍스트를 분석한 결과, RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 최적의 클러스터 개수 결정을 위해 사용됨이 확인됩니다. |
| **평가값** | 근거 충실도 0.857, 답변 관련성 0.895<br>문맥 정밀도 0.700, 문맥 재현율 1.000 |

[그림 5-2] RAPTOR의 BIC 질문에 대한 입력 구간, 답변과 평가값

## 5.3 분석 방법

분석은 조건별 원점수, 질문 유형별 평균, 질문별 변화의 순서로 진행하였다. 먼저 질문 60개에 대한 여덟 조건의 평균과 표준편차를 지표별로 계산하였다(5.4절). 다음으로 같은 평균을 세 질문 유형으로 나누어 계산하고, 각 기법이 유리한 유형을 비교하였다(5.5절).

질문별 변화는 같은 질문에서 비교 조건의 점수에서 기준 조건의 점수를 뺀 값이다. 기준 조건은 따로 밝히지 않으면 미적용이며, 검색 결과를 쓰는 세 지표는 SCD 적용 여부가 같은 조건끼리 비교한다. 차이가 0.05보다 크면 오른 질문, −0.05보다 작으면 내린 질문, 그 사이면 비슷한 질문으로 세었고, 처리 시간은 1초를 경계로 삼았다. 두 조건 중 한쪽의 답변 관련성이 0인 질문은 오르내림 대신 관련성 0점이 생기거나 사라진 질문으로 따로 세었다.

같은 조건에서도 점수가 크게 오른 질문과 크게 내린 질문이 함께 있을 수 있으므로, 질문별 원점수를 평행좌표(지표를 세로축으로 나란히 두고 한 질문의 값을 선으로 이은 그림)로 그려 유형마다 평균에서 멀리 떨어진 질문을 찾았다(5.6절). 이렇게 찾은 질문마다 원문 정답 근거, 입력 구간, 생성 답변을 같은 질문의 미적용 조건 결과와 대조하였다(5.7절).

근거 충실도 480개 값 가운데 5개가 결측이다(CAD 조건 2개, SCD 조건 3개). 결측 질문은 해당 조건의 평균과 대응 비교에서 제외하였고, 나머지 지표는 480개 값을 모두 사용하였다.

### 5.4 조건별 평가 결과

여덟 조건의 평균에서 SCD를 포함한 네 조건은 한국어 문자 비율이 SCD를 포함하지 않은 네 조건보다 모두 높았지만, 두 기법 이상을 조합한 조건의 답변 관련성은 모두 HyDE 단독보다 낮았다. 표 5-1은 질문 60개에 대한 조건별 평균과 표준편차를 지표별로 정리한 것이다.

SCD를 적용하지 않은 조건 1, 2, 3, 5에서는 HyDE가 답변 관련성을 0.683에서 0.763으로 가장 크게 높였다. 관련성 0점이 없는 질문끼리 비교하면 HyDE로 관련성이 오른 질문은 16개, 내린 질문은 5개였다. CAD를 적용하면 충실도 값이 있는 58개 질문에서 근거 충실도의 평균이 미적용의 0.810에서 0.839로 올랐지만, 0.05 넘게 오른 질문은 16개, 내린 질문은 19개였다. 답변 관련성은 0.675로 미적용의 0.683과 비슷하였다. HyDE+CAD는 근거 충실도가 0.860으로 가장 높았지만 답변 관련성은 0.705로 HyDE 단독보다 낮았다. 검색 지표에서는 미적용의 문맥 정밀도가 0.749로 HyDE의 0.714보다 높았고, 문맥 재현율은 두 조건이 0.933으로 같았다.

SCD를 적용한 조건 4, 6, 7, 8에서는 HyDE+SCD의 답변 관련성이 0.710으로 가장 높았다. 여기에 CAD를 더한 HyDE+CAD+SCD는 0.667, SCD에 CAD를 더한 CAD+SCD는 0.600으로 낮아졌다. 여덟 조건 가운데 관련성 0점 답변은 HyDE에서 3개로 가장 적었고 CAD+SCD에서 11개로 가장 많았다.

[표 5-1] 8개 조건의 평가 지표별 평균(표준편차)

| 조건 | 근거 충실도 | 답변 관련성 | 문맥 정밀도 | 문맥 재현율 | 한국어 문자 비율 | 처리 시간(초) |
|---|---|---|---|---|---|---|
| 1 미적용 | 0.791 (0.260) | 0.683 (0.282) | **0.749 (0.302)** | **0.933 (0.252)** | 0.494 (0.265) | 16.656 (5.051) |
| 2 HyDE | 0.834 (0.186) | **0.763 (0.209)** | 0.714 (0.296) | **0.933 (0.252)** | 0.556 (0.213) | 23.533 (4.385) |
| 3 CAD | 0.839 (0.201) | 0.675 (0.261) | 0.740 (0.302) | 0.917 (0.279) | 0.488 (0.245) | 64.182 (24.563) |
| 4 SCD | 0.787 (0.254) | 0.637 (0.296) | **0.763 (0.300)** | 0.900 (0.303) | 0.699 (0.329) | 18.658 (5.001) |
| 5 HyDE+CAD | **0.860 (0.181)** | 0.705 (0.248) | 0.736 (0.271) | 0.900 (0.303) | 0.503 (0.229) | 72.527 (21.245) |
| 6 HyDE+SCD | 0.822 (0.218) | 0.710 (0.272) | 0.743 (0.281) | 0.900 (0.303) | **0.807 (0.200)** | 24.811 (5.145) |
| 7 CAD+SCD | 0.777 (0.270) | 0.600 (0.321) | 0.752 (0.301) | 0.850 (0.360) | 0.719 (0.218) | 56.033 (26.463) |
| 8 HyDE+CAD+SCD | **0.831 (0.253)** | 0.667 (0.286) | 0.754 (0.267) | **0.917 (0.279)** | 0.731 (0.209) | 65.770 (20.091) |

질문 60개의 평균이며 괄호 안은 표준편차다. 근거 충실도는 결측이 있는 CAD 2개, SCD 3개 질문을 빼고, 처리 시간은 각 생성 실행의 첫 기록인 2개 질문을 빼고 계산하였다. 근거 충실도, 문맥 정밀도, 문맥 재현율은 조건 1, 2, 3, 5를 영어 검색 결과로, 조건 4, 6, 7, 8을 한국어 번역 검색 결과로 평가하였으므로 굵은 값은 각 네 조건 안의 최댓값이다. 답변 관련성과 한국어 문자 비율의 굵은 값은 8개 조건 중 최댓값이다. 미적용과 CAD, SCD와

CAD+SCD는 각각 질문 60개 모두에서 같은 입력 구간으로 평가하였으므로, 두 쌍의 문맥 정밀도와 문맥 재현율 차이는 평가 모델이 같은 입력을 다르게 판정한 데서 생겼다.

한국어 문자 비율은 SCD를 적용한 네 조건(0.699에서 0.807)이 SCD를 적용하지 않은 네 조건(0.488에서 0.556)보다 모두 높았다. 가장 높은 조건은 HyDE+SCD(0.807)였다. SCD를 단독으로 적용하면 질문 60개 가운데 50개에서 한국어 문자 비율이 미적용보다 0.05 넘게 올랐다.

조합의 손실은 같은 질문끼리 비교해도 나타났다. HyDE에 CAD를 더하면 답변 관련성이 내린 질문이 18개, 오른 질문이 5개였고, HyDE+SCD에 CAD를 더해도 내린 질문이 14개, 오른 질문이 5개였다. 두 기법 이상을 조합한 네 조건의 답변 관련성은 0.600에서 0.710 사이였고, 조합이 일관되게 높인 지표는 SCD를 포함할 때의 한국어 문자 비율이었다.

처리 시간은 CAD를 포함한 네 조건(56.033초에서 72.527초)이 CAD를 포함하지 않은 네 조건(16.656초에서 24.811초)보다 약 세 배 길었다. CAD는 토큰을 하나 생성할 때마다 검색 결과를 뺀 입력의 로짓을 한 번 더 계산한다. HyDE는 번역과 가상 문서 생성 때문에 미적용보다 평균 6.877초, SCD는 2.002초 더 걸렸다.

CAD에 SCD를 더한 CAD+SCD는 CAD 단독보다 평균 8.148초 짧았다. 1초 넘게 짧아진 31개 질문은 모두 답변 길이가 줄었고, 58개 답변의 평균 길이는 1,064자에서 765자로 줄었다. CAD의 추가 계산은 생성하는 토큰 수만큼 반복되므로 답변이 짧아진 만큼 처리 시간도 줄었다.

세 기법을 모두 적용한 HyDE+CAD+SCD는 검색 입력, 근거 반영, 출력 언어를 한 조건에서 함께 조정한다. 이 조합의 근거 충실도는 SCD를 적용한 네 조건 가운데 가장 높은 0.831이었고, 값이 있는 57개 질문을 SCD 단독과 비교하면 0.05 넘게 오른 질문이 27개, 내린 질문이 15개였다. 답변 관련성은 0.667로 미적용(0.683)과 비슷하였고, 한국어 문자 비율은 미적용의 0.494에서 0.731로 올랐다. 두 지표는 모두 HyDE+SCD(0.710, 0.807)보다 낮았고, 처리 시간은 65.770초로 미적용의 약 네 배, HyDE+SCD의 약 2.7배였다.

### 5.5 질문 유형별 결과

질문을 세 유형으로 나누면 각 기법이 유리한 질문이 서로 달랐다. 표 5-2는 표 5-1의 평균을 수치 질문, 방법 질문, 개념과 결과 질문으로 나누어 계산한 것이다.

HyDE는 방법 질문에서 가장 큰 차이를 만들었다. 방법 질문 25개의 답변 관련성은 미적용 0.575에서 HyDE 0.745로, 문맥 재현율은 0.880에서 0.960으로 올랐다. 미적용에서 관련성이 0점이던 방법 질문 5개는 HyDE 적용 후 모두 양수가 되었고, 그중 3개는 질문에 필요한 정보를 제시하였다. 새로 0점이 된 질문은 1개였다. 개념과 결과 질문에서도 답변 관련성은 0.778에서 0.815로, 근거 충실도는 0.848에서 0.903으로 올랐다. 수치 질문의 답변 관련성은 0.743에서 0.740으로 비슷하였고, 문맥 정밀도와 재현율은 각각 0.668에서 0.622, 0.944에서 0.889로 낮아졌다. 문서별로는 관련성 0점이 없는 질문끼리 비교한 HyDE의 답변 관련성 변화가 RAG Survey 질문 14개에서 평균 +0.110, CAD 논문 질문 13개에서 평균 −0.008로 달랐다.

CAD는 수치 질문과 방법 질문에서 근거 충실도의 평균을 높였다. 수치 질문의 충실도는 0.826에서 0.896으로, 값이 있는 방법 질문 23개의 충실도는 0.769에서 0.830으로 올랐다.

같은 질문끼리 비교하면 0.05 넘게 오른 질문과 내린 질문이 수치 질문에서 6개씩, 방법 질문에서 8개와 6개였으므로, 평균의 상승은 크게 오른 몇 개 질문에서 나왔다. 수치 질문에서 충실도가 가장 높은 조건은 SCD를 적용하지 않은 조건 가운데 HyDE+CAD, 적용한 조건 가운데 HyDE+CAD+SCD였고 둘 다 0.927이었다. 개념과 결과 질문에서는 반대로 충실도가 0.848에서 0.789로, 답변 관련성이 0.778에서 0.663으로 낮아졌다. 이 유형은 미적용에서 이미 문맥 재현율이 1.000, 근거 충실도가 0.848이었고, CAD 적용 후 관련성 0점 답변이 2개 생겼다. 같은 유형 안에서도 문서에 따라 변화의 크기가 달랐다. 수치 질문에서 CAD의 근거 충실도 변화는 RAPTOR 질문 6개가 평균 +0.163, CAD 논문 질문 4개가 +0.120, Mi:dm 질문 8개가 −0.024였다.

SCD는 세 유형 모두에서 한국어 문자 비율을 높였다. 상승폭은 개념과 결과 질문(0.456에서 0.709)과 수치 질문(0.585에서 0.814)이 방법 질문(0.455에서 0.610)보다 컸다. 방법 질문 가운데 RAG Survey의 검색 기법을 묻는 세 질문은 SCD 적용 후에도 답변이 영어 원문을 이어 써 비율이 0에 머물렀다. HyDE와 함께 적용한 HyDE+SCD는 세 유형 모두에서 비율이 가장 높았고(수치 0.835, 방법 0.785, 개념과 결과 0.810), SCD를 적용한 조건 가운데 방법 질문의 근거 충실도도 0.829로 가장 높았다.

세 기법의 이득은 서로 다른 지표에서 나타났고, 그 대가도 달랐다. CAD의 충실도 상승에는 미적용의 약 네 배인 처리 시간이 따랐고, 개념과 결과 질문에서는 관련성 하락이 함께 나타났다. SCD 단독의 답변 관련성은 0.637로 미적용(0.683)보다 낮았다. HyDE는 처리 시간을 6.877초 늘렸고, 수치 질문에서 문맥 정밀도와 재현율을 낮추었다.

[표 5-2] 질문 유형별 8개 조건의 평가 지표 평균

| 조건 | 근거 충실도 | | | 답변 관련성 | | |
|---|---|---|---|---|---|---|
| | 수치 (18개) | 방법 (25개) | 개념과 결과 (17개) | 수치 (18개) | 방법 (25개) | 개념과 결과 (17개) |
| 1 미적용 | 0.826 | 0.726 | 0.848 | 0.743 | 0.575 | 0.778 |
| 2 HyDE | 0.842 | 0.782 | **0.903** | 0.740 | **0.745** | **0.815** |
| 3 CAD | 0.896 | **0.830** | 0.789 | 0.752 | 0.629 | 0.663 |
| 4 SCD | 0.848 | 0.710 | 0.821 | 0.723 | 0.524 | 0.713 |
| 5 HyDE+CAD | **0.927** | 0.796 | 0.882 | **0.761** | 0.630 | 0.755 |
| 6 HyDE+SCD | 0.844 | **0.829** | 0.790 | 0.719 | 0.685 | 0.736 |
| 7 CAD+SCD | 0.767 | 0.761 | 0.809 | 0.719 | 0.503 | 0.616 |
| 8 HyDE+CAD+SCD | **0.927** | 0.765 | **0.828** | 0.666 | 0.650 | 0.694 |
| 조건 | 문맥 정밀도 | | | 문맥 재현율 | | |
| | 수치 (18개) | 방법 (25개) | 개념과 결과 (17개) | 수치 (18개) | 방법 (25개) | 개념과 결과 (17개) |
| 1 미적용 | 0.668 | 0.730 | **0.862** | **0.944** | 0.880 | **1.000** |
| 2 HyDE | 0.622 | 0.722 | 0.802 | 0.889 | **0.960** | 0.941 |
| 3 CAD | 0.670 | **0.734** | 0.821 | 0.889 | 0.880 | **1.000** |
| 4 SCD | 0.687 | 0.727 | **0.898** | **0.889** | 0.840 | **1.000** |
| 5 HyDE+CAD | **0.680** | 0.729 | 0.804 | **0.944** | 0.840 | 0.941 |
| 6 HyDE+SCD | **0.713** | 0.689 | 0.854 | **0.889** | 0.840 | **1.000** |
| 7 CAD+SCD | 0.677 | 0.729 | 0.867 | 0.833 | 0.800 | 0.941 |
| 8 HyDE+CAD+SCD | 0.683 | **0.764** | 0.813 | 0.778 | **0.960** | **1.000** |
| 조건 | 한국어 문자 비율 | | | 처리 시간(초) | | |
| | 수치 (18개) | 방법 (25개) | 개념과 결과 (17개) | 수치 (18개) | 방법 (25개) | 개념과 결과 (17개) |
| 1 미적용 | 0.585 | 0.455 | 0.456 | 14.648 | 16.662 | 18.906 |
| 2 HyDE | 0.552 | 0.568 | 0.543 | 20.896 | 24.336 | 25.294 |
| 3 CAD | 0.571 | 0.417 | 0.504 | 55.410 | 67.124 | 69.636 |
| 4 SCD | 0.814 | 0.610 | 0.709 | 16.924 | 18.572 | 20.737 |
| 5 HyDE+CAD | 0.520 | 0.458 | 0.552 | 60.591 | 78.747 | 76.623 |
| 6 HyDE+SCD | **0.835** | **0.785** | **0.810** | 24.065 | 23.737 | 27.262 |
| 7 CAD+SCD | 0.768 | 0.654 | 0.764 | 50.435 | 52.436 | 67.728 |
| 8 HyDE+CAD+SCD | 0.737 | 0.688 | 0.789 | 59.862 | 64.909 | 73.706 |

괄호 안은 각 유형의 질문 수다. 근거 충실도는 결측 질문을, 처리 시간은 각 생성 실행의 첫 기록인 2개 질문을 빼고 계산하였다. 근거 충실도, 문맥 정밀도, 문맥 재현율의 굵은 값은

SCD 미적용 네 조건과 적용 네 조건 안에서 각각 구한 최댓값이고, 답변 관련성과 한국어 문자 비율의 굵은 값은 8개 조건 중 최댓값이다.

조합의 결과도 유형마다 달랐다. 수치 질문에서는 SCD를 적용하지 않은 조건 가운데 HyDE+CAD의 근거 충실도(0.927)가 가장 높았고, 답변 관련성(0.761)은 여덟 조건 가운데 가장 높았다. 방법 질문과 개념과 결과 질문에서는 HyDE에 CAD를 더하면 답변 관련성이 각각 0.745에서 0.630, 0.815에서 0.755로 낮아졌다. 방법 질문에서 HyDE+CAD+SCD의 근거 충실도와 답변 관련성은 0.765와 0.650으로 HyDE+SCD의 0.829와 0.685보다 낮았다. 문맥 정밀도와 문맥 재현율은 0.764와 0.960으로 HyDE+SCD의 0.689와 0.840보다 높았다. CAD는 생성 단계에만 작용하므로, 이 차이에는 HyDE의 가상 문서를 조건마다 다시 생성하면서 달라진 검색 결과와 평가 모델의 판정 차이가 함께 들어 있다. 수치 질문에서는 HyDE+CAD+SCD의 문맥 재현율이 SCD 단독의 0.889보다 낮은 0.778이었고, 답변 관련성은 미적용 0.743에서 0.666으로 낮아졌다.

### 5.6 질문별 원점수의 분포

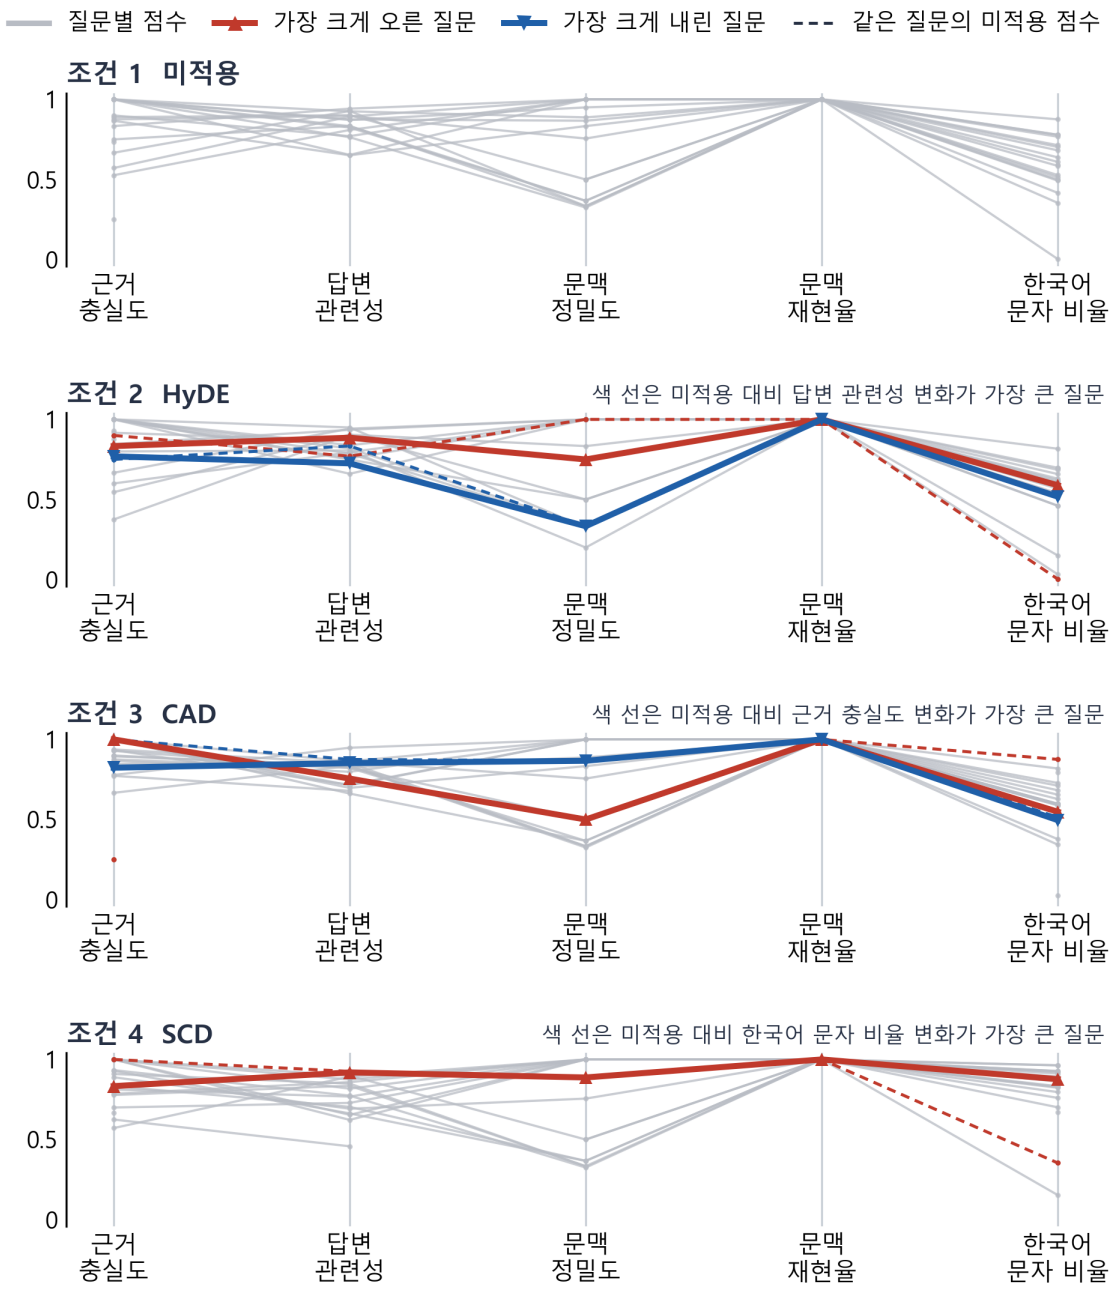
같은 유형의 평균이 오른 경우에도 질문마다 변화의 크기와 방향은 달랐다. 그림 5-3부터 그림 5-5까지는 세 유형의 질문별 원점수를 미적용, HyDE, CAD, SCD 조건으로 나누어 그린 평행좌표로, 평균이 가리는 질문 사이의 차이와 평균에서 멀리 떨어진 질문을 보여 준다. 색 선은 미적용과 비교하여 HyDE의 답변 관련성, CAD의 근거 충실도, SCD의 한국어 문자 비율이 가장 크게 오르거나 내린 질문을 나타낸다.

그림 5-3에서 수치 질문의 선은 네 조건 모두 근거 충실도와 문맥 재현율의 위쪽에 모였고, 문맥 정밀도에서는 0점을 뺀 값이 0.200에서 1.000까지 넓게 퍼졌다. HyDE 조건에서 답변 관련성이 가장 크게 오른 질문은 Mi:dm의 레드팀 평가에서 유해한 응답을 끌어내는 공격의 성공률을 묻는 질문(0.770에서 0.886)이었다. CAD 조건에서 근거 충실도가 가장 크게 오른 질문은 RAPTOR의 청크 길이와 문장 경계 처리를 묻는 질문(0.250에서 1.000)이었지만, 이 답변은 질문과 다른 내용을 설명하였다(5.7절).

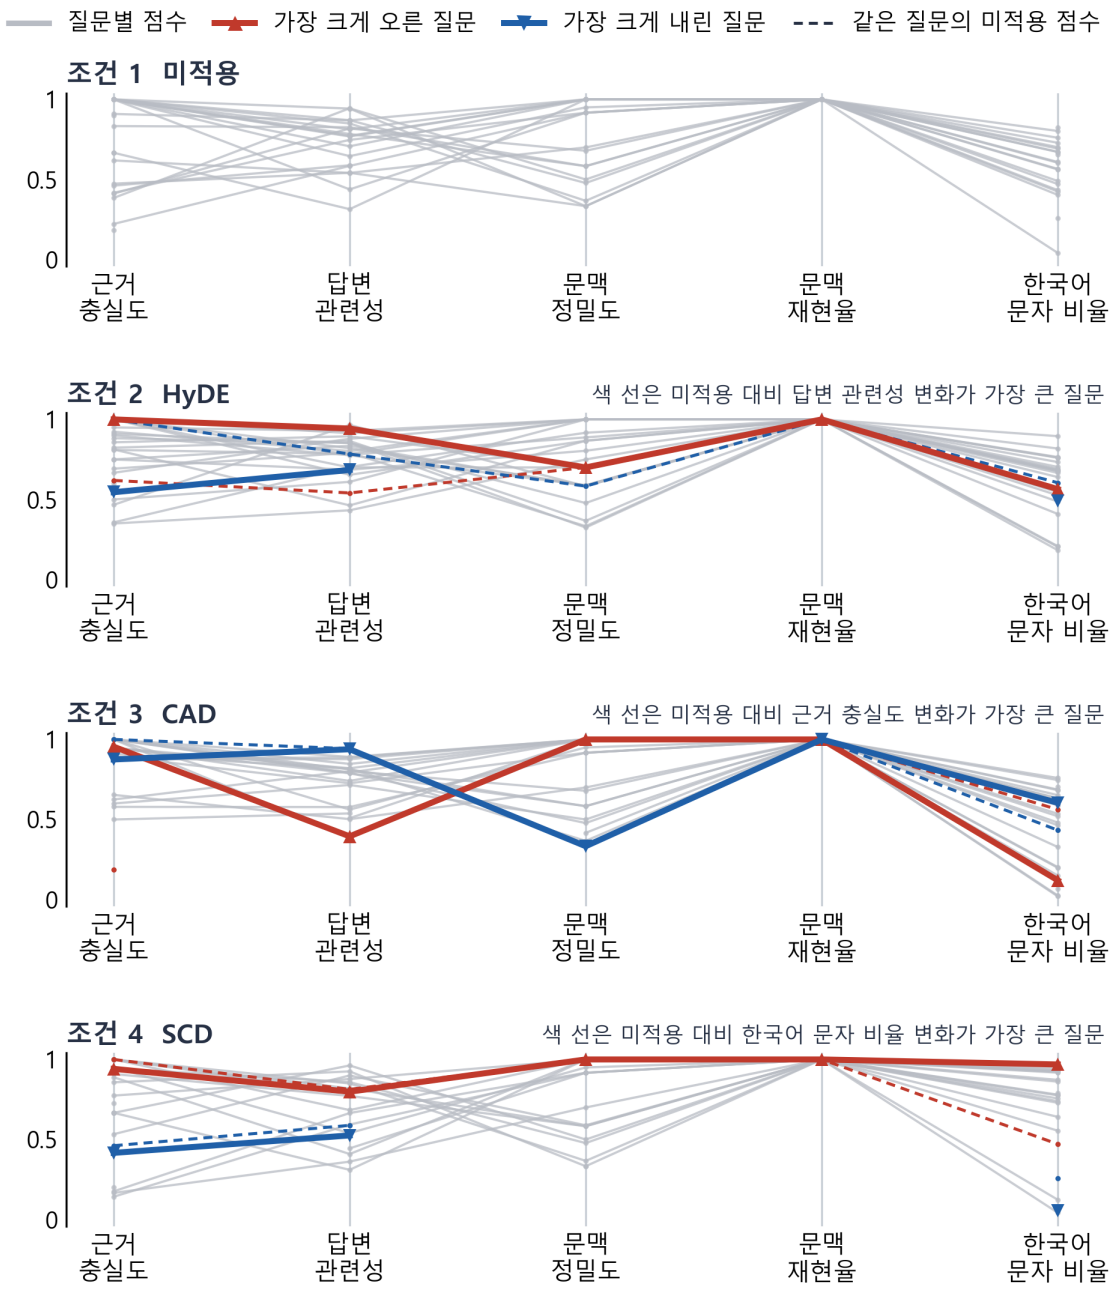
그림 5-4의 방법 질문은 미적용에서 근거 충실도와 답변 관련성이 넓게 흩어져 있었고, 관련성 0점으로 선이 끊긴 질문이 5개였다. HyDE 조건에서는 관련성 축의 선이 위쪽으로 모였고 0점 질문은 1개로 줄었다. 0점을 제외하면 RAPTOR에서 가우시안 혼합 모델(Gaussian Mixture Model, GMM) 클러스터링 전에 차원 축소 기법인 UMAP(Uniform Manifold Approximation and Projection)을 쓰는 이유를 묻는 질문의 관련성이 0.541에서 0.943으로 가장 크게 올랐다. CAD 조건에서 충실도가 가장 크게 오른 질문은 Natural Questions(NQ)의 정답 엔티티(인명, 지명 같은 고유 대상)를 바꾼 NQ-Swap 데이터셋의 생성 절차를 묻는 질문(0.185에서 0.955)으로, 이 답변은 입력 구간의 영어 문단을 그대로 옮긴 것이었다(5.7절).

그림 5-5의 개념과 결과 질문은 미적용에서 문맥 재현율이 모두 1.000이었고, 근거 충실도와 답변 관련성도 위쪽에 모여 있었다. HyDE 조건의 분포는 미적용과 비슷하였고, CAD 조건에서는 충실도와 관련성이 아래로 내려간 선이 늘었다. 충실도가 가장 크게 내린 질문은 RAG가 지식 집약 과제에서 갖는 이점을 묻는 질문(0.938에서 0.500)으로, CAD 답변에는 '위 내용 참조'와 요청 문장 조각만 남았다.

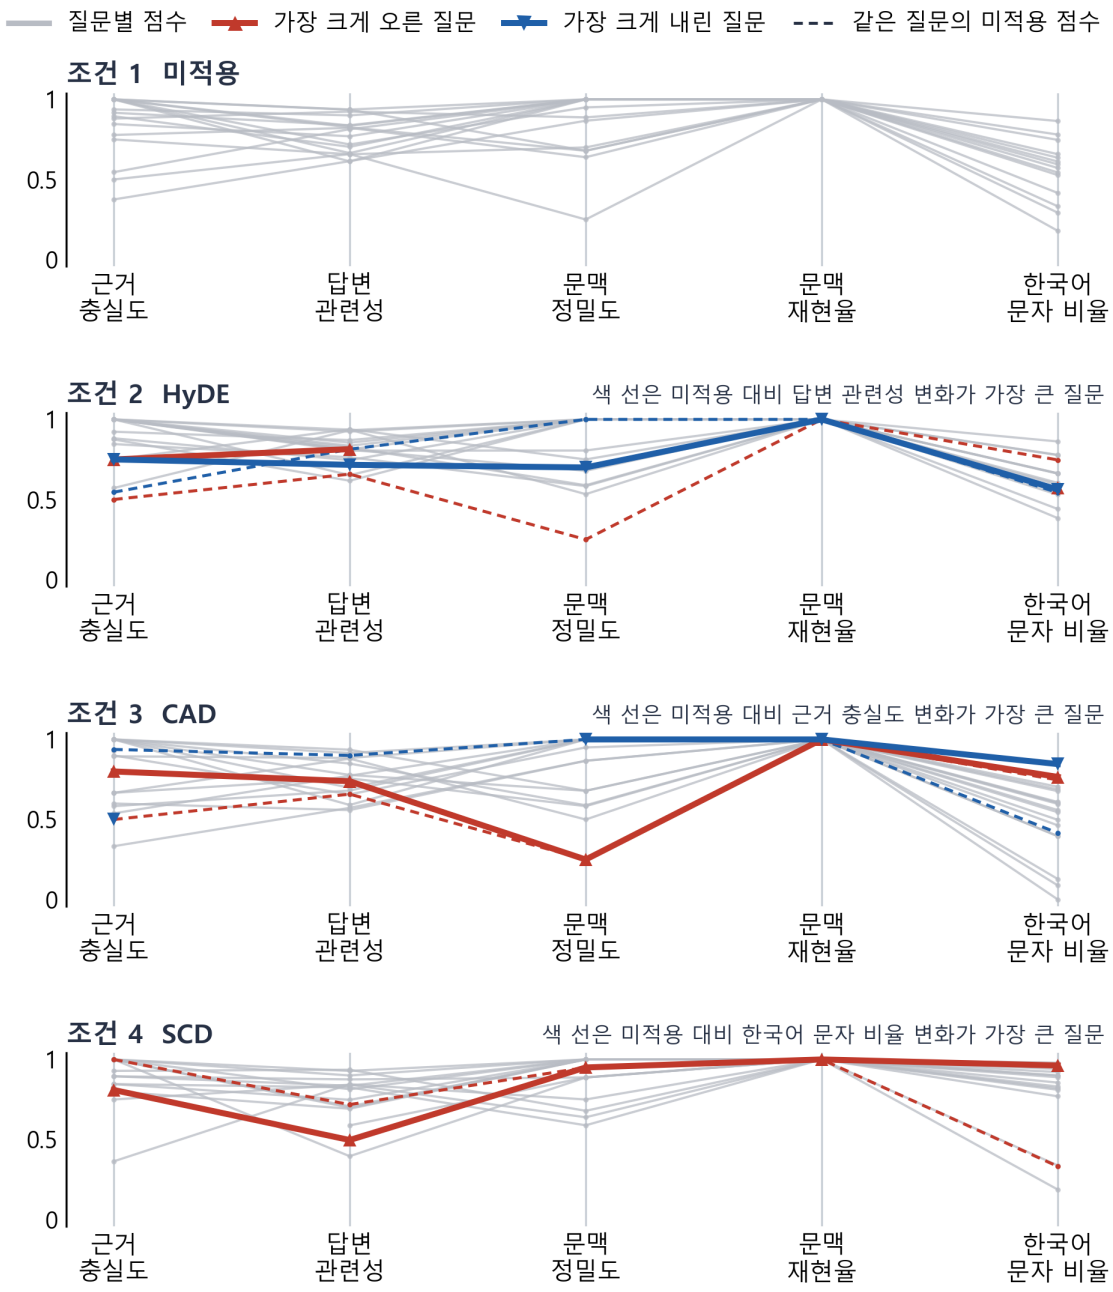
SCD 조건에서는 세 유형 모두 한국어 문자 비율 축의 선이 위로 올라갔다. 비율이 가장 크게 오른 질문은 수치 질문에서 Mi:dm의 문맥 길이(0.354에서 0.877), 방법 질문에서 사후 학습(post-training) 단계의 모델 병합(0.471에서 0.969), 개념과 결과 질문에서 RAG와 파인튜닝(사전 학습한 모델의 추가 학습)의 비교(0.332에서 0.962)를 묻는 질문이었다. 세 그림에서 유형 평균의 큰 변화는 일부 질문의 큰 변화에서 나왔다. 방법 질문의 HyDE 관련성 상승은 주로 관련성 0점 답변 5개가 양수로 바뀐 데서, 개념과 결과 질문의 CAD 하락은 주로 관련성 0점 답변 2개가 생긴 데서 비롯되었다.




[그림 5-3] 수치 질문 18개의 조건별 원점수 평행좌표




[그림 5-4] 방법 질문 25개의 조건별 원점수 평행좌표




[그림 5-5] 개념과 결과 질문 17개의 조건별 원점수 평행좌표

## 5.7 실제 답변에서 확인한 변화

점수가 크게 바뀐 질문을 원문 정답, 입력 구간, 생성 답변과 대조하면 점수 변화의 원인은 유형마다 달랐다. 이 절의 비교는 모두 같은 질문의 미적용 답변을 기준으로 한다.

RAPTOR는 문서 구간을 임베딩한 뒤 클러스터로 묶고 각 클러스터를 요약하여 트리를 만든다. 이 과정에서 BIC가 무엇을 정하는지 묻는 방법 질문에서 미적용의 입력 구간에는 최적 클러스터 수를 정한다는 문장이 없었고, 답변은 해당 정보를 확인할 수 없다고 하였다. HyDE

를 적용하자 이 문장이 입력 구간에 들어왔고, 답변은 BIC가 최적 클러스터 수를 정하는 데 쓰인다고 설명하였다. 답변 관련성은 0.000에서 0.895로, 문맥 재현율은 0.000에서 1.000으로 올랐다.

CAD 논문의 NQ-Swap 데이터셋이 어떻게 만들어졌는지 묻는 방법 질문에서는 미적용과 HyDE 모두 생성 절차가 담긴 원문 구간을 입력받았다. 미적용 답변은 절마다 설명을 요청하는 문장을 나열하여 관련성이 0.000이었고, HyDE 답변은 엔티티가 정답인 질문의 선택, 근거 문서 탐색, 정답 엔티티의 무작위 치환이라는 세 단계를 설명하여 0.785를 받았다. 같은 입력에서 CAD 답변은 CAD 논문의 α 설정 문단을 영어 그대로 옮겨 근거 충실도가 0.185에서 0.955로 올랐고, 답변 관련성은 0.395였다.

관련성 점수가 올라도 요구 정보가 빠진 답변이 있었다. Mi:dm 보고서의 지도 파인튜닝(Supervised Fine-Tuning, SFT) 가운데 Fusion SFT 단계에서 non-reasoning 데이터 비중을 늘린 목적을 묻는 질문의 정답은 대화 정렬이라는 목적과 창작, 번역, 일반 질의응답 데이터의 보강이며, 이 내용은 미적용과 HyDE의 입력 구간에 모두 있었다. HyDE 답변은 사전 학습 단계의 데이터 구성을 다룬 영어 원문을 이어 썼다. 이 답변에는 목적과 보강 과제가 빠졌지만 답변 관련성은 0.000에서 0.463으로 올랐다.

수치 질문에서는 정답 수치가 담긴 구간이 입력에 들어오는지가 결과를 갈랐다. RAPTOR 논문은 QuALITY 데이터셋의 한 이야기에서 트리의 맨 아래 계층만 검색한 경우와 세 계층을 모두 검색한 경우의 정확도를 비교한다. 이 두 정확도를 묻는 질문에서 미적용의 입력 구간과 답변에는 57.9와 73.68이 모두 있었다. HyDE를 적용하자 73.68이 담긴 구간이 입력에서 빠졌고, 답변은 비교 수치를 확인할 수 없다고 한 뒤 트리 검색의 일반적인 장점을 설명하였다. 답변 관련성은 0.871에서 0.000으로, 문맥 재현율은 1.000에서 0.000으로 내려갔다.

CAD로 근거 충실도가 오른 답변 가운데에는 다른 수치나 다른 내용을 옮긴 경우도 있었다. CAD 논문의 표에서 LLaMA-30B의 요약 데이터셋 XSUM(Extreme Summarization) 결과를 묻는 질문의 정답은 일반 디코딩과 CAD의 ROUGE-L(Recall-Oriented Understudy for Gisting Evaluation-Longest Common Subsequence, 요약 지표) 18.7과 22.0, factKB(사실 일치 지표) 47.7과 66.4, BERT-P(BERTScore 정밀도) 87.1과 90.3이다. 미적용과 CAD 답변은 모두 같은 표의 다른 행 값인 ROUGE-L 25.8과 31.8, factKB 87.8을 XSUM 결과로 제시하였다. CAD 답변에서 정답과 같은 값은 일반 디코딩의 factKB 47.7과 BERT-P 87.1뿐이었지만, 근거 충실도는 0.526에서 0.867로 올랐다. RAPTOR가 문서를 100토큰 단위로 나누는 규칙을 묻는 질문에서도 CAD 답변은 트리 구축 비용이 문서 길이에 선형으로 늘어난다는 다른 내용을 설명하였고, 근거 충실도는 0.250에서 1.000으로, 답변 관련성은 0.000에서 0.755로 올랐다. 근거 충실도는 답변의 주장이 입력 구간에 있는지를 평가하므로, 입력 구간의 다른 행이나 다른 문단을 옮긴 답변도 높은 점수를 받는다.

개념과 결과 질문에서는 CAD가 이미 정확했던 답변을 짧게 바꾼 경우가 있었다. RAG Survey에서 지식 집약 과제에 RAG가 주는 이점을 묻는 질문에서 미적용 답변은 실시간 지식 갱신과 외부 지식 활용을 원문 인용과 함께 정리하였다. 같은 입력 구간에서 CAD 답변은 '위 내용 참조'와 요청 문장 조각만 남겼고, 근거 충실도는 0.938에서 0.500으로, 답변 관련성은 0.900에서 0.000으로 내려갔다. 처리 시간도 22.556초에서 3.975초로 줄었다.

HyDE와 CAD를 함께 적용하면 HyDE 단독에서 얻은 설명이 사라진 경우도 있었다. RAG Survey에서 Naive RAG의 처리 과정을 묻는 질문에서 미적용, HyDE, HyDE+CAD의 세 조건은 모두 인덱싱, 검색, 생성의 세 단계를 담은 구간을 입력받았다. 미적용 답변은 파인튜닝과 프롬프트 엔지니어링을 비교한 영어 원문을 이어 쓴 뒤 다른 질문을 스스로 만들었고(관련성 0.747), HyDE 답변은 세 단계를 한국어로 설명하였다(관련성 0.929). HyDE+CAD 답변은 Modular RAG의 새 모듈을 묻는 질문을 만든 뒤 그 내용을 설명하여 관련성이 0.000이 되었다.

SCD를 적용한 뒤에도 한국어 문자 비율이 낮은 답변은 영어 원문을 이어 쓴 경우였다. RAG Survey에서 큰 청크와 작은 청크의 장단점을 묻는 질문에서 미적용 답변은 참고문헌 목록을 이어 쓴 뒤 RAG의 세 구성 요소를 한국어로 설명하였고, SCD 답변은 영어 참고문헌만 이어 써 비율이 0.425에서 0.000으로 내려갔다. 두 답변 모두 질문한 장단점 대신 다른 내용을 담았다. 부록 B에는 이 절에서 다룬 질문의 정답 근거와 답변 발췌를 정리하였다.

### 5.8 질문 유형에 따른 기법 선택

질문 유형별 결과를 정리하면 유형마다 적합한 기법이 달랐다. 방법 질문에는 HyDE가 가장 효과적이었다. 답변 관련성이 0.575에서 0.745로, 문맥 재현율이 0.880에서 0.960으로 올랐고, 관련성 0점이던 질문 5개 가운데 3개는 질문에 필요한 정보를 담은 설명으로 바뀌었다.

수치 질문에서 HyDE의 답변 관련성은 미적용의 0.743과 비슷한 0.740이었고 문맥 정밀도와 재현율은 낮아졌다. 근거 충실도는 SCD를 적용하지 않은 CAD와 HyDE+CAD, SCD를 적용한 HyDE+CAD+SCD에서 0.896에서 0.927 사이였지만, 세 조건의 처리 시간은 55.410초에서 60.591초 사이로 미적용(14.648초)의 약 네 배였고, 다른 행의 수치를 옮긴 답변도 높은 충실도를 받았다. 수치 질문의 답변 품질은 정답 수치가 담긴 구간이 입력에 들어오는지와 답변이 그 값을 정확히 옮기는지에 달려 있었다.

개념과 결과 질문은 미적용에서 이미 점수가 높았고, HyDE가 답변 관련성과 근거 충실도를 더 높였다. CAD는 이 유형에서 두 지표를 모두 낮추었으므로, 개념과 결과 질문에는 미적용이나 HyDE가 적합하다. SCD는 세 유형 모두에서 한국어 문자 비율을 높였으므로 한국어 답변이 필요할 때 유형과 관계없이 더할 수 있다.

질문 60개 평균에서 두 기법 이상을 조합한 네 조건의 답변 관련성은 모두 HyDE 단독보다 낮았고, HyDE에 CAD를 더하면 관련성이 내린 질문(18개)이 오른 질문(5개)보다 많았다. 따라서 적용할 기법은 우선하는 지표에 따라 정해야 한다. 답변 관련성은 HyDE 단독이 0.763으로 가장 높았고, 처리 시간은 미적용보다 6.877초 늘었지만 CAD를 포함한 조건보다 짧았다. 답변 관련성을 우선하면 HyDE 하나가 적합하다. 수치 질문에서 근거 충실도가 중요하면 HyDE+CAD가 적합하다. HyDE+CAD는 네 품질 지표를 모두 미적용 이상으로 유지하며 근거 충실도를 0.826에서 0.927로 높였지만, 한국어 문자 비율은 0.585에서 0.520으로 낮아졌다. 한국어 답변이 필요하면 HyDE+SCD가 적합하다. HyDE+SCD는 세 유형 모두에서 한국어 문자 비율이 가장 높았고, 답변 관련성도 HyDE+CAD+SCD보다 높았다. HyDE+SCD에 CAD를 더해 세 기법을 모두 적용하면 수치 질문에서 근거 충실도가 0.844에서 0.927로 올랐지만 처리 시간도 약 2.5배가 되었으므로, 세 기법 조합은 한국어 답변에서 수치 질문의 근거 충실도를 처리 시간보다 우선할 때 고르는 구성이다.

# 6. 결론

이 장은 연구 질문별 결과, 연구의 의의와 적용 조건, 후속 연구를 정리한다.

## 6.1 연구 질문별 결과

영어 문서 네 종의 질문 60개에서 얻은 세 연구 질문의 답은 다음과 같다.

RQ1. 답변 관련성은 HyDE(0.763), 한국어 문자 비율은 HyDE+SCD(0.807)가 가장 높았고, 근거 충실도는 HyDE+CAD(0.860)가 SCD 미적용 조건에서, HyDE+CAD+SCD(0.831)가 적용 조건에서 가장 높았다. 두 기법 이상을 조합한 네 조건의 답변 관련성은 모두 HyDE 단독보다 낮았고, 조합이 일관되게 높인 지표는 SCD를 포함할 때의 한국어 문자 비율이었다. CAD를 포함한 조건의 처리 시간은 포함하지 않은 조건의 약 세 배였다(표 5-1).

RQ2. HyDE는 방법 질문의 답변 관련성을 0.575에서 0.745로, 문맥 재현율을 0.880에서 0.960으로 높였고, 수치 질문의 관련성은 미적용과 비슷하였다. CAD는 수치 질문과 방법 질문에서 근거 충실도의 평균을 높였지만 오른 질문과 내린 질문의 수는 비슷하였고, 개념과 결과 질문의 충실도와 관련성은 낮추었다. SCD는 세 유형 모두에서 한국어 문자 비율을 높였고, 이 비율은 유형마다 HyDE+SCD에서 가장 높았다(표 5-2).

RQ3. 방법 질문에서 크게 오른 답변은 HyDE로 필요한 구간을 찾거나 같은 구간을 질문에 맞게 설명한 경우였고, 관련성이 양수로 바뀐 다섯 답변 중 둘에는 요구 정보가 없었다. 수치 질문의 큰 하락은 정답 수치가 담긴 구간이 입력에서 빠진 경우였고, CAD로 근거 충실도가 높아진 답변 가운데에는 다른 행이나 다른 문단을 옮긴 경우도 있었다. 개념과 결과 질문에서는 CAD가 정확한 설명을 '위 내용 참조' 같은 짧은 문장으로 바꾼 경우가 있었다(5.7절).

## 6.2 연구의 의의와 적용 조건

이 연구는 같은 기법도 질문 유형에 따라 이득과 손실이 달라짐을 보였다.

답변 관련성을 우선하면 HyDE 하나를 적용하고, 개념과 결과 질문에도 HyDE가 적합하다. 수치 질문에서는 정답 수치가 담긴 구간이 검색되는지를 확인하고, 근거 충실도를 우선하면 HyDE에 CAD를 더한다. 한국어 답변이 필요하면 HyDE에 SCD를 더한다. 여기에 CAD까지 더한 세 기법 조합은 HyDE+SCD보다 답변 관련성과 한국어 문자 비율이 낮고 처리 시간이 약 2.7배이므로, 수치 질문의 근거 충실도를 처리 시간보다 우선할 때 고른다.

## 6.3 후속 연구

후속 연구는 다음과 같다. 첫째, 허위 전제나 지식 충돌을 담은 질문을 추가하여 CAD의 효과를 문서 내용을 묻는 질문과 비교한다. 둘째, 수치 질문에서 정답 수치가 담긴 구간이 검색되었는지와 답변이 그 값을 정확히 옮겼는지를 함께 평가한다. 셋째, 같은 질문의 생성과 평가를 반복하여 질문별 점수의 변동을 측정한다. 넷째, 번역만 적용한 조건을 추가하여 HyDE의 효과를 번역과 가상 문서 생성으로 나눈다. 다섯째, 모든 조건을 같은 언어의 검색 결과로 다시 평가하여 SCD가 근거 충실도와 검색 지표에 주는 영향을 확인한다. 여섯째, 다른 생성 모델과 새 질문으로 같은 비교를 반복하고, 사람의 정답 판정을 RAGAS 점수와 비교한다.

# 참고문헌


[1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Advances in Neural Information Processing Systems, Vol. 33, pp. 9459-9474, 2020.

[2] L. Gao et al., “Precise Zero-Shot Dense Retrieval without Relevance Labels,” Proceedings of ACL, pp. 1762-1777, 2023, doi: 10.18653/v1/2023.acl-long.99.

[3] W. Shi et al., “Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding,” Proceedings of NAACL, pp. 783-791, 2024, doi: 10.18653/v1/2024.naacl-short.69.

[4] B. Li, Z. Xu, and R. Xie, “Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation,” Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519-31526, 2026, doi: 10.1609/aaai.v40i37.40417.

[5] J. Chen et al., “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318-2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson, S. Walker, S. Jones, M. M. Hancock-Beaulieu, and M. Gatford, “Okapi at TREC-3,” Proceedings of the Third Text REtrieval Conference (TREC-3), NIST Special Publication 500-225, pp. 109-126, 1995 (conference 1994).

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” Proceedings of SIGIR, pp. 758-759, 2009, doi: 10.1145/1571941.1572114.

[8] S. MacAvaney, A. Yates, A. Cohan, and N. Goharian, “CEDR: Contextualized Embeddings for Document Ranking,” Proceedings of SIGIR, pp. 1101-1104, 2019, doi: 10.1145/3331184.3331317.

[9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157-173, 2024, doi: 10.1162/tacl_a_00638.

[10] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented

Generation," Proceedings of EACL System Demonstrations, pp. 150-158, 2024, doi: 10.18653/v1/2024.eacl-demo.16.

[11] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proceedings of EMNLP, pp. 6769-6781, 2020, doi: 10.18653/v1/2020.emnlp-main.550.

[12] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proceedings of EACL, pp. 874-880, 2021, doi: 10.18653/v1/2021.eacl-main.74.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286-12312, 2023, doi: 10.18653/v1/2023.acl-long.687.

[14] P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S. Jeong, J. Baek, S. Cho, S. J. Hwang, and J. Park, "Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity," Proceedings of NAACL, pp. 7036-7050, 2024, doi: 10.18653/v1/2024.naacl-long.389.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, No. 1, pp. 1-29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] W. Fan et al., "A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models," Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 6491-6501, 2024, doi: 10.1145/3637528.3671470.

[19] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[20] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EACL, pp. 2014-2037, 2023, doi: 10.18653/v1/2023.eacl-main.148.

[21] P. Dasigi, K. Lo, I. Beltagy, A. Cohan, N. A. Smith, and M. Gardner, “A Dataset of Information-Seeking Questions and Answers Anchored in Research Papers,” Proceedings of NAACL, pp. 4599-4610, 2021, doi: 10.18653/v1/2021.naacl-main.365.

[22] M. A. Sultan, J. Ganhotra, and R. F. Astudillo, “Structured Chain-of-Thought Prompting for Few-Shot Generation of Content-Grounded QA Conversations,” Findings of EMNLP, pp. 16172-16187, 2024, doi: 10.18653/v1/2024.findings-emnlp.948.

실험 사용 모델 및 원문 자료 출처

학술 참고문헌 [1]~[22]와 별도로 구현에 사용한 모델 카드[M1][M2]와 검색 대상 문서 [D1]~[D4]의 출처를 정리하였다.

[M1] K-intelligence/Midm-2.0-Base-Instruct 공식 모델 카드(KT), https://huggingface.co/K-intelligence/Midm-2.0-Base-Instruct (접근일 2026-10-17).

[M2] MiniLM CrossEncoder 재정렬 모델의 공식 모델 카드, https://huggingface.co/cross-encoder/ms-marco-MiniLM-L6-v2 (접근일 2026-10-17). 원래 질의와 후보 구간의 쌍을 입력하는 CrossEncoder 재정렬에 사용하였다(구현 설정의 표기는 cross-encoder/ms-marco-MiniLM-L-6-v2).

[D1] Y. Gao et al., “Retrieval-Augmented Generation for Large Language Models: A Survey,” arXiv:2312.10997, https://arxiv.org/abs/2312.10997 (접근일 2026-10-20). 실험 원문 파일은 paper_nlp_rag.pdf이다.

[D2] W. Shi et al., CAD 논문[3]. 실험 원문 파일은 paper_nlp_cad.pdf이다.

[D3] P. Sarthi et al., RAPTOR 논문[14]. 실험 원문 파일은 paper_nlp_raptor.pdf이다.

[D4] KT Tech Innovation Group, “Mi:dm K 2.5 Pro,” 기업 기술보고서, arXiv:2603.18788v2, 2026, https://arxiv.org/abs/2603.18788v2 (접근일 2026-10-20). 실험 원문 파일은 paper_midm.pdf이다.

질문별 원문 페이지와 정답 근거는 부록 A에 제시하였다.

그림 자료 이용 정보

그림 2-1~2-4는 아래 문헌의 구조를 바탕으로 본 연구에서 작성하였으며, 각 항목 아래에 참고 자료의 주소를 적었다.

그림 2-1 — Lewis 외[1]의 RAG 구조

https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf (접근일 2026-10-20)

그림 2-2 — Gao 외[2]의 HyDE 구조

https://aclanthology.org/2023.acl-long.99/ (접근일 2026-10-20)

그림 2-3 — Shi 외[3]의 CAD 로짓 결합

https://aclanthology.org/2024.naacl-short.69/ (접근일 2026-10-20)

그림 2-4 — Li 외[4]의 SCD 토큰별 점수 조정

https://ojs.aaai.org/index.php/AAAI/article/view/40417 (접근일 2026-10-20)

# 부록 A. 60개 질문과 정답 근거

표 A-1은 각 질문의 대상 문서와 유형, 원문 페이지, 정답 근거를 정리한 것이다. 유형은 5.1절의 수치, 방법, 개념과 결과 질문이며, 질문 ID는 저장된 생성 기록과 평가 기록을 연결하는 식별자다.

[표 A-1] 60개 질문의 대상 문서, 유형과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| ext_cad_001 | 언어 모델이 생성 시 활용하는 prior knowledge와 context knowledge는 각각 어디에서 오는 정보입니까? | CAD | 개념과 결과 | 1 | the context contains external knowledge; prior knowledge is encoded in the model parameters |
| ext_cad_002 | CAD의 요약 실험에는 어떤 데이터셋과 평가 지표가 사용되었습니까? | CAD | 방법 | 3 | CNN–DM and XSUM; ROUGE-L, BERT-Precision, and FactKB |
| ext_cad_003 | CAD의 지식 충돌 실험에는 어떤 두 데이터셋이 사용되었고 각각 무엇을 평가합니까? | CAD | 방법 | 3 | MemoTrap investigates memorization traps; NQ-Swap tests faithful answering from a modified reliable document. |
| ext_cad_004 | NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까? | CAD | 방법 | 3 | identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity |
| ext_cad_005 | CAD 실험에서 요약 과제와 지식 충돌 과제에 사용한 α 값은 각각 얼마이며, 지식 충돌 과제에서 더 큰 값을 사용한 이유는 무엇입니까? | CAD | 수치 | 3 | α = 0.5 for summarization and α = 1 for knowledge conflicts, where prior knowledge needs to be factored out more |

[계속표 A-1 (2/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| ext_cad_006 | CAD 논문의 베이스라인 디코딩은 요약 과제와 지식 충돌 과제에서 각각 어떤 샘플링 전략을 사용합니까? | CAD | 방법 | 3 | greedy decoding for knowledge conflict tasks and top-p sampling with p=0.9 for summarization tasks |
| ext_cad_007 | CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까? | CAD | 방법 | 3 | OPT, GPT-Neo, LLaMA, and FLAN-T5 |
| ext_cad_008 | 지식 충돌 과제에서 모델 크기가 커질수록 CAD의 성능 향상 폭은 어떤 경향을 보였습니까? | CAD | 개념과 결과 | 5 | the gain increases as the model size grows |
| ext_cad_009 | LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까? | CAD | 수치 | 4 | Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3 |
| ext_cad_010 | 외부 컨텍스트가 생성 토큰과 조건부 독립이라면 α가 0이 아니어도 CAD의 출력 분포에는 어떤 영향이 있습니까? | CAD | 개념과 결과 | 2 | even a non-zero α would not have an impact to the original output distribution |
| ext_cad_011 | CAD는 특정 instruction-finetuned 언어 모델에만 제한됩니까, 아니면 어떤 언어 모델에도 적용 가능한 디코딩 전략입니까? | CAD | 개념과 결과 | 6 | a decoding strategy applicable to any LM |
| ext_midm_001 | Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까? | Mi:dm | 방법 | 3 | licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data |
| ext_midm_002 | Mi:dm K 2.5 Pro는 한국어 중심 학습을 유지하기 위해 다국어 데이터를 한국어 코퍼스 대비 어느 정도 비율로 제한하며, 그 이유는 무엇입니까? | Mi:dm | 수치 | 3 | 3-10% of the Korean corpus, to encourage cross-lingual transfer without diluting the Korean-language focus |

[계속표 A-1 (3/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| ext_midm_003 | 응답 스타일 재작성 후 평균 응답 길이는 몇 % 증가했고, bullet_count=0인 응답의 비율은 어떻게 변했습니까? | Mi:dm | 수치 | 8 | mean response length increases by 256.70%; bullet_count = 0 drops from 82.8% to 3.9% |
| ext_midm_004 | Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까? | Mi:dm | 방법 | 15 | interaction structure, topic and task, and persona |
| ext_midm_005 | Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까? | Mi:dm | 방법 | 21 | to favor versatile conversational alignment; creative writing, translation, and general question answering |
| ext_midm_006 | Fully asynchronous GSPO 학습은 synchronous 방식과 비교해 step time과 token throughput을 각각 어느 정도 개선했습니까? | Mi:dm | 수치 | 23 | reduces step time by approximately 15% and improves token throughput by approximately 30% |
| ext_midm_007 | LLM-as-a-Judge 기반 reward signal은 사람의 평가와 어느 정도의 일치율을 보였습니까? | Mi:dm | 수치 | 24 | an agreement rate of 91% |
| ext_midm_008 | Reasoning-enabled 평가에서 Mi:dm K 2.5 Pro가 HumanEval+와 τ²-Bench Telecom에서 기록한 점수는 각각 얼마입니까? | Mi:dm | 수치 | 25 | HumanEval+ 92.07% and τ²-Bench Telecom 89% |
| ext_midm_009 | 한국어 red-teaming 평가에서 Mi:dm K 2.5 Pro의 Attack Success Rate는 얼마였으며 비교 모델들 가운데 어떤 수준이었습니까? | Mi:dm | 수치 | 31 | ASR of 36.3%, the lowest attack success rate among the compared models |
| ext_rag_001 | Advanced RAG의 pre-retrieval 단계는 인덱스와 사용자 질의를 각각 어떤 방향으로 최적화합니까? | RAG Survey | 방법 | 4 | optimizing the indexing structure and the original query |

[계속표 A-1 (4/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| ext_rag_002 | Advanced RAG의 post-retrieval 단계에서 사용되는 두 가지 핵심 방법은 무엇입니까? | RAG Survey | 방법 | 4 | rerank chunks and context compressing |
| ext_rag_003 | RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까? | RAG Survey | 방법 | 8 | Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise. |
| ext_rag_004 | 문서 청크에 타임스탬프 같은 메타데이터를 부여하면 time-aware RAG는 최신 정보를 어떻게 우선할 수 있습니까? | RAG Survey | 방법 | 8 | Assigning different weights to document timestamps during retrieval can achieve time-aware RAG, ensuring the freshness of knowledge and avoiding outdated information. |
| ext_rag_005 | Reverse HyDE는 문서로부터 가상의 질문을 생성해 원래 질문과 답변 사이의 의미적 간극을 어떻게 줄입니까? | RAG Survey | 방법 | 8 | using LLM to generate questions that can be answered by the document, then calculating the similarity between the original question and the hypothetical question |
| ext_rag_006 | Multi-Query와 Sub-Query 방식은 원래 질의를 확장하거나 분해하는 방식에서 어떻게 다릅니까? | RAG Survey | 방법 | 8 | Multi-Query expands queries via LLMs for parallel execution; Sub-Query decomposes a complex question into simpler sub-questions. |

[계속표 A-1 (5/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| ext_rag_007 | Iterative Retrieval, Recursive Retrieval, Adaptive Retrieval은 검색을 반복하거나 중단하는 방식에서 각각 어떻게 구분됩니까? | RAG Survey | 방법 | 11 | Iterative retrieval alternates retrieval and generation; recursive retrieval refines queries and breaks problems into sub-problems; adaptive retrieval determines whether retrieval is necessary and when to stop. |
| ext_rag_008 | RAG 평가에서 요구되는 네 가지 핵심 능력은 무엇입니까? | RAG Survey | 방법 | 12 | noise robustness, negative rejection, information integration, and counterfactual robustness |
| ext_rag_009 | RAG 평가에서 Negative Rejection은 어떤 능력을 측정합니까? | RAG Survey | 개념과 결과 | 12 | refraining from responding when the retrieved documents do not contain the necessary knowledge to answer a question |
| ext_rag_010 | RAG와 파인튜닝을 비교할 때 지식 업데이트의 동적 특성과 해석 가능성 측면에서 RAG가 갖는 특징은 무엇입니까? | RAG Survey | 개념과 결과 | 5 | real-time knowledge updates and effective utilization of external knowledge sources with high interpretability |
| ext_raptor_001 | RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까? | RAPTOR | 수치 | 3 | length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk |
| ext_raptor_002 | RAPTOR의 leaf node를 만들 때 텍스트 임베딩에 사용한 모델은 무엇입니까? | RAPTOR | 방법 | 3 | SBERT, a BERT-based encoder (multi-qa-mpnet-base-cos-v1) |
| ext_raptor_003 | RAPTOR의 GMM 클러스터링 전에 UMAP을 사용하는 이유는 무엇입니까? | RAPTOR | 방법 | 4 | to mitigate the challenge of high-dimensional vector embeddings by dimensionality reduction |

[계속표 A-1 (6/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| ext_raptor_004 | RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까? | RAPTOR | 방법 | 4 | to determine the optimal number of clusters |
| ext_raptor_005 | RAPTOR에서 클러스터별 요약을 생성하는 데 사용한 언어 모델은 무엇입니까? | RAPTOR | 방법 | 4 | gpt-3.5-turbo |
| ext_raptor_006 | RAPTOR의 트리 구축 비용은 문서 길이가 증가할 때 build time과 token expenditure 측면에서 어떻게 확장됩니까? | RAPTOR | 개념과 결과 | 16 | both build time and token expenditure scale linearly with document length |
| ext_raptor_007 | QASPER 데이터셋은 몇 개의 질문과 NLP 논문으로 구성되며, 논문에서는 어떤 지표로 성능을 평가합니까? | RAPTOR | 수치 | 6 | 5,049 questions across 1,585 NLP papers; accuracy is measured using standard F1 |
| ext_raptor_008 | QuALITY-HARD는 일반 QuALITY 질문 중 어떤 기준을 만족하는 질문들로 구성됩니까? | RAPTOR | 개념과 결과 | 6 | questions that a majority of human annotators answered incorrectly in a speed-setting |
| ext_raptor_009 | QASPER에서 RAPTOR의 F1 Match 점수는 GPT-3, GPT-4, UnifiedQA를 사용할 때 각각 얼마였습니까? | RAPTOR | 수치 | 7 | 53.1%, 55.7%, and 36.6%, respectively |
| ext_raptor_010 | QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까? | RAPTOR | 수치 | 9 | 57.9 with one leaf layer versus 73.68 with all three layers |
| ext_raptor_011 | Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까? | RAPTOR | 개념과 결과 | 20 | RAPTOR retrieves relevant information across tree layers, while DPR retrieves detailed descriptions of a narrow subset of the story |

[계속표 A-1 (7/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| track1_0009 | RAG가 LLM에서 사실적으로 부정확한 콘텐츠 생성을 줄이는 데 어떻게 기여합니까? | RAG Survey | 개념과 결과 | 1 | By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content. |
| track1_0010 | RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까? | RAG Survey | 방법 | 3 | The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework. |
| track1_0012 | RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까? | RAG Survey | 개념과 결과 | 1 | This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information. |
| track1_0015 | RAG 프로세스에서 핵심적인 역할을 하는 세 가지 구성 기술은 무엇인가요? | RAG Survey | 개념과 결과 | 2 | the aspects of Retrieval, Generation and Augmentation |
| track1_0016 | RAG 방법론의 평가 방법은 어떻게 요약되어 있습니까? | RAG Survey | 방법 | 2 | We have summarized the current assessment methods of RAG, covering 26 tasks, nearly 50 datasets, outlining the evaluation objectives and metrics, as well as the current evaluation benchmarks and tools. |

[계속표 A-1 (8/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| track1_0019 | LLaMA-30B 모델에 CAD를 적용했을 때 CNN-DM 데이터셋에서 어떤 성과가 있었나요? | CAD | 수치 | 3 | Specifically, when applied to LLAMA-30B in CNN-DM, CAD leads to 21% increase in ROUGE-L, 14.3% increase in factKB and 7.8% increase in BERT-P. |
| track1_0021 | CAD는 어떻게 잘못된 정보 생성을 줄이나요? | CAD | 개념과 결과 | 2 | These results demonstrate the potential of CAD in mitigating hallucinations in text generation and overriding prior knowledge with reliable and trusted information. |
| track1_0023 | CAD는 언어 모델이 생성하는 요약문의 사실적 정확성을 향상시키나요? | CAD | 개념과 결과 | 1 | Experimental results from summarization tasks show that context-aware decoding significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs such as FLAN (Chung et al., 2022). |
| track1_0024 | CAD를 적용하지 않은 경우와 비교했을 때, knowledge conflict QA 데이터셋에서 LLaMA-30B의 성능은 어떻게 변화하나요? | CAD | 수치 | 2 | CAD brings a 2.9x improvement to LLaMA-30B on a knowledge conflicts QA dataset (Longpre et al., 2021). |

[계속표 A-1 (9/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| track1_0025 | RAPTOR 모델이 QuALITY 벤치마크에서 기존 성능을 얼마나 개선했나요? | RAPTOR | 수치 | 1 | we can improve the best performance on the QuALITY benchmark by 20% in absolute accuracy. |
| track1_0026 | RAPTOR의 트리 구조는 텍스트 클러스터링을 통해 어떻게 구축되나요? | RAPTOR | 방법 | 2 | RAPTOR recursively clusters chunks of text based on their vector embeddings and generates text summaries of those clusters, constructing a tree from the bottom up. |
| track1_0027 | RAPTOR가 여러 QA 작업에서 달성한 결과는 무엇인가요? | RAPTOR | 개념과 결과 | 2 | RAPTOR coupled with GPT-4, and sometimes even with UnifiedQA, gives new state-of-the-art results on three QA tasks: free text response questions on books and movies (NarrativeQA, Ko˘cisk`y et al. 2018), full-text NLP papers (QASPER, Dasigi et al. 2021), and multiple-choice questions based on medium-length passages (QuALITY, Pang et al. 2022). |
| track1_0032 | RAPTOR의 계층에서 검색된 노드가 어느 계층에서 오는지에 대한 연구 결과는 무엇인가요? | RAPTOR | 수치 | 22 | We observe that between 18.5% to 57% of the retrieved nodes come from non-leaf nodes. |
| track1_0033 | Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까? | Mi:dm | 수치 | 2 | 32B parameters |
| track1_0034 | Mi:dm K 2.5 Pro의 방법론에서 AST 분석은 어떤 목적으로 사용됩니까? | Mi:dm | 방법 | 1 | abstract syntax tree (AST) analysis for code |

[계속표 A-1 (10/10)] 60개 질문과 정답 근거

| 질문 ID | 한국어 질문 | 문서 | 유형 | 쪽 | 정답 근거 구간 |
|---|---|---|---|---|---|
| track1_0035 | Mi:dm K 2.5 Pro 모델은 어떤 한국어 벤치마크에서 최첨단 결과를 달성했습니까? | Mi:dm | 개념과 결과 | 1 | sets state-of-the-art results on Korean-specific benchmarks |
| track1_0036 | Mi:dm K 2.5 Pro가 해결하려는 주요 문제는 무엇입니까? | Mi:dm | 개념과 결과 | 1 | address enterprise-grade complexity through reasoning-focused optimization |
| track1_0037 | Mi:dm K 2.5 Pro 모델의 컨텍스트 윈도우(context window) 길이는 얼마인가요? | Mi:dm | 수치 | 1 | 128K token context window |
| track1_0040 | Mi:dm K 2.5 Pro의 사후 훈련 파이프라인에서 모델 병합은 어떤 역할을 합니까? | Mi:dm | 방법 | 2 | improve training stability and achieve balanced performance across complex reasoning, coding, instruction following, and agentic task execution |

# 부록 B. 질문별 검색 근거와 실제 답변

5.7절에서 다룬 질문의 원문과 정답 근거, 비교한 두 답변의 발췌와 점수를 정리하였다. 모든 비교의 기준은 같은 질문의 미적용 답변이다.

## B.1 RAPTOR에서 BIC가 결정하는 항목

질문은 'RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?'이고, 정답 근거는 RAPTOR 원문 4쪽의 'to determine the optimal number of clusters'이다. 이 질문은 방법 질문에 속한다.

미적용과 HyDE 조건을 비교하였다. 미적용의 입력 구간에는 최적 클러스터 수를 정한다는 문장이 없었고, 답변은 해당 정보를 확인할 수 없다고 하였다. HyDE를 적용하자 이 문장이 입력 구간에 들어왔고, 답변은 BIC가 최적 클러스터 수를 정하는 데 쓰인다고 설명하였다.

미적용 답변 발췌는 '제공된 논문 컨텍스트를 면밀히 검토한 결과, RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)이 어떤 결정을 내리는 데 사용되는지에 관한 구체적인 정보는 확인할 수 없습니다.'이고, HyDE 답변 발췌는 '제공된 논문 컨텍스트를 분석한 결과, RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 최적의 클러스터 개수 결정을 위해 사용됨이 확인됩니다.'이다.

답변 관련성은 0.000에서 0.895로, 문맥 재현율은 0.000에서 1.000으로 바뀌었다. SCD와 HyDE+SCD를 비교해도 같은 문장이 입력 구간에 새로 들어왔고, 답변 관련성은 0.000에서 0.895로 올랐다.

## B.2 NQ-Swap 데이터셋의 생성 절차

질문은 'NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?'이고, 정답 근거는 CAD 원문 3쪽의 'identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity'이다. 이 질문은 방법 질문에 속한다.

미적용과 HyDE 조건을 비교하였다. 두 조건 모두 생성 절차를 설명한 원문 구간을 입력받았다. 미적용 답변은 CAD 수식 문장을 이어 쓴 뒤 절마다 설명을 요청하는 문장을 나열하였고, HyDE 답변은 엔티티가 정답인 질문의 선택, 근거 문서 탐색, 정답 엔티티의 무작위 치환이라는 세 단계를 제시하였다.

미적용 답변 발췌는 '2.1 Background 섹션에서 CAD의 개발 배경과 해결하고자 하는 문제를 구체적으로 설명해주세요.'이고, HyDE 답변 발췌는 '1. 원본 데이터 식별: 먼저 NQ 데이터셋에서 개체명(named entity) 답변을 포함하는 질문들을 식별합니다.', '3. 정답 교체: 원본 문서에서 발견된 정답 개체(entity)를 무작위로 선택된 다른 개체로 대체합니다.'이다.

답변 관련성은 0.000에서 0.785로, 근거 충실도는 0.185에서 0.809로 바뀌었다. 같은 입력 구간에서 CAD 답변은 CAD 논문의 α 설정 문단을 영어로 그대로 옮겼다. 근거 충실도는 0.185에서 0.955로 올랐고 답변 관련성은 0.395였다.

### B.3 Fusion SFT의 non-reasoning 비중 확대 목적

질문은 'Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?'이고, 정답 근거는 Mi:dm K 2.5 Pro Technical Report 원문 21쪽의 'to favor versatile conversational alignment; creative writing, translation, and general question answering'이다. 이 질문은 방법 질문에 속한다.

미적용과 HyDE 조건을 비교하였다. 두 조건의 입력 구간에는 대화 정렬이라는 목적과 창작, 번역, 일반 질의응답이라는 보강 과제가 모두 있었다. 미적용 답변은 설명을 요청하는 문장 뒤에 단계별 성능 표를 나열하였고, HyDE 답변은 사전 학습 단계의 데이터 구성을 다룬 영어 원문을 이어 썼다. 목적과 보강 과제는 두 답변 모두에서 빠졌다.

미적용 답변 발췌는 '표 10: 단계별 성능 변화 - 추론 중심 후훈련'이고, HyDE 답변 발췌는 'In CPT stage 2, we increase the proportion of STEM data relative to the previous stage in order to further enhance overall performance and strengthen reasoning capability.'이다.

답변 관련성은 0.000에서 0.463으로, 한국어 문자 비율은 0.609에서 0.000으로 바뀌었다.

### B.4 QuALITY의 계층별 검색 성능 비교

질문은 'QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?'이고, 정답 근거는 RAPTOR 원문 9쪽의 '57.9 with one leaf layer versus 73.68 with all three layers'이다. 이 질문은 수치 질문에 속한다.

미적용과 HyDE 조건을 비교하였다. 미적용의 입력 구간과 답변에는 한 계층의 57.9와 세 계층의 73.68이 모두 있었다. HyDE를 적용하자 73.68이 담긴 구간이 입력에서 빠졌고, 답변은 직접 비교할 수치를 확인할 수 없다고 한 뒤 트리 검색의 일반적인 장점을 설명하였다.

미적용 답변 발췌는 '- 성능 점수: 57.9%', '- 성능 점수: 73.68%'이고, HyDE 답변 발췌는 '제공된 논문 컨텍스트를 검토한 결과, QuALITY 데이터셋의 특정 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때와 leaf node 한 계층만 검색했을 때의 성능 차이에 대한 직접적인 비교 데이터는 확인할 수 없습니다.'이다.

답변 관련성은 0.871에서 0.000으로, 문맥 재현율은 1.000에서 0.000으로, 근거 충실도는 1.000에서 0.929로 바뀌었다. SCD와 HyDE+SCD를 비교해도 같은 구간이 빠졌고, 답변 관련성은 0.768에서 0.000으로 내려갔다.

### B.5 LLaMA-30B의 XSUM 세 지표 비교

질문은 'LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?'이고, 정답 근거는 CAD 원문 4쪽의 'Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3'이다. 이 질문은 수치 질문에 속한다.

미적용과 CAD 조건을 비교하였다. 두 조건의 입력 구간은 같았고, 정답 수치인 ROUGE-L 18.7과 22.0, factKB 47.7과 66.4, BERT-P 87.1과 90.3이 들어 있었다. 두 답변은 모두 같

은 표의 다른 행 값인 ROUGE-L 25.8과 31.8, factKB 87.8을 XSUM 결과로 제시하였다. CAD 답변은 일반 디코딩의 factKB 47.7과 BERT-P 87.1은 정답대로 옮겼지만, CAD 적용 값은 factKB 87.8, BERT-P 92.2로 정답과 달랐다.

미적용 답변 발췌는 '- Regular decoding: 25.8점', '- CAD 적용 시: 87.8점'이고, CAD 답변 발췌는 '- Regular Decoding: ROUGE-L 25.8점, factKB 47.7점, BERT-P 87.1점', '- CAD 적용 시: ROUGE-L 31.8점, factKB 87.8점, BERT-P 92.2점'이다.

근거 충실도는 0.526에서 0.867로, 답변 관련성은 0.809에서 0.798로 바뀌었다.

### B.6 RAPTOR 청크 길이와 문장 경계 처리

질문은 'RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?'이고, 정답 근거는 RAPTOR 원문 3쪽의 'length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk'이다. 이 질문은 수치 질문에 속한다.

미적용과 CAD 조건을 비교하였다. 두 조건의 입력 구간은 같았고, 100토큰 청크와 한계를 넘는 문장을 다음 청크로 옮기는 규칙이 들어 있었다. 미적용 답변은 문서 길이와 성능을 묻는 문장을 반복하였고, CAD 답변은 트리 구축 비용이 문서 길이에 선형으로 늘어난다는 다른 내용을 설명하였다.

미적용 답변 발췌는 '문서 길이와 관련하여 어떤 성능 특성을 보이는지 설명해주세요'이고, CAD 답변 발췌는 'RAPTOR는 빌드 시간(build time)이 초기 문서 길이와 선형적인 관계를 보입니다. Figure 6에 제시된 실험 결과에 따르면, 최대 80,000 토큰에 이르는 문서들에 대해 RAPTOR 나무 구조(tree construction) 건설 시간이 문서 길이에'이다.

근거 충실도는 0.250에서 1.000으로, 답변 관련성은 0.000에서 0.755로 바뀌었다.

### B.7 지식 집약 과제에서 RAG의 이점

질문은 'RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?'이고, 정답 근거는 RAG Survey 원문 1쪽의 'This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.'이다. 이 질문은 개념과 결과 질문에 속한다.

미적용과 CAD 조건을 비교하였다. 두 조건의 입력 구간은 같았다. 미적용 답변은 실시간 지식 갱신과 외부 지식 활용을 원문 인용과 함께 정리하였고, CAD 답변은 '위 내용 참조'와 요청 문장 조각만 남겼다.

미적용 답변 발췌는 '는 "RAG excels in dynamic environments by offering realtime knowledge updates and effective utilization of external knowledge sources with high interpretability"라고 명시하고 있습니다. RAG는 실시간 지식 업데이트를 제공하며 외부'이고, CAD 답변 발췌는 '위 내용 참조'이다.

답변 관련성은 0.900에서 0.000으로, 근거 충실도는 0.938에서 0.500으로 바뀌었다.

### B.8 Naive RAG의 처리 과정

질문은 ‘RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?’이고, 정답 근거는 RAG Survey 원문 3쪽의 ‘The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework.’이다. 이 질문은 방법 질문에 속한다.

미적용과 HyDE+CAD 조건을 비교하였다. 미적용, HyDE, HyDE+CAD의 세 조건은 모두 인덱싱, 검색, 생성의 세 단계를 담은 구간을 입력받았다. 미적용 답변은 파인튜닝과 프롬프트 엔지니어링을 비교한 영어 원문을 이어 쓴 뒤 세 가지 패러다임을 묻는 질문을 스스로 만들었다. HyDE 답변은 세 단계를 한국어로 설명하였고, HyDE+CAD 답변은 Modular RAG의 새 모듈을 묻는 질문을 만든 뒤 그 내용을 설명하였다.

미적용 답변 발췌는 ‘RAG, however, takes a hybrid approach, combining the strengths of both methods.’, ‘질문: RAG 시스템의 세 가지 패러다임(Naive, Advanced, Modular) 간의 차이점과 각각의 특징을 설명해주세요.’이고, HyDE+CAD 답변 발췌는 ‘Modular RAG 패러다임에서 새롭게 도입된 모듈들은 무엇이며’, ‘Modular RAG 프레임워크에서 가장 주목할 만한 혁신 중 하나는 Search Module의 도입입니다.’이다.

답변 관련성은 0.747에서 0.000으로, 근거 충실도는 0.417에서 0.733으로 바뀌었다. HyDE 단독 답변은 인덱싱, 검색, 생성의 세 단계를 설명하였고 답변 관련성은 0.929였다.

### B.9 큰 청크와 작은 청크의 장단점

질문은 ‘RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?’이고, 정답 근거는 RAG Survey 원문 8쪽의 ‘Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.’이다. 이 질문은 방법 질문에 속한다.

미적용과 SCD 조건을 비교하였다. 두 조건의 입력 구간은 같았다. 미적용 답변은 참고문헌 목록을 이어 쓴 뒤 RAG의 세 구성 요소를 한국어로 설명하였고, SCD 답변은 영어 참고문헌만 이어 썼다. 두 답변 모두 질문한 장단점 대신 다른 내용을 담았다.

미적용 답변 발췌는 ‘따라서 RAG의 세 가지 핵심 구성요소는 Retrieval(검색), Generation(생성)’이고, SCD 답변 발췌는 ‘few examples,” arXiv preprint arXiv:2305.06296, 2023. [7] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. K¨uttler, M. Lewis, W.’이다.

한국어 문자 비율은 0.425에서 0.000으로 바뀌었다.