졸업자격실험보고서

한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

지도교수 [지도교수 입력]

[소속 학과 입력]
[소속 대학·캠퍼스 입력]

[학생명 입력], [학번 입력]

[제출연도 입력]

졸업자격실험보고서

한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

Combination Experiments of HyDE, CAD, and SCD in RAG for Searching English Academic and Technical Documents with Korean Queries

[학생명 입력], [학번 입력]

지도교수 [지도교수 입력]

본 보고서를 졸업자격 실험보고서로 제출함.
[제출일 입력]

[학생명 입력]의 졸업자격 실험보고 통과를 인준함.
[인준일 입력]

주심 [주심 입력] (인)
부심 [부심 입력] (인)

[소속 대학·캠퍼스 입력] [소속 학과 입력]

국문초록

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 질문과 관련된 문서 구간을 검색하고 그 텍스트를 이용해 답변을 생성하는 방법이다. 한국어 질의로 영어 학술·기술 문서를 검색하는 환경에서는 검색 결과의 관련성, 답변이 근거를 반영하는 정도와 출력 언어를 함께 살펴볼 필요가 있다. 본 연구는 가상 문서 임베딩(Hypothetical Document Embeddings, HyDE), 문맥 인식 디코딩(Context-Aware Decoding, CAD), 소프트 제약 디코딩(Soft Constrained Decoding, SCD)을 같은 검색·생성 파이프라인에 적용하여 조합별 결과를 비교하였다.

영어 문서 4종에서 한국어 질의를 각각 15개씩 구성하였다. 질의 60개 각각에 세 기법의 적용 여부를 조합한 8조건을 적용하여 생성 기록 480개를 수집하였다. BGE-M3와 BM25의 검색 결과를 가중 역순위 융합으로 결합하고 CrossEncoder로 재정렬한 뒤 Mi:dm 2.0 Base Instruct로 답변을 생성하였다. 네 품질 지표는 RAG 자동 평가 프레임워크 RAGAS로 측정하고, 한국어 문자 비율은 생성 답변에서 계산하였다. 질의를 반복측정 단위로 삼아 조건별 평균과 표준편차, 요인별 주효과와 상호작용, 대응 점수 차이를 분석하였다. 품질 평가는 SCD OFF의 영어 문맥과 SCD ON의 한국어 번역 문맥을 구분하였다. 통계 검정에는 양측 유의수준 0.05와 Holm 보정을 적용하였다.

CAD와 SCD를 미적용한 HyDE 비교에서 답변 관련성의 평균 대응 점수 차이는 +0.080점이었다. 대응 t-검정은 $t(59)=2.236$, 보정 전 $p=0.029$, 네 품질 지표에 대한 보정 후 $p=0.117$이었다. 같은 검색 문맥에서 CAD를 비교한 근거 충실도 차이는 +0.029점, $t(57)=0.862$, 보정 전 $p=0.393$이었다. SCD의 HyDE OFF 동일 문맥 비교에서는 질의별로 두 CAD 상태의 차이를 평균하였다. 한국어 문자 비율의 평균 차이는 +21.8%p였으며, $t(59)=13.951$, 보정 후 $p<0.001$이었다. 전체 8조건의 문자 비율 분석에서도 SCD 주효과가 유의하였다. 조건 실행 시간에서는 HyDE와 CAD의 주효과 및 CAD×SCD 상호작용이 보정 후 유의하였다.

세 기법은 서로 다른 처리 단계와 평가 항목에 영향을 주었다. 본 연구는 동일한 질의와 파이프라인에서 답변 품질, 출력 언어와 실행 시간을 구분하고, 단순 비교와 요인 효과를 연결하여 조합별 특성을 제시하였다.

주제어: 검색 증강 생성, HyDE, CAD, SCD, 한국어 질의, 영어 문서, 반복측정 실험

Abstract

Retrieval-Augmented Generation (RAG) retrieves document passages and uses their text to generate answers. When Korean queries are used to search English academic and technical documents, retrieval relevance, grounding in retrieved evidence, and output language require separate evaluation. This study compares combinations of Hypothetical Document Embeddings (HyDE), Context-Aware Decoding (CAD), and Soft Constrained Decoding (SCD) within a fixed retrieval and generation pipeline.

Sixty Korean queries, fifteen from each of four English documents, were evaluated under all eight conditions of a two-level, three-factor design, yielding 480 generation records. The pipeline combines BGE-M3 and BM25 retrieval through weighted Reciprocal Rank Fusion (RRF), CrossEncoder reranking, and Mi:dm 2.0 Base Instruct generation. Four quality metrics were measured with the RAGAS evaluation framework, and the Korean-character ratio was computed directly from generated answers. Queries served as repeated-measures units. Quality analyses were stratified by the evaluation-context protocol: English contexts for SCD OFF and Korean-translated contexts for SCD ON. Two-sided tests used a significance level of 0.05 and Holm adjustment.

With CAD and SCD disabled, the HyDE comparison yielded a mean paired answer-relevancy difference of +0.080, $t(59)=2.236$, unadjusted $p=0.029$, and $p=0.117$ after adjustment across four quality metrics. The identical-context CAD comparison yielded a faithfulness difference of +0.029, $t(57)=0.862$, and unadjusted $p=0.393$. For the primary SCD comparison, the two CAD-state differences were averaged within each query under HyDE OFF. The mean Korean-character-ratio difference was +21.8 percentage points, $t(59)=13.951$, adjusted $p<0.001$. The eight-condition analysis also identified an SCD main effect on this ratio. HyDE and CAD main effects and the CAD-by-SCD interaction were significant for condition execution time after adjustment.

The comparisons distinguish changes in answer quality, output language, and execution time at different pipeline stages. Reporting simple contrasts alongside factorial effects provides an empirical account of how the three techniques behave in combination.

Keywords: Retrieval-Augmented Generation, HyDE, Context-Aware Decoding, Soft Constrained Decoding, Korean queries, English documents, repeated measures

목 차

1. 서론 ····· 1

1.1 연구배경 및 목적 ····· 1

1.2 연구범위 ····· 2

1.3 연구 질문 및 논문 구성 ····· 2

2. 이론적 배경 ····· 3

2.1 Retrieval-Augmented Generation ····· 3

2.2 하이브리드 검색과 재정렬 ····· 3

2.3 가상 문서 임베딩과 검색 ····· 4

2.4 Context-Aware Decoding ····· 5

2.5 Soft Constrained Decoding과 언어 이탈 ····· 6

2.6 RAG 평가 ····· 7

2.7 관련 연구와 본 연구의 위치 ····· 7

3. 시스템 설계 ····· 9

3.1 연구 및 실험 요구사항 ····· 9

3.2 아키텍처 설계 ····· 9

3.3 완전요인 실험 및 대응 비교 설계 ····· 9

4. 프로그램 구현 ····· 11

4.1 시스템 환경 ····· 11

4.2 시스템 구성 ····· 11

4.3 시스템 구현과 실행 기록 ····· 12

5. 실험 ····· 13

5.1 평가 대상 및 질의 구성 ····· 13

5.2 평가 지표와 해석 기준 ····· 13

5.3 실험 조건 및 평가 절차 ····· 14

5.4 통계 분석 방법 ····· 15

5.5 조합별 평가 결과 ····· 16

5.6 요인 주효과 및 상호작용 ····· 17

5.7 연구 질문별 대응 비교 ····· 19
5.8 종합 논의 ····· 20
5.9 평가 범위와 후속 검증 ····· 20
6. 결론 ····· 21
6.1 연구 질문별 결과 ····· 21
6.2 연구의 의의 ····· 21
6.3 적용 조건과 후속 연구 ····· 21
참고문헌 ····· 22
부록 A. 60개 질의 목록 ····· 25
부록 B. 추가 사례 및 탐색 분석 ····· 33
B.1 저장된 생성·검색 사례 ····· 33
B.2 문서별 및 질문 유형별 탐색 분석 ····· 37

그 림 목 차

[그림 1-1] 한국어 질의와 영어 학술·기술 문서를 사용하는 RAG 실험 환경 ····· 1
[그림 2-1] RAG의 검색기-생성기 구조 ····· 3
[그림 2-2] HyDE의 가상 문서 기반 검색 구조 ····· 4
[그림 2-3] CAD의 문맥 포함·제외 로짓 결합 ····· 5
[그림 2-4] SCD의 토큰 그룹별 로짓 조정 ····· 6
[그림 4-1] 한국어 질의의 검색·융합·재정렬 및 답변 생성 흐름 ····· 12
[그림 5-1] 질의별 생성 기록과 평가값을 연결하는 대응 비교 절차 ····· 14
[그림 5-2] RAPTOR 질의의 검색 근거, 생성 답변 및 평가 예시 ····· 15
[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 사례 ····· 33
[그림 B-2] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례 ····· 34
[그림 B-3] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례 ····· 35
[그림 B-4] SCD 미적용 조건의 영어 중심 출력 사례 ····· 35
[그림 B-5] SCD 적용 전후 한국어 문자 비율 변화 사례 ····· 36

표 목 차

[표 2-1] 선행연구의 접근과 본 연구의 비교 질문 ····· 8
[표 3-1] HyDE·CAD·SCD의 3요인 2수준 실험 조건 ····· 9
[표 4-1] 검색·재정렬·생성 단계의 모델과 공통 실행 설정 ····· 11
[표 5-1] 평가 문맥 언어별 8조건의 품질 및 한국어 문자 비율 평균(SD) ····· 16
[표 5-2] 8조건의 질의별 조건 실행 시간 평균과 표준편차 ····· 17
[표 5-3] SCD OFF 영어 평가 문맥의 품질 지표 H×C 반복측정 ANOVA ····· 17
[표 5-4] SCD ON 한국어 번역 평가 문맥의 품질 지표 H×C 반복측정 ANOVA · 18
[표 5-5] 한국어 문자 비율의 H×C×S 반복측정 ANOVA ····· 18
[표 5-6] 조건 실행 시간의 H×C×S 반복측정 ANOVA ····· 18
[표 5-7] HyDE·CAD 단순 비교의 품질 대응 점수 차이와 검정 결과 ····· 19
[표 5-8] SCD 한국어 문자 비율의 질의별 평균 대응 차이(%p)와 검정 결과 ····· 19
[표 A-1] 60개 한국어 질의의 대상 문서·유형·원문 페이지 및 정답 근거 ····· 25
[표 B-1] 문서별 HyDE·CAD 대응 점수 차이의 평균(SD) ····· 37
[표 B-2] 질문 유형별 HyDE·CAD 대응 점수 차이의 평균(SD) ····· 39

1. 서론

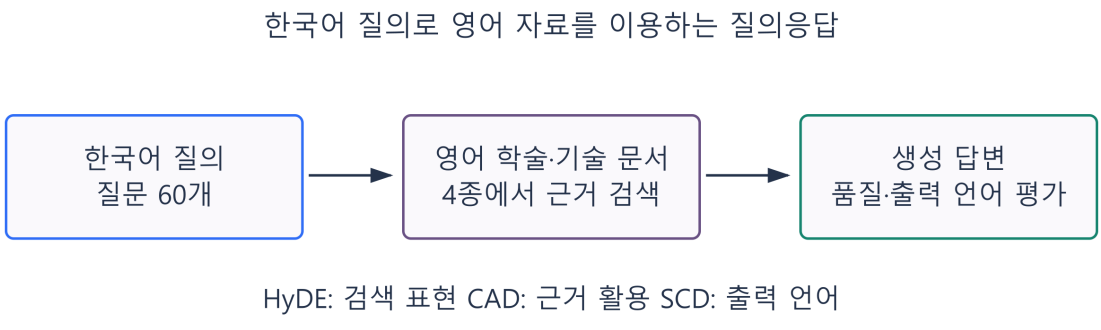
1.1 연구배경 및 목적

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 사용자의 질문과 관련된 문서 구간을 외부 자료에서 검색하고, 검색 결과에 포함된 텍스트를 생성 모델에 제공하여 답변을 생성하는 방법이다[1]. 본 논문에서는 생성 모델에 제공하는 검색 결과의 텍스트를 검색 문맥으로 지칭한다. 검색기는 필요한 근거를 찾고, 생성 모델은 질문과 검색 문맥을 함께 입력받아 답변을 작성한다.

RAG의 검색 입력과 답변 생성 과정을 개선하기 위해 여러 기법이 제안되었다. 가상 문서 임베딩(Hypothetical Document Embeddings, HyDE)은 질의에서 생성한 가상 문서를 검색에 활용한다[2]. 문맥 인식 디코딩(Context-Aware Decoding, CAD)은 검색 문맥을 포함한 입력과 제외한 입력의 다음 토큰 점수를 결합한다[3]. 소프트 제약 디코딩(Soft Constrained Decoding, SCD)은 목표 언어에 해당하는 토큰의 점수를 조정하여 출력 언어를 제어한다[4]. 각 기법은 검색 표현, 검색 근거의 활용, 출력 언어에 개입한다.

한국어 질의로 영어 문서를 검색할 때에는 질문과 원문에 쓰인 언어와 표현이 다르다. 검색 단계에서는 질문에 필요한 문서 구간을 찾는지가 중요하다. 생성 단계에서는 찾은 구간이 답변의 주장을 뒷받침하는지 확인해야 한다. 영어 근거를 이용한 답변이 한국어 중심으로 작성되는지도 별도로 측정할 필요가 있다. 세 기법을 같은 파이프라인에 적용하면 이러한 항목이 적용 여부와 조합에 따라 어떻게 달라지는지 비교할 수 있다.

본 연구는 영어 학술·기술 문서의 텍스트 구간을 검색하고 이를 바탕으로 답변을 생성하는 고정 파이프라인을 구성하였다. 이하 이 파이프라인을 Paper-RAG로 지칭한다. Paper-RAG에 HyDE, CAD, SCD를 각각 적용하거나 미적용하여 8개 조건을 구성하였다. 이 조건 배치를 RAG-Cube로 지칭한다. 연구 목적은 한국어 질의와 영어 문서를 사용하는 동일한 환경에서 답변 품질과 출력 언어를 비교하고, 각 기법의 단순 효과와 조합에 따른 요인 효과를 분석하는 것이다.



[그림 1-1] 한국어 질의와 영어 학술·기술 문서를 사용하는 RAG 실험 환경

1.2 연구범위

RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 영어 문서 4종을 대상으로 문서별 한국어 질의 15개씩 총 60개를 구성하였다. 각 질의에는 검색 대상 문서를 지정하였다. 검색 범위는 지정 문서의 텍스트 구간이며, 질의마다 같은 8조건을 적용하여 생성 기록 480개를 분석하였다.

비교 대상은 네 RAGAS 품질 지표, 한국어 문자 비율과 조건 실행 시간이다. 답변 생성 모델은 Mi:dm 2.0 Base Instruct이며, Mi:dm K 2.5 Pro Technical Report는 검색 대상 문서다. 두 명칭은 각각 생성 모델과 평가 자료를 가리킨다. 검색·재정렬·생성 설정은 4장에 제시한다.

1.3 연구 질문 및 논문 구성

RQ1. CAD와 SCD를 미적용한 상태에서 HyDE 적용 여부에 따라 답변 관련성, 근거 충실도, 문맥 정밀도와 문맥 재현율은 어떻게 달라지는가?

RQ2. 같은 검색 문맥에서 CAD 적용 여부에 따라 답변 품질과 조건 실행 시간은 어떻게 달라지는가?

RQ3. SCD 적용 여부에 따라 생성 답변의 한국어 문자 비율은 어떻게 달라지는가?

RQ4. HyDE·CAD·SCD의 조합에 따라 답변 품질, 한국어 문자 비율 및 실행 시간은 어떻게 달라지는가?

RQ1과 RQ2는 다른 기법을 미적용한 대응 비교로 분석한다. RQ3은 검색 문맥이 같은 HyDE OFF 비교를 중심으로 분석하고, RQ4는 반복측정 요인 분석으로 다룬다. 지표마다 비교 조건과 분석 단위를 명시하여 개별 조건의 차이와 요인 주효과를 구분한다.

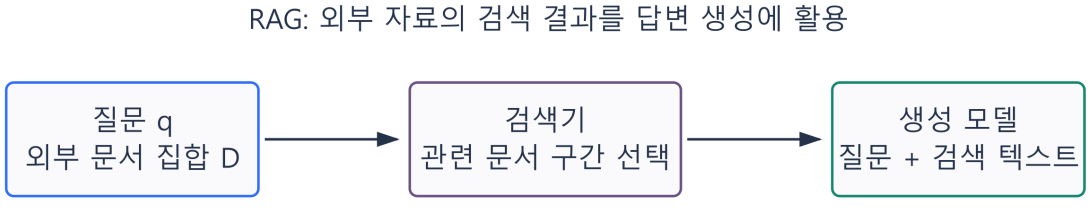
2장에서는 기법과 선행연구를 정리한다. 3장에서는 완전요인 실험 설계를, 4장에서는 구현과 기록 방법을 설명한다. 5장에서는 평가 절차와 통계 결과를 제시하고, 6장에서는 연구 질문별 결과와 후속 연구를 논의한다.

2. 이론적 배경

2.1 Retrieval-Augmented Generation

RAG는 질의와 관련된 외부 문서를 검색하고, 검색한 문맥을 생성 모델에 제공하여 답변을 만드는 구조이다[1]. 검색기는 질의 q를 이용해 문서 집합 D에서 관련 문맥 C_q를 선택한다. 생성 모델은 질의 q와 검색된 문맥 C_q를 입력받아 답변 y를 생성한다. 검색 결과의 관련성과 답변의 근거 충실도는 별도로 평가한다.

Lewis 외[1]는 검색기(retriever)가 외부 문서 인덱스에서 관련 문서를 찾고, 생성기(generator)가 질의와 검색 문서를 함께 사용해 출력을 생성하는 RAG 구조를 제시하였다. 그림 2-1은 검색 문서를 생성기의 입력으로 제공하는 RAG 구조를 나타낸다. 본 연구에서는 HyDE를 밀집 검색 입력에 적용하고, CAD와 SCD를 답변 생성 단계에 적용하였다.



[그림 2-1] RAG의 검색기-생성기 구조

본 연구에서 작성한 도식이며, Lewis 외[1]의 RAG 구조를 참고하였다.

검색 청크 ID, 재정렬 청크 ID, 최종 검색 문맥과 생성 답변을 저장하고, 검색 문맥에 관한 지표와 답변에 관한 지표를 구분하여 계산하였다.

$$C_q = Retrieve(q, D)$$

$$y = LM(q, C_q)$$

2.2 하이브리드 검색과 재정렬

고정 백본은 BGE-M3 밀집 검색과 BM25 희소 검색을 결합한다. 밀집 검색은 질의와 문서 구간의 의미적 유사성을 기준으로 관련 문서 구간을 검색한다. BM25는 모델명, 약어, 수치처럼 질의와 원문에 동일하게 등장하는 표현을 검색 단서로 활용하였다[5][6]. 두 검색 결과의 순위를 가중 역순위 융합(weighted Reciprocal Rank Fusion, RRF)으로 결합한다[7]. 이어 CrossEncoder가 원질의와 각 후보 구간의 관련성을 계산하여 순서를 다시 정한다[8].

밀집 검색과 BM25의 가중치는 각각 0.6과 0.4, 검색 후보 수와 재정렬 후보 수는 각각 8개, 최종 문맥 수는 5개로 고정하였다. 이 설정을 모든 RAG-Cube 조건에 공통으로 적용하였

다.

한국어로 작성한 질문은 영어 문서에 사용된 제목이나 방법론 용어와 어휘 및 표현 방식에서 차이가 날 수 있다. BM25의 어휘 일치 검색에는 논문명, 데이터셋명, 모델 크기와 하이퍼파라미터 표기를 검색 단서로 사용하였다.

재정렬은 검색 후보의 우선순위를 조정하고, 생성 모델은 선택된 문맥을 입력으로 답변을 만든다. HyDE 비교에는 검색 결과의 변화를 포함하였고, CAD 주 비교에서는 검색 문맥을 동일하게 유지하였다.

관련 문서 구간을 검색하더라도 생성 모델이 이를 활용하는 정도는 입력 내 위치에 따라 달라질 수 있다. Liu 외[9]는 다중 문서 질의응답에서 정답 문서가 입력의 처음이나 끝에 있을 때보다 중간에 있을 때 성능이 낮아지는 U자형 패턴을 보고하였다. 본 실험에서는 최종 입력 문맥을 상위 5개 청크로 구성하고, 재정렬 순서대로 배치하였다. 검색 성능과 답변 품질은 별도 지표로 평가하였다.

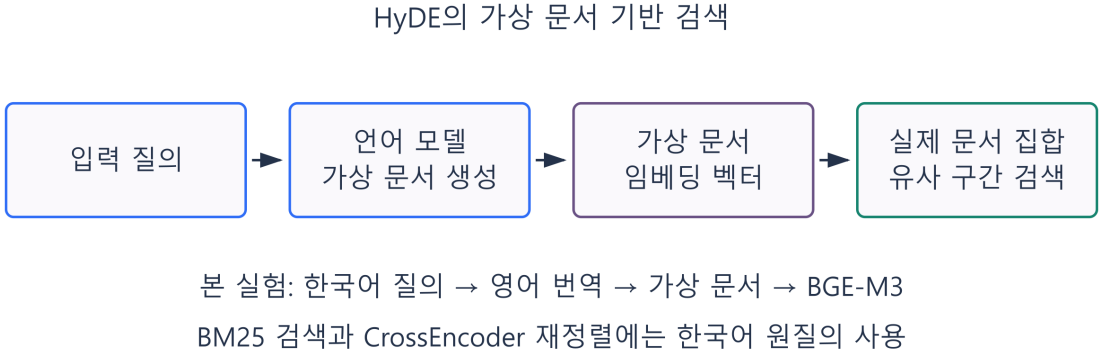
본 실험에서는 RRF 상수 k를 60으로 설정하였다. 두 검색 순위를 결합한 점수는 다음 식으로 계산하였다.

$$RRF(d) = \frac{0.6}{k + rank_{dense(d)}} + \frac{0.4}{k + rank_{BM25(d)}}$$

2.3 가상 문서 임베딩과 검색

가상 문서 임베딩(Hypothetical Document Embeddings, HyDE)은 입력 질의를 바탕으로 가상 문서를 생성한 뒤, 이를 임베딩 벡터로 변환한다. 생성된 벡터를 이용해 실제 문서 집합에서 유사한 문서를 검색한다[2]. Gao 외[2]는 관련성 레이블 없이 수행하는 검색에서 Contriever와 비교하고, 영어 과제와 한국어를 포함한 비영어 검색 과제의 성능을 보고하였다. 본 연구에서는 영어 문서에 대한 한국어 질의를 번역·가상 문서 생성과 결합하여 비교한다.

그림 2-2는 입력 질의로 가상 문서를 생성하고, 이를 임베딩한 뒤 실제 문서 집합을 검색하는 HyDE의 처리 과정을 나타낸다.



[그림 2-2] HyDE의 가상 문서 기반 검색 구조

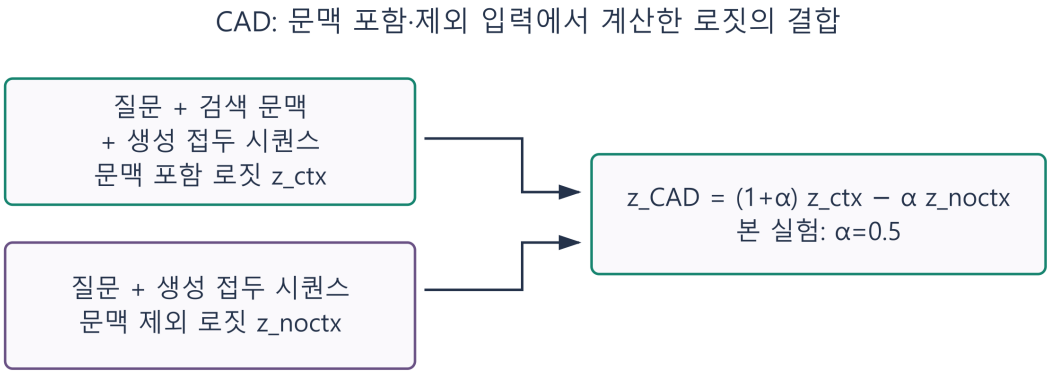
본 연구에서 작성한 도식이며, Gao 외[2]의 HyDE 구조를 참고하였다.

HyDE ON 조건에서는 답변 생성에 사용하는 Mi:dm 2.0 Base Instruct를 이용해 한국어 질의를 영어로 번역하고 가상 문서를 생성하였다. 생성된 가상 문서를 BGE-M3로 임베딩하여 밀집 검색에 사용하였다. BM25 검색과 CrossEncoder 재정렬에는 원래의 한국어 질의를 사용하였다. 검색 범위는 질의에 지정한 문서의 청크로 정하였으며, 최종 답변은 검색한 실제 문서 구간으로 생성하였다. HyDE ON/OFF 비교에서는 질의 번역과 가상 문서 생성에 따라 밀집 검색 입력이 달라진다. 검색 청크 ID와 최종 검색 문맥을 대조하여 검색 결과의 변화를 확인하고, 생성 답변의 답변 관련성도 함께 분석하였다.

2.4 Context-Aware Decoding

CAD는 검색 문맥을 포함한 경우와 제외한 경우에 계산한 다음 토큰의 점수를 비교하는 디코딩 방법이다. 두 조건에서 계산한 로짓을 가중 결합하여 검색 문맥의 영향을 토큰 선택에 반영한다[3]. CAD ON 조건에는 α=0.5를 적용하였다. CAD 주 비교에는 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 동일한 대응쌍을 사용하였다.

Shi 외[3]는 OPT, GPT, LLaMA, FLAN-T5를 이용한 요약 및 지식 충돌 과제에서 CAD의 근거 활용을 평가하였다. 본 연구는 한국어 질의와 영어 검색 문맥을 사용하는 Mi:dm 모델에서 같은 문맥의 CAD 적용 여부를 비교한다. 그림 2-3은 두 입력에서 계산한 로짓을 결합하는 과정을 나타낸다.



[그림 2-3] CAD의 문맥 포함·제외 로짓 결합

본 연구에서 작성한 도식이며, Shi 외[3]의 CAD 로짓 결합을 참고하였다.

같은 질의와 생성 접두 시퀀스에서 계산한 문맥 포함 로짓을 z_ctx, 문맥 제외 로짓을 z_noctx라고 하면, 본 연구의 CAD 점수는 다음과 같이 표현된다.

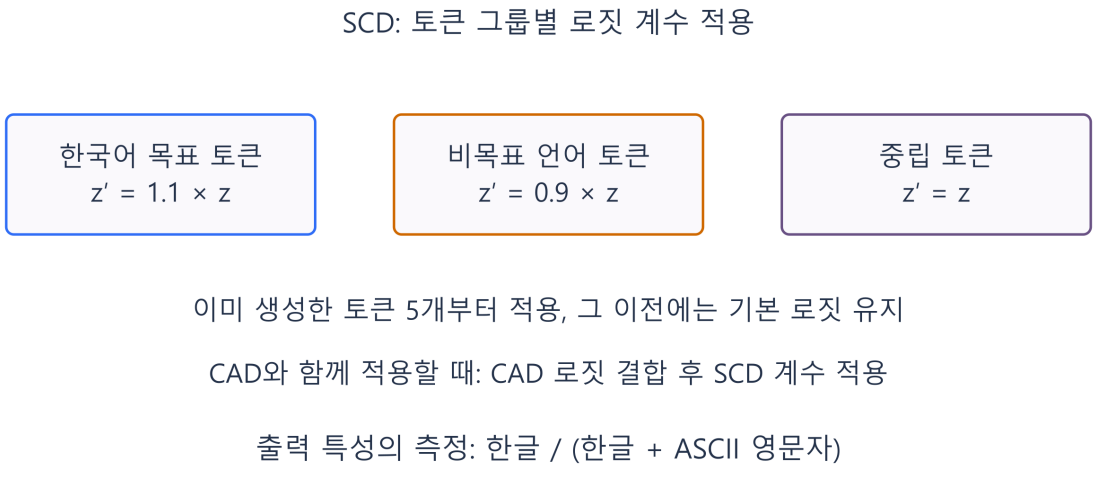
$$z_{CAD} = (1+\alpha) z_{ctx} - \alpha z_{noctx}$$

CAD는 토큰을 생성할 때 검색 문맥을 포함한 입력과 제외한 입력에 대해 각각 다음 토큰의 로짓을 계산한다. CAD의 실행 시간에 대한 요인 효과는 5.6절에서, 같은 검색 문맥에서의

답변 품질 차이는 5.7절에서 분석한다.

2.5 Soft Constrained Decoding과 언어 이탈

다국어 RAG에서는 검색 문서의 언어로 답변이 생성되는 출력 언어 이탈(language drift)이 발생할 수 있다. Li 외[4]는 목표 언어와 비목표 언어가 추론 과정에서 혼합된 뒤 최종 출력이 비목표 언어로 이동하는 사례를 분석하였다. Li 외[4]는 세 다국어 데이터셋과 여러 언어·모델에서 언어 이탈과 SCD를 평가하였다. 그림 2-4는 본 실험의 한국어 목표 토큰, 비목표 언어 토큰과 중립 토큰의 점수 조정 과정을 나타낸다.



[그림 2-4] SCD의 토큰 그룹별 로짓 조정

본 연구에서 작성한 도식이며, Li 외[4]의 SCD 토큰별 점수 조정을 참고하였다.

SCD는 어휘 집합을 목표 언어 토큰, 비목표 언어 토큰과 중립 토큰으로 나누고, 토큰의 로짓을 조정하는 디코딩 방법이다[4]. 본 실험에서는 한국어를 목표 언어로 두고 α=1.1, β=0.9, Tstart=5를 사용하였다. 이미 생성된 토큰이 5개 미만이면 로짓을 그대로 사용하고, 5개 이상이면 한국어 목표 토큰의 로짓에는 α, 비목표 언어 토큰의 로짓에는 β를 곱하였다. 중립 토큰의 로짓은 그대로 유지하였다. CAD와 함께 적용하는 조건에서는 CAD 로짓을 계산한 뒤 SCD를 적용하였다.

한국어 문자 비율은 생성 답변의 한글 문자 수를 한글 문자 수와 ASCII 영문자 수의 합으로 나누어 계산하였다.

SCD의 토큰 그룹별 점수 조정과 한국어 문자 비율은 다음 수식으로 정의한다.

$$\tilde{z}_i = \alpha z_i$$

$$\tilde{z}_i = \beta z_i$$

$$\tilde{z}_i = z_i$$

$$KoreanRatio = \frac{N_{Hangul}}{N_{Hangul} + N_{ASCII}}$$

한국어 문자 비율 0.700은 계산 대상인 한글과 ASCII 영문자 중 한글이 70.0%임을 나타낸다. 한글 완성형·자모와 ASCII 영문자를 세며, 숫자·공백·문장부호는 계산에서 제외한다. 영어 논문 제목, 모델명과 데이터셋명의 ASCII 영문자는 분모에 포함한다. 한국어 문자 비율 분석기는 계산 대상 문자 수가 0인 답변의 비율을 0으로 기록한다. 해당 답변 1건의 처리와 질의 제외 민감도 분석은 5.4절에서, SCD 대응쌍의 구성은 3.3절에서 설명한다.

2.6 RAG 평가

RAG 자동 평가 프레임워크(Retrieval Augmented Generation Assessment, RAGAS)는 검색 결과와 생성 답변을 지표별로 평가한다[10]. 본 연구의 답변 품질은 RAGAS의 근거 충실도(faithfulness), 답변 관련성(answer relevancy), 문맥 정밀도(context precision), 문맥 재현율(context recall)로 평가하였다[10]. 근거 충실도는 검색 문맥이 답변의 주장을 뒷받침하는 정도를 측정한다. 답변 관련성은 평가 모델이 생성 답변을 바탕으로 만든 질문과 원질문의 의미적 유사도를 이용해 측정한다. 본 실험에서 사용한 RAGAS 0.2.15의 문맥 정밀도는 참조 답변을 기준으로 검색 문맥의 관련성을 판정하고, 관련 문맥이 상위에 배치되는 정도를 측정한다. 문맥 재현율은 검색 문맥이 참조 답변의 내용을 뒷받침하는 정도를 측정한다.

Es 외[10]는 WikiEval에서 질문, 검색 문맥과 생성 답변을 대조하여 근거 충실도를 설명하였다. 본 연구의 실제 평가 예시는 5.3절에 제시한다.

네 RAGAS 지표는 검색 근거와 답변 사이의 관계를 서로 다른 입력과 계산 방식으로 측정한다. 출력 언어는 생성 답변의 한국어 문자 비율로 측정한다. 대응쌍의 구성은 3.3절에서, 유효 표본 수와 통계 분석 방법은 5.4절에서 설명한다.

2.7 관련 연구와 본 연구의 위치

RAG 관련 선행연구에서는 검색기의 표현력, 여러 검색 문맥의 활용, 디코딩 제어와 검색 근거의 품질을 다루었다. Dense Passage Retrieval은 질의와 문서 구간을 각각 임베딩하여 검색하는 구조를 제시했고[11], Fusion-in-Decoder는 여러 검색 문서 구간을 각각 인코딩한 뒤 디코더에서 함께 활용하는 방식을 제안했다[12]. 긴 문맥에서는 관련 정보의 입력 위치에 따라 답변 성능이 달라지는 현상이 보고되었으며[9], Contrastive Decoding은 큰 모델과 작은 모델의 출력 로그확률 차이를 토큰 선택에 활용하였다[13]. RAPTOR는 문서 청크를 반복적으로 군집화하고 요약하여 계층적 검색 구조를 구성했다[14]. Self-RAG[15]는 검색 필요성과 생성 결과를 평가하는 방법을 제안하였다. Corrective RAG[16]는 검색된 문서의 품질을 평가하고 검색 결과를 보완하는 방법을 제안하였다.

RAG 시스템을 정리한 조사 연구[17], 한국어와 영어를 다루는 Mi:dm 2.0 연구[18], RAG의 구성과 평가를 다룬 조사 연구[19]를 참고하여 검색 구조, 생성 구조와 언어 조건을 설정하였다. BEIR[20]와 MTEB[21]는 검색 및 임베딩 모델을 여러 데이터셋과 과제에서 평가하는 선행 연구로 참고하였다. 실험 대상 문서 중 Mi:dm K 2.5 Pro는 해당 기술 보고서[22]를 사용하였다.

본 연구에서는 HyDE를 밀집 검색 입력에, CAD와 SCD를 답변 생성 단계에 적용하였다.

HyDE는 검색 결과와 답변의 변화를, CAD는 같은 검색 문맥에서 답변 품질의 변화를, SCD는 한국어 문자 비율의 변화를 비교하였다.

표 2-1은 선행연구와 본 실험의 연결을 정리한 것이다. 앞서 설명한 Contrastive Decoding과 CAD는 대조 대상이 다르다. Contrastive Decoding은 큰 모델과 작은 모델의 출력을, CAD는 같은 모델에 문맥을 포함한 경우와 제외한 경우의 다음 토큰 분포를 대조한다. Self-RAG와 CRAG는 검색 및 근거 품질을 점검하는 관련 연구로 참고하였다.

[표 2-1] 선행연구의 접근과 본 연구의 비교 질문

연구	핵심 접근	본 연구의 비교 질문
HyDE[2]	가상 문서를 임베딩하여 검색	번역·가상 문서 검색을 함께 적용한 조건의 품질 차이
CAD[3]	문맥 포함·제외 로짓의 결합	같은 문맥에서 답변 품질과 실행 시간 차이
SCD[4]	언어별 토큰 로짓의 조정	한국어 문자 비율과 다른 요인과의 상호작용
DPR[11], FiD[12]	밀집 검색과 다중 검색 구간 활용	고정 검색·생성 구조의 구성
Self-RAG[15], CRAG[16]	검색 및 근거 품질의 점검	검색 지표와 답변 지표를 구분하는 평가
RAGAS[10], BEIR[20], MTEB[21]	자동 평가와 검색·임베딩 평가	고정 문서 집합에서 질의별 대응 비교

3. 시스템 설계

3.1 연구 및 실험 요구사항

본 연구는 한국어 질의 60개 각각에 HyDE, CAD, SCD의 적용 여부를 조합한 8조건을 적용하였다. 검색·재정렬·생성 모델은 고정하고, 질의별 검색 결과와 생성 답변, 실행 시간 및 적용 파라미터를 저장하였다. 같은 질의의 결과를 조건별로 연결하여 품질, 출력 언어와 실행 시간을 비교하도록 설계하였다.

3.2 아키텍처 설계

Paper-RAG는 한국어 질의와 대상 문서를 입력받아 밀집·희소 검색, 순위 융합, 재정렬, 답변 생성을 수행한다. HyDE 적용 조건에서는 질의를 영어로 번역하고 가상 문서를 생성하여 BGE-M3 밀집 검색에 사용한다. 미적용 조건에서는 한국어 원질의를 사용한다. BM25 희소 검색과 CrossEncoder 재정렬에는 모든 조건에서 한국어 원질의를 사용한다.

가중 RRF가 두 검색 순위를 결합하고 CrossEncoder가 후보 구간을 재정렬한다. 상위 5개 구간을 문맥 길이 관리 절차에 통과시킨 뒤 생성 모델에 제공한다. CAD와 SCD를 함께 적용할 때에는 문맥 포함·제외 로짓을 CAD 식으로 결합한 후 SCD의 언어별 계수를 적용한다. 최종 답변과 중간 기록은 평가 단계의 입력으로 저장한다.

3.3 완전요인 실험 및 대응 비교 설계

HyDE, CAD, SCD를 각각 미적용과 적용의 두 수준으로 설정한 3요인 2수준 완전요인설계(2^3 full factorial design)를 사용하였다. 요인 H, C, S는 각각 HyDE, CAD, SCD이며 0은 미적용, 1은 적용을 뜻한다. 같은 질의 60개를 8조건에서 측정하여 480개 생성 결과를 얻었다. 질의가 반복측정 단위이며, 같은 조건에서 난수 시드를 바꾸어 반복 생성한 횟수와 구분한다.

[표 3-1] HyDE·CAD·SCD의 3요인 2수준 실험 조건

조건	H	C	S
H0C0S0	0	0	0
H0C0S1	0	0	1
H0C1S0	0	1	0
H0C1S1	0	1	1
H1C0S0	1	0	0
H1C0S1	1	0	1
H1C1S0	1	1	0
H1C1S1	1	1	1

HyDE의 단순 비교는 H0C0S0과 H1C0S0, CAD의 단순 비교는 H0C0S0과 H0C1S0을 사용한다. CAD 비교에서는 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥의 동일성을 확인하였다. SCD 주 비교는 H0C0S0-H0C0S1과 H0C1S0-H0C1S1의 동일 문맥 120쌍이다. 전체 비

교는 각 질의의 H·C 상태를 맞춘 240쌍이다. SCD 검정에서는 질의별 두 차이 또는 네 차이를 먼저 평균하여 표본 60개를 구성한다.

단순 비교는 나머지 요인을 특정 수준으로 고정했을 때의 차이를 측정한다. 주효과는 다른 요인의 수준에 걸친 평균 차이이며, 상호작용은 한 요인의 차이가 다른 요인의 수준에 따라 달라지는 정도를 나타낸다. RAGAS는 SCD 상태에 따라 평가 문맥의 언어가 달라지므로 각 상태 안에서 H×C 효과를 분석한다. 한국어 문자 비율과 조건 실행 시간에는 전체 H×C×S 분석을 적용한다.

4. 프로그램 구현

4.1 시스템 환경

모든 조건은 같은 검색·재정렬·생성 구성으로 실행하였다. 표 4-1은 비교 요인 이외에 공통으로 적용한 설정과 각 기법의 파라미터를 정리한다. 청크 분할과 문맥 길이 관리는 공백으로 분리한 단어 수를 사용하며, 답변 길이 제한은 생성 모델의 토큰 수를 사용한다.

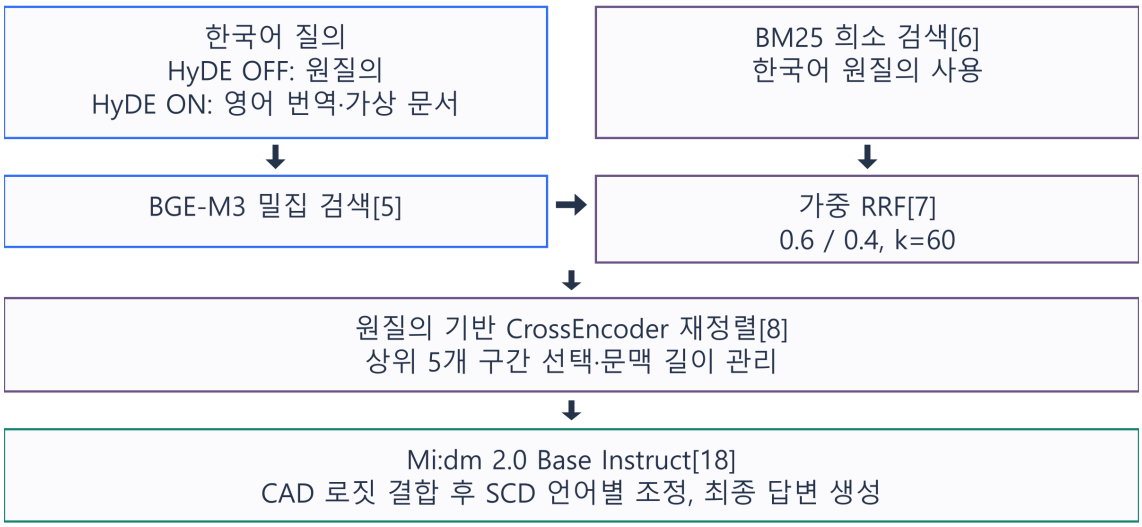
[표 4-1] 검색·재정렬·생성 단계의 모델과 공통 실행 설정

구성 단계	사용 모델 또는 방법	주요 설정
밀집 검색	BAAI/bge-m3	후보 8개, 가중치 0.6
희소 검색	BM25	후보 8개, 가중치 0.4
순위 융합	가중 RRF	k=60
재정렬	cross-encoder/ms-marco-MiniLM-L-6-v2	후보 8개, 최종 구간 5개
문서 분할	공백 기준 단어 분할	최대 512단어, 중첩 64단어, 최소 50단어
문맥 길이 관리	ContextCompressor	3,072단어 초과 시 압축, 비율 0.5
답변 생성	K-intelligence/Midm-2.0-Base-Instruct	greedy, 최대 새 토큰 512개
HyDE	영어 번역과 가상 문서 생성	temperature=0.1, top_p=0.9, sampling
CAD	문맥 포함·제외 로짓 결합	α=0.5 고정
SCD	reference_scd	α=1.1, β=0.9, Tstart=5

4.2 시스템 구성

그림 4-1은 입력 질의에서 답변까지의 처리 순서를 나타낸다. HyDE의 가상 문서는 밀집 검색 입력에 사용하고, 답변 생성에는 실제로 검색한 영어 문서 구간을 제공한다. BM25와 재정렬은 한국어 원질의를 유지한다. 검색 결과, 재정렬 결과와 최종 입력 구간을 각각 기록하여 조건 간 검색 입력을 대조할 수 있도록 하였다.

Paper-RAG는 본 연구의 고정 검색·생성 파이프라인이다.



[그림 4-1] 한국어 질의의 검색·융합·재정렬 및 답변 생성 흐름

4.3 시스템 구현과 실행 기록

시스템은 각 생성 기록에 질의 ID, 실험 조건, 검색·재정렬 청크 ID, 최종 검색 문맥, 생성 답변, 실행 시간과 적용 파라미터를 저장한다. 평가 기록은 질의 ID와 조건명을 기준으로 연결한다. 원문 근거와 참조 답변, 검색 문맥 및 생성 답변의 역할을 구분하여 지표별 입력을 구성한다.

조건 실행 시간은 모델과 검색 구성요소의 초기화가 끝난 뒤, 각 질의·조건의 처리를 시작하는 시점부터 답변 생성과 기록용 메타데이터 구성이 끝난 시점까지 측정하였다. HyDE 조건에서는 번역과 가상 문서 생성, 이후 검색·재정렬·문맥 처리·답변 생성 시간이 포함된다. 평가 API 호출과 파일 기록은 측정 구간 이후에 수행한다. 초 단위 측정값은 로그에 소수점 세 자리로 저장되었다. 실행 시간은 저장된 조건 순서와 초기 질의 처리를 포함한 해당 실행 환경의 측정값이다.

CAD는 매 생성 단계에서 문맥을 포함한 입력과 제외한 입력의 로짓을 각각 구한다. SCD는 이미 생성한 토큰 수를 기준으로 언어별 로짓 조정을 시작한다. 검색 문맥이 같은 CAD 비교와 HyDE OFF SCD 비교는 저장된 텍스트 및 ID를 직접 대조하였다. 나머지 조합의 문맥 변화는 HyDE 가상 문서 샘플링을 포함한 실제 실행 결과로 기록하였다.

5. 실험

5.1 평가 대상 및 질의 구성

RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 네 영어 문서를 대상으로 문서별 15개씩, 총 60개의 한국어 평가 질의를 구성하였다. 모든 질의는 한국어로 작성하고, 지정된 영어 문서에서 근거를 검색하였다.

네 문서의 평가 질의는 같은 절차로 작성하였다. 연구자는 각 문서의 질문 형식과 범위를 정하기 위해 초기 질문 3개를 작성하였다. 이후 초기 질문의 표현 방식과 범위를 기준으로 대규모 언어 모델(Large Language Model, LLM)이 각 문서의 주요 내용을 요약하도록 하였다. 요약을 15개의 내용 단위로 나누고, 각 단위에서 한국어 평가 질의 1개를 작성하여 문서별 15개, 총 60개를 구성하였다.

질의 구성의 최종 검증 자료는 한국어 질의 60개, 대상 문서, 원문 페이지 및 정답 근거로 구성된다. 부록 A는 각 질의와 원문 근거의 대응 관계를 제시한다.

연구자는 각 질의를 원문 PDF와 대조하여 대상 문서, 원문 페이지, 정답 근거와 답변 가능성을 확인하였다. 원문에서 찾은 정답 근거를 기록하고, 질문과 근거가 대응하는지 검토하였다.

평가 질의는 요구하는 정보에 따라 사실 및 정의, 방법 및 절차, 결과 및 비교, 목적 및 기여의 네 유형으로 분류하였다. 사실 및 정의 유형은 개념, 수치 또는 구성 요소를 묻는 질의이다. 방법 및 절차 유형은 모델 구조, 처리 과정, 데이터셋 구성, 평가 방법 또는 실험 설정을 묻는다. 결과 및 비교 유형은 정량적 결과, 정성적 결과 또는 방법 간 비교를 묻는다. 목적 및 기여 유형은 연구 목적, 문제 설정 또는 주요 기여를 묻는다. 최종 분포는 사실 및 정의 8개, 방법 및 절차 29개, 결과 및 비교 20개, 목적 및 기여 3개다.

검색 설정을 정할 때는 최종 평가 집합과 분리한 튜닝 질의 5개를 사용하였다. 이 과정에서 검색 후보 수 8, 재정렬 후보 수 8, 최종 생성 문맥 5를 확정하였다. 최종 평가에서는 검색 설정을 고정하고, 60개 질의 각각에 8개 RAG-Cube 조건을 적용하여 총 480개의 생성 기록을 저장하였다.

문서별 15개 구성은 문서별 질의 수를 맞추기 위한 기준이다. 질문 유형의 비중은 원문에서 묻는 내용에 따라 달라진다. 부록 A는 60개 질의의 원문 페이지와 정답 근거를 제시한다. 각 질의의 대상 문서, 원문 근거의 존재, 해당 근거로 질문에 답할 수 있는지를 확인하였다.

5.2 평가 지표와 해석 기준

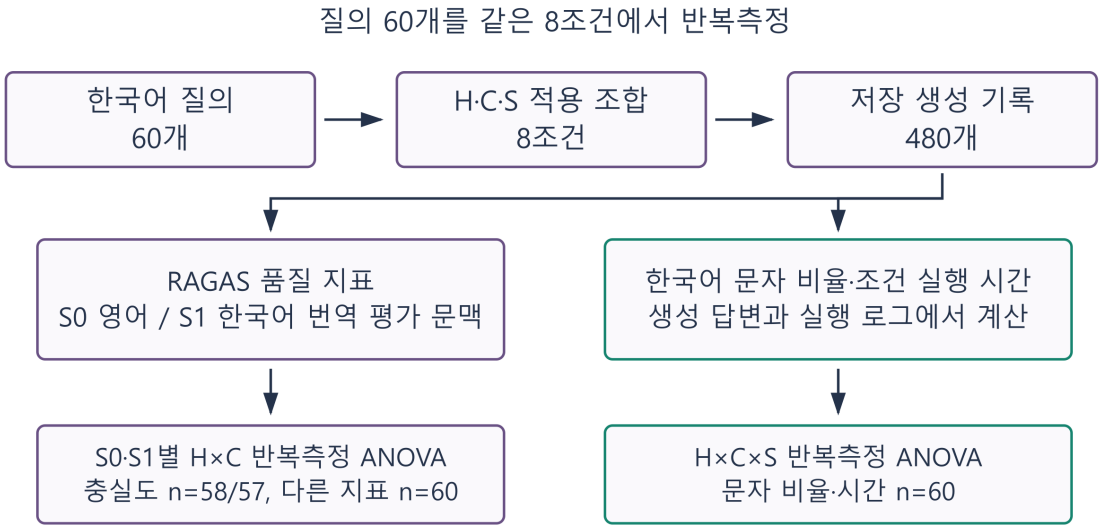
근거 충실도는 생성 답변에서 추출한 주장 중 검색 문맥으로 뒷받침되는 주장의 비율이다. 답변 관련성은 생성 답변을 바탕으로 평가 모델이 만든 질문과 원질문 사이의 임베딩 코사인 유사도를 사용한다. 문맥 정밀도는 참조 답변에 유용한 검색 구간이 상위 순위에 배치된 정도를 평균 정밀도로 계산한다. 문맥 재현율은 참조 답변의 주장 중 검색 문맥이 뒷받침하는 비율이다. 네 지표는 값이 높을수록 각 지표가 평가하는 관련성이나 근거 포괄 정도가 높다. 답변 관련성의 코사인 유사도는 이론적으로 −1~1이며, 본 실험에서 저장된 네 품질 지표의 관측값은 0~1 범위였다.

한국어 문자 비율은 한글 문자 수를 한글과 ASCII 영문자 수의 합으로 나눈 값이다. 0.700은 한글 사용 비중 70.0%를 뜻하며, 조건 간 비율 차이 0.218은 21.8%p다. 이 지표는 문자 구성의 측정값이다. 정답과의 의미적 일치와 문장 자연스러움은 별도 평가 대상으로 구분한다. 조건 실행 시간은 초 단위이며 측정 구간은 4.3절에 제시하였다.

5.3 실험 조건 및 평가 절차

평가에는 RAGAS 0.2.15, OpenAI gpt-4o 평가 모델과 BAAI/bge-m3 임베딩 모델을 사용하였다. 실제 사용한 지표는 Faithfulness, AnswerRelevancy, ContextPrecision과 ContextRecall이다. RAGAS 0.2.15에서 ContextPrecision은 참조 답변을 사용하는 LLMContextPrecisionWithReference를 상속한다. 생성 답변을 기준으로 관련 구간을 판정하는 지표와 입력이 구분된다.

SCD OFF의 RAGAS 평가에는 답변 생성에 입력한 영어 검색 문맥을 사용하였다. SCD ON의 평가에는 저장된 영어 문맥을 gpt-4o로 한국어 번역한 평가용 문맥을 사용하였다. 답변 생성에는 모든 조건에서 영어 문맥을 입력했고, 평가할 생성 답변은 저장된 원문을 유지하였다. 따라서 품질 결과표에는 평가 문맥 언어를 표시하고, H×C 분석은 각 SCD 상태 안에서 수행하였다.



[그림 5-1] 질의별 생성 기록과 평가값을 연결하는 대응 비교 절차

그림 5-2는 RAPTOR 문서의 질의 ext_raptor_011에 대해 질문, 검색 근거, 생성 답변과 평가값을 연결한 예시다. 참조 답변은 원문 근거에서 구성하며, 검색 문맥과 생성 답변은 해당 조건의 저장 기록을 사용한다. 근거 충실도는 답변의 주장과 검색 문맥을, 문맥 재현율은 참조 답변과 검색 문맥을 대조한다. 각 지표가 사용하는 입력을 구분하여 결과를 해석하였다.

E01 | ext_raptor_011
질문: Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_raptor_12d47c916205, paper_nlp_raptor_4f4f51e0f19a
문맥[1] 발췌: [...] RAPTOR selects nodes from different layers depending on the level of granularity required by the Published as a conference paper at ICLR 2024 Algorithm 2 Collapsed Tree A [...]
저장 답변 발췌: [...] 첫째, RAPTOR는 계층적 구조를 통해 다양한 수준의 추상화(abstraction)를 제공합니다. 논문의 Figure 4에서 확인할 수 있듯이, RAPTOR는 질문의 요구사항에 따라 서로 다른 층위(layer)에서 노드를 선택할 수 있습니다. 반면 DPR은 단일 층위의 leaf 노드만을 선택하여 정보를 제공합니다. [...]
Faithfulness 1.0000 | Answer Relevancy 0.9365
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.5274
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 5-2] RAPTOR 질의의 검색 근거, 생성 답변 및 평가 예시

5.4 통계 분석 방법

질의 ID와 조건으로 연결한 원정밀도 평가값을 사용하였다. 조건별 기술통계는 평균과 표본 표준편차(SD, 분모 $n-1$)로 제시하였다. RAGAS 평가 셀 1,920개 중 1,915개가 유효했고, 결측 5개는 모두 근거 충실도에서 발생하였다. 결측 질의는 ext_rag_003, ext_rag_005, ext_rag_006이다. H0C1S0에서 003·006, H0C0S1에서 003·005·006이 결측이었다. 검정에 필요한 모든 조건의 값이 있는 질의를 사용하였다. 충실도의 H×C 분석은 SCD OFF n=58, ON n=57이며, 다른 지표는 n=60이다.

RAGAS는 평가 문맥 언어별 H×C 반복측정 ANOVA를, 한국어 문자 비율과 실행 시간은 H×C×S 반복측정 ANOVA를 적용하였다. 모든 요인은 두 수준이므로 효과별 자유도는 $(1, n-1)$이다. 질의별 직교 요인 대비에서 계산한 t^2와 statsmodels AnovaRM의 F값을 대조하였다. 효과크기는 부분 η^2로 제시하였다.

RQ1과 RQ2는 3.3절의 조건을 고정한 양측 대응 t-검정으로 분석하고, 평균 대응 점수 차이와 차이의 SD, t, 자유도, p, Cohen dz를 보고하였다. SCD는 같은 질의의 두 CAD 상태 차이를 평균한 주 비교와 네 H·C 상태 차이를 평균한 전체 비교를 사용하였다. 두 비교 모두 검정 단위는 질의 60개다. 개별 차이와 대응 t 통계량은 다음과 같다.

$$\Delta_i = s_i^{ON} - s_i^{OFF}$$

$$\overline{\Delta} = \frac{1}{n}\sum_{i=1}^{n}\Delta_i$$

$$t = \frac{\overline{\Delta}}{s_\Delta / \sqrt{n}}$$

실행 시간의 CAD×SCD 상호작용을 해석하기 위해, 각 SCD 상태에서 두 HyDE 수준을 평균한 CAD 단순 효과를 추가로 검정하였다. 두 후속 비교에 별도로 Holm 보정을 적용하였다.

양측 유의수준은 0.05로 정하였다. 품질 요인 검정 24개를 한 가설군으로, 문자 비율과 실행 시간의 요인 검정은 각각 7개를 가설군으로 정해 Holm 보정을 적용하였다. HyDE와 CAD의 단순 비교는 각각 네 품질 지표를, SCD 문자 비율은 주 비교와 전체 비교 두 검정을 함께 보정하였다. 본 연구의 통계 분석은 수집한 결과에 대한 탐색적 분석이며, 각 검정의 보정 전·후 p를 함께 제시한다.

질의별 대응 차이의 분포와 0·1 경계값, 동률을 확인하고, 질의 단위 부호 순열검정 100,000회(seed=20261015)와 Wilcoxon 부호순위 검정을 민감도 분석으로 수행하였다. 문서 하나씩을 제외한 평균 차이도 계산하였다. 같은 질의의 조건들을 함께 묶어 재표집하거나 평균하여 반복측정 구조를 유지하였다. 질의 단위 부트스트랩 신뢰구간은 보조자료에 제시하였다.

track1_0035의 H1C0S1 답변은 숫자만 반복하여 한글·ASCII 영문자 분모가 0이었다. 분석기는 이 답변의 한국어 문자 비율을 0으로 기록하였다. 해당 질의 전체를 제외한 n=59 민감도 분석으로 이 처리의 영향을 확인하였다.

5.5 조합별 평가 결과

표 5-1은 8조건의 품질 지표와 한국어 문자 비율의 평균(SD)을 제시한다. 품질은 S0의 영어 평가 문맥과 S1의 한국어 번역 평가 문맥을 구분하였다.

[표 5-1] 평가 문맥 언어별 8조건의 품질 및 한국어 문자 비율 평균(SD)

조건	충실도	관련성	정밀도	재현율	한국어 비율
H0C0S0	0.791 (0.260)	0.683 (0.282)	0.749 (0.302)	0.933 (0.252)	0.494 (0.265)
H0C0S1	0.787 (0.254)	0.637 (0.296)	0.763 (0.300)	0.900 (0.303)	0.699 (0.329)
H0C1S0	0.839 (0.201)	0.675 (0.261)	0.740 (0.302)	0.917 (0.279)	0.488 (0.245)
H0C1S1	0.777 (0.270)	0.600 (0.321)	0.752 (0.301)	0.850 (0.360)	0.719 (0.218)
H1C0S0	0.834 (0.186)	0.763 (0.209)	0.714 (0.296)	0.933 (0.252)	0.556 (0.213)
H1C0S1	0.822 (0.218)	0.710 (0.272)	0.743 (0.281)	0.900 (0.303)	0.807 (0.200)
H1C1S0	0.860 (0.181)	0.705 (0.248)	0.736 (0.271)	0.900 (0.303)	0.503 (0.229)
H1C1S1	0.831 (0.253)	0.667 (0.286)	0.754 (0.267)	0.917 (0.279)	0.731 (0.209)

S0는 영어 문맥 평가, S1은 한국어 번역 문맥 평가다. 충실도는 H0C1S0 n=58, H0C0S1 n=57이며, 나머지 조건·지표는 n=60이다. 한국어 비율은 생성 답변에서 계산하였다. 질의별 관측값의 SD와 대응 차이의 SD는 서로 다른 통계량이다.

[표 5-2] 8조건의 질의별 조건 실행 시간 평균과 표준편차

조건	평균(초)	SD(초)
H0C0S0	20.792	23.404
H0C0S1	18.898	5.085
H0C1S0	63.867	25.312
H0C1S1	55.159	26.465
H1C0S0	23.440	4.707
H1C0S1	24.892	5.196
H1C1S0	73.532	21.584
H1C1S1	64.125	21.675

모든 조건의 실행 시간 표본 수는 60이다. 시간에는 조건별 검색과 답변 생성 과정이 포함되며, HyDE 적용 시 번역과 가상 문서 생성도 포함된다.

5.6 요인 주효과 및 상호작용

[표 5-3] SCD OFF 영어 평가 문맥의 품질 지표 H×C 반복측정 ANOVA

지표	효과	df	F	p	보정 p	부분 η^2
근거 충실도	H	1, 57	1.162	0.286	1.000	0.020
근거 충실도	C	1, 57	1.034	0.313	1.000	0.018
근거 충실도	H×C	1, 57	0.073	0.789	1.000	0.001
답변 관련성	H	1, 59	2.844	0.097	1.000	0.046
답변 관련성	C	1, 59	1.498	0.226	1.000	0.025
답변 관련성	H×C	1, 59	1.185	0.281	1.000	0.020
문맥 정밀도	H	1, 59	0.496	0.484	1.000	0.008
문맥 정밀도	C	1, 59	0.226	0.636	1.000	0.004
문맥 정밀도	H×C	1, 59	1.567	0.216	1.000	0.026
문맥 재현율	H	1, 59	0.039	0.843	1.000	0.001
문맥 재현율	C	1, 59	1.000	0.321	1.000	0.017
문맥 재현율	H×C	1, 59	0.109	0.742	1.000	0.002

[표 5-4] SCD ON 한국어 번역 평가 문맥의 품질 지표 H×C 반복측정 ANOVA

지표	효과	df	F	p	보정 p	부분 η²
근거 충실도	H	1, 56	2.434	0.124	1.000	0.042
근거 충실도	C	1, 56	0.137	0.713	1.000	0.002
근거 충실도	H×C	1, 56	0.188	0.666	1.000	0.003
답변 관련성	H	1, 59	3.012	0.088	1.000	0.049
답변 관련성	C	1, 59	2.628	0.110	1.000	0.043
답변 관련성	H×C	1, 59	0.011	0.917	1.000	0.000
문맥 정밀도	H	1, 59	0.158	0.693	1.000	0.003
문맥 정밀도	C	1, 59	0.000	0.994	1.000	0.000
문맥 정밀도	H×C	1, 59	0.823	0.368	1.000	0.014
문맥 재현율	H	1, 59	0.529	0.470	1.000	0.009
문맥 재현율	C	1, 59	0.396	0.532	1.000	0.007
문맥 재현율	H×C	1, 59	2.744	0.103	1.000	0.044

품질 요인 검정 24개에 Holm 보정을 적용한 결과는 모두 0.05 이상이었다. SCD OFF 답변 관련성의 HyDE 주효과는 F(1,59)=2.844, 보정 전 p=0.097이었다. 이 값은 CAD OFF에 고정한 HyDE 단순 비교와 다른 가설을 검정한다. 품질 요인 효과의 크기와 방향은 표의 F와 부분 η², 조건 평균을 함께 사용해 해석하였다.

[표 5-5] 한국어 문자 비율의 H×C×S 반복측정 ANOVA

효과	df	F	p	보정 p	부분 η²
H	1, 59	2.924	0.093	0.370	0.047
C	1, 59	3.365	0.072	0.358	0.054
S	1, 59	341.302	<0.001	<0.001	0.853
H×C	1, 59	4.417	0.040	0.239	0.070
H×S	1, 59	0.771	0.384	0.940	0.013
C×S	1, 59	0.006	0.939	0.940	0.000
H×C×S	1, 59	1.035	0.313	0.940	0.017

[표 5-6] 조건 실행 시간의 H×C×S 반복측정 ANOVA

효과	df	F	p	보정 p	부분 η²
H	1, 59	16.362	<0.001	<0.001	0.217
C	1, 59	423.765	<0.001	<0.001	0.878
S	1, 59	6.097	0.016	0.066	0.094
H×C	1, 59	2.262	0.138	0.414	0.037
H×S	1, 59	0.401	0.529	0.976	0.007
C×S	1, 59	12.080	<0.001	0.005	0.170
H×C×S	1, 59	0.487	0.488	0.976	0.008

한국어 문자 비율은 SCD 주효과가 유의하였다(F(1,59)=341.302, 보정 p<0.001). H×C 상호작용의 보정 전 p는 0.040, 보정 후 p는 0.239였다. 실행 시간에서는 HyDE와 CAD 주효과

및 CAD×SCD 상호작용이 보정 후 유의하였다. SCD의 실행 시간 주효과는 보정 전 p=0.016, 보정 후 p=0.066이었다.

실행 시간의 후속 비교에서 CAD 적용에 따른 질의별 평균 차이는 SCD OFF에서 +46.583초(SD 18.937), t(59)=19.054, dz=2.460이었다. SCD ON에서는 +37.747초(SD 18.405), t(59)=15.886, dz=2.051이었다. 두 비교 모두 보정 p<0.001이었다. CAD의 시간 증가는 두 SCD 수준에서 관찰되었고, 그 평균 차이는 SCD ON에서 더 작았다.

5.7 연구 질문별 대응 비교

[표 5-7] HyDE·CAD 단순 비교의 품질 대응 점수 차이와 검정 결과

요인·지표	n	평균 차이(SD)	t(df)	p	보정 p	dz
HyDE 근거 충실도	60	0.044 (0.281)	1.200 (59)	0.235	0.705	0.155
HyDE 답변 관련성	60	0.080 (0.279)	2.236 (59)	0.029	0.117	0.289
HyDE 문맥 정밀도	60	−0.034 (0.234)	−1.134 (59)	0.261	0.705	−0.146
HyDE 문맥 재현율	60	0.000 (0.368)	0.000 (59)	1.000	1.000	0.000
CAD 근거 충실도	58	0.029 (0.255)	0.862 (57)	0.393	1.000	0.113
CAD 답변 관련성	60	−0.007 (0.313)	−0.181 (59)	0.857	1.000	−0.023
CAD 문맥 정밀도	60	−0.009 (0.077)	−0.930 (59)	0.356	1.000	−0.120
CAD 문맥 재현율	60	−0.017 (0.129)	−1.000 (59)	0.321	1.000	−0.129

HyDE 비교는 C0S0, CAD 비교는 H0S0에 고정하였다. 평균 차이는 적용 조건 점수에서 미적용 조건 점수를 뺀 값이다. SD는 질의별 차이의 표본표준편차이며, 각 요인의 네 품질 검정에 Holm 보정을 적용하였다.

HyDE의 답변 관련성은 평균 대응 점수 차이 +0.080점, 차이 SD 0.279였다. 보정 전 p=0.029, 보정 후 p=0.117로, 네 품질 지표를 함께 고려한 검정의 보정 p는 유의수준 0.05보다 높았다. HyDE 조건은 번역과 가상 문서 생성에 따른 밀집 검색 입력의 변화를 함께 포함한다. 검색 경로가 달라진 실제 사례는 부록 B에 제시하였다.

CAD의 근거 충실도 평균 대응 점수 차이는 +0.029점, 차이 SD 0.255였고, t(57)=0.862, 보정 전 p=0.393이었다. 질의별로 증가와 감소가 함께 나타났다. 같은 검색 문맥의 문맥 정밀도 8/60쌍과 문맥 재현율 1/60쌍에서도 평가값 차이가 기록되었다. 평가 입력 대조와 평가자 변동성의 해석은 5.9절에서 다룬다. CAD의 추가 로짓 계산과 실행 시간 증가는 함께 관찰되었다.

[표 5-8] SCD 한국어 문자 비율의 질의별 평균 대응 차이(%p)와 검정 결과

요인·지표	n	평균 차이(SD)	t(df)	p	보정 p	dz
HyDE OFF 동일 문맥	60	21.822 (12.117)	13.951 (59)	<0.001	<0.001	1.801
전체 H·C 상태 일치	60	22.894 (9.599)	18.474 (59)	<0.001	<0.001	2.385

주 비교는 120쌍, 전체 비교는 240쌍을 질의별로 평균한 결과이며 각각 검정 표본은 60개다. 한국어 문자 비율의 평균 차이는 주 비교 +21.822%p, 전체 비교 +22.894%p였고, 두 검정 모두 보정 p<0.001이었다.

5.8 종합 논의

검색 입력을 바꾸는 HyDE, 생성 로짓에 개입하는 CAD와 출력 언어를 조정하는 SCD는 서로 다른 평가 항목에서 결과를 보였다. HyDE 답변 관련성의 단순 비교에서는 양의 평균 차이가 관찰되었으며, 네 품질 지표 보정 후 p는 0.117이었다. CAD는 평균 충실도 차이에 비해 질의별 차이의 SD가 컸다. 기법별 품질 변화는 조건 평균, 질의별 대응 차이와 Holm 보정 검정 결과를 함께 사용해 해석하였다.

SCD의 한국어 문자 비율 증가는 단순 비교와 전체 요인 분석에서 일관되었다. 이 결과는 문자 사용 비중에 관한 관측이다. 자연스러운 한국어 문장과 원문 근거의 정확한 전달은 별도의 질적 검토가 필요하다. CAD 적용에 따른 실행 시간 증가는 SCD OFF에서 +46.583초, ON에서 +37.747초로, SCD 상태에 따라 달랐다. 실행 시간을 비교할 때에는 답변 길이와 저장된 실행 순서의 영향도 고려해야 한다.

문서별·질문 유형별 평균 대응 차이와 SD는 부록 B에 제시하였다. 문서 하나씩을 제외한 분석과 질의 단위 순열검정으로 특정 문서와 경계값이 결과에 미치는 영향을 확인하였다. 적용 조건의 선택은 필요한 출력 언어와 허용 가능한 실행 시간을 정한 뒤, 그 조건의 품질 결과와 함께 판단할 수 있다.

HyDE 답변 관련성 차이의 Shapiro–Wilk 검정은 $p<0.001$이었다. 평균 차이를 검정하는 질의 단위 부호 순열검정의 Holm 보정 p는 0.112였고, 순위에 근거한 위치 차이를 다루는 Wilcoxon 검정의 보정 p는 0.012였다. 검정이 사용하는 정보와 가설에 따라 결과가 달랐으며, 본문의 평균 차이 해석에는 대응 t-검정과 부호 순열 결과를 함께 사용하였다. SCD의 두 문자 비율 비교는 부호 순열과 Wilcoxon 검정에서도 보정 $p<0.001$이었다.

문서 하나씩을 제외했을 때 HyDE 답변 관련성 평균 차이는 +0.064~+0.108점, CAD 충실도는 +0.013~+0.049점, SCD 주 비교 문자 비율은 +21.2~+22.8%p였다. 숫자 반복 답변의 질의를 제외한 n=59 분석에서도 SCD 문자 비율 주효과는 $F(1,58)=332.971$, Holm 보정 $p<0.001$이었다. 전체 기술통계와 민감도 검정은 동일한 저장 기록에서 재계산하였다.

5.9 평가 범위와 후속 검증

평가 문서는 네 종류이며 각 문서에서 구성한 질의 15개가 분석에 사용되었다. 반복측정 검정은 이 문서 집합의 질의별 변동을 다룬다. 다양한 문서 집단에 대한 효과는 문서 수와 주제를 확대한 실험에서 검증할 수 있다. HyDE 가상 문서는 샘플링으로 생성되었고, 각 질의·조건의 생성은 한 번씩 수행하였다. 생성 시드 간 변동은 별도 반복 실험으로 확인할 항목이다.

HyDE ON에서는 조건마다 가상 문서를 샘플링하므로 검색 문맥이 달라질 수 있다. H1에서의 CAD·SCD 비교와 전체 요인 효과에는 이러한 검색 차이가 함께 포함된다. 따라서 H1의 요인 효과는 가상 문서 샘플링을 포함한 조합 조건의 결과다.

RAGAS 품질은 SCD 상태별 평가 문맥 언어에 따라 분석하였다. 후속 품질 비교에서는 평가 문맥 언어를 통일한다. CAD의 H0S0 비교는 60쌍 모두 질문·참조 답변·평가 문맥이 같았으며, 문맥 정밀도 8쌍과 재현율 1쌍에서 점수 차이가 나타났다. 이 변동의 크기는 동일 입력의 반복 평가로 측정할 수 있다. 결측 5개와 숫자 반복 답변 1건의 처리는 5.4절에 제시하였다.

6. 결론

본 연구는 한국어 질의로 영어 학술·기술 문서를 검색하는 고정 RAG 파이프라인에서 HyDE, CAD, SCD의 8개 조합을 비교하였다. 질의 60개와 생성 기록 480개를 이용하여 품질, 한국어 문자 비율과 조건 실행 시간을 분석하였다.

6.1 연구 질문별 결과

RQ1에서 HyDE의 답변 관련성 평균 대응 점수 차이는 +0.080점이었다. CAD와 SCD를 미적용한 비교의 보정 전 p는 0.029였고, 네 품질 지표를 함께 보정한 p는 0.117이었다. RQ2에서 같은 문맥의 CAD 충실도 차이는 +0.029점, 보정 전 p=0.393이었다. 두 비교의 평균 차이는 양수였으며, Holm 보정 p는 각각 0.117과 1.000이었다.

RQ3에서 HyDE OFF 동일 문맥의 SCD 한국어 문자 비율 차이는 +21.8%p였으며 보정 $p<0.001$이었다. 질의별로 네 H·C 상태를 평균한 전체 비교의 차이는 +22.9%p였고 보정 $p<0.001$이었다. SCD는 본 실험의 한국어 문자 사용 비중을 높였다.

RQ4에서 품질의 H×C 효과는 SCD 평가 프로토콜별 Holm 보정 후 모두 $p\geq0.05$였다. 문자 비율에서는 SCD 주효과가, 실행 시간에서는 HyDE와 CAD 주효과 및 CAD×SCD 상호작용이 유의하였다. 이 결과는 답변 품질, 한국어 문자 비율과 실행 시간에 대한 조합별 차이를 제시한다.

6.2 연구의 의의

본 연구는 세 선행기법을 같은 검색·생성 파이프라인과 질의 집합에서 비교하였다. 검색 경로를 바꾸는 HyDE 비교와 검색 문맥이 같은 CAD 비교를 구분하고, SCD 출력 언어 비교의 여러 대응쌍을 질의 단위로 묶어 검정하였다. 또한 단순 비교와 요인 주효과·상호작용을 함께 제시하여 고정 조건의 결과와 조합 전반의 결과를 연결하였다.

6.3 적용 조건과 후속 연구

한국어 중심의 출력을 우선하는 경우에는 SCD의 문자 비율 결과를 참고할 수 있다. 답변의 근거 충실도와 실행 시간이 중요한 경우에는 CAD의 질의별 변화와 추가 비용을 함께 검토해야 한다. HyDE는 번역과 가상 문서 생성이 결합된 검색 조건으로 해석하며, 번역만 적용한 비교를 추가하면 각 요소의 기여를 구분할 수 있다.

후속 연구에서는 평가 문서와 질의 범위를 확대하고, 생성 시드와 평가 모델을 반복하여 변동성을 측정할 필요가 있다. 모든 조건에 통일한 RAGAS 평가 프로토콜을 적용하고, 숫자 반복 및 언어 혼합 사례의 의미 정확성과 문장 자연스러움을 사람 평가와 함께 확인할 수 있다.

참고문헌

[1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Advances in Neural Information Processing Systems, Vol. 33, 2020.

[2] L. Gao et al., “Precise Zero-Shot Dense Retrieval without Relevance Labels,” Proceedings of ACL, pp. 1762-1777, 2023.

[3] W. Shi et al., “Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding,” Proceedings of NAACL, pp. 783-791, 2024.

[4] B. Li, Z. Xu, and R. Xie, “Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation,” Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519-31526, 2026.

[5] J. Chen et al., “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318-2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson et al., “Okapi at TREC-3,” Text REtrieval Conference, 1994.

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” Proceedings of SIGIR, pp. 758-759, 2009.

[8] R. Nogueira and K. Cho, “Passage Re-ranking with BERT,” arXiv:1901.04085, 2019.

[9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157-173, 2024.

[10] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented Generation,” Proceedings of EACL System Demonstrations, pp. 150-158, 2024.

[11] V. Karpukhin et al., “Dense Passage Retrieval for Open-Domain Question Answering,” Proceedings of EMNLP, pp. 6769-6781, 2020.

[12] G. Izacard and E. Grave, “Leveraging Passage Retrieval with Generative

Models for Open Domain Question Answering," Proceedings of EACL, pp. 874-880, 2021.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286-12312, 2023.

[14] P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S.-Q. Yan et al., "Corrective Retrieval Augmented Generation," arXiv:2401.15884, 2024.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, pp. 1-29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] D. Shin et al., "Mi:dm 2.0 Korea-centric Bilingual Language Models," arXiv:2601.09066, 2026.

[19] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv:2312.10997, 2023.

[20] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[21] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EACL, pp. 2014-2037, 2023.

[22] KT Tech Innovation Group, "Mi:dm K 2.5 Pro," technical report, arXiv:2603.18788v2, 2026.

그림 자료 이용 정보

그림 2-1~2-4는 선행연구의 개념과 본 실험의 처리 과정을 참고하여 본 연구에서 작성한 독립 도식이다. 각 그림의 개념 출처와 참고 자료는 다음과 같다.

그림 2-1 — 본 연구 작성. Lewis 외[1]의 RAG 구조를 참고하여 독립 도식을 작성하였다.

참고 자료: https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf

그림 2-2 — 본 연구 작성. Gao 외[2]의 HyDE 구조를 참고하여 독립 도식을 작성하였다.

참고 자료: https://aclanthology.org/2023.acl-long.99/

그림 2-3 — 본 연구 작성. Shi 외[3]의 CAD 로짓 결합을 참고하여 독립 도식을 작성하였다.

참고 자료: https://aclanthology.org/2024.naacl-short.69/

그림 2-4 — 본 연구 작성. Li 외[4]의 SCD 토큰별 점수 조정을 참고하여 독립 도식을 작성하였다.

참고 자료: https://arxiv.org/abs/2511.09984

부록 A. 60개 질의 목록

각 질의의 대상 문서, 원문 페이지와 정답 근거를 제시한다.

[표 A-1] 60개 한국어 질의의 대상 문서·유형·원문 페이지 및 정답 근거

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_001	언어 모델이 생성 시 활용하는 prior knowledge와 context knowledge는 각각 어디에서 오는 정보입니까?	CAD	사실 및 정의	1	the context contains external knowledge; prior knowledge is encoded in the model parameters
ext_cad_002	CAD의 요약 실험에는 어떤 데이터셋과 평가 지표가 사용되었습니까?	CAD	방법 및 절차	3	CNN-DM and XSUM; ROUGE-L, BERT-Precision, and FactKB
ext_cad_003	CAD의 지식 충돌 실험에는 어떤 두 데이터셋이 사용되었고 각각 무엇을 평가합니까?	CAD	방법 및 절차	3	MemoTrap investigates memorization traps; NQ-Swap tests faithful answering from a modified reliable document.
ext_cad_004	NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?	CAD	방법 및 절차	3	identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity
ext_cad_005	CAD 실험에서 요약 과제와 지식 충돌 과제에 사용한 α 값은 각각 얼마이며, 지식 충돌 과제에서 더 큰 값을 사용한 이유는 무엇입니까?	CAD	방법 및 절차	3	α = 0.5 for summarization and α = 1 for knowledge conflicts, where prior knowledge needs to be factored out more
ext_cad_006	CAD 논문의 베이스라인 디코딩은 요약 과제와 지식 충돌 과제에서 각각 어떤 샘플링 전략을 사용합니까?	CAD	방법 및 절차	3	greedy decoding for knowledge conflict tasks and top-p sampling with p=0.9 for summarization tasks
ext_cad_007	CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?	CAD	방법 및 절차	3	OPT, GPT-Neo, LLaMA, and FLAN-T5
ext_cad_008	지식 충돌 과제에서 모델 크기가 커질수록 CAD의 성능 향상 폭은 어떤 경향을 보였습니까?	CAD	결과 및 비교	5	the gain increases as the model size grows

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_009	LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?	CAD	결과 및 비교	4	Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3
ext_cad_010	외부 컨텍스트가 생성 토큰과 조건부 독립이라면 α가 0이 아니어도 CAD의 출력 분포에는 어떤 영향이 있습니까?	CAD	사실 및 정의	2	even a non-zero α would not have an impact to the original output distribution
ext_cad_011	CAD는 특정 instruction-finetuned 언어 모델에만 제한됩니까, 아니면 어떤 언어 모델에도 적용 가능한 디코딩 전략입니까?	CAD	사실 및 정의	6	a decoding strategy applicable to any LM
ext_midm_001	Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	3	licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data
ext_midm_002	Mi:dm K 2.5 Pro는 한국어 중심 학습을 유지하기 위해 다국어 데이터를 한국어 코퍼스 대비 어느 정도 비율로 제한하며, 그 이유는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	3	3-10% of the Korean corpus, to encourage cross-lingual transfer without diluting the Korean-language focus
ext_midm_003	응답 스타일 재작성 후 평균 응답 길이는 몇 % 증가했고, bullet_count=0인 응답의 비율은 어떻게 변했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	8	mean response length increases by 256.70%; bullet_count = 0 drops from 82.8% to 3.9%
ext_midm_004	Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	15	interaction structure, topic and task, and persona
ext_midm_005	Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	21	to favor versatile conversational alignment; creative writing, translation, and general question answering
ext_midm_006	Fully asynchronous GSPO 학습은 synchronous 방식과 비교해 step time과 token throughput을 각각 어느 정도 개선했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	23	reduces step time by approximately 15% and improves token throughput by approximately 30%

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_midm_007	LLM-as-a-Judge 기반 reward signal은 사람의 평가와 어느 정도의 일치율을 보였습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	24	an agreement rate of 91%
ext_midm_008	Reasoning-enabled 평가에서 Mi:dm K 2.5 Pro가 HumanEval+와 τ²-Bench Telecom에서 기록한 점수는 각각 얼마입니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	25	HumanEval+ 92.07% and τ²-Bench Telecom 89%
ext_midm_009	한국어 red-teaming 평가에서 Mi:dm K 2.5 Pro의 Attack Success Rate는 얼마였으며 비교 모델들 가운데 어떤 수준이었습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	31	ASR of 36.3%, the lowest attack success rate among the compared models
ext_rag_001	Advanced RAG의 pre-retrieval 단계는 인덱스와 사용자 질의를 각각 어떤 방향으로 최적화합니까?	RAG Survey	방법 및 절차	4	optimizing the indexing structure and the original query
ext_rag_002	Advanced RAG의 post-retrieval 단계에서 사용되는 두 가지 핵심 방법은 무엇입니까?	RAG Survey	방법 및 절차	4	rerank chunks and context compressing
ext_rag_003	RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?	RAG Survey	방법 및 절차	8	Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.
ext_rag_004	문서 청크에 타임스탬프 같은 메타데이터를 부여하면 time-aware RAG는 최신 정보를 어떻게 우선할 수 있습니까?	RAG Survey	방법 및 절차	8	Assigning different weights to document timestamps during retrieval can achieve time-aware RAG, ensuring the freshness of knowledge and avoiding outdated information.
ext_rag_005	Reverse HyDE는 문서로부터 가상의 질문을 생성해 원래 질문과 답변 사이의 의미적 간극을 어떻게 줄입니까?	RAG Survey	방법 및 절차	8	using LLM to generate questions that can be answered by the document, then calculating the similarity between the original question and the hypothetical question

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_rag_006	Multi-Query와 Sub-Query 방식은 원래 질의를 확장하거나 분해하는 방식에서 어떻게 다릅니까?	RAG Survey	방법 및 절차	8	Multi-Query expands queries via LLMs for parallel execution; Sub-Query decomposes a complex question into simpler sub-questions.
ext_rag_007	Iterative Retrieval, Recursive Retrieval, Adaptive Retrieval은 검색을 반복하거나 중단하는 방식에서 각각 어떻게 구분됩니까?	RAG Survey	방법 및 절차	11	Iterative retrieval alternates retrieval and generation; recursive retrieval refines queries and breaks problems into sub-problems; adaptive retrieval determines whether retrieval is necessary and when to stop.
ext_rag_008	RAG 평가에서 요구되는 네 가지 핵심 능력은 무엇입니까?	RAG Survey	방법 및 절차	12	noise robustness, negative rejection, information integration, and counterfactual robustness
ext_rag_009	RAG 평가에서 Negative Rejection은 어떤 능력을 측정합니까?	RAG Survey	사실 및 정의	12	refraining from responding when the retrieved documents do not contain the necessary knowledge to answer a question
ext_rag_010	RAG와 파인튜닝을 비교할 때 지식 업데이트의 동적 특성과 해석 가능성 측면에서 RAG가 갖는 특징은 무엇입니까?	RAG Survey	결과 및 비교	5	real-time knowledge updates and effective utilization of external knowledge sources with high interpretability
ext_raptor_001	RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?	RAPTOR	방법 및 절차	3	length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk
ext_raptor_002	RAPTOR의 leaf node를 만들 때 텍스트 임베딩에 사용한 모델은 무엇입니까?	RAPTOR	방법 및 절차	3	SBERT, a BERT-based encoder (multi-qa-mpnet-base-cos-v1)
ext_raptor_003	RAPTOR의 GMM 클러스터링 전에 UMAP을 사용하는 이유는 무엇입니까?	RAPTOR	방법 및 절차	4	to mitigate the challenge of high-dimensional vector embeddings by dimensionality reduction
ext_raptor_004	RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?	RAPTOR	방법 및 절차	4	to determine the optimal number of clusters

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_raptor_005	RAPTOR에서 클러스터별 요약을 생성하는 데 사용한 언어 모델은 무엇입니까?	RAPTOR	방법 및 절차	4	gpt-3.5-turbo
ext_raptor_006	RAPTOR의 트리 구축 비용은 문서 길이가 증가할 때 build time과 token expenditure 측면에서 어떻게 확장됩니까?	RAPTOR	결과 및 비교	16	both build time and token expenditure scale linearly with document length
ext_raptor_007	QASPER 데이터셋은 몇 개의 질문과 NLP 논문으로 구성되며, 논문에서는 어떤 지표로 성능을 평가합니까?	RAPTOR	방법 및 절차	6	5,049 questions across 1,585 NLP papers; accuracy is measured using standard F1
ext_raptor_008	QuALITY-HARD는 일반 QuALITY 질문 중 어떤 기준을 만족하는 질문들로 구성됩니까?	RAPTOR	사실 및 정의	6	questions that a majority of human annotators answered incorrectly in a speed-setting
ext_raptor_009	QASPER에서 RAPTOR의 F1 Match 점수는 GPT-3, GPT-4, UnifiedQA를 사용할 때 각각 얼마였습니까?	RAPTOR	결과 및 비교	7	53.1%, 55.7%, and 36.6%, respectively
ext_raptor_010	QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?	RAPTOR	결과 및 비교	9	57.9 with one leaf layer versus 73.68 with all three layers
ext_raptor_011	Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?	RAPTOR	결과 및 비교	20	RAPTOR retrieves relevant information across tree layers, while DPR retrieves detailed descriptions of a narrow subset of the story
track1_0009	RAG가 LLM에서 사실적으로 부정확한 콘텐츠 생성을 줄이는 데 어떻게 기여합니까?	RAG Survey	목적 및 기여	1	By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content.
track1_0010	RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?	RAG Survey	방법 및 절차	3	The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework.

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0012	RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?	RAG Survey	목적 및 기여	1	This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.
track1_0015	RAG 프로세스에서 핵심적인 역할을 하는 세 가지 구성 기술은 무엇인가요?	RAG Survey	사실 및 정의	2	the aspects of Retrieval, Generation and Augmentation
track1_0016	RAG 방법론의 평가 방법은 어떻게 요약되어 있습니까?	RAG Survey	방법 및 절차	2	We have summarized the current assessment methods of RAG, covering 26 tasks, nearly 50 datasets, outlining the evaluation objectives and metrics, as well as the current evaluation benchmarks and tools.
track1_0019	LLaMA-30B 모델에 CAD를 적용했을 때 CNN-DM 데이터셋에서 어떤 성과가 있었나요?	CAD	결과 및 비교	3	Specifically, when applied to LLAMA-30B in CNN-DM, CAD leads to 21% increase in ROUGE-L, 14.3% increase in factKB and 7.8% increase in BERT-P.
track1_0021	CAD는 어떻게 잘못된 정보 생성을 줄이나요?	CAD	결과 및 비교	2	These results demonstrate the potential of CAD in mitigating hallucinations in text generation and overriding prior knowledge with reliable and trusted information.
track1_0023	CAD는 언어 모델이 생성하는 요약문의 사실적 정확성을 향상시키나요?	CAD	결과 및 비교	1	Experimental results from summarization tasks show that context-aware decoding significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs such as FLAN (Chung et al., 2022).

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0024	CAD를 적용하지 않은 경우와 비교했을 때, knowledge conflict QA 데이터셋에서 LLaMA-30B의 성능은 어떻게 변화하나요?	CAD	결과 및 비교	2	CAD brings a 2.9x improvement to LLaMA-30B on a knowledge conflicts QA dataset (Longpre et al., 2021).
track1_0025	RAPTOR 모델이 QuALITY 벤치마크에서 기존 성능을 얼마나 개선했나요?	RAPTOR	결과 및 비교	1	we can improve the best performance on the QuALITY benchmark by 20% in absolute accuracy.
track1_0026	RAPTOR의 트리 구조는 텍스트 클러스터링을 통해 어떻게 구축되나요?	RAPTOR	방법 및 절차	2	RAPTOR recursively clusters chunks of text based on their vector embeddings and generates text summaries of those clusters, constructing a tree from the bottom up.
track1_0027	RAPTOR가 여러 QA 작업에서 달성한 결과는 무엇인가요?	RAPTOR	결과 및 비교	2	RAPTOR coupled with GPT-4, and sometimes even with UnifiedQA, gives new state-of-the-art results on three QA tasks: free text response questions on books and movies (NarrativeQA, Ko˘cisk`y et al. 2018), full-text NLP papers (QASPER, Dasigi et al. 2021), and multiple-choice questions based on medium-length passages (QuALITY, Pang et al. 2022).
track1_0032	RAPTOR의 계층에서 검색된 노드가 어느 계층에서 오는지에 대한 연구 결과는 무엇인가요?	RAPTOR	결과 및 비교	22	We observe that between 18.5% to 57% of the retrieved nodes come from non-leaf nodes.
track1_0033	Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까?	Mi:dm K 2.5 Pro Technical Report	사실 및 정의	2	32B parameters
track1_0034	Mi:dm K 2.5 Pro의 방법론에서 AST 분석은 어떤 목적으로 사용됩니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	1	abstract syntax tree (AST) analysis for code
track1_0035	Mi:dm K 2.5 Pro 모델은 어떤 한국어 벤치마크에서 최첨단 결과를 달성했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	1	sets state-of-the-art results on Korean-specific benchmarks

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0036	Mi:dm K 2.5 Pro가 해결하려는 주요 문제는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	목적 및 기여	1	address enterprise-grade complexity through reasoning-focused optimization
track1_0037	Mi:dm K 2.5 Pro 모델의 컨텍스트 윈도우(context window) 길이는 얼마인가요?	Mi:dm K 2.5 Pro Technical Report	사실 및 정의	1	128K token context window
track1_0040	Mi:dm K 2.5 Pro의 사후 훈련 파이프라인에서 모델 병합은 어떤 역할을 합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	2	improve training stability and achieve balanced performance across complex reasoning, coding, instruction following, and agentic task execution

부록 B. 추가 사례 및 탐색 분석

B.1 저장된 생성·검색 사례

E06 | track1_0012
질문: RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?
A/B 검색 문맥, 검색 및 재정렬 ID 동일
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_rag_bf4cd54870dd_2, paper_nlp_rag_bf4cd54870dd
문맥[1] 발췌: [...] knowledge-intensive tasks across different topics, [28] revealed that while unsupervised fine-tuning shows some improvement, RAG consistently outperforms it, for both existing knowledge encountered du [...]
저장 답변 발췌: [...] ### 1. 외부 지식 활용의 우수성
논문에서는 "RAG excels in dynamic environments by offering realtime knowledge updates and effective utilization of external knowledge sources with high interpretability"라고 명시하고 있습니다. [...]
Faithfulness 0.9375 | Answer Relevancy 0.9001
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.4157
B | hyde_off__cad_only
HyDE OFF / CAD ON / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_rag_bf4cd54870dd_2, paper_nlp_rag_bf4cd54870dd
저장 답변 발췌: [...] 논문]
위 내용 참조
**
답변을 뒷받침하는 구체적인 예시나 연구 결과도 포함해 주세요.
breath
** [...]
Faithfulness 0.5000 | Answer Relevancy 0.0000
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.8462
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 사례

E04 | ext_midm_004
질문: Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?
A/B 검색 문맥, 검색 및 재정렬 ID 변경
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_88a1c1d7a494, paper_midm_6954efe611cf
문맥[1] 발췌: [...] complex tasks. Furthermore, we have expanded Mi:dm K from a Korean-English bilingual model to a multilingual model supporting four languages, including Japanese and Chine [...]
저장 답변 발췌: [...] 제공된 논문 컨텍스트를 면밀히 검토한 결과, Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터가 어떤 세 가지 차원을 기준으로 고품질 대화를 설계하는지에 관한 구체적인 정보를 확인할 수 없습니다. [...]
Faithfulness 0.9000 | Answer Relevancy 0.0000
Context Precision 0.0000 | Context Recall 0.0000
전체 답변 한국어 비율 0.8250
B | hyde_on__no_decoder_control
HyDE ON / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_b8ec113edfbf, paper_midm_94d24ba9b194
문맥[4] 발췌: [...] We define high quality multi-turn conversations along three dimensions: interaction structure, topic and task, and persona. [...]
저장 답변 발췌: [...] **1. 상호작용 구조(Interaction Structure) 차원** [...]
저장 답변 발췌: [...] **2. 주제 및 과제(Topic and Task) 차원** [...]
저장 답변 발췌: [...] **3. 페르소나(Persona) 차원** [...]
Faithfulness 0.8824 | Answer Relevancy 0.8531
Context Precision 0.3250 | Context Recall 1.0000
전체 답변 한국어 비율 0.6773
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-2] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례

E05 | ext_midm_001
질문: Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?
A/B 검색 문맥, 검색 및 재정렬 ID 동일
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_6954efe611cf, paper_midm_88370fe7a52d
문맥[2] 발췌: [...] licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data. [...]
저장 답변 발췌: [...] **1. 라이선스 보유 독점(proprietary) 데이터셋** [...]
저장 답변 발췌: [...] **2. 상업적 이용이 허가된 공개(public) 데이터셋** [...]
저장 답변 발췌: [...] **3. 자체(in-house) 합성(synthetic) 데이터** [...]
Faithfulness 0.8333 | Answer Relevancy 0.8261
Context Precision 0.5833 | Context Recall 1.0000
전체 답변 한국어 비율 0.7606
B | hyde_off__cad_only
HyDE OFF / CAD ON / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_6954efe611cf, paper_midm_88370fe7a52d
저장 답변 발췌: [...] **1. Licensed Proprietary Datasets (라이선스 취득 전용 데이터셋)** [...]
저장 답변 발췌: [...] **2. Public Datasets Permitting Commercial Use (상업적 이용이 허용된 공개 데이터셋)** [...]
저장 답변 발췌: [...] **3. In-house Synthetic Data (자체 생성 합성 데이터)** [...]
Faithfulness 1.0000 | Answer Relevancy 0.8124
Context Precision 0.5833 | Context Recall 1.0000
전체 답변 한국어 비율 0.7466
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-3] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례

E02 | ext_cad_007
질문: CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?
A | hyde_on__cad_only
HyDE ON / CAD ON / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_cad_363806f889e1, paper_nlp_cad_6d4aeefa6dab
문맥[1] 발췌: [...] CAD can be used with off-the-shelf pretrained language models without any additional training. [...]
저장 답변 발췌: [...] . Improving transformer generalization through weight normalization. _arXiv preprint arXiv:2204.03296_. Sheng-Hong Huang, Xiaodan Zheng, and Jianfeng Gao. 2018. Factually faithful abstractive summarization. In _Proceedings of the 2018 Conference [...]
Faithfulness 0.0769 | Answer Relevancy 0.4602
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.0000
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-4] SCD 미적용 조건의 영어 중심 출력 사례

E03 | ext_midm_005
질문: Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?
A/B 검색 문맥, 검색 및 재정렬 ID 동일
A | hyde_on__no_decoder_control
HyDE ON / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_5fd8fb92ae53, paper_midm_fe2d192ffc71
문맥[1] 발췌: [...] In the Fusion SFT phase, we partition the training data into reasoning and non-reasoning subsets. We deliberately emphasize non-reasoning tasks that are relatively underrepresented in earlier stages, including creative writing, translation, and general question answering. [...]
저장 답변 발췌: [...] tasks such as math problems, code snippets, and general knowledge questions, with a composition of 29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, we apply a model merging technique using checkpoints saved at regular intervals [25]. [...]
Faithfulness 0.8125 | Answer Relevancy 0.4632
Context Precision 0.8667 | Context Recall 1.0000
전체 답변 한국어 비율 0.0000
B | hyde_on__scd_only
HyDE ON / CAD OFF / SCD ON
검색 ID (앞 2개 / 전체 8개): paper_midm_5fd8fb92ae53, paper_midm_fe2d192ffc71
저장 답변 발췌: [...] tasks such as math problems, code snippets, and general knowledge questions, with a composition of 29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, 우리는 정기적인 간격으로 저장된 체크포인트를 사용한 모델 병합 기법을 적용합니다 [25]. 단계 1의 최종 체크포인트와 비교하여, 병합된 모델은 대부분의 평가 지표에서 향상된 성능을 보여주며, GSM8K [15]를 제외하고는 그렇습니다. CPT 단계 2에서는 이전 단계에 비해 [...]
Faithfulness 0.8889 | Answer Relevancy 0.5231
Context Precision 0.8667 | Context Recall 1.0000
전체 답변 한국어 비율 0.7713
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-5] SCD 적용 전후 한국어 문자 비율 변화 사례

E03은 HyDE ON 사례로 전체 상태 일치 비교에 속한다. 주 비교의 HyDE OFF 동일 문맥 120쌍과 구분한다. 각 그림은 저장된 답변의 발췌이며, 전체 원문과 지표는 연결된 생성·평가 기록에서 확인할 수 있다.

B.2 문서별 및 질문 유형별 탐색 분석

[표 B-1] 문서별 HyDE·CAD 대응 점수 차이의 평균(SD)

집단	요인	지표	유효 n	평균 차이(SD)
CAD	HyDE	근거 충실도	15	−0.049 (0.260)
CAD	HyDE	답변 관련성	15	−0.002 (0.287)
CAD	HyDE	문맥 정밀도	15	−0.082 (0.203)
CAD	HyDE	문맥 재현율	15	−0.067 (0.258)
CAD	CAD	근거 충실도	15	0.066 (0.227)
CAD	CAD	답변 관련성	15	−0.010 (0.126)
CAD	CAD	문맥 정밀도	15	−0.055 (0.131)
CAD	CAD	문맥 재현율	15	−0.067 (0.258)
Mi:dm K 2.5 Pro Technical Report	HyDE	근거 충실도	15	0.001 (0.198)
Mi:dm K 2.5 Pro Technical Report	HyDE	답변 관련성	15	0.099 (0.244)
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 정밀도	15	−0.014 (0.240)
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 재현율	15	0.133 (0.352)
Mi:dm K 2.5 Pro Technical Report	CAD	근거 충실도	15	0.008 (0.171)
Mi:dm K 2.5 Pro Technical Report	CAD	답변 관련성	15	0.034 (0.362)
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 정밀도	15	0.000 (0.000)
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 재현율	15	0.000 (0.000)
RAG Survey	HyDE	근거 충실도	15	0.157 (0.361)
RAG Survey	HyDE	답변 관련성	15	0.131 (0.134)
RAG Survey	HyDE	문맥 정밀도	15	0.004 (0.258)
RAG Survey	HyDE	문맥 재현율	15	0.067 (0.258)
RAG Survey	CAD	근거 충실도	13	−0.042 (0.381)
RAG Survey	CAD	답변 관련성	15	−0.100 (0.322)
RAG Survey	CAD	문맥 정밀도	15	0.007 (0.062)
RAG Survey	CAD	문맥 재현율	15	0.000 (0.000)

집단	요인	지표	유효 n	평균 차이(SD)
RAPTOR	HyDE	근거 충실도	15	0.065 (0.266)
RAPTOR	HyDE	답변 관련성	15	0.093 (0.396)
RAPTOR	HyDE	문맥 정밀도	15	−0.044 (0.248)
RAPTOR	HyDE	문맥 재현율	15	−0.133 (0.516)
RAPTOR	CAD	근거 충실도	15	0.073 (0.224)
RAPTOR	CAD	답변 관련성	15	0.047 (0.385)
RAPTOR	CAD	문맥 정밀도	15	0.011 (0.031)
RAPTOR	CAD	문맥 재현율	15	0.000 (0.000)

[표 B-2] 질문 유형별 HyDE·CAD 대응 점수 차이의 평균(SD)

집단	요인	지표	유효 n	평균 차이(SD)
결과 및 비교	HyDE	근거 충실도	20	−0.051 (0.176)
결과 및 비교	HyDE	답변 관련성	20	−0.022 (0.207)
결과 및 비교	HyDE	문맥 정밀도	20	−0.029 (0.153)
결과 및 비교	HyDE	문맥 재현율	20	−0.050 (0.394)
결과 및 비교	CAD	근거 충실도	20	−0.004 (0.149)
결과 및 비교	CAD	답변 관련성	20	−0.068 (0.302)
결과 및 비교	CAD	문맥 정밀도	20	−0.012 (0.081)
결과 및 비교	CAD	문맥 재현율	20	−0.050 (0.224)
목적 및 기여	HyDE	근거 충실도	3	0.188 (0.272)
목적 및 기여	HyDE	답변 관련성	3	−0.029 (0.052)
목적 및 기여	HyDE	문맥 정밀도	3	−0.111 (0.229)
목적 및 기여	HyDE	문맥 재현율	3	0.000 (0.000)
목적 및 기여	CAD	근거 충실도	3	−0.160 (0.241)
목적 및 기여	CAD	답변 관련성	3	−0.314 (0.508)
목적 및 기여	CAD	문맥 정밀도	3	0.000 (0.000)
목적 및 기여	CAD	문맥 재현율	3	0.000 (0.000)
방법 및 절차	HyDE	근거 충실도	29	0.079 (0.343)
방법 및 절차	HyDE	답변 관련성	29	0.172 (0.339)
방법 및 절차	HyDE	문맥 정밀도	29	−0.003 (0.252)
방법 및 절차	HyDE	문맥 재현율	29	0.069 (0.371)
방법 및 절차	CAD	근거 충실도	27	0.082 (0.325)
방법 및 절차	CAD	답변 관련성	29	0.068 (0.326)
방법 및 절차	CAD	문맥 정밀도	29	0.003 (0.015)
방법 및 절차	CAD	문맥 재현율	29	0.000 (0.000)
사실 및 정의	HyDE	근거 충실도	8	0.097 (0.221)
사실 및 정의	HyDE	답변 관련성	8	0.045 (0.088)
사실 및 정의	HyDE	문맥 정밀도	8	−0.133 (0.337)
사실 및 정의	HyDE	문맥 재현율	8	−0.125 (0.354)
사실 및 정의	CAD	근거 충실도	8	0.000 (0.174)
사실 및 정의	CAD	답변 관련성	8	−0.014 (0.084)
사실 및 정의	CAD	문맥 정밀도	8	−0.049 (0.170)
사실 및 정의	CAD	문맥 재현율	8	0.000 (0.000)

하위집단 표는 탐색적 기술통계다. 질문 유형의 질의 수는 사실·정의 8, 방법·절차 29, 결과·비교 20, 목적·기여 3개이며, 결측이 있는 비교는 표의 유효 n을 사용하였다.