졸업자격실험보고서

한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

지도교수 [지도교수 입력]

[소속 학과 입력]
[소속 대학·캠퍼스 입력]

[학생명 입력], [학번 입력]

[제출연도 입력]

졸업자격실험보고서

한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

Combination Experiments of HyDE, CAD, and SCD in RAG for Searching English Academic and Technical Documents with Korean Queries

[학생명 입력], [학번 입력]

지도교수 [지도교수 입력]

본 보고서를 졸업자격 실험보고서로 제출함.
[제출일 입력]

[학생명 입력]의 졸업자격 실험보고 통과를 인준함.
[인준일 입력]

주심 [주심 입력] (인)
부심 [부심 입력] (인)

[소속 대학·캠퍼스 입력] [소속 학과 입력]

목 차

1. 서론 ····· 1

1.1 연구배경 및 목적 ····· 1

1.2 연구범위 ····· 2

1.3 연구 질문 및 논문 구성 ····· 2

2. 이론적 배경 ····· 3

2.1 Retrieval-Augmented Generation ····· 3

2.2 하이브리드 검색과 재정렬 ····· 3

2.3 가상 문서 임베딩과 검색 ····· 4

2.4 Context-Aware Decoding ····· 4

2.5 Soft Constrained Decoding과 언어 이탈 ····· 5

2.6 RAG 평가 ····· 6

2.7 관련 연구와 본 연구의 위치 ····· 6

3. 시스템 설계 ····· 9

3.1 연구 및 실험 요구사항 ····· 9

3.2 아키텍처 설계 ····· 9

3.3 완전요인 실험 및 대응 비교 설계 ····· 9

4. 프로그램 구현 ····· 10

4.1 시스템 환경 ····· 10

4.2 시스템 구성 ····· 10

4.3 시스템 구현과 실행 기록 ····· 11

5. 실험 ····· 12

5.1 평가 대상 및 질의 구성 ····· 12

5.2 평가 지표와 해석 기준 ····· 12

5.3 실험 조건 및 평가 절차 ····· 13

5.4 통계 분석 방법 ····· 14

5.5 조합별 평가 결과 ····· 16

5.6 연구 질문별 대응 비교 ····· 17

5.7 요인 주효과 및 상호작용 ····· 18
5.8 종합 논의 ····· 21
5.9 평가 범위와 후속 검증 ····· 21
6. 결론 ····· 22
6.1 연구 질문별 결과 ····· 22
6.2 연구의 의의 ····· 22
6.3 적용 조건과 후속 연구 ····· 22
참고문헌 ····· 23
부록 A. 60개 질의 목록 ····· 27
부록 B. 추가 사례 및 탐색 분석 ····· 35
B.1 저장된 생성·검색 사례 ····· 35
B.2 문서별 및 질문 유형별 탐색 분석 ····· 39
B.3 품질 지표의 반복측정 ANOVA ····· 42

그 림 목 차

[그림 1-1] 한국어 질의와 영어 학술·기술 문서를 사용하는 RAG 실험 환경 ····· 1
[그림 2-1] RAG의 검색기-생성기 구조 ····· 3
[그림 2-2] HyDE의 가상 문서 기반 검색 구조 ····· 4
[그림 2-3] CAD의 문맥 포함·제외 로짓 결합 ····· 5
[그림 2-4] SCD의 토큰 그룹별 로짓 조정 ····· 6
[그림 4-1] 한국어 질의의 검색·융합·재정렬 및 답변 생성 흐름 ····· 11
[그림 5-1] 질의별 생성 기록과 평가값을 연결하는 대응 비교 절차 ····· 13
[그림 5-2] RAPTOR 질의의 검색 근거, 생성 답변 및 평가 예시 ····· 14
[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 사례 ····· 35
[그림 B-2] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례 ····· 36
[그림 B-3] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례 ····· 37
[그림 B-4] SCD 미적용 조건의 영어 중심 출력 사례 ····· 37
[그림 B-5] SCD 적용 전후 한국어 문자 비율 변화 사례 ····· 38

표 목 차

[표 2-1] 선행연구의 접근과 본 연구의 비교 질문 ····· 8
[표 3-1] HyDE·CAD·SCD의 3요인 2수준 실험 조건 ····· 9
[표 4-1] 검색·재정렬·생성 단계의 모델과 공통 실행 설정 ····· 10
[표 5-1] 평가 문맥 언어별 8조건의 품질 및 한국어 문자 비율 평균(SD) ····· 16
[표 5-2] 8조건의 조건 실행 시간 평균, 표준편차와 중앙값 ····· 17
[표 5-3] 연구 질문별 핵심 지표의 대응 t-검정 ····· 17
[표 5-4] 한국어 문자 비율의 H×C×S 반복측정 ANOVA ····· 19
[표 5-5] 조건 실행 시간의 H×C×S 반복측정 ANOVA ····· 19
[표 5-6] 유의한 상호작용의 단순 효과 대응 t-검정 ····· 19
[표 5-7] 보조 지표의 대응 t-검정 ····· 20
[표 A-1] 60개 한국어 질의의 대상 문서·유형·원문 페이지 및 정답 근거 ····· 27
[표 B-1] 문서별 HyDE·CAD 대응 점수 차이의 평균(SD) ····· 39
[표 B-2] 질문 유형별 HyDE·CAD 대응 점수 차이의 평균(SD) ····· 41
[표 B-3] SCD OFF 영어 평가 문맥의 품질 지표 H×C 반복측정 ANOVA ····· 42
[표 B-4] SCD ON 한국어 번역 평가 문맥의 품질 지표 H×C 반복측정 ANOVA 42

1. 서론

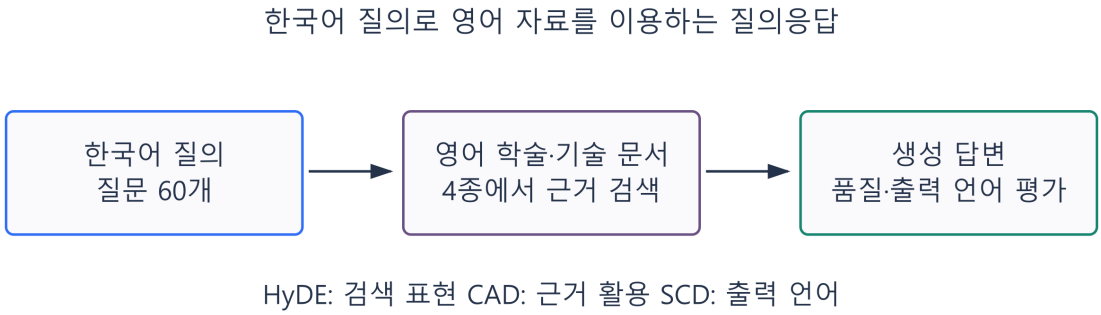
1.1 연구배경 및 목적

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 질문과 관련된 문서 구간을 외부 자료에서 검색하고, 검색한 텍스트를 생성 모델의 입력에 넣어 답변을 만드는 방법이다[1]. 모델이 학습하지 않은 최신 논문이나 기술 문서에 대해서도 원문을 근거로 답할 수 있어 학술 문서 질의응답에 널리 쓰인다.

RAG의 성능은 검색 단계와 생성 단계 모두에서 개선할 수 있다. 가상 문서 임베딩(Hypothetical Document Embeddings, HyDE)은 질문으로 답변 형태의 가상 문서를 먼저 생성하고, 이 문서의 임베딩으로 실제 문서를 검색한다[2]. 문맥 인식 디코딩(Context-Aware Decoding, CAD)은 검색 문맥이 있을 때와 없을 때의 다음 토큰 점수를 비교하여, 문맥이 지지하는 토큰을 더 강하게 선택하게 한다[3]. 소프트 제약 디코딩(Soft Constrained Decoding, SCD)은 목표 언어 토큰의 점수를 높이고 다른 언어 토큰의 점수를 낮추어 출력 언어를 제어한다[4].

한국어 사용자가 영어 논문을 검색할 때에는 두 가지 문제가 함께 나타난다. 첫째, 한국어 질문과 영어 원문은 같은 개념을 다른 어휘로 표현하므로 질문에 맞는 근거를 찾기 어렵다. 둘째, 생성 모델이 영어 근거를 그대로 따라 영어로 답하는 언어 이탈(language drift)이 발생한다. HyDE는 첫째 문제와, SCD는 둘째 문제와 관련되며, CAD는 검색한 근거를 답변에 반영하는 정도와 관련된다. 그러나 세 기법은 서로 다른 모델과 과제에서 따로 제안되고 평가되었으며, 한국어 질문과 영어 문서를 사용하는 하나의 RAG 파이프라인에서 함께 비교한 결과는 확인하기 어렵다.

본 연구는 영어 학술·기술 문서를 검색하여 한국어로 답하는 고정 파이프라인 Paper-RAG를 구성하고, HyDE·CAD·SCD의 적용 여부를 조합한 8개 조건(RAG-Cube)을 같은 한국어 질의 60개에 적용하였다(그림 1-1). 각 기법을 단독으로 켰을 때의 변화와 세 기법을 조합했을 때의 효과를 답변 품질, 출력 언어, 실행 시간으로 측정하고 통계적으로 검정하였다.



[그림 1-1] 한국어 질의와 영어 학술·기술 문서를 사용하는 RAG 실험 환경

1.2 연구범위

검색 대상은 RAG Survey[D1], CAD[D2], RAPTOR[D3], Mi:dm K 2.5 Pro Technical Report[D4]의 영어 문서 4종이다. 문서마다 한국어 질의 15개를 작성하여 총 60개를 구성하였고, 각 질의는 지정한 문서 안에서만 검색하였다. 질의마다 8개 조건을 적용하여 생성 답변 480개를 얻었다.

답변 생성 모델은 Mi:dm 2.0 Base Instruct[M1]이다. 답변 품질은 RAGAS의 네 지표로, 출력 언어는 한국어 문자 비율로, 비용은 조건 실행 시간으로 측정하였다. 검색·재정렬·생성 설정은 4장에 정리하였다.

1.3 연구 질문 및 논문 구성

각 연구 질문은 해당 기법의 목적에 맞는 지표 하나를 핵심 지표로 정하였다.

RQ1. CAD와 SCD를 적용하지 않은 조건에서, 번역과 가상 문서 생성을 포함한 HyDE 검색은 답변 관련성을 높이는가?

RQ2. 같은 검색 문맥을 사용할 때, CAD는 답변의 근거 충실도를 높이는가?

RQ3. SCD는 생성 답변의 한국어 문자 비율을 높이는가?

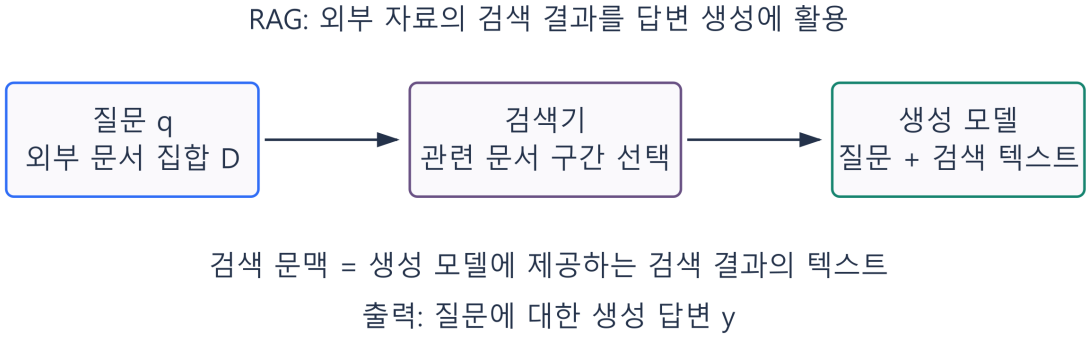
RQ4. HyDE·CAD·SCD를 조합하면 한국어 문자 비율과 실행 시간에 주효과와 상호작용이 나타나는가?

RQ1~RQ3은 대응 t-검정으로, RQ4는 반복측정 분산분석(ANOVA)으로 분석하였다. 나머지 품질 지표는 보조 결과로 함께 보고한다. 2장에서는 세 기법과 관련 연구를, 3장과 4장에서는 실험 설계와 구현을, 5장에서는 평가 방법과 결과를, 6장에서는 결론을 제시한다.

2. 이론적 배경

2.1 Retrieval-Augmented Generation

Lewis 외[1]의 RAG는 검색기(retriever)가 외부 문서 인덱스에서 관련 문서를 찾고, 생성기(generator)가 질의와 검색 문서를 함께 입력받아 답변을 생성하는 구조다(그림 2-1).



[그림 2-1] RAG의 검색기-생성기 구조

본 연구에서 작성한 도식이며, Lewis 외[1]의 RAG 구조를 참고하였다.

질의를 q, 문서 집합을 D라 하면 검색기는 D에서 질의와 관련된 문맥 C_q를 선택하고, 생성 모델은 q와 C_q를 입력받아 답변 y를 생성한다. 본 논문에서 검색 문맥은 C_q, 즉 생성 모델에 실제로 입력한 문서 구간의 텍스트를 뜻한다.

$$C_q = Retrieve(q, D)$$

$$y = LM(q, C_q)$$

2.2 하이브리드 검색과 재정렬

밀집 검색은 질의와 문서 구간을 임베딩한 벡터의 유사도로, BM25 희소 검색은 두 텍스트의 어휘 일치로 관련 구간을 찾는다[5][6]. 한국어 질문과 영어 원문은 어휘가 거의 겹치지 않지만, 논문명·모델명·데이터셋명·수치처럼 두 언어에 같은 형태로 쓰이는 표기는 BM25의 검색 단서가 된다.

두 검색 결과는 가중 역순위 융합(weighted Reciprocal Rank Fusion, RRF)으로 결합한다[7]. 문서 d의 밀집 검색 순위와 BM25 순위를 각각 rank_dense(d), rank_BM25(d)라 할 때, 가중치 0.6과 0.4, 상수 k=60을 적용한 결합 점수는 다음과 같다.

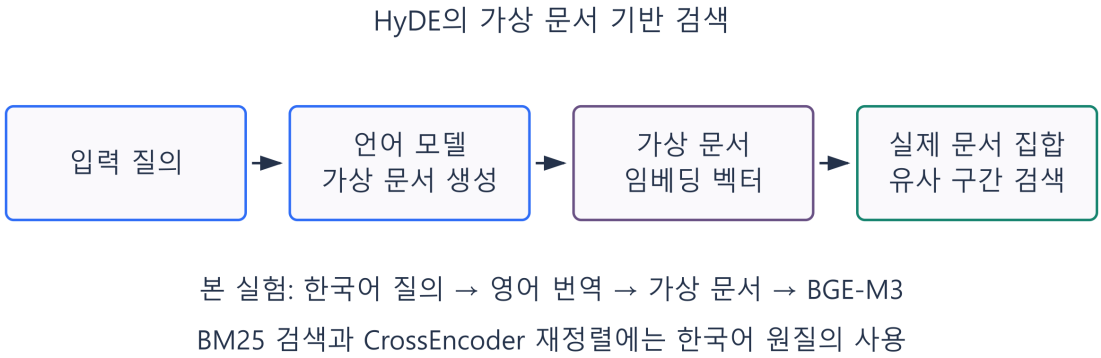
$$RRF(d) = \frac{0.6}{k + rank_{dense(d)}} + \frac{0.4}{k + rank_{BM25(d)}}$$

결합한 후보는 재정렬 모델로 다시 정렬한다. 재정렬 모델은 질의와 후보 구간을 한 쌍으로 입력받아 관련성 점수를 계산하며, CEDR[8]처럼 문맥화된 언어 모델 표현을 순위 계산에 활용하는 방식이 대표적이다. 생성 모델은 입력 내 위치에 따라 근거를 다르게 활용할 수 있으

므로[9], 재정렬 순서는 최종 문맥의 배치에도 영향을 준다.

2.3 가상 문서 임베딩과 검색

HyDE는 입력 질의를 바탕으로 가상 문서를 생성한 뒤, 이를 임베딩 벡터로 변환한다. 생성된 벡터로 실제 문서 집합에서 유사한 문서를 검색한다[2]. 가상 문서의 내용이 틀릴 수 있어도 답변과 비슷한 어휘와 문장 구조를 갖기 때문에, 짧은 질문을 그대로 임베딩할 때보다 관련 문서에 가까운 검색 입력을 얻을 수 있다. 최종 답변의 근거는 가상 문서가 아니라 검색한 실제 문서 구간이다(그림 2-2).



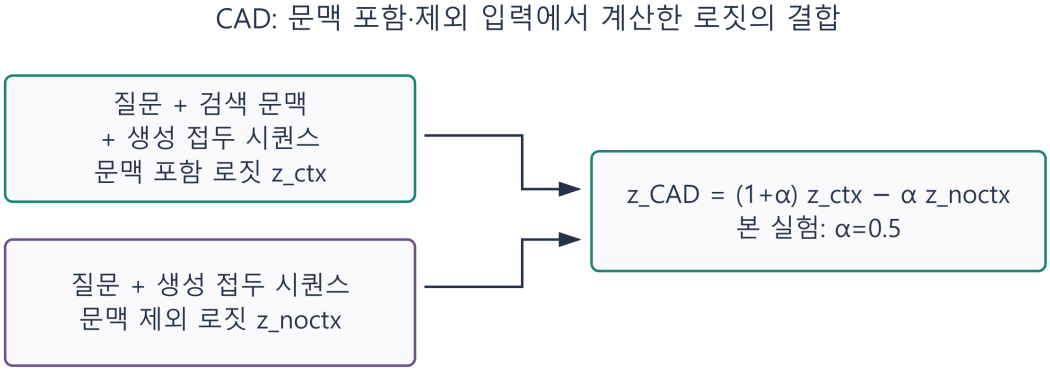
[그림 2-2] HyDE의 가상 문서 기반 검색 구조

본 연구에서 작성한 도식이며, Gao 외[2]의 HyDE 구조를 참고하였다.

Gao 외[2]는 관련성 레이블 없이 수행하는 검색에서 HyDE가 Contriever보다 높은 성능을 보이며, 한국어를 포함한 비영어 검색에서도 효과가 있음을 보고하였다. 본 연구에서는 한국어 질의를 영어로 번역한 뒤 영어 가상 문서를 생성하였으므로, HyDE 조건의 변화에는 번역과 가상 문서 생성의 효과가 함께 포함된다.

2.4 Context-Aware Decoding

CAD는 검색 문맥을 포함한 경우와 제외한 경우에 계산한 다음 토큰의 점수를 비교하는 디코딩 방법이다[3]. 두 점수의 차이가 큰 토큰은 문맥 덕분에 선택되는 토큰이므로, 이 차이를 키우면 모델의 사전 지식보다 문맥의 내용을 따르는 답변이 생성된다(그림 2-3).



[그림 2-3] CAD의 문맥 포함·제외 로짓 결합

본 연구에서 작성한 도식이며, Shi 외[3]의 CAD 로짓 결합을 참고하였다.

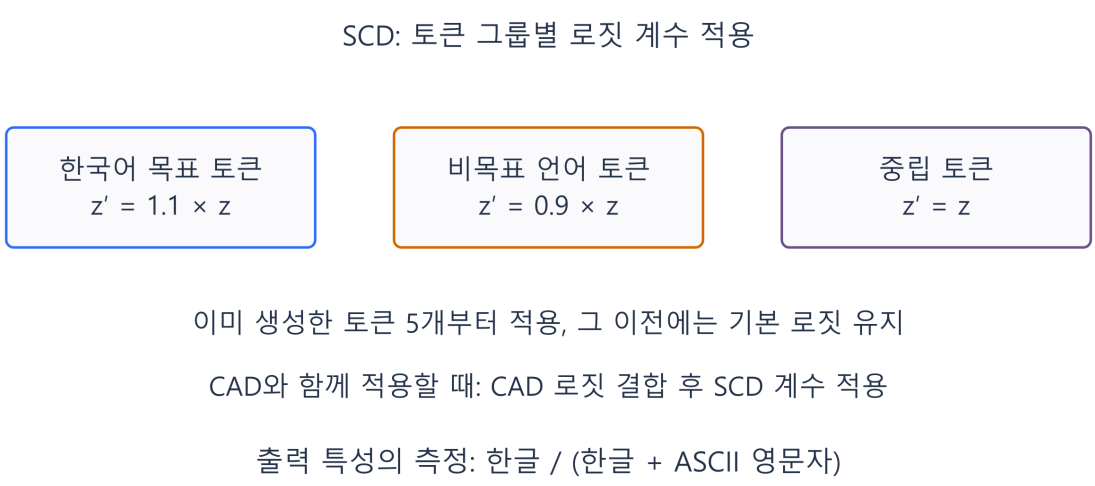
같은 생성 접두 시퀀스에서 문맥을 포함한 로짓을 z_ctx, 문맥을 제외한 로짓을 z_noctx라 하면 CAD의 로짓은 다음과 같다. α는 문맥의 영향을 키우는 정도이며 α=0이면 일반 디코딩과 같다.

$$z_{CAD} = (1+\alpha) z_{ctx} - \alpha z_{noctx}$$

Shi 외[3]는 요약 과제와, 모델의 사전 지식이 문맥과 충돌하는 지식 충돌 과제에서 CAD가 문맥 반영을 높인다고 보고하였다. CAD는 토큰마다 문맥을 제외한 입력을 한 번 더 계산하므로 생성 시간이 늘어난다.

2.5 Soft Constrained Decoding과 언어 이탈

다국어 RAG에서는 질문과 다른 언어의 문서를 검색하면 답변이 검색 문서의 언어로 바뀌는 언어 이탈이 발생할 수 있다. Li 외[4]는 이 현상을 분석하고, 디코딩 단계에서 목표 언어 토큰의 점수를 조정하는 SCD를 제안하였다. SCD는 어휘 집합을 목표 언어 토큰, 비목표 언어 토큰과 숫자·기호 같은 중립 토큰으로 나누어 로짓을 조정한다(그림 2-4).



[그림 2-4] SCD의 토큰 그룹별 로짓 조정

본 연구에서 작성한 도식이며, Li 외[4]의 SCD 토큰별 점수 조정을 참고하였다.

생성한 토큰 수가 Tstart 이상이 되면 목표 언어 토큰의 로짓 z_i에는 α를, 비목표 언어 토큰의 로짓에는 β를 곱하고, 중립 토큰은 그대로 둔다. 본 연구는 한국어를 목표 언어로 하여 원 논문의 곱셈식을 그대로 적용하였다.

$$\tilde{z}_i = \alpha z_i$$

$$\tilde{z}_i = \beta z_i$$

$$\tilde{z}_i = z_i$$

2.6 RAG 평가

RAGAS(Retrieval Augmented Generation Assessment)는 참조 답변 없이도 RAG의 검색과 생성을 나누어 평가할 수 있도록 제안된 자동 평가 프레임워크다[10]. 평가 모델(LLM)이 답변을 주장 단위로 나누고 각 주장이 검색 문맥에 근거하는지 판정하는 방식으로 근거 충실도(faithfulness)를 계산하며, 답변 관련성(answer relevancy), 문맥 정밀도(context precision), 문맥 재현율(context recall)도 함께 제공한다. 근거 충실도와 답변 관련성은 생성 답변을, 문맥 정밀도와 문맥 재현율은 검색 문맥을 평가한다. 본 연구에서 사용한 지표별 계산 방식은 5.2절에 정리하였다.

2.7 관련 연구와 본 연구의 위치

RAG의 검색 구조는 질의와 문서를 각각 임베딩하는 Dense Passage Retrieval[11]과 여러 검색 구간을 디코더에서 함께 활용하는 Fusion-in-Decoder[12]를 거쳐 발전하였다. 생성 단계에서는 출력 분포를 직접 조정하는 디코딩 기법이 연구되었다. Contrastive Decoding[13]은 큰 모델과 작은 모델의 로그확률 차이로 토큰을 선택하며, CAD는 같은 모델에서 문맥을 포함한 입력과 제외한 입력을 대조한다는 점에서 다르다.

검색 단위와 검색 시점을 조정하는 연구도 이어졌다. RAPTOR[14]는 문서 청크를 반복적으로 군집화하고 요약하여 계층적 검색 구조를 만들며, 본 실험의 검색 대상 문서[D3]이기도 하다. Self-RAG[15]는 검색 필요성과 생성 결과를 스스로 평가하고, Adaptive-RAG[16]는 질문의 복잡도에 따라 검색 전략을 선택한다. 검색과 생성의 구성 요소별 기법은 Zhao 외[17]와 Fan 외[18]의 조사 연구에 정리되어 있으며, 검색 모델의 성능 비교에는 BEIR[19]와 MTEB[20] 같은 공개 벤치마크가 쓰인다.

이들 연구는 검색 전략이나 디코딩 기법을 각각 개선하는 데 초점을 둔다. 본 연구는 검색·생성 백본을 고정한 채 검색 입력(HyDE)과 디코딩 제어(CAD, SCD)를 함께 바꾸어, 한국어 질의-영어 문서 환경에서 각 기법의 단독 효과와 조합 효과를 비교한다. 표 2-1에 주요 선행 연구와 본 연구의 비교 질문을 정리하였다.

[표 2-1] 선행연구의 접근과 본 연구의 비교 질문

연구	핵심 접근	본 연구의 비교 질문
HyDE[2]	가상 문서를 임베딩하여 검색	번역과 가상 문서 검색에 따른 답변 관련성 차이
CAD[3]	문맥 포함·제외 로짓의 결합	같은 검색 문맥에서 근거 충실도와 실행 시간 차이
SCD[4]	언어별 토큰 로짓의 조정	한국어 문자 비율 차이와 다른 기법과의 상호작용
DPR[11], FiD[12]	밀집 검색과 다중 검색 구간 활용	고정 검색·생성 백본의 구성
Self-RAG[15], Adaptive-RAG[16]	자기평가와 질문 복잡도에 따른 검색 전략 선택	고정 백본에서 검색 입력·디코딩 조합의 효과
RAGAS[10], BEIR[19], MTEB[20]	RAG 자동 평가와 검색·임베딩 벤치마크	고정 문서 집합에서 질의별 대응 비교

3. 시스템 설계

3.1 연구 및 실험 요구사항

세 기법의 효과를 비교하려면 기법 이외의 조건이 모든 실험 조건에서 같아야 한다. 따라서 검색·재정렬·생성 모델과 공통 파라미터를 고정하고, 질의마다 검색 결과, 생성 답변, 실행 시간과 적용 파라미터를 저장하여 질의 ID로 조건 간 결과를 연결하였다.

3.2 아키텍처 설계

Paper-RAG는 한국어 질의와 대상 문서를 입력받아 검색 후보를 구성하고, 선택한 문맥을 답변 생성 모듈에 전달한다. HyDE를 적용하면 밀집 검색의 입력이 원질의에서 가상 문서로 바뀌며, BM25 검색과 재정렬에는 항상 한국어 원질의를 사용한다. 두 검색 결과는 가중 RRF로 결합한 뒤 CrossEncoder로 재정렬하고, 상위 5개 구간을 생성 모델에 입력한다. CAD와 SCD는 생성 단계의 로짓에 적용하며, 함께 적용할 때에는 CAD로 로짓을 결합한 다음 SCD의 언어별 계수를 곱한다.

3.3 완전요인 실험 및 대응 비교 설계

HyDE, CAD, SCD를 각각 미적용(0)과 적용(1)의 두 수준으로 둔 2^3 완전요인설계를 사용하였다(표 3-1). 조건명의 H, C, S는 각각 HyDE, CAD, SCD를 뜻한다. 같은 질의 60개를 8개 조건에 모두 적용하였으므로, 질의가 반복측정의 단위가 된다. 각 질의·조건의 답변은 한 번씩 생성하였다.

[표 3-1] HyDE·CAD·SCD의 3요인 2수준 실험 조건

조건	H	C	S
H0C0S0	0	0	0
H0C0S1	0	0	1
H0C1S0	0	1	0
H0C1S1	0	1	1
H1C0S0	1	0	0
H1C0S1	1	0	1
H1C1S0	1	1	0
H1C1S1	1	1	1

이 설계에서는 두 종류의 비교가 가능하다. 단순 비교는 다른 두 기법의 수준을 고정하고 한 기법만 켜고 끈 두 조건을 비교한다. 예를 들어 HyDE의 단순 비교는 H0C0S0과 H1C0S0을, CAD의 단순 비교는 H0C0S0과 H0C1S0을 비교한다. CAD 비교에서는 두 조건의 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 모두 같음을 확인하였다. 요인 분석은 8개 조건 전체를 사용하여, 다른 기법의 수준을 평균한 각 기법의 주효과와, 한 기법의 효과가 다른 기법의 적용 여부에 따라 달라지는 상호작용을 검정한다.

4. 프로그램 구현

4.1 시스템 환경

표 4-1은 모든 조건에 공통으로 적용한 검색·재정렬·생성 설정과 기법별 파라미터다. 청크 분할과 문맥 길이는 공백 기준 단어 수로, 답변 길이는 생성 모델의 토큰 수로 계산하였다.

[표 4-1] 검색·재정렬·생성 단계의 모델과 공통 실행 설정

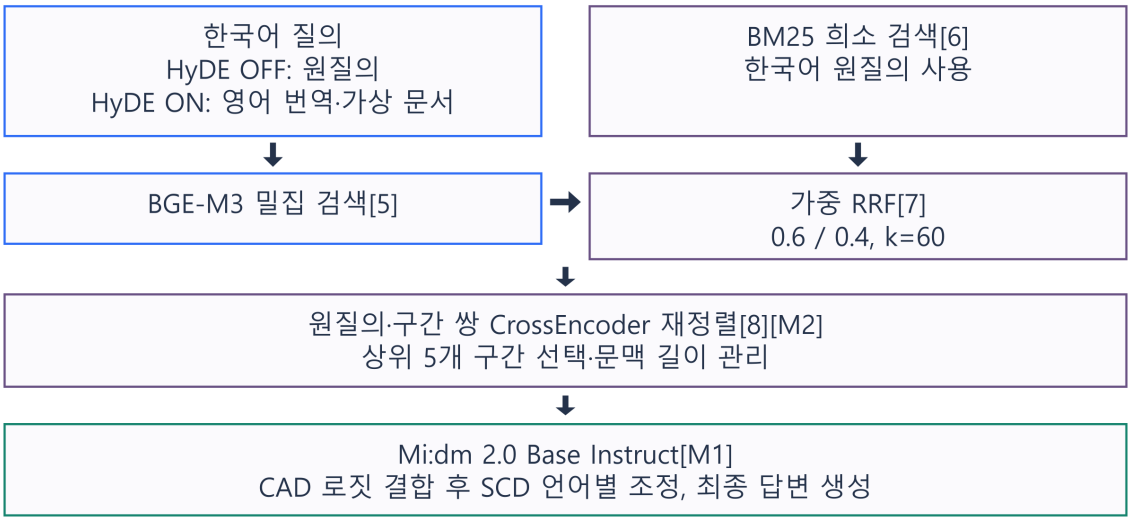
구성 단계	사용 모델 또는 방법	주요 설정
밀집 검색	BAAI/bge-m3	후보 8개, 가중치 0.6
희소 검색	BM25	후보 8개, 가중치 0.4
순위 융합	가중 RRF	k=60
재정렬	cross-encoder/ms-marco-MiniLM-L-6-v2	후보 8개, 최종 구간 5개
문서 분할	공백 기준 단어 분할	최대 512단어, 중첩 64단어, 최소 50단어
문맥 길이 관리	ContextCompressor	3,072단어 초과 시 압축, 비율 0.5
답변 생성	K-intelligence/Midm-2.0-Base-Instruct	greedy, 최대 새 토큰 512개
HyDE	영어 번역과 가상 문서 생성	temperature=0.1, top_p=0.9, sampling
CAD	문맥 포함·제외 로짓 결합	α=0.5 고정
SCD	reference_scd	α=1.1, β=0.9, Tstart=5

재정렬에는 MS MARCO로 학습한 MiniLM CrossEncoder[M2]를 사용하였고, 한국어 원질의와 영어 후보 구간을 한 쌍으로 입력하였다. 선택한 5개 구간의 단어 수 합이 3,072단어를 넘으면 ContextCompressor가 질의와 공통으로 등장하는 단어의 비율로 문장 순위를 매기고, 구간마다 단어 수의 절반에 해당하는 문장을 원래 순서대로 남긴다. 검색 후보 수 8, 재정렬 후보 수 8, 최종 문맥 5는 평가 질의와 분리한 튜닝 질의 5개로 정한 뒤 고정하였다.

4.2 시스템 구성

그림 4-1은 질의 입력부터 답변 생성까지의 처리 순서다. HyDE 조건에서는 답변 생성과 같은 Mi:dm 2.0 Base Instruct로 한국어 질의를 영어로 번역하고, 번역문으로 영어 가상 문서를 생성하여 밀집 검색에 사용한다. 답변 생성에는 검색한 실제 영어 구간을 입력한다.

Paper-RAG는 본 연구의 고정 검색·생성 파이프라인이다.



[그림 4-1] 한국어 질의의 검색·융합·재정렬 및 답변 생성 흐름

4.3 시스템 구현과 실행 기록

CAD는 생성 단계마다 같은 지시문에서 검색 문맥만 뺀 입력의 로짓을 다시 계산하여 2.4절의 식으로 결합한다. SCD는 생성한 토큰이 5개가 되면 한국어 토큰과 비한국어 토큰에 각각 α와 β를 곱한다.

각 생성 기록에는 질의 ID, 실험 조건, 검색·재정렬 청크 ID, 최종 검색 문맥, 생성 답변, 실행 시간과 적용 파라미터를 저장하였다. 평가값은 질의 ID와 조건명으로 생성 기록에 연결하였다.

조건 실행 시간은 모델과 검색 구성요소의 초기화가 끝난 뒤, 각 질의·조건의 처리 시작부터 답변 생성과 기록용 메타데이터 구성이 끝날 때까지 측정하였다. HyDE 조건에는 번역과 가상 문서 생성 시간이 포함되며, 평가 API 호출과 파일 기록은 측정 구간에서 제외하였다. 측정값은 초 단위로 소수점 셋째 자리까지 저장하였다.

5. 실험

5.1 평가 대상 및 질의 구성

평가 질의는 RAG Survey[D1], CAD[D2], RAPTOR[D3], Mi:dm K 2.5 Pro Technical Report[D4]의 영어 문서 4종에서 문서별 15개씩 총 60개를 구성하였다. 네 문서는 각각 RAG의 개요, 근거 활용 디코딩, 계층적 검색, 한국어·영어 언어 모델 기술을 다룬다.

질의는 다음 순서로 작성하였다. 먼저 문서마다 질문 형식과 범위를 정하는 초기 질문 3개를 작성하고, 대규모 언어 모델(Large Language Model, LLM)로 문서의 주요 내용을 15개 내용 단위로 요약하였다. 단위마다 한국어 질의를 1개씩 작성한 뒤, 연구자가 원문 PDF에서 각 질의의 답변 가능성과 정답 근거를 확인하고 원문 페이지를 기록하였다(부록 A). 질문 작성과 답변 근거 확인을 분리하는 방식은 논문 기반 질의응답 데이터셋인 QASPER[21]와 문서 기반 대화 생성 연구[22]의 절차를 참고하였다.

질문 유형은 요구하는 정보에 따라 분류하였다. 개념·수치·구성 요소를 묻는 '사실 및 정의' 8개, 구조·처리 과정·실험 설정을 묻는 '방법 및 절차' 29개, 정량·정성 결과나 방법 간 차이를 묻는 '결과 및 비교' 20개, 연구 목적과 기여를 묻는 '목적 및 기여' 3개다. 문서별 질의 수는 같게 맞추었으나 유형별 질의 수는 문서 내용에 따라 달라졌다.

5.2 평가 지표와 해석 기준

답변 품질은 RAGAS의 네 지표로 평가하였다. 근거 충실도는 생성 답변의 주장 가운데 검색 문맥으로 뒷받침되는 주장의 비율이다. 답변 관련성은 평가 모델이 생성 답변으로부터 역으로 만든 질문과 원질문의 임베딩 코사인 유사도다. 문맥 정밀도는 참조 답변에 유용한 검색 구간이 상위에 배치된 정도이며, 문맥 재현율은 참조 답변의 주장 가운데 검색 문맥이 뒷받침하는 비율이다. 참조 답변은 부록 A의 정답 근거를 사용하였다. 네 지표 모두 0~1 범위이며 값이 클수록 좋다.

출력 언어는 생성 답변의 한국어 문자 비율로 측정하였다. 한글 문자 수를 N_Hangul, ASCII 영문자 수를 N_ASCII라 하면 다음과 같다.

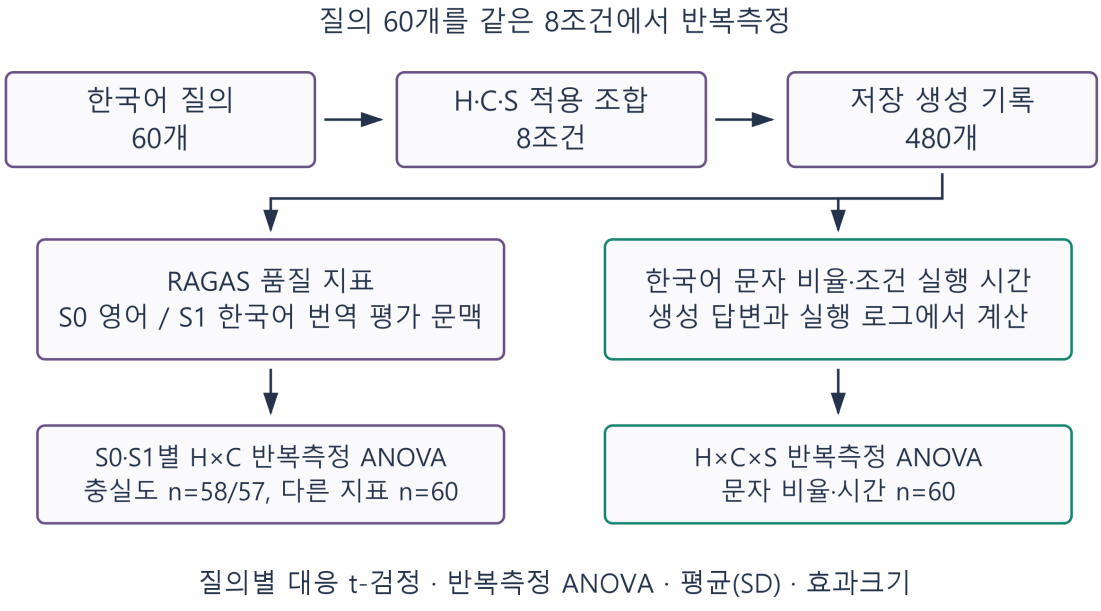
$$KoreanRatio = \frac{N_{Hangul}}{N_{Hangul} + N_{ASCII}}$$

숫자·공백·문장부호는 계산에서 제외하였다. 영어 논문명·모델명도 ASCII 영문자로 세므로, 자연스러운 한국어 답변도 1.0보다 낮은 값을 가질 수 있다. 비율 0.700은 계산 대상 문자의 70.0%가 한글이라는 뜻이며, 두 조건의 차이 0.218은 21.8%p로 읽는다. 숫자만 반복하여 분모가 0인 답변 1건(track1_0035, H1C0S1)은 분석기에 저장된 값 0을 사용하였다.

5.3 실험 조건 및 평가 절차

평가에는 RAGAS 0.2.15, 평가 모델 OpenAI gpt-4o, 임베딩 모델 BAAI/bge-m3를 사용하였다. 문맥 정밀도는 참조 답변을 입력받는 ContextPrecision(LLMContextPrecisionWithReference 상속)으로 계산하였다.

SCD를 적용한 답변은 대부분 한국어이므로, 영어 검색 문맥과 한국어 답변을 그대로 대조하면 평가 모델이 같은 내용을 다른 언어로 쓴 주장을 근거로 인정하지 않을 수 있다. 이를 줄이기 위해 SCD ON 조건은 저장된 영어 검색 문맥을 gpt-4o로 한국어 번역한 평가용 문맥으로, SCD OFF 조건은 생성에 사용한 영어 문맥으로 평가하였다(그림 5-1). 답변 생성에는 모든 조건에서 영어 문맥을 입력했고, 평가할 답변은 수정하지 않았다. 두 조건의 평가 입력이 다르므로 SCD ON과 OFF의 품질 점수는 직접 비교하지 않고, 품질 분석은 SCD 상태별로 나누어 수행하였다.



[그림 5-1] 질의별 생성 기록과 평가값을 연결하는 대응 비교 절차

그림 5-2는 RAPTOR 질의 ext_raptor_011의 질문, 영어 검색 근거, 참조 답변, 생성 답변과 평가값이다. 검색 근거로는 원문과 고수준 요약을 함께 검색하는 이유를 설명한 원문 9쪽의 문장을, 참조 답변으로는 19~20쪽의 Cinderella 정성 비교를 사용하였다. 근거 충실도는 생성 답변의 주장을 검색 문맥과, 문맥 재현율은 참조 답변을 검색 문맥과 대조한다.

E01 | ext_raptor_011
질문: Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?
참조 답변 원문 근거 (PDF 20쪽): The text retrieved by RAPTOR contains short descriptions of all the major parts of the story, whereas the text retrieved by DPR contains detailed descriptions of a narrow subset of the story.
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_raptor_12d47c916205, paper_nlp_raptor_4f4f51e0f19a
문맥[4], PDF 9쪽 발췌: [...] By providing both the original text and higher-level summaries for retrieval, RAPTOR can effectively handle a wider range of questions, from higher-order thematic queries to detail-oriented questions. [...]
저장 답변 발췌: [...] 첫째, RAPTOR는 계층적 구조를 통해 다양한 수준의 추상화(abstraction)를 제공합니다. 논문의 Figure 4에서 확인할 수 있듯이, RAPTOR는 질문의 요구사항에 따라 서로 다른 층위(layer)에서 노드를 선택할 수 있습니다. 반면 DPR은 단일 층위의 leaf 노드만을 선택하여 정보를 제공합니다. [...]
Faithfulness 1.0000 | Answer Relevancy 0.9365
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.5274
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 5-2] RAPTOR 질의의 검색 근거, 생성 답변 및 평가 예시

5.4 통계 분석 방법

통계 분석에는 대응 t-검정과 반복측정 ANOVA를 사용하였다. 같은 질의 60개를 모든 조건에서 측정하였으므로 조건 간 점수는 서로 독립이 아니다. 따라서 두 조건의 비교에는 질의별 점수 차이를 검정하는 대응 t-검정을, 세 기법의 주효과와 상호작용에는 질의를 반복측정 단위로 한 반복측정 ANOVA를 적용하였다. 유의수준은 양측 0.05로 정하였다.

대응 t-검정의 귀무가설은 질의별 ON−OFF 차이의 평균이 0이라는 것이다. 질의 i의 적용 조건 점수를 s_i^ON, 미적용 조건 점수를 s_i^OFF라 하면 차이, 평균 차이와 t 통계량은 다음과 같다. s_Δ는 질의별 차이의 표본표준편차이며 자유도는 n−1이다.

$$\Delta_i = s_i^{ON} - s_i^{OFF}$$

$$\overline{\Delta} = \frac{1}{n}\sum_{i=1}^{n}\Delta_i$$

$$t = \frac{\overline{\Delta}}{s_\Delta / \sqrt{n}}$$

효과크기는 평균 차이를 차이의 표준편차로 나눈 Cohen dz로 나타내었다. RQ3에서는 한 질의에 SCD 대응쌍이 둘(CAD OFF·ON) 있으므로, 질의별로 두 차이를 먼저 평균하여 검정 표본을 60개로 맞추었다. 이렇게 하지 않으면 같은 질의의 쌍을 서로 독립인 표본으로 중복 계산하게 된다.

반복측정 ANOVA의 각 효과는 두 수준을 가지므로 자유도는 (1, n−1)이고, 효과크기는 부분 η^2=F/(F+오차 자유도)로 계산하였다. 한국어 문자 비율과 실행 시간은 8개 조건 전체로 H×C×S 3요인 ANOVA를 수행하였다. 품질 지표는 5.3절의 이유로 SCD OFF와 ON 안에서 각각 H×C 2요인 ANOVA를 수행하였다. 유의한 상호작용은 해당 조건별 단순 효과를 대응 t-검정으로 확인하였다.

RAGAS 평가값 1,920개 중 1,915개가 유효했고, 결측 5개는 모두 근거 충실도에서 발생하였다(ext_rag_003·006의 H0C1S0, ext_rag_003·005·006의 H0C0S1). 각 검정은 필요한 조건의 값이 모두 있는 질의만 사용하였으며, 이에 따라 RQ2의 표본은 58개다.

이 분석은 실험을 마친 뒤 연구 질문에 맞추어 정리한 탐색적 분석이며, 핵심 지표를 사전에 등록하지는 않았다. 여러 검정을 수행하였으므로 개별 p값은 제1종 오류가 누적될 수 있다는 점을 고려하여 해석하였다.

5.5 조합별 평가 결과

표 5-1은 8개 조건의 품질 지표와 한국어 문자 비율의 평균(SD)이다. 위쪽 네 행은 영어 문맥으로, 아래쪽 네 행은 한국어 번역 문맥으로 평가한 결과다.

[표 5-1] 평가 문맥 언어별 8조건의 품질 및 한국어 문자 비율 평균(SD)

조건	충실도	관련성	정밀도	재현율	한국어 비율
H0C0S0	0.791 (0.260)	0.683 (0.282)	0.749 (0.302)	0.933 (0.252)	0.494 (0.265)
H0C1S0	0.839 (0.201)	0.675 (0.261)	0.740 (0.302)	0.917 (0.279)	0.488 (0.245)
H1C0S0	0.834 (0.186)	0.763 (0.209)	0.714 (0.296)	0.933 (0.252)	0.556 (0.213)
H1C1S0	0.860 (0.181)	0.705 (0.248)	0.736 (0.271)	0.900 (0.303)	0.503 (0.229)
H0C0S1	0.787 (0.254)	0.637 (0.296)	0.763 (0.300)	0.900 (0.303)	0.699 (0.329)
H0C1S1	0.777 (0.270)	0.600 (0.321)	0.752 (0.301)	0.850 (0.360)	0.719 (0.218)
H1C0S1	0.822 (0.218)	0.710 (0.272)	0.743 (0.281)	0.900 (0.303)	0.807 (0.200)
H1C1S1	0.831 (0.253)	0.667 (0.286)	0.754 (0.267)	0.917 (0.279)	0.731 (0.209)

충실도는 H0C1S0이 n=58, H0C0S1이 n=57이고 나머지는 n=60이다. 영어 문맥으로 평가한 조건 중 답변 관련성은 H1C0S0(0.763)이, 근거 충실도는 H1C1S0(0.860)이 가장 높았다. 한국어 문자 비율은 SCD를 적용한 네 조건이 모두 0.699 이상으로, 적용하지 않은 네 조건(0.488~0.556)보다 높았고 H1C0S1이 0.807로 가장 높았다. 이 순위는 평균의 비교이며, 조건 간 차이가 통계적으로 유의한지는 5.6절과 5.7절에서 검정한다.

[표 5-2] 8조건의 조건 실행 시간 평균, 표준편차와 중앙값

조건	평균(초)	SD(초)	중앙값(초)
H0C0S0	20.792	23.404	16.077
H0C0S1	18.898	5.085	17.579
H0C1S0	63.867	25.312	57.819
H0C1S1	55.159	26.465	51.127
H1C0S0	23.440	4.707	22.245
H1C0S1	24.892	5.196	24.714
H1C1S0	73.532	21.584	71.700
H1C1S1	64.125	21.675	64.834

CAD를 적용한 네 조건은 55~74초로, 적용하지 않은 네 조건(19~25초)의 약 2.9배였다. H0C0S0의 SD가 다른 CAD 미적용 조건보다 큰 것은 각 질의 세트의 첫 실행이었던 track1_0009(164.2초)와 ext_rag_001(117.3초) 때문이다. 두 기록은 각 실행에서 모델 초기화 직후 처음 처리된 질의로, 다른 질의의 같은 조건(중앙값 16.1초)보다 7~10배 길었다. 두 질의를 제외한 58개로 다시 분석하면 H0C0S0의 평균은 16.7초가 되고, SCD는 CAD 미적용 조건에서 실행 시간을 1~2초 늘리고 CAD 적용 조건에서는 7~8초 줄였다. H·C 주효과와 C×S 상호작용의 유의성은 바뀌지 않았다(C×S $F(1,57)=12.022$, $p=0.001$). 주 분석은 원자료 60개를 그대로 사용하였다.

5.6 연구 질문별 대응 비교

표 5-3은 RQ1~RQ3의 핵심 지표에 대한 대응 t-검정 결과다. 평균 차이는 적용(ON) 조건 점수에서 미적용(OFF) 조건 점수를 뺀 값이고, SD는 질의별 차이의 표준편차다.

[표 5-3] 연구 질문별 핵심 지표의 대응 t-검정

연구 질문·지표	비교 조건	n	평균 ON(SD)	평균 OFF(SD)	평균 차이(SD)	t(df)	p	dz
RQ1 HyDE 답변 관련성	H1C0S0 − H0C0S0	60	0.763 (0.209)	0.683 (0.282)	0.080 (0.279)	2.236 (59)	0.029	0.289
RQ2 CAD 근거 충실도	H0C1S0 − H0C0S0	58	0.839 (0.201)	0.810 (0.239)	0.029 (0.255)	0.862 (57)	0.393	0.113
RQ3 SCD 한국어 문자 비율	HyDE OFF, S1 − S0	60	0.709 (0.247)	0.491 (0.232)	0.218 (0.121)	13.951 (59)	<0.001	1.801

RQ1에서 HyDE를 적용하면 답변 관련성이 평균 0.080점 높아졌고, 이 차이는 유의하였다 ($t(59)=2.236$, $p=0.029$, $dz=0.29$). 60개 질의 중 38개에서 점수가 올랐고 17개에서 내렸다. 평균 차이의 95% 신뢰구간은 [0.009, 0.153]이다. 밀집 검색의 입력이 가상 문서로 바뀌면서 검색 문맥과 답변이 함께 달라진 사례를 부록 B의 그림 B-2에 제시하였다.

RQ2에서 CAD를 적용하면 근거 충실도가 평균 0.029점 높아졌으나 유의하지 않았다 ($t(57)=0.862$, $p=0.393$, $dz=0.11$). 표의 OFF 평균 0.810은 양쪽 값이 모두 있는 58개 질의의 평균이므로 표 5-1의 0.791과 다르다. 질의별로는 22개가 오르고 24개가 내렸으며 12개는 같았다. 차이의 표준편차(0.255)가 평균 차이의 약 9배여서, 같은 검색 문맥에서도 CAD의 효과

가 질의마다 크게 달랐다. 충실도가 오른 사례(그림 B-3)와 내린 사례(그림 B-1)를 부록 B에 제시하였다.

RQ3에서 SCD를 적용하면 한국어 문자 비율이 평균 21.8%p 높아졌다($t(59)=13.951$, $p<0.001$, $dz=1.80$). 60개 질의 중 58개에서 비율이 올랐다. HyDE·CAD의 네 상태를 모두 평균한 비교에서도 22.9%p 높아졌다(표 5-7). SCD 미적용 조건에서 영어 중심으로 답한 사례와 SCD 적용 후 한국어 비율이 높아진 사례를 그림 B-4와 그림 B-5에 제시하였다.

5.7 요인 주효과 및 상호작용

RQ4는 8개 조건 전체에 대한 반복측정 ANOVA로 분석하였다. 표 5-4와 표 5-5는 한국어 문자 비율과 실행 시간의 결과다.

[표 5-4] 한국어 문자 비율의 H×C×S 반복측정 ANOVA

효과	df	F	p	부분 η²
H	1, 59	2.924	0.093	0.047
C	1, 59	3.365	0.072	0.054
S	1, 59	341.302	<0.001	0.853
H×C	1, 59	4.417	0.040	0.070
H×S	1, 59	0.771	0.384	0.013
C×S	1, 59	0.006	0.939	0.000
H×C×S	1, 59	1.035	0.313	0.017

[표 5-5] 조건 실행 시간의 H×C×S 반복측정 ANOVA

효과	df	F	p	부분 η²
H	1, 59	16.362	<0.001	0.217
C	1, 59	423.765	<0.001	0.878
S	1, 59	6.097	0.016	0.094
H×C	1, 59	2.262	0.138	0.037
H×S	1, 59	0.401	0.529	0.007
C×S	1, 59	12.080	<0.001	0.170
H×C×S	1, 59	0.487	0.488	0.008

한국어 문자 비율에서는 SCD 주효과가 가장 컸다($F(1,59)=341.302$, $p<0.001$, 부분 $\eta^2=0.853$). SCD는 HyDE·CAD의 적용 여부와 관계없이 한국어 비율을 높였으며, SCD가 포함된 상호작용(H×S, C×S, H×C×S)은 모두 유의하지 않았다. 이와 별도로 H×C 상호작용이 유의하였다($F(1,59)=4.417$, $p=0.040$).

실행 시간에서는 CAD 주효과($F(1,59)=423.765$, $p<0.001$, 부분 $\eta^2=0.878$)와 HyDE 주효과($F(1,59)=16.362$, $p<0.001$)가 유의하였다. CAD는 토큰마다 문맥 제외 입력을 다시 계산하고, HyDE는 번역과 가상 문서 생성을 추가로 수행하기 때문이다. SCD 주효과($p=0.016$)와 C×S 상호작용($p<0.001$)도 유의하였다.

표 5-6은 유의한 두 상호작용을 단순 효과로 나누어 본 결과다. 두 SCD 상태 또는 두 HyDE 상태는 질의별로 평균하였다.

[표 5-6] 유의한 상호작용의 단순 효과 대응 t-검정

상호작용과 단순 효과	n	평균 ON(SD)	평균 OFF(SD)	평균 차이(SD)	t(df)	p	dz
한국어 비율 H×C: CAD OFF의 HyDE	60	0.682 (0.173)	0.597 (0.283)	0.085 (0.268)	2.458 (59)	0.017	0.317
한국어 비율 H×C: CAD ON의 HyDE	60	0.617 (0.199)	0.604 (0.213)	0.014 (0.250)	0.422 (59)	0.674	0.055
실행 시간 C×S: SCD OFF의 CAD	60	68.699 (19.912)	22.116 (12.118)	46.583 (18.937)	19.054 (59)	<0.001	2.460
실행 시간 C×S: SCD ON의 CAD	60	59.642 (18.999)	21.895 (4.243)	37.747 (18.405)	15.886 (59)	<0.001	2.051

HyDE는 CAD를 적용하지 않았을 때 한국어 문자 비율을 8.5%p 높였으나(p=0.017), CAD를 적용했을 때에는 차이가 1.4%p로 유의하지 않았다(p=0.674). CAD는 두 SCD 상태 모두에서 실행 시간을 유의하게 늘렸으며, 증가폭은 SCD OFF에서 46.6초, SCD ON에서 37.7초였다. 즉 C×S 상호작용은 SCD를 함께 적용할 때 CAD의 추가 시간이 약 9초 줄어든 결과다. SCD 주효과는 이 감소가 CAD 적용 조건에서 나타난 것이며, CAD 미적용 조건에서 SCD는 중앙값 기준으로 실행 시간을 1.5~2.5초 늘렸다(표 5-2).

품질 지표의 H×C ANOVA(부록 B의 표 B-3, 표 B-4)에서는 두 평가 문맥 모두 유의한 효과가 없었다. p값이 가장 작은 효과는 영어 문맥(p=0.097)과 번역 문맥(p=0.088) 모두 답변 관련성의 HyDE 주효과였다. 즉 CAD 수준을 평균하면 HyDE의 답변 관련성 향상은 유의하지 않았으며, RQ1의 유의한 차이는 CAD를 적용하지 않은 조건에서 관찰된 결과다. CAD를 적용한 조건에서 HyDE의 답변 관련성 차이는 0.029점이었다(t(59)=0.661, p=0.512).

보조 지표의 단순 비교 결과는 표 5-7과 같다. HyDE와 CAD는 핵심 지표 이외의 품질 지표에서도 유의한 변화를 보이지 않았다.

[표 5-7] 보조 지표의 대응 t-검정

요인·지표	n	평균 차이(SD)	t(df)	p	dz
HyDE 근거 충실도	60	0.044 (0.281)	1.200 (59)	0.235	0.155
HyDE 문맥 정밀도	60	−0.034 (0.234)	−1.134 (59)	0.261	−0.146
HyDE 문맥 재현율	60	0.000 (0.368)	0.000 (59)	1.000	0.000
CAD 답변 관련성	60	−0.007 (0.313)	−0.181 (59)	0.857	−0.023
CAD 문맥 정밀도	60	−0.009 (0.077)	−0.930 (59)	0.356	−0.120
CAD 문맥 재현율	60	−0.017 (0.129)	−1.000 (59)	0.321	−0.129
SCD 한국어 비율(H·C 4상태)	60	0.229 (0.096)	18.474 (59)	<0.001	2.385

HyDE는 C0S0, CAD는 H0S0 조건에서 비교하였다. CAD의 문맥 정밀도와 재현율은 같은 검색 문맥을 평가하므로 차이가 0이어야 하지만, 평가 모델이 같은 입력을 정밀도 8쌍, 재현율 1쌍에서 다르게 채점하였다. 이는 RAGAS 평가값 자체에 평가 모델의 변동이 포함되어 있음을 보여 준다.

5.8 종합 논의

세 기법 중 목표 지표에서 가장 뚜렷한 효과를 보인 것은 SCD다. SCD는 영어 근거를 입력받은 답변의 한국어 비율을 약 22%p 높였고, 이 효과는 HyDE·CAD의 적용 여부와 관계없이 나타났다. CAD 미적용 조건에서 늘어난 실행 시간도 중앙값 기준 1.5~2.5초였다. 한국어 질의-영어 문서 RAG에서 한국어 답변이 필요하다면 SCD는 비용이 작은 선택지다.

HyDE는 다른 기법을 적용하지 않은 기본 조건에서 답변 관련성을 높였다. 번역과 가상 문서로 검색 입력이 바뀌면서 질문에 더 맞는 근거가 검색되고, 답변이 질문에 더 직접 답하게 된 것으로 해석할 수 있다. 다만 CAD를 함께 적용하면 이 차이가 작아졌고, 문맥 정밀도·재현율은 변하지 않았다. HyDE의 효과에는 번역과 가상 문서 생성이 함께 포함되어 있으며, 실행 시간은 다른 기법 수준을 평균하여 약 7초 늘었다.

CAD는 같은 검색 문맥에서 근거 충실도를 유의하게 높이지 못했다. 저장 자료에서 확인되는 이유는 세 가지다. 첫째, CAD 미적용 답변 58개 중 25개가 이미 충실도 1.0이어서 개선될 여지가 작았다. 둘째, CAD는 답변을 일부 수정하는 것이 아니라 전혀 다른 답변을 생성하였고(CAD 미적용 답변과 같은 답변 0개), 그 결과 질의별 차이의 표준편차가 평균 차이보다 훨씬 컸다. 이 정도의 효과크기(dz=0.11)를 검출하려면 현재보다 훨씬 많은 질의가 필요하다. 셋째, 같은 입력에서도 평가 모델의 채점이 달라지는 경우가 있어 작은 차이는 평가 변동에 묻힐 수 있다. 또한 CAD는 모델의 사전 지식과 문맥이 충돌할 때 효과가 크도록 설계되었으나[3], 본 실험의 질의는 모델이 잘 알지 못하는 특정 문서의 세부 내용이어서 기본 RAG도 이미 문맥을 따르는 경우가 많았다. 반면 실행 시간은 약 2.9배로 늘었으므로, 본 실험 조건에서 CAD는 품질 이득보다 시간 비용이 분명한 기법이었다.

조합 측면에서는 SCD와 다른 기법 사이에 한국어 비율의 상호작용이 없어 SCD를 독립적으로 추가할 수 있었다. HyDE의 한국어 비율 향상은 CAD 미적용 조건에서만 나타났고, CAD와 SCD를 함께 쓰면 CAD의 추가 시간이 약 9초 줄었다. 평균값 기준으로는 H1C0S1이 한국어 비율이 가장 높고(0.807), CAD를 쓰지 않아 실행 시간도 24.9초로 짧은 조건이었다.

5.9 평가 범위와 후속 검증

분석 대상은 문서 4종에서 구성한 질의 60개이며 각 질의·조건의 답변은 한 번씩 생성하고 평가하였다. 따라서 결과는 이 질의 집합에서 관찰된 조건 간 차이이며, 다른 분야의 문서나 생성 시드에서의 변동은 확인하지 않았다. HyDE 조건은 가상 문서를 샘플링하므로 같은 질의라도 실행마다 검색 문맥이 달라질 수 있다. RAGAS 품질은 SCD 상태에 따라 평가 문맥의 언어가 달라 SCD의 품질 효과는 비교 대상에서 제외하였다. 한국어 문자 비율은 답변의 언어 구성을 측정하는 지표이므로, 번역의 정확성과 문장의 자연스러움은 사람 평가로 따로 확인해야 한다.

6. 결론

본 연구는 한국어 질의로 영어 학술·기술 문서를 검색하는 Paper-RAG에서 HyDE·CAD·SCD의 8개 조합을 같은 질의 60개에 적용하고, 대응 t-검정과 반복측정 ANOVA로 각 기법의 단독 효과와 조합 효과를 분석하였다.

6.1 연구 질문별 결과

RQ1: CAD와 SCD를 적용하지 않은 조건에서 HyDE는 답변 관련성을 평균 0.080점 높였다($t(59)=2.236$, $p=0.029$). CAD 수준을 평균한 주효과는 유의하지 않았다($p=0.097$).

RQ2: 같은 검색 문맥에서 CAD의 근거 충실도 차이는 평균 0.029점으로 유의하지 않았다($t(57)=0.862$, $p=0.393$).

RQ3: SCD는 한국어 문자 비율을 평균 21.8%p 높였다($t(59)=13.951$, $p<0.001$).

RQ4: 한국어 문자 비율에서는 SCD 주효과($p<0.001$)와 H×C 상호작용($p=0.040$)이, 실행 시간에서는 HyDE·CAD·SCD 주효과와 C×S 상호작용($p<0.001$)이 유의하였다. CAD는 실행 시간을 약 2.9배로 늘렸고, SCD와 함께 적용하면 그 증가폭이 약 9초 줄었다.

6.2 연구의 의의

본 연구는 서로 다른 환경에서 제안된 HyDE·CAD·SCD를 한국어 질의-영어 문서라는 하나의 RAG 환경에서 같은 백본과 질의로 비교하였다. 그 결과 출력 언어 제어(SCD)는 다른 기법과 독립적으로 큰 효과를 보였고, 검색 입력 변경(HyDE)은 기본 조건에서 답변 관련성을 높였으며, 근거 반영 디코딩(CAD)은 이 환경에서 품질 이득 없이 시간 비용이 컸다는 점을 정량적으로 보였다. 또한 단순 비교와 요인 분석을 함께 사용하여, 특정 조건에서의 효과와 다른 기법 수준을 평균한 효과가 다를 수 있음을 확인하였다.

6.3 적용 조건과 후속 연구

한국어 답변이 필요한 영어 문서 RAG에는 SCD를 기본으로 적용하고, 답변 관련성이 중요하면 HyDE를 함께 적용하는 구성을 우선 고려할 수 있다. CAD는 실행 시간이 크게 늘어나므로 모델의 사전 지식과 문서 내용이 충돌하는 질의처럼 효과가 기대되는 경우에 선택적으로 적용하는 것이 적절하다.

후속 연구로는 다음을 제안한다. 첫째, 번역만 적용한 조건을 추가하여 HyDE의 효과를 번역과 가상 문서 생성으로 분리한다. 둘째, CAD의 α를 바꾸고 지식 충돌형 질의를 포함하여 CAD가 효과를 보이는 조건을 확인한다. 셋째, 질의 수와 문서 분야를 늘리고 생성과 평가를 반복하여 결과의 변동을 측정하며, 모든 조건의 평가 문맥 언어를 통일한다. 넷째, 사람 평가로 한국어 답변의 정확성과 자연스러움을 확인한다.

참고문헌

[1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Advances in Neural Information Processing Systems, Vol. 33, pp. 9459-9474, 2020.

[2] L. Gao et al., “Precise Zero-Shot Dense Retrieval without Relevance Labels,” Proceedings of ACL, pp. 1762-1777, 2023, doi: 10.18653/v1/2023.acl-long.99.

[3] W. Shi et al., “Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding,” Proceedings of NAACL, pp. 783-791, 2024, doi: 10.18653/v1/2024.naacl-short.69.

[4] B. Li, Z. Xu, and R. Xie, “Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation,” Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519-31526, 2026, doi: 10.1609/aaai.v40i37.40417.

[5] J. Chen et al., “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318-2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson, S. Walker, S. Jones, M. M. Hancock-Beaulieu, and M. Gatford, “Okapi at TREC-3,” Proceedings of the Third Text REtrieval Conference (TREC-3), NIST Special Publication 500-225, pp. 109-126, 1995 (conference 1994).

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” Proceedings of SIGIR, pp. 758-759, 2009, doi: 10.1145/1571941.1572114.

[8] S. MacAvaney, A. Yates, A. Cohan, and N. Goharian, “CEDR: Contextualized Embeddings for Document Ranking,” Proceedings of SIGIR, pp. 1101-1104, 2019, doi: 10.1145/3331184.3331317.

[9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157-173, 2024, doi: 10.1162/tacl_a_00638.

[10] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented

Generation," Proceedings of EACL System Demonstrations, pp. 150-158, 2024, doi: 10.18653/v1/2024.eacl-demo.16.

[11] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proceedings of EMNLP, pp. 6769-6781, 2020, doi: 10.18653/v1/2020.emnlp-main.550.

[12] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proceedings of EACL, pp. 874-880, 2021, doi: 10.18653/v1/2021.eacl-main.74.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286-12312, 2023, doi: 10.18653/v1/2023.acl-long.687.

[14] P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S. Jeong, J. Baek, S. Cho, S. J. Hwang, and J. Park, "Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity," Proceedings of NAACL, pp. 7036-7050, 2024, doi: 10.18653/v1/2024.naacl-long.389.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, No. 1, pp. 1-29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] W. Fan et al., "A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models," Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 6491-6501, 2024, doi: 10.1145/3637528.3671470.

[19] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[20] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EACL, pp. 2014-2037, 2023, doi: 10.18653/v1/2023.eacl-main.148.

[21] P. Dasigi, K. Lo, I. Beltagy, A. Cohan, N. A. Smith, and M. Gardner, “A Dataset of Information-Seeking Questions and Answers Anchored in Research Papers,” Proceedings of NAACL, pp. 4599-4610, 2021, doi: 10.18653/v1/2021.naacl-main.365.

[22] M. A. Sultan, J. Ganhotra, and R. F. Astudillo, “Structured Chain-of-Thought Prompting for Few-Shot Generation of Content-Grounded QA Conversations,” Findings of EMNLP, pp. 16172-16187, 2024, doi: 10.18653/v1/2024.findings-emnlp.948.

실험 사용 모델 및 원문 자료 출처

학술 참고문헌 [1]~[22]와 별도로 구현에 사용한 모델 카드[M1][M2]와 검색 대상 문서 [D1]~[D4]의 출처를 정리하였다.

[M1] KT, K-intelligence/Midm-2.0-Base-Instruct, 공식 모델 카드, https://huggingface.co/K-intelligence/Midm-2.0-Base-Instruct (확인: 2026-10-17). 실행 기록의 생성 모델 ID는 이 모델이며 답변 생성은 greedy, 최대 새 토큰 512개다. 저장 기록의 버전 정보는 모델 ID와 실행 파라미터로 구성된다.

[M2] Sentence Transformers, cross-encoder/ms-marco-MiniLM-L6-v2, 공식 모델 카드, https://huggingface.co/cross-encoder/ms-marco-MiniLM-L6-v2 (확인: 2026-10-17). 실행 설정의 모델 문자열은 cross-encoder/ms-marco-MiniLM-L-6-v2이며, 원질의·후보 구간 쌍을 입력하는 CrossEncoder 재정렬에 사용하였다.

[D1] Y. Gao et al., “Retrieval-Augmented Generation for Large Language Models: A Survey,” arXiv:2312.10997. 실험 원문: paper_nlp_rag.pdf.

[D2] W. Shi et al., CAD 논문[3]. 실험 원문: paper_nlp_cad.pdf.

[D3] P. Sarthi et al., RAPTOR 논문[14]. 실험 원문: paper_nlp_raptor.pdf.

[D4] KT Tech Innovation Group, “Mi:dm K 2.5 Pro,” 기업 기술보고서, arXiv:2603.18788v2, 2026, https://arxiv.org/abs/2603.18788v2. 실험 원문: paper_midm.pdf.

D1~D4의 실험 PDF는 저장된 원본 바이트를 사용한다. 문서별 SHA-256과 질의·원문 페이지·정답 근거 대응은 동봉 자료 출처 검증표와 부록 A에서 제시한다.

그림 자료 이용 정보

그림 2-1~2-4는 본 연구에서 작성한 독립 도식이다. 각 그림의 개념 출처와 참고 자료는 다음과 같다.

그림 2-1 — 본 연구 작성. Lewis 외[1]의 RAG 구조를 참고하여 독립 도식을 작성하였다.

참고 자료: https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf

그림 2-2 — 본 연구 작성. Gao 외[2]의 HyDE 구조를 참고하여 독립 도식을 작성하였다.

참고 자료: https://aclanthology.org/2023.acl-long.99/

그림 2-3 — 본 연구 작성. Shi 외[3]의 CAD 로짓 결합을 참고하여 독립 도식을 작성하였다.

참고 자료: https://aclanthology.org/2024.naacl-short.69/

그림 2-4 — 본 연구 작성. Li 외[4]의 SCD 토큰별 점수 조정을 참고하여 독립 도식을 작성하였다.

참고 자료: https://ojs.aaai.org/index.php/AAAI/article/view/40417

부록 A. 60개 질의 목록

표 A-1은 각 질의의 대상 문서, 원문 페이지와 정답 근거를 제시한다.

[표 A-1] 60개 한국어 질의의 대상 문서·유형·원문 페이지 및 정답 근거

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_001	언어 모델이 생성 시 활용하는 prior knowledge와 context knowledge는 각각 어디에서 오는 정보입니까?	CAD	사실 및 정의	1	the context contains external knowledge; prior knowledge is encoded in the model parameters
ext_cad_002	CAD의 요약 실험에는 어떤 데이터셋과 평가 지표가 사용되었습니까?	CAD	방법 및 절차	3	CNN-DM and XSUM; ROUGE-L, BERT-Precision, and FactKB
ext_cad_003	CAD의 지식 충돌 실험에는 어떤 두 데이터셋이 사용되었고 각각 무엇을 평가합니까?	CAD	방법 및 절차	3	MemoTrap investigates memorization traps; NQ-Swap tests faithful answering from a modified reliable document.
ext_cad_004	NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?	CAD	방법 및 절차	3	identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity
ext_cad_005	CAD 실험에서 요약 과제와 지식 충돌 과제에 사용한 α 값은 각각 얼마이며, 지식 충돌 과제에서 더 큰 값을 사용한 이유는 무엇입니까?	CAD	방법 및 절차	3	α = 0.5 for summarization and α = 1 for knowledge conflicts, where prior knowledge needs to be factored out more
ext_cad_006	CAD 논문의 베이스라인 디코딩은 요약 과제와 지식 충돌 과제에서 각각 어떤 샘플링 전략을 사용합니까?	CAD	방법 및 절차	3	greedy decoding for knowledge conflict tasks and top-p sampling with p=0.9 for summarization tasks
ext_cad_007	CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?	CAD	방법 및 절차	3	OPT, GPT-Neo, LLaMA, and FLAN-T5
ext_cad_008	지식 충돌 과제에서 모델 크기가 커질수록 CAD의 성능 향상 폭은 어떤 경향을 보였습니까?	CAD	결과 및 비교	5	the gain increases as the model size grows

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_009	LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?	CAD	결과 및 비교	4	Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3
ext_cad_010	외부 컨텍스트가 생성 토큰과 조건부 독립이라면 α가 0이 아니어도 CAD의 출력 분포에는 어떤 영향이 있습니까?	CAD	사실 및 정의	2	even a non-zero α would not have an impact to the original output distribution
ext_cad_011	CAD는 특정 instruction-finetuned 언어 모델에만 제한됩니까, 아니면 어떤 언어 모델에도 적용 가능한 디코딩 전략입니까?	CAD	사실 및 정의	6	a decoding strategy applicable to any LM
ext_midm_001	Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	3	licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data
ext_midm_002	Mi:dm K 2.5 Pro는 한국어 중심 학습을 유지하기 위해 다국어 데이터를 한국어 코퍼스 대비 어느 정도 비율로 제한하며, 그 이유는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	3	3-10% of the Korean corpus, to encourage cross-lingual transfer without diluting the Korean-language focus
ext_midm_003	응답 스타일 재작성 후 평균 응답 길이는 몇 % 증가했고, bullet_count=0인 응답의 비율은 어떻게 변했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	8	mean response length increases by 256.70%; bullet_count = 0 drops from 82.8% to 3.9%
ext_midm_004	Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	15	interaction structure, topic and task, and persona
ext_midm_005	Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	21	to favor versatile conversational alignment; creative writing, translation, and general question answering
ext_midm_006	Fully asynchronous GSPO 학습은 synchronous 방식과 비교해 step time과 token throughput을 각각 어느 정도 개선했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	23	reduces step time by approximately 15% and improves token throughput by approximately 30%

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_midm_007	LLM-as-a-Judge 기반 reward signal은 사람의 평가와 어느 정도의 일치율을 보였습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	24	an agreement rate of 91%
ext_midm_008	Reasoning-enabled 평가에서 Mi:dm K 2.5 Pro가 HumanEval+와 τ²-Bench Telecom에서 기록한 점수는 각각 얼마입니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	25	HumanEval+ 92.07% and τ²-Bench Telecom 89%
ext_midm_009	한국어 red-teaming 평가에서 Mi:dm K 2.5 Pro의 Attack Success Rate는 얼마였으며 비교 모델들 가운데 어떤 수준이었습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	31	ASR of 36.3%, the lowest attack success rate among the compared models
ext_rag_001	Advanced RAG의 pre-retrieval 단계는 인덱스와 사용자 질의를 각각 어떤 방향으로 최적화합니까?	RAG Survey	방법 및 절차	4	optimizing the indexing structure and the original query
ext_rag_002	Advanced RAG의 post-retrieval 단계에서 사용되는 두 가지 핵심 방법은 무엇입니까?	RAG Survey	방법 및 절차	4	rerank chunks and context compressing
ext_rag_003	RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?	RAG Survey	방법 및 절차	8	Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.
ext_rag_004	문서 청크에 타임스탬프 같은 메타데이터를 부여하면 time-aware RAG는 최신 정보를 어떻게 우선할 수 있습니까?	RAG Survey	방법 및 절차	8	Assigning different weights to document timestamps during retrieval can achieve time-aware RAG, ensuring the freshness of knowledge and avoiding outdated information.
ext_rag_005	Reverse HyDE는 문서로부터 가상의 질문을 생성해 원래 질문과 답변 사이의 의미적 간극을 어떻게 줄입니까?	RAG Survey	방법 및 절차	8	using LLM to generate questions that can be answered by the document, then calculating the similarity between the original question and the hypothetical question

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_rag_006	Multi-Query와 Sub-Query 방식은 원래 질의를 확장하거나 분해하는 방식에서 어떻게 다릅니까?	RAG Survey	방법 및 절차	8	Multi-Query expands queries via LLMs for parallel execution; Sub-Query decomposes a complex question into simpler sub-questions.
ext_rag_007	Iterative Retrieval, Recursive Retrieval, Adaptive Retrieval은 검색을 반복하거나 중단하는 방식에서 각각 어떻게 구분됩니까?	RAG Survey	방법 및 절차	11	Iterative retrieval alternates retrieval and generation; recursive retrieval refines queries and breaks problems into sub-problems; adaptive retrieval determines whether retrieval is necessary and when to stop.
ext_rag_008	RAG 평가에서 요구되는 네 가지 핵심 능력은 무엇입니까?	RAG Survey	방법 및 절차	12	noise robustness, negative rejection, information integration, and counterfactual robustness
ext_rag_009	RAG 평가에서 Negative Rejection은 어떤 능력을 측정합니까?	RAG Survey	사실 및 정의	12	refraining from responding when the retrieved documents do not contain the necessary knowledge to answer a question
ext_rag_010	RAG와 파인튜닝을 비교할 때 지식 업데이트의 동적 특성과 해석 가능성 측면에서 RAG가 갖는 특징은 무엇입니까?	RAG Survey	결과 및 비교	5	real-time knowledge updates and effective utilization of external knowledge sources with high interpretability
ext_raptor_001	RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?	RAPTOR	방법 및 절차	3	length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk
ext_raptor_002	RAPTOR의 leaf node를 만들 때 텍스트 임베딩에 사용한 모델은 무엇입니까?	RAPTOR	방법 및 절차	3	SBERT, a BERT-based encoder (multi-qa-mpnet-base-cos-v1)
ext_raptor_003	RAPTOR의 GMM 클러스터링 전에 UMAP을 사용하는 이유는 무엇입니까?	RAPTOR	방법 및 절차	4	to mitigate the challenge of high-dimensional vector embeddings by dimensionality reduction
ext_raptor_004	RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?	RAPTOR	방법 및 절차	4	to determine the optimal number of clusters

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_raptor_005	RAPTOR에서 클러스터별 요약을 생성하는 데 사용한 언어 모델은 무엇입니까?	RAPTOR	방법 및 절차	4	gpt-3.5-turbo
ext_raptor_006	RAPTOR의 트리 구축 비용은 문서 길이가 증가할 때 build time과 token expenditure 측면에서 어떻게 확장됩니까?	RAPTOR	결과 및 비교	16	both build time and token expenditure scale linearly with document length
ext_raptor_007	QASPER 데이터셋은 몇 개의 질문과 NLP 논문으로 구성되며, 논문에서는 어떤 지표로 성능을 평가합니까?	RAPTOR	방법 및 절차	6	5,049 questions across 1,585 NLP papers; accuracy is measured using standard F1
ext_raptor_008	QuALITY-HARD는 일반 QuALITY 질문 중 어떤 기준을 만족하는 질문들로 구성됩니까?	RAPTOR	사실 및 정의	6	questions that a majority of human annotators answered incorrectly in a speed-setting
ext_raptor_009	QASPER에서 RAPTOR의 F1 Match 점수는 GPT-3, GPT-4, UnifiedQA를 사용할 때 각각 얼마였습니까?	RAPTOR	결과 및 비교	7	53.1%, 55.7%, and 36.6%, respectively
ext_raptor_010	QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?	RAPTOR	결과 및 비교	9	57.9 with one leaf layer versus 73.68 with all three layers
ext_raptor_011	Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?	RAPTOR	결과 및 비교	20	RAPTOR retrieves relevant information across tree layers, while DPR retrieves detailed descriptions of a narrow subset of the story
track1_0009	RAG가 LLM에서 사실적으로 부정확한 콘텐츠 생성을 줄이는 데 어떻게 기여합니까?	RAG Survey	목적 및 기여	1	By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content.
track1_0010	RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?	RAG Survey	방법 및 절차	3	The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework.

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0012	RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?	RAG Survey	목적 및 기여	1	This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.
track1_0015	RAG 프로세스에서 핵심적인 역할을 하는 세 가지 구성 기술은 무엇인가요?	RAG Survey	사실 및 정의	2	the aspects of Retrieval, Generation and Augmentation
track1_0016	RAG 방법론의 평가 방법은 어떻게 요약되어 있습니까?	RAG Survey	방법 및 절차	2	We have summarized the current assessment methods of RAG, covering 26 tasks, nearly 50 datasets, outlining the evaluation objectives and metrics, as well as the current evaluation benchmarks and tools.
track1_0019	LLaMA-30B 모델에 CAD를 적용했을 때 CNN-DM 데이터셋에서 어떤 성과가 있었나요?	CAD	결과 및 비교	3	Specifically, when applied to LLAMA-30B in CNN-DM, CAD leads to 21% increase in ROUGE-L, 14.3% increase in factKB and 7.8% increase in BERT-P.
track1_0021	CAD는 어떻게 잘못된 정보 생성을 줄이나요?	CAD	결과 및 비교	2	These results demonstrate the potential of CAD in mitigating hallucinations in text generation and overriding prior knowledge with reliable and trusted information.
track1_0023	CAD는 언어 모델이 생성하는 요약문의 사실적 정확성을 향상시키나요?	CAD	결과 및 비교	1	Experimental results from summarization tasks show that context-aware decoding significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs such as FLAN (Chung et al., 2022).

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0024	CAD를 적용하지 않은 경우와 비교했을 때, knowledge conflict QA 데이터셋에서 LLaMA-30B의 성능은 어떻게 변화하나요?	CAD	결과 및 비교	2	CAD brings a 2.9x improvement to LLaMA-30B on a knowledge conflicts QA dataset (Longpre et al., 2021).
track1_0025	RAPTOR 모델이 QuALITY 벤치마크에서 기존 성능을 얼마나 개선했나요?	RAPTOR	결과 및 비교	1	we can improve the best performance on the QuALITY benchmark by 20% in absolute accuracy.
track1_0026	RAPTOR의 트리 구조는 텍스트 클러스터링을 통해 어떻게 구축되나요?	RAPTOR	방법 및 절차	2	RAPTOR recursively clusters chunks of text based on their vector embeddings and generates text summaries of those clusters, constructing a tree from the bottom up.
track1_0027	RAPTOR가 여러 QA 작업에서 달성한 결과는 무엇인가요?	RAPTOR	결과 및 비교	2	RAPTOR coupled with GPT-4, and sometimes even with UnifiedQA, gives new state-of-the-art results on three QA tasks: free text response questions on books and movies (NarrativeQA, Ko˘cisk`y et al. 2018), full-text NLP papers (QASPER, Dasigi et al. 2021), and multiple-choice questions based on medium-length passages (QuALITY, Pang et al. 2022).
track1_0032	RAPTOR의 계층에서 검색된 노드가 어느 계층에서 오는지에 대한 연구 결과는 무엇인가요?	RAPTOR	결과 및 비교	22	We observe that between 18.5% to 57% of the retrieved nodes come from non-leaf nodes.
track1_0033	Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까?	Mi:dm K 2.5 Pro Technical Report	사실 및 정의	2	32B parameters
track1_0034	Mi:dm K 2.5 Pro의 방법론에서 AST 분석은 어떤 목적으로 사용됩니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	1	abstract syntax tree (AST) analysis for code
track1_0035	Mi:dm K 2.5 Pro 모델은 어떤 한국어 벤치마크에서 최첨단 결과를 달성했습니까?	Mi:dm K 2.5 Pro Technical Report	결과 및 비교	1	sets state-of-the-art results on Korean-specific benchmarks

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
track1_0036	Mi:dm K 2.5 Pro가 해결하려는 주요 문제는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	목적 및 기여	1	address enterprise-grade complexity through reasoning-focused optimization
track1_0037	Mi:dm K 2.5 Pro 모델의 컨텍스트 윈도우(context window) 길이는 얼마인가요?	Mi:dm K 2.5 Pro Technical Report	사실 및 정의	1	128K token context window
track1_0040	Mi:dm K 2.5 Pro의 사후 훈련 파이프라인에서 모델 병합은 어떤 역할을 합니까?	Mi:dm K 2.5 Pro Technical Report	방법 및 절차	2	improve training stability and achieve balanced performance across complex reasoning, coding, instruction following, and agentic task execution

부록 B. 추가 사례 및 탐색 분석

B.1 저장된 생성·검색 사례

E06 | track1_0012
질문: RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?
A/B 검색 문맥, 검색 및 재정렬 ID 동일
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_rag_bf4cd54870dd_2, paper_nlp_rag_bf4cd54870dd
문맥[1] 발췌: [...] knowledge-intensive tasks across different topics, [28] revealed that while unsupervised fine-tuning shows some improvement, RAG consistently outperforms it, for both existing knowledge encountered du [...]
저장 답변 발췌: [...] ### 1. 외부 지식 활용의 우수성
논문에서는 "RAG excels in dynamic environments by offering realtime knowledge updates and effective utilization of external knowledge sources with high interpretability"라고 명시하고 있습니다. [...]
Faithfulness 0.9375 | Answer Relevancy 0.9001
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.4157
B | hyde_off__cad_only
HyDE OFF / CAD ON / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_rag_bf4cd54870dd_2, paper_nlp_rag_bf4cd54870dd
저장 답변 발췌: [...] 논문]
위 내용 참조
**
답변을 뒷받침하는 구체적인 예시나 연구 결과도 포함해 주세요.
breath
** [...]
Faithfulness 0.5000 | Answer Relevancy 0.0000
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.8462
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 사례

E04 | ext_midm_004
질문: Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?
A/B 검색 문맥, 검색 및 재정렬 ID 변경
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_88a1c1d7a494, paper_midm_6954efe611cf
문맥[1] 발췌: [...] complex tasks. Furthermore, we have expanded Mi:dm K from a Korean-English bilingual model to a multilingual model supporting four languages, including Japanese and Chine [...]
저장 답변 발췌: [...] 제공된 논문 컨텍스트를 면밀히 검토한 결과, Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터가 어떤 세 가지 차원을 기준으로 고품질 대화를 설계하는지에 관한 구체적인 정보를 확인할 수 없습니다. [...]
Faithfulness 0.9000 | Answer Relevancy 0.0000
Context Precision 0.0000 | Context Recall 0.0000
전체 답변 한국어 비율 0.8250
B | hyde_on__no_decoder_control
HyDE ON / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_b8ec113edfbf, paper_midm_94d24ba9b194
문맥[4] 발췌: [...] We define high quality multi-turn conversations along three dimensions: interaction structure, topic and task, and persona. [...]
저장 답변 발췌: [...] **1. 상호작용 구조(Interaction Structure) 차원** [...]
저장 답변 발췌: [...] **2. 주제 및 과제(Topic and Task) 차원** [...]
저장 답변 발췌: [...] **3. 페르소나(Persona) 차원** [...]
Faithfulness 0.8824 | Answer Relevancy 0.8531
Context Precision 0.3250 | Context Recall 1.0000
전체 답변 한국어 비율 0.6773
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-2] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례

E05 | ext_midm_001
질문: Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?
A/B 검색 문맥, 검색 및 재정렬 ID 동일
A | hyde_off__no_decoder_control
HyDE OFF / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_6954efe611cf, paper_midm_88370fe7a52d
문맥[2] 발췌: [...] licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data. [...]
저장 답변 발췌: [...] **1. 라이선스 보유 독점(proprietary) 데이터셋** [...]
저장 답변 발췌: [...] **2. 상업적 이용이 허가된 공개(public) 데이터셋** [...]
저장 답변 발췌: [...] **3. 자체(in-house) 합성(synthetic) 데이터** [...]
Faithfulness 0.8333 | Answer Relevancy 0.8261
Context Precision 0.5833 | Context Recall 1.0000
전체 답변 한국어 비율 0.7606
B | hyde_off__cad_only
HyDE OFF / CAD ON / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_6954efe611cf, paper_midm_88370fe7a52d
저장 답변 발췌: [...] **1. Licensed Proprietary Datasets (라이선스 취득 전용 데이터셋)** [...]
저장 답변 발췌: [...] **2. Public Datasets Permitting Commercial Use (상업적 이용이 허용된 공개 데이터셋)** [...]
저장 답변 발췌: [...] **3. In-house Synthetic Data (자체 생성 합성 데이터)** [...]
Faithfulness 1.0000 | Answer Relevancy 0.8124
Context Precision 0.5833 | Context Recall 1.0000
전체 답변 한국어 비율 0.7466
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-3] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례

E02 | ext_cad_007
질문: CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?
A | hyde_on__cad_only
HyDE ON / CAD ON / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_nlp_cad_363806f889e1, paper_nlp_cad_6d4aeefa6dab
문맥[1] 발췌: [...] CAD can be used with off-the-shelf pretrained language models without any additional training. [...]
저장 답변 발췌: [...] . Improving transformer generalization through weight normalization. _arXiv preprint arXiv:2204.03296_. Sheng-Hong Huang, Xiaodan Zheng, and Jianfeng Gao. 2018. Factually faithful abstractive summarization. In _Proceedings of the 2018 Conference [...]
Faithfulness 0.0769 | Answer Relevancy 0.4602
Context Precision 1.0000 | Context Recall 1.0000
전체 답변 한국어 비율 0.0000
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-4] SCD 미적용 조건의 영어 중심 출력 사례

E03 | ext_midm_005
질문: Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?
A/B 검색 문맥, 검색 및 재정렬 ID 동일
A | hyde_on__no_decoder_control
HyDE ON / CAD OFF / SCD OFF
검색 ID (앞 2개 / 전체 8개): paper_midm_5fd8fb92ae53, paper_midm_fe2d192ffc71
문맥[1] 발췌: [...] In the Fusion SFT phase, we partition the training data into reasoning and non-reasoning subsets. We deliberately emphasize non-reasoning tasks that are relatively underrepresented in earlier stages, including creative writing, translation, and general question answering. [...]
저장 답변 발췌: [...] tasks such as math problems, code snippets, and general knowledge questions, with a composition of 29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, we apply a model merging technique using checkpoints saved at regular intervals [25]. [...]
Faithfulness 0.8125 | Answer Relevancy 0.4632
Context Precision 0.8667 | Context Recall 1.0000
전체 답변 한국어 비율 0.0000
B | hyde_on__scd_only
HyDE ON / CAD OFF / SCD ON
검색 ID (앞 2개 / 전체 8개): paper_midm_5fd8fb92ae53, paper_midm_fe2d192ffc71
저장 답변 발췌: [...] tasks such as math problems, code snippets, and general knowledge questions, with a composition of 29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, 우리는 정기적인 간격으로 저장된 체크포인트를 사용한 모델 병합 기법을 적용합니다 [25]. 단계 1의 최종 체크포인트와 비교하여, 병합된 모델은 대부분의 평가 지표에서 향상된 성능을 보여주며, GSM8K [15]를 제외하고는 그렇습니다. CPT 단계 2에서는 이전 단계에 비해 [...]
Faithfulness 0.8889 | Answer Relevancy 0.5231
Context Precision 0.8667 | Context Recall 1.0000
전체 답변 한국어 비율 0.7713
발췌는 원문 구간이며, 평가값은 전체 생성 답변 기준이다.

[그림 B-5] SCD 적용 전후 한국어 문자 비율 변화 사례

그림 B-5(E03)는 HyDE를 적용한 조건의 사례로, RQ3의 HyDE OFF 비교에 포함되지 않는다. 그림 B-1~B-5의 전체 답변과 지표는 동봉한 FINALDOCS/DATA/evidence_manifest_60q.json의 사례 ID와 질의 ID로 찾을 수 있다. 이 목록에는 생성 기록의 파일 경로와 적용 조건이 있으며, 평가값은 experiments/results/evaluation의 질의 ID·조건명으로 연결된다.

B.2 문서별 및 질문 유형별 탐색 분석

[표 B-1] 문서별 HyDE·CAD 대응 점수 차이의 평균(SD)

집단	요인	지표	유효 n	평균 차이(SD)
CAD	HyDE	근거 충실도	15	−0.049 (0.260)
CAD	HyDE	답변 관련성	15	−0.002 (0.287)
CAD	HyDE	문맥 정밀도	15	−0.082 (0.203)
CAD	HyDE	문맥 재현율	15	−0.067 (0.258)
CAD	CAD	근거 충실도	15	0.066 (0.227)
CAD	CAD	답변 관련성	15	−0.010 (0.126)
CAD	CAD	문맥 정밀도	15	−0.055 (0.131)
CAD	CAD	문맥 재현율	15	−0.067 (0.258)
Mi:dm K 2.5 Pro Technical Report	HyDE	근거 충실도	15	0.001 (0.198)
Mi:dm K 2.5 Pro Technical Report	HyDE	답변 관련성	15	0.099 (0.244)
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 정밀도	15	−0.014 (0.240)
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 재현율	15	0.133 (0.352)
Mi:dm K 2.5 Pro Technical Report	CAD	근거 충실도	15	0.008 (0.171)
Mi:dm K 2.5 Pro Technical Report	CAD	답변 관련성	15	0.034 (0.362)
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 정밀도	15	0.000 (0.000)
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 재현율	15	0.000 (0.000)
RAG Survey	HyDE	근거 충실도	15	0.157 (0.361)
RAG Survey	HyDE	답변 관련성	15	0.131 (0.134)
RAG Survey	HyDE	문맥 정밀도	15	0.004 (0.258)
RAG Survey	HyDE	문맥 재현율	15	0.067 (0.258)
RAG Survey	CAD	근거 충실도	13	−0.042 (0.381)
RAG Survey	CAD	답변 관련성	15	−0.100 (0.322)
RAG Survey	CAD	문맥 정밀도	15	0.007 (0.062)
RAG Survey	CAD	문맥 재현율	15	0.000 (0.000)

집단	요인	지표	유효 n	평균 차이(SD)
RAPTOR	HyDE	근거 충실도	15	0.065 (0.266)
RAPTOR	HyDE	답변 관련성	15	0.093 (0.396)
RAPTOR	HyDE	문맥 정밀도	15	−0.044 (0.248)
RAPTOR	HyDE	문맥 재현율	15	−0.133 (0.516)
RAPTOR	CAD	근거 충실도	15	0.073 (0.224)
RAPTOR	CAD	답변 관련성	15	0.047 (0.385)
RAPTOR	CAD	문맥 정밀도	15	0.011 (0.031)
RAPTOR	CAD	문맥 재현율	15	0.000 (0.000)

[표 B-2] 질문 유형별 HyDE·CAD 대응 점수 차이의 평균(SD)

집단	요인	지표	유효 n	평균 차이(SD)
결과 및 비교	HyDE	근거 충실도	20	−0.051 (0.176)
결과 및 비교	HyDE	답변 관련성	20	−0.022 (0.207)
결과 및 비교	HyDE	문맥 정밀도	20	−0.029 (0.153)
결과 및 비교	HyDE	문맥 재현율	20	−0.050 (0.394)
결과 및 비교	CAD	근거 충실도	20	−0.004 (0.149)
결과 및 비교	CAD	답변 관련성	20	−0.068 (0.302)
결과 및 비교	CAD	문맥 정밀도	20	−0.012 (0.081)
결과 및 비교	CAD	문맥 재현율	20	−0.050 (0.224)
목적 및 기여	HyDE	근거 충실도	3	0.188 (0.272)
목적 및 기여	HyDE	답변 관련성	3	−0.029 (0.052)
목적 및 기여	HyDE	문맥 정밀도	3	−0.111 (0.229)
목적 및 기여	HyDE	문맥 재현율	3	0.000 (0.000)
목적 및 기여	CAD	근거 충실도	3	−0.160 (0.241)
목적 및 기여	CAD	답변 관련성	3	−0.314 (0.508)
목적 및 기여	CAD	문맥 정밀도	3	0.000 (0.000)
목적 및 기여	CAD	문맥 재현율	3	0.000 (0.000)
방법 및 절차	HyDE	근거 충실도	29	0.079 (0.343)
방법 및 절차	HyDE	답변 관련성	29	0.172 (0.339)
방법 및 절차	HyDE	문맥 정밀도	29	−0.003 (0.252)
방법 및 절차	HyDE	문맥 재현율	29	0.069 (0.371)
방법 및 절차	CAD	근거 충실도	27	0.082 (0.325)
방법 및 절차	CAD	답변 관련성	29	0.068 (0.326)
방법 및 절차	CAD	문맥 정밀도	29	0.003 (0.015)
방법 및 절차	CAD	문맥 재현율	29	0.000 (0.000)
사실 및 정의	HyDE	근거 충실도	8	0.097 (0.221)
사실 및 정의	HyDE	답변 관련성	8	0.045 (0.088)
사실 및 정의	HyDE	문맥 정밀도	8	−0.133 (0.337)
사실 및 정의	HyDE	문맥 재현율	8	−0.125 (0.354)
사실 및 정의	CAD	근거 충실도	8	0.000 (0.174)
사실 및 정의	CAD	답변 관련성	8	−0.014 (0.084)
사실 및 정의	CAD	문맥 정밀도	8	−0.049 (0.170)
사실 및 정의	CAD	문맥 재현율	8	0.000 (0.000)

표 B-1과 표 B-2는 하위집단의 탐색적 기술통계다. 질문 유형의 질의 수는 사실·정의 8, 방법·절차 29, 결과·비교 20, 목적·기여 3개이며, 결측이 있는 비교는 표의 유효 n을 사용하였다.

B.3 품질 지표의 반복측정 ANOVA

표 B-3과 표 B-4는 SCD 상태별 평가 문맥에서 네 품질 지표의 H×C 반복측정 ANOVA 결과다. 근거 충실도는 결측을 제외하여 SCD OFF n=58, ON n=57이며 나머지 지표는 n=60이다. 두 표의 모든 효과는 $p \geq 0.05$였다.

[표 B-3] SCD OFF 영어 평가 문맥의 품질 지표 H×C 반복측정 ANOVA

지표	효과	df	F	p	부분 η^2
근거 충실도	H	1, 57	1.162	0.286	0.020
근거 충실도	C	1, 57	1.034	0.313	0.018
근거 충실도	H×C	1, 57	0.073	0.789	0.001
답변 관련성	H	1, 59	2.844	0.097	0.046
답변 관련성	C	1, 59	1.498	0.226	0.025
답변 관련성	H×C	1, 59	1.185	0.281	0.020
문맥 정밀도	H	1, 59	0.496	0.484	0.008
문맥 정밀도	C	1, 59	0.226	0.636	0.004
문맥 정밀도	H×C	1, 59	1.567	0.216	0.026
문맥 재현율	H	1, 59	0.039	0.843	0.001
문맥 재현율	C	1, 59	1.000	0.321	0.017
문맥 재현율	H×C	1, 59	0.109	0.742	0.002

[표 B-4] SCD ON 한국어 번역 평가 문맥의 품질 지표 H×C 반복측정 ANOVA

지표	효과	df	F	p	부분 η^2
근거 충실도	H	1, 56	2.434	0.124	0.042
근거 충실도	C	1, 56	0.137	0.713	0.002
근거 충실도	H×C	1, 56	0.188	0.666	0.003
답변 관련성	H	1, 59	3.012	0.088	0.049
답변 관련성	C	1, 59	2.628	0.110	0.043
답변 관련성	H×C	1, 59	0.011	0.917	0.000
문맥 정밀도	H	1, 59	0.158	0.693	0.003
문맥 정밀도	C	1, 59	0.000	0.994	0.000
문맥 정밀도	H×C	1, 59	0.823	0.368	0.014
문맥 재현율	H	1, 59	0.529	0.470	0.009
문맥 재현율	C	1, 59	0.396	0.532	0.007
문맥 재현율	H×C	1, 59	2.744	0.103	0.044