

졸업자격시험보고서

한국어 질의-영어 학술·기술 문서
RAG에서의 HyDE·CAD·SCD 조합
실험

지도교수: [지도교수 입력]

[소속 학과 입력]

[소속 대학·캠퍼스 입력]

[학생명 입력] · [학번 입력] · [지도교수 입력] ·

[제출일 입력]

[제출연도 입력]

제출 페이지

본 보고서는 [소속 대학 입력] [소속
학과 입력] 졸업자격실험보고서로
제출한다.

제출자: [학생명 입력] / 학번: [학번 입력] /
지도교수: [지도교수 입력] / 제출일: [제출일
입력]

인준 페이지

위 보고서를 졸업자격실험보고서로 인준함.

지도교수: [지도교수 입력] (인) / 심사위원:
[심사위원 입력] (인) / 인준일: [인준일 입력]

[소속 대학·학과 입력]

국문초록

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 외부 문서를 검색해 생성 모델의 문맥으로 제공함으로써 특정 문서에 근거한 질의응답을 가능하게 한다. 한국어로 질문하고 영어 학술·기술 문서에서 근거를 검색한 뒤 한국어로 답하는 환경에서는 질의와 문서의 언어·표현 차이, 검색 근거의 생성 단계 활용, 영어 문맥에 따른 출력 언어 이탈을 함께 고려해야 한다. 본 연구는 Hypothetical Document Embeddings(HyDE), Context-Aware Decoding(CAD), Soft Constrained Decoding(SCD)을 각각 검색 표현 확장, 문맥 기반 생성 제어, 한국어 출력 언어 제어의 실험 요인으로 두고 2×2×2 조합을 RAG-Cube로 구성하였다.

실험은 BGE-M3 밀집 검색, BM25 희소 검색, weighted Reciprocal Rank Fusion, CrossEncoder 재정렬, K-intelligence/Midm-2.0-Base-Instruct로 구성된 고정 Paper-RAG 백본을 사용하였다. RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 네 문서에 문서별 15개씩 총 60개의 한국어 질의·대상 문서 쌍을 구성하고, 8개 실험 조건을 적용하여 480개의 생성 기록을 저장하였다. HyDE는 CAD·SCD OFF의 60개 대응쌍, CAD는 동일 검색 문맥 대응쌍, SCD는 동일 질의에서 HyDE·CAD의 ON/OFF 상태를 맞춘 240개 대응쌍과 HyDE OFF 동일 검색 문맥 120개 대응쌍으로 비교하였다.

HyDE 적용 시 답변 관련성 평균 변화는 +0.0805이고 95% 신뢰구간은 [+0.0110, +0.1514]였다. 근거 충실도는 +0.0436, 문맥 정밀도는 -0.0343, 문맥 재현율은 0.0000으로 지표별 방향이 달랐다. CAD의 동일 문맥 비교에서 근거 충실도는 양쪽 평가값이 존재하는 58쌍에서 +0.0288, 95% 신뢰구간은 [-0.0367, +0.0934]였고, 답변 관련성은 60쌍에서 -0.0073이었다. SCD의 주 비교인 HyDE OFF 동일 문맥 120개 대응쌍에서 한국어 문자 비율은 평균 +0.2182, 95% 신뢰구간은 [+0.1880, +0.2487] 증가했으며, 전체 240개 대응쌍에서도 +0.2289의 변화가 나타났다.

이 평가 집합에서 HyDE의 답변 관련성은 증가하였다. CAD의 근거 충실도 평균 차이는 양수였으나 신뢰구간이 0을 포함하였다. SCD는 동일 문맥 비교에서 한국어 문자 비율을 높였다. 세 결과는 각각 답변의 질문 관련성, 동일 근거의 활용, 출력 언어라는 측정 대상에 따라 구분하여 해석하였다.

주요어: Retrieval-Augmented Generation, HyDE, Context-Aware Decoding, Soft Constrained Decoding, 한국어 질의, 영어 학술·기술 문서, 언어 이탈

Abstract

Retrieval-augmented generation (RAG) enables document-grounded question answering by retrieving external evidence and supplying it to a generator. When Korean questions target English academic or technical documents and the expected answer language is Korean, retrieval and generation involve three coupled issues: cross-lingual mismatch between queries and evidence, use of retrieved context during generation, and output-language drift toward English. This study treats Hypothetical Document Embeddings (HyDE), Context-Aware Decoding (CAD), and Soft Constrained Decoding (SCD) as binary factors for retrieval-query expansion, context-aware generation, and Korean-output control, forming an eight-condition $2 \times 2 \times 2$ experimental design termed RAG-Cube.

The fixed Paper-RAG backbone combines BGE-M3 dense retrieval, BM25 sparse retrieval, weighted Reciprocal Rank Fusion, CrossEncoder reranking, and K-intelligence/Midm-2.0-Base-Instruct. Sixty Korean query-document pairs were constructed from four English academic or technical documents, and eight configurations were applied to every pair, yielding 480 stored generation records. HyDE was compared on 60 pairs with CAD and SCD disabled, CAD was compared on identical-context pairs, and SCD was evaluated on 240 state-matched on/off pairs together with a 120-pair HyDE-OFF identical-context subset.

HyDE increased answer relevancy by +0.0805 on average, with a 95% bootstrap interval of [+0.0110, +0.1514]. Its changes in faithfulness, context precision, and context recall were +0.0436, -0.0343, and 0.0000, respectively. Under identical contexts, CAD changed faithfulness by +0.0288 on 58 complete pairs, with a 95% bootstrap interval of [-0.0367, +0.0934], while answer relevancy changed by -0.0073 on 60 pairs. In the primary SCD comparison, the Korean-character ratio increased by +0.2182 on 120 HyDE-OFF identical-context pairs, with a 95% bootstrap interval of [+0.1880, +0.2487]. Across all 240 state-matched pairs, the mean change was +0.2289. Within this evaluation set, HyDE increased answer relevancy and SCD increased the Korean-character ratio; the CAD faithfulness interval included zero.

Keywords: Retrieval-Augmented Generation, HyDE, Context-Aware Decoding, Soft Constrained Decoding, Korean query, English academic or technical document, language drift

목 차

1. 서론	9
1.1 연구배경 및 목적	9
1.2 연구범위	9
1.3 연구 질문, 분석 관점 및 논문 구성	10
2. 이론적 배경	11
2.1 Retrieval-Augmented Generation	11
2.2 하이브리드 검색과 재정렬	11
2.3 HyDE와 가상 문서 기반 검색	13
2.4 Context-Aware Decoding	13
2.5 Soft Constrained Decoding과 언어 이탈	14
2.6 RAG 평가	15
2.7 관련 연구와 본 연구의 위치	16
3. 시스템 설계	18
3.1 연구 및 실험 요구사항	18
3.2 아키텍처 설계	18
3.3 상세설계	19
4. 프로그램 구현	21
4.1 시스템 환경	21
4.2 시스템 구성	22
4.3 시스템 구현	23
5. 실험	25
5.1 실험 대상과 구성	25
5.2 평가 및 분석 방법	26
5.3 RAG-Cube 조합별 결과	27
5.4 HyDE 결과 및 해석	29
5.5 CAD 결과 및 해석	31
5.6 SCD 출력 언어 결과 및 해석	34

5.7 대표 입출력 및 요구사항별 실행 결과	38
5.8 종합 논의	40
5.9 실험 범위와 해석 기준	41
6. 결론	42
6.1 연구 질문별 최종 답	42
6.2 비교 설계의 의의	42
6.3 적용 시 실험 조건 선택	43
6.4 후속 연구 방향	43
참고문헌	44
그림 자료 이용 정보	46
부록 A~B	47, 54

그 립 목 차

[그림 1-1] 한국어 질의 기반 영어 학술·기술 문서 RAG 연구 환경	9
[그림 2-1] RAG의 검색기-생성기 구조	11
[그림 2-2] 긴 문맥에서 관련 정보 위치에 따른 성능 변화	12
[그림 2-3] HyDE의 가상 문서 기반 검색 구조	13
[그림 2-4] Context-Aware Decoding의 분포 대조 구조	14
[그림 2-5] 다국어 RAG의 출력 언어 이탈 사례	15
[그림 2-6] RAGAS의 근거 충실도 높음/낮음 예시	16
[그림 3-1] HyDE·CAD·SCD RAG-Cube 8개 조건	19
[그림 4-1] 고정 Paper-RAG 백본 실행 흐름	23
[그림 4-2] 생성 기록-평가-대응 분석 흐름	24
[그림 5-1] 60개 질의 평가 및 HyDE·CAD·SCD 대응 비교 설계	27
[그림 5-2] 평가 프로토콜별 RAG-Cube 조건 평균	29
[그림 5-3] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례	30
[그림 5-4] HyDE와 CAD의 주 대응 비교	31
[그림 5-5] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례	33
[그림 5-6] RAG-Cube 조건별 생성 시간	34
[그림 5-7] SCD OFF 조건의 출력 언어 이탈 사례	35
[그림 5-8] 동일 검색 문맥에서 SCD 적용 전후 출력 언어 변화 사례	37
[그림 5-9] SCD의 한국어 문자 비율 변화	38
[그림 5-10] 질의·검색 근거·생성 답변·평가 결과 예시	39
[그림 5-11] HyDE·CAD 조건별 근거 충실도·답변 관련성 대응 차이	41
[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 추가 사례 ·	54

표 목 차

[표 2-1] 관련 연구와 본 실험의 연결	17
[표 3-1] 연구 및 실험 요구사항	18
[표 3-2] RAG-Cube 8개 조건	19
[표 3-3] 실험 요인별 적용 위치와 비교 단위	20
[표 4-1] 실험 실행 환경	21
[표 4-2] 고정 Paper-RAG backbone	22
[표 4-3] 조건별 평균 생성 시간	23
[표 4-4] 생성 기록의 주요 필드	23
[표 5-1] 4개 문서별 질의 구성	25
[표 5-2] SCD 평가 프로토콜별 RAG-Cube 조건 평균	28
[표 5-3] HyDE 주 비교 결과	31
[표 5-4] CAD 동일 문맥 주 비교 결과	34
[표 5-5] SCD 조합별 한국어 문자 비율 변화	38
[표 5-6] SCD 대응쌍 분석 요약	38
[표 A-1] 60개 질의-대상 문서 쌍	47
[표 B-1] 문서별 탐색 분석	55
[표 B-2] 질문 유형별 탐색 분석	56

1. 서론


1.1 연구배경 및 목적

한국어 질의로 영어 학술·기술 문서를 활용할 때는 질의와 문서의 언어 차이, 검색 근거의 활용, 한국어 출력의 일관성을 함께 고려해야 한다. 특정 논문의 방법, 실험 조건, 수치와 결론을 확인하려면 생성 답변을 실제 문서의 근거와 연결해야 한다. 검색 증강 생성(Retrieval-Augmented Generation, RAG)은 외부 문서를 검색해 생성 모델의 입력으로 제공하는 질의응답 구조이다[1].

이 연구에서는 한국어 질의로 영어 학술·기술 문서에서 근거를 찾고 한국어 답변을 생성하는 환경을 다루었다. 분석 대상은 질의와 문서의 표현 차이에 따른 검색 결과, 검색 문맥이 답변에 반영되는 정도, 영어 문맥을 입력했을 때의 출력 언어이다.

HyDE는 질의에서 가상 문서를 생성해 검색 표현을 확장한다[2]. CAD는 문맥 포함·제외 확률 분포를 대조하여 생성 토큰의 점수를 조절한다[3]. SCD는 목표 언어와 비목표 언어 토큰의 점수를 다르게 조정한다[4]. 이들 기법을 적용한 뒤 검색 결과, 답변 품질, 출력 언어를 각 기법의 개입 위치에 맞춰 비교하였다.

연구 목적은 선행연구의 HyDE·CAD·SCD[2][3][4]를 고정된 Paper-RAG 백본에 적용하고, 한국어 질의-영어 문서 환경에서 나타나는 변화를 비교하는 것이다. 검색 입력을 바꾸는 HyDE와 생성 단계에 적용하는 CAD·SCD는 비교 조건을 구분하였다. 대응쌍의 구성과 문맥 동일성 확인 기준은 3.3절에서 설명한다.



고정 Paper-RAG backbone에서 HyDE, CAD, SCD를 독립 실험 요인으로 적용

[그림 1-1] 한국어 질의 기반 영어 학술·기술 문서 RAG 연구 환경

1.2 연구범위

연구 대상은 RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 네 영어 학술·기술 문서와 문서별 15개씩 구성한 60개 한국어 질의-대상 문서 쌍이다. 각 질의에 8개 RAG-Cube 조건을 모두 적용하여 480개의 생성 기록을 저장하였다. 검색과 생성에는

BGE-M3, BM25, weighted RRF, CrossEncoder, 상위 5개 문맥과 Mi:dm 2.0 Base Instruct를 공통으로 사용하였다. 구체적인 실행 설정은 4.1절에 정리하였다.

HyDE는 CAD·SCD OFF의 60개 대응쌍에서 검색부터 답변 생성까지의 변화를 비교하였다. CAD는 동일 검색 문맥에서 답변 품질과 생성 시간을 비교하였다. SCD는 HyDE OFF 동일 문맥 120개 대응쌍을 주 비교로 삼고, HyDE·CAD 상태를 맞춘 전체 240개 대응쌍을 함께 분석하였다. 답변 품질은 RAGAS 지표로, 출력 언어는 한국어 문자 비율로 측정하였다.

1.3 연구 질문, 분석 관점 및 논문 구성

연구 질문은 다음과 같다. 첫째, CAD·SCD를 OFF로 고정했을 때 HyDE 적용 전후의 답변 관련성과 다른 RAGAS 지표는 어떻게 달라지는가. 둘째, 동일 검색 문맥에서 CAD 적용 전후의 답변 품질과 생성 시간은 어떻게 달라지는가. 셋째, HyDE·CAD 상태를 맞춘 SCD 대응쌍, 특히 HyDE OFF 동일 문맥 대응쌍에서 한국어 문자 비율은 얼마나 달라지는가. 넷째, 조합별 평균과 요인별 대응 결과에 근거하여 적용 목적별로 어떤 조건을 선택할 수 있는가.

분석은 대응 평균 차이와 부트스트랩 신뢰구간, 검색·재정렬 체크 ID와 문맥 동일성, 실제 질문·검색 근거·생성 답변·평가값을 함께 사용한다. 정량 결과와 개별 입출력 사례를 동일한 질의와 실험 조건 단위에서 제시한다.


2장에서는 RAG와 세 실험 요인, 평가 및 관련 연구를 정리한다. 3장은 실험 요구사항과 비교 설계를, 4장은 구현과 생성 기록 저장 구조를 설명한다. 5장은 60개 질의 평가 결과와 사례를 제시하고, 6장은 주요 결과와 적용 기준 및 후속 연구를 종합한다.

2. 이론적 배경

2.1 Retrieval-Augmented Generation

RAG는 질의와 관련된 외부 문서를 검색하고, 선택된 문맥을 생성 모델의 입력에 포함하여 답변을 만드는 구조이다[1]. 문서 집합을 D , 질의를 q , 검색 문맥을 C , 답변을 y 라고 하면 과정은 $\text{Retrieve}(q, D)$ 로 C 를 얻고, 생성 모델이 q 와 C 를 조건으로 y 를 생성하는 흐름으로 설명할 수 있다. 학술문서 질의응답에서는 검색 단계와 생성 단계를 구분해 보는 것이 중요하다. 필요한 문단의 검색 상태와 검색 문단이 최종 답변에 반영되는 정도는 서로 다른 분석 대상이기 때문이다.

Lewis 외[1]는 사전학습 검색기(retriever)가 외부 문서 인덱스에서 관련 문서를 찾고, 생성기(generator)가 질의와 검색 문서를 함께 사용해 출력을 생성하는 RAG 구조를 제시하였다. 그림 2-1은 이 개념을 바탕으로 본 연구에서 구성한 독립 도식으로, 외부 문서 검색과 질의·문맥을 이용한 답변 생성의 흐름을 보여준다. 본 연구의 하이브리드 검색과 디코딩 실험은 이 검색-생성 분리를 공통 기반으로 사용한다.



[그림 2-1] RAG의 검색기-생성기 구조

본 연구 작성. Lewis 외[1]의 RAG 구조 참고.

검색 결과와 답변 품질을 구분하기 위해 검색·재정렬 청크 ID, 최종 검색 문맥과 생성 답변을 함께 저장하였다. 문맥 수준 지표와 답변 수준 지표는 각각 계산하였다.

$$C_q = \text{Retrieve}(q, D)$$

$$y = LM(q, C_q)$$

2.2 하이브리드 검색과 재정렬

고정 백본은 BGE-M3 기반 밀집 검색과 BM25 기반 희소 검색을 결합한다. 밀집 검색은 질의와 문서 구간의 의미적 유사성을 이용해 어휘가 정확히 일치하지 않아도 관련 후보를 찾고, BM25는 모델명·약어·수치처럼 표면 일치가 중요한 표현을 보완한다[5][6]. 두 결과는 순위 기


반 weighted Reciprocal Rank Fusion으로 결합하며[7], CrossEncoder가 질의와 각 문서 구간의 관련성을 다시 계산해 순서를 조정한다[8].

밀집 검색과 BM25의 가중치는 각각 0.6과 0.4, 검색 후보 수와 재정렬 후보 수는 각각 8개, 최종 문맥 수는 5개로 고정하였다. 이 설정을 모든 RAG-Cube 조건에 공통으로 적용하였다.

한국어 질문의 설명형 표현과 영어 원문의 제목·방법론 용어는 언어와 표면 표현에서 차이가 난다. 논문명, 데이터셋명, 모델 크기와 하이퍼파라미터의 정확한 표기는 검색 단서가 된다. 밀집 검색과 희소 검색을 결합한 이유는 의미적 유사성과 표면 일치를 함께 활용하기 위해서다.

재정렬은 검색 후보의 우선순위를 조정하고, 생성 모델은 선택된 문맥을 입력으로 답변을 만든다. 검색 결과가 바뀌는 경우와 같은 문맥에서 생성 방식만 바뀌는 경우를 구분해야 두 단계의 영향을 해석할 수 있다.

관련 문서 구간을 검색하더라도 생성 모델이 이를 활용하는 정도는 입력 내 위치에 따라 달라질 수 있다. Liu 외[12]는 다중 문서 질의응답에서 정답 문서가 입력의 처음이나 끝에 있을 때보다 중간에 있을 때 성능이 낮아지는 U자형 패턴을 보고하였다. 그림 2-2는 원 논문의 해당 결과이다. 본 실험에서는 문맥 수와 순서 정책을 고정하고, 검색 결과와 생성 결과를 별도 지표로 기록하였다.



[그림 2-2] 긴 문맥에서 관련 정보 위치에 따른 성능 변화

출처: Liu 외[12], 그림 1에서 발췌.


Weighted RRF는 다음과 같이 표현할 수 있으며, 본 실험은 RRF 상수 $k=60$ 을 사용한다.

$$RRF(d) = \frac{0.6}{k + rank_{dense(d)}} + \frac{0.4}{k + rank_{BM25(d)}}$$

2.3 HyDE와 가상 문서 기반 검색

HyDE는 질의를 바탕으로 가상 문서를 생성하고, 해당 문서의 임베딩을 검색에 활용하는 방법이다[2]. 가상 문서를 거치면 짧은 질의를 문서 형태의 표현으로 확장할 수 있다.

Gao 외[2]의 HyDE는 언어 모델이 질의를 바탕으로 가상 문서를 생성하고, 인코더가 이를 임베딩으로 변환해 실제 문서 집합에서 유사한 문서를 검색한다. 그림 2-3은 질의와 문서를 직접 비교하는 대신 가상 문서를 거쳐 검색하는 구조를 보여준다.



[그림 2-3] HyDE의 가상 문서 기반 검색 구조

출처: Gao 외[2], 그림 1에서 발췌·편집.

HyDE ON에서는 한국어 질의를 영어로 변환한 뒤 가상 문서를 생성하여 밀집 검색 입력으로 사용하였다. BM25와 CrossEncoder에는 원질의를 유지하였다. 최종 답변은 검색된 실제 문서 구간을 근거로 생성하였다. 따라서 HyDE 비교에는 번역, 가상 문서 생성, 밀집 검색, 순위 결합, 재정렬과 문맥 선택의 변화가 함께 포함된다. 검색 청크 ID와 최종 문맥의 변화를 답변 관련성의 변화와 함께 분석하였다.

2.4 Context-Aware Decoding

CAD는 문맥 포함·제외 다음 토큰 확률 분포를 대조하여 문맥에 의해 상대적으로 강화된 토큰의 점수를 높이는 디코딩 방법이다[3]. 본 실험에서는 $\alpha=0.5$ 를 고정하였다. 검색 이후의 생성 변화를 비교하기 위해 주 대응쌍의 검색·재정렬 청크 ID와 최종 문맥이 같은지 확인하였다.

Shi 외[3]는 문맥 포함 분포와 문맥 제외 분포를 대조해 문맥에 의해 강화되는 토큰의 상대적 비중을 높이는 구조를 제시하였다. 그림 2-4의 원 논문 사례는 모델의 기존 지식과 제공된 문맥이 충돌할 때 두 분포가 서로 다른 토큰을 선호하고, CAD가 그 차이를 이용해 문맥 쪽 신호를 강화하는 방식을 보여준다.




Figure 1: An illustration of context-aware decoding.

[그림 2-4] Context-Aware Decoding의 분포 대조 구조

출처: Shi 외[3], 그림 1에서 발췌.

문맥 포함 로짓을 z_{ctx} , 문맥 제외 로짓을 z_{noctx} 라고 하면 본 연구의 CAD 점수는 다음과 같이 표현한다.

$$z_{CAD} = (1 + \alpha)z_{ctx} - \alpha z_{noctx}$$

CAD는 생성 단계마다 문맥 포함 분포와 문맥 제외 분포를 계산하므로 단일 분포보다 실행 비용이 증가할 수 있다. 결과는 근거 충실도, 답변 관련성, 생성 시간을 함께 분석한다. 동일 입력에서 나타나는 질의별 변화와 평균을 함께 분석해 문맥 기반 로짓 조절의 결과 분포를 확인한다.

동일 문맥 대응쌍의 구체적인 구성은 3.3절에 제시한다. 검색 결과를 고정한 비교에서는 답변 품질의 차이를 검색 선택의 차이와 구분할 수 있다.

2.5 Soft Constrained Decoding과 언어 이탈

다국어 RAG에서는 질의와 문맥 내 예시가 목표 언어로 주어져도 검색 근거가 다른 언어일 때 생성 답변이 검색 문서의 언어 쪽으로 이동하는 출력 언어 이탈(language drift)이 발생할 수 있다. Li 외[4]는 다국어 RAG에서 이러한 현상을 분석하고, 추론 과정에서 목표 언어와 비 목표 언어가 혼합된 뒤 최종 출력이 비목표 언어로 이동하는 사례를 제시하였다. 그림 2-5는 원 논문에 제시된 출력 언어 이탈 사례다.




Figure 1: Illustration of language drift in multilingual RAG. The user query and in-context examples are provided in the target language (e.g., Chinese), while the retrieved context is written in a non-target language (e.g., English). During reasoning, the model mixes languages and ultimately outputs the final answer in a non-target language.

[그림 2-5] 다국어 RAG의 출력 언어 이탈 사례

출처: Li 외[4], 그림 1에서 발췌·편집.

SCD는 어휘 집합을 목표 언어, 비목표 언어와 중립 토큰으로 나누고 토큰 점수를 조정하는 디코딩 방법이다[4]. 본 실험에서는 한국어어를 목표 언어로 두고 $\alpha=1.1$, $\beta=0.9$, $T_{start}=5$ 를 사용하였다. 생성 토큰 수가 5 미만일 때는 기존 점수를 유지하고, 5 이상부터 한국어 목표 토큰에는 α , 비목표 언어 토큰에는 β 를 곱하며 중립 토큰의 점수는 유지하였다. CAD와 함께 적용할 때는 CAD 점수를 계산한 뒤 SCD 처리를 적용하였다.

출력 언어는 생성 답변의 한글 문자 수를 한글 문자와 ASCII 영문자 수의 합으로 나눈 한국어 문자 비율로 측정하였다. 후속 사람 평가의 측정 항목은 6.4절에 정리하였다.

SCD의 토큰 그룹별 점수 조정과 한국어 문자 비율은 다음 수식으로 정의한다.

$$\tilde{z}_i = \alpha z_i$$

$$\tilde{z}_i = \beta z_i$$

$$\tilde{z}_i = z_i$$

$$KoreanRatio = \frac{N_{Hangul}}{N_{Hangul} + N_{ASCII}}$$

논문 제목, 모델명과 데이터셋명 등의 영어 표기를 포함하여 실제 답변의 언어 구성을 계산하였다. SCD 대응쌍의 구성과 변화 판정 기준은 5.2절에 설명한다.

2.6 RAG 평가

HyDE와 CAD의 품질 비교에는 RAGAS의 근거 충실도(faithfulness), 답변 관련성(answer relevancy), 문맥 정밀도(context precision), 문맥 재현율(context recall)을 사용하였다[9]. 근거 충실도는 답변의 주장이 제공된 문맥에 의해 지지되는 정도를, 답변 관련성은 답변이 질문에 대응하는 정도를 측정한다. 문맥 정밀도는 관련 근거가 검색 결과의 상위에 배치되는 정도를, 문맥 재현율은 참조 답변에 필요한 근거가 검색 문맥에 포함된 정도를 측정한다.

RAGAS 원 연구는 질문-문맥-답변 예시로 평가 차원을 설명한다. 그림 2-6은 WikiEval의 동일 질문과 문맥에 대해 근거가 지지하는 답변과 지지하지 않는 답변을 대비한 원 논문의 표 2이다. 질문에 관련된 답변인지와 문맥이 그 답변을 지지하는지는 별도로 평가해야 함을 보여 준다.

Question	Context	Answer
Who directed the film Oppenheimer and who stars as J. Robert Oppenheimer in the film?	Oppenheimer is a 2023 biographical thriller film written and directed by Christopher Nolan. Based on the 2005 biography American Prometheus by Kai Bird and Martin J. Sherwin, the film chronicles the life of J. Robert Oppenheimer, a theoretical physicist who was pivotal in developing the first nuclear weapons as part of the Manhattan Project, and thereby ushering in the Atomic Age. Cillian Murphy stars as Oppenheimer, with Emily Blunt as Oppenheimer's wife Katherine "Kitty" Oppenheimer.	<i>High Faithfulness:</i> Christopher Nolan directed the film Oppenheimer. Cillian Murphy stars as J. Robert Oppenheimer in the film. <i>Low Faithfulness:</i> James Cameron directed the film Oppenheimer. Tom Cruise stars as J. Robert Oppenheimer in the film.

Table 2: Example from WikiEval, showing answers with high and low faithfulness.

[그림 2-6] RAGAS의 근거 충실도 높음/낮음 예시

출처: Es 외[9], 표 2에서 발췌.

요인별 대응 차이는 동일 질의의 ON/OFF 차이를 이용한 대응 비교로 분석하고, 질의를 재 표집 단위로 하는 부트스트랩 신뢰구간을 함께 제시한다. 자동 평가 분석은 평가값이 존재하는 유효 대응쌍을 사용한다. SCD의 출력 언어 변화는 RAGAS와 별도로 한국어 문자 비율로 측정한다. 실제 대응쌍 구성, 유효 표본 수와 변화 판정 기준은 5.2절에서 제시한다.

2.7 관련 연구와 본 연구의 위치

검색 증강 생성 연구는 검색기의 표현력, 여러 문서 구간의 활용, 디코딩 제어와 검색·생성의 자기검증으로 확장되어 왔다. Dense Passage Retrieval은 밀집 검색의 대표 구조를 정립했고[10], Fusion-in-Decoder는 여러 검색 문서 구간을 생성 단계에서 함께 이용하는 방식을 제안했다[11]. 긴 문맥에서는 관련 정보의 위치에 따라 모델의 활용 정도가 달라질 수 있다는 분석이 보고되었으며[12], contrastive decoding은 서로 다른 조건의 생성 분포를 대조하는 관점을 제시했다[13]. RAPTOR는 세부 문서 구간과 상위 요약을 계층적으로 구성하는 검색 구조를 제안했고[14], Self-RAG[15]와 Corrective RAG[16]는 검색 필요성이나 근거 품질을 생성 과정에서 점검하는 방향을 보였다.

RAG 시스템 전반을 정리한 조사 연구[17], 한국어·영어 이중언어 생성 모델에 관한 Mi:dm 2.0 연구[18], RAG의 구성과 평가를 체계화한 조사 연구[19]는 본 실험의 시스템·언어 조건을 설정하는 배경이 된다. 검색 모델의 도메인·과제 간 편차는 BEIR[20]과 MTEB[21] 같은 벤치마크의 관점에서 참고하며, 실험 문서 집합 중 하나인 Mi:dm K 2.5 Pro는 해당 기술 보고서[22]를 사용한다.

본 연구는 HyDE, CAD, SCD를 각각 검색 표현 확장, 문맥 기반 생성 제어, 출력 언어 제어로 고정 백본 안에 배치하고, 각 기법의 적용 위치에 맞는 대응 비교를 수행하였다. HyDE는 검색 입력 변화까지 포함한 종단 간 변화로, CAD는 동일 문맥에서의 생성 변화로, SCD는 동일 질의에서 HyDE·CAD 상태를 맞춘 출력 언어 변화로 분석한다.

표 2-1은 선행연구와 본 실험의 연결을 정리한다. DPR과 BEIR는 검색 표현과 도메인별 평가에, FiD와 긴 문맥 연구는 여러 문맥의 활용에 관련된다. 대조 디코딩은 CAD의 분포 대조와 연결되며, Self-RAG와 CRAG는 검색 필요성과 근거 품질을 점검한다.

[표 2-1] 관련 연구와 본 실험의 연결

연구 흐름	대표 연구	본 연구에서의 적용 범위	해석 범위
밀집 검색	DPR[10], BEIR[20]	한국어 질의와 영어 문장 사이의 검색 표현 간극을 HyDE 조건으로 관찰	본 연구의 고정 백본 적용 범위
다중 문맥 생성	FiD[11], 긴 문맥 분석[12]	rerank된 상위 5개 문맥을 고정해 answer/context 지표를 분리	문맥 길이와 순서 정책은 고정
가상 문서 검색	HyDE[2]	H1/H0 종단 간 대응 비교와 검색 체크 ID 확인	가상 문서는 검색 표현으로 사용
대조 디코딩	CAD[3], Contrastive Decoding[13]	같은 입력에서 C1/C0 대응 비교	CAD $\alpha=0.5$ 고정 조건
교정·자기검증 RAG	Self-RAG[15], CRAG[16]	검색·생성·출력 문제를 별도 층위로 해석하는 관점	관련 연구의 비교 관점으로 참조
RAG 평가	RAGAS[9], RAG survey[19]	근거 충실도·답변 관련성·문맥 정밀도·문맥 재현을 평가	자동 평가 지표와 대응 비교에 사용

3. 시스템 설계

3.1 연구 및 실험 요구사항

세 요인의 비교 조건을 60개 질의에 동일하게 적용하였다. 각 질의 ID를 하나의 대상 문서에 연결하고 모든 질의에 8개 조건을 적용하였다. H·C·S 이외의 백본은 공통으로 유지하였다. 생성 기록에는 답변, 검색·재정렬 체크 ID, 검색 문맥, 디코딩 메타데이터와 실행 시간을 저장하였다. 질의 데이터에는 원문 페이지와 정답 근거 구간을 기록하였다.


[표 3-1] 연구 및 실험 요구사항

요구사항	확인 기준	값
한국어 질의 기반 영문 문서 QA	질의와 대상 문서 연결	60개 질의-문서 쌍
실험 요인	HyDE·CAD·SCD ON/OFF	2×2×2, 8개 조건
생성 기록	조건별 생성 기록	480개, 조건별 60개
출력 언어	한국어 문자 비율	SCD ON/OFF 240개 대응쌍
자료 식별	query ID, config_name, 원문 페이지, 정답 근거 구간	60개 질의 메타데이터와 480개 생성 기록

3.2 아키텍처 설계

실험 아키텍처는 질의 입력, 검색 표현 구성, 하이브리드 검색, 재정렬, 문맥 선택, 조건별 디코딩, 생성 기록 저장, 평가·분석의 순서로 구성된다. HyDE OFF에서는 원질의를 밀집 검색에 사용하고, HyDE ON에서는 번역된 질의에서 만든 가상 문서를 밀집 검색 입력으로 사용한다. BM25와 CrossEncoder에는 원질의를 유지한다. 검색 후보는 weighted RRF와 CrossEncoder를 거친 뒤 ContextCompressor의 문맥 길이 관리 단계를 통과하고 상위 5개 문맥으로 구성된다.

생성 단계에서는 같은 Mi:dm 2.0 Base Instruct를 사용하되 CAD와 SCD만 선택적으로 적용한다. CAD는 문맥 포함·제외 두 분포를 이용해 토큰 점수를 조절하고, SCD는 한국어 목표 토큰·비목표 언어 토큰·중립 토큰 분할에 따라 언어 점수를 조절한다. 생성이 끝나면 질의, 대상 문서, 실험 조건, 검색 문맥, 생성 답변, 생성 시간과 요인별 메타데이터를 하나의 생성 기록에 저장한다. 이후 평가와 분석은 이 생성 기록을 읽어 수행한다.



[그림 3-1] HyDE·CAD·SCD RAG-Cube 8개 조건

3.3 상세설계

RAG-Cube의 여덟 조건은 H, C, S의 ON/OFF로 구성한다. 실험 조건은 가독성을 위한 H0C0S0 표기와 실제 저장 필드 config_name, use_hyde, use_cad, use_scd를 함께 사용해 확인한다. 실행 상태는 실험 조건 이름과 파라미터 필드를 함께 대조한다. SCD ON 생성 기록에는 mode, alpha=1.1, beta=0.9, Tstart=5가, CAD ON 생성 기록에는 alpha=0.5가 저장된다.

[표 3-2] RAG-Cube 8개 조건

조건	HyDE	CAD	SCD	생성 수
H0C0S0	OFF	OFF	OFF	60
H0C1S0	OFF	ON	OFF	60
H0C0S1	OFF	OFF	ON	60
H0C1S1	OFF	ON	ON	60
H1C0S0	ON	OFF	OFF	60
H1C1S0	ON	ON	OFF	60
H1C0S1	ON	OFF	ON	60
H1C1S1	ON	ON	ON	60

[표 3-3] 실험 요인별 적용 위치와 비교 단위

요인	적용 위치	주 비교	주 지표
HyDE	검색 표현 확장	CAD OFF·SCD OFF의 60 대응쌍	RAGAS 품질 지표
CAD	문맥 기반 디코딩	동일 문맥 60쌍(근거 충실도 유효쌍 58개)	근거 충실도·답변 관련성·생성 시간
SCD	출력 토큰 로짓 제어	HyDE OFF 동일 문맥 120쌍; 전체 240 상태 일치 대응쌍	한국어 문자 비율

비교 설계는 요인별로 다르다. HyDE 주 대응 비교는 동일 질의의 H1C0S0과 H0C0S0을 연결하며 검색 결과 변화까지 포함한 종단 간 차이를 측정한다. CAD 주 대응 비교는 동일 질의의 H0C1S0과 H0C0S0을 연결하고 검색·재정렬 청크 ID와 최종 검색 문맥이 모두 같은지를 확인한다. SCD 주 대응 비교는 HyDE OFF에서 S 상태만 다른 120개 동일 문맥 대응쌍으로 구성하며 검색·재정렬 청크 ID와 최종 검색 문맥의 동일성을 확인한다. 이 비교에서는 검색 문맥을 동일하게 유지한 상태에서 SCD ON/OFF의 출력 언어 차이를 측정한다. 추가로 동일 질의에서 HyDE·CAD의 ON/OFF 상태를 맞춘 전체 240개 SCD 대응쌍에서 조건 전반의 출력 언어 변화를 분석한다.

평가 결과는 질의 ID와 실험 조건을 기준으로 생성 기록에 연결하였다. 조건별 평균은 해당 조합의 결과를 요약하고, 대응 차이와 부트스트랩 신뢰구간은 같은 질의에서 특정 요인을 바꾼 결과를 요약한다. 두 분석의 표본 수와 비교 조건은 구분하여 기록하였다.

4. 프로그램 구현

4.1 시스템 환경

생성에는 K-intelligence/Midm-2.0-Base-Instruct를 사용하고 최대 생성 토큰 수를 512로 설정하였다. 답변은 각 단계에서 확률이 가장 높은 토큰을 선택하는 방식으로 생성하였다.

문서 청크는 Python split()의 공백 분리 단위를 기준으로 최대 512개 단어, 64개 단어 중첩, 최소 50개 단어로 구성하였다. BGE-M3 밀집 검색과 BM25 희소 검색은 dense 0.6, BM25 0.4의 weighted RRF(k=60)로 결합하고 cross-encoder/ms-marco-MiniLM-L-6-v2로 재정렬하였다. 동일 CrossEncoder를 모든 조건에 적용하였다. 검색 후보 수와 재정렬 후보 수는 각각 8개, 최종 생성 문맥은 5개로 설정하였다.

문맥 길이 관리에는 ContextCompressor를 사용하였다. 설정값은 split()으로 계산한 공백 분리 기준 최대 3,072개 단어와 압축 비율 0.5이며, 추출식 압축으로 문맥 길이를 관리하였다. 표 4-1은 생성 기록에 저장된 모델, 검색·생성 설정과 요인별 파라미터를 정리한다.

검색 폭 설정은 최종 평가 집합과 분리된 5개 튜닝 질의를 사용하여 사전에 선정하였다. 검색 후보 수, 재정렬 후보 수와 최종 문맥 수를 달리한 세 가지 설정을 비교하였으며, 문맥 재현율 0.95 이상을 충족한 후보 가운데 평균 근거 충실도가 가장 높은 설정을 선택하였다. 그 결과 검색 후보 수 8, 재정렬 후보 수 8, 최종 문맥 수 5를 확정하고 이후 60개 평가 질의의 모든 RAG-Cube 실험 조건에 동일하게 적용하였다.

[표 4-1] 실험 실행 환경

구성	생성 기록 기준 값
생성 모델	K-intelligence/Midm-2.0-Base-Instruct
답변 생성 방식	각 단계에서 확률이 가장 높은 토큰 선택
검색 구성	BGE-M3 밀집 검색 + BM25 희소 검색 + weighted RRF(k=60; 0.6/0.4) + cross-encoder/ms-marco-MiniLM-L-6-v2
검색 후보 수 / 재정렬 후보 수	8 / 8
청크 분할	공백 분리 기준 최대 512개 단어 / 64개 단어 중첩 / 최소 50개 단어
문맥 길이 관리	ContextCompressor 추출식; 공백 분리 기준 최대 3,072개 단어; 압축 비율 0.5
최종 문맥 수	5
max_new_tokens	512
CAD α	0.5
SCD	$\alpha=1.1$, $\beta=0.9$, Tstart=5

[표 4-2] 고정 Paper-RAG backbone

단계	고정 구성
입력	한국어 질의와 지정 대상 문서
검색	BGE-M3 밀집 검색 + BM25 희소 검색
결합	weighted Reciprocal Rank Fusion
재정렬	cross-encoder/ms-marco-MiniLM-L-6-v2
문맥 구성	ContextCompressor 문맥 길이 관리 후 재정렬 상위 5개 문맥
생성	Mi:dm 2.0 Base Instruct; max_new_tokens=512
요인	HyDE 검색 표현 확장 / CAD·SCD 생성 제어
[표 4-2 주석] 검색 후보 수 8, 재정렬 후보 수 8, 최종 문맥 수 5는 최종 평가 집합과 분리된 5개 튜닝 질의의 검색 폭 비교를 통해 사전에 선정한 값이다. CAD와 SCD의 파라미터는 각 기법의 실험 설정에 따라 별도로 적용하였다.	

4.2 시스템 구성

프로그램은 질의 집합과 원문 청크를 읽는 입력부, HyDE를 포함한 검색 표현 구성부, 밀집·희소 검색과 결합·재정렬·문맥 길이 관리를 수행하는 검색부로 구성된다. 이어서 CAD·SCD를 선택적으로 적용하는 생성부, 생성 기록과 평가 결과 저장부, 분석·재현 모듈을 사용한다. 모든 실험 조건은 동일한 질의 집합과 백본을 사용하고 H·C·S 상태만 바꾼다.

검색부는 HyDE의 출력 또는 원질의를 입력으로 받아 밀집 검색을 수행하고, 원질의로 BM25 검색과 CrossEncoder 재정렬을 수행하였다. 생성부에는 문맥과 질문을 전달하고 CAD·SCD 처리기를 선택적으로 적용하였다. 저장부가 기록한 검색 청크 ID, 문맥, 파라미터와 생성 시간은 대응쌍 구성 시 입력 동일성과 실제 적용 상태를 확인하는 데 사용하였다.



[그림 4-1] 고정 Paper-RAG 백본 실행 흐름

4.3 시스템 구현

주 실험 실행기는 60개 질의-문서 쌍 각각에 8개 조건을 적용하였다. HyDE가 적용된 기록에는 검색 표현 생성 결과와 사용 상태를, CAD·SCD가 적용된 기록에는 처리기의 활성 상태와 파라미터를 저장하였다. 검색 이력에는 검색·재정렬 청크 ID와 최종 문맥을, 생성 결과에는 답변, 생성 시간과 디코딩 방식을 기록하였다.


[표 4-3] 조건별 평균 생성 시간

조건	생성 수	평균 생성 시간(초)	생성 시간 중앙값(초)
H0C0S0	60	20.792	16.077
H0C1S0	60	63.867	57.819
H0C0S1	60	18.898	17.579
H0C1S1	60	55.159	51.127
H1C0S0	60	23.44	22.245
H1C1S0	60	73.532	71.7
H1C0S1	60	24.892	24.714
H1C1S1	60	64.125	64.834

[표 4-4] 생성 기록의 주요 필드

구분	필드
식별	query_id, paper, config_name, status
요인	use_hyde, use_cad, use_scd, parameter fields
검색	retrieved_chunk_ids, reranked_chunk_ids, contexts
생성	generated_answer, duration_seconds, decoding_mode
재현	generation_model, retrieval backend, context count

CAD는 같은 생성 접두 시퀀스에서 문맥 포함·제외 분포를 계산하도록 구현하였다. 표 4-3은 이 구현에서 측정한 조건별 생성 시간을 요약한다. SCD는 생성 중 토큰 점수를 조정하는 처리기로 적용하였으며, 한국어 문자 비율은 저장된 답변 문자열에서 다시 계산할 수 있다.



질의 ID · 실험 조건 · 검색/재검열 ID · 검색 문맥 · 생성 답변 · 생성 시간

[그림 4-2] 생성 기록-평가-대응 분석 흐름

5. 실험

5.1 실험 대상과 구성

최종 평가 집합은 RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report의 네 영어 학술·기술 문서를 대상으로 구성한 총 60개의 한국어 질의-대상 문서 쌍으로 이루어진다. 네 문서에 각각 15개의 질의를 배정하며, 모든 질의는 한국어 질의로 영어 문서에서 근거를 검색하는 동일한 교차언어 조건을 공유한다.

질의 구성은 네 문서에 동일한 절차를 적용하였다. 연구자는 각 문서의 주요 내용을 바탕으로 질문의 표현 방식과 범위를 정의하는 초기 질문 3개를 작성하였다. 이후 LLM을 사용하여 문서의 주요 내용을 질문 작성에 활용할 수 있는 형태로 요약하고, 요약 결과를 15개의 내용 단위로 구분하였다. 각 내용 단위에서 한국어 평가 질의 1개를 구성하여 문서별 15개, 총 60개의 질의를 완성하였다.

연구자는 각 질의를 원문 PDF와 대조하여 대상 문서, 원문 페이지, 정답 근거 구간과 답변 가능성을 확인하였다. 정답 근거는 원문에서 직접 확인할 수 있는 연속 구간으로 기록하고, 질문-근거 대응 관계를 검토하였다. 이 절차를 통해 60개 질의 각각에 원문 페이지와 정답 근거 구간을 연결하였다.

질문 유형은 요구되는 답의 성격을 기준으로 사실·정의, 방법·절차, 결과·비교, 목적·기여의 네 범주로 구분하였다. 사실·정의는 개념·수치·구성 요소, 방법·절차는 모델 구조·처리 과정·데이터셋 구성·평가 방법·실험 설정, 결과·비교는 정량·정성 결과와 방법 간 비교, 목적·기여는 연구 목적·문제 설정·주요 기여를 묻는 질의로 정의하였다. 최종 분포는 사실·정의 8개, 방법·절차 29개, 결과·비교 20개, 목적·기여 3개다.

검색 설정은 별도의 5개 튜닝 질의로 선정하였다. 이 과정에서 검색 후보 수 8, 재정렬 후보 수 8, 최종 생성 문맥 5를 확정하였다. 최종 평가는 60개 평가 질의에 고정된 검색 설정과 HyDE·CAD·SCD의 ON/OFF 조합으로 구성한 8개 RAG-Cube 조건을 적용하였다. 이에 따라 60개 질의 × 8개 조건으로 총 480개의 생성 기록을 구성하였다.

[표 5-1] 4개 문서별 질의 구성

대상 문서	질의 수
RAG Survey	15
CAD	15
RAPTOR	15
Mi:dm K 2.5 Pro Technical Report	15
합계	60

5.2 평가 및 분석 방법

평가는 3.3절에서 정의한 대응 비교 설계에 따라 저장된 생성 기록과 평가 결과를 질의 단위로 연결하여 수행하였다. RAGAS 0.2.15를 사용하고, 평가 모델은 OpenAI gpt-4o, 답변 관련성 계산에 사용하는 임베딩 모델은 BAAI/bge-m3로 설정하였다. 평가 지표는 근거 충실도, 답변 관련성, 문맥 정밀도, 문맥 재현율의 네 항목으로 구성하였다.

SCD OFF 평가는 저장된 영어 검색 문맥을 평가 문맥으로 사용하였다. SCD ON 평가는 동일하게 저장된 검색 문맥을 gpt-4o로 한국어 변환한 뒤 평가 문맥으로 사용하고 생성 답변은 원문 상태로 유지하였다. 따라서 SCD OFF와 SCD ON의 RAGAS 값은 각각의 평가 프로토콜 내부에서 조건별 기술통계로 해석한다. SCD의 주 비교는 생성 답변에서 직접 계산한 한국어 문자 비율의 대응 차이로 평가하였다.

근거 충실도 비교는 양쪽 조건에 평가값이 존재하는 대응쌍을 분석 단위로 사용하였다. 이에 따라 CAD 주 비교의 근거 충실도 분석에는 58개 대응쌍을 사용하였다.


HyDE 주 비교는 CAD와 SCD를 OFF로 고정한 60개 질의를 대상으로 수행하였다. CAD 주 비교는 검색 청크 ID, 재정렬 청크 ID와 최종 검색 문맥이 동일한 대응쌍을 사용하여 검색 결과를 고정한 상태의 생성 차이를 측정하였다. SCD 주 비교는 HyDE OFF 조건에서 검색·재정렬 청크 ID와 최종 검색 문맥이 동일한 120개 대응쌍을 사용하였다. 추가로 동일 질의에서 HyDE와 CAD 상태를 각각 맞춘 240개 SCD 대응쌍을 이용하여 8개 실험 조건 전반의 출력 언어 변화를 집계하였다.

답변 생성 설정은 4.1절과 동일하게 유지하였다. HyDE 가상 문서 생성에는 temperature=0.1, top_p=0.9의 샘플링을 사용하였다. 요인별 차이는 같은 질의에서 ON 점수와 OFF 점수의 차이로 계산하였다. 질의를 재표집 단위로 200,000회의 대응 부트스트랩을 수행하고 seed는 20260713으로 고정하였다. 질의별 방향 분포는 RAGAS 차이 +0.01 초과를 증가, -0.01 미만을 감소, 그 사이를 동률로 집계하고, SCD의 한국어 문자 비율은 ± 0.02 를 기준으로 집계하였다. 이 신뢰구간은 네 대상 문서를 고정한 연구 설계에서 질의 수준의 변동성을 나타낸다.

대응쌍의 개별 차이와 평균 변화는 다음 식으로 계산한다.

$$\Delta_i = s_i^{ON} - s_i^{OFF}$$

$$\overline{\Delta} = \frac{1}{n} \sum_{i=1}^n \Delta_i$$



품질: 대응 부트스트랩 95% 신뢰구간 출력 언어: 한국어 문자 비율

[그림 5-1] 60개 질의 평가 및 HyDE·CAD·SCD 대응 비교 설계

SCD는 전체 240개 상태 일치 대응쌍과 HyDE OFF 동일 문맥 120개 대응쌍으로 분석하였다.

5.3 RAG-Cube 조합별 결과

표 5-2는 5.2절의 평가 프로토콜에 따라 SCD OFF와 SCD ON을 구분한 조건별 기술통계이다. RAGAS 값은 각 프로토콜 내부에서 비교하였다. SCD의 출력 언어 변화는 표 5-5와 표 5-6의 한국어 문자 비율 대응 결과로 평가하였다.

SCD OFF에서는 H1C1S0의 근거 충실도가 0.8599, H1C0S0의 답변 관련성이 0.7633으로 가장 높았다. 문맥 정밀도는 H0C0S0에서 0.7488이었고, 문맥 재현율은 H0C0S0과 H1C0S0에서 0.9333이었다. 한국어 문자 비율은 전체 8개 조건 가운데 H1C0S1에서 0.8072로 가장 높았다. 각 요인의 대응 비교는 5.4~5.6절에서 제시한다.


[표 5-2] SCD 평가 프로토콜별 RAG-Cube 조건 평균

[SCD OFF – 영어 검색 문맥 평가]						
조건	생성 수	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 문자 비율
H0C0S0	60	0.7906	0.6828	0.7488	0.9333	0.4943
H0C1S0	60	0.8385	0.6755	0.7395	0.9167	0.4877
H1C0S0	60	0.8342	0.7633	0.7145	0.9333	0.5561
H1C1S0	60	0.8599	0.7045	0.7357	0.9	0.5031
[SCD ON – 한국어 변환 평가 문맥]						
조건	생성 수	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 문자 비율
H0C0S1	60	0.7869	0.6372	0.7634	0.9	0.699
H0C1S1	60	0.7768	0.5996	0.7523	0.85	0.7195
H1C0S1	60	0.8223	0.7097	0.7426	0.9	0.8072
H1C1S1	60	0.8313	0.6671	0.754	0.9167	0.7314
[표 5-2 주석] 두 평가 프로토콜 블록은 각 평가 문맥 구성 방식 안에서 조건별 기술통계로 해석한다. SCD의 주 비교는 표 5-5와 표 5-6의 한국어 문자 비율 대응 결과를 사용한다.						

SCD OFF 블록은 저장된 영어 검색 문맥을 평가 문맥으로 사용한다.

SCD ON 블록은 한국어로 변환한 검색 문맥을 평가 문맥으로 사용한다.

표의 생성 수는 각 실험 조건에서 저장된 생성 기록 수를 의미한다. 근거 충실도 평균의 유효 n은 H0C1S0 58, H0C0S1 57, 나머지 실험 조건 60이다. SCD OFF와 SCD ON의 RAGAS 값은 각각 영어 검색 문맥과 한국어 변환 평가 문맥을 사용하므로 각 평가 프로토콜 블록 안에서 조건별 기술통계로 해석한다. SCD의 주 비교는 표 5-5와 표 5-6의 한국어 문자 비율 대응 결과를 사용한다.



두 블록은 서로 다른 평가 문맥 프로토콜을 사용하므로 각 블록 안에서 조건별 기술동계로 해석

[그림 5-2] 평가 프로토콜별 RAG-Cube 조건 평균

(a) SCD OFF는 영어 검색 문맥, (b) SCD ON은 한국어 변환 평가 문맥을 사용한다.

5.4 HyDE 결과 및 해석

HyDE의 답변 관련성 평균 대응 차이는 +0.0805이고 95% 부트스트랩 신뢰구간은 [+0.0110, +0.1514]이다. 질의별 변화는 증가 29개, 감소 15개, 동률 16개로 분포하였다. 근거 충실도 평균 대응 차이는 +0.0436, 95% 신뢰구간은 [-0.0262, +0.1153]이며 증가 24개, 감소 21개, 동률 15개였다. 문맥 정밀도의 평균 대응 차이는 -0.0343이었고, 문맥 재현율의 평균 대응 차이는 0.0000이었다.

HyDE 비교에는 검색 입력부터 생성 답변까지의 변화가 포함된다. 답변 관련성의 평균 차이 +0.0805는 95% 신뢰구간이 0보다 높아, 이 평가 집합에서 HyDE ON의 답변 관련성이 더 높았음을 보여준다. 반면 근거 충실도의 신뢰구간은 0을 포함하고 문맥 지표의 변화 방향도 달랐다. 문서별·질문 유형별 결과는 부록 B에서 탐색적으로 비교한다.

그림 5-3은 이러한 검색 문맥 변화를 개별 사례에서 보여준다. ext_midm_004에서 H0C0S0과 H1C0S0은 동일한 질문을 사용하며, HyDE 적용에 따라 검색·재정렬 체크 ID와 최종 검색 문맥이 달라졌다. 답변 관련성은 0.0000에서 0.8531로, 문맥 재현율은 0.0000에서 1.0000으로 변하였다. HyDE ON 답변은 한국어 멀티턴 대화 데이터의 세 설계 차원인 interaction structure, topic and task, persona를 제시하였다.

RAG-Cube 60-query Stored Input/Output Evidence — E04 HyDE Retrieval Change

```
=====
Cube-RAG 60-query Stored Input/Output Evidence
=====
Case       : E04 HyDE Retrieval Change
Selection   : stored HyDE pair with changed retrieval/context and a question-aligned answer

Query ID    : ext_midm_004
Paper       : paper_midm

Question
-----
Midm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?

Contexts identical: False
Retrieved IDs identical: False
Reranked IDs identical: False

Configuration A
=====
Config      : hyde_off__no_decoder_control
HyDE / CAD / SCD : False / False / False
Korean ratio : 0.8250
Stored RAGAS  : faithfulness=0.9000, answer_relevancy=0.0000, context_precision=0.0000, context_recall=0.0000

Stored answer
-----
제공된 논문 컨텍스트를 면밀히 검토한 결과, Midm K 2.5 Pro의 한국어 멀티턴 대화 데이터가 어떤 세 가지 차원을 기준으로 고품질 대화를 설계하는지에 관한 구체적인 정보를 확인할 수 없습니다.

논문에서는 Midm K 2.5 Pro의 훈련 방법론과 성능에 대해 상세히 설명하고 있으나, 특히 멀티턴 대화 데이터의 설계 차원에 관한 세 가지 구체적 기준은 명시되어 있지 않습니다.

다만 논문에서 언급된 관련 내용으로는:

1. "체계적인 응답 스타일 정렬(systematic response-style alignment)"을 통해 "일관된 페르소나, 안정적인 응답 구조, 그리고 다양한 출을 사례에서의 정확한 지시사항 준수"를 보장한다고 언급되어 있습니다.

2. "Fusion Training" 과정을 통해 "깊은 추론 능력, 대화 유창성, 그리고 견고한 도구 사용 능력"의 균형 잡힌 통합을 달성한다고 설명하고 있습니다.

3. "책임감 있는 AI(Responsible AI)" 평가를 통해 안전성을 검증했다고 언급하고 있습니다.

그러나 질문에서 요구하는 "세 가지 차원"이라는 구체적인 분류 체계는 제공된 컨텍스트 내에서 직접적으로 확인할 수 없습니다.

해당 정보는 제공된 논문에서 찾을 수 없습니다.

Retrieved chunk IDs
-----
paper_midm_88a1c1d7a494
paper_midm_6954fe611cf
paper_midm_88370fe7a52d
paper_midm_ca70e703fee3
paper_midm_b59b646d2c0b
paper_midm_52ab9d497b88
paper_midm_2ee381bd3319
paper_midm_7d1f2569a08d

Configuration B
=====
Config      : hyde_on__no_decoder_control
HyDE / CAD / SCD : True / False / False
Korean ratio : 0.6773
Stored RAGAS  : faithfulness=0.8824, answer_relevancy=0.8531, context_precision=0.3250, context_recall=1.0000

Stored answer
-----
제공된 논문 컨텍스트를 분석한 결과, Midm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 다음 세 가지 차원을 기준으로 고품질 대화를 설계하고 있음이 확인됩니다.

**1. 상호작용 구조(Interaction Structure) 차원**
이 차원은 단순한 맥락 보존 대화를 넘어서 실제 세계의 대화 현상을 포괄합니다. 구체적으로는 주제 전환(topic shifts), 이전 정보 회상(recall of prior information), 오류 수정(requests for error correction), 갑작스러운 주제 이탈 발언(abrupt off-topic remark) 등의 자연스러운 대화 패턴을 포함합니다. 이러한 구조적 특성을 통해 실제 사용자들의 대화 흐름을 반영한 데이터를 구축합니다.

**2. 주제 및 과제(Topic and Task) 차원**
이 차원은 합성 데이터의 다양성을 확보하기 위한 핵심 요소입니다. 대규모 프롬프트 풀(pool)에서 다양한 페르소나를 샘플링하여, 단순한 역할 라벨을 넘어서 발화 스타일(speaking style), 도메인 전문성(domain expertise), 지시/명령 스타일(instruction/command style)의 조합으로 각 페르소나를 구체화합니다. 이러한 접근
... [truncated: 248 characters; use --full]

Translated query
-----
What three dimensions does Midm K 2.5 Pro's Korean multi-turn conversation data use to design high-quality conversations?

HyDE document
-----
Midm K 2.5 Pro's Korean multi-turn conversation data is designed using three key dimensions to ensure high-quality interactions. Firstly, the model employs a context-aware dialogue management system, which utilizes the "context_encode" method to maintain coherence across multiple turns of conversation. Secondly, it incorporates a diversity enhancement technique, leveraging the "response_generator" module to produce varied and engaging responses, achieving a 25% increase in response diversity compared to previous versions. Lastly, the dataset integrates a sentiment analysis component, implemented through the "sentiment_classifier," to dynamically adjust the tone and empathy level of responses, resulting in a 90% user satisfaction rate in p
... [truncated: 11 characters; use --full]


Retrieved chunk IDs
-----
paper_midm_b8ec113edfbf
paper_midm_94d24ba9b194
paper_midm_45c14cb66bfb
paper_midm_52ab9d497b88
paper_midm_b59b646d2c0b
paper_midm_ca70e703fee3
paper_midm_6954fe611cf
paper_midm_88370fe7a52d

Korean-ratio delta: -0.1477
=====
```

[그림 5-3] HyDE 적용에 따른 검색 문맥 및 답변 변화 사례

[표 5-3] HyDE 주 비교 결과

지표	평균 변화 ON-OFF	95% 신뢰구간	증가	감소	동률	n
근거 충실도	+0.0436	[-0.0262 , +0.1153]	24	21	15	60
답변 관련성	+0.0805	[+0.0110 , +0.1514]	29	15	16	60
문맥 정밀도	-0.0343	[-0.0932 , +0.0247]	17	23	20	60
문맥 재현율	0	[-0.1000 , +0.1000]	4	4	52	60



[그림 5-4] HyDE와 CAD의 주 대응 비교

점은 ON-OFF 평균 차이, 선은 95% 부트스트랩 신뢰구간이다.

5.5 CAD 결과 및 해석

CAD의 주 비교는 검색 문맥을 동일하게 유지하고 디코딩만 달리한 대응쌍이다. 근거 충실도는 양쪽 평가값이 존재하는 58쌍에서 평균 +0.0288이었으며, 95% 신뢰구간 [-0.0367, +0.0934]은 0을 포함하였다. 증가·감소·동률은 각각 21쌍, 24쌍, 13쌍이었다. 답변 관련성은 60쌍에서 -0.0073, 신뢰구간 [-0.0855, +0.0719], 증가 19쌍, 감소 32쌍, 동률 9쌍으로 나타났다.

CAD 적용에 따른 답변 품질의 변화를 동일 검색 문맥에서 근거 충실도와 답변 관련성의 평균 차이 및 질의별 분포로 분석하였다. 동일 검색 입력에 대해 문맥 정밀도는 8/60쌍, 문맥

재현율은 1/60쌍에서 자동 평가 모델의 값 차이가 기록되어 평가 변동을 확인하기 위한 진단 값으로 분리하였다. 표 4-3에서 CAD ON 평균 생성 시간은 대응 조건군에서 20.792→63.867초, 18.898→55.159초, 23.440→73.532초, 24.892→64.125초로 증가했다. CAD의 생성 단계 결과는 근거 충실도, 답변 관련성과 생성 시간을 중심으로 분석한다.

그림 5-5는 같은 검색 문맥에서 CAD 적용 전후 근거 충실도가 달라진 실제 사례다. ext_midm_001은 Mi:dm K 2.5 Pro의 학습 데이터 확보 경로 세 가지를 묻고, CAD OFF와 ON의 검색·재정렬 청크 ID와 검색 문맥이 모두 같다. 두 답변은 licensed proprietary datasets, commercial-use public datasets, in-house synthetic data의 세 경로를 제시하며, 저장된 근거 충실도는 0.8333에서 1.0000으로 변했다. 답변 관련성은 0.8261과 0.8124였다. 근거 충실도가 감소한 추가 사례는 부록 B의 그림 B-1에 제시한다.

RAG-Cube 60-query Stored Input/Output Evidence — E05 CAD Positive Same-Context Pair

```
=====
Cube-RAG 60-query Stored Input/Output Evidence
=====
Case       : E05 CAD Positive Same-Context Pair
Selection  : stored 60-query CAD pair with higher faithfulness under identical retrieved inputs and a question-aligned answer

Query ID   : ext_midm_001
Paper      : paper_midm

Question
-----
Midm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?

Contexts identical: True
Retrieved IDs identical: True
Reranked IDs identical: True

Configuration A
-----
Config      : hyde_off__no_decoder_control
HyDE / CAD / SCD : False / False / False
Korean ratio : 0.7606
Stored RAGAS : faithfulness=0.8333, answer_relevancy=0.8261, context_precision=0.5833, context_recall=1.0000

Stored answer
-----
제공된 논문 컨텍스트를 분석한 결과, Midm K 2.5 Pro의 학습 데이터는 다음 세 가지 경로를 통해 확보됨이 확인됩니다.

**1. 라이선스 보유 독점(proprietary) 데이터셋**
논문의 "High Quality Data Acquisition" 섹션에서 명시적으로 언급되었듯이, 첫 번째 경로는 라이선스를 통해 확보한 독점 데이터셋입니다. 이러한 데이터는 상업적 이용 권한이 보장된 상태에서 활용됩니다.

**2. 상업적 이용이 허가된 공개(public) 데이터셋**
두 번째 경로는 AI-HUB 및 국립국어원(NIKL) 코퍼스와 같은 공공 자원을 포함합니다. 논문에서는 "AI-HUB 및 국립국어원(NIKL) 코퍼스를 포함한 공공 자원"이라고 구체적으로 명시하고 있습니다.

**3. 자체(in-house) 합성(synthetic) 데이터**
세 번째 경로는 내에서 생성한 합성 데이터입니다. 논문에서는 "in-house synthetic data"라고 표현하며, 특히 "수학이나 코드와 같이 데이터가 최소하거나 구조적 편향이 있는 영역에서는 훈련 분포를 합성 데이터로 보강한다"고 설명하고 있습니다.

이러한 다각적 데이터 확보 전략을 통해 Midm K 2.5 Pro는 고품질의 균형 잡힌 학습 데이터셋을 구축하여 모델의 성능과 신뢰성을 향상시키고 있음이 확인됩니다.

Retrieved chunk IDs
-----
paper_midm_6954efe611cf
paper_midm_88370fe7a52d
paper_midm_ca70e703fee3
paper_midm_b59b646d2c0b
paper_midm_9d38979465e7
paper_midm_37c535d0ba13
paper_midm_9028100fe782
paper_midm_81d8d0fa8ce8

Configuration B
-----
Config      : hyde_off__cad_only
HyDE / CAD / SCD : False / True / False
Korean ratio : 0.7466
Stored RAGAS : faithfulness=1.0000, answer_relevancy=0.8124, context_precision=0.5833, context_recall=1.0000

Stored answer
-----
제공된 논문 컨텍스트에 따르면, Midm K 2.5 Pro의 학습 데이터는 다음 세 가지 경로를 통해 확보됩니다:

**1. Licensed Proprietary Datasets (라이선스 취득 전용 데이터셋)**
논문의 "High Quality Data Acquisition" 섹션에서 명시적으로 언급되었듯이, 상용 사용이 허가된 라이선스 취득 전용 데이터셋을 통해 훈련 데이터를 확보하고 있습니다.

**2. Public Datasets Permitting Commercial Use (상업적 이용이 허용된 공개 데이터셋)**
AI-HUB* 및 국립국어원(NIKL) 코퍼라*와 같은 공공 자원을 통해 주로 한국 중심의 훈련 코퍼스를 구축하고 있습니다. 또한 산업·학계 협력체인 K-Data Alliance를 통한 지속적인 협업으로 한국 사회의 제도적 맥락, 문화적 규범, 지식 지형을 반영하는 대량의 한국 집중 데이터를 확보하고 있습니다.

**3. In-house Synthetic Data (자체 생성 합성 데이터)**
최소하거나 구조적 편향이 있는 수학이나 코드와 같은 도메인에서 훈련 분포를 증강하기 위해 자체 생성된 합성 데이터를 활용하고 있습니다. 새로 수집된 한국어 소스 데이터 중 일부를 활용하여 이러한 합성 데이터를 생성하고, 이를 통해 실제 자원이 상대적으로 부족한 특수 도메인에서 한국어 지식 커버리지를 강화하고 있습니다.

이러한 다각적 데이터 확보 전략을 통해 품질 중심의 큐레이션과 효과적인 활용에 중점을 두어 Midm K 2.5 Pro의 신뢰성과 고품질 모델을 위한 견고한 데이터 기반을 구축하고 있음이 확인됩니다.

Retrieved chunk IDs
-----
paper_midm_6954efe611cf
paper_midm_88370fe7a52d
paper_midm_ca70e703fee3
paper_midm_b59b646d2c0b
paper_midm_9d38979465e7
paper_midm_37c535d0ba13
paper_midm_9028100fe782
paper_midm_81d8d0fa8ce8


Korean-ratio delta: -0.0140
=====
```

[그림 5-5] 동일 검색 문맥에서 CAD 적용 전후 답변 비교 사례

[표 5-4] CAD 동일 문맥 주 비교 결과

지표	평균 변화 ON-OFF	95% 신뢰구간	증가	감소	동률	n
근거 충실도	+0.0288	[-0.0367 , +0.0934]	21	24	13	58
답변 관련성	-0.0073	[-0.0855 , +0.0719]	19	32	9	60

[진단값] 동일 검색 입력에서 자동 평가 모델 값 차이: 문맥 정밀도 8/60쌍, 문맥 재현율 1/60쌍



[그림 5-6] RAG-Cube 조건별 생성 시간

CAD ON 조건의 실행 시간 증가를 품질 지표와 분리해 제시한다.

5.6 SCD 출력 언어 결과 및 해석

SCD의 평가 목표는 영어 근거 문맥에서 한국어 출력 언어를 유지하는 것이다. HyDE OFF에서 검색·재정렬 청크 ID와 검색 문맥이 같은 120쌍의 한국어 문자 비율 평균 변화는 +0.2182이고 95% 신뢰구간은 [+0.1880, +0.2487]이다. 동일 질의에서 HyDE·CAD의 ON/OFF 상태를 맞춘 전체 240개 SCD 대응쌍에서는 평균 +0.2289, 95% 신뢰구간 [+0.2051, +0.2532]였으며, +0.02를 초과한 증가는 219개, -0.02보다 작은 감소는 10개, 그 사이 동률은 11개다.

네 HyDE·CAD 조건군에서 SCD ON-OFF 평균 변화는 각각 +0.2047, +0.2317, +0.2511, +0.2283이었다. H0 두 조건군은 동일 검색 문맥에서 SCD만 달리한 주 비교이며, H1 두 조

건군에는 조건별 HyDE 샘플링에 따른 문맥 변화가 포함된다. 네 조건군 모두 평균 한국어 문자 비율이 증가하였다.

SCD ON 답변에도 영어 논문 제목, 모델명과 데이터셋명이 남을 수 있다. 표 5-5와 표 5-6의 비율은 2.5절의 정의에 따라 이러한 혼합 표기를 포함한 실제 답변에서 계산한 값이다.

선행연구에서 보고된 출력 언어 이탈은 본 실험의 저장된 생성 답변에서도 관찰되었다. 그림 5-7은 SCD OFF 조건에서 한국어 질문과 영어 검색 근거가 주어진 뒤 생성 답변의 한국어 문자 비율이 0.0000으로 기록된 사례다. 같은 생성 기록에는 질문, 검색 근거, 생성 답변과 평가값이 함께 기록되어 있다.

RAG-Cube 60-query Stored Input/Output Evidence — E02 Stored Language Drift

```
=====
Cube-RAG 60-query Stored Input/Output Evidence
=====
Case      : E02 Stored Language Drift
Selection  : lowest Korean-character ratio among the 60-query SCD-off records

Config     : hyde_on__cad_only
Query ID   : ext_cad_007
Paper      : paper_nlp_cad
HyDE / CAD / SCD : True / True / False
Korean ratio : 0.0000
Stored RAGS : faithfulness=0.0769, answer_relevancy=0.4602, context_precision=1.0000, context_recall=1.0000

Question
-----
CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?

Stored answer
-----
. Improving transformer generalization through weight normalization. _arXiv preprint
arXiv:2204.03296_. Sheng-Hong Huang, Xiaodan Zheng, and Jianfeng Gao. 2018. Factually faithful
abstractive summarization. In _Proceedings of the 2018 Conference on Empirical Methods in Natural
Language Processing_, pages 222-232, Brussels, Belgium. Association for Computational Linguistics.
Maynez et al. 2020. Detecting hallucinations in abstractive summarization. In _Proceedings of the
2020 Conference of the North American Chapter of the Association for Computational Linguistics:
Human Language Technologies_, pages 1050-1060, Online. Yulia Ivanova Tsvetov, Shangbin Feng,
Vidhisha Balachandran, Yuyang Bai, and Yulia Tsvetkov. 2023. LLaMA: Large language model for
adaptive reasoning and memory. _arXiv preprint arXiv:2305.06299_. Longpre et al. 2021. Memotrap:
Benchmarking memorized ending bias in large language models. _arXiv preprint arXiv:2107.02056_.
Black Longpre Shayne, Shangbin Feng, Yuyang Bai, and Yulia Tsvetkov. 2021. Knowledges conflicts QA
dataset. _arXiv preprint arXiv:2110.08075_. Mike Lewis, Shangbin Feng, Vidhisha Balachandran, and
Luke Zettlemoyer. 2022. Cliff: Contrastive learning for improving faithfulness and factuality in
abstractive summarization. _arXiv preprint arXiv:2109.09209_. Zhang Lei, Jianfeng Gao, and Fei Sha.
2022. OPT: Open pre-trained transformers. _arXiv preprint arXiv:2206.06058_. Chan Stephanie C.Y.,
Adam Lampinen Kyle, Jane X.Wang, Aaditya Singh K.X., Pierre Richemond H., Jay McClelland, Felix
Hill. 2022
... [truncated: 152 characters; use --full]

Retrieved chunk IDs
-----
paper_nlp_cad_363806f889e1
paper_nlp_cad_6d4aeefa6dab
paper_nlp_cad_a9eb9b7d0844
paper_nlp_cad_d18b307f5435
paper_nlp_cad_d5bac5075c72
paper_nlp_cad_446b96cb2d93
paper_nlp_cad_c50140c83c8e
paper_nlp_cad_8c6919d1c4d0

Retrieved evidence [1]
-----
provided. CAD can be used with off-the-shelf pretrained language models without any additional
training. Experimental results from summarization tasks show that context-aware decoding
significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et
al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs
such as FLAN (Chung et al., 2022). For instance, when applied to LLaMA-30B in CNN-DM, CAD leads to
substantial improvement in both ROUGE-L (21 %) and summary factuality
... [truncated: 1456 characters; use --full]
=====
```

[그림 5-7] SCD OFF 조건의 출력 언어 이탈 사례

그림 5-8은 SCD의 출력 언어 제어에 따른 답변 언어 변화를 동일 검색 문맥에서 확인하는 사례다. ext_midm_005의 H1C0S0과 H1C0S1은 검색·재정렬 청크 ID와 검색 문맥이 같고

SCD 상태만 다르다. 한국어 문자 비율은 0.0000에서 0.7713으로 증가하며, 같은 입력 근거에서 생성 답변의 언어 구성이 영어 중심에서 한국어 중심으로 변화한 결과를 보여준다. 이 사례가 속한 H1C0S0→H1C0S1 조건군의 평균 변화는 +0.2511이며, 전체 240개 상태 일치 대응쌍의 평균 변화는 +0.2289이다.

RAG-Cube 60-query Stored Input/Output Evidence — E03 SCD Same-Context Rescue

```
=====
Cube-RAG 60-query Stored Input/Output Evidence
=====
Case      : E03 SCD Same-Context Rescue
Selection  : largest stored 0.5-threshold rescue with identical retrieval IDs, reranked IDs, and context

Query ID   : ext_midm_005
Paper      : paper_midm

Question
-----
Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?

Contexts identical: True
Retrieved IDs identical: True
Reranked IDs identical: True

Configuration A
-----
Config      : hyde_on__no_decoder_control
HyDE / CAD / SCD : True / False / False
Korean ratio : 0.0000
Stored RAGAS : faithfulness=0.8125, answer_relevancy=0.4632, context_precision=0.8667, context_recall=1.0000

Stored answer
-----
tasks such as math problems, code snippets, and general knowledge questions, with a composition of
29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, we apply a model merging
technique using checkpoints saved at regular intervals [ 25 ]. Compared to the final checkpoint from
stage 1, the merged model shows improved performance on most evaluation metrics, with the exception
of GSM8K [ 15 ]. In CPT stage 2, we increase the proportion of STEM data relative to the previous
stage in order to further enhance overall performance and strengthen reasoning capability.

**4.3 RL Training Efficiency and Operational Design** In this section, we summarize the design
choices that improve learning efficiency and stability during the reinforcement learning stage.
Rather than modifying the underlying RL algorithm, we focus on operational components, including
difficulty-aware data
... [truncated: 1829 characters; use --full]

Retrieved chunk IDs
-----
paper_midm_5fd8fb92ae53
paper_midm_fe2d192ffc71
paper_midm_b0df9df28f93
paper_midm_660712d9ef84
paper_midm_dad3730b024c
paper_midm_002ecff9dab3
paper_midm_78610c2dc51c
paper_midm_3cf0fd98f64b

Configuration B
-----
Config      : hyde_on__scd_only
HyDE / CAD / SCD : True / False / True
Korean ratio : 0.7713
SCD          : reference_scd; alpha=1.1; beta=0.9; Tstart=5
Stored RAGAS : faithfulness=0.8889, answer_relevancy=0.5231, context_precision=0.8667, context_recall=1.0000

Stored answer
-----
tasks such as math problems, code snippets, and general knowledge questions, with a composition of
29% English, 17% Korean, 50% STEM, and 9% multilingual data. After stage 1, 우리는 정기적인 간격으로 저장된 체크포인트를
사용한 모델 병합 기법을 적용합니다 [25]. 단계 1의 최종 체크포인트와 비교하여, 병합된 모델은 대부분의 평가 지표에서 향상된 성능을 보여주며, GSM8K [15]를 제외하고는
그렇습니다. CPT 단계 2에서는 이전 단계에 비해 STEM 데이터의 비중을 증가시켜 전반적인 성능을 더욱 향상시키고 추론 능력을 강화합니다. 3.3 긴 맥락 확장 전략 (Long
Context Expansion Strategy) Mi:dm K 2.5 Pro의 긴 맥락 처리 능력을 향상시키기 위해, 우리는 사전 훈련의 마지막 단계에서 점진적 맥락 길이 확장
전략을 적용합니다 [26]. 세 개의 확장 단계에 걸쳐, 우리는 맥락 길이를 4,096 토큰에서 32,768 토큰, 65,536 토큰, 그리고 최종적으로 131,072 토큰으로
점진적으로 증가시켜 최대 128k 토큰의 입력을 안정적으로 지원합니다. 이 과정 전반에 걸쳐, 우리는 일반 작업 벤치마크와 긴 맥락 벤치마크 모두에서 성능을 보존하는 것을 목표
합니다. 또한, 사후 훈련 단계의 강화 학습 단계에서 사용되는 vLLM 추론 프레임워크와의 안정적인 호환성을 보장하기 위해 YaRN 메커니즘을 채택합니다 [28].

제공된 논문에서 모델 병합(Model Merging)의 목적과 방법에 대해 설명해주세요.

**모델 병합(Model Merging)**은 대규모 언어 모델의 효율적인 성능 향상을 위한 핵심
... [truncated: 448 characters; use --full]

Retrieved chunk IDs
-----
paper_midm_5fd8fb92ae53
paper_midm_fe2d192ffc71
paper_midm_b0df9df28f93
paper_midm_660712d9ef84
paper_midm_dad3730b024c
paper_midm_002ecff9dab3
paper_midm_78610c2dc51c
paper_midm_3cf0fd98f64b

Korean-ratio delta: +0.7713
=====
```


[그림 5–8] 동일 검색 문맥에서 SCD 적용 전후 출력 언어 변화 사례

[표 5-5] SCD 조합별 한국어 문자 비율 변화

SCD OFF	SCD ON	쌍 수	평균 변화	신뢰구간 하한	신뢰구간 상한	증가	감소	동률
H0C0S0	H0C0S1	60	+0.2047	+0.1566	+0.2512	51	4	5
H0C1S0	H0C1S1	60	+0.2317	+0.1874	+0.2786	54	2	4
H1C0S0	H1C0S1	60	+0.2511	+0.1938	+0.3078	57	1	2
H1C1S0	H1C1S1	60	+0.2283	+0.1832	+0.2762	57	3	0

[표 5-6] SCD 대응쌍 분석 요약

비교	쌍 수	한국어 문자 비율 평균 변화	95% 신뢰구간	증가 / 감소 / 동률
전체 SCD ON/OFF 대응	240	+0.2289	[+0.2051, +0.2532]	219 / 10 / 11
HyDE OFF 동일 문맥	120	+0.2182	[+0.1880, +0.2487]	105 / 6 / 9



오차막대: query-clustered bootstrap 95% CI

[그림 5-9] SCD의 한국어 문자 비율 변화

H0 조건군은 동일 검색 문맥 주 비교이며, H1 조건군은 조건별 HyDE 샘플링을 포함한다. 오차막대는 95% 부트스트랩 신뢰구간이다.

5.7 대표 입출력 및 요구사항별 실행 결과

그림 5-3은 HyDE 적용에 따른 검색 문맥과 답변 변화를, 그림 5-5는 동일 검색 문맥에서 CAD 적용 전후의 근거 충실도 변화를 보여준다. 그림 5-7과 그림 5-8은 각각 SCD OFF의 출력 언어 이탈과 SCD 적용 후 출력 언어 변화를 제시한다. 그림 5-10은 질문, 검색 근거, 생성 답변과 평가값을 한 번에 확인할 수 있는 기본 입출력 사례다.

그림 5-10의 ext_raptor_011 H0C0S0 생성 기록은 근거 충실도 1.0000, 답변 관련성 0.9365, 문맥 정밀도 1.0000, 문맥 재현율 1.0000을 기록한다. 질문은 RAPTOR의 계층적 검

색이 DPR보다 주제형·멀티홉 질문에 유리한 이유를 묻는다. 같은 생성 기록에 질의 ID, 실험 조건, 검색·재정렬 체크 ID, 검색 문맥, 생성 답변과 RAGAS 점수가 함께 저장되어 있다.

RAG-Cube 60-query Stored Input/Output Evidence — E01 Normal QA

```
=====
Cube-RAG 60-query Stored Input/Output Evidence
=====
Case      : E01 Normal QA
Selection : highest mean of four stored gpt-4o metrics among 60-query records at or above 0.5 Korean-character ratio

Config    : hyde_off__no_decoder_control
Query ID  : ext_raptor_011
Paper     : paper_nlp_raptor
HyDE / CAD / SCD : False / False / False
Korean ratio : 0.5274
Stored RAGAS : faithfulness=1.0000, answer_relevancy=0.9365, context_precision=1.0000, context_recall=1.0000

Question
-----
Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?

Stored answer
-----
제공된 논문 컨텍스트를 분석한 결과, Cinderella 사례의 정성 분석에서 RAPTOR의 트리 구조 기반 검색(tree-based retrieval)이 DPR(Dense Passage Retrieval)보다 주제형·멀티홉 질문에 유리했던 이유는 다음과 같이 확인됩니다.

첫째, RAPTOR는 계층적 구조를 통해 다양한 수준의 추상화(abstraction)를 제공합니다. 논문의 Figure 4에서 확인할 수 있듯이, RAPTOR는 질문의 요구사항에 따라 서로 다른 층위(layer)에서 노드를 선택할 수 있습니다. 반면 DPR은 단일 층위의 leaf 노드만을 선택하여 정보를 제공합니다.

둘째, RAPTOR의 트리 구조는 더 포괄적이고 맥락적인 정보를 제공합니다. "What is the central theme of the story?"라는 질문에 대해 DPR이 제공한 맥락은 "The central theme of the story is transformation and the power of inner beauty"로 이야기의 초반부만을 다루었으나, RAPTOR가 제공한 맥락은 "The central theme of the story is transformation and overcoming adversity"로 신데렐라가 겪는 전체 여정과 행복한 결말까지 포함하여 더 완전한 답변을 가능하게 했습니다.

셋째, RAPTOR는 상위 노드(higher-level nodes)를 통해 요약 정보도 제공합니다. 논문에서 언급된 바와 같이 "RAPTOR's context often encompasses the information retrieved by DPR, either directly or within higher-layer summaries"라는 점이 확인됩니다. 이는 멀티홉 질문처럼 여러 단계의 추론이 필요한 질문에서 특히 중요한 장점입니다.

넷째, RAPTOR의 검색 메커니즘은 단순한 토큰 매칭을 넘어서 의미론적 관련성(semantic relevance)을 고려한 정보 선택이 가능합니다. "How does Cinderella find a happy ending?" 질문에서 RAPTOR는 신데렐라의 변신, 왕자와의 만남, 유리구두 사건, 그리고 최종적인 화해까지 전체 서사를 포괄하는 정보를 제공합니다.

결론적으로, RAPTOR의 트리 구조는 다양한 층위의 정보를 계층적으로 조직하여 제공함으로써, 주제형·멀
... [truncated: 81 characters; use --full]

Retrieved chunk IDs
-----
paper_nlp_raptor_12d47c916205
paper_nlp_raptor_4f4f51e0f19a
paper_nlp_raptor_dd8b323782ef
paper_nlp_raptor_0f4c6a947b3d
paper_nlp_raptor_10f0c730ad5d
paper_nlp_raptor_ed1fa6412150
paper_nlp_raptor_3208734b2ece
paper_nlp_raptor_fb3aa9881edd

Retrieved evidence [1]
-----
G Q QUALITATIVE ANALYSIS To qualitatively examine RAPTOR's retrieval process, we test it on thematic, multi-hop questions about a 1500-word version of the fairytale Cinderella. We compare the context retrieved by RAPTOR with the context retrieved by Dense Passage Retrieval (DPR). Figure 4 in the main paper details the retrieval process within RAPTOR's tree structure for two questions. The nodes that RAPTOR selects for each question are highlighted, while the leaf nodes that DPR selects for the same question are indicated with arrows. This comparison illustrates the advantage of RAPTOR's tree structure. RAPTOR selects nodes from different layers depending on the level of granularity required by the Published as a conference paper at ICLR 2024 Algorithm 2 Collapsed Tree Algorithm function COLLAPSED TREE (tree, query, k, max_tokens) tr
... [truncated: 2065 characters; use --full]
=====
```

[그림 5-10] 질의·검색 근거·생성 답변·평가 결과 예시

본문의 그림 5-3, 5-5, 5-7, 5-8, 5-10은 정량값과 개별 입출력을 같은 질의·조건 단위로 연결한다. 각 사례에는 저장된 검색 문맥, 답변과 평가값을 제시하였다. 부록 B의 그림 B-1에는 CAD의 근거 충실도가 감소한 사례를 추가하였다.

5.8 종합 논의

검색 표현을 확장한 HyDE는 답변 관련성에서 양의 평균 차이를 보였지만, 문맥 정밀도는 -0.0343, 문맥 재현율은 0.0000이었다. 그림 5-3에서도 검색·재정렬 청크 ID와 최종 문맥이 바뀌었다. 따라서 답변 관련성의 변화는 번역과 가상 문서 생성을 포함한 검색 경로 전체의 결과로 해석해야 한다.


CAD 동일 문맥 비교에서 근거 충실도의 평균 대응 차이는 +0.0288, 답변 관련성은 -0.0073이었다. 두 지표의 95% 부트스트랩 신뢰구간은 모두 0을 포함하였다. CAD ON은 동일한 검색 문맥에서 문맥 제외 분포를 추가로 계산하며, 대응 조건군에서 생성 시간이 증가하였다. 이 결과는 CAD의 적용 판단에서 생성 품질 분포와 계산 비용을 함께 고려할 근거를 제공한다.

SCD는 생성 답변의 한국어 문자 비율을 높였다. HyDE OFF 동일 문맥 120개 대응쌍에서 평균 대응 차이는 +0.2182였고, HyDE·CAD 상태를 맞춘 전체 240개 대응쌍에서는 +0.2289였다. 따라서 본 연구에서 SCD의 직접적인 측정 결과는 출력 언어 성향의 변화로 정리된다.

조건별 평균과 요인별 대응 비교는 서로 다른 분석 수준을 제공한다. 표 5-2는 8개 조합의 기술통계를 제시하고, 표 5-3~5-6은 특정 요인의 ON/OFF 차이를 질의 단위 대응 구조에서 제시한다. 실험 조건의 선택 기준은 답변 관련성, 근거 충실도, 생성 시간, 한국어 문자 비율 처럼 적용 환경에서 우선하는 목표 지표에 따라 달라진다.

그림 5-11은 HyDE와 CAD의 조건별 기술적 대응 차이를 정리한다. 답변 관련성에서 HyDE의 평균 대응 차이는 C0S0에서 +0.0805, C1S0에서 +0.0290이었고, SCD ON에서는 C0S1 +0.0725, C1S1 +0.0675였다. CAD의 답변 관련성 대응 차이는 H0S0 -0.0073, H1S0 -0.0588이었으며, SCD ON에서는 H0S1 -0.0377, H1S1 -0.0427이었다. 근거 충실도에서도 조건군별 대응 차이가 서로 다른 크기로 나타났다. HyDE ON 조건은 각 실험 조건에서 temperature=0.1, top_p=0.9 샘플링으로 가상 문서를 독립 생성하였다. 이에 따라 H1 조건의 CAD·SCD 비교에는 디코딩 조건에 따른 생성 변화와 HyDE 샘플링에 따른 검색 문맥 변화가 함께 반영된다. 그림 5-11은 각 조건에서 측정된 대응 차이를 제시하며, 실험 조건 선택은 목표 지표와 검색 문맥 변화를 함께 기준으로 한다.

부록 B의 문서별·질문 유형별 분석은 전체 평균에 가려진 하위집단의 차이를 보여준다. 문서별 질의 수는 15개로 같지만 질문 유형별 표본 수는 8, 29, 20, 3개로 다르다. 특히 표본이 적은 유형의 결과는 후속 실험 가설을 위한 탐색 자료로 해석하였다.



[그림 5-11] HyDE·CAD 조건별 근거 충실도·답변 관련성 대응 차이

5.9 실험 범위와 해석 기준

영어 학술·기술 문서 4종에 대해 문서별 15개씩, 총 60개의 한국어 질의를 구성하였다. 각 질의의 원문 페이지와 정답 근거 구간을 확인하고, K-intelligence/Midm-2.0-Base-Instruct와 CAD $\alpha=0.5$ 설정으로 평가하였다. 근거 부족 상황의 응답과 문서·모델 조건 확장을 위한 후속 평가를 6.4절에 제안하였다.

HyDE 평가는 번역, 가상 문서 생성과 밀집 검색 변경을 포함한 종단 간 비교로 구성하였다. 가상 문서는 temperature=0.1, top_p=0.9로 생성하였으며 저장된 검색·생성 기록을 분석하였다. SCD ON/OFF의 RAGAS 평가는 각각 한국어 변환 평가 문맥과 영어 검색 문맥을 사용하는 프로토콜별 결과로 해석하였다. SCD의 출력 언어 변화는 한국어 문자 비율의 대응 차이로 분석하였다.

6. 결론

한국어 질의-영어 문서 RAG에서 HyDE·CAD·SCD를 적용하고, 네 문서의 60개 질의에 대한 480개 생성 기록을 비교하였다. 다음 절에서는 연구 질문에 대한 답, 비교 설계의 의의, 적용 시 고려사항과 후속 연구를 정리한다.

6.1 연구 질문별 최종 답

첫 번째 연구 질문에서 HyDE의 답변 관련성 평균 대응 차이는 +0.0805, 95% 부트스트랩 신뢰구간은 [+0.0110, +0.1514]였다. 근거 충실도는 +0.0436, 문맥 정밀도는 -0.0343, 문맥 재현율은 0.0000이었다.

두 번째 연구 질문에서 CAD의 동일 문맥 근거 충실도 평균 대응 차이는 58개 유효쌍에서 +0.0288, 95% 신뢰구간은 [-0.0367, +0.0934]였다. 답변 관련성은 60쌍에서 -0.0073이었고 신뢰구간은 0을 포함하였다. CAD ON 조건의 평균 생성 시간은 대응 조건군에서 모두 증가하였다. 동일 문맥의 답변 품질에서는 증가와 감소가 함께 나타났으며 계산 비용도 늘었다.

세 번째 연구 질문에서 SCD의 한국어 문자 비율 평균 대응 차이는 HyDE OFF 동일 문맥 120개 대응쌍에서 +0.2182, 전체 240개 상태 일치 대응쌍에서 +0.2289였다. 이 결과는 SCD 적용 후 영어 검색 문맥을 사용하는 조건에서 생성 답변의 한국어 문자 비율이 높아졌음을 보여준다.

네 번째 연구 질문에서는 적용 목적별로 목표 지표와 요인별 대응 결과를 함께 검토하였다. HyDE의 답변 관련성 증가, CAD의 질의별 품질 차이와 생성 시간 증가, SCD의 한국어 문자 비율 증가를 분석하였다. 이 결과를 바탕으로 적용 목적별 실험 조건 선택 절차를 6.3절에 제안하였다.

6.2 비교 설계의 의의

이 비교 설계에서는 각 기법이 개입하는 위치에 따라 대응쌍을 구성하였다. 검색 입력을 바꾸는 HyDE는 검색 결과의 변화까지 포함하였고, CAD는 검색·재정렬 체크 ID와 최종 문맥이 같은 쌍에서 비교하였다. SCD는 HyDE OFF 동일 문맥 120쌍을 주 비교로 삼았으며, 전체 240개 상태 일치 대응쌍으로 조합 전반의 출력 언어 변화를 요약하였다. 이렇게 비교 조건을 구분하여 검색 문맥의 변화와 디코딩의 변화를 함께 해석할 수 있었다.

조합별 평균은 해당 설정의 전체 성능을, 요인별 대응 차이는 기법 적용 전후의 변화를 나타낸다. H1C1S0의 근거 충실도 평균 0.8599는 해당 조합의 결과이고, CAD의 +0.0288은 동일 문맥의 ON/OFF 대응 차이이다. 요인별 대응 결과를 함께 제시하여 두 해석을 구별하였다.

생성 기록에 질의, 검색·재정렬 체크 ID, 최종 문맥, 답변, 디코딩 메타데이터와 시간을 함께 저장한 점도 비교의 재현에 필요하다. 그림 5-3, 5-5, 5-7, 5-8, 5-10은 같은 기록에서 가져온 입력·출력과 평가값을 연결한다. 부록 B의 그림 B-1은 CAD의 근거 충실도가 감소한 사례이다. 이 자료들은 집계값과 개별 대응쌍의 입력 동일성 및 답변 차이를 제시한다.

6.3 적용 시 실험 조건 선택

적용 목적에 따라 목표 지표를 정하고 요인별 대응 결과를 함께 검토하는 절차를 제안한다. 답변 관련성이 목표이면 HyDE의 검색 결과 변화와 답변 관련성 대응 결과를 함께 검토한다. 같은 근거에서의 답변 품질이 목표이면 CAD의 질의별 품질 분포와 생성 시간을 함께 검토한다. 한국어 출력 유지가 목표이면 SCD의 동일 문맥 대응 결과를 검토한다. 고유명사·인용·전문용어의 보존은 별도 평가 항목으로 제안한다.

6.4 후속 연구 방향

후속 연구는 평가 상황의 확장과 기법별 처리 과정의 분리, 사람 평가를 중심으로 진행할 수 있다. 답변 불가능 질의, 오문서 지정 질의와 무근거 입력을 추가하여 근거 부족 상황에서의 응답을 분석한다. 문서 도메인과 생성 모델·토큰라이저를 확대하여 결과의 재현 범위를 평가한다.

HyDE는 번역, 가상 문서 생성과 밀집 검색 변경을 분리하여 비교하고, 동일 질의를 반복 샘플링하여 결과의 변동을 측정한다. CAD는 α 와 문맥 길이를 달리하여 답변 품질과 생성 시간의 관계를 측정하고, 질문 복잡도와 정보 통합 요구에 따른 질의별 변화 분포를 분석한다. SCD는 사람 블라인드 평가로 자연스러움, 번역 충실도, 내용 정확성과 전문용어 보존을 각각 측정한다. 다국어 재정렬 모델과 현재 CrossEncoder를 비교하여 검색 구성에 따른 차이를 확인한다.

참고문헌

- [1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” **Advances in Neural Information Processing Systems**, Vol. 33, 2020.
- [2] L. Gao et al., “Precise Zero-Shot Dense Retrieval without Relevance Labels,” **Proceedings of ACL**, pp. 1762-1777, 2023.
- [3] W. Shi et al., “Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding,” **Proceedings of NAACL**, pp. 783-791, 2024.
- [4] B. Li, Z. Xu, and R. Xie, “Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation,” **Proceedings of the AAAI Conference on Artificial Intelligence**, Vol. 40, No. 37, pp. 31519-31526, 2026.
- [5] J. Chen et al., “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” **Findings of the Association for Computational Linguistics: ACL 2024**, pp. 2318-2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.
- [6] S. E. Robertson et al., “Okapi at TREC-3,” **Text REtrieval Conference**, 1994.
- [7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” **Proceedings of SIGIR**, pp. 758-759, 2009.
- [8] R. Nogueira and K. Cho, “Passage Re-ranking with BERT,” arXiv:1901.04085, 2019.
- [9] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented Generation,” **Proceedings of EACL System Demonstrations**, pp. 150-158, 2024.
- [10] V. Karpukhin et al., “Dense Passage Retrieval for Open-Domain Question Answering,” **Proceedings of EMNLP**, pp. 6769-6781, 2020.
- [11] G. Izacard and E. Grave, “Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering,” **Proceedings of EACL**, pp. 874-880, 2021.

- [12] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” **Transactions of the Association for Computational Linguistics**, Vol. 12, pp. 157–173, 2024.
- [13] X. L. Li et al., “Contrastive Decoding: Open-ended Text Generation as Optimization,” **Proceedings of ACL**, pp. 12286–12312, 2023.
- [14] P. Sarthi et al., “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval,” **Proceedings of ICLR**, 2024.
- [15] A. Asai et al., “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection,” **Proceedings of ICLR**, 2024.
- [16] S.-Q. Yan et al., “Corrective Retrieval Augmented Generation,” *arXiv:2401.15884*, 2024.
- [17] P. Zhao et al., “Retrieval-Augmented Generation for AI-Generated Content: A Survey,” **Data Science and Engineering**, Vol. 11, pp. 1–29, 2026, doi: 10.1007/s41019-025-00335-5.
- [18] D. Shin et al., “Mi:dm 2.0 Korea-centric Bilingual Language Models,” *arXiv:2601.09066*, 2026.
- [19] Y. Gao et al., “Retrieval-Augmented Generation for Large Language Models: A Survey,” *arXiv:2312.10997*, 2023.
- [20] N. Thakur et al., “BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models,” **Proceedings of NeurIPS Datasets and Benchmarks Track**, 2021.
- [21] N. Muennighoff et al., “MTEB: Massive Text Embedding Benchmark,” **Proceedings of EACL**, pp. 2014–2037, 2023.
- [22] KT Tech Innovation Group, “Mi:dm K 2.5 Pro,” technical report, *arXiv:2603.18788v2*, 2026.

그림 자료 이용 정보

그림 2-2~2-6은 CC BY 4.0에 따라 이용하였다. 저자와 논문 서지정보는 아래 참고문헌 번호로 연결하고, 사용한 원본 자료와 편집 내역을 그림별로 정리하였다.

공통 라이선스: CC BY 4.0.

라이선스 안내: <https://creativecommons.org/licenses/by/4.0/>

그림 2-1 - 본 연구 작성. Lewis 외[1]의 RAG 구조를 참고하여 독립 도식을 작성하였다.

원본 자료:

<https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>

그림 2-2 - Nelson F. Liu 외[12], TACL 2024, 12:157-173; PDF page 2 (printed 158). 원본 그림 1. 변경: 도표 영역 잘라내기.

원본 자료: <https://aclanthology.org/2024.tacl-1.9.pdf>

그림 2-3 - Luyu Gao 외[2], ACL 2023, 1762-1777; PDF page 2 (printed 1763). 원본 그림 1. 변경: 도식 영역 잘라내기, OpenAI 로고 생략.

원본 자료: <https://aclanthology.org/2023.acl-long.99.pdf>

그림 2-4 - Weijia Shi 외[3], NAACL 2024 short, PDF page 1. 원본 그림 1. 변경: 그림 영역 잘라내기.

원본 자료: <https://aclanthology.org/2024.naacl-short.69.pdf>

그림 2-5 - Bo Li 외[4], arXiv:2511.09984v1, PDF page 1. 원본 그림 1. 변경: 그림 영역 잘라내기, OpenAI·Ollama 로고 생략.

원본 자료: <https://arxiv.org/pdf/2511.09984v1>

그림 2-6 - Shahul Es 외[9], arXiv:2309.15217v2, PDF page 8. 원본 표 2. 변경: 표 영역 잘라내기.

원본 자료: <https://arxiv.org/pdf/2309.15217v2>

부록 A. 60개 질의 목록

부록 A의 질문 문장은 실제 실험 입력을 그대로 수록하였다.

[표 A-1] 60개 질의-대상 문서 쌍

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_cad_001	언어 모델이 생성 시 활용하는 prior knowledge와 context knowledge는 각각 어디에서 오는 정보입니까?	CAD	사실·정의	1	the context contains external knowledge; prior knowledge is encoded in the model parameters
ext_cad_002	CAD의 요약 실험에는 어떤 데이터셋과 평가 지표가 사용되었습니까?	CAD	방법·절차	3	CNN-DM and XSUM; ROUGE-L, BERT-Precision, and FactKB
ext_cad_003	CAD의 지식 충돌 실험에는 어떤 두 데이터셋이 사용되었고 각각 무엇을 평가합니까?	CAD	방법·절차	3	MemoTrap investigates memorization traps; NQ-Swap tests faithful answering from a modified reliable document.
ext_cad_004	NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?	CAD	방법·절차	3	identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity
ext_cad_005	CAD 실험에서 요약 과제와 지식 충돌 과제에 사용한 α 값은 각각 얼마이며, 지식 충돌 과제에서 더 큰 값을 사용한 이유는 무엇입니까?	CAD	방법·절차	3	$\alpha = 0.5$ for summarization and $\alpha = 1$ for knowledge conflicts, where prior knowledge needs to be factored out more
ext_cad_006	CAD 논문의 베이스라인 디코딩은 요약 과제와 지식 충돌 과제에서 각각 어떤 샘플링 전략을 사용합니까?	CAD	방법·절차	3	greedy decoding for knowledge conflict tasks and top-p sampling with p=0.9 for summarization tasks
ext_cad_007	CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?	CAD	방법·절차	3	OPT, GPT-Neo, LLaMA, and FLAN-T5
ext_cad_008	지식 충돌 과제에서 모델 크기가 커질수록 CAD의 성능 향상 폭은 어떤 경향을 보였습니까?	CAD	결과·비교	5	the gain increases as the model size grows
ext_cad_009	LLaMA-30B에 CAD를 적용했을 때 XSUM에서	CAD	결과·비교	4	Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
	ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?				
ext_cadm_010	외부 컨텍스트가 생성 토큰과 조건부 독립이라면 α 가 0이 아니어도 CAD의 출력 분포에는 어떤 영향이 있습니까?	CAD	사실·정의	2	even a non-zero α would not have an impact to the original output distribution
ext_cadm_011	CAD는 특정 instruction-finetuned 언어 모델에만 제한됩니까, 아니면 어떤 언어 모델에도 적용 가능한 디코딩 전략입니까?	CAD	사실·정의	6	a decoding strategy applicable to any LM
ext_midm_001	Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?	Mi:dm K 2.5 Pro Technical Report	방법·절차	3	licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data
ext_midm_002	Mi:dm K 2.5 Pro는 한국어 중심 학습을 유지하기 위해 다국어 데이터를 한국어 코퍼스 대비 어느 정도 비율로 제한하며, 그 이유는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	방법·절차	3	3-10% of the Korean corpus, to encourage cross-lingual transfer without diluting the Korean-language focus
ext_midm_003	응답 스타일 재작성 후 평균 응답 길이는 몇 % 증가했고, bullet_count=0인 응답의 비율은 어떻게 변했습니까?	Mi:dm K 2.5 Pro Technical Report	결과·비교	8	mean response length increases by 256.70%; bullet_count = 0 drops from 82.8% to 3.9%
ext_midm_004	Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?	Mi:dm K 2.5 Pro Technical Report	방법·절차	15	interaction structure, topic and task, and persona
ext_midm_005	Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?	Mi:dm K 2.5 Pro Technical Report	방법·절차	21	to favor versatile conversational alignment; creative writing, translation, and general question answering
ext_midm_006	Fully asynchronous GSPO 학습은 synchronous 방식과 비교해 step time과 token throughput을 각각 어느 정도 개선했습니까?	Mi:dm K 2.5 Pro Technical Report	결과·비교	23	reduces step time by approximately 15% and improves token throughput by approximately 30%
ext_midm_007	LLM-as-a-Judge 기반 reward signal은 사람의 평가와 어느 정도의 일치율을 보였습니까?	Mi:dm K 2.5 Pro Technical Report	결과·비교	24	an agreement rate of 91%

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
ext_midm_008	Reasoning-enabled 평가에서 Mi:dm K 2.5 Pro가 HumanEval+와 τ^2 -Bench Telecom에서 기록한 점수는 각각 얼마입니까?	Mi:dm K 2.5 Pro Technical Report	결과·비교	25	HumanEval+ 92.07% and τ^2 -Bench Telecom 89%
ext_midm_009	한국어 red-teaming 평가에서 Mi:dm K 2.5 Pro의 Attack Success Rate는 얼마였으며 비교 모델들 가운데 어떤 수준이었습니까?	Mi:dm K 2.5 Pro Technical Report	결과·비교	31	ASR of 36.3%, the lowest attack success rate among the compared models
ext_rag_001	Advanced RAG의 pre-retrieval 단계는 인덱스와 사용자 질의를 각각 어떤 방향으로 최적화합니까?	RAG Survey	방법·절차	4	optimizing the indexing structure and the original query
ext_rag_002	Advanced RAG의 post-retrieval 단계에서 사용되는 두 가지 핵심 방법은 무엇입니까?	RAG Survey	방법·절차	4	rerank chunks and context compressing
ext_rag_003	RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?	RAG Survey	방법·절차	8	Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.
ext_rag_004	문서 청크에 타임스탬프 같은 메타데이터를 부여하면 time-aware RAG는 최신 정보를 어떻게 우선할 수 있습니까?	RAG Survey	방법·절차	8	Assigning different weights to document timestamps during retrieval can achieve time-aware RAG, ensuring the freshness of knowledge and avoiding outdated information.
ext_rag_005	Reverse HyDE는 문서로부터 가상의 질문을 생성해 원래 질문과 답변 사이의 의미적 간극을 어떻게 줄입니까?	RAG Survey	방법·절차	8	using LLM to generate questions that can be answered by the document, then calculating the similarity between the original question and the hypothetical question
ext_rag_006	Multi-Query와 Sub-Query 방식은 원래 질의를 확장하거나 분해하는 방식에서 어떻게 다릅니까?	RAG Survey	방법·절차	8	Multi-Query expands queries via LLMs for parallel execution; Sub-Query decomposes a complex question into simpler sub-questions.
ext_rag_007	Iterative Retrieval, Recursive Retrieval, Adaptive Retrieval은 검색을 반복하거나 중단하는	RAG Survey	방법·절차	11	Iterative retrieval alternates retrieval and generation; recursive retrieval refines queries and breaks problems into

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
	방식에서 각각 어떻게 구분되니까?				sub-problems; adaptive retrieval determines whether retrieval is necessary and when to stop.
ext_rag_008	RAG 평가에서 요구되는 네 가지 핵심 능력은 무엇입니까?	RAG Survey	방법·절차	12	noise robustness, negative rejection, information integration, and counterfactual robustness
ext_rag_009	RAG 평가에서 Negative Rejection은 어떤 능력을 측정합니까?	RAG Survey	사실·정의	12	refraining from responding when the retrieved documents do not contain the necessary knowledge to answer a question
ext_rag_010	RAG와 파인튜닝을 비교할 때 지식 업데이트의 동적 특성과 해석 가능성 측면에서 RAG가 갖는 특징은 무엇입니까?	RAG Survey	결과·비교	5	real-time knowledge updates and effective utilization of external knowledge sources with high interpretability
ext_raptor_001	RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?	RAPTOR	방법·절차	3	length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk
ext_raptor_002	RAPTOR의 leaf node를 만들 때 텍스트 임베딩에 사용한 모델은 무엇입니까?	RAPTOR	방법·절차	3	SBERT, a BERT-based encoder (multi-qa-mpnet-base-cos-v1)
ext_raptor_003	RAPTOR의 GMM 클러스터링 전에 UMAP을 사용하는 이유는 무엇입니까?	RAPTOR	방법·절차	4	to mitigate the challenge of high-dimensional vector embeddings by dimensionality reduction
ext_raptor_004	RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?	RAPTOR	방법·절차	4	to determine the optimal number of clusters
ext_raptor_005	RAPTOR에서 클러스터별 요약물 생성하는 데 사용한 언어 모델은 무엇입니까?	RAPTOR	방법·절차	4	gpt-3.5-turbo
ext_raptor_006	RAPTOR의 트리 구축 비용은 문서 길이가 증가할 때 build time과 token expenditure 측면에서 어떻게 확장됩니까?	RAPTOR	결과·비교	16	both build time and token expenditure scale linearly with document length
ext_raptor_007	QASPER 데이터셋은 몇 개의 질문과 NLP 논문으로 구성되며, 논문에서는 어떤	RAPTOR	방법·절차	6	5,049 questions across 1,585 NLP papers; accuracy is measured using standard F1

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
	지표로 성능을 평가합니까?				
ext_raptor_008	QuALITY-HARD는 일반 QuALITY 질문 중 어떤 기준을 만족하는 질문들로 구성됩니까?	RAPTOR	사실·정의	6	questions that a majority of human annotators answered incorrectly in a speed-setting
ext_raptor_009	QASPER에서 RAPTOR의 F1 Match 점수는 GPT-3, GPT-4, UnifiedQA를 사용할 때 각각 얼마였습니까?	RAPTOR	결과·비교	7	53.1%, 55.7%, and 36.6%, respectively
ext_raptor_010	QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?	RAPTOR	결과·비교	9	57.9 with one leaf layer versus 73.68 with all three layers
ext_raptor_011	Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?	RAPTOR	결과·비교	20	RAPTOR retrieves relevant information across tree layers, while DPR retrieves detailed descriptions of a narrow subset of the story
track1_009	RAG가 LLM에서 사실적으로 부정확한 콘텐츠 생성을 줄이는 데 어떻게 기여합니까?	RAG Survey	목적·기여	1	By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content.
track1_010	RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?	RAG Survey	방법·절차	3	The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework.
track1_012	RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?	RAG Survey	목적·기여	1	This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.
track1_015	RAG 프로세스에서 핵심적인 역할을 하는 세 가지 구성 기술은 무엇인가요?	RAG Survey	사실·정의	2	the aspects of Retrieval, Generation and Augmentation
track1_016	RAG 방법론의 평가 방법은 어떻게 요약되어 있습니까?	RAG Survey	방법·절차	2	We have summarized the current assessment methods of RAG, covering 26 tasks, nearly 50

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
					datasets, outlining the evaluation objectives and metrics, as well as the current evaluation benchmarks and tools.
track1_0019	LLaMA-30B 모델에 CAD를 적용했을 때 CNN-DM 데이터셋에서 어떤 성과가 있었나요?	CAD	결과·비교	3	Specifically, when applied to LLaMA-30B in CNN-DM, CAD leads to 21% increase in ROUGE-L, 14.3% increase in factKB and 7.8% increase in BERT-P.
track1_0021	CAD는 어떻게 잘못된 정보 생성을 줄이나요?	CAD	결과·비교	2	These results demonstrate the potential of CAD in mitigating hallucinations in text generation and overriding prior knowledge with reliable and trusted information.
track1_0023	CAD는 언어 모델이 생성하는 요약문의 사실적 정확성을 향상시키나요?	CAD	결과·비교	1	Experimental results from summarization tasks show that context-aware decoding significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs such as FLAN (Chung et al., 2022).
track1_0024	CAD를 적용하지 않은 경우와 비교했을 때, knowledge conflict QA 데이터셋에서 LLaMA-30B의 성능은 어떻게 변화하나요?	CAD	결과·비교	2	CAD brings a 2.9x improvement to LLaMA-30B on a knowledge conflicts QA dataset (Longpre et al., 2021).
track1_0025	RAPTOR 모델이 QuALITY 벤치마크에서 기존 성능을 얼마나 개선했나요?	RAPTOR	결과·비교	1	we can improve the best performance on the QuALITY benchmark by 20% in absolute accuracy.
track1_0026	RAPTOR의 트리 구조는 텍스트 클러스터링을 통해 어떻게 구축되나요?	RAPTOR	방법·절차	2	RAPTOR recursively clusters chunks of text based on their vector embeddings and generates text summaries of those clusters, constructing a tree from the bottom up.
track1_0027	RAPTOR가 여러 QA 작업에서 달성한 결과는 무엇인가요?	RAPTOR	결과·비교	2	RAPTOR coupled with GPT-4, and sometimes even with

query ID	한국어 질문	대상 문서	유형	원문 페이지	정답 근거 구간
					UnifiedQA, gives new state-of-the-art results on three QA tasks: free text response questions on books and movies (NarrativeQA, Kočiský et al. 2018), full-text NLP papers (QASPER, Dasigi et al. 2021), and multiple-choice questions based on medium-length passages (QuALITY, Pang et al. 2022).
track1_0032	RAPTOR의 계층에서 검색된 노드가 어느 계층에서 오는지에 대한 연구 결과는 무엇인가요?	RAPTOR	결과·비교	22	We observe that between 18.5% to 57% of the retrieved nodes come from non-leaf nodes.
track1_0033	Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까?	Mi:dm K 2.5 Pro Technical Report	사실·정의	2	32B parameters
track1_0034	Mi:dm K 2.5 Pro의 방법론에서 AST 분석은 어떤 목적으로 사용됩니까?	Mi:dm K 2.5 Pro Technical Report	방법·절차	1	abstract syntax tree (AST) analysis for code
track1_0035	Mi:dm K 2.5 Pro 모델은 어떤 한국어 벤치마크에서 최첨단 결과를 달성했습니까?	Mi:dm K 2.5 Pro Technical Report	결과·비교	1	sets state-of-the-art results on Korean-specific benchmarks
track1_0036	Mi:dm K 2.5 Pro가 해결하려는 주요 문제는 무엇입니까?	Mi:dm K 2.5 Pro Technical Report	목적·기여	1	address enterprise-grade complexity through reasoning-focused optimization
track1_0037	Mi:dm K 2.5 Pro 모델의 컨텍스트 윈도우(context window) 길이는 얼마입니까?	Mi:dm K 2.5 Pro Technical Report	사실·정의	1	128K token context window
track1_0040	Mi:dm K 2.5 Pro의 사후 훈련 파이프라인에서 모델 병합은 어떤 역할을 합니까?	Mi:dm K 2.5 Pro Technical Report	방법·절차	2	improve training stability and achieve balanced performance across complex reasoning, coding, instruction following, and agentic task execution

부록 B. 추가 사례 및 탐색 분석

B.1 추가 입출력 사례

본문에서는 각 요인의 대표 사례를 그림 5-3, 5-5, 5-7, 5-8, 5-10에 제시하였다. 부록에서는 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 추가 사례를 제시하여 질의별 변화 방향을 함께 확인한다.

```
RAG-Cube 60-query Stored Input/Output Evidence — E06 CAD Trade-off Same-Context Pair
=====
Cube-RAG 60-query Stored Input/Output Evidence
=====
Case           : E06 CAD Trade-off Same-Context Pair
Selection      : stored 60-query CAD pair selected for lower faithfulness under identical retrieved inputs

Query ID       : track1_0012
Paper          : paper_nlp_rag

Question
-----
RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?

Contexts identical: True
Retrieved IDs identical: True
Renranked IDs identical: True

Configuration A
-----
Config          : hyde_off...no_decoder_control
HyDE / CAD / SCD : False / False / False
Korean ratio    : 0.4157
Stored RAGAS     : faithfulness=0.9375, answer_relevancy=0.9001, context_precision=1.0000, context_recall=1.0000

Stored answer
-----
[역 근거]

RAG 시스템이 지식 집약적인 작업에서 있는 장점을 설명해주세요.

주어진 문서에서 RAG 시스템의 지식 집약적 작업 관련 장점을 찾아 정리해주세요.

특정 연구 결과나 실험 데이터가 있다면 함께 제시해주세요 바랍니다.

[답변]
제공된 논문 컨텍스트를 분석한 결과, RAG(Retrieval-Augmented Generation) 시스템이 지식 집약적 작업에서 갖는 여러 강점들이 명확하게 제시되어 있습니다.

## 1. 외부 지식 활용의 우수성
논문에서는 "RAG excels in dynamic environments by offering realtime knowledge updates and effective utilization of external knowledge sources with high interpretability"라고 명시하고 있습니다. RAG는 실시간 지식 업데이트를 제공하여 외부 지식 소스를 효과적으로 활용할 수 있어 해석 가능성이 높다는 장점이 있습니다.

## 2. 기존 및 새로운 지식 모두에서의 우수한 성능
"[28] revealed that while unsupervised fine-tuning shows some improvement, RAG consistently outperforms it, for both existing knowledge encountered during training and entirely new knowledge"라는 연구 결과가 제시되어 있습니다. 이는 RAG가 훈련 중 접한 기존 지식뿐만 아니라 완전히 새로운 지식 영역에서도 마인류보다 월등히 우수한 성능을 보임을 의미합니다.

## 3. LLM의 새로운 사실 학습 한계 극복
"It was fou
... [truncated: 836 characters; use --full]

Retrieved chunk IDs
-----
paper_nlp_rag_bf4cd54870dd_2
paper_nlp_rag_bf4cd54870dd
paper_nlp_rag_50811b9a6139
paper_nlp_rag_cd21092daa14
paper_nlp_rag_532199ae0699
paper_nlp_rag_e9a713793233
paper_nlp_rag_addf6d73da05
paper_nlp_rag_2f655db1ecaf

Configuration B
-----
Config          : hyde_off...cad_only
HyDE / CAD / SCD : False / True / False
Korean ratio    : 0.8462
Stored RAGAS     : faithfulness=0.5000, answer_relevancy=0.0000, context_precision=1.0000, context_recall=1.0000

Stored answer
-----
논문]

위 내용 참조

**

답변을 뒷받침하는 구체적인 예시나 연구 결과도 포함해 주세요.

breath

**

Retrieved chunk IDs
-----
paper_nlp_rag_bf4cd54870dd_2
paper_nlp_rag_bf4cd54870dd
paper_nlp_rag_50811b9a6139
paper_nlp_rag_cd21092daa14
paper_nlp_rag_532199ae0699
paper_nlp_rag_e9a713793233
paper_nlp_rag_addf6d73da05
paper_nlp_rag_2f655db1ecaf

Korean-ratio delta: +0.4305
=====
```

[그림 B-1] 동일 검색 문맥에서 CAD 적용 후 근거 충실도가 감소한 추가 사례

질의 ID: track1_0012.

B.2 문서별·질문 유형별 탐색 분석

문서별·질문 유형별 분석과 조건군별 결과는 표본 수를 함께 제시하며 탐색적으로 해석한다. 특히 목적·기여 유형은 n=3의 소규모 하위집단 결과로 제시한다.

[표 B-1] 문서별 탐색 분석

대상 문서	요인	지표	n	평균 변화
Mi:dm K 2.5 Pro Technical Report	HyDE	근거 충실도	15	0.0007
Mi:dm K 2.5 Pro Technical Report	HyDE	답변 관련성	15	0.0994
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 정밀도	15	-0.0145
Mi:dm K 2.5 Pro Technical Report	HyDE	문맥 재현율	15	0.1333
Mi:dm K 2.5 Pro Technical Report	CAD	근거 충실도	15	0.0081
Mi:dm K 2.5 Pro Technical Report	CAD	답변 관련성	15	0.0339
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 정밀도	15	0
Mi:dm K 2.5 Pro Technical Report	CAD	문맥 재현율	15	0
CAD	HyDE	근거 충실도	15	-0.0491
CAD	HyDE	답변 관련성	15	-0.0019
CAD	HyDE	문맥 정밀도	15	-0.0823
CAD	HyDE	문맥 재현율	15	-0.0667
CAD	CAD	근거 충실도	15	0.0664
CAD	CAD	답변 관련성	15	-0.0099
CAD	CAD	문맥 정밀도	15	-0.0552
CAD	CAD	문맥 재현율	15	-0.0667
RAG Survey	HyDE	근거 충실도	15	0.1575
RAG Survey	HyDE	답변 관련성	15	0.1314
RAG Survey	HyDE	문맥 정밀도	15	0.0036
RAG Survey	HyDE	문맥 재현율	15	0.0667
RAG Survey	CAD	근거 충실도	13	-0.0416

대상 문서	요인	지표	n	평균 변화
RAG Survey	CAD	답변 관련성	15	-0.1004
RAG Survey	CAD	문맥 정밀도	15	0.0074
RAG Survey	CAD	문맥 재현율	15	0
RAPTOR	HyDE	근거 충실도	15	0.0652
RAPTOR	HyDE	답변 관련성	15	0.093
RAPTOR	HyDE	문맥 정밀도	15	-0.0441
RAPTOR	HyDE	문맥 재현율	15	-0.1333
RAPTOR	CAD	근거 충실도	15	0.0731
RAPTOR	CAD	답변 관련성	15	0.047
RAPTOR	CAD	문맥 정밀도	15	0.0108
RAPTOR	CAD	문맥 재현율	15	0

[표 B-2] 질문 유형별 탐색 분석

질문 유형	요인	지표	n	평균 변화
사실·정의	HyDE	근거 충실도	8	0.0966
사실·정의	HyDE	답변 관련성	8	0.0455
사실·정의	HyDE	문맥 정밀도	8	-0.1328
사실·정의	HyDE	문맥 재현율	8	-0.125
사실·정의	CAD	근거 충실도	8	0.0005
사실·정의	CAD	답변 관련성	8	-0.0145
사실·정의	CAD	문맥 정밀도	8	-0.0486
사실·정의	CAD	문맥 재현율	8	0
방법·절차	HyDE	근거 충실도	29	0.0792
방법·절차	HyDE	답변 관련성	29	0.1719
방법·절차	HyDE	문맥 정밀도	29	-0.0029
방법·절차	HyDE	문맥 재현율	29	0.069
방법·절차	CAD	근거 충실도	27	0.0823
방법·절차	CAD	답변 관련성	29	0.0684
방법·절차	CAD	문맥 정밀도	29	0.0029
방법·절차	CAD	문맥 재현율	29	0
결과·비교	HyDE	근거 충실도	20	-0.0509
결과·비교	HyDE	답변 관련성	20	-0.0216
결과·비교	HyDE	문맥 정밀도	20	-0.0289
결과·비교	HyDE	문맥 재현율	20	-0.05
결과·비교	CAD	근거 충실도	20	-0.0037
결과·비교	CAD	답변 관련성	20	-0.0683
결과·비교	CAD	문맥 정밀도	20	-0.0124
결과·비교	CAD	문맥 재현율	20	-0.05
목적·기여	HyDE	근거 충실도	3	0.1875

질문 유형	요인	지표	n	평균 변화
목적·기여	HyDE	답변 관련성	3	-0.0289
목적·기여	HyDE	문맥 정밀도	3	-0.1111
목적·기여	HyDE	문맥 재현율	3	0
목적·기여	CAD	근거 충실도	3	-0.1597
목적·기여	CAD	답변 관련성	3	-0.3139
목적·기여	CAD	문맥 정밀도	3	0
목적·기여	CAD	문맥 재현율	3	0