졸업자격실험보고서

한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

지도교수

졸업자격실험보고서

한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

Combination Experiments of HyDE, CAD, and SCD in RAG for Searching English Academic and Technical Documents with Korean Queries

지도교수

본 보고서를 졸업자격 실험보고서로 제출함.

졸업자격 실험보고 통과를 인준함.

주심 (인)

부심 (인)

목 차

1. 서론 ····· 1
1.1 연구배경 및 목적 ····· 1
1.2 연구범위 ····· 2
1.3 연구 질문 및 논문 구성 ····· 2
2. 이론적 배경 ····· 3
2.1 Retrieval-Augmented Generation ····· 3
2.2 하이브리드 검색과 재정렬 ····· 3
2.3 가상 문서 임베딩과 검색 ····· 4
2.4 Context-Aware Decoding ····· 4
2.5 Soft Constrained Decoding과 언어 이탈 ····· 5
2.6 RAG 평가 ····· 6
2.7 관련 연구와 본 연구의 위치 ····· 6
3. 시스템 설계 ····· 7
3.1 연구 및 실험 요구사항 ····· 7
3.2 아키텍처 설계 ····· 7
3.3 실험 조건과 질문별 대응 비교 ····· 7
4. 프로그램 구현 ····· 8
4.1 시스템 환경 ····· 8
4.2 시스템 구성 ····· 8
4.3 시스템 구현과 실행 기록 ····· 9
5. 실험 ····· 10
5.1 질문 구성과 분석 대상 ····· 10
5.2 평가 지표와 평가 입력 ····· 10
5.3 질문별 대응 비교 방법 ····· 12
5.4 질문 유형별 단일 기법의 결과 ····· 12
5.5 복수 기법 조합과 검색 결과의 변화 ····· 17
5.6 질문이 요구한 정보와 실제 답변 ····· 18

5.7 한국어 출력과 처리 시간 ····· 19
5.8 질문 구성과 적용 조건에 대한 논의 ····· 23
6. 결론 ····· 24
6.1 연구 질문별 결과 ····· 24
6.2 연구의 의의와 적용 조건 ····· 24
6.3 후속 연구 ····· 24
참고문헌 ····· 25
부록 A. 60개 질문과 정답 근거 ····· 29
부록 B. 질문별 검색 근거와 실제 답변 ····· 39
B.1 RAPTOR에서 BIC가 결정하는 항목 ····· 39
B.2 NQ-Swap 데이터셋의 생성 절차 ····· 39
B.3 Fusion SFT의 non-reasoning 비중 확대 목적 ····· 40
B.4 QuALITY의 계층별 검색 성능 비교 ····· 40
B.5 LLaMA-30B·XSUM의 세 지표 비교 ····· 40
B.6 RAPTOR 청크 길이와 문장 경계 처리 ····· 41
B.7 지식 집약 과제에서 RAG의 이점 ····· 41
B.8 Naive RAG의 처리 과정 ····· 42
B.9 큰 청크와 작은 청크의 장단점 ····· 42

그 림 목 차

[그림 1-1] Paper-RAG에서 HyDE·CAD·SCD의 적용 위치 ····· 1
[그림 2-1] RAG의 검색기-생성기 구조[1] ····· 3
[그림 2-2] HyDE의 가상 문서 기반 검색 구조[2] ····· 4
[그림 2-3] CAD의 문맥 포함·제외 로짓 결합[3] ····· 5
[그림 2-4] SCD의 토큰 그룹별 로짓 조정[4] ····· 5
[그림 4-1] 한국어 질의의 검색·융합·재정렬 및 답변 생성 흐름 ····· 9
[그림 5-1] 질문별 생성 기록과 평가값을 연결하는 비교 절차 ····· 11
[그림 5-2] RAPTOR의 BIC 질문에 제공한 입력 구간·답변과 평가값 ····· 12
[그림 5-3] HyDE 적용 후 질문 유형별 개별 점수 ····· 15
[그림 5-4] CAD 적용 후 질문 유형별 개별 점수 ····· 16
[그림 5-5] SCD 적용 후 질문 유형별 개별 점수 ····· 21

표 목 차

[표 2-1] 선행연구의 핵심 접근과 본 연구와의 관계 ····· 6

[표 4-1] 검색·재정렬·생성 단계의 모델과 공통 실행 설정 ····· 8

[표 5-1] HyDE 적용 전후의 유형별 답변 관련성 ····· 13

[표 5-2] CAD 적용 전후의 유형별 근거 충실도 ····· 14

[표 5-3] 복수 기법 조합의 유형별 답변 관련성 ····· 17

[표 5-4] HyDE 적용 전후의 유형별 검색 지표 ····· 18

[표 5-5] SCD 적용 전후의 유형별 한국어 문자 비율 ····· 20

[표 5-6] 단일 기법 적용 전후의 유형별 처리 시간 ····· 22

[표 A-1] 60개 질문의 대상 문서·유형·정답 근거 ····· 29

1. 서론

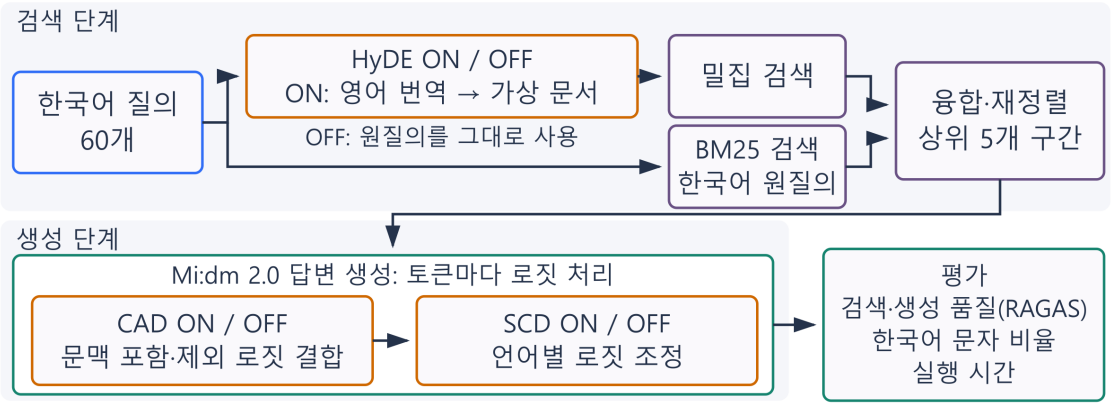
1.1 연구배경 및 목적

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 질문과 관련된 문서 구간을 외부 자료에서 검색하고, 검색한 구간을 생성 모델의 입력에 넣어 답변을 만드는 방법이다[1]. RAG는 모델의 학습 시점 이후에 나온 논문과 기술 문서도 원문을 근거로 답할 수 있어 학술 문서 질의응답에 널리 쓰인다.

RAG의 성능을 높이는 기법은 검색 단계와 생성 단계에 모두 있다. 검색 단계의 가상 문서 임베딩(Hypothetical Document Embeddings, HyDE)은 질문에 대한 답변 형태의 가상 문서를 먼저 생성하고, 이 문서의 임베딩으로 실제 문서를 검색한다[2]. 생성 단계의 문맥 인식 디코딩(Context-Aware Decoding, CAD)은 검색 결과를 입력에 포함했을 때와 제외했을 때의 다음 토큰 점수를 비교하여, 검색 결과가 뒷받침하는 토큰이 선택될 가능성을 높인다[3]. 소프트 제약 디코딩(Soft Constrained Decoding, SCD)도 생성 단계에서 목표 언어 토큰과 다른 언어 토큰의 로짓에 서로 다른 계수를 곱해 출력 언어를 제어한다[4].

한국어 질의로 영어 논문을 다루는 RAG는 세 가지 과제를 함께 풀어야 한다. 검색에서는 한국어 질의와 영어 원문의 어휘 차이를 넘어 근거를 찾아야 하고, 답변 생성에서는 영어 근거의 내용을 한국어 답변에 충실히 반영해야 한다. 또한 모델이 영어 근거를 따라 영어로 답하는 언어 이탈(language drift)을 막아야 한다. 앞의 세 기법은 이 과제에 하나씩 대응한다. HyDE는 검색 입력을, CAD는 근거 반영을, SCD는 출력 언어를 조정한다. 세 기법의 원 논문은 각기 다른 모델과 과제에서 검색 입력, 문맥 반영, 출력 언어를 평가하였다. 본 연구에서는 같은 파이프라인과 한국어 질문에 세 기법을 적용하고, 질문 유형과 요구 정보에 따른 답변·검색 점수와 실행 시간을 비교한다.

실험에는 영어 학술·기술 문서를 검색하여 한국어 답변을 생성하는 고정 파이프라인 Paper-RAG를 사용하였다. 같은 한국어 질문 60개에 HyDE·CAD·SCD의 여덟 적용 조건을 구성하였다(그림 1-1).



[그림 1-1] Paper-RAG에서 HyDE·CAD·SCD의 적용 위치

본 연구의 목적은 한국어 질의-영어 문서 RAG에서 질문의 유형과 요구 정보에 따라 HyDE·CAD·SCD의 결과가 어떻게 달라지는지 확인하는 것이다. 같은 질문의 원점수와 조건

간 차이를 질문 유형별로 정리하고, 검색 구간과 실제 답변을 대조하여 개선과 실패의 양상을 설명한다. 한국어 문자 비율, 질문에 대한 관련성, 검색 근거에 대한 충실도와 처리 비용을 구분하여 적용 조건을 제시한다.

1.2 연구범위

검색 대상은 영어 문서 4종으로, RAG Survey[D1], CAD[D2], RAPTOR[D3], Mi:dm K 2.5 Pro Technical Report[D4]이다. 문서마다 한국어 질의를 15개씩, 총 60개 작성하였고, 각 질의의 검색 범위는 해당 문서로 한정하였다. 질의마다 8개 조합을 적용하여 생성 답변 480개를 얻었다.

답변 생성 모델은 Mi:dm 2.0 Base Instruct[M1]이다. 검색·생성 품질은 RAGAS의 네 지표로, 출력 언어는 한국어 문자 비율로, 비용은 조합별 실행 시간으로 측정하였다. 검색·재정렬·생성 설정은 4장에 정리하였다.

1.3 연구 질문 및 논문 구성

연구의 중심 질문은 ‘한국어 질의로 영어 문서를 다루는 RAG에서 질문의 유형과 특성에 따라 HyDE·CAD·SCD의 결과가 어떻게 달라지는가?’이다. 이를 다음 네 연구 질문(research question, RQ)으로 나누었다.

RQ1. 네 질문 유형에서 HyDE와 CAD를 각각 적용할 때 답변 관련성·근거 충실도와 검색 지표는 어떻게 달라지는가?

RQ2. 같은 평가 언어 안에서 단일 기법과 두 기법 이상 조합의 차이는 질문 유형별로 어떻게 나타나는가?

RQ3. SCD 추가 후 한국어 문자 비율과 단일 기법 적용의 처리 시간은 질문 유형별로 어떻게 달라지는가?

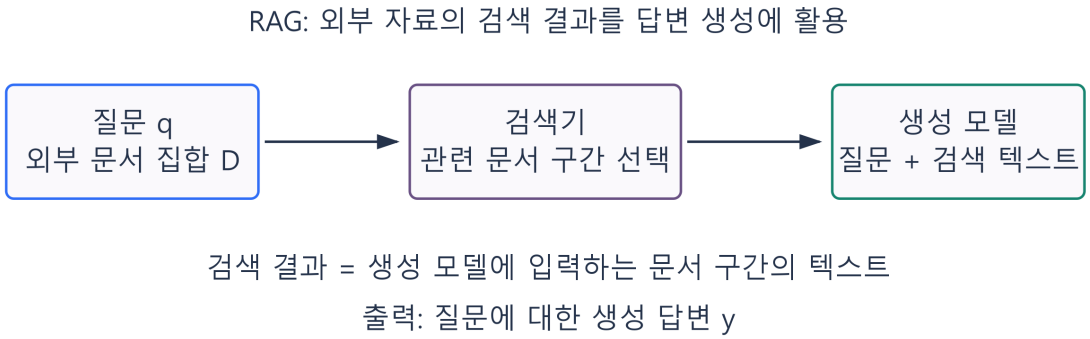
RQ4. 개선과 악화를 보인 실제 질문에서 요구 정보, 검색 근거와 생성 답변은 어떻게 달라지며, 자동 평가값과 요구 정보 충족은 일치하는가?

2장은 세 기법과 관련 연구를, 3장과 4장은 실험 설계와 구현을 설명한다. 5장은 네 유형의 대응 비교와 실제 질문 사례를 분석하고, 6장은 관측된 적용 조건과 후속 연구를 정리한다. 부록 A는 60개 질문과 정답 근거를, 부록 B는 질문별 특성과 사례의 검색·답변 대조를 제시한다.

2. 이론적 배경

2.1 Retrieval-Augmented Generation

Lewis 외의 RAG는 검색기(retriever)가 외부 문서 인덱스에서 관련 문서를 찾고, 생성기(generator)가 질의와 검색 문서를 함께 입력받아 답변을 생성하는 구조다(그림 2-1).



[그림 2-1] RAG의 검색기-생성기 구조[1]

질의를 q, 문서 집합을 D라 하면 검색기 Retrieve는 D에서 질의와 관련된 문서 구간을 골라 검색 결과 C_q를 만들고, 생성 모델 LM은 q와 C_q를 입력받아 답변 y를 생성한다.

$$C_q = Retrieve(q, D)$$

$$y = LM(q, C_q)$$

2.2 하이브리드 검색과 재정렬

밀집 검색은 질의와 문서 구간을 임베딩한 벡터의 유사도로, BM25 희소 검색은 두 텍스트의 어휘 일치로 관련 구간을 찾는다[5][6]. 한국어 질의와 영어 원문은 어휘가 대부분 다르지만, 논문명·모델명·데이터셋명·수치처럼 두 언어에 같은 형태로 쓰이는 표기는 BM25의 검색 단서가 된다.

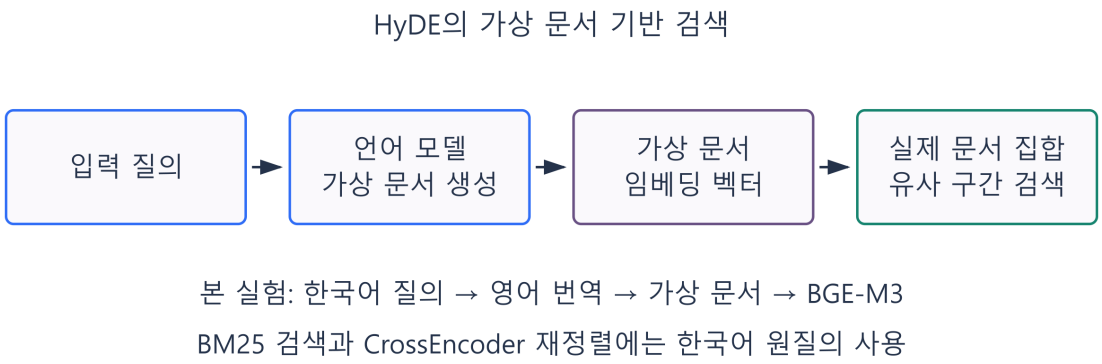
두 검색 결과는 가중 역순위 융합(weighted Reciprocal Rank Fusion, RRF)으로 결합한다[7]. 문서 d의 밀집 검색 순위와 BM25 순위를 각각 rank_dense(d), rank_BM25(d)라 할 때, 가중치 0.6과 0.4, 상수 k=60을 적용한 결합 점수는 다음과 같다.

$$RRF(d) = \frac{0.6}{k + rank_{dense(d)}} + \frac{0.4}{k + rank_{BM25(d)}}$$

융합한 검색 후보는 질의와 후보 구간을 한 쌍으로 입력받는 재정렬 모델의 관련성 점수로 다시 정렬한다. 재정렬 모델로는 문맥화된 언어 모델 표현을 문서 순위 계산에 활용한 CEDR[8] 등이 있다. 재정렬 순서는 생성 모델에 입력하는 검색 결과의 배치를 정한다. 생성 모델은 입력 내 위치에 따라 근거를 다르게 활용할 수 있으므로[9], 이 배치가 답변에도 영향을 줄 수 있다.

2.3 가상 문서 임베딩과 검색

HyDE는 입력 질의로 생성한 가상 문서를 임베딩하여 실제 문서 집합에서 유사한 문서를 검색한다. 가상 문서의 내용이 틀릴 수 있어도 답변과 비슷한 어휘와 문장 구조를 갖기 때문에, 짧은 질문을 그대로 임베딩할 때보다 관련 문서에 가까운 검색 입력을 얻을 수 있다. 가상 문서는 검색 입력으로만 쓰이고, 최종 답변의 근거는 검색한 실제 문서 구간이다(그림 2-2).



[그림 2-2] HyDE의 가상 문서 기반 검색 구조[2]

Gao 외는 관련성 레이블 없이 수행하는 검색에서 HyDE가 Contriever보다 높은 성능을 보이고, 한국어를 포함한 비영어 검색에서도 효과가 있다고 보고하였다. 본 연구에서는 한국어 질의를 영어로 번역한 뒤 영어 가상 문서를 생성하였으므로, HyDE를 적용한 결과의 변화에는 번역과 가상 문서 생성의 효과가 함께 포함된다.

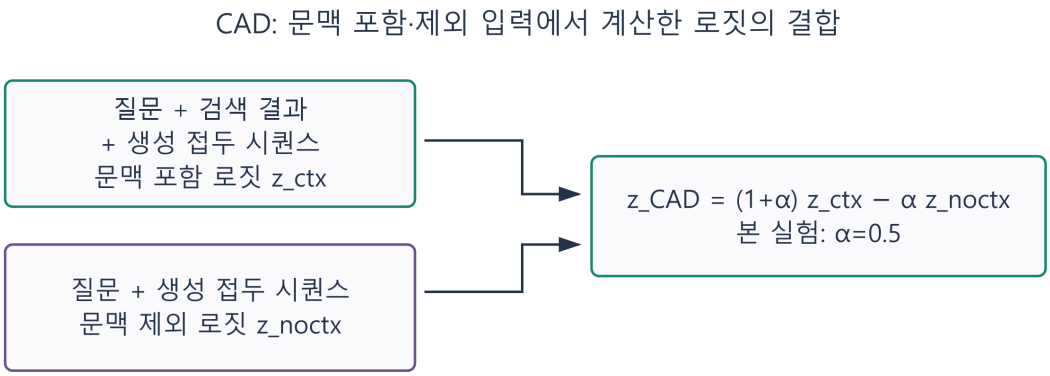
2.4 Context-Aware Decoding

CAD는 검색 결과를 포함했을 때와 제외했을 때의 다음 토큰 로짓을 가중 결합하는 디코딩 방법이다. 검색 결과를 넣었을 때 로짓이 크게 오르는 토큰일수록 검색 결과의 영향을 많이 받는다. CAD는 두 로짓의 차이를 키워, 모델의 사전 지식보다 검색 결과의 내용을 반영하는 토큰이 선택되도록 한다(그림 2-3).

지금까지 생성한 토큰열을 동일하게 두고, 검색 결과를 포함한 입력의 로짓을 z_ctx, 제외한 입력의 로짓을 z_noctx라 하면 CAD의 로짓은 다음과 같다. α는 검색 결과의 영향을 키우는 정도를 정하며, α=0이면 일반 디코딩과 같다.

$$z_{CAD} = (1+\alpha) z_{ctx} - \alpha z_{noctx}$$

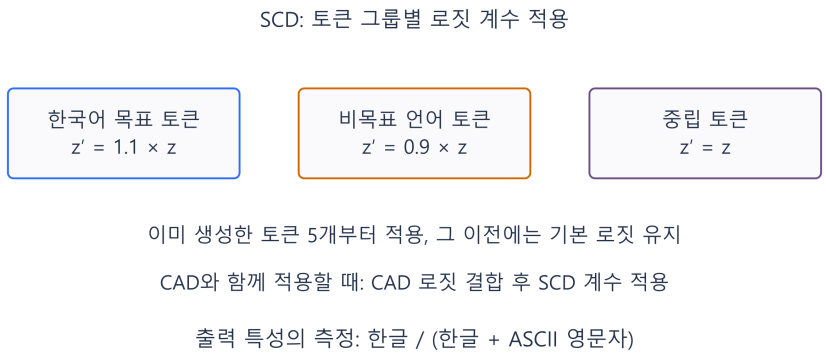
Shi 외는 요약 과제와 지식 충돌 과제(모델의 사전 지식이 입력 문서의 내용과 충돌하는 과제)에서 CAD가 입력 문서를 더 충실히 반영한다고 보고하였다. CAD는 토큰마다 검색 결과를 제외한 입력의 로짓을 한 번 더 계산하므로 생성 시간이 늘어난다.



[그림 2-3] CAD의 문맥 포함·제외 로짓 결합[3]

2.5 Soft Constrained Decoding과 언어 이탈

다국어 RAG에서는 질문과 다른 언어의 문서를 검색하면 답변이 검색 문서의 언어로 바뀌는 언어 이탈이 발생할 수 있다. Li 외는 이 현상을 분석하고, 디코딩 단계에서 목표 언어 토큰의 점수를 조정하는 SCD를 제안하였다. SCD는 어휘 집합을 목표 언어 토큰, 비목표 언어 토큰과 숫자·기호 같은 중립 토큰으로 나누어 로짓을 조정한다(그림 2-4).



[그림 2-4] SCD의 토큰 그룹별 로짓 조정[4]

생성한 토큰 수가 Tstart 이상이 되면 목표 언어 토큰의 로짓 z_i에는 α를, 비목표 언어 토큰의 로짓에는 β를 곱하고, 중립 토큰은 그대로 둔다. 아래 식의 좌변은 조정된 로짓이다. 본 연구는 한국어를 목표 언어로 하여 원 논문의 곱셈식을 그대로 적용하였다. 이 식은 원시 로짓에 계수를 곱하므로, 로짓이 양수인 토큰과 음수인 토큰에서 점수가 변하는 방향이 반대가 된다.

$$\tilde{z}_i = \alpha z_i$$

$$\tilde{z}_i = \beta z_i$$

$$\tilde{z}_i = z_i$$

2.6 RAG 평가

RAGAS(Retrieval Augmented Generation Assessment)는 RAG의 검색과 생성을 나누어 자동으로 평가하는 프레임워크다[10]. RAGAS가 제공하는 근거 충실도(faithfulness), 답변 관련성(answer relevancy), 문맥 정밀도(context precision), 문맥 재현율(context recall) 가운데 근거 충실도와 답변 관련성은 생성 답변을, 문맥 정밀도와 문맥 재현율은 검색 결과를 평가한다. 근거 충실도는 평가 모델로 쓰는 대규모 언어 모델(Large Language Model, LLM)이 답변을 주장 단위로 나누고 각 주장이 검색 결과에 근거하는지 판정하여 계산한다. 지표별 계산 방식은 5.2절에 정리하였다.

2.7 관련 연구와 본 연구의 위치

Dense Passage Retrieval(DPR)[11]은 질의와 문서를 각각 임베딩하는 밀집 검색을, Fusion-in-Decoder(FiD)[12]는 여러 검색 구간을 디코더에서 결합하는 생성을 다룬다. Contrastive Decoding[13]은 두 모델의 출력 분포를 대조하며, CAD는 같은 모델의 문맥 포함·제외 입력을 대조한다.

RAPTOR[14]는 계층적 요약 검색을, Self-RAG[15]와 Adaptive-RAG[16]는 검색 필요성과 질문 복잡도에 따른 검색 전략을 다룬다. Zhao 외[17]와 Fan 외[18]는 구성 요소별 기법을 정리하였고, BEIR[19]와 MTEB[20]은 검색·임베딩 비교 벤치마크다.

본 연구는 검색·생성 백본을 고정한 채 HyDE·CAD·SCD를 조합하고, 한국어 질문 60개의 유형별 점수 변화를 실제 검색·답변에 연결한다. 표 2-1은 선행연구의 접근과 본 연구의 분석 대상을 정리한 것이다.

[표 2-1] 선행연구의 핵심 접근과 본 연구와의 관계

연구	핵심 접근	본 연구와의 관계
HyDE[2]	가상 문서를 임베딩하여 검색	번역과 가상 문서 검색에 따른 답변 관련성 차이
CAD[3]	문맥 포함·제외 로짓의 결합	같은 검색 결과에서 근거 충실도와 실행 시간 차이
SCD[4]	언어별 토큰 로짓의 조정	한국어 문자 비율과 처리 시간의 차이
DPR[11], FiD[12]	밀집 검색과 다중 검색 구간 활용	고정 검색·생성 백본의 구성
Self-RAG[15], Adaptive-RAG[16]	자기평가와 질문 복잡도에 따른 검색 전략 선택	고정 백본에서 검색 입력·디코딩 조합의 효과
RAGAS[10], BEIR[19], MTEB[20]	RAG 자동 평가와 검색·임베딩 벤치마크	고정 문서 집합에서 질의별 대응 비교

3. 시스템 설계

3.1 연구 및 실험 요구사항

모든 조합에서 검색·재정렬·생성 모델, 청크 분할, 후보 수의 상한과 생성 설정을 고정하고, 같은 한국어 질의 60개를 사용하였다. 질의마다 검색 결과, 생성 답변, 실행 시간과 파라미터를 저장하여 조합 간 결과를 질의 ID로 연결하였다.

3.2 아키텍처 설계

Paper-RAG는 검색, 재정렬, 생성의 세 단계로 구성되며, 실행 순서는 4.2절의 그림 4-1에 제시하였다. 검색 단계에서는 BGE-M3 기반 밀집 검색과 BM25 희소 검색을 함께 사용한다. HyDE는 밀집 검색의 입력만 원질의에서 영어 가상 문서로 바꾸고, BM25와 재정렬에는 항상 한국어 원질의를 사용한다.

두 검색 결과를 가중 RRF로 결합하고 CrossEncoder로 재정렬한 뒤, 상위 5개 구간을 생성 모델에 입력한다. 생성 단계에서는 검색 결과 유무에 따른 원래 로짓의 차이를 쓰는 CAD를 먼저 적용하고, SCD는 CAD가 결합한 로짓에 언어별 계수를 곱한다. 두 기법은 생성 단계에만 작용하므로, HyDE 미적용 조합에서 CAD와 SCD의 적용 전후 비교에는 같은 검색 결과가 쓰인다.

3.3 실험 조건과 질문별 대응 비교

HyDE·CAD·SCD의 적용 여부를 조합한 여덟 조건을 사용하였다. 조건 번호는 1 미적용, 2 CAD, 3 HyDE, 4 HyDE+CAD, 5 SCD, 6 CAD+SCD, 7 HyDE+SCD, 8 HyDE+CAD+SCD이다. 모든 조건에 같은 60개 질문을 입력하여 480개 생성 기록을 얻었다. 각 기법의 파라미터와 공통 모델은 4장에 정리하였다.

품질 지표는 영어 검색 근거로 평가한 조건 1~4 안에서, 한국어 번역 근거로 평가한 조건 5~8 안에서 비교한다. 한국어 문자 비율과 실행 시간은 여덟 조건에서 직접 측정한 값을 사용한다. 대응 비교는 질문 ID로 연결하며, 질문 유형은 사실 및 정의, 방법 및 절차, 결과 및 비교, 목적 및 기여의 네 분류를 유지한다.

미적용에서 CAD를 적용한 비교와 SCD에서 CAD+SCD를 적용한 비교는 60개 모두 입력 문서 구간이 같다. HyDE에서 HyDE+CAD를 적용한 비교와 HyDE+SCD에서 세 기법을 적용한 비교는 입력 문서 구간이 같은 질문이 각각 18개와 24개다. 각 조건에서 저장된 가상 문서와 검색 결과가 달라진 질문을 포함하므로, 후자의 차이는 검색 변화가 함께 포함된 조합 간 관측 차이로 해석한다.

4. 프로그램 구현

4.1 시스템 환경

표 4-1은 모든 조합에 공통으로 적용한 검색·재정렬·생성 설정과 기법별 파라미터다. 청크 분할과 입력 길이는 공백 기준 단어 수로, 답변 길이는 생성 모델의 토큰 수로 계산하였다.

[표 4-1] 검색·재정렬·생성 단계의 모델과 공통 실행 설정

구성 단계	사용 모델 또는 방법	주요 설정
밀집 검색	BAAI/bge-m3	후보 8개, 가중치 0.6
희소 검색	BM25	후보 8개, 가중치 0.4
순위 융합	가중 RRF	k=60
재정렬	cross-encoder/ms-marco-MiniLM-L-6-v2	후보 8개, 최종 구간 5개
문서 분할	공백 기준 단어 분할	최대 512단어, 중첩 64단어, 최소 50단어
입력 길이 관리	ContextCompressor	3,072단어 초과 시 압축, 비율 0.5
답변 생성	K-intelligence/Midm-2.0-Base-Instruct	greedy, 최대 새 토큰 512개
HyDE	영어 번역과 가상 문서 생성	temperature=0.1, top_p=0.9, sampling
CAD	문맥 포함·제외 로짓 결합	α=0.5 고정
SCD	reference_scd	α=1.1, β=0.9, Tstart=5

재정렬에는 MS MARCO로 학습한 MiniLM CrossEncoder[M2]를 사용하였고, 한국어 원질의와 영어 후보 구간을 한 쌍으로 입력하였다. 선택한 5개 구간의 단어 수 합이 3,072단어를 넘으면 ContextCompressor를 적용하였다. ContextCompressor는 질의와 겹치는 단어의 비율로 문장 순위를 정하고, 구간마다 단어 수의 50% 안에서 상위 문장을 골라 원래 순서대로 남긴다. 평가 질의와 분리한 튜닝 질의 5개에서 문맥 재현율이 0.95 이상인 후보 설정을 비교하였다. 그중 근거 충실도가 가장 높은 설정을 선택하여 검색 후보와 재정렬 후보의 상한을 각각 8개, 최종 입력 구간을 5개로 모든 조합에 설정하였다. CAD의 α는 Shi 외가 요약 과제에 사용한 0.5로 고정하였고, SCD의 α=1.1, β=0.9, Tstart=5는 Li 외가 제시한 설정을 따랐다.

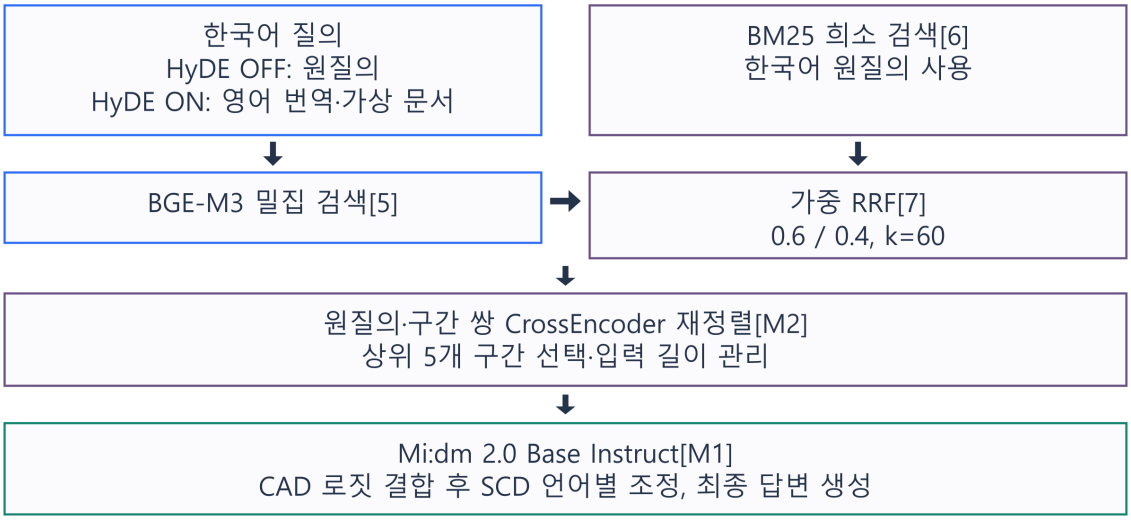
4.2 시스템 구성

Paper-RAG는 질의 하나를 검색 입력 구성, 검색·재정렬, 답변 생성, 실행 기록의 순서로 처리한다(그림 4-1). 먼저 질의에 지정된 대상 문서의 밀집 검색·BM25 인덱스를 불러온다. HyDE를 적용하면 답변 생성에 쓰는 Mi:dm 2.0 Base Instruct로 한국어 질의를 영어로 번역하고, 번역문으로 영어 가상 문서를 생성하여 밀집 검색의 입력으로 쓴다. HyDE 미적용 조건은 한국어 원질의를 그대로 쓴다.

검색 단계에서는 밀집 검색과 원질의를 쓰는 BM25 검색에서 각각 최대 후보 8개를 얻어 가중 RRF로 결합한다. 한국어 원질의로 BM25를 실행한 기록에서는 60개 질문 중 13개가 후

보 0개, 3개가 2개, 44개가 8개였다. CrossEncoder로 후보를 재정렬하여 상위 5개 구간을 고른다. 고른 구간의 단어 수 합이 3,072단어를 넘으면 ContextCompressor로 압축한 뒤 생성 모델에 입력하고, 3,072단어 이내이면 그대로 입력한다.

생성 단계에서는 검색 결과와 질의로 생성 프롬프트를 만들고, 조합에 따라 CAD·SCD 로짓 처리기를 붙여 greedy 디코딩으로 답변을 생성한다. 마지막으로 검색·재정렬 청크 ID, 최종 검색 결과, 답변, 실행 시간과 파라미터를 기록하며, 평가값은 질의 ID와 조건 코드로 이 기록에 연결한다.



[그림 4-1] 한국어 질의의 검색·융합·재정렬 및 답변 생성 흐름

4.3 시스템 구현과 실행 기록

CAD는 토큰을 하나 생성할 때마다 같은 지시문에서 검색 결과만 뺀 입력의 로짓을 추가로 계산하고, 두 로짓을 2.4절의 식으로 결합한다. SCD는 생성한 토큰이 5개 이상이 되면 한국어 토큰과 비한국어 토큰의 로짓에 각각 α와 β를 곱한다.

각 실행에서는 미적용, CAD, SCD, CAD+SCD, HyDE, HyDE+CAD, HyDE+SCD, HyDE+CAD+SCD의 순서로 한 조건의 질문을 모두 처리한 뒤 다음 조건으로 넘어갔다. 모델 초기화 직후의 첫 질문 두 건은 미적용 조건에서 각각 164.2초와 117.3초로 기록되었다(5.7절).

조합별 실행 시간은 모델과 검색 구성요소의 초기화가 끝난 뒤, 각 질의·조합의 처리 시작부터 답변 생성과 기록용 메타데이터 구성이 끝날 때까지 측정하였다. HyDE를 적용한 조합에는 번역과 가상 문서 생성 시간이 포함되며, 평가 API 호출과 파일 기록은 측정이 끝난 뒤에 수행하였다.

5. 실험

5.1 질문 구성과 분석 대상

실험은 네 영어 문서에 관한 한국어 질문 60개를 대상으로 하였다. RAG Survey, CAD, RAPTOR, Mi:dm K 2.5 Pro Technical Report에서 문서마다 15개 질문을 구성하고, 각 질문에 여덟 조건을 적용하여 480개 답변을 생성하였다. 질문별 검색 범위는 지정된 한 문서다.

문서별 초기 질문 3개와 주요 내용 15개 단위의 요약을 바탕으로 질문을 작성하고, 연구자가 원문에서 답변 가능성과 정답 근거의 페이지를 확인하였다. 초기 질문은 문서별 15개에 포함된다. 문서 기반 질문의 작성과 근거 확인에는 QASPER[21]와 질문 생성 연구[22]의 절차를 참고하였다. 부록 A에 질문 원문과 정답 근거를 제시하였다.

질문은 사실·정의 8개, 방법·절차 29개, 결과·비교 20개, 목적·기여 3개다. 사실·정의는 개념이나 조건의 의미를, 방법·절차는 구조와 처리 방법을, 결과·비교는 성능 수치와 차이를, 목적·기여는 연구의 목적과 이점을 묻는다. 예를 들어 최적 클러스터 수의 결정 방법은 방법·절차에, 서로 다른 검색 계층의 성능 수치는 결과·비교에 속한다. 목적·기여의 평균은 세 질문의 값으로 계산하였다.

분류는 질문의 내용과 정답 근거를 전수 대조하여 확인하였다. 답 형태는 서술형 42개와 수치형 18개이며, 한 질문에서 요구한 항목 수도 함께 기록하였다. 질문의 유형, 답 형태, 요구 항목은 서로 다른 특성이다. 모델의 명칭을 묻는 방법 질문과 정성적인 차이를 묻는 결과 질문도 포함된다. 유형별 비교에는 이 구성을 그대로 사용하였다.

5.2 평가 지표와 평가 입력

평가는 답변의 내용, 검색된 근거, 출력 언어와 처리 시간을 대상으로 한다. RAGAS 0.2.15의 근거 충실도·답변 관련성·문맥 정밀도·문맥 재현율은 GPT-4o 평가 모델과 BGE-M3 임베딩으로 계산하였다. 참조 답변은 부록 A의 영어 정답 근거다.

근거 충실도는 생성 답변의 주장 가운데 입력 문서 구간이 뒷받침하는 비율이다. 답변 관련성은 생성 답변에서 역으로 만든 질문과 원질문의 임베딩 코사인 유사도를 바탕으로 계산한다. RAGAS는 답변을 모호하거나 회피적인 응답으로 판정하면 관련성을 0으로 계산한다. 480개 답변 중 54개가 0으로 기록되었다. 관련성 비교표의 평균과 개선·악화 수는 두 조건 모두 0이 아닌 질문으로 계산하고 0점 응답의 변화는 5.6절에서 실제 답변과 함께 따로 살펴본다.

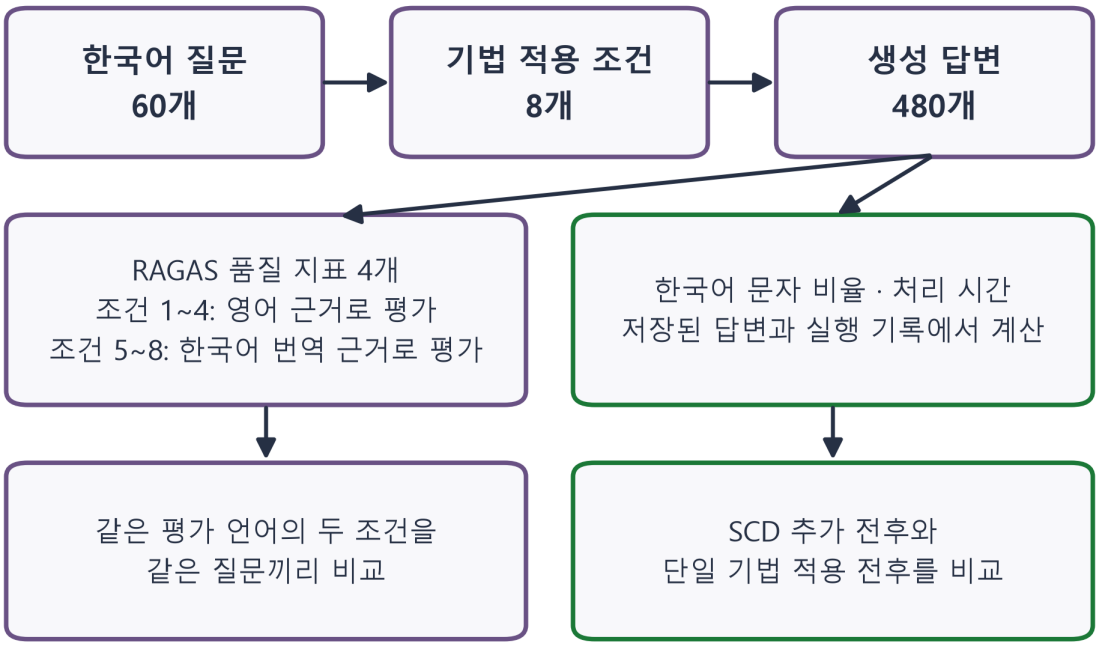
문맥 정밀도는 참조 답변에 유용한 검색 구간이 상위에 배치되는 정도이며, 문맥 재현율은 참조 답변의 주장을 검색 결과가 뒷받침하는 비율이다. 충실도·정밀도·재현율은 0~1이고, 관련성의 이론적 범위는 −1~1이다. 이번 관련성 관측값은 모두 0~1이었다. 네 지표는 높을수록 각각의 평가 기준에서 높은 점수다.

한국어 문자 비율은 생성 답변의 한글 문자 수를 한글 문자 수와 ASCII 영문자 수의 합으로 나눈 값이다.

$$KoreanRatio = \frac{N_{Hangul}}{N_{Hangul} + N_{ASCII}}$$

N_Hangul은 한글 문자 수이고 N_ASCII는 ASCII 영문자 수다. 모델명과 논문명에 쓰인 영문자도 집계한다. 숫자만 반복한 출력 한 건은 원래 측정 기록에 비율 0으로 저장되어 있다. 비율 차이 0.20은 20%p다. 실행 시간은 질문 처리의 시작부터 답변 생성과 메타데이터 구성까지의 초 단위 기록이며, 짧을수록 처리 비용이 작다.

품질 평가에 제공한 근거의 언어는 SCD 상태에 따라 달랐다. SCD를 적용하지 않은 조건 1~4는 영어 검색 결과로 평가했고, SCD를 적용한 조건 5~8은 같은 실행에서 저장한 검색 결과를 한국어로 번역하여 평가하였다. 답변 생성 단계의 근거와 두 평가 묶음의 참조 답변은 모두 영어였다. 품질 표는 각각 같은 평가 언어의 기준 조건과 적용 조건을 대응시킨 결과다.



[그림 5-1] 질문별 생성 기록과 평가값을 연결하는 비교 절차

그림 5-2는 RAPTOR에서 BIC가 결정하는 항목을 묻는 질문에 입력 구간·참조 답변·생성 답변과 평가값을 연결한 예다. 충실도는 생성 답변의 주장을, 재현율은 참조 답변의 주장을 검색 결과와 대조한다.

질문	RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?
참조 답변	to determine the optimal number of clusters (원문 4쪽)
입력 구간	To determine the optimal number of clusters, we employ the Bayesian Information Criterion (BIC) for model selection.
생성 답변	제공된 논문 컨텍스트를 분석한 결과, RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 최적의 클러스터 개수 결정을 위해 사용됨이 확인됩니다.
평가값	근거 충실도 0.857 · 답변 관련성 0.895 / 문맥 정밀도 0.700 · 문맥 재현율 1.000

[그림 5-2] RAPTOR의 BIC 질문에 제공한 입력 구간·답변과 평가값

5.3 질문별 대응 비교 방법

분석은 같은 질문에서 적용 조건의 점수로부터 기준 조건의 점수를 빼는 방식으로 수행하였다. 유형별로 같은 유효 질문의 기준 평균과 적용 평균, 평균 변화량을 계산하였다. 점수 차이가 0.05보다 크면 개선, −0.05보다 작으면 악화, 두 경계를 포함한 사이는 비슷함으로 집계하였다. 시간 변화는 1초를 경계로 증가·감소·비슷함을 구분하였다.

영어 근거 평가에서는 미적용에 HyDE 또는 CAD를 적용한 비교와, HyDE 또는 CAD에 나머지 기법을 추가한 비교를 수행하였다. 한국어 번역 근거 평가에서는 SCD에 HyDE 또는 CAD를 더한 비교와, HyDE+SCD 또는 CAD+SCD에 나머지 기법을 추가한 비교를 수행하였다. 한국어 문자 비율은 네 HyDE·CAD 설정에서 SCD 추가 전후를 대응시켰다.

근거 충실도 480개 가운데 결측은 5개였다. CAD의 두 질문과 SCD의 세 질문에서 발생하였으며, 해당 대응 비교의 두 평균을 계산할 때 같은 질문을 함께 제외하였다. 질문 유형과 비교 조건에 따라 표의 유효 질문 수가 달라지는 이유다. 나머지 지표의 480개 값은 모두 저장되어 있었다.

유형 평균의 변화를 확인한 뒤 큰 변화에 속한 질문, 같은 유형의 반대 사례와 문서별 구성을 조사하였다. 실제 사례는 이 분석에서 발견한 근거 확보, 답변 형식의 변화, 수치 누락과 자동 점수의 불일치를 설명하도록 선정하였다. 사례마다 원문 정답 근거, 실제 입력 구간과 생성 답변을 대조하였다.

5.4 질문 유형별 단일 기법의 결과

HyDE는 두 평가 언어 모두에서 답변 관련성을 높인 질문이 낮춘 질문보다 많았다. 관련성 0점을 제외한 영어 근거 평가 51개에서 평균은 0.772에서 0.816으로 올랐고 개선 16개, 악화

5개였다. 한국어 번역 근거 평가 47개에서는 0.754에서 0.789로 올랐고 개선 13개, 악화 9개였다. 표 5-1은 두 평가 언어의 결과를 유형별로 보여준다.

[표 5-1] HyDE 적용 전후의 유형별 답변 관련성

질문 유형	질문 수	적용 전 평균	적용 후 평균	평균 변화량	개선/악화/비슷
기법 미적용 상태에서 HyDE만 적용했을 때의 답변 관련성 영어 근거로 평가하였다. 관련성 0점이 있는 질문 9개를 제외하였다.					
사실·정의	8	0.776	0.821	+0.045	4/1/3
방법·절차	22	0.726	0.795	+0.069	8/2/12
결과·비교	18	0.820	**0.844**	+0.024	4/1/13
목적·기여	3	0.817	0.788	−0.029	0/1/2
전체 60개	51	0.772	0.816	+0.044	16/5/30
SCD에 HyDE를 추가했을 때의 답변 관련성 한국어로 번역한 근거로 평가하였다. 관련성 0점이 있는 질문 13개를 제외하였다.					
사실·정의	7	0.806	0.780	−0.025	0/2/5
방법·절차	20	0.722	0.767	+0.045	6/5/9
결과·비교	18	0.752	0.807	+0.055	7/1/10
목적·기여	2	0.918	**0.892**	−0.026	0/1/1
전체 60개	47	0.754	0.789	+0.035	13/9/25

주: 같은 유효 질문의 적용 전후 평균이며, 변화량은 적용 후 평균에서 적용 전 평균을 뺀 값이다. 굵은 값은 같은 비교의 네 유형 중 적용 평균 최댓값(동률 모두)이다. 차이 >0.05 개선, <−0.05 악화, 나머지 비슷함. 두 조건 중 하나라도 답변 관련성이 0점으로 기록된 질문은 평균과 개수에서 제외하였다.

유형별로는 영어 근거 평가에서 방법·절차의 상승이 +0.069(22개, 개선 8개, 악화 2개)로 가장 컸다. 한국어 번역 근거 평가에서는 결과·비교가 +0.055, 방법·절차가 +0.045였다. 방법·절차의 영어 평가 상승은 RAG Survey(+0.139)와 RAPTOR(+0.100) 질문에서 나왔고 CAD(−0.037)와 Mi:dm(−0.022) 질문에서는 작게 낮아졌다.

결과·비교 질문의 영어 평가 변화는 +0.024였고 18개 중 13개가 비슷함 범위였다. 결과·비교 20개 중 12개는 수치를 묻는 질문이며, 이 질문들에서는 정답 수치가 담긴 구간이 입력되는지에 따라 답변이 달라졌다(5.6절). 사실·정의의 영어 평가 변화는 +0.045, 목적·기여는 −0.029였다.

CAD는 입력 구간을 바꾸지 않고 생성 단계만 조정한다. 전체 60개에서 미적용에 CAD를 추가한 근거 충실도 차이는 유효 58개 기준 +0.029였고 개선 16개, 악화 19개였다. 같은 비교의 답변 관련성 차이는 0점을 제외한 48개에서 −0.021이었고 개선 8개, 악화 14개였다. 유형별로는 방법·절차의 충실도가 유효 27개에서 +0.082로 가장 크게 올랐다. SCD에 CAD를 추가한 한국어 번역 근거 평가에서는 방법·절차가 +0.028이고 개선과 악화가 각각 11개였다.

[표 5-2] CAD 적용 전후의 유형별 근거 충실도

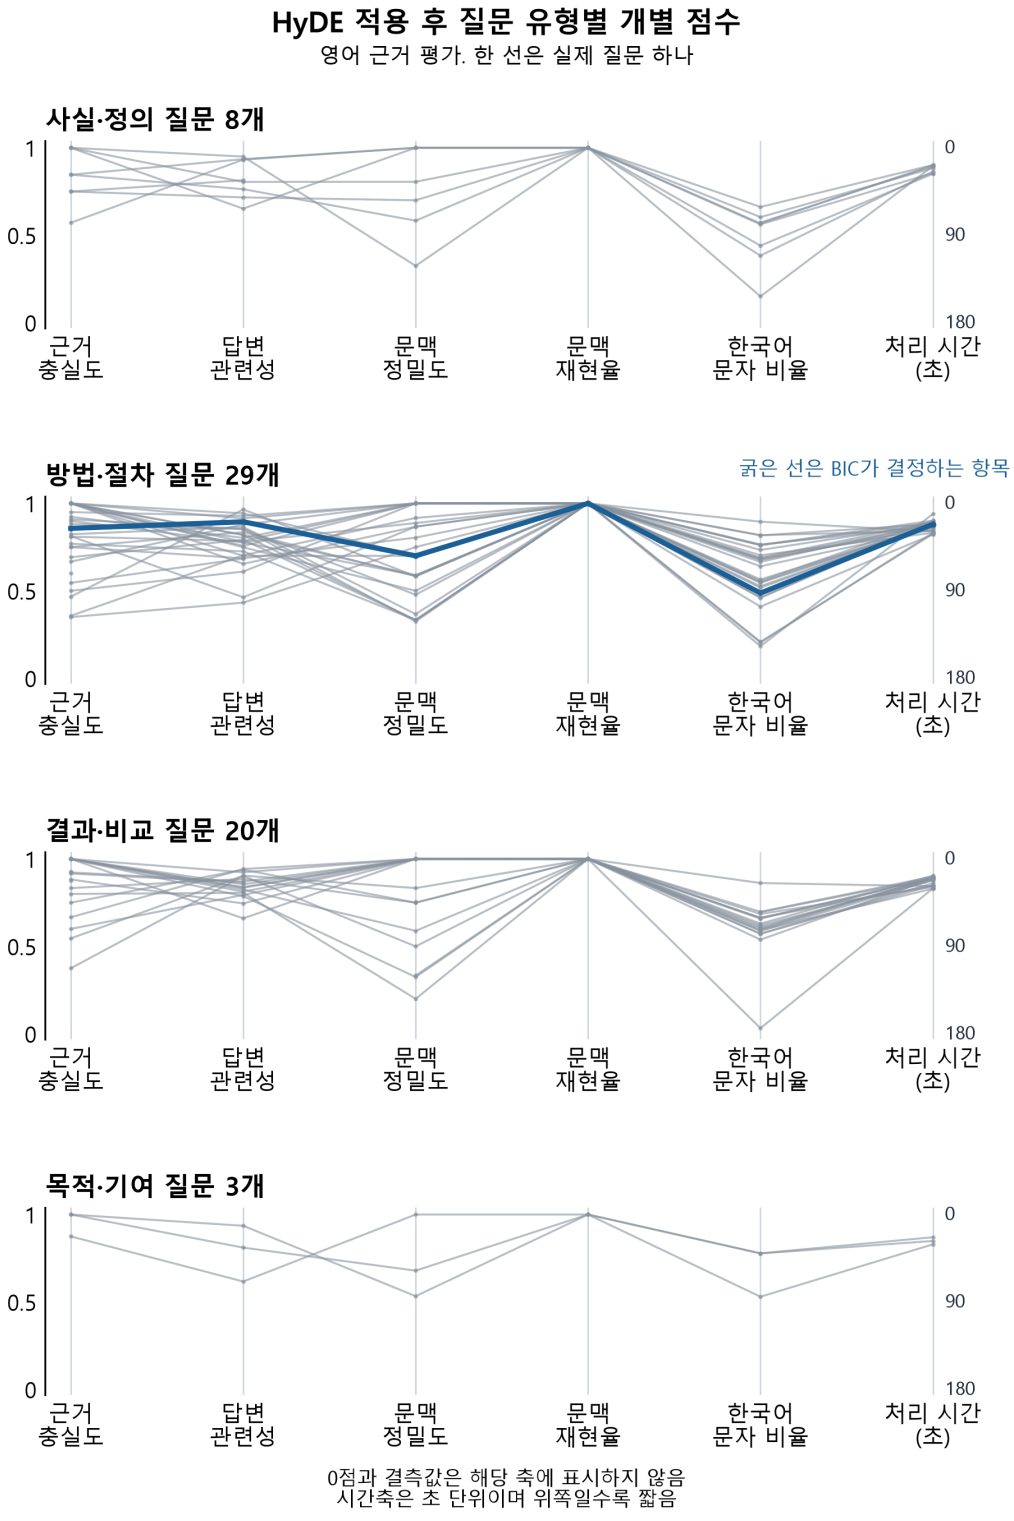
질문 유형	질문 수	적용 전 평균	적용 후 평균	평균 변화량	개선/악화/비슷
기법 미적용 상태에서 CAD만 적용했을 때의 근거 충실도 영어 근거로 평가하였다.					
사실·정의	8	0.749	0.749	+0.000	2/4/2
방법·절차	27	0.761	0.843	+0.082	10/7/10
결과·비교	20	0.906	**0.902**	−0.004	4/7/9
목적·기여	3	0.771	0.611	−0.160	0/1/2
전체 60개	58	0.810	0.839	+0.029	16/19/23
SCD에 CAD를 추가했을 때의 근거 충실도 한국어로 번역한 근거로 평가하였다.					
사실·정의	8	0.748	0.806	+0.057	5/2/1
방법·절차	26	0.731	0.759	+0.028	11/11/4
결과·비교	20	0.897	**0.851**	−0.046	5/7/8
목적·기여	3	0.643	0.556	−0.087	2/1/0
전체 60개	57	0.787	0.787	+0.000	23/21/13

주: 같은 유효 질문의 적용 전후 평균이며, 변화량은 적용 후 평균에서 적용 전 평균을 뺀 값이다. 굵은 값은 같은 비교의 네 유형 중 적용 평균 최댓값(동률 모두)이다. 차이 >0.05 개선, <−0.05 악화, 나머지 비슷함.

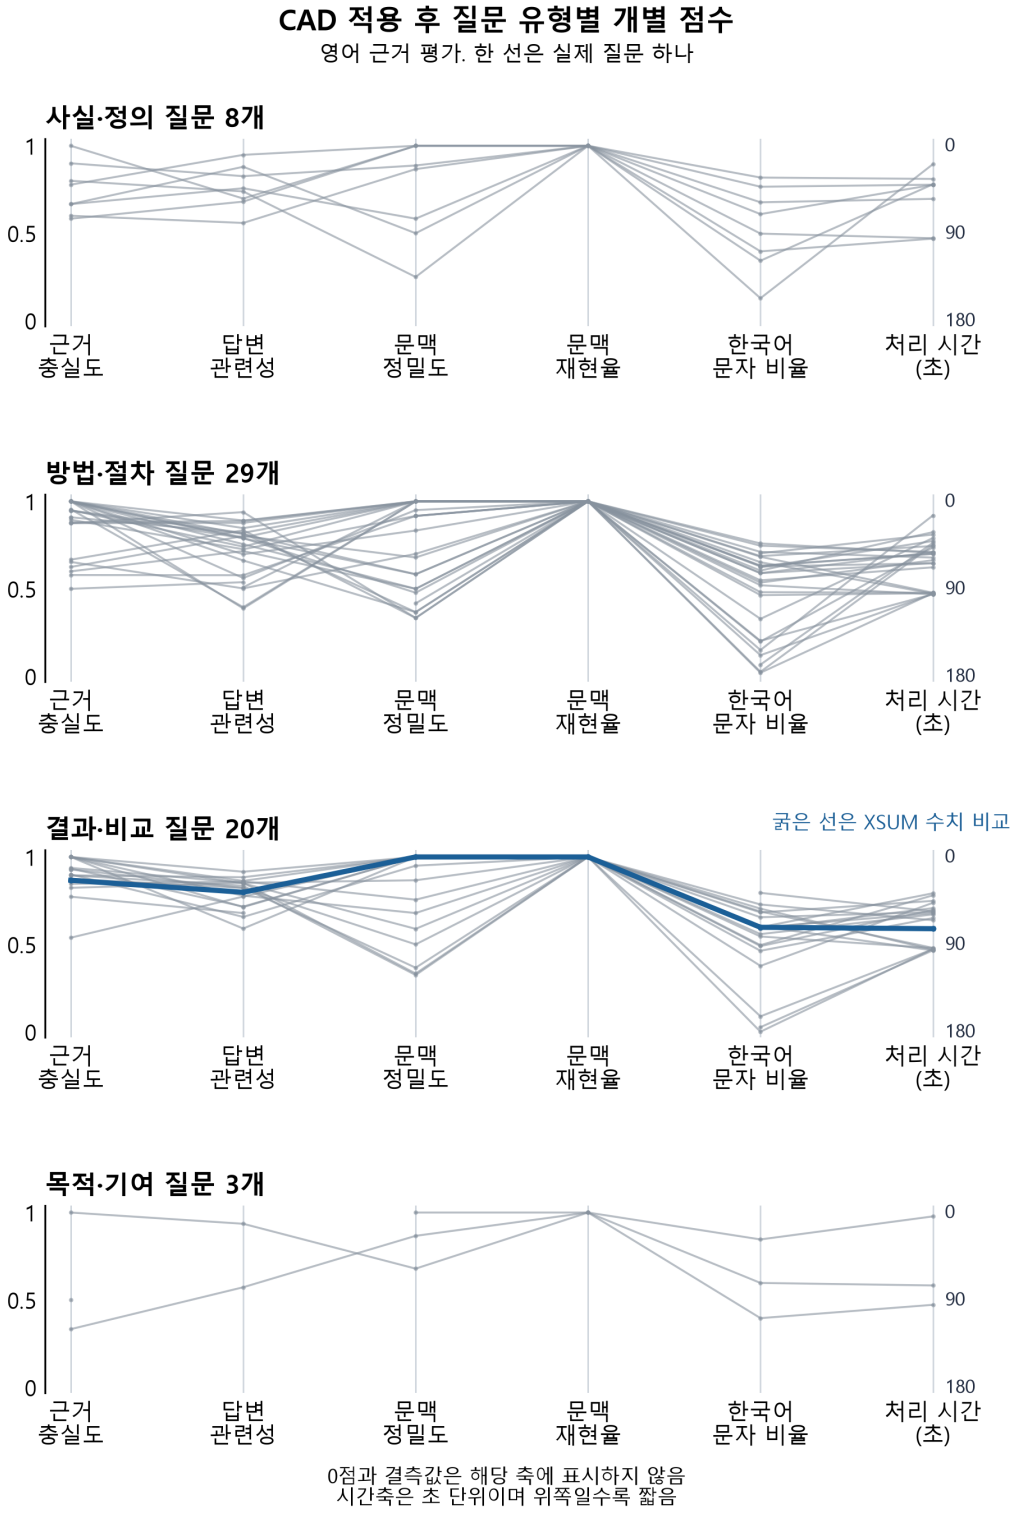
목적·기여 세 질문에서 CAD의 충실도 평균 차이는 −0.160이었다. RAG가 지식 집약 과제에 주는 이점을 묻는 질문의 충실도가 0.938에서 0.500으로 낮아진 결과가 이 평균에 포함된다. 같은 입력 구간에서 출력이 짧은 지시문으로 바뀐 이 사례는 5.6절에서 설명한다.

질문별 점수의 형태는 질문 유형을 나눈 평행좌표로 확인하였다. 한 선은 실제 질문 하나이며 사실·정의 8개, 방법·절차 29개, 결과·비교 20개, 목적·기여 3개를 각각의 패널에 표시하였다. 다섯 점수 지표는 0~1 축을 사용하고, 처리 시간은 실제 초 단위의 별도 축을 사용하였다. 시간축의 위쪽은 0초, 아래쪽은 180초이므로 위쪽일수록 짧은 시간이다. 모든 지표의 0점과 결측값은 해당 축에 표시하지 않고 선을 끊었다. 세 기법의 그래프는 같은 축 범위를 사용하였다.

그림 5-3은 HyDE 적용 후, 그림 5-4는 CAD 적용 후의 개별 점수다. 같은 유형 안에서 충실도·관련성·검색 지표·출력 언어와 시간의 높낮이가 다른 질문을 확인하였다. 굵은 선은 전체 분석 뒤 실제 답변을 대조한 사례이며, BIC가 결정하는 항목과 XSUM의 수치 비교 질문을 각각 표시하였다. 기법 적용 전후의 수치 변화와 질문 수는 표 5-1~5-4에 제시하였다.



[그림 5-3] HyDE 적용 후 질문 유형별 개별 점수



[그림 5-4] CAD 적용 후 질문 유형별 개별 점수

5.5 복수 기법 조합과 검색 결과의 변화

조합의 결과는 추가한 기법에 따라 달랐다. HyDE에 CAD를 추가하면 관련성 0점을 제외한 53개 질문의 평균이 0.803에서 0.776으로 낮아졌고 개선 5개, 악화 18개였다. HyDE와 SCD에 CAD를 추가한 비교도 개선 5개, 악화 14개였다. CAD 또는 CAD와 SCD에 HyDE를 추가했을 때는 개선이 악화보다 많았다(각각 9개와 8개, 12개와 8개).

[표 5-3] 복수 기법 조합의 유형별 답변 관련성

질문 유형	질문 수	적용 전 평균	적용 후 평균	평균 변화량	개선/악화/비슷
HyDE에 CAD를 추가했을 때의 답변 관련성 영어 근거로 평가하였다. 관련성 0점이 있는 질문 7개를 제외하였다.					
사실·정의	8	0.821	0.832	+0.011	2/1/5
방법·절차	25	0.763	0.728	−0.035	2/10/13
결과·비교	18	0.844	0.808	−0.036	1/7/10
목적·기여	2	0.873	**0.880**	+0.006	0/0/2
전체 60개	53	0.803	0.776	−0.027	5/18/30
CAD에 HyDE를 추가했을 때의 답변 관련성 영어 근거로 평가하였다. 관련성 0점이 있는 질문 11개를 제외하였다.					
사실·정의	8	0.761	0.832	+0.071	3/0/5
방법·절차	23	0.719	0.714	−0.004	5/7/11
결과·비교	17	0.797	0.799	+0.002	1/1/15
목적·기여	1	0.936	**0.936**	+0.000	0/0/1
전체 60개	49	0.757	0.767	+0.010	9/8/32
HyDE와 SCD에 CAD를 추가했을 때의 답변 관련성 한국어로 번역한 근거로 평가하였다. 관련성 0점이 있는 질문 10개를 제외하였다.					
사실·정의	8	0.791	0.781	−0.010	1/1/6
방법·절차	23	0.770	0.737	−0.032	3/8/12
결과·비교	17	0.834	0.804	−0.030	1/5/11
목적·기여	2	0.892	**0.873**	−0.019	0/0/2
전체 60개	50	0.800	0.773	−0.027	5/14/31
CAD와 SCD에 HyDE를 추가했을 때의 답변 관련성 한국어로 번역한 근거로 평가하였다. 관련성 0점이 있는 질문 17개를 제외하였다.					
사실·정의	7	0.787	0.787	+0.000	2/1/4
방법·절차	19	0.707	0.723	+0.016	4/4/11
결과·비교	16	0.786	0.804	+0.018	6/3/7
목적·기여	1	0.936	**0.936**	+0.000	0/0/1
전체 60개	43	0.755	0.768	+0.014	12/8/23

주: 같은 유효 질문의 적용 전후 평균이며, 변화량은 적용 후 평균에서 적용 전 평균을 뺀 값이다. 굵은 값은 같은 비교의 네 유형 중 적용 평균 최댓값(동률 모두)이다. 차이 >0.05 개선, <−0.05 악화, 나머지 비슷함. 두 조건 중 하나라도 답변 관련성이 0점으로 기록된 질문은 평균과 개수에서 제외하였다.

HyDE가 포함된 조건에서는 가상 문서를 조건마다 다시 생성하였다. HyDE와 HyDE+CAD의 가상 문서가 같은 질문은 60개 중 한 개였고, 최종 입력 구간이 같은 질문은 18개였다. HyDE+SCD와 세 기법 조합에서는 가상 문서가 모두 달랐으며 입력 구간은 24개에서 같았다. 이 조합 비교에는 생성 제어의 차이와 실제 검색 결과의 차이가 함께 포함된다.

반면 미적용에서 CAD를 적용한 비교와 SCD에서 CAD+SCD를 적용한 비교는 각각 60개 모두 입력 구간이 같았다. CAD 단독 비교의 문맥 정밀도는 일곱 질문, 문맥 재현율은 한 질문에서 평가값 차이가 0.05를 넘었다. 같은 입력 구간을 평가한 기록에도 이러한 차이가 저장되어 있었다.

검색 지표는 답변 관련성과 다른 방향으로 움직였다. 영어 근거 평가에서 문맥 정밀도의 전체 평균은 미적용 0.749가 HyDE 0.714보다 높았고, 문맥 재현율은 두 조건 모두 0.933이었다. 방법·절차 질문에서는 HyDE 적용 후 관련성이 +0.069, 재현율이 +0.069 바뀌었고 정밀도는 −0.003이었다. 사실·정의 질문은 관련성 +0.045와 정밀도 −0.133이 함께 관측되었다. 표 5-4는 두 검색 지표를 유형별로 정리한 것이다.

[표 5-4] HyDE 적용 전후의 유형별 검색 지표

질문 유형	질문 수	정밀도 적용 전	정밀도 적용 후	재현율 적용 전	재현율 적용 후
기법 미적용 상태에서 HyDE만 적용했을 때의 검색 지표 영어 근거로 평가하였다.					
사실·정의	8	0.810	0.677	1.000	0.875
방법·절차	29	0.700	0.697	0.897	0.966
결과·비교	20	0.781	**0.752**	0.950	0.900
목적·기여	3	0.849	0.737	1.000	**1.000**
전체 60개	60	0.749	0.714	0.933	0.933
SCD에 HyDE를 추가했을 때의 검색 지표 한국어로 번역한 근거로 평가하였다.					
사실·정의	8	0.910	**0.885**	1.000	**1.000**
방법·절차	29	0.702	0.673	0.862	0.862
결과·비교	20	0.780	0.789	0.900	0.900
목적·기여	3	0.856	0.721	1.000	**1.000**
전체 60개	60	0.763	0.743	0.900	0.900

주: 정밀도는 문맥 정밀도, 재현율은 문맥 재현율의 평균이다. 굵은 값은 같은 비교·지표의 네 유형 중 적용 평균 최댓값(동률 모두)이다.

5.6 질문이 요구한 정보와 실제 답변

표의 평균에서 제외한 관련성 0점 응답은 실제 답변으로 확인하였다. 미적용에서 관련성이 0이던 방법·절차 질문 6개는 HyDE 적용 후 모두 양수가 되었고, 이 중 4개는 질문이 요구한 정보를 제시하였다. 2개는 필요한 근거를 새로 검색한 경우였고 2개는 같은 근거를 질문에 맞게 설명한 경우였다. RAPTOR에서 BIC가 결정하는 항목을 묻는 질문은 HyDE 적용 후 최적 클러스터 수를 정한다는 구간을 입력받았고, 답변에도 그 내용을 제시하였다. 관련성은 0.000

에서 0.895로, 재현율은 0.000에서 1.000으로 바뀌었다. NQ-Swap의 생성 절차를 묻는 질문은 두 조건 모두 정답 구간을 입력받았다. 미적용의 출력은 절별 설명을 요청하는 문장들이었고, HyDE의 출력은 개체 정답 질문 선택·근거 문서 탐색·정답 개체 치환의 세 단계였다.

관련성이 양수로 바뀐 질문 중에는 다른 주제의 원문을 이어 쓴 답변도 있었다. Fusion SFT에서 non-reasoning 데이터의 비중을 늘린 목적을 묻는 질문의 HyDE 답변은 사전학습 단계의 데이터 구성을 영어로 설명하였다. 요구된 정보는 대화 정렬이라는 목적과 창작·번역·일반 질의응답의 보강이었고, 기록된 관련성은 0.000에서 0.463으로 바뀌었다. 나머지 1개도 영어 원문을 이어 쓴 답변이었다. 관련성이 양수가 된 것과 요구 정보의 제시가 일치하지 않은 경우다.

수치 비교 질문에서는 필요한 표의 값과 답변이 옮긴 행을 확인하였다. QuALITY의 한 계층과 세 계층 성능을 묻는 질문은 미적용의 입력 구간과 답변에 57.9와 73.68이 모두 있었다. HyDE 적용 후 73.68을 담은 구간이 빠졌고 답변은 일반적인 전체 트리 검색의 장점 설명으로 바뀌었다. 관련성은 0.871에서 0.000으로, 재현율은 1.000에서 0.000으로 낮아졌다.

LLaMA-30B의 XSUM 결과를 묻는 질문은 같은 입력 구간에서도 표의 다른 행을 답하였다. 정답은 ROUGE-L 18.7·22.0, factKB 47.7·66.4, BERT-P 87.1·90.3이었다. 미적용과 CAD 답변은 다른 행의 ROUGE-L 25.8·31.8과 factKB 87.8을 XSUM 값으로 제시하였다. CAD 적용 후 근거 충실도는 0.526에서 0.867로 바뀌었다. 높은 충실도와 잘못 옮긴 표의 행이 함께 기록된 경우다.

CAD가 다른 내용의 답변을 생성한 사례도 있었다. RAPTOR의 청크 길이와 문장 경계 처리를 묻는 질문에서 미적용은 설명을 요청하는 문장을 반복했고 CAD는 트리 구축 비용의 선형 증가를 설명하였다. 질문의 정답 근거는 100토큰 청크와 다음 청크로 문장을 옮기는 규칙이었다. 기록된 충실도는 0.250에서 1.000으로, 관련성은 0.000에서 0.755로 바뀌었다. RAG의 지식 집약 과제 이점을 묻는 질문에서는 미적용의 지식 갱신 설명이 CAD 적용 후 '위 내용 참조'라는 짧은 지시문으로 바뀌었다. 관련성은 0.900에서 0.000으로, 시간은 22.6초에서 4.0초로 바뀌었다.

복수 기법 비교에서는 입력 구간의 변화와 출력 주제의 이동을 함께 확인하였다. Naive RAG의 과정을 묻는 질문은 HyDE와 HyDE+CAD 모두 색인·검색·생성의 세 단계를 담은 구간을 입력받았다. 가상 문서를 다시 생성한 뒤 최종 다섯 구간 중 하나가 바뀌었고, HyDE+CAD 답변은 Modular RAG의 새 모듈을 묻는 질문을 스스로 만든 뒤 그 내용을 설명하였다. 관련성은 0.929에서 0.000으로 낮아졌다. 부록 B에는 이 절에서 설명한 질문의 정답 근거와 필요한 답변 발췌를 정리하였다.

5.7 한국어 출력과 처리 시간

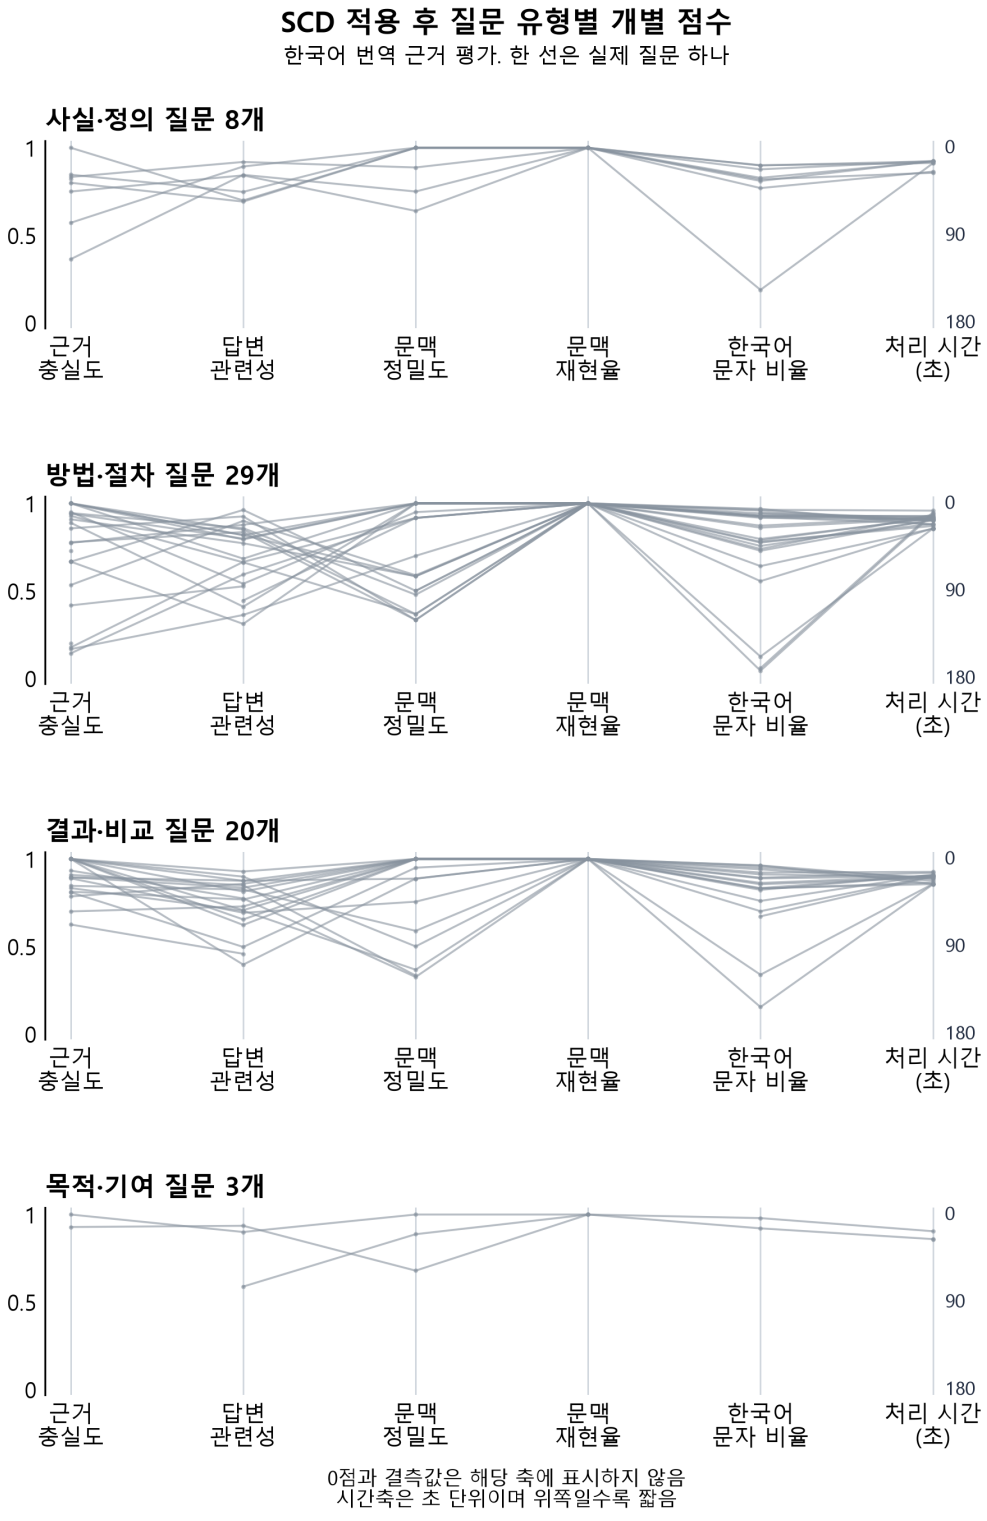
SCD 추가 후 네 HyDE·CAD 설정에서 한국어 문자 비율의 유형별 평균이 모두 높아졌다. 미적용에 SCD를 추가한 변화는 사실·정의 +0.278, 방법·절차 +0.156, 결과·비교 +0.254, 목적·기여 +0.147이었다. HyDE에 SCD를 추가하면 방법·절차 29개 중 26개와 결과·비교 20개 중 19개가 0.05를 넘게 증가하였다.

[표 5-5] SCD 적용 전후의 유형별 한국어 문자 비율

질문 유형	질문 수	적용 전 평균	적용 후 평균	평균 변화량	개선/악화/비슷
기법 미적용 상태에서 SCD만 적용했을 때의 한국어 문자 비율					
사실·정의	8	0.484	**0.761**	+0.278	8/0/0
방법·절차	29	0.494	0.650	+0.156	22/2/5
결과·비교	20	0.501	0.755	+0.254	18/0/2
목적·기여	3	0.487	0.634	+0.147	2/1/0
전체 60개	60	0.494	0.699	+0.205	50/3/7
HyDE에 SCD를 추가했을 때의 한국어 문자 비율					
사실·정의	8	0.493	0.828	+0.336	8/0/0
방법·절차	29	0.568	0.783	+0.215	26/1/2
결과·비교	20	0.544	0.829	+0.285	19/0/1
목적·기여	3	0.695	**0.840**	+0.145	3/0/0
전체 60개	60	0.556	0.807	+0.251	56/1/3
CAD에 SCD를 추가했을 때의 한국어 문자 비율					
사실·정의	8	0.530	0.753	+0.224	7/0/1
방법·절차	29	0.445	0.684	+0.239	27/1/1
결과·비교	20	0.514	0.748	+0.234	17/0/3
목적·기여	3	0.613	**0.781**	+0.168	2/0/1
전체 60개	60	0.488	0.719	+0.232	53/1/6
HyDE와 CAD에 SCD를 추가했을 때의 한국어 문자 비율					
사실·정의	8	0.527	0.701	+0.174	6/1/1
방법·절차	29	0.474	0.706	+0.231	26/1/2
결과·비교	20	0.540	**0.788**	+0.249	20/0/0
목적·기여	3	0.475	0.679	+0.204	2/1/0
전체 60개	60	0.503	0.731	+0.228	54/3/3

주: 같은 유효 질문의 적용 전후 평균이며, 변화량은 적용 후 평균에서 적용 전 평균을 뺀 값이다. 굵은 값은 같은 비교의 네 유형 중 적용 평균 최댓값(동률 모두)이다. 차이 >0.05 개선, <−0.05 악화, 나머지 비슷함.

그림 5-5는 SCD 적용 후의 질문 유형별 점수 분포다. 품질 지표는 한국어로 번역한 근거를 사용한 평가값이며, 한국어 문자 비율과 시간은 같은 답변의 원래 측정값이다. 네 유형의 평균과 질문별 높낮이는 표 5-5와 함께 확인하였다.



[그림 5-5] SCD 적용 후 질문 유형별 개별 점수

SCD 적용 후에도 비율이 오르지 않은 질문은 답변이 영어 원문을 이어 쓴 경우였다. 큰 청크와 작은 청크의 장단점을 묻는 질문에서 미적용 답변은 참고문헌 목록 뒤에 RAG의 세 구

성요소를 한국어로 설명했고, SCD 답변은 영어 참고문헌만 이어 썼다. 한국어 문자 비율은 0.425에서 0.000으로 낮아졌고, 두 답변 모두 질문한 장단점 대신 다른 내용을 담았다.

처리 시간은 CAD에서 가장 크게 늘었다. 미적용에 CAD를 적용하면 전체 평균이 20.8초에서 63.9초로 늘었고 60개 중 56개 질문에서 1초 넘게 증가하였다. HyDE는 +2.6초, SCD는 −1.9초였다. 표 5-6은 단일 기법별 실측 시간을 유형별로 제시한다. 미적용의 기준 시간에는 모델 초기화 직후의 두 기록이 포함되어 있다. RAG가 부정확한 생성을 줄이는 방식을 묻는 질문은 164.2초, Advanced RAG의 검색 전 최적화 대상을 묻는 질문은 117.3초로 기록되었고, 목적·기여의 음수 시간 차이는 앞의 기록에서 비롯되었다.

[표 5-6] 단일 기법 적용 전후의 유형별 처리 시간

질문 유형	질문 수	적용 전 시간	적용 후 시간	평균 변화량	증가/감소/비슷
기법 미적용 상태에서 CAD만 적용했을 때의 처리 시간					
사실·정의	8	15.0초	52.3초	+37.2초	7/1/0
방법·절차	29	20.1초	64.4초	+44.3초	28/1/0
결과·비교	20	17.2초	**68.6초**	+51.5초	20/0/0
목적·기여	3	66.9초	58.0초	−8.9초	1/2/0
전체 60개	60	20.8초	63.9초	+43.1초	56/4/0
기법 미적용 상태에서 HyDE만 적용했을 때의 처리 시간					
사실·정의	8	15.0초	21.4초	+6.4초	8/0/0
방법·절차	29	20.1초	23.4초	+3.3초	23/4/2
결과·비교	20	17.2초	23.8초	+6.6초	19/0/1
목적·기여	3	66.9초	**27.1초**	−39.8초	2/1/0
전체 60개	60	20.8초	23.4초	+2.6초	52/5/3
기법 미적용 상태에서 SCD만 적용했을 때의 처리 시간					
사실·정의	8	15.0초	17.2초	+2.1초	7/1/0
방법·절차	29	20.1초	18.2초	−1.9초	18/5/6
결과·비교	20	17.2초	20.1초	+2.9초	17/1/2
목적·기여	3	66.9초	**22.7초**	−44.2초	2/1/0
전체 60개	60	20.8초	18.9초	−1.9초	44/8/8

주: 같은 질문의 적용 전후 평균 시간과 차이(초). 굵은 값은 같은 비교의 네 유형 중 가장 긴 적용 시간이며, 시간은 짧을수록 비용이 작다. 차이 >1초 증가, <−1초 감소, 나머지 비슷함.

두 기법 이상의 조건에서는 CAD가 포함된 조건의 시간이 길었다. 전체 평균은 HyDE+CAD 73.5초, HyDE+CAD+SCD 64.1초, CAD+SCD 55.2초, HyDE+SCD 24.9초였다. CAD에 SCD를 추가하면 평균 시간이 63.9초에서 55.2초로 8.7초 줄었다. 1초 넘게 줄어든 32개 질문은 모두 답변이 짧아졌고, 60개 답변의 평균 길이는 1,062자에서 753자로 줄었다. HyDE+CAD에 SCD를 추가한 비교에서도 시간이 줄어든 29개 질문의 답변이 모두 짧아졌다. CAD는 토큰마다 로짓을 두 번 계산하므로 생성 길이가 줄어든 만큼 전체 시간이 감소하였다.

5.8 질문 구성과 적용 조건에 대한 논의

기법을 결합한 조건에서는 답변 관련성이 낮아진 질문이 더 많았다. 답변 관련성에서 개선이 악화보다 많은 비교는 모두 HyDE를 추가한 비교였고, CAD를 추가한 네 비교는 모두 악화가 더 많았다. 근거 충실도는 CAD를 추가한 비교에서도 개선과 악화의 수가 비슷하였다. 한국어 문자 비율은 SCD를 포함한 네 조건이 모두 0.699 이상으로 SCD 미적용 조건(0.488~0.556)보다 높았으며, HyDE+SCD가 0.807로 가장 높았다. 따라서 조합의 이점이 분명한 경우는 한국어 출력이 필요할 때 SCD를 더하는 경우였다.

질문 유형과 문서에 따라 HyDE의 효과가 달랐다. 영어 근거 평가에서는 방법·절차 질문의 관련성 상승이 가장 컸고, 그 상승은 RAG Survey와 RAPTOR 질문에서 나왔다. 미적용에서 관련성이 0이던 방법·절차 질문 6개는 HyDE 적용 후 모두 양수가 되었으며, 이 중 4개가 요구 정보를 제시하였다. 수치를 묻는 결과·비교 질문에서는 HyDE의 평균 변화가 작았고, 정답 수치가 담긴 구간의 확보와 답변이 옮긴 표의 행이 결과를 좌우하였다. 목적·기여는 세 질문이어서 한 질문의 변화가 평균을 크게 바꾸었다.

자동 점수와 실제 답변은 함께 읽어야 한다. CAD의 충실도가 오른 XSUM 답변은 다른 행의 수치를 옮겼고, RAPTOR 청크 질문의 CAD 답변은 질문과 다른 내용을 설명하였다. 같은 입력 구간에서 ‘정보를 확인할 수 없다’고 답한 BIC 질문의 미적용 답변은 관련성 0.000, CAD 답변은 0.890으로 기록되었다. 60개 질문은 모두 대상 문서의 명시적 내용으로 답하는 질문이다. CAD가 설계된 지식 충돌 상황의 효과는 허위 전제나 사전 지식과 충돌하는 질문 그룹을 구성하여 비교할 수 있다.

6. 결론

6.1 연구 질문별 결과

RQ1. HyDE는 관련성 0점을 제외한 비교에서 답변 관련성을 영어 근거 평가 +0.044(개선 16개, 악화 5개), 한국어 번역 근거 평가 +0.035(개선 13개, 악화 9개) 높였다. 영어 평가에서는 방법·절차의 상승(+0.069)이 가장 컸고, 관련성이 0이던 방법·절차 질문 6개 중 4개가 요구 정보를 제시하였다. CAD는 입력 구간이 같은 상태에서 충실도를 +0.029, 관련성을 −0.021 바꾸었다(표 5-1, 5-2).

RQ2. CAD를 더한 조합은 관련성을 낮춘 질문이 높인 질문보다 많았다. HyDE에 CAD를 더하면 개선 5개, 악화 18개였고 HyDE+SCD에 CAD를 더하면 개선 5개, 악화 14개였다. HyDE가 포함된 조합 비교에는 다시 생성된 가상 문서로 바뀐 입력 구간이 함께 반영되었다(표 5-3).

RQ3. SCD는 네 HyDE·CAD 설정에서 한국어 문자 비율을 +0.205~+0.251 높였고, 60개 중 50~56개 질문에서 0.05를 넘게 증가시켰다. 처리 시간은 CAD가 미적용보다 평균 43.1초 길었고, SCD 단독의 평균 차이는 −1.9초였다(표 5-5, 5-6).

RQ4. 실제 질문 대조에서는 필요한 구간의 회복, 비교 수치의 누락, 다른 표 행의 인용, 질문과 다른 내용의 설명을 확인하였다. 높은 충실도나 관련성이 요구 정보의 제시와 일치하지 않는 답변도 있었다(5.6절, 부록 B).

6.2 연구의 의의와 적용 조건

이 연구는 같은 검색·생성 파이프라인에서 HyDE·CAD·SCD의 여덟 조건을 질문 유형별로 비교하고, 점수 변화를 실제 검색 구간과 답변으로 확인하였다. 관측 결과에 따른 적용 조건은 다음과 같다. HyDE는 두 평가 언어에서 관련성을 높인 질문이 더 많았으므로 기본으로 적용하며, 특히 방법·절차 질문에서 효과가 컸다. 한국어 답변이 필요하면 SCD를 더한다. 수치를 묻는 질문은 정답 수치가 담긴 구간이 입력되었는지 확인한다. CAD는 평균 43.1초의 추가 시간에 비해 관련성이 오히려 낮아진 질문이 많았으므로, 문서와 사전 지식이 충돌하는 질문에서 별도로 검토한다.

6.3 후속 연구

이번 결과는 영어 문서 네 종, 한국어 질문 60개, 생성 모델 한 종에서 질문·조건별로 한 번 생성하고 평가한 기록이다. 다음 실험은 문서·유형별 질문 구성의 균형, 반복 생성·평가와 사람의 요구 항목 검토를 중심으로 확장할 수 있다. 허위 전제나 지식 충돌을 담은 질문을 별도 그룹으로 구성하면 문서 근거를 따르는 정도를 CAD와 함께 비교할 수 있다. 번역 단독 검색과 고정 가상 문서를 적용한 조건은 검색 입력 변경과 생성 제어를 각각 비교하는 데 사용한다. 수치·인용의 정확성과 한국어 자연스러움을 함께 확인하면 이번 질문별 관측을 더 넓은 문서와 생성 모델에서 검토할 수 있다.

참고문헌

[1] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Advances in Neural Information Processing Systems, Vol. 33, pp. 9459-9474, 2020.

[2] L. Gao et al., “Precise Zero-Shot Dense Retrieval without Relevance Labels,” Proceedings of ACL, pp. 1762-1777, 2023, doi: 10.18653/v1/2023.acl-long.99.

[3] W. Shi et al., “Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding,” Proceedings of NAACL, pp. 783-791, 2024, doi: 10.18653/v1/2024.naacl-short.69.

[4] B. Li, Z. Xu, and R. Xie, “Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation,” Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519-31526, 2026, doi: 10.1609/aaai.v40i37.40417.

[5] J. Chen et al., “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation,” Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318-2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson, S. Walker, S. Jones, M. M. Hancock-Beaulieu, and M. Gatford, “Okapi at TREC-3,” Proceedings of the Third Text REtrieval Conference (TREC-3), NIST Special Publication 500-225, pp. 109-126, 1995 (conference 1994).

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” Proceedings of SIGIR, pp. 758-759, 2009, doi: 10.1145/1571941.1572114.

[8] S. MacAvaney, A. Yates, A. Cohan, and N. Goharian, “CEDR: Contextualized Embeddings for Document Ranking,” Proceedings of SIGIR, pp. 1101-1104, 2019, doi: 10.1145/3331184.3331317.

[9] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157-173, 2024, doi: 10.1162/tacl_a_00638.

[10] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented

Generation," Proceedings of EACL System Demonstrations, pp. 150-158, 2024, doi: 10.18653/v1/2024.eacl-demo.16.

[11] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proceedings of EMNLP, pp. 6769-6781, 2020, doi: 10.18653/v1/2020.emnlp-main.550.

[12] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proceedings of EACL, pp. 874-880, 2021, doi: 10.18653/v1/2021.eacl-main.74.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286-12312, 2023, doi: 10.18653/v1/2023.acl-long.687.

[14] P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S. Jeong, J. Baek, S. Cho, S. J. Hwang, and J. Park, "Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity," Proceedings of NAACL, pp. 7036-7050, 2024, doi: 10.18653/v1/2024.naacl-long.389.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, No. 1, pp. 1-29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] W. Fan et al., "A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models," Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 6491-6501, 2024, doi: 10.1145/3637528.3671470.

[19] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[20] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EACL, pp. 2014-2037, 2023, doi: 10.18653/v1/2023.eacl-main.148.

[21] P. Dasigi, K. Lo, I. Beltagy, A. Cohan, N. A. Smith, and M. Gardner, “A Dataset of Information-Seeking Questions and Answers Anchored in Research Papers,” Proceedings of NAACL, pp. 4599-4610, 2021, doi: 10.18653/v1/2021.naacl-main.365.

[22] M. A. Sultan, J. Ganhotra, and R. F. Astudillo, “Structured Chain-of-Thought Prompting for Few-Shot Generation of Content-Grounded QA Conversations,” Findings of EMNLP, pp. 16172-16187, 2024, doi: 10.18653/v1/2024.findings-emnlp.948.

실험 사용 모델 및 원문 자료 출처

학술 참고문헌 [1]~[22]와 별도로 구현에 사용한 모델 카드[M1][M2]와 검색 대상 문서 [D1]~[D4]의 출처를 정리하였다.

[M1] K-intelligence/Midm-2.0-Base-Instruct 공식 모델 카드(KT), https://huggingface.co/K-intelligence/Midm-2.0-Base-Instruct (확인: 2026-10-17).

[M2] MiniLM CrossEncoder 재정렬 모델의 공식 모델 카드, https://huggingface.co/cross-encoder/ms-marco-MiniLM-L6-v2 (확인: 2026-10-17). 원질의·후보 구간 쌍을 입력하는 CrossEncoder 재정렬에 사용하였다(구현 설정 표기: cross-encoder/ms-marco-MiniLM-L-6-v2).

[D1] Y. Gao et al., “Retrieval-Augmented Generation for Large Language Models: A Survey,” arXiv:2312.10997, https://arxiv.org/abs/2312.10997 (확인: 2026-10-20). 실험 원문: paper_nlp_rag.pdf.

[D2] W. Shi et al., CAD 논문[3]. 실험 원문: paper_nlp_cad.pdf.

[D3] P. Sarthi et al., RAPTOR 논문[14]. 실험 원문: paper_nlp_raptor.pdf.

[D4] KT Tech Innovation Group, “Mi:dm K 2.5 Pro,” 기업 기술보고서, arXiv:2603.18788v2, 2026, https://arxiv.org/abs/2603.18788v2 (확인: 2026-10-20). 실험 원문: paper_midm.pdf.

질의별 원문 페이지와 정답 근거는 부록 A에 제시하였다.

그림 자료 이용 정보

그림 2-1~2-4는 아래 문헌의 구조를 바탕으로 본 연구에서 작성하였으며, 각 항목 아래에 참고 자료의 주소를 적었다.

그림 2-1 — Lewis 외[1]의 RAG 구조

https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf (확인: 2026-10-20)

그림 2-2 — Gao 외[2]의 HyDE 구조

https://aclanthology.org/2023.acl-long.99/ (확인: 2026-10-20)

그림 2-3 — Shi 외[3]의 CAD 로짓 결합

https://aclanthology.org/2024.naacl-short.69/ (확인: 2026-10-20)

그림 2-4 — Li 외[4]의 SCD 토큰별 점수 조정

https://ojs.aaai.org/index.php/AAAI/article/view/40417 (확인: 2026-10-20)

부록 A. 60개 질문과 정답 근거

각 질문의 대상 문서, 유형, 원문 페이지와 정답 근거를 제시하였다. 질문 ID는 저장된 생성·평가 기록을 연결하는 식별자다.

[표 A-1] 60개 질문의 대상 문서·유형·정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
ext_cad_001	언어 모델이 생성 시 활용하는 prior knowledge와 context knowledge는 각각 어디에서 오는 정보입니까?	CAD	사실·정의	1	the context contains external knowledge; prior knowledge is encoded in the model parameters
ext_cad_002	CAD의 요약 실험에는 어떤 데이터셋과 평가 지표가 사용되었습니까?	CAD	방법·절차	3	CNN-DM and XSUM; ROUGE-L, BERT-Precision, and FactKB
ext_cad_003	CAD의 지식 충돌 실험에는 어떤 두 데이터셋이 사용되었고 각각 무엇을 평가합니까?	CAD	방법·절차	3	MemoTrap investigates memorization traps; NQ-Swap tests faithful answering from a modified reliable document.
ext_cad_004	NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?	CAD	방법·절차	3	identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity
ext_cad_005	CAD 실험에서 요약 과제와 지식 충돌 과제에 사용한 α 값은 각각 얼마이며, 지식 충돌 과제에서 더 큰 값을 사용한 이유는 무엇입니까?	CAD	방법·절차	3	α = 0.5 for summarization and α = 1 for knowledge conflicts, where prior knowledge needs to be factored out more

[계속표 A-1 (2/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
ext_cad_006	CAD 논문의 베이스라인 디코딩은 요약 과제와 지식 충돌 과제에서 각각 어떤 샘플링 전략을 사용합니까?	CAD	방법·절차	3	greedy decoding for knowledge conflict tasks and top-p sampling with p=0.9 for summarization tasks
ext_cad_007	CAD가 실험에서 적용된 사전학습 및 instruction-finetuned 언어 모델 계열은 무엇입니까?	CAD	방법·절차	3	OPT, GPT-Neo, LLaMA, and FLAN-T5
ext_cad_008	지식 충돌 과제에서 모델 크기가 커질수록 CAD의 성능 향상 폭은 어떤 경향을 보였습니까?	CAD	결과·비교	5	the gain increases as the model size grows
ext_cad_009	LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?	CAD	결과·비교	4	Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3
ext_cad_010	외부 컨텍스트가 생성 토큰과 조건부 독립이라면 α가 0이 아니어도 CAD의 출력 분포에는 어떤 영향이 있습니까?	CAD	사실·정의	2	even a non-zero α would not have an impact to the original output distribution
ext_cad_011	CAD는 특정 instruction-finetuned 언어 모델에만 제한됩니까, 아니면 어떤 언어 모델에도 적용 가능한 디코딩 전략입니까?	CAD	사실·정의	6	a decoding strategy applicable to any LM
ext_midm_001	Mi:dm K 2.5 Pro의 학습 데이터는 어떤 세 가지 경로를 통해 확보됩니까?	Mi:dm	방법·절차	3	licensed proprietary datasets, public datasets that permit commercial use, and in-house synthetic data
ext_midm_002	Mi:dm K 2.5 Pro는 한국어 중심 학습을 유지하기 위해 다국어 데이터를 한국어 코퍼스 대비 어느 정도 비율로 제한하며, 그 이유는 무엇입니까?	Mi:dm	방법·절차	3	3-10% of the Korean corpus, to encourage cross-lingual transfer without diluting the Korean-language focus

[계속표 A-1 (3/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
ext_midm_003	응답 스타일 재작성 후 평균 응답 길이는 몇 % 증가했고, bullet_count=0인 응답의 비율은 어떻게 변했습니까?	Mi:dm	결과·비교	8	mean response length increases by 256.70%; bullet_count = 0 drops from 82.8% to 3.9%
ext_midm_004	Mi:dm K 2.5 Pro의 한국어 멀티턴 대화 데이터는 어떤 세 가지 차원을 기준으로 고품질 대화를 설계합니까?	Mi:dm	방법·절차	15	interaction structure, topic and task, and persona
ext_midm_005	Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?	Mi:dm	방법·절차	21	to favor versatile conversational alignment; creative writing, translation, and general question answering
ext_midm_006	Fully asynchronous GSPO 학습은 synchronous 방식과 비교해 step time과 token throughput을 각각 어느 정도 개선했습니까?	Mi:dm	결과·비교	23	reduces step time by approximately 15% and improves token throughput by approximately 30%
ext_midm_007	LLM-as-a-Judge 기반 reward signal은 사람의 평가와 어느 정도의 일치율을 보였습니까?	Mi:dm	결과·비교	24	an agreement rate of 91%
ext_midm_008	Reasoning-enabled 평가에서 Mi:dm K 2.5 Pro가 HumanEval+와 τ²-Bench Telecom에서 기록한 점수는 각각 얼마입니까?	Mi:dm	결과·비교	25	HumanEval+ 92.07% and τ²-Bench Telecom 89%
ext_midm_009	한국어 red-teaming 평가에서 Mi:dm K 2.5 Pro의 Attack Success Rate는 얼마였으며 비교 모델들 가운데 어떤 수준이었습니까?	Mi:dm	결과·비교	31	ASR of 36.3%, the lowest attack success rate among the compared models
ext_rag_001	Advanced RAG의 pre-retrieval 단계는 인덱스와 사용자 질의를 각각 어떤 방향으로 최적화합니까?	RAG Survey	방법·절차	4	optimizing the indexing structure and the original query

[계속표 A-1 (4/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
ext_rag_002	Advanced RAG의 post-retrieval 단계에서 사용되는 두 가지 핵심 방법은 무엇입니까?	RAG Survey	방법·절차	4	rerank chunks and context compressing
ext_rag_003	RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?	RAG Survey	방법·절차	8	Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.
ext_rag_004	문서 청크에 타임스탬프 같은 메타데이터를 부여하면 time-aware RAG는 최신 정보를 어떻게 우선할 수 있습니까?	RAG Survey	방법·절차	8	Assigning different weights to document timestamps during retrieval can achieve time-aware RAG, ensuring the freshness of knowledge and avoiding outdated information.
ext_rag_005	Reverse HyDE는 문서로부터 가상의 질문을 생성해 원래 질문과 답변 사이의 의미적 간극을 어떻게 줄입니까?	RAG Survey	방법·절차	8	using LLM to generate questions that can be answered by the document, then calculating the similarity between the original question and the hypothetical question
ext_rag_006	Multi-Query와 Sub-Query 방식은 원래 질의를 확장하거나 분해하는 방식에서 어떻게 다릅니까?	RAG Survey	방법·절차	8	Multi-Query expands queries via LLMs for parallel execution; Sub-Query decomposes a complex question into simpler sub-questions.

[계속표 A-1 (5/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
ext_rag_007	Iterative Retrieval, Recursive Retrieval, Adaptive Retrieval은 검색을 반복하거나 중단하는 방식에서 각각 어떻게 구분됩니까?	RAG Survey	방법·절차	11	Iterative retrieval alternates retrieval and generation; recursive retrieval refines queries and breaks problems into sub-problems; adaptive retrieval determines whether retrieval is necessary and when to stop.
ext_rag_008	RAG 평가에서 요구되는 네 가지 핵심 능력은 무엇입니까?	RAG Survey	방법·절차	12	noise robustness, negative rejection, information integration, and counterfactual robustness
ext_rag_009	RAG 평가에서 Negative Rejection은 어떤 능력을 측정합니까?	RAG Survey	사실·정의	12	refraining from responding when the retrieved documents do not contain the necessary knowledge to answer a question
ext_rag_010	RAG와 파인튜닝을 비교할 때 지식 업데이트의 동적 특성과 해석 가능성 측면에서 RAG가 갖는 특징은 무엇입니까?	RAG Survey	결과·비교	5	real-time knowledge updates and effective utilization of external knowledge sources with high interpretability
ext_raptor_001	RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?	RAPTOR	방법·절차	3	length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk
ext_raptor_002	RAPTOR의 leaf node를 만들 때 텍스트 임베딩에 사용한 모델은 무엇입니까?	RAPTOR	방법·절차	3	SBERT, a BERT-based encoder (multi-qa-mpnet-base-cos-v1)
ext_raptor_003	RAPTOR의 GMM 클러스터링 전에 UMAP을 사용하는 이유는 무엇입니까?	RAPTOR	방법·절차	4	to mitigate the challenge of high-dimensional vector embeddings by dimensionality reduction

[계속표 A-1 (6/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
ext_raptor_004	RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?	RAPTOR	방법·절차	4	to determine the optimal number of clusters
ext_raptor_005	RAPTOR에서 클러스터별 요약을 생성하는 데 사용한 언어 모델은 무엇입니까?	RAPTOR	방법·절차	4	gpt-3.5-turbo
ext_raptor_006	RAPTOR의 트리 구축 비용은 문서 길이가 증가할 때 build time과 token expenditure 측면에서 어떻게 확장됩니까?	RAPTOR	결과·비교	16	both build time and token expenditure scale linearly with document length
ext_raptor_007	QASPER 데이터셋은 몇 개의 질문과 NLP 논문으로 구성되며, 논문에서는 어떤 지표로 성능을 평가합니까?	RAPTOR	방법·절차	6	5,049 questions across 1,585 NLP papers; accuracy is measured using standard F1
ext_raptor_008	QuALITY-HARD는 일반 QuALITY 질문 중 어떤 기준을 만족하는 질문들로 구성됩니까?	RAPTOR	사실·정의	6	questions that a majority of human annotators answered incorrectly in a speed-setting
ext_raptor_009	QASPER에서 RAPTOR의 F1 Match 점수는 GPT-3, GPT-4, UnifiedQA를 사용할 때 각각 얼마였습니까?	RAPTOR	결과·비교	7	53.1%, 55.7%, and 36.6%, respectively
ext_raptor_010	QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?	RAPTOR	결과·비교	9	57.9 with one leaf layer versus 73.68 with all three layers
ext_raptor_011	Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?	RAPTOR	결과·비교	20	RAPTOR retrieves relevant information across tree layers, while DPR retrieves detailed descriptions of a narrow subset of the story

[계속표 A-1 (7/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
track1_0009	RAG가 LLM에서 사실적으로 부정확한 콘텐츠 생성을 줄이는 데 어떻게 기여합니까?	RAG Survey	목적·기여	1	By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content.
track1_0010	RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?	RAG Survey	방법·절차	3	The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve–Read' framework.
track1_0012	RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?	RAG Survey	목적·기여	1	This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.
track1_0015	RAG 프로세스에서 핵심적인 역할을 하는 세 가지 구성 기술은 무엇인가요?	RAG Survey	사실·정의	2	the aspects of Retrieval, Generation and Augmentation
track1_0016	RAG 방법론의 평가 방법은 어떻게 요약되어 있습니까?	RAG Survey	방법·절차	2	We have summarized the current assessment methods of RAG, covering 26 tasks, nearly 50 datasets, outlining the evaluation objectives and metrics, as well as the current evaluation benchmarks and tools.

[계속표 A-1 (8/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
track1_0019	LLaMA-30B 모델에 CAD를 적용했을 때 CNN-DM 데이터셋에서 어떤 성과가 있었나요?	CAD	결과·비교	3	Specifically, when applied to LLAMA-30B in CNN-DM, CAD leads to 21% increase in ROUGE-L, 14.3% increase in factKB and 7.8% increase in BERT-P.
track1_0021	CAD는 어떻게 잘못된 정보 생성을 줄이나요?	CAD	결과·비교	2	These results demonstrate the potential of CAD in mitigating hallucinations in text generation and overriding prior knowledge with reliable and trusted information.
track1_0023	CAD는 언어 모델이 생성하는 요약문의 사실적 정확성을 향상시키나요?	CAD	결과·비교	1	Experimental results from summarization tasks show that context-aware decoding significantly enhances the generation faithfulness of various vanilla LMs including OPT (Zhang et al., 2022), GPT-Neo (Black et al., 2021), LLaMA (Touvron et al., 2023) and instruction-finetuned LMs such as FLAN (Chung et al., 2022).
track1_0024	CAD를 적용하지 않은 경우와 비교했을 때, knowledge conflict QA 데이터셋에서 LLaMA-30B의 성능은 어떻게 변화하나요?	CAD	결과·비교	2	CAD brings a 2.9x improvement to LLaMA-30B on a knowledge conflicts QA dataset (Longpre et al., 2021).

[계속표 A-1 (9/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
track1_0025	RAPTOR 모델이 QuALITY 벤치마크에서 기존 성능을 얼마나 개선했나요?	RAPTOR	결과·비교	1	we can improve the best performance on the QuALITY benchmark by 20% in absolute accuracy.
track1_0026	RAPTOR의 트리 구조는 텍스트 클러스터링을 통해 어떻게 구축되나요?	RAPTOR	방법·절차	2	RAPTOR recursively clusters chunks of text based on their vector embeddings and generates text summaries of those clusters, constructing a tree from the bottom up.
track1_0027	RAPTOR가 여러 QA 작업에서 달성한 결과는 무엇인가요?	RAPTOR	결과·비교	2	RAPTOR coupled with GPT-4, and sometimes even with UnifiedQA, gives new state-of-the-art results on three QA tasks: free text response questions on books and movies (NarrativeQA, Ko˘cisk`y et al. 2018), full-text NLP papers (QASPER, Dasigi et al. 2021), and multiple-choice questions based on medium-length passages (QuALITY, Pang et al. 2022).
track1_0032	RAPTOR의 계층에서 검색된 노드가 어느 계층에서 오는지에 대한 연구 결과는 무엇인가요?	RAPTOR	결과·비교	22	We observe that between 18.5% to 57% of the retrieved nodes come from non-leaf nodes.
track1_0033	Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까?	Mi:dm	사실·정의	2	32B parameters
track1_0034	Mi:dm K 2.5 Pro의 방법론에서 AST 분석은 어떤 목적으로 사용됩니까?	Mi:dm	방법·절차	1	abstract syntax tree (AST) analysis for code

[계속표 A-1 (10/10)] 60개 질문과 정답 근거

질문 ID	한국어 질문	문서	유형	쪽	정답 근거 구간
track1_0035	Mi:dm K 2.5 Pro 모델은 어떤 한국어 벤치마크에서 최첨단 결과를 달성했습니까?	Mi:dm	결과·비교	1	sets state-of-the-art results on Korean-specific benchmarks
track1_0036	Mi:dm K 2.5 Pro가 해결하려는 주요 문제는 무엇입니까?	Mi:dm	목적·기여	1	address enterprise-grade complexity through reasoning-focused optimization
track1_0037	Mi:dm K 2.5 Pro 모델의 컨텍스트 윈도우(context window) 길이는 얼마인가요?	Mi:dm	사실·정의	1	128K token context window
track1_0040	Mi:dm K 2.5 Pro의 사후 훈련 파이프라인에서 모델 병합은 어떤 역할을 합니까?	Mi:dm	방법·절차	2	improve training stability and achieve balanced performance across complex reasoning, coding, instruction following, and agentic task execution

부록 B. 질문별 검색 근거와 실제 답변

본문에서 확인한 현상을 질문 원문과 정답 근거, 실제 답변의 필요한 부분으로 정리하였다. 전체 답변과 입력 구간은 질문별 분석 자료에 보존되어 있다.

B.1 RAPTOR에서 BIC가 결정하는 항목

질문: ‘RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 어떤 결정을 내리는 데 사용됩니까?’

정답 근거: RAPTOR 원문 4쪽의 ‘to determine the optimal number of clusters’이다.

기준 조건은 미적용, 적용 조건은 HyDE이다. 미적용의 입력 구간에는 최적 클러스터 수를 정한다는 문장이 없었고 답변은 정보를 확인할 수 없다고 하였다. HyDE 적용 후 해당 문장이 입력 구간에 들어왔고 답변은 BIC가 최적 클러스터 수를 정한다고 설명하였다.

기준 답변 발췌: ‘제공된 논문 컨텍스트를 면밀히 검토한 결과, RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)이 어떤 결정을 내리는 데 사용되는지에 관한 구체적인 정보는 확인할 수 없습니다.’

적용 답변 발췌: ‘제공된 논문 컨텍스트를 분석한 결과, RAPTOR의 클러스터링 과정에서 Bayesian Information Criterion(BIC)은 최적의 클러스터 개수 결정을 위해 사용됨이 확인됩니다.’

답변 관련성: 0.000 → 0.895 (차이 +0.895). 문맥 재현율: 0.000 → 1.000 (차이 +1.000).

B.2 NQ-Swap 데이터셋의 생성 절차

질문: ‘NQ-Swap 데이터셋은 기존 Natural Questions의 정답과 문서를 어떤 방식으로 변형해 만들어집니까?’

정답 근거: CAD 원문 3쪽의 ‘identify questions with named entity answers, find the supportive document, then replace the gold answer entity with a random entity’이다.

기준 조건은 미적용, 적용 조건은 HyDE이다. 두 조건 모두 생성 절차를 설명한 원문 구간을 입력받았다. 미적용 답변은 CAD 수식 문장을 이어 쓴 뒤 절별 설명을 요청하는 문장을 나열하였고, HyDE 답변은 개체 정답 질문 선택, 근거 문서 탐색, 정답 개체 치환의 세 단계를 제시하였다.

기준 답변 발췌: ‘2.1 Background 섹션에서 CAD의 개발 배경과 해결하고자 하는 문제를 구체적으로 설명해주세요.’

적용 답변 발췌: ‘1. 원본 데이터 식별: 먼저 NQ 데이터셋에서 개체명(named entity) 답변을 포함하는 질문들을 식별합니다.’ / ‘3. 정답 교체: 원본 문서에서 발견된 정답 개체(entity)를 무작위로 선택된 다른 개체로 대체합니다.’

답변 관련성: 0.000 → 0.785 (차이 +0.785). 근거 충실도: 0.185 → 0.809 (차이 +0.624).

B.3 Fusion SFT의 non-reasoning 비중 확대 목적

질문: ‘Fusion SFT 단계에서 non-reasoning 데이터의 비중을 높인 목적은 무엇이며, 어떤 유형의 과제를 특히 보강합니까?’

정답 근거: Mi:dm K 2.5 Pro Technical Report 원문 21쪽의 ‘to favor versatile conversational alignment; creative writing, translation, and general question answering’이다.

기준 조건은 미적용, 적용 조건은 HyDE이다. 두 조건의 입력 구간에 목적과 보강 과제가 모두 있었다. HyDE 답변은 사전학습 단계의 데이터 구성을 다룬 영어 원문을 이어 썼고, 대화 정렬이라는 목적과 창작·번역·일반 질의응답이라는 과제는 답변에 없었다. 답변 관련성은 0.000에서 0.463으로 올랐다.

기준 답변 발췌: ‘## 표 10: 단계별 성능 변화 - 추론 중심 후훈련’

적용 답변 발췌: ‘In CPT stage 2, we increase the proportion of STEM data relative to the previous stage in order to further enhance overall performance and strengthen reasoning capability.’

답변 관련성: 0.000 → 0.463 (차이 +0.463). 한국어 문자 비율: 0.609 → 0.000 (차이 -0.609).

B.4 QuALITY의 계층별 검색 성능 비교

질문: ‘QuALITY의 한 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때의 성능은 leaf node 한 계층만 검색했을 때와 어떻게 달라졌습니까?’

정답 근거: RAPTOR 원문 9쪽의 ‘57.9 with one leaf layer versus 73.68 with all three layers’이다.

기준 조건은 미적용, 적용 조건은 HyDE이다. 미적용의 입력 구간과 답변에는 한 계층 57.9와 세 계층 73.68이 모두 있었다. HyDE 적용 후 73.68이 담긴 구간이 빠졌고, 답변은 직접 비교 수치를 확인할 수 없다고 한 뒤 전체 트리 검색의 일반적 장점을 설명하였다.

기준 답변 발췌: ‘- 성능 점수: 57.9%’ / ‘- 성능 점수: 73.68%’

적용 답변 발췌: ‘제공된 논문 컨텍스트를 검토한 결과, QuALITY 데이터셋의 특정 스토리에서 RAPTOR가 전체 3개 계층을 검색했을 때와 leaf node 한 계층만 검색했을 때의 성능 차이에 대한 직접적인 비교 데이터는 확인할 수 없습니다.’

답변 관련성: 0.871 → 0.000 (차이 -0.871). 문맥 재현율: 1.000 → 0.000 (차이 -1.000). 근거 충실도: 1.000 → 0.929 (차이 -0.071).

B.5 LLaMA-30B·XSUM의 세 지표 비교

질문: ‘LLaMA-30B에 CAD를 적용했을 때 XSUM에서 ROUGE-L, factKB, BERT-P 점수는 regular decoding과 비교해 어떻게 달라졌습니까?’

정답 근거: CAD 원문 4쪽의 ‘Regular: 18.7, 47.7, 87.1; CAD: 22.0, 66.4, 90.3’이다.

기준 조건은 미적용, 적용 조건은 CAD이다. 두 조건의 입력 구간은 같고 정답 수치 18.7·22.0, 47.7·66.4, 87.1·90.3이 들어 있었다. 두 답변은 모두 같은 표의 다른 행 값인 ROUGE-L 25.8·31.8과 factKB 87.8을 XSUM 결과로 제시하였다. CAD 적용 후 근거 충실도는 0.526에서 0.867로 올랐다.

기준 답변 발췌: '- Regular decoding: 25.8점' / '- CAD 적용 시: 87.8점'

적용 답변 발췌: '- Regular Decoding: ROUGE-L 25.8점, factKB 47.7점, BERT-P 87.1점' / '- CAD 적용 시: ROUGE-L 31.8점, factKB 87.8점, BERT-P 92.2점'

근거 충실도: 0.526 → 0.867 (차이 +0.340). 답변 관련성: 0.809 → 0.798 (차이 -0.011).

B.6 RAPTOR 청크 길이와 문장 경계 처리

질문: 'RAPTOR는 초기 문서를 몇 토큰 길이의 청크로 나누며, 문장이 청크 경계를 넘을 때 어떻게 처리합니까?'

정답 근거: RAPTOR 원문 3쪽의 'length 100; if a sentence exceeds the 100-token limit, the entire sentence is moved to the next chunk'이다.

기준 조건은 미적용, 적용 조건은 CAD이다. 입력 구간에는 100토큰 청크와 문장 이동 규칙이 있었다. 미적용 답변은 문서 길이와 성능을 묻는 문장을 반복하였고, CAD 답변은 트리 구축 비용이 문서 길이에 선형으로 증가한다는 다른 내용을 설명하였다. 근거 충실도는 0.250에서 1.000으로, 답변 관련성은 0.000에서 0.755로 올랐지만 청크 길이와 문장 처리 규칙은 두 답변 모두에 없었다.

기준 답변 발췌: '문서 길이와 관련하여 어떤 성능 특성을 보이는지 설명해주세요'

적용 답변 발췌: 'RAPTOR는 빌드 시간(build time)이 초기 문서 길이와 선형적인 관계를 보입니다. Figure 6에 제시된 실험 결과에 따르면, 최대 80,000 토큰에 이르는 문서들에 대해 RAPTOR 나무 구조(tree construction) 건설 시간이 문서 길이에'

근거 충실도: 0.250 → 1.000 (차이 +0.750). 답변 관련성: 0.000 → 0.755 (차이 +0.755).

B.7 지식 집약 과제에서 RAG의 이점

질문: 'RAG 시스템은 지식 집약적인 작업에서 어떻게 유리합니까?'

정답 근거: RAG Survey 원문 1쪽의 'This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information.'이다.

기준 조건은 미적용, 적용 조건은 CAD이다. 입력 구간은 같았다. 미적용 답변은 실시간 지식 갱신과 외부 지식 활용을 원문 인용과 함께 정리하였고, CAD 답변은 '위 내용 참조'와 요청 문장 조각만 남겼다. 이 질문의 답변 관련성은 0.900에서 0.000으로 낮아졌다. 관련성 평균에서는 이 질문을 제외하였다.

기준 답변 발췌: '는 "RAG excels in dynamic environments by offering realtime knowledge updates and effective utilization of external knowledge sources with high interpretability"라고 명시하고 있습니다. RAG는 실시간 지식 업데이트를 제공하며 외부'

적용 답변 발췌: ‘위 내용 참조’

답변 관련성: 0.900 → 0.000 (차이 -0.900). 근거 충실도: 0.938 → 0.500 (차이 -0.438).

B.8 Naive RAG의 처리 과정

질문: ‘RAG의 Naive RAG 방법론은 어떤 과정으로 구성되어 있습니까?’

정답 근거: RAG Survey 원문 3쪽의 ‘The Naive RAG follows a traditional process that includes indexing, retrieval, and generation, which is also characterized as a 'Retrieve-Read' framework.’이다.

기준 조건은 HyDE, 적용 조건은 HyDE+CAD이다. 두 조건 모두 첫 입력 구간에 색인·검색·생성의 세 단계가 있었고, 가상 문서가 다시 생성되어 다섯 구간 중 하나가 바뀌었다. HyDE 답변은 세 단계를 설명하였고, HyDE+CAD 답변은 입력 구간을 이어 쓴 뒤 Modular RAG의 새 모듈을 묻는 질문을 스스로 만들어 그 내용을 설명하였다.

기준 답변 발췌: ‘1. Indexing(색인화)’ / ‘2. Retrieval(검색)’ / ‘3. Generation(생성)’

적용 답변 발췌: ‘Modular RAG 패러다임에서 새롭게 도입된 모듈들은 무엇이며’ / ‘Modular RAG 프레임워크에서 가장 주목할 만한 혁신 중 하나는 Search Module의 도입입니다.’

답변 관련성: 0.929 → 0.000 (차이 -0.929). 근거 충실도: 0.950 → 0.733 (차이 -0.217).

B.9 큰 청크와 작은 청크의 장단점

질문: ‘RAG에서 큰 청크와 작은 청크를 사용할 때 각각 어떤 장단점이 발생합니까?’

정답 근거: RAG Survey 원문 8쪽의 ‘Larger chunks can capture more context, but they also generate more noise; smaller chunks may not fully convey the necessary context, but have less noise.’이다.

기준 조건은 미적용, 적용 조건은 SCD이다. 두 답변 모두 질문한 장단점을 설명하지 않았다. 미적용 답변은 참고문헌 목록을 이어 쓴 뒤 RAG의 세 구성요소를 한국어로 설명하였고, SCD 답변은 영어 참고문헌만 이어 써서 한국어 문자 비율이 0.425에서 0.000으로 낮아졌다.

기준 답변 발췌: ‘따라서 RAG의 세 가지 핵심 구성요소는 Retrieval(검색), Generation(생성)’

적용 답변 발췌: ‘few examples,” arXiv preprint arXiv:2305.06296, 2023. [7] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. K¨uttler, M. Lewis, W.’

한국어 문자 비율: 0.425 → 0.000 (차이 -0.425).