한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 동국대학교 WISE캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

01 연구 배경과 목적

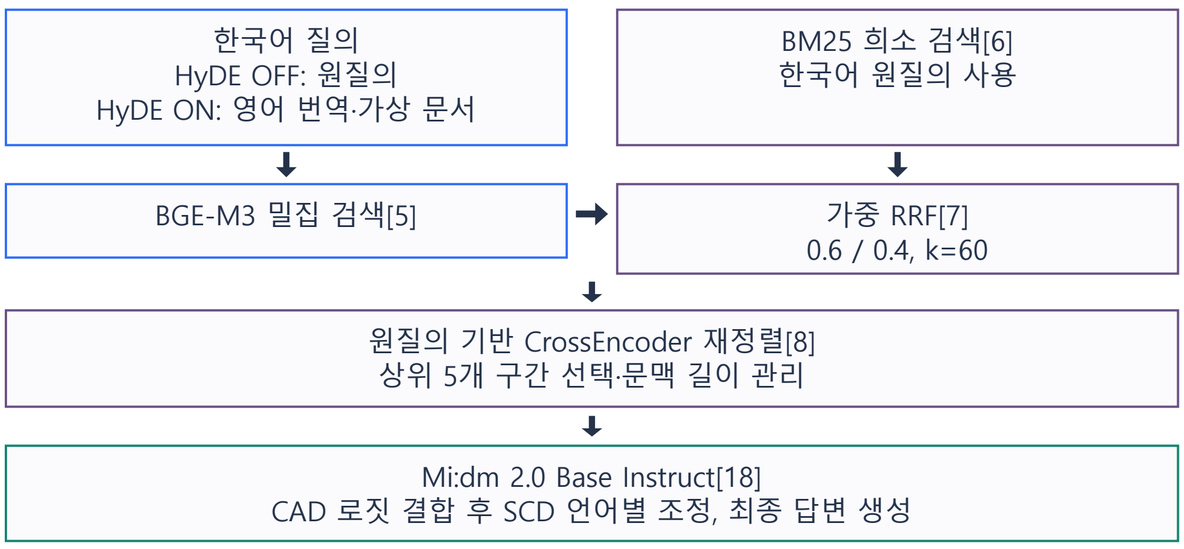
RAG는 질문과 관련된 문서 구간을 검색하고,
그 텍스트를 생성 모델에 제공해 답변을 만든다[1].

HyDE: Hypothetical Document Embeddings[2]
CAD: Context-Aware Decoding[3]
SCD: Soft Constrained Decoding[4]

본 연구는 한국어 질의로 영어 문서를 검색하는 RAG에서 검색 결과, 답변의 근거 충실도 및 출력 언어를 평가한다. 같은 파이프라인에서 세 기법의 8개 조합을 비교한다.

02 Paper-RAG 구조와 기법 적용 위치

Paper-RAG는 본 연구의 고정 검색·생성 파이프라인이다.



03 3요인 완전요인 실험 설계

H=HyDE, C=CAD, S=SCD 0=미적용, 1=적용

조건	H	C	S
H0C0S0	0	0	0
H0C0S1	0	0	1
H0C1S0	0	1	0
H0C1S1	0	1	1
H1C0S0	1	0	0
H1C0S1	1	0	1
H1C1S0	1	1	0
H1C1S1	1	1	1

영어 문서 4종 × 15개 질의 × 8조건 = 480개 생성 기록

생성 512토큰, CAD α=0.5, SCD α=1.1·β=0.9·Tstart=5

문서 요약을 15개 내용 단위로 나누어 질의를 작성하고,
총 60개 질의의 원문 페이지·정답 근거·답변 가능성을 확인

04 평가 지표 및 실험·통계 방법

근거 충실도: 답변 주장 중 검색 근거가 뒷받침하는 비율
답변 관련성: 답변에서 만든 질문과 원질문의 의미 유사도
문맥 정밀도: 참조 답변에 유용한 구간의 상위 배치 정도
문맥 재현율: 참조 답변 주장을 검색 문맥이 포괄하는 비율
한국어 비율: 한글 / (한글 + ASCII 영문자)

높은 품질 점수는 근거 지지·질문 관련성·근거 활용을 뜻한다.
한국어 비율 0.700은 계산 대상 문자 중 한글이 70.0%다.

평가 예시 ext_raptor_011, H0C0S0

질문: Cinderella 사례의 정성 분석에서 RAPTOR의
tree-based retrieval이 DPR보다 주제형·멀티홉
질문에 유리했던 이유는 무엇입니까?

검색 근거(발췌): “within higher-layer summaries”
참조답변(발췌): “The text retrieved by RAPTOR”
생성 답변(발췌): “RAPTOR는 계층적 구조를 통해”
평가: 충실도 1.000, 관련성 0.937

평가: RAGAS 0.2.15[10], gpt-4o, BGE-M3 임베딩
S0: 영어 문맥 / S1: 한국어 번역 평가 문맥
생성에는 영어 문맥 사용, 저장 답변은 그대로 평가

질의 60개 반복측정, 양측 α=0.05와 Holm 보정
품질: S0·S1별 H×C / 문자 비율·시간: H×C×S
SCD 120·240쌍은 질의별 평균 차이 60개로 검정

05 조합별 결과와 통계 검정

8조건 평균(SD) · 시간 단위: 초

조건	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 비율	실행 시간
H0C0S0	0.791 (0.260)	0.683 (0.282)	0.749 (0.302)	0.933 (0.252)	0.494 (0.265)	20.792 (23.404)
H0C0S1	0.787 (0.254)	0.637 (0.296)	0.763 (0.300)	0.900 (0.303)	0.699 (0.329)	18.898 (5.085)
H0C1S0	0.839 (0.201)	0.675 (0.261)	0.740 (0.302)	0.917 (0.279)	0.488 (0.245)	63.867 (25.312)
H0C1S1	0.777 (0.270)	0.600 (0.321)	0.752 (0.301)	0.850 (0.360)	0.719 (0.218)	55.159 (26.465)
H1C0S0	0.834 (0.186)	0.763 (0.209)	0.714 (0.296)	0.933 (0.252)	0.556 (0.213)	23.440 (4.707)
H1C0S1	0.822 (0.218)	0.710 (0.272)	0.743 (0.281)	0.900 (0.303)	0.807 (0.200)	24.892 (5.196)
H1C1S0	0.860 (0.181)	0.705 (0.248)	0.736 (0.271)	0.900 (0.303)	0.503 (0.229)	73.532 (21.584)
H1C1S1	0.831 (0.253)	0.667 (0.286)	0.754 (0.267)	0.917 (0.279)	0.731 (0.209)	64.125 (21.675)

S0: 영어 평가 문맥 / S1: 한국어 번역 평가 문맥
충실도 H0C1S0 n=58, H0C0S1 n=57, 나머지 n=60
한국어 비율과 시간은 생성 기록에서 직접 계산

3요인 반복측정 ANOVA · 각 효과 df=(1,59)

요인	한국어 비율 F	보정 p	실행 시간 F	보정 p
H	2.924	0.370	16.362	<0.001
C	3.365	0.358	423.765	<0.001
S	341.302	<0.001	6.097	0.066
H×C	4.417	0.239	2.262	0.414
H×S	0.771	0.940	0.401	0.976
C×S	0.006	0.940	12.080	0.005
H×C×S	1.035	0.940	0.487	0.976

문자 비율·시간은 각각 7검정에 Holm 보정.
RAGAS H×C 검정은 평가 문맥 언어별로 수행했으며,
전체 24검정의 Holm 보정 p는 모두 0.05 이상이었다.

기법별 대응 비교 · 질의별 평균 차이, 양측 검정

비교	차이 (SD)	t(df)	보정 전 p	보정 후 p
HyDE 답변 관련성	0.080 (0.279)	2.236 (59)	0.029	0.117
CAD 근거 충실도	0.029 (0.255)	0.862 (57)	0.393	1.000
SCD H0 한국어 비율	0.218 (0.121)	13.951 (59)	<0.001	<0.001

HyDE: C0S0, CAD: H0S0, SCD: H0의 CAD 상태 평균
보정: HyDE·CAD 각 4지표, SCD 주·전체 비교 2검정
SCD 차이 +0.218은 한글 비중 +21.8%p에 해당

06 결과 해석

HyDE 관련성 차이는 +0.080점, Holm 보정 p=0.117이다.
CAD 충실도 차이는 +0.029점(SD 0.255), p=0.393이다.
SCD 문자 비율의 주·전체 비교는 모두 보정 p<0.001이다.
HyDE 비교에는 번역·가상 문서 샘플링의 차이가 포함된다.

07 결론

본 연구는 HyDE·CAD·SCD 조합별 답변 품질,
한국어 문자 비율 및 실행 시간을 평가하였다.
SCD는 한국어 문자 비율을 높였다(보정 p<0.001).
실행 시간의 H·C 주효과와 C×S 상호작용도 유의하였다.
적용 조건은 목표 언어, 품질 결과와 허용 시간으로 비교한다.

08 주요 참고문헌

[1] Lewis et al. RAG. NeurIPS, 2020.
[2] Gao et al. HyDE. ACL, 2023.
[3] Shi et al. Context-Aware Decoding. NAACL, 2024.
[4] Li et al. Language Drift and SCD. AAAI, 2026.
[5] Chen et al. M3-Embedding. ACL Findings, 2024.
[10] Es et al. RAGAs. EACL Demonstrations, 2024.

전체 22편과 통계 상세표·결측·민감도 분석은 동봉 자료에 수록

A1 594 × 841 mm