

한국어 질의-영어 학술·기술 문서 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 2021214556 · 동국대학교 WISE 캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

01 연구 배경과 선행연구: 한국어 질의-영어 문서

한국어 질문으로 영어 문서를 검색할 때의 쟁점

한국어 질문과 영어 원문의 표현 차이에 따른 검색 결과 비교

근거 충실도와 한국어 문자 비율을 각각 측정

HyDE의 검색 결과, CAD의 답변 품질, SCD의 출력 언어 비교


RQ1 검색	HyDE 적용 전후 검색 결과와 답변 품질은 어떻게 달라지는가
RQ2 생성	같은 문맥에서 CAD 적용 전후 답변 품질과 실행 시간은 어떻게 달라지는가
RQ3 언어	SCD 적용 전후 한국어 문자 비율은 어떻게 달라지는가
RQ4 조합	답변 품질, 한국어 문자 비율과 실행 시간으로 어떤 조건을 선택하는가

RAG [1]	관련 문맥을 검색하고 생성 모델에 입력하여 답변 생성 Paper-RAG의 검색과 생성 모델은 모든 조건에서 고정
HyDE [2]	한국어 질의를 영어로 번역해 가상 문서를 생성하고 벡터화 가상 문서 벡터로 밀집 검색, BM25와 재정렬은 한국어 질의 사용
CAD [3]	같은 모델에서 문맥을 포함한 입력과 제외한 입력의 로짓 계산 로짓을 $(1+\alpha)z_{ctx} - \alpha z_{noctx}$ 로 가중 결합
SCD [4]	한국어와 다른 언어 토큰의 로짓에 각각 계수를 곱함 한국어 로짓×1.1, 다른 언어×0.9. 중립 토큰과 첫 5토큰 유지

관련 연구: DPR[11], FiD[12], 긴 문맥[9], Self-RAG와 CRAG[15,16]

02 Paper-RAG 시스템 구조와 세 기법의 적용 위치


검색: 한국어 질문을 바탕으로 영어 문서에서 근거 검색



최종 평가와 분리한 튜닝 질의 5개로 검색 폭 선정

두 기법을 함께 적용하면 CAD($\alpha=0.5$) 계산 후 SCD 적용

03 RAG-Cube 실험 설계: 같은 질의에 8조건 적용



H: HyDE C: CAD S: SCD
60질의 × (2×2×2) = 480개 답변, 0=OFF / 1=ON

문서	RAG Survey[19], CAD[3], RAPTOR[14], Midm K 2.5 Pro[22]
질의 구성	초기 질문 3개로 표현과 범위 설정 → LLM으로 각 문서 주요 내용 요약 요약 15개 단위에서 질의 작성 → 문서별 15개, 총 60개 근거 확인
검색/융합	BGE-M3 + BM25 / RRF 가중치 0.6/0.4, k=60
재정렬/생성	cross-encoder/ms-marco-MiniLM-L-6-v2 / K-intelligence/Midm-2.0-Base-Instruct
후보/청크	검색 8개, 재정렬 8개, 문맥 5개; 청크 최대 512, 중첩 64, 최소 50단어
압축/디코딩	문맥 3,072단어 초과 시 압축(0.5); 탐욕적 디코딩, 최대 512토큰

질의 유형: 사실 및 정의 8, 방법 및 절차 29, 결과 및 비교 20, 목적 및 기어 3

04 평가 방법: 답변 품질과 출력 언어의 대응 비교

질의, 답변, 검색 문맥과 참조 답변으로 품질 평가. 한국어 문자 비율 별도 측정

RAGAS[10] 0.2.15: 평가 gpt-4o, 답변 관련성 임베딩 BGE-M3

근거 충실도	검색 문맥이 답변의 주장을 뒷받침하는 정도
답변 관련성	생성 답변이 질문의 요구에 대응하는 정도
문맥 정밀도	관련 근거가 검색 결과 상위에 배치된 정도
문맥 재현율	정답에 필요한 근거가 검색 문맥에 포함된 정도

SCD OFF	저장된 영어 검색 문맥으로 RAGAS 평가
SCD ON	영어 문맥을 gpt-4o로 한국어 번역한 뒤 RAGAS 평가

답변 생성에는 영어 문맥을 사용하며, 저장된 답변은 그대로 평가

SCD ON/OFF의 RAGAS 평균은 평가 문맥 언어가 달라 각각 제시

요인	비교 조건과 목적	유효 표본
HyDE	CAD와 SCD OFF, 검색 경로 변화 포함	60쌍
CAD	검색과 재정렬 청크 ID, 최종 문맥 동일	60쌍, 충실도 58쌍
SCD	주 비교 HyDE OFF 동일 문맥 / 전체 H/C 상태 일치	120 / 240쌍

HyDE OFF의 동일 문맥 120쌍을 주 비교로 사용. 전체 240쌍도 집계

한국어 문자 비율 = 한글 / (한글 + ASCII 영문자)

한글과 ASCII 영문자 수로 계산. 논문명과 모델명의 영어 표기도 포함

RAGAS 평가값 1,920개 중 1,915개 유효. 근거 충실도 5개 결측

평균 변화는 ON - OFF, 질의 단위 대응 부트스트랩 200,000회

문서 4종 고정, seed=20260713. 질의 단위 95% 신뢰구간

07 결론: 기법별 결과와 조건 선택

HyDE 적용 후 답변 관련성이 평균 +0.0805 증가

CAD 근거 충실도 평균 대응 차이 +0.0288. 95% 신뢰구간은 0 포함

H0S0에서 CAD 조건 실행 시간은 20.792초에서 63.867초로 증가

SCD 한국어 문자 비율은 HyDE OFF 동일 문맥 120쌍에서 평균 +0.2182 증가

답변 관련성, 근거 충실도, 한국어 문자 비율과 실행 시간으로 조건 선택

평가 범위: 영어 문서 4종, 한국어 질의 60개, 생성 모델 1종과 자동 평가

08 참고문헌

[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, Vol. 33, 2020.

[2] L. Gao et al., "Precise Zero-Shot Dense Retrieval without Relevance Labels," Proceedings of ACL, pp. 1762–1777, 2023.

[3] W. Shi et al., "Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding," Proceedings of NAACL, pp. 783–791, 2024.

[4] B. Li, Z. Xu, and R. Xie, "Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation," Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519–31526, 2026.

[5] J. Chen et al., "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318–2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson et al., "Okapi at TREC-3," Text REtrieval Conference, 1994.

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," Proceedings of SIGIR, pp. 758–759, 2009.

[8] R. Nogueira and K. Cho, "Passage Re-ranking with BERT," arXiv:1901.04085, 2019.

[9] N. F. Liu et al., "Lost in the Middle: How Language Models Use Long Contexts," Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157–173, 2024.

[10] S. Es et al., "RAGAs: Automated Evaluation of Retrieval Augmented Generation," Proceedings of EACL System Demonstrations, pp. 150–158, 2024.

[11] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proceedings of EMNLP, pp. 6769–6781, 2020.

[12] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proceedings of EACL, pp. 874–880, 2021.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286–12312, 2023.

[14] P. Santhi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S.-Q. Yan et al., "Corrective Retrieval Augmented Generation," arXiv:2401.15884, 2024.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, pp. 1–29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] D. Shin et al., "Midm 2.0 Korea-centric Bilingual Language Models," arXiv:2601.09066, 2026.

[19] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv:2312.10997, 2023.

[20] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[21] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EACL, pp. 2014–2037, 2023.

[22] KT Tech Innovation Group, "Midm K 2.5 Pro," technical report, arXiv:2603.18788v2, 2026.