

한국어 질의-영어 학술·기술 문서 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 2021214556 · 동국대학교 WISE 캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

01 연구 배경과 선행연구: 한국어 질의-영어 문서

한국어 질문으로 영어 문서를 검색할 때의 쟁점

한국어 질문과 영어 원문의 표현 차이에 따른 검색 결과 비교

근거 충실도와 한국어 문자 비율을 각각 측정

HyDE의 검색 결과, CAD의 답변 품질, SCD의 출력 언어 비교


RQ1 검색	HyDE 적용 전후 답변 관련성은 어떻게 달라지는가
RQ2 생성	같은 문맥에서 CAD 적용 전후 답변 품질과 실행 시간은 어떻게 달라지는가
RQ3 언어	SCD 적용 전후 한국어 문자 비율은 어떻게 달라지는가
RQ4 조합	관련성, 충실도, 한국어 비율과 실행 시간에 따라 어떤 조건을 선택하는가

RAG [1]	관련 문서를 검색해 생성 모델의 입력으로 제공하고 답변 생성 Paper-RAG의 검색과 생성 모델은 모든 조건에서 고정
HyDE [2]	한국어 질의를 영어로 번역해 가상 문서를 생성하고 벡터화 가상 문서 벡터로 밀집 검색, BM25와 재정렬은 한국어 질의 사용
CAD [3]	같은 모델의 문맥 포함 분포와 문맥 제외 분포를 비교 토큰 점수를 $(1+\alpha)z_{\text{ctx}} - \alpha z_{\text{noctx}}$ 로 조절
SCD [4]	토큰의 언어에 따라 생성 점수를 조절해 한국어 출력을 유도 CAD 후 한국어×1.1, 다른 언어×0.9; 중립 토큰과 첫 5토큰 유지

관련 연구: DPR[11], FiD[12], 긴 문맥[9], Self-RAG와 CRAG[15,16]

02 Paper-RAG 시스템 구조와 세 기법의 적용 위치


검색: 한국어 질문을 바탕으로 영어 문서에서 근거 검색



HyDE는 밀집 검색 입력을 바꾸며, CAD와 SCD는 생성 중 토큰 점수를 조정

CAD와 SCD 동시 적용 시 CAD($\alpha=0.5$) 후 SCD 적용; 같은 질의의 8조건 비교

03 RAG-Cube 실험 설계: 같은 질의에 8조건 적용



H: HyDE

C: CAD

S: SCD

60질의 × (2×2×2) = 480개 답변, 0=OFF / 1=ON

문서	RAG Survey[19], CAD[3], RAPTOR[14], Midm K 2.5 Pro[22]
질의 구성	초기 질문 3개로 질문 형식과 범위 설정 → LLM으로 문서 주요 내용 요약 요약을 15개 단위로 나뉜 질의 작성 → 각 질의의 원문 페이지와 근거 확인
검색/융합	BGE-M3 + BM25 / RRF 가중치 0.6/0.4, k=60
재정렬/생성	cross-encoder/ms-marco-MiniLM-L-6-v2 / K-intelligence/Midm-2.0-Base-Instruct
후보/청크	검색 8개, 재정렬 8개, 문맥 5개; 청크 최대 512, 중첩 64, 최소 50단어
압축/디코딩	문맥 3,072단어 초과 시 압축(0.5); 탐욕적 디코딩, 최대 512토큰

질의 유형: 사실/정의 8, 방법/절차 29, 결과/비교 20, 목적/기여 3

04 평가 방법: 답변 품질과 출력 언어의 대응 비교

질의, 답변, 검색 문맥과 참조 답변으로 품질 평가; 출력 언어는 한국어 문자 비율로 측정

RAGAS[10] 0.2.15: 평가 gpt-4o, 답변 관련성 임베딩 BGE-M3

근거 충실도	답변의 주장이 검색 문맥으로 지지되는 정도
답변 관련성	생성 답변이 질문의 요구에 대응하는 정도
문맥 정밀도	관련 근거가 검색 결과 상위에 배치된 정도
문맥 재현율	정답에 필요한 근거가 검색 문맥에 포함된 정도

SCD OFF	저장된 영어 검색 문맥으로 RAGAS 평가
SCD ON	gpt-4o로 한국어 변환한 문맥으로 RAGAS 평가

답변 생성에는 영어 문맥을 사용하며, 저장된 답변은 그대로 평가

SCD ON/OFF의 RAGAS 평균은 평가 문맥 언어가 달라 각각 제시

요인	비교 조건과 목적	유효 표본
HyDE	CAD와 SCD OFF, 검색 경로 변화 포함	60쌍
CAD	검색과 재정렬 청크 ID, 최종 문맥 동일	60쌍, 충실도 58쌍
SCD	주 비교 H0 동일 문맥 / 전체 H/C 상태 일치	120 / 240쌍

HyDE ON은 가상 문서 재생성으로 문맥이 달라질 수 있어, OFF 120쌍을 주 비교로 사용

한국어 문자 비율 = 한글 / (한글 + ASCII 영문자)

한글과 ASCII 영문자만 계산; 논문명과 모델명의 영어 표기도 반영

RAGAS 평가값 1,920개 중 1,915개 유효; 근거 충실도 5개 결측

평균 변화는 ON - OFF, 질의 단위 대응 부트스트랩 200,000회

문서 4종 고정, seed=20260713; 질의 단위 95% 신뢰구간

07 결론: 기법별 결과와 조건 선택

HyDE 적용 후 답변 관련성이 평균 +0.0805 증가

CAD 근거 충실도 변화 +0.0288; 95% 신뢰구간은 0 포함

CAD 조건 실행 시간은 20.792초에서 63.867초로 증가

SCD 한국어 문자 비율은 동일 문맥120쌍에서 평균 +0.2182 증가

답변 관련성, 근거 충실도, 한국어 문자 비율과 실행 시간으로 조건 선택

평가 범위: 영어 문서 4종, 한국어 질의 60개, 생성 모델 1종과 자동 평가

08 참고문헌

[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, Vol. 33, 2020.

[2] L. Gao et al., "Precise Zero-Shot Dense Retrieval without Relevance Labels," Proceedings of ACL, pp. 1762–1777, 2023.

[3] W. Shi et al., "Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding," Proceedings of NAACL, pp. 783–791, 2024.

[4] B. Li, Z. Xu, and R. Xie, "Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation," Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519–31526, 2026.

[5] J. Chen et al., "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318–2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson et al., "Okapi at TREC-3," Text REtrieval Conference, 1994.

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," Proceedings of SIGIR, pp. 758–759, 2009.

[8] R. Nogueira and K. Cho, "Passage Re-ranking with BERT," arXiv:1901.04085, 2019.

[9] N. F. Liu et al., "Lost in the Middle: How Language Models Use Long Contexts," Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157–173, 2024.

[10] S. Es et al., "RAGAs: Automated Evaluation of Retrieval Augmented Generation," Proceedings of EACL System Demonstrations, pp. 150–158, 2024.

[11] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proceedings of EMNLP, pp. 6769–6781, 2020.

[12] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proceedings of EACL, pp. 874–880, 2021.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286–12312, 2023.

[14] P. Santhi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S.-Q. Yan et al., "Corrective Retrieval Augmented Generation," arXiv:2401.15884, 2024.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, pp. 1–29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] D. Shin et al., "Midm 2.0 Korea-centric Bilingual Language Models," arXiv:2601.09066, 2026.

[19] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv:2312.10997, 2023.

[20] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[21] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EACL, pp. 2014–2037, 2023.

[22] KT Tech Innovation Group, "Midm K 2.5 Pro," technical report, arXiv:2603.18788v2, 2026.