한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 동국대학교 WISE캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

01 연구 배경과 목적

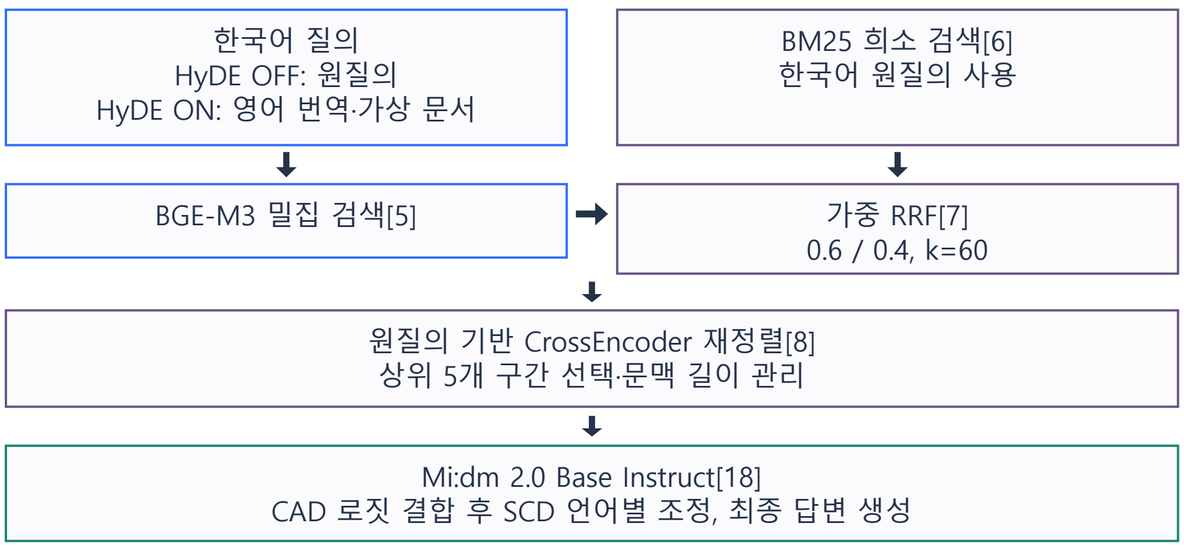
검색 증강 생성(Retrieval-Augmented Generation, RAG)은
관련 문서 구간을 검색하고 그 텍스트로 답변을 생성한다[1].

HyDE(Hypothetical Document Embeddings): 가상 문서 검색[2]
CAD(Context-Aware Decoding): 검색 근거의 영향 조정[3]
SCD(Soft Constrained Decoding): 출력 언어 제어[4]

한국어 질문에 맞는 영어 근거를 찾고 한국어로 답변하는 과정에서는 검색 관련성과 근거 활용·출력 언어를 함께 평가할 필요가 있다. 본 연구는 같은 파이프라인에서 세 기법의 적용 여부와 조합에 따른 결과를 비교한다.

02 Paper-RAG 구조와 기법 적용 위치

Paper-RAG는 본 연구의 고정 검색·생성 파이프라인이다.



03 3요인 완전요인 실험 설계

H=HyDE, C=CAD, S=SCD 0=미적용, 1=적용

조건	H	C	S
H0C0S0	0	0	0
H0C0S1	0	0	1
H0C1S0	0	1	0
H0C1S1	0	1	1
H1C0S0	1	0	0
H1C0S1	1	0	1
H1C1S0	1	1	0
H1C1S1	1	1	1

영어 문서 4종 × 15개 질의 × 8조건 = 480개 생성 기록

생성 512토큰, CAD α=0.5, SCD α=1.1·β=0.9·Tstart=5

문서 요약을 15개 내용 단위로 나누어 질의를 작성하고,
총 60개 질의의 원문 페이지·정답 근거·답변 가능성을 확인

04 평가 지표 및 실험·통계 방법

근거 충실도: 답변 주장 중 검색 근거가 뒷받침하는 비율
답변 관련성: 답변에서 만든 질문과 원질문의 의미 유사도
문맥 정밀도: 참조 답변에 유용한 구간의 상위 배치 정도
문맥 재현율: 참조 답변 주장을 검색 문맥이 포괄하는 비율
한국어 비율: 한글 / (한글 + ASCII 영문자)

품질 관측값은 0~1이며, 높은 값은 각 측정 특성이 큼을 뜻한다.
관련성 +0.080은 적용−미적용 평균 대응 점수 차이다.
한국어 비율 0.700은 70.0%, 차이 +0.218은 +21.8%p다.

평가 예시 ext_raptor_011, H0C0S0

질문: Cinderella 사례의 정성 분석에서 RAPTOR의
tree-based retrieval이 DPR보다 주제형·멀티홉
질문에 유리했던 이유는 무엇입니까?

근거 발췌: "RAPTOR selects nodes from different layers"
답변 발췌: "질문의 요구사항에 따라 서로 다른
층위(layer)에서 노드를 선택할 수 있습니다."

충실도 1.000: 평가자가 추출한 주장을 검색 문맥이 지지
관련성 0.937: 답변 기반 질문과 원질문의 평균 의미 유사도

평가: RAGAS 0.2.15[10], gpt-4o, BGE-M3 임베딩
S0: 영어 문맥 / S1: 한국어 번역 평가 문맥
생성에는 영어 문맥 사용, 저장 답변은 그대로 평가

3요인 반복측정 분산분석(ANOVA)·대응 t-검정, Holm·α=0.05
질의 60개, 품질 S별 H×C / 문자 비율·시간 H×C×S
SCD 120·240쌍은 질의별 평균 차이 60개로 검정

05 조합별 결과와 통계 검정

HyDE·CAD·SCD 8조합의 품질·한국어 비율·시간 평균(SD)

조건	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 비율	실행 시간
H0C0S0	0.791 (0.260)	0.683 (0.282)	0.749 (0.302)	0.933 (0.252)	0.494 (0.265)	20.792 (23.404)
H0C1S0	0.839 (0.201)	0.675 (0.261)	0.740 (0.302)	0.917 (0.279)	0.488 (0.245)	63.867 (25.312)
H1C0S0	0.834 (0.186)	0.763 (0.209)	0.714 (0.296)	0.933 (0.252)	0.556 (0.213)	23.440 (4.707)
H1C1S0	0.860 (0.181)	0.705 (0.248)	0.736 (0.271)	0.900 (0.303)	0.503 (0.229)	73.532 (21.584)
H0C0S1	0.787 (0.254)	0.637 (0.296)	0.763 (0.300)	0.900 (0.303)	0.699 (0.329)	18.898 (5.085)
H0C1S1	0.777 (0.270)	0.600 (0.321)	0.752 (0.301)	0.850 (0.360)	0.719 (0.218)	55.159 (26.465)
H1C0S1	0.822 (0.218)	0.710 (0.272)	0.743 (0.281)	0.900 (0.303)	0.807 (0.200)	24.892 (5.196)
H1C1S1	0.831 (0.253)	0.667 (0.286)	0.754 (0.267)	0.917 (0.279)	0.731 (0.209)	64.125 (21.675)

S0: 영어 평가 문맥 / S1: 한국어 번역 평가 문맥
충실도 H0C1S0 n=58, H0C0S1 n=57, 나머지 n=60
한국어 비율·시간(초)은 생성 기록에서 직접 계산

3요인 반복측정 ANOVA · 각 효과 df=(1,59)

요인	한국어 비율 F	보정 p	실행 시간 F	보정 p
H	2.924	0.370	16.362	<0.001
C	3.365	0.358	423.765	<0.001
S	341.302	<0.001	6.097	0.066
H×C	4.417	0.239	2.262	0.414
H×S	0.771	0.940	0.401	0.976
C×S	0.006	0.940	12.080	0.005
H×C×S	1.035	0.940	0.487	0.976

문자 비율·시간은 각각 7검정에 Holm 보정.
RAGAS H×C 검정은 평가 문맥 언어별로 수행했으며,
전체 24검정의 Holm 보정 p는 모두 0.05 이상이었다.

기법별 대응 비교 · 질의별 평균 차이, 양측 검정

비교	차이 (SD)	t(df)	보정 전 p	보정 후 p
HyDE 답변 관련성	0.080 (0.279)	2.236 (59)	0.029	0.117
CAD 근거 충실도	0.029 (0.255)	0.862 (57)	0.393	1.000
SCD H0 한국어 비율	0.218 (0.121)	13.951 (59)	<0.001	<0.001

HyDE: C0S0, CAD: H0S0, SCD: H0의 CAD 상태 평균
보정: HyDE·CAD 각 4지표, SCD 주·전체 비교 2검정
SCD 차이 +0.218은 한글 비중 +21.8%p에 해당

06 결과 해석

HyDE의 양의 관련성 차이는 다중비교 보정 결과와 함께 해석한다.
CAD는 질의별 충실도 변동과 추가 실행 시간을 함께 비교한다.
SCD의 효과는 생성 답변에서 한글이 차지하는 비중의 증가다.
시간의 C×S 상호작용은 SCD별 CAD 시간 증가가 다름을 뜻한다.

07 결론

답변 품질은 평균 대응 차이와 보정 검정 결과로 판단한다.
한국어 사용 비중을 높이는 목적에는 SCD 결과를 참고한다.
CAD 적용은 질의별 충실도와 추가 실행 시간을 함께 검토한다.
HyDE 적용은 번역·가상 문서 생성과 검색 결과를 함께 비교한다.
최종 조합은 목표 언어·품질·허용 시간을 기준으로 선택한다.

08 주요 참고문헌

[1] Lewis et al. RAG. NeurIPS, 2020.
[2] Gao et al. HyDE. ACL, 2023.
[3] Shi et al. Context-Aware Decoding. NAACL, 2024.
[4] Li et al. Language Drift and SCD. AAAI, 2026.
[5] Chen et al. M3-Embedding. ACL Findings, 2024.
[10] Es et al. RAGAs. EACL Demonstrations, 2024.

전체 22편과 통계 상세표·결측·민감도 분석은 동봉 자료에 수록

A1 594 × 841 mm