

한국어 질의-영어 학술·기술 문서 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 2021214556 · 동국대학교 WISE 캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

01 연구 배경과 선행연구: 한국어 질의-영어 문서

영어 논문에 한국어로 질문할 때 생기는 문제

한국어 질문과 영어 원문의 표현 차이가 검색에 미치는 영향 확인
검색한 근거를 답변에 얼마나 반영하는지, 한국어 출력을 유지하는지 확인
검색, 답변 생성과 출력 언어에서 세 기법의 적용 전후 비교


RQ1 검색	HyDE 적용 전후 답변 관련성은 어떻게 달라지는가
RQ2 생성	같은 문맥에서 CAD 적용 전후 품질과 시간은 어떻게 달라지는가
RQ3 언어	SCD 적용 전후 한국어 문자 비율은 어떻게 달라지는가
RQ4 조합	관련성, 충실도, 한국어 비율과 실행 시간에 따라 어떤 조건을 고르는가

RAG [1]	검색 증강 생성: 관련 문서를 검색해 답변 생성에 활용 Paper-RAG의 검색과 생성 모델은 모든 조건에서 고정
HyDE [2]	한국어 질문을 영어로 바꾸고 가상 문서를 생성해 벡터로 변환 벡터는 밀집 검색에 사용, BM25와 재정렬은 원래 질문 사용
CAD [3]	같은 모델의 문맥 포함 분포와 문맥 제외 분포를 비교 토큰 점수를 $(1+\alpha)z_{\text{ctx}} - \alpha z_{\text{noctx}}$ 로 조절
SCD [4]	토큰의 언어에 따라 생성 점수를 조절해 한국어 출력을 유도 CAD 후 한국어1.1, 비록표0.9 적용; 중립과 초기5생성단계 유지

관련 연구: DPR[11], FiD[12], 긴 문맥[9], 자기검증[15,16]


02 Paper-RAG 시스템 구조와 세 기법의 적용 위치

검색: 한국어 질문을 바탕으로 영어 문서에서 근거 검색



HyDE는 밀집 검색 전에 적용하며, CAD와 SCD는 생성 중 매 토큰의 점수를 조절
함께 쓰면 CAD($\alpha=0.5$) 다음 SCD 적용; 백본을 고정한 8조건의 답변을 같은 질의끼리 비교

03 RAG-Cube 실험 설계: 같은 질의에 8조건 적용



H: HyDE C: CAD S: SCD
60질의 × (2×2×2) = 480개 답변, 0=OFF / 1=ON

문서	RAG Survey[19], CAD[3], RAPTOR[14], Mi:dm K 2.5 Pro[22]
질의 구성	연구자가 초기 질문 3개로 표현과 범위 설정 → LLM 문서 요약을 15개 내용 단위로 구분 단위별 한국어 질의 1개 작성 → 문서별 15질의의 원문 페이지와 근거 확인
검색/융합	BGE-M3 + BM25 / RRF 가중치 0.6/0.4, k=60
재정렬/생성	cross-encoder/ms-marco-MiniLM-L-6-v2 / K-intelligence/Mi:dm-2.0-Base-Instruct
후보/청크	검색8 → 재정렬8 → 문맥5 / 청크 최대512단어, 중첩64, 최소50
압축/디코딩	문맥 한도3072단어, 초과 시 압축(비율0.5); argmax, 최대512토큰

질문 유형: 사실/정의8, 방법/절차29, 결과/비교20, 목적/기여3

04 평가 방법: 답변 품질과 출력 언어의 대응 비교

질의, 답변, 문맥과 정답으로 품질 평가; 한국어 문자 비율로 출력 언어 측정

RAGAS[10] 0.2.15: 평가 gpt-4o, 답변 관련성 임베딩 BGE-M3

근거 충실도	답변의 주장이 검색 문맥으로 지지되는 정도
답변 관련성	생성 답변이 질문의 요구에 대응하는 정도
문맥 정밀도	관련 근거가 검색 결과 상위에 배치된 정도
문맥 재현율	정답에 필요한 근거가 검색 문맥에 포함된 정도

SCD OFF	저장된 영어 검색 문맥으로 RAGAS 평가
SCD ON	gpt-4o로 한국어 변환한 문맥으로 RAGAS 평가

답변 생성에는 영어 문맥을 사용하며, 저장된 답변은 그대로 평가
SCD ON/OFF 품질 평균은 서로 다른 평가 문맥의 기술통계로 해석

요인	비교 조건과 목적	유효 표본
HyDE	CAD와 SCD OFF, 검색 경로 변화 포함	60쌍
CAD	검색/재정렬 ID와 최종 문맥이 동일	60 / 충실도58
SCD	HyDE OFF 동일 문맥 / HyDE와 CAD 상태 일치	120 / 240쌍

HyDE ON은 가상 문서 재생성으로 문맥이 달라질 수 있어, OFF 120쌍을 주 비교로 사용

한국어 문자 비율 = 한글 / (한글 + ASCII 영문자)

숫자와 기호는 제외하며, 논문 제목과 모델명의 혼합 표기는 포함

평가값 1,920개 중 1,915개 유효, 충실도 결측5개는 결측 유지

평균 변화는 ON - OFF, 질의 단위 대응 부트스트랩 200,000회

문서4중 고정, seed=20260713; 질의 수준의 95% 신뢰구간

07 결론: 기법별 결과와 조건 선택

HyDE 적용 후 답변 관련성이 평균 +0.0805 증가

CAD 충실도는 평균 +0.0288 변화했으며 95% 구간에 0 포함

CAD 주 비교의 조건 실행 시간은 20.792초에서 63.867초로 증가

SCD 한국어 문자 비율은 동일 문맥120쌍에서 평균 +0.2182 증가

관련성, 충실도, 한국어 문자 비율과 실행 시간을 기준으로 조건 선택

평가 범위: 영어 문서4중, 한국어 질의60개, 단일 생성 모델과 자동 평가

08 참고문헌

[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, Vol. 33, 2020.

[2] L. Gao et al., "Precise Zero-Shot Dense Retrieval without Relevance Labels," Proceedings of ACL, pp. 1762–1777, 2023.

[3] W. Shi et al., "Trusting Your Evidence: Hallucinate Less with Context-Aware Decoding," Proceedings of NAACL, pp. 783–791, 2024.

[4] B. Li, Z. Xu, and R. Xie, "Language Drift in Multilingual Retrieval-Augmented Generation: Characterization and Decoding-Time Mitigation," Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 40, No. 37, pp. 31519–31526, 2026.

[5] J. Chen et al., "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," Findings of the Association for Computational Linguistics: ACL 2024, pp. 2318–2335, 2024, doi: 10.18653/v1/2024.findings-acl.137.

[6] S. E. Robertson et al., "Okapi at TREC-3," Text REtrieval Conference, 1994.

[7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," Proceedings of SIGIR, pp. 758–759, 2009.

[8] R. Nogueira and K. Cho, "Passage Re-ranking with BERT," arXiv:1901.04085, 2019.

[9] N. F. Liu et al., "Lost in the Middle: How Language Models Use Long Contexts," Transactions of the Association for Computational Linguistics, Vol. 12, pp. 157–173, 2024.

[10] S. Es et al., "RAGAs: Automated Evaluation of Retrieval Augmented Generation," Proceedings of EAACL System Demonstrations, pp. 150–158, 2024.

[11] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proceedings of EMNLP, pp. 6769–6781, 2020.

[12] G. Izacard and E. Grave, "Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering," Proceedings of EAACL, pp. 874–880, 2021.

[13] X. L. Li et al., "Contrastive Decoding: Open-ended Text Generation as Optimization," Proceedings of ACL, pp. 12286–12312, 2023.

[14] P. Santhi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proceedings of ICLR, 2024.

[15] A. Asai et al., "Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection," Proceedings of ICLR, 2024.

[16] S.-Q. Yan et al., "Corrective Retrieval Augmented Generation," arXiv:2401.15884, 2024.

[17] P. Zhao et al., "Retrieval-Augmented Generation for AI-Generated Content: A Survey," Data Science and Engineering, Vol. 11, pp. 1–29, 2026, doi: 10.1007/s41019-025-00335-5.

[18] D. Shin et al., "Mi:dm 2.0 Korea-centric Bilingual Language Models," arXiv:2601.09066, 2026.

[19] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv:2312.10997, 2023.

[20] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," Proceedings of NeurIPS Datasets and Benchmarks Track, 2021.

[21] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," Proceedings of EAACL, pp. 2014–2037, 2023.

[22] KT Tech Innovation Group, "Mi:dm K 2.5 Pro," technical report, arXiv:2603.18788v2, 2026.