# 한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 동국대학교 WISE캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

## 01 연구 배경과 목적

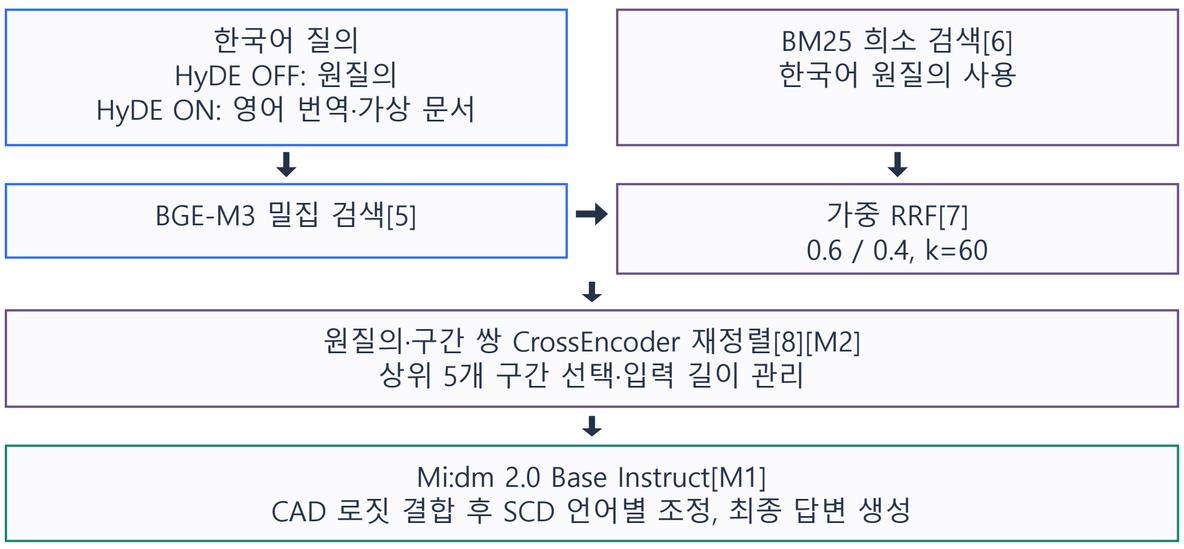
검색 증강 생성(Retrieval-Augmented Generation, RAG)은
관련 문서 구간을 검색하고 그 텍스트로 답변을 생성한다[1].

HyDE: 가상 문서 임베딩(Hypothetical Document Embeddings)
가상 문서 검색 입력 구성[2]
CAD: 문맥 인식 디코딩(Context-Aware Decoding)
검색 근거의 영향 조정[3]
SCD: 소프트 제약 디코딩(Soft Constrained Decoding)
출력 언어 제어[4]

**HyDE는 한국어를 포함한 다국어 검색에서 평가되었다[2].**
**한국어 질의–영어 문서 환경에서 HyDE·CAD·SCD의**
**개별 차이와 조합 효과를 같은 파이프라인에서 비교하였다.**

## 02 Paper-RAG 구조와 기법 적용 위치

Paper-RAG는 실험에 사용한 고정 검색·생성 파이프라인이다.




## 03 3요인 완전요인 실험 설계

H=HyDE, C=CAD, S=SCD 0=미적용, 1=적용

| 조건 | H | C | S |
|---|---|---|---|
| H0C0S0 | 0 | 0 | 0 |
| H0C0S1 | 0 | 0 | 1 |
| H0C1S0 | 0 | 1 | 0 |
| H0C1S1 | 0 | 1 | 1 |
| H1C0S0 | 1 | 0 | 0 |
| H1C0S1 | 1 | 0 | 1 |
| H1C1S0 | 1 | 1 | 0 |
| H1C1S1 | 1 | 1 | 1 |

**같은 질의 60개 × 8조건 반복측정 = 480개 생성 기록**

생성 512토큰, CAD α=0.5, SCD α=1.1·β=0.9·Tstart=5

문서 요약을 15개 내용 단위로 나누어 질의를 작성하고,
총 60개 질의의 원문 페이지·정답 근거·답변 가능성을 확인

## 04 평가 지표 및 실험·통계 방법

근거 충실도: 높을수록 검색 근거가 지지하는 답변 주장 비율이 크다.
답변 관련성: 높을수록 답변 기반 질문과 원질문의 의미가 가깝다.
문맥 정밀도: 높을수록 참조 답변에 유용한 구간이 상위에 놓인다.
문맥 재현율: 높을수록 검색 근거가 포괄하는 참조 답변 비중이 크다.
한국어 비율: 한글 / (한글 + ASCII 영문자), 높을수록 한글 비중이 크다.

품질 관측값은 0~1이다. 관련성 +0.080은 ON−OFF 평균 차이
0.080점이다. SD는 질의별 분포의 표본표준편차다.
한국어 비율 0.700은 70.0%, 차이 +0.218은 +21.8%p다.

**평가 예시 ext_raptor_011, H0C0S0**
질문: Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based
retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?
검색 근거(PDF p.9): "By providing both the original text and higher-level summaries
for retrieval, RAPTOR can effectively handle a wider range of
questions, from higher-order thematic queries to detail-oriented questions."
참조 답변 요지(PDF p.20): RAPTOR는 이야기의 주요 부분을,
DPR은 이야기의 좁은 일부를 자세히 검색한다.
생성 답변 발췌: "질문의 요구사항에 따라 서로 다른
층위(layer)에서 노드를 선택할 수 있습니다."
충실도 1.000: 추출된 답변 주장을 검색 결과가 모두 지지
관련성 0.937: 답변 기반 질문과 원질문의 평균 의미 유사도
평가: RAGAS 0.2.15[10]·gpt-4o·BGE-M3, 저장 답변 평가
평가 언어: S0 영어 / S1 한국어 번역, 생성 입력은 모두 영어

**반복측정 분산분석(ANOVA)·대응 t-검정, 양측 α=0.05**
**품질 S별 H×C / 문자·시간 H×C×S, SCD 120·240쌍→질의60**

## 05 조합별 결과와 통계 검정

**HyDE·CAD·SCD 8조합의 품질·한국어 비율·시간 평균(SD)**

| 조건 | 근거 충실도 | 답변 관련성 | 문맥 정밀도 | 문맥 재현율 | 한국어 비율 | 실행 시간 |
|---|---|---|---|---|---|---|
| H0C0S0 | 0.791 (0.260) | 0.683 (0.282) | 0.749 (0.302) | 0.933 (0.252) | 0.494 (0.265) | 20.792 (23.404) |
| H0C1S0 | 0.839 (0.201) | 0.675 (0.261) | 0.740 (0.302) | 0.917 (0.279) | 0.488 (0.245) | 63.867 (25.312) |
| H1C0S0 | 0.834 (0.186) | 0.763 (0.209) | 0.714 (0.296) | 0.933 (0.252) | 0.556 (0.213) | 23.440 (4.707) |
| H1C1S0 | 0.860 (0.181) | 0.705 (0.248) | 0.736 (0.271) | 0.900 (0.303) | 0.503 (0.229) | 73.532 (21.584) |
| H0C0S1 | 0.787 (0.254) | 0.637 (0.296) | 0.763 (0.300) | 0.900 (0.303) | 0.699 (0.329) | 18.898 (5.085) |
| H0C1S1 | 0.777 (0.270) | 0.600 (0.321) | 0.752 (0.301) | 0.850 (0.360) | 0.719 (0.218) | 55.159 (26.465) |
| H1C0S1 | 0.822 (0.218) | 0.710 (0.272) | 0.743 (0.281) | 0.900 (0.303) | 0.807 (0.200) | 24.892 (5.196) |
| H1C1S1 | 0.831 (0.253) | 0.667 (0.286) | 0.754 (0.267) | 0.917 (0.279) | 0.731 (0.209) | 64.125 (21.675) |

S0: 영어로 평가 / S1: 한국어 번역으로 평가
충실도 H0C1S0 n=58, H0C0S1 n=57, 나머지 n=60
한국어 비율·시간(초)은 생성 기록에서 직접 계산

**3요인 반복측정 ANOVA · 각 효과 df=(1,59)**

| 요인 | 한국어 비율 F | p | 실행 시간 F | p |
|---|---|---|---|---|
| H | 2.924 | 0.093 | 16.362 | <0.001 |
| C | 3.365 | 0.072 | 423.765 | <0.001 |
| S | 341.302 | <0.001 | 6.097 | 0.016 |
| H×C | 4.417 | 0.040 | 2.262 | 0.138 |
| H×S | 0.771 | 0.384 | 0.401 | 0.529 |
| C×S | 0.006 | 0.939 | 12.080 | <0.001 |
| H×C×S | 1.035 | 0.313 | 0.487 | 0.488 |

p<0.05: 한국어 비율 S·H×C / 실행 시간 H·C·S·C×S
RAGAS H×C 검정은 평가 언어별로 수행했으며,
품질 4지표 24검정의 p는 모두 0.05 이상이었다.

**기법별 대응 비교 · 질의별 평균 차이, 양측 검정**

| 비교 | 차이 (SD) | t(df) | p | dz |
|---|---|---|---|---|
| HyDE 답변 관련성 | 0.080 (0.279) | 2.236 (59) | 0.029 | 0.289 |
| CAD 근거 충실도 | 0.029 (0.255) | 0.862 (57) | 0.393 | 0.113 |
| SCD H0 한국어 비율 | 0.218 (0.121) | 13.951 (59) | <0.001 | 1.801 |

HyDE: C0S0, CAD: H0S0, SCD: H0의 CAD 상태 평균
p: 다중비교 보정 없는 양측 p, dz: 차이 평균/차이 SD
SCD 차이 +0.218은 한글 비중 +21.8%p에 해당
평균표 SD는 점수의 산포, 대응표 SD는 ON−OFF 차이의 산포

## 06 결과 해석

HyDE 관련성은 평균 +0.080점, t(59)=2.236, p=0.029였다.
CAD 충실도는 평균 +0.029점, t(57)=0.862, p=0.393이었다.
SCD 주 비교의 한국어 비율은 21.822%p 높았다(p<0.001).
CAD 시간 증가: SCD OFF +46.583초 / ON +37.747초.

## 07 결론

HyDE는 C0S0에서 관련성을 높였고(p=0.029), CAD 충실도 차이는 p=0.393이었다.
SCD는 같은 영어 근거에서 한국어 사용 비중을 높였다.
CAD는 실행 시간을 SCD 미적용 3.1배, 적용 2.7배로 늘렸다.
HyDE 비교에는 질의 번역과 가상 문서 생성이 함께 포함됐다.
후속 실험: 번역 단독 조건, 반복 생성·평가, 한국어 사람 평가.

## 08 주요 참고문헌

[1] Lewis et al. RAG. NeurIPS, 2020.
[2] Gao et al. HyDE. ACL, 2023.
[3] Shi et al. Context-Aware Decoding. NAACL, 2024.
[4] Li et al. Language Drift and SCD. AAAI, 2026.
[5] Chen et al. M3-Embedding. ACL Findings, 2024.
[6] Robertson et al. Okapi at TREC-3. NIST, 1995.
[7] Cormack et al. Reciprocal Rank Fusion. SIGIR, 2009.
[8] MacAvaney et al. CEDR. SIGIR, 2019.
[10] Es et al. RAGAs. EACL Demonstrations, 2024.

전체 참고문헌 22편과 모델·자료 출처는 논문의 참고문헌에 수록
영어 문서 4종 · 질의 60개 · 생성 모델 1종 · 질의별 반복측정
공식 모델 [M1] KT Mi:dm 2.0 / [M2] MiniLM CrossEncoder