한국어 질의 기반 영문 문서 검색 증강 생성(RAG)의 성능 개선 알고리즘 비교 분석

[학과] [학번] [이름], 지도교수 [지도교수]

01 연구 배경과 목적

- 한국어 질문으로 영어 문서를 찾아 한국어로 답하는 RAG[1]
- 질문과 원문의 어휘가 달라 근거 구간을 찾기 어려움
- 영어 근거를 한국어 답변에 충실히 옮기기 어려움
- 답변이 근거를 따라 영어로 바뀌는 언어 이탈이 생김
- 세 문제에 맞춘 HyDE, CAD, SCD를 조합해 같은 질문 60개에 적용
- 질문 유형별로 기법과 조합을 비교 분석해 적합한 조합을 고르는 기준 제시

HyDE(Hypothetical Document Embeddings), CAD(Context-Aware Decoding), SCD(Soft Constrained Decoding)

02 파이프라인

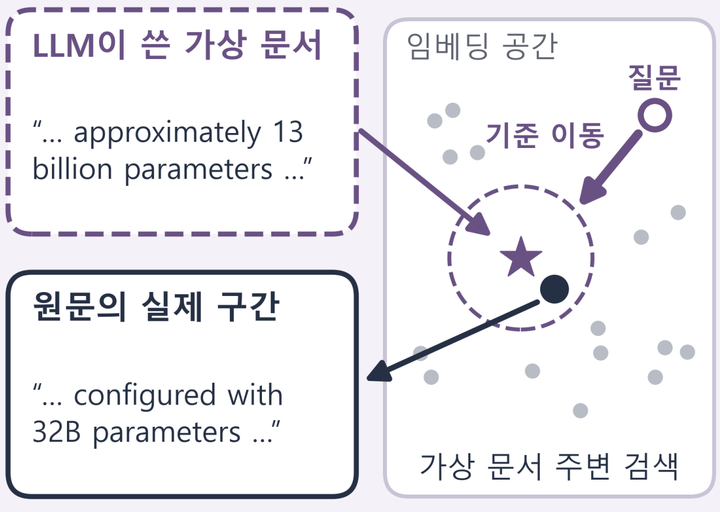


03 예시 질문으로 본 단독 기법의 작동

예시 질문 Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까? 정답 근거 32B parameters(원문 2쪽)

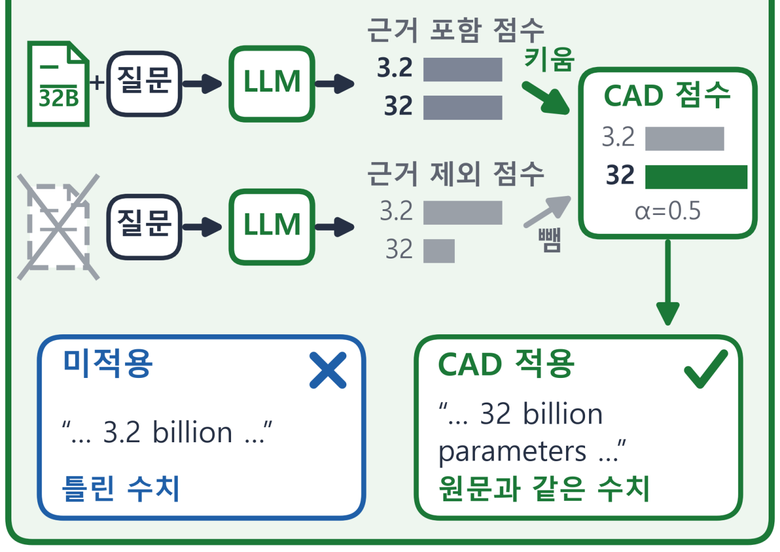
HyDE — Gao 외, ACL 2023 — 검색 단계

가상 문서로 실제 근거를 검색



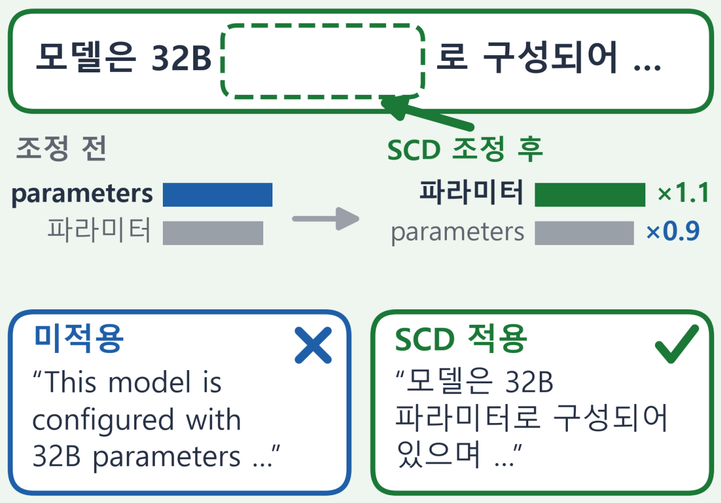
CAD — Shi 외, NAACL 2024 — 생성 단계

근거가 올린 토큰 점수를 키움



SCD — Li 외, AAAI 2026 — 생성 단계

언어별로 다른 계수를 토큰 점수에 곱함



답변 관련성 0.89에서 0.95 ▲ **근거 충실도 0.57에서 0.78 ▲** **한국어 문자 비율 0.64에서 0.83 ▲**

04 질문과 평가

- 영어 문서 네 종에서 15개씩, 한국어 질문 60개(수치 18, 방법 25, 개념과 결과 17)
- 세 기법의 적용 여부를 조합한 조건 8개, 답변 480개
- 생성 모델 Mi:dm 2.0 Base Instruct, 평가 모델 GPT-4o
- 다섯 지표의 관측값은 모두 0에서 1 사이, 한국어 문자 비율을 뺀 네 지표는 RAGAS(Retrieval Augmented Generation Assessment)[5]로 계산
- SCD를 적용한 조건 4, 6, 7, 8의 충실도, 정밀도, 재현율은 한국어로 번역한 입력 구간으로 평가해 SCD 적용 여부가 같은 조건끼리 비교

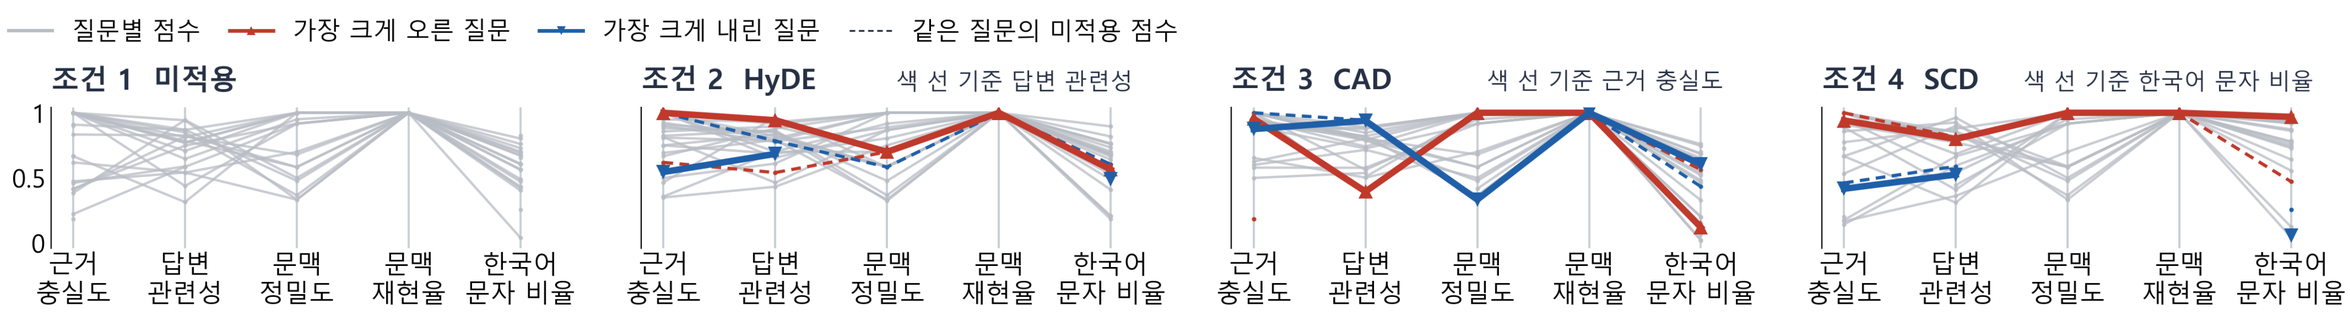
지표	측정 내용	값의 방향
근거 충실도	답변의 주장 중 입력 구간이 뒷받침하는 비율 값이 없는 방법 질문의 답변 5개는 평균에서 뺌	높을수록 근거에 충실
답변 관련성	답변에서 역으로 만든 질문과 원래 질문의 유사도 모호하거나 회피하는 답변은 0	높을수록 질문에 부합
문맥 정밀도	정답 근거에 유용한 구간의 순위가 높은 정도	높을수록 순위가 정확
문맥 재현율	정답 근거의 주장을 입력 구간이 뒷받침하는 비율	높을수록 정답 근거 확보
한국어 문자 비율	답변의 한글 문자 수 ÷ (한글 + ASCII 영문자 수)	높을수록 한국어 출력

05 질문 유형별 평균 점수

조건	근거 충실도			답변 관련성			문맥 정밀도			문맥 재현율			한국어 문자 비율		
	수치	방법	개념과 결과	수치	방법	개념과 결과	수치	방법	개념과 결과	수치	방법	개념과 결과	수치	방법	개념과 결과
1 미적용	0.83	0.73	0.85	0.74	0.57	0.78	0.67	**0.73**	**0.86**	**0.94**	0.88	**1.00**	0.58	0.46	0.46
2 HyDE	0.84	0.78	**0.90**	0.74	**0.74**	**0.82**	0.62	0.72	0.80	0.89	**0.96**	0.94	0.55	0.57	0.54
3 CAD	0.90	**0.83**	0.79	0.75	0.63	0.66	0.67	**0.73**	0.82	0.89	0.88	**1.00**	0.57	0.42	0.50
4 SCD	0.85	0.71	0.82	0.72	0.52	0.71	0.69	0.73	**0.90**	**0.89**	0.84	**1.00**	0.81	0.61	0.71
5 HyDE+CAD	**0.93**	0.80	0.88	**0.76**	0.63	0.75	**0.68**	**0.73**	0.80	**0.94**	0.84	0.94	0.52	0.46	0.55
6 HyDE+SCD	0.84	**0.83**	0.79	0.72	0.68	0.74	**0.71**	0.69	0.85	**0.89**	0.84	**1.00**	**0.83**	**0.79**	**0.81**
7 CAD+SCD	0.77	0.76	0.81	0.72	0.50	0.62	0.68	0.73	0.87	0.83	0.80	0.94	0.77	0.65	0.76
8 HyDE+CAD+SCD	**0.93**	0.76	**0.83**	0.67	0.65	0.69	0.68	**0.76**	0.81	0.78	**0.96**	**1.00**	0.74	0.69	0.79

- 굵은 값은 최댓값이며, 충실도, 정밀도, 재현율은 SCD 적용 여부가 같은 네 조건 안에서, 관련성과 한국어 문자 비율은 여덟 조건에서 구하고 최댓값과 같은 표시 값도 굵게 표시함

06 방법 질문 25개의 원점수 평행좌표



- HyDE 적용 후 관련성 축의 선이 위로 모이고 관련성 0점으로 선이 끊긴 답변이 5개에서 1개로 줄어듦

07 결론

- 답변 관련성이 중요하면 HyDE 하나만 적용
- 수치 질문에서 근거 충실도가 중요하면 HyDE+CAD 적용
- 한국어 답변이 중요하면 한국어 문자 비율이 가장 높은 HyDE+SCD 적용
- 한국어 답변이 중요한 수치 질문이면 세 기법 모두 적용
- 두 기법 이상 조합한 경우는 모두 답변 관련성이 HyDE만 쓸 때보다 낮음
- 모든 유형에서 일관되게 오른 지표는 SCD를 넣었을 때의 한국어 문자 비율뿐

[1] Lewis et al., RAG, NeurIPS 2020 [2] Gao et al., HyDE, ACL 2023 [3] Shi et al., CAD, NAACL 2024 [4] Li et al., SCD, AAAI 2026 [5] Es et al., RAGAs, EACL 2024