한국어 질의로 영어 학술·기술 문서를 검색하는 RAG에서의 HyDE·CAD·SCD 조합 실험

문종건 · 동국대학교 WISE캠퍼스 컴퓨터공학과 · 지도교수 김진석 · 2026.10.15

01 연구 배경과 목적

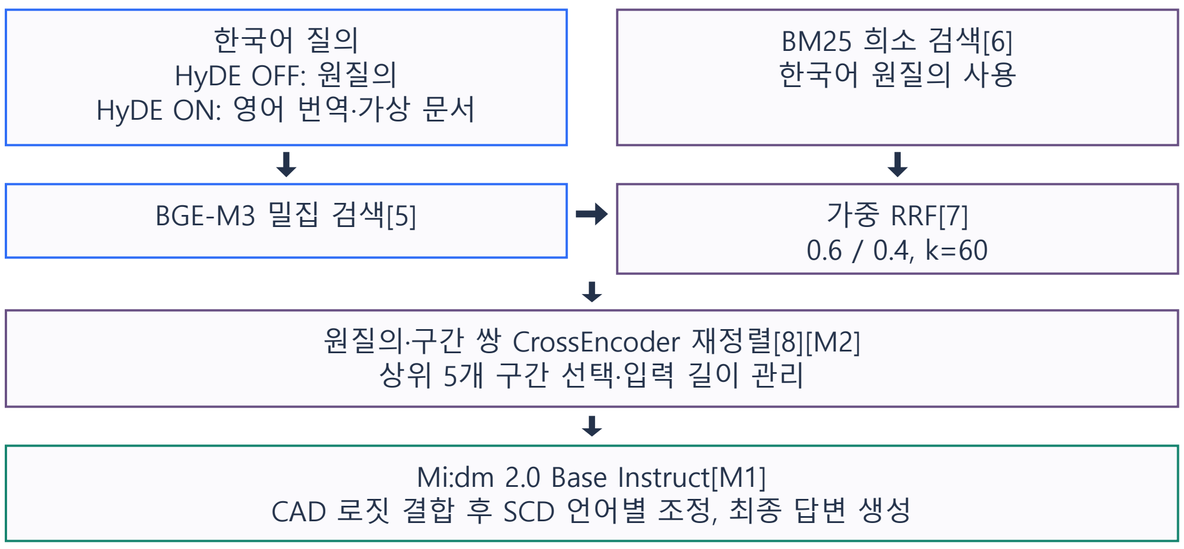
검색 증강 생성(Retrieval-Augmented Generation, RAG)은
관련 문서 구간을 검색하고 그 텍스트로 답변을 생성한다[1].

HyDE: 가상 문서 임베딩(Hypothetical Document Embeddings)
가상 문서 검색 입력 구성[2]
CAD: 문맥 인식 디코딩(Context-Aware Decoding)
검색 근거의 영향 조정[3]
SCD: 소프트 제약 디코딩(Soft Constrained Decoding)
출력 언어 제어[4]

HyDE는 한국어를 포함한 다국어 검색에서 평가되었다[2].
한국어 질의–영어 문서 환경에서 HyDE·CAD·SCD의
개별 차이와 조합 효과를 같은 파이프라인에서 비교하였다.

02 Paper-RAG 구조와 기법 적용 위치

Paper-RAG는 실험에 사용한 고정 검색·생성 파이프라인이다.



03 3요인 완전요인 실험 설계

H=HyDE, C=CAD, S=SCD 0=미적용, 1=적용

조건	H	C	S
H0C0S0	0	0	0
H0C0S1	0	0	1
H0C1S0	0	1	0
H0C1S1	0	1	1
H1C0S0	1	0	0
H1C0S1	1	0	1
H1C1S0	1	1	0
H1C1S1	1	1	1

같은 질의 60개 × 8조건 반복측정 = 480개 생성 기록

생성 512토큰, CAD α=0.5, SCD α=1.1·β=0.9·Tstart=5

문서 요약을 15개 내용 단위로 나누어 질의를 작성하고,
총 60개 질의의 원문 페이지·정답 근거·답변 가능성을 확인

04 평가 지표 및 실험·통계 방법

근거 충실도: 높을수록 검색 근거가 지지하는 답변 주장 비율이 크다.
답변 관련성: 높을수록 답변 기반 질문과 원질문의 의미가 가깝다.
문맥 정밀도: 높을수록 참조 답변에 유용한 구간이 상위에 놓인다.
문맥 재현율: 높을수록 검색 근거가 포괄하는 참조 답변 비중이 크다.
한국어 비율: 한글 / (한글 + ASCII 영문자), 높을수록 한글 비중이 크다.
품질 관측값은 0~1이다. 관련성 +0.080은 ON−OFF 평균 차이
0.080점이다. SD는 질의별 분포의 표본표준편차다.
한국어 비율 0.700은 70.0%, 차이 +0.218은 +21.8%p다.

평가 예시 ext_raptor_011, H0C0S0
질문: Cinderella 사례의 정성 분석에서 RAPTOR의 tree-based
retrieval이 DPR보다 주제형·멀티홉 질문에 유리했던 이유는 무엇입니까?
검색 근거(PDF p.9): "By providing both the original text and higher-level summaries
for retrieval, RAPTOR can effectively handle a wider range of
questions, from higher-order thematic queries to detail-oriented questions."
참조 답변 요지(PDF p.20): RAPTOR는 이야기의 주요 부분을,
DPR은 이야기의 좁은 일부를 자세히 검색한다.
생성 답변 발췌: "질문의 요구사항에 따라 서로 다른
층위(layer)에서 노드를 선택할 수 있습니다."
충실도 1.000: 추출된 답변 주장을 검색 결과가 모두 지지
관련성 0.937: 답변 기반 질문과 원질문의 평균 의미 유사도
평가: RAGAS 0.2.15[10]·gpt-4o·BGE-M3, 저장 답변 평가
평가 언어: S0 영어 / S1 한국어 번역, 생성 입력은 모두 영어

반복측정 분산분석(ANOVA)·대응 t-검정, 양측 α=0.05
품질: SCD 상태별 H×C / 한국어 비율·시간: H×C×S, SCD 대응쌍은 질의별 평균(n=60)

05 조합별 결과와 통계 검정

HyDE·CAD·SCD 8조합의 품질·한국어 비율·시간 평균(SD)

조건	근거 충실도	답변 관련성	문맥 정밀도	문맥 재현율	한국어 비율	실행 시간
H0C0S0	0.791 (0.260)	0.683 (0.282)	0.749 (0.302)	0.933 (0.252)	0.494 (0.265)	20.792 (23.404)
H0C1S0	0.839 (0.201)	0.675 (0.261)	0.740 (0.302)	0.917 (0.279)	0.488 (0.245)	63.867 (25.312)
H1C0S0	0.834 (0.186)	0.763 (0.209)	0.714 (0.296)	0.933 (0.252)	0.556 (0.213)	23.440 (4.707)
H1C1S0	0.860 (0.181)	0.705 (0.248)	0.736 (0.271)	0.900 (0.303)	0.503 (0.229)	73.532 (21.584)
H0C0S1	0.787 (0.254)	0.637 (0.296)	0.763 (0.300)	0.900 (0.303)	0.699 (0.329)	18.898 (5.085)
H0C1S1	0.777 (0.270)	0.600 (0.321)	0.752 (0.301)	0.850 (0.360)	0.719 (0.218)	55.159 (26.465)
H1C0S1	0.822 (0.218)	0.710 (0.272)	0.743 (0.281)	0.900 (0.303)	0.807 (0.200)	24.892 (5.196)
H1C1S1	0.831 (0.253)	0.667 (0.286)	0.754 (0.267)	0.917 (0.279)	0.731 (0.209)	64.125 (21.675)

S0: 영어로 평가 / S1: 한국어 번역으로 평가
충실도 H0C1S0 n=58, H0C0S1 n=57, 나머지 n=60
한국어 비율·시간(초)은 생성 기록에서 직접 계산

3요인 반복측정 ANOVA · 각 효과 df=(1,59)

요인	한국어 비율 F	p	실행 시간 F	p
H	2.924	0.093	16.362	<0.001
C	3.365	0.072	423.765	<0.001
S	341.302	<0.001	6.097	0.016
H×C	4.417	0.040	2.262	0.138
H×S	0.771	0.384	0.401	0.529
C×S	0.006	0.939	12.080	<0.001
H×C×S	1.035	0.313	0.487	0.488

p<0.05: 한국어 비율 S·H×C / 실행 시간 H·C·S·C×S
RAGAS H×C 검정은 평가 언어별로 수행했으며,
품질 4지표 24검정의 p는 모두 0.05 이상이었다.

기법별 대응 비교 · 질의별 평균 차이, 양측 검정

비교	차이 (SD)	t(df)	p	dz
HyDE 답변 관련성	0.080 (0.279)	2.236 (59)	0.029	0.289
CAD 근거 충실도	0.029 (0.255)	0.862 (57)	0.393	0.113
SCD H0 한국어 비율	0.218 (0.121)	13.951 (59)	<0.001	1.801

HyDE: C0S0, CAD: H0S0, SCD: H0의 CAD 상태 평균
p: 다중비교 보정 없는 양측 p, dz: 차이 평균/차이 SD
SCD 차이 +0.218은 한글 비중 +21.8%p에 해당
평균표 SD는 점수의 산포, 대응표 SD는 ON−OFF 차이의 산포

06 결과 해석

HyDE 관련성은 평균 +0.080점, t(59)=2.236, p=0.029였다.
CAD 충실도는 평균 +0.029점, t(57)=0.862, p=0.393이었다.
SCD 주 비교의 한국어 비율은 21.8%p 높았다(p<0.001).
CAD 시간 증가: SCD OFF +46.6초 / ON +37.7초.

07 결론

HyDE는 C0S0에서 관련성을 높였고(p=0.029), CAD 충실도 차이는 p=0.393이었다.
SCD는 같은 영어 근거에서 한국어 사용 비중을 높였다.
CAD는 실행 시간을 SCD 미적용 3.1배, 적용 2.7배로 늘렸다.
HyDE 비교에는 질의 번역과 가상 문서 생성이 함께 포함됐다.
후속 실험: 번역 단독 조건, 반복 생성·평가, 한국어 사람 평가.

08 주요 참고문헌

[1] Lewis et al. RAG. NeurIPS, 2020.
[2] Gao et al. HyDE. ACL, 2023.
[3] Shi et al. Context-Aware Decoding. NAACL, 2024.
[4] Li et al. Language Drift and SCD. AAAI, 2026.
[5] Chen et al. M3-Embedding. ACL Findings, 2024.
[6] Robertson et al. Okapi at TREC-3. NIST, 1995.
[7] Cormack et al. Reciprocal Rank Fusion. SIGIR, 2009.
[8] MacAvaney et al. CEDR. SIGIR, 2019.
[10] Es et al. RAGAs. EACL Demonstrations, 2024.

공식 모델 [M1] KT Mi:dm 2.0 / [M2] MiniLM CrossEncoder

전체 참고문헌 22편과 모델·자료 출처는 논문의 참고문헌에 수록

영어 문서 4종 · 질의 60개 · 생성 모델 1종 · 질의별 반복측정