한국어 질의 기반 영문 문서 검색 증강 생성(RAG)의 성능 개선 알고리즘 비교 분석

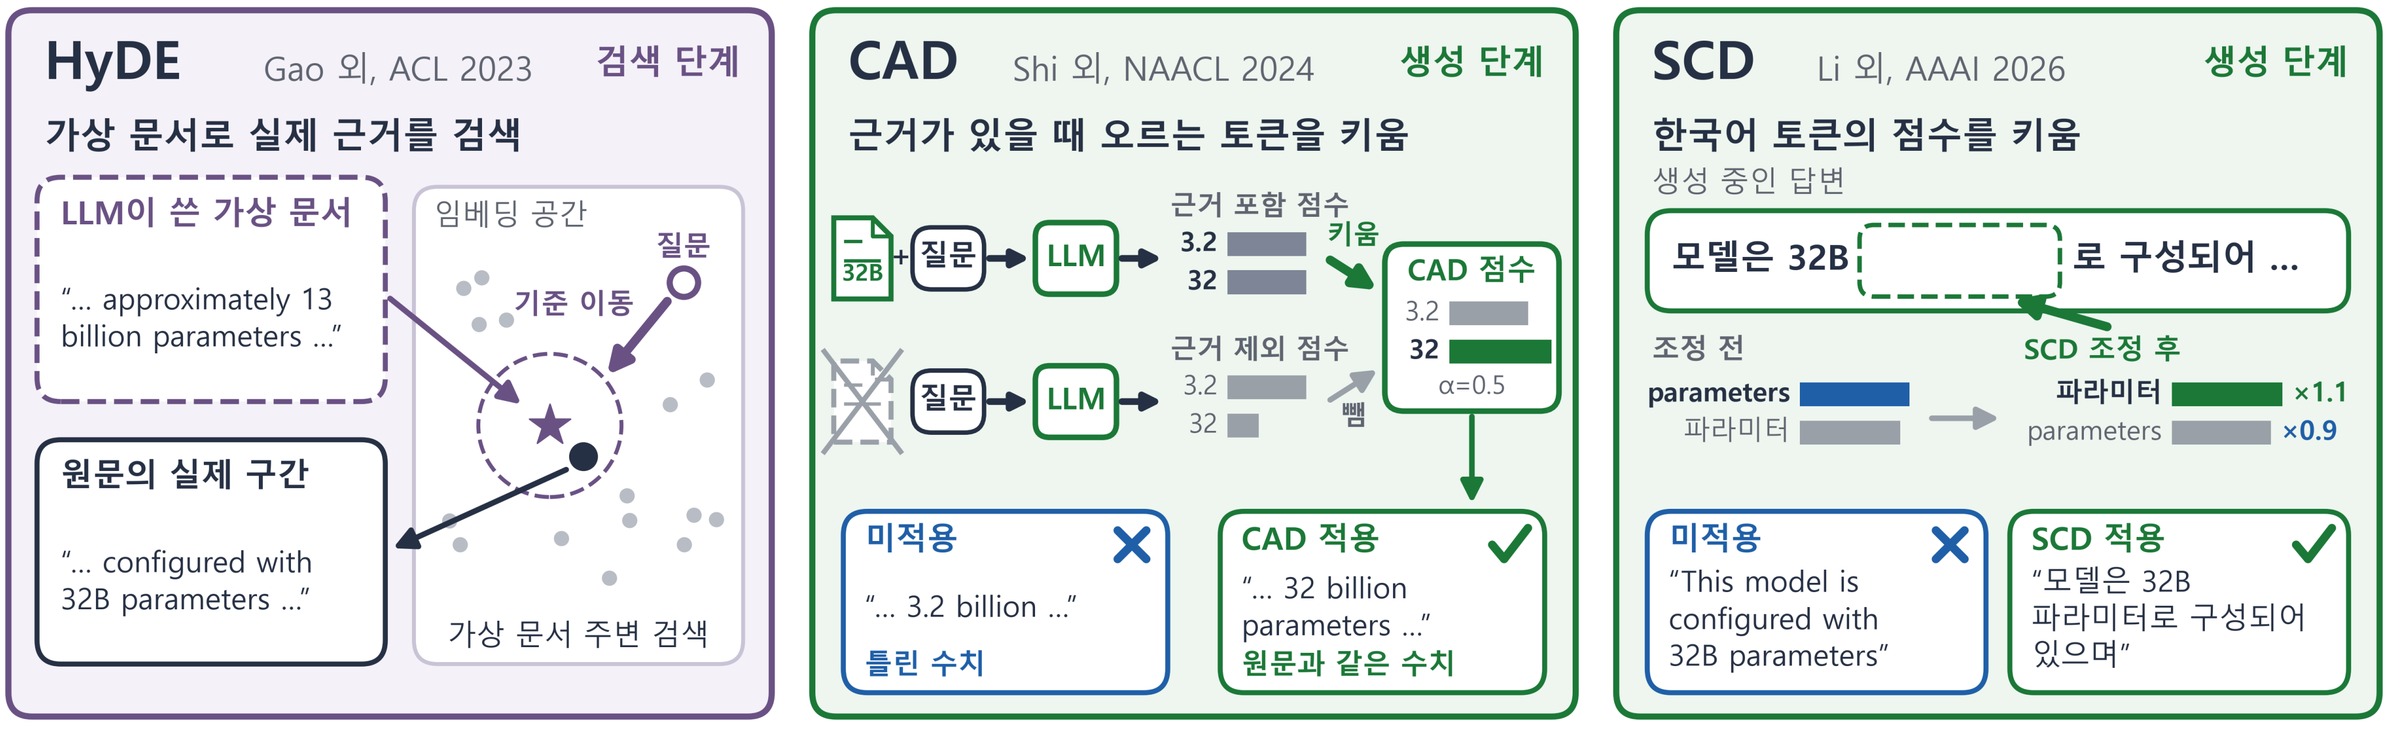
[학과] [학번] [이름], 지도교수 [지도교수]

01 연구 배경과 목적

- 한국어 질문으로 영어 문서를 찾아 한국어로 답하는 RAG
- 질문과 원문의 어휘가 달라 근거 구간을 찾기 어려움
- 영어 근거를 한국어 답변에 충실히 옮기기 어려움
- 답변이 근거를 따라 영어로 바뀌는 언어 이탈
- 세 문제에 맞춘 HyDE, CAD, SCD를 조합해 같은 질문 60개에 적용
- 질문 유형별로 기법과 조합을 비교 분석해 적합한 조합을 고르는 기준 제시

02 예시 질문으로 본 단독 기법의 작동

예시 질문 Mi:dm K 2.5 Pro 모델의 파라미터 수는 몇 개입니까? 정답 근거 32B parameters(원문 2쪽)



답변 관련성 0.89에서 0.95 ▲ **근거 충실도 0.57에서 0.78 ▲** **한국어 문자 비율 0.64에서 0.83 ▲**

HyDE Hypothetical Document Embeddings CAD Context-Aware Decoding SCD Soft Constrained Decoding 패널마다 미적용과 단독 적용 조건을 비교

03 질문과 평가

- 영어 문서 4종에서 15개씩, 한국어 질문 60개
- 수치 18개, 방법 25개, 개념과 결과 17개
- 세 기법의 적용 여부를 조합한 조건 8개, 답변 480개
- 지표값은 모두 0에서 1 사이, 한국어 비율을 뺀 네 지표는 RAGAS로 계산
- SCD를 적용한 조건 4, 6, 7, 8의 충실도, 정밀도, 재현율은 한국어로 번역한 근거로 평가해 SCD 적용 여부가 같은 조건끼리 비교

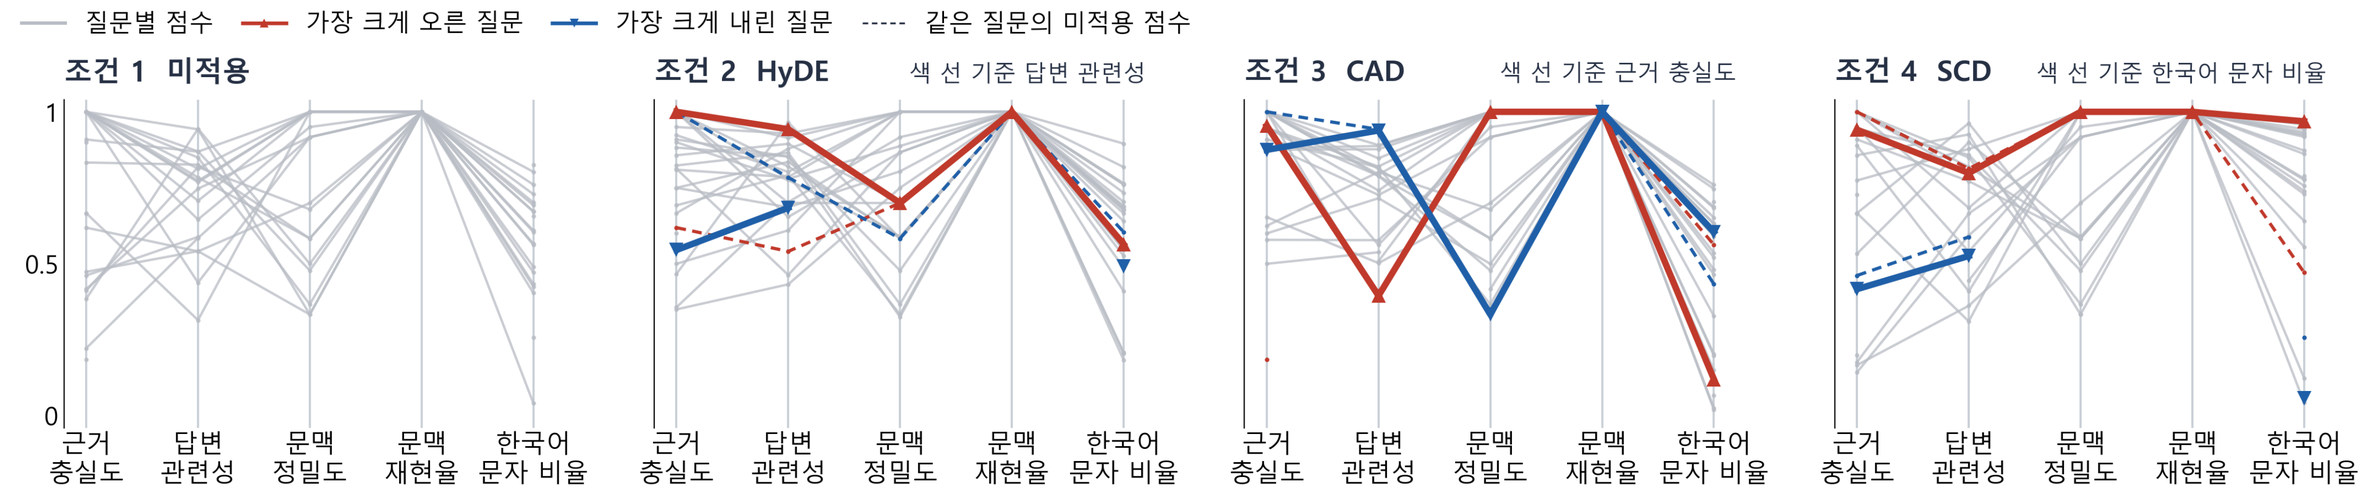
지표	측정 내용	값의 방향
근거 충실도	답변의 주장 중 검색 구간이 뒷받침하는 비율	높을수록 근거에 충실
답변 관련성	답변에서 역으로 만든 질문과 원래 질문의 유사도 모호하거나 회피하는 답변은 0	높을수록 질문에 부합
문맥 정밀도	참조 답변에 유용한 구간의 순위가 높은 정도	높을수록 순위가 정확
문맥 재현율	참조 답변의 주장을 검색 구간이 뒷받침하는 비율	높을수록 정답 근거 확보
한국어 문자 비율	답변의 한글 문자 수 ÷ (한글 + ASCII 영문자 수)	높을수록 한국어 출력

04 질문 유형별 평균 점수

조건	근거 충실도			답변 관련성			문맥 정밀도			문맥 재현율			한국어 문자 비율		
	수치	방법	개념과 결과	수치	방법	개념과 결과	수치	방법	개념과 결과	수치	방법	개념과 결과	수치	방법	개념과 결과
1 미적용	0.83	0.73	0.85	0.74	0.57	0.78	0.67	**0.73**	**0.86**	**0.94**	0.88	**1.00**	0.58	0.46	0.46
2 HyDE	0.84	0.78	**0.90**	0.74	**0.74**	**0.82**	0.62	0.72	0.80	0.89	**0.96**	0.94	0.55	0.57	0.54
3 CAD	0.90	**0.83**	0.79	0.75	0.63	0.66	0.67	**0.73**	0.82	0.89	0.88	**1.00**	0.57	0.42	0.50
4 SCD	0.85	0.71	0.82	0.72	0.52	0.71	0.69	0.73	**0.90**	**0.89**	0.84	**1.00**	0.81	0.61	0.71
5 HyDE+CAD	**0.93**	0.80	0.88	**0.76**	0.63	0.75	**0.68**	**0.73**	0.80	**0.94**	0.84	0.94	0.52	0.46	0.55
6 HyDE+SCD	0.84	**0.83**	0.79	0.72	0.68	0.74	**0.71**	0.69	0.85	**0.89**	0.84	**1.00**	**0.83**	**0.79**	**0.81**
7 CAD+SCD	0.77	0.76	0.81	0.72	0.50	0.62	0.68	0.73	0.87	0.83	0.80	0.94	0.77	0.65	0.76
8 HyDE+CAD+SCD	**0.93**	0.76	**0.83**	0.67	0.65	0.69	0.68	**0.76**	0.81	0.78	**0.96**	**1.00**	0.74	0.69	0.79

- 굵은 값은 최댓값이며, 충실도, 정밀도, 재현율은 SCD 적용 여부가 같은 네 조건 안에서, 관련성과 한국어 비율은 여덟 조건 전체에서 구함

05 방법 질문 25개의 원점수 평행좌표



- HyDE 적용 후 관련성 축의 선이 위로 모이고 관련성 0점 답변이 5개에서 1개로 줄어듦

06 결론

- 답변 관련성과 처리 시간이 중요하면 HyDE 하나만 적용
- 수치 질문에서 근거 충실도가 중요하면 HyDE+CAD 적용
- 한국어 답변이 중요하면 HyDE+SCD 적용, 한국어 비율이 가장 높음
- 두 기법 이상 조합한 경우는 모두 답변 관련성이 HyDE만 쓸 때보다 낮음
- 조합으로 일관되게 오른 지표는 SCD를 넣었을 때의 한국어 문자 비율뿐
- 세 기법을 모두 쓰면 수치 질문 충실도가 오르는 대신 처리 시간이 늘어남

[1] Lewis et al., RAG, NeurIPS 2020 [2] Gao et al., HyDE, ACL 2023 [3] Shi et al., CAD, NAACL 2024 [4] Li et al., SCD, AAAI 2026 [5] Es et al., RAGAs, EACL 2024